

# OPTIMISASI LANJUT DAN ANALISIS KONVEKS

MODUL BECKER 3: REDUKSI VARIANS UNTUK SAA  
EDISI BAHASA INDONESIA

Stephen Becker; catatan ketik oleh Mitchell Krock

Sumber dibekukan pada commit 98ed693, 24 Juni 2026

Terjemahan kerja bahasa Indonesia dari bagian terpilih *APPM5720Notes*.  
Materi sumber dipertahankan berdasarkan Lisensi MIT; terjemahan, koreksi, penghubung,  
latihan, dan solusi mandiri dilisensikan CC BY-SA 4.0.  
Edisi ini bukan karya resmi atau dukungan Stephen Becker, Mitchell Krock, University of  
Colorado Boulder, maupun pihak sumber lain.

# TENTANG MODUL INI

---

Modul ini menerjemahkan dan menyunting satu rentang terbatas dari berkas TeX

`TypedNotes/APPM5720Notes.tex`

dalam repositori Stephen Becker, *convex-optimization-class*, pada commit

`98ed6930084c435ba0f67  
5f7646ced1f2fd8729e.`

Catatan ketik sumber mengreditkan Mitchell Krock. Berkas sumber lengkap memiliki 130911 byte dan SHA-256

`dd2e209a05a6f993ccac3b7c32e46400  
5466b45c93237e96c85da56147466cb8.`

Rentang yang dipakai tepat baris 2971–2988. Irisan 18 baris tersebut memiliki 900 byte dalam pengodean UTF-8 dengan akhir baris LF dan SHA-256

`b81634bf07565fcf8d2774bea7b96e56  
5e5fdd76cf5e782c5e4eb6fb3268c5ed.`

Saksi bahasa Inggris yang membungkus irisan itu hanya dengan penanda batas berada dalam

`source/en/becker-03-variance-  
reduction-source.tex`

dengan 977 byte dan SHA-256

`66f243b97cd379b73d217c6a3e424db6  
88f8ace246852cb24f78108c53186607.`

---

Isi di antara penanda saksi cocok byte demi byte dengan irisan sumber beku.

Donor memperkenalkan SAGA, menyebut SAG dan SVRG, lalu memberi pernyataan laju linear dan catatan iterat rata-rata tanpa hipotesis yang diperlukan. Edisi ini mempertahankan batas sumber tersebut, memperbaiki klaim yang dapat ditentukan, dan menambahkan penghubung mandiri berupa bukti ketakbiasan, identitas varians, hasil laju yang bersyarat tepat, serta dua latihan dengan petunjuk dan solusi. Tidak ada algoritma, latihan, solusi, kode, atau gambar dari luar rentang beku yang diimpor.

Provenans produksi edisi: OpenAI Codex gpt-5.6-sol, Ultra, atas instruksi pengguna repositori; seluruh kredit sumber dan kontributor manusia tetap dipertahankan.

# DAFTAR ISI

---

|     |                                          |   |
|-----|------------------------------------------|---|
| 1   | REDUKSI VARIANS UNTUK SAA                | 1 |
| 1.1 | Tabel gradien dan penaksir SAGA          | 1 |
| 1.2 | Mengapa koreksi tabel mengurangi varians | 2 |
| 1.3 | Laju konvergensi dan iterat rata-rata    | 3 |
| 1.4 | Latihan dengan petunjuk dan solusi       | 3 |

# 1 REDUKSI VARIANS UNTUK SAA

---

Pertimbangkan masalah jumlah hingga dari aproksimasi rata-rata sampel (*sample average approximation*, SAA)

$$(1.1) \quad \min_{x \in \mathbb{R}^n} f(x), \quad f(x) = \frac{1}{N} \sum_{i=1}^N f_i(x),$$

dengan  $f$  bernilai hingga pada domain model. Sebagai contoh, untuk model dengan prediktor linear dan fungsi kerugian dapat dipakai

$$(1.2) \quad f_i(x) = \ell(a_i^\top x - b_i),$$

dengan  $\ell$  fungsi kerugian. Huruf  $\ell$  menggantikan huruf  $L$  pada donor agar tidak bertabrakan dengan konstanta kemulusan Lipschitz yang dipakai di bawah.

## 1.1 TABEL GRADIEN DAN PENAKSIR SAGA

Pilih iterat awal  $x_0$  dan inisialisasikan satu titik tabel  $\varphi_i^0 = x_0$  untuk setiap  $i = 1, \dots, N$ . Simpan, pada iterasi  $k \geq 0$ ,

$$(1.3) \quad g_i^k = \nabla f_i(\varphi_i^k), \quad \bar{g}_k = \frac{1}{N} \sum_{i=1}^N g_i^k.$$

Dengan  $x \in \mathbb{R}^n$ , tabel lengkap mempunyai  $N$  kolom gradien di  $\mathbb{R}^n$ . Ambil indeks acak  $J_k \sim \text{Unif}\{1, \dots, N\}$  dan bentuk

$$(1.4) \quad v_k = \nabla f_{J_k}(x_k) - g_{J_k}^k + \bar{g}_k.$$

Pembaruan SAGA tanpa suku proksimal adalah

$$(1.5) \quad x_{k+1} = x_k - t_k v_k.$$

Sesudah  $v_k$  dihitung dari tabel lama, hanya kolom terpilih yang disegarkan:

$$(1.6) \quad g_i^{k+1} = \begin{cases} \nabla f_i(x_k), & i = J_k, \\ g_i^k, & i \neq J_k, \end{cases} \quad \varphi_i^{k+1} = \begin{cases} x_k, & i = J_k, \\ \varphi_i^k, & i \neq J_k. \end{cases}$$

Ini menuliskan secara eksplisit inisialisasi dan urutan pembaruan yang hanya tersirat pada donor. Suku  $-g_{J_k}^k + \bar{g}_k$  merupakan peubah kontrol (*control variate*). Donor juga menyebut SAG dan SVRG; keduanya adalah metode reduksi varians lain, tetapi algoritmanya tidak diimpor dari bagian di luar rentang beku.

## 1.2 MENGAPA KOREKSI TABEL MENGURANGI VARIANS

### Penghubung mandiri.

Ambil  $\mathcal{F}_k$  sebagai informasi sebelum  $J_k$  ditarik, sehingga  $x_k$  dan seluruh tabel tetap ketika ekspektasi bersyarat dihitung.

**Proposisi 1.1** (Takbias bersyarat). Penaksir (1.4) memenuhi

$$(1.7) \quad \mathbb{E}[v_k \mid \mathcal{F}_k] = \nabla f(x_k).$$

*Bukti.* Keseragaman  $J_k$  memberi

$$\begin{aligned} \mathbb{E}[v_k \mid \mathcal{F}_k] &= \frac{1}{N} \sum_{i=1}^N (\nabla f_i(x_k) - g_i^k + \bar{g}_k) \\ &= \nabla f(x_k) - \bar{g}_k + \bar{g}_k = \nabla f(x_k). \end{aligned}$$

□

Lebih tepat lagi, tuliskan  $a_i^k = \nabla f_i(x_k) - g_i^k$  dan  $\bar{a}_k = N^{-1} \sum_i a_i^k$ . Maka

$$(1.8) \quad \mathbb{E}[\|v_k - \nabla f(x_k)\|_2^2 \mid \mathcal{F}_k] = \frac{1}{N} \sum_{i=1}^N \|a_i^k - \bar{a}_k\|_2^2 \leq \frac{1}{N} \sum_{i=1}^N \|a_i^k\|_2^2.$$

Identitas ini memperlihatkan mekanismenya: ketika gradien tersimpan mendekati gradien komponen pada iterat sekarang, ruas kanan menyusut meskipun langkah  $t_k$  tidak dipaksa menuju nol. Berbeda dari SAG, koreksi SAGA pada (1.4) membuat arah langkah takbias. SVRG mencapai gagasan serupa dengan gradien penuh pada titik acuan berkala, sehingga tidak menyimpan seluruh tabel gradien tetapi memakai evaluasi gradien tambahan.

### 1.3 LAJU KONVERGENSI DAN ITERAT RATA-RATA

Pernyataan donor “untuk  $t$  yang sesuai, metode ini konvergen secara linear” memerlukan hipotesis. Bentuk berikut adalah spesialisasi nonkomposit dari hasil SAGA oleh Defazio, Bach, dan Lacoste-Julien (2014).

**Teorema 1.2** (Laju linear SAGA dengan kekonveksan kuat). *Andaikan setiap  $f_i$  konveks, terdiferensial, dan mempunyai gradien  $L$ -Lipschitz. Andaikan pula  $f$  pada (1.1)  $\mu$ -konveks kuat dan mempunyai peminimum  $x^*$ . Jika seluruh titik tabel diinisialisasi pada  $x_0$  dan  $t_k = t = 1/(3L)$ , maka*

$$(1.9) \quad \mathbb{E}\|x_k - x^*\|_2^2 \leq \left(1 - \min\left\{\frac{1}{4N}, \frac{\mu}{3L}\right\}\right)^k C_0,$$

dengan

$$(1.10) \quad C_0 = \|x_0 - x^*\|_2^2 + \frac{2N}{3L}(f(x_0) - f(x^*)).$$

Konstanta dan laju pada teorema tersebut mengikuti hasil adaptivitas terhadap kekonveksan kuat dalam Defazio, Bach, dan Lacoste-Julien, SAGA (2014). Teorema donor tanpa hipotesis tidak dipertahankan sebagai klaim universal: tanpa kemulusan dan struktur konveks yang sesuai, laju linear tidak mengikuti hanya dari bentuk pembaruan.

Jika  $f$  hanya konveks, definisikan iterat rata-rata secara tidak ambigu sebagai

$$(1.11) \quad \bar{x}_k = \frac{1}{k} \sum_{r=1}^k x_r.$$

Di bawah asumsi konveks dan  $L$ -mulus di atas, dengan  $t = 1/(3L)$ , hasil yang sama memberi batas

$$(1.12) \quad \mathbb{E}[f(\bar{x}_k)] - f(x^*) \leq \frac{4N}{k} \left[ \frac{2L}{N} \|x_0 - x^*\|_2^2 + f(x_0) - f(x^*) \right].$$

Jadi perataan bukan jaminan tanpa syarat untuk laju yang lebih baik; dalam rezim konveks yang dinyatakan, ia menyediakan jaminan sublinear  $O(1/k)$  untuk nilai fungsi.

### 1.4 LATIHAN DENGAN PETUNJUK DAN SOLUSI

Latihan berikut merupakan materi baru untuk edisi ini; tidak ada latihan, petunjuk, atau solusi pada rentang donor.

**Latihan 1.3 (Takbias dan identitas varians).** Dengan  $a_i^k = \nabla f_i(x_k) - g_i^k$ , buktikan Proposisi 1.1 dan identitas (1.8). Jelaskan kapan varians bersyaratnya sama dengan nol.

**Petunjuk.** Gunakan  $v_k - \nabla f(x_k) = a_{J_k}^k - \bar{a}_k$  dan kembangkan kuadratnya.

**Solusi lengkap.** Keseragaman indeks memberi  $\mathbb{E}[a_{J_k}^k \mid \mathcal{F}_k] = \bar{a}_k$ , sehingga selisih tersebut bermean nol. Selanjutnya,

$$\begin{aligned} \mathbb{E}\|a_{J_k}^k - \bar{a}_k\|_2^2 &= \frac{1}{N} \sum_i \left( \|a_i^k\|_2^2 - 2 \langle a_i^k, \bar{a}_k \rangle + \|\bar{a}_k\|_2^2 \right) \\ &= \frac{1}{N} \sum_i \|a_i^k\|_2^2 - \|\bar{a}_k\|_2^2, \end{aligned}$$

yang sama dengan ruas tengah (1.8) dan tidak melebihi ruas kanannya. Variansnya nol tepat ketika semua  $a_i^k$  sama; khususnya, nol jika  $g_i^k = \nabla f_i(x_k)$  untuk semua  $i$ .

**Latihan 1.4 (Satu langkah kuadratik).** Ambil  $N = 2$ ,  $f_1(x) = \frac{1}{2}(x - 1)^2$ ,  $f_2(x) = \frac{1}{2}(x + 1)^2$ ,  $x_k = 2$ ,  $\varphi_1^k = 0$ , dan  $\varphi_2^k = 1$ . Hitung dua nilai mungkin bagi  $v_k$ , ekspektasi dan variansnya, lalu bandingkan dengan gradien stokastik biasa  $\nabla f_{J_k}(x_k)$ . Untuk  $t_k = 0,1$ , hitung pula dua iterat berikutnya.

**Petunjuk.**  $g_1^k = -1$ ,  $g_2^k = 2$ , dan  $\bar{g}_k = 1/2$ .

**Solusi lengkap.** Pada  $x_k = 2$ , gradien komponen adalah 1 dan 3. Oleh karena itu  $v_k = 1 - (-1) + 1/2 = 5/2$  jika  $J_k = 1$ , sedangkan  $v_k = 3 - 2 + 1/2 = 3/2$  jika  $J_k = 2$ . Maka  $\mathbb{E}[v_k] = 2 = \nabla f(2)$  dan  $\text{Var}(v_k) = \frac{1}{2}[(1/2)^2 + (-1/2)^2] = 1/4$ . Penaksir SGD biasa bernilai 1 atau 3, sehingga mean-nya juga 2 tetapi variansnya 1. Dengan  $t_k = 0,1$ , SAGA menghasilkan  $x_{k+1} = 1,75$  atau  $x_{k+1} = 1,85$ .

## CATATAN PERUBAHAN TERHADAP SUMBER

---

Perubahan berikut dibuat oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber.

- (i) Frasa donor “model terlinearisasi umum” diperjelas menjadi model dengan prediktor linear, sesuai bentuk  $a_i^\top x - b_i$  yang ditampilkan. Notasi fungsi kerugian donor  $L$  dinormalkan menjadi  $\ell$  agar tidak bertabrakan dengan konstanta gradien  $L$ -Lipschitz; frasa  $f(x) < \infty$  dijelaskan sebagai asumsi bernilai hingga pada domain model.
- (ii) Inisialisasi donor yang hanya menyebut  $x^{(1)}$  dilengkapi menjadi  $\varphi_i^0 = x_0$  untuk seluruh  $i$ , sehingga setiap kolom tabel gradien terdefinisi sebelum iterasi pertama.
- (iii) Titik tabel  $\varphi_i^k$ , gradien tersimpan  $g_i^k$ , rata-rata tabel, serta urutan penyegaran satu kolom ditulis terpisah. Ini menghilangkan ambiguitas indeks dan pembaruan serentak pada donor.
- (iv) Klaim laju linear donor dilengkapi dengan asumsi konveks, gradien  $L$ -Lipschitz, kekonveksan kuat  $\mu$ , langkah  $1/(3L)$ , dan laju eksplisit dari Defazio, Bach, dan Lacoste-Julien (2014). Klaim tanpa syarat tidak dipertahankan.
- (v) Notasi  $\bar{x}_k$  dinormalkan menjadi  $\bar{x}_k$  dan catatan perataan dilengkapi dengan asumsi serta batas  $\mathcal{O}(1/k)$ ; perataan tidak dinyatakan sebagai perbaikan universal.
- (vi) Bukti ketakbiasan bersyarat, identitas varians, dan perbandingan ringkas antara SAGA, SAG, dan SVRG merupakan teks penghubung mandiri, bukan terjemahan donor.
- (vii) Dua latihan, petunjuk, dan solusi lengkap merupakan materi baru edisi ini; rentang donor tidak memiliki permukaan penilaian tersebut.

## ATRIBUSI, HAK, DAN NONDUKUNGAN

---

Sumber: Stephen Becker, repositori *convex-optimization-class*, dengan catatan ketik *AP-PM5720Notes* oleh Mitchell Krock, commit 98ed6930084c435ba0f675f7646ced1f2fd8729e, [repositori sumber](#). Materi donor berada di bawah Lisensi MIT. Terjemahan bahasa Indonesia, penyusunan, rumusan koreksi, penghubung, latihan, petunjuk, dan solusi mandiri tersedia berdasarkan Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0), <https://creativecommons.org/licenses/by-sa/4.0/>. Lisensi komponen tetap terpisah; tidak ada lisensi yang menghapus kewajiban lisensi lainnya.

Hasil laju SAGA yang dipakai untuk memperbaiki hipotesis donor dikreditkan kepada Aaron Defazio, Francis Bach, dan Simon Lacoste-Julien, *SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives* (2014). Hanya fakta dan rumus matematis yang dinyatakan ulang secara mandiri; tidak ada prosa atau tata letak makalah tersebut yang disalin.

Stephen Becker, Mitchell Krock, Aaron Defazio, Francis Bach, Simon Lacoste-Julien, dan University of Colorado Boulder tidak menyusun, memeriksa, menyetujui, atau mendukung edisi ini. Penyebutan mereka semata-mata untuk atribusi karya sumber dan hasil matematis terkait.

## PEMBERITAHUAN LISENSI MIT SUMBER

---

### MIT License

Copyright (c) 2017 Stephen Becker

Permission is hereby granted, free of charge, to any person obtaining a copy of this software and associated documentation files (the "Software"), to deal in the Software without restriction, including without limitation the rights to use, copy, modify, merge, publish, distribute, sublicense, and/or sell copies of the Software, and to permit persons to whom the Software is furnished to do so, subject to the following conditions:

The above copyright notice and this permission notice shall be included in all copies or substantial portions of the Software.

THE SOFTWARE IS PROVIDED "AS IS", WITHOUT WARRANTY OF ANY KIND, EXPRESS OR IMPLIED, INCLUDING BUT NOT LIMITED TO THE WARRANTIES OF MERCHANTABILITY, FITNESS FOR A PARTICULAR PURPOSE AND NONINFRINGEMENT. IN NO EVENT SHALL THE AUTHORS OR COPYRIGHT HOLDERS BE LIABLE FOR ANY CLAIM, DAMAGES OR OTHER LIABILITY, WHETHER IN AN ACTION OF CONTRACT, TORT OR OTHERWISE, ARISING FROM, OUT OF OR IN CONNECTION WITH THE SOFTWARE OR THE USE OR OTHER DEALINGS IN THE SOFTWARE.