

Optimisasi Lanjut dan Analisis Konveks

Modul pendamping Bahasa Indonesia - Habring Bab 3-9

Checkpoint pembaca koheren ini menghimpun tujuh unit yang telah diterjemahkan dan divalidasi. Ini adalah modul pendamping parsial, bukan korpus utama D90 yang lengkap dan bukan klaim peninjauan oleh penulis sumber atau institusinya.

Isi

- Bab 3 - Subgradien
- Bab 4 - Metode Subgradien Terproyeksi
- Bab 5 - Metode Gradien Proksimal
- Bab 6 - Akselerasi
- Bab 7 - Dualitas
- Bab 8 - Penurunan Gradien Stokastik
- Bab 9 - Selingan tentang Transportasi Optimal

Hak dan atribusi

Terjemahan/adaptasi independen dari Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1. Materi turunan dan halaman pengantar ini disediakan di bawah Creative Commons Attribution 4.0 International (CC BY 4.0). Perubahan terjemahan, koreksi, dan penyusunan modul dinyatakan dalam berkas sumber dan ledger proyek. Tidak ada dukungan atau persetujuan penulis sumber yang tersirat.

Versi lengkap komponen, sumber, manifest, dan riwayat preservasi:

<https://doi.org/10.5281/zenodo.22059741>

Batas aksesibilitas: seluruh halaman dapat dicari dan dokumen mendeklarasikan bahasa id-ID, tetapi PDF belum bertanda semantik dan peninjauan manusia/penutur asli Bahasa Indonesia belum dicatat.

OPTIMISASI KONVEKS

UNIT 3: SUBGRADIEN
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 3, “Subgradients”, dari versi sumber yang ditentukan di atas. Bab-bab prasyarat tidak diulang. Pembaca diharapkan telah mengenal ruang bernorma dan ruang Hilbert, kekonveksan, epigraf, serta karakterisasi orde pertama fungsi konveks terdiferensialkan.

Notasi, rumus, urutan teorema, bukti, contoh, dan dua gambar sumber dipertahankan. Beberapa kekeliruan yang dapat ditentukan secara matematis diperbaiki secara terbuka; ringkasannya disertakan pada akhir unit dan rekaman terstruktur lengkap menyertai sumber edisi ini. Figur merupakan salinan persis aset sumber. Tidak ada layanan daring atau perangkat lunak tertutup yang diperlukan untuk membaca unit ini.

DAFTAR ISI

3	SUBGRADIEN	1
---	------------	---

3 SUBGRADIEN

Ingat kembali definisi turunan (Fréchet).

Sepanjang bab ini, X dan Y menyatakan ruang bernorma real; apabila gradien digunakan, X merupakan ruang Hilbert. Setiap kali V atau W muncul, keduanya menyatakan ruang bernorma real berdimensi hingga. Pada pasangan dual, argumen pertama selalu fungsional dan argumen kedua selalu vektor.

Definisi 3.1 (Turunan Fréchet). Misalkan $f : X \rightarrow Y$. Fungsi f dikatakan terdiferensialkan (dalam arti Fréchet) di $x \in X$ apabila terdapat pemetaan linear kontinu $A : X \rightarrow Y$ sedemikian sehingga

$$(3.1) \quad \lim_{\|h\| \rightarrow 0} \frac{\|f(x+h) - f(x) - Ah\|}{\|h\|} = 0.$$

Kita menuliskan $A = Df(x)$.

Definisi 3.2 (Gradien). Misalkan $f : X \rightarrow \mathbb{R}$ terdiferensialkan dan X merupakan ruang Hilbert. Gradien f di titik x , yang dilambangkan dengan $\nabla f(x)$, adalah unsur tunggal di X sedemikian sehingga

$$(3.2) \quad Df(x)h = \langle \nabla f(x), h \rangle, \quad h \in X.$$

Keberadaan dan ketunggalan gradien merupakan akibat langsung dari teorema representasi Riesz, sebab $Df(x) \in X^*$ apabila f bernilai real. Perhatikan pula bahwa **gradien bergantung pada hasil kali dalam yang dipilih**.

Walaupun definisi umum di atas mungkin tampak agak abstrak, gradien yang kita temui biasanya cukup sederhana. Secara khusus, apabila $X = \mathbb{R}^d$ dilengkapi dengan hasil kali dalam Euklides baku, maka

$$(3.3) \quad \nabla f(x) = Df(x)^T,$$

yaitu, gradien hanyalah transpos dari turunannya.

Turunan dapat ditafsirkan sebagai hampiran linear terbaik terhadap fungsi di suatu titik, yakni

$$(3.4) \quad f(y) = f(x) + Df(x)(y - x) + o(\|y - x\|),$$

dengan o kecil menyatakan suatu suku yang meluruh *lebih cepat daripada laju linear*. Kebanyakan metode optimisasi dapat ditafsirkan sebagai proses berulang untuk meminimumkan hampiran fungsi yang lebih mudah. Akan tetapi, banyak fungsi penting tidak memiliki gradien dalam pengertian di atas. Sebagai contoh, kita mungkin ingin menyelesaikan persoalan

$$(3.5) \quad \min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|Kx\|_1,$$

dengan A dan K linear. Persoalan komposit semacam ini sangat umum dalam pengolahan citra. Karena itu, kita dapat bertanya apakah terdapat gagasan hampiran linear yang lebih umum tetapi memiliki sifat serupa dengan gradien. Definisi berikut menjawab pertanyaan ini secara positif.

Definisi 3.3 (Subdiferensial). Misalkan $f : X \rightarrow (-\infty, \infty]$ dan $x \in \text{dom}(f)$. Kita menyebut $g \in X^*$ sebagai *subgradien* f di x apabila

$$(3.6) \quad f(x) + \langle g, y - x \rangle \leq f(y), \quad \forall y \in X.$$

Subdiferensial $\partial f(x)$ di x adalah himpunan semua subgradien di x , yakni

$$(3.7) \quad \partial f(x) = \{g \in X^* \mid f(x) + \langle g, y - x \rangle \leq f(y), \quad \forall y \in X\}.$$

Untuk $x \notin \text{dom}(f)$, kita menetapkan $\partial f(x) = \emptyset$.

Jadi, subdiferensial dapat saja kosong; menurut konvensi di atas, subdiferensial kosong di setiap titik $x \in X$ dengan $f(x) = \infty$.

Contoh 3.4.

(i) Norma: Misalkan $f = \|\cdot\|$. Maka

$$\partial f(0) = \overline{B}_{\|\cdot\|_*,1}(0),$$

yaitu bola satuan untuk norma dual. Ingat bahwa norma dual $\|\cdot\|_*$ didefinisikan oleh

$$\|y\|_* = \sup_{\|x\| \leq 1} |\langle y, x \rangle|.$$

Sebagai contoh, apabila $f = \|\cdot\|_1$ pada $\mathbb{R}^n$, maka

$$\partial f(0) = \overline{B}_{\|\cdot\|_\infty,1}(0) = [-1, 1]^n.$$

(ii) Untuk suatu himpunan tak kosong $S \subseteq X$ dan titik $x \in S$, tinjau fungsi indikator δ_S . Subdiferensialnya adalah

$$\partial \delta_S(x) = \{y \in X^* : \langle y, z - x \rangle \leq 0, \forall z \in S\} =: N_S(x),$$

yang disebut *kerucut normal* S di x . Subdiferensial fungsi indikator dari bola satuan adalah

$$N_{\overline{B}_{\|\cdot\|,1}(0)}(x) = \begin{cases} \{y \in X^* \mid \|y\|_* \leq \langle y, x \rangle\} & \text{jika } \|x\| \leq 1, \\ \emptyset & \text{jika } \|x\| > 1. \end{cases}$$

Kita perlu memastikan bahwa subdiferensial benar-benar memperumum gradien biasa.

Lema 3.5. Misalkan $f : X \rightarrow \mathbb{R}$ konveks dan terdiferensialkan di $x \in \text{dom}(f)^\circ$, dengan X ruang Hilbert. Maka $\partial f(x) = \{\nabla f(x)\}$.


Bukti. Kita perlu menunjukkan (i) $\nabla f(x) \in \partial f(x)$ dan (ii) jika $g \in \partial f(x)$, maka $g = \nabla f(x)$. Bagian (i) langsung mengikuti karakterisasi orde pertama untuk fungsi konveks terdiferensialkan, yang memberikan

$$(3.8) \quad f(x) + \langle \nabla f(x), y - x \rangle \leq f(y), \quad y \in X,$$

sehingga $\nabla f(x) \in \partial f(x)$. Untuk (ii), menurut definisi subgradien, bagi setiap $g \in \partial f(x)$, $h \in X$, dan $t > 0$ yang cukup kecil sehingga $x + th \in \text{dom}(f)$, berlaku

$$(3.9) \quad \langle g, h \rangle \leq \frac{f(x + th) - f(x)}{t}.$$

Dengan mengambil limit $t \rightarrow 0$, diperoleh $\langle g, h \rangle \leq \langle \nabla f(x), h \rangle$. Menerapkan ketaksamaan yang sama pada $-h$ memberikan ketaksamaan sebaliknya. Karena itu $\langle g, h \rangle = \langle \nabla f(x), h \rangle$ untuk setiap h , sehingga $g = \nabla f(x)$. $\square$



Gambar 3.1: Kiri: gradien sebagai kemiringan garis singgung. Kanan: sebuah subgradien sebagai kemiringan garis pendukung.

Dalam dimensi hingga, kebalikannya juga berlaku bagi fungsi konveks yang hingga pada suatu lingkungan titik x : jika subdiferensial di x hanya terdiri atas satu unsur, maka f terdiferensialkan di x dan $\partial f(x) = \{\nabla f(x)\}$.

Deskripsi gambar. Panel kiri memperlihatkan parabola halus dan satu garis singgung putus-putus pada titik yang ditandai. Panel kanan memperlihatkan grafik berbentuk V untuk norma satu dimensi dan tiga garis pendukung dengan kemiringan berbeda yang semuanya melalui titik sudut yang ditandai. Label matematis pada kedua figur dipertahankan persis dari aset sumber.

Contoh 3.6.

(i) Untuk $f(x) = \|x\|_2$, diperoleh

$$\partial f(x) = \begin{cases} \left\{ \frac{x}{\|x\|_2} \right\} & x \neq 0, \\ \overline{B}_{\|\cdot\|_2,1}(0) & \text{selain itu.} \end{cases}$$

(ii) Khususnya, untuk $d = 1$ dan $f(x) = |x|$, diperoleh

$$\partial f(x) = \begin{cases} \{\text{sign}(x)\} & x \neq 0, \\ [-1, 1] & \text{selain itu.} \end{cases}$$

Lema 3.7. *Jika domain $f : X \rightarrow (-\infty, \infty]$ konveks dan subdiferensialnya tak kosong di setiap titik dalam domain, maka f konveks.*

Bukti. Misalkan $x, y \in \text{dom } f$, $\lambda \in (0, 1)$, dan $g \in \partial f(x + \lambda(y - x))$. Menurut definisi subdiferensial,

$$(3.10) \quad f(x + \lambda(y - x)) + \langle g, x - (x + \lambda(y - x)) \rangle \leq f(x),$$

$$(3.11) \quad f(x + \lambda(y - x)) + \langle g, y - (x + \lambda(y - x)) \rangle \leq f(y),$$

atau, setara dengan itu,

$$(3.12) \quad f(x + \lambda(y - x)) + \langle g, -\lambda(y - x) \rangle \leq f(x),$$

$$(3.13) \quad f(x + \lambda(y - x)) + \langle g, (1 - \lambda)(y - x) \rangle \leq f(y).$$

Dengan membagi ketaksamaan pertama oleh λ , membagi yang kedua oleh $1 - \lambda$, lalu menjumlahkannya, diperoleh

$$(3.14) \quad \frac{1}{\lambda}f(x + \lambda(y - x)) + \frac{1}{1 - \lambda}f(x + \lambda(y - x)) \leq \frac{1}{\lambda}f(x) + \frac{1}{1 - \lambda}f(y).$$

Mengalikan dengan $\lambda(1 - \lambda)$ menghasilkan

$$(3.15) \quad f(x + \lambda(y - x)) \leq (1 - \lambda)f(x) + \lambda f(y),$$

sebagaimana yang diperlukan. □

Seperti disebutkan di atas, subdiferensial dapat kosong. Namun, bagi fungsi konveks berdimensi hingga kita mempunyai jaminan berikut.

Fungsi bernilai real diperluas disebut *sejati (proper)* apabila domain efektifnya tidak kosong dan fungsi itu tidak pernah bernilai minus tak hingga.

Teorema 3.8. Misalkan X ruang bernorma real berdimensi hingga dan $f : X \rightarrow \overline{\mathbb{R}}$ sejati dan konveks. Maka $\partial f(x) \neq \emptyset$ untuk setiap $x \in \text{dom}(f)^\circ$.

Sebelum membuktikan hasil ini, kita memerlukan beberapa persiapan.

Lema 3.9. Interior suatu himpunan konveks adalah konveks.

Bukti. Misalkan C konveks. Jika $C^\circ = \emptyset$, tidak ada yang perlu dibuktikan; jadi anggap $C^\circ \neq \emptyset$. Ambil $x, y \in C^\circ$ dan $\lambda \in (0, 1)$. Kita perlu menunjukkan bahwa $x_\lambda := \lambda x + (1 - \lambda)y \in C^\circ$. Terdapat $\varepsilon > 0$ sedemikian sehingga $B_\varepsilon(x), B_\varepsilon(y) \subset C^\circ$. Sekarang ambil $z \in B_\varepsilon(x_\lambda)$. Dengan demikian, $z = x_\lambda + h$ untuk suatu $\|h\| < \varepsilon$. Kita dapat menuliskan

$$(3.16) \quad z = \lambda x + (1 - \lambda)y + h = \lambda(x + h) + (1 - \lambda)(y + h).$$

Karena $x + h \in B_\varepsilon(x) \subset C$ dan $y + h \in B_\varepsilon(y) \subset C$, kekonveksan C memberikan $z \in C$. Jadi $B_\varepsilon(x_\lambda) \subset C$ dan $x_\lambda \in C^\circ$. $\square$

Lema 3.10. Jika $C \subset \mathbb{R}^d$, $d \geq 1$ konveks dan $C^\circ = \emptyset$, maka terdapat hiperbidang H sedemikian sehingga $C \subset H$.

Bukti. Jika C kosong, sembarang hiperbidang memenuhi kesimpulan. Selanjutnya anggap C tak kosong. Tanpa mengurangi keumuman, kita boleh menganggap $0 \in C$. Jika tidak, pilih sembarang $x_0 \in C$ dan tinjau $\tilde{C} = C - x_0$; pada akhir bukti, hiperbidang yang diperoleh ditranslasikan kembali.

Kita akan menunjukkan bahwa C merupakan himpunan bagian suatu subruang berdimensi paling besar $d - 1$. Andaikan sebaliknya bahwa C memuat d unsur yang bebas linear, yaitu terdapat $x_1, \dots, x_d \in C$ yang bebas linear. Karena C konveks, selubung konveks

$$(3.17) \quad \text{conv}((x_i)_i) = \left\{ \sum_{i=1}^d \lambda_i x_i \mid \lambda \in \Delta^d \right\}$$

juga merupakan himpunan bagian C . Kita mengklaim bahwa $x_\star := \frac{1}{2d} \sum_{i=1}^d x_i \in C^\circ$. Pertama, dari kekonveksan,

$$x_\star = \frac{1}{2d} \sum_{i=1}^d x_i = \sum_{i=1}^d \frac{1}{2d} x_i + \frac{1}{2} 0 \in C.$$

Karena x_i bebas linear, setiap $h \in \mathbb{R}^d$ dapat ditulis sebagai $h = \sum_i \lambda_i x_i$. Pemetaan $\lambda \mapsto h$ adalah pemetaan linear bijektif $\mathbb{R}^d \rightarrow \mathbb{R}^d$. Oleh karena itu terdapat $\varepsilon > 0$ sedemikian sehingga $\|h\| < \varepsilon$ mengakibatkan $|\lambda_i| < \frac{1}{2d}$ untuk semua i . Khususnya, $\frac{1}{2d} + \lambda_i \in [0, 1]$ dan $\sum_{i=1}^d (\frac{1}{2d} + \lambda_i) \in [0, 1]$. Akibatnya, untuk setiap $\|h\| < \varepsilon$,

$$(3.18) \quad x_\star + h = \sum_{i=1}^d \left(\frac{1}{2d} + \lambda_i \right) x_i + \left(1 - \sum_{i=1}^d \left(\frac{1}{2d} + \lambda_i \right) \right) 0 \in C.$$

Jadi, apabila C memuat d unsur bebas linear, interiornya tidak mungkin kosong, sebab $B_\varepsilon(x_\star) \subset C$. Ini bertentangan dengan asumsi. Maka C memuat paling banyak $d - 1$ unsur bebas linear. Pilih himpunan bebas linear maksimal $x_1, \dots, x_k$ di dalam C ; maksimalitas memberikan

$$C \subset \text{span}\{x_i \mid i = 1, \dots, k\}.$$

Dimensi subruang ini kurang dari d , sehingga subruang tersebut termuat dalam suatu hiperbidang. Setelah translasi balik bila diperlukan, diperoleh hiperbidang afin yang memuat himpunan semula. $\square$

Dengan kedua hasil sebelumnya, kita dapat membuktikan teorema hiperbidang pendukung.

Teorema 3.11 (Teorema hiperbidang pendukung). *Misalkan V ruang bernorma real berdimensi hingga, $C \subset V$ tak kosong dan konveks, serta $x_0 \in \partial C = \overline{C} \setminus C^\circ$ ¹. Maka terdapat $a \in V^*$, $a \neq 0$, sedemikian sehingga*

$$(3.19) \quad \langle a, v \rangle \leq \langle a, x_0 \rangle, \quad v \in C.$$

Bukti. Hasil ini merupakan akibat teorema pemisahan Hahn–Banach. Kita membedakan dua kasus. Pertama, andaikan $C^\circ \neq \emptyset$. Himpunan C° terbuka, konveks, dan tak kosong. Teorema pemisahan Hahn–Banach dapat diterapkan pada C° dan $\{x_0\}$, sehingga ketaksamaan pendukung berlaku pada interior. Karena $C \subset \overline{C^\circ}$ dan fungsional pemisah kontinu, ketaksamaan itu meluas ke seluruh C .

Sebaliknya, jika C° kosong, lema sebelumnya memberikan hiperbidang afin H yang memuat C . Karena H tertutup dan $x_0 \in \overline{C}$, hiperbidang ini juga memuat titik batas tersebut. Ambil $a \in V^*$ yang tak nol dan $b \in \mathbb{R}$ sedemikian sehingga

$$H = \{x \mid \langle a, x \rangle = b\}.$$

Fungsional a ini memenuhi (3.19). $\square$

Sekarang kita dapat membuktikan keberadaan subgradien.

Bukti teorema 3.8. Kita ingin menunjukkan bahwa terdapat $g \in X^*$ sedemikian sehingga

$$(3.20) \quad f(x) + \langle g, y - x \rangle \leq f(y)$$

untuk semua $y \in X$. Ini setara dengan

$$(3.21) \quad \langle g, y \rangle - f(y) \leq \langle g, x \rangle - f(x).$$

¹yakni batas C

Bentuk ini menyerupai struktur pemisahan Hahn–Banach. Agar dapat menggunakannya, kita beralih ke epigraf. Perhatikan bahwa $(x, f(x)) \in \partial \text{epi}(f)$. Selain itu, kekonveksan f mengakibatkan $\text{epi}(f)$ konveks. Dengan menerapkan teorema hiperbidang pendukung, diperoleh unsur tak nol $(g, -\alpha) \in (X \times \mathbb{R})^* = X^* \times \mathbb{R}$ sedemikian sehingga²

$$(3.22) \quad \langle (g, -\alpha), (y, t) \rangle \leq \langle (g, -\alpha), (x, f(x)) \rangle, \quad (y, t) \in \text{epi}(f).$$

Ini setara dengan

$$(3.23) \quad \langle g, y \rangle - \alpha t \leq \langle g, x \rangle - \alpha f(x), \quad (y, t) \in \text{epi}(f).$$

Kita akan menunjukkan bahwa $\alpha > 0$. Andaikan $\alpha < 0$. Karena $(x, t) \in \text{epi}(f)$ untuk setiap $t > f(x)$, kita dapat membiarkan $t \rightarrow \infty$ dan memperoleh kontradiksi. Berikutnya, andaikan $\alpha = 0$. Maka

$$(3.24) \quad \langle g, y - x \rangle \leq 0$$

bagi semua $y \in \text{dom}(f)$. Karena $x \in \text{dom}(f)^\circ$, hal ini memaksa $g = 0$. Padahal teorema pemisahan menghasilkan unsur pemisah yang tak nol; sekali lagi kita memperoleh kontradiksi. Jadi $\alpha > 0$, dan kita dapat membagi (3.22) dengan α untuk memperoleh

$$(3.25) \quad \langle \tilde{g}, y \rangle - t \leq \langle \tilde{g}, x \rangle - f(x), \quad (y, t) \in \text{epi}(f),$$

dengan $\tilde{g} = g/\alpha$. Memilih $t = f(y)$ memberikan $\tilde{g} \in \partial f(x)$. □

Seperti pada turunan biasa, kita dapat menurunkan beberapa aturan hitung untuk memperoleh subgradien dalam praktik.

Teorema 3.12. Misalkan $f : V \rightarrow \mathbb{R}$ sejati dan konveks serta $\alpha \geq 0$. Maka, untuk setiap $x \in \text{dom}(f)$,

$$\partial(\alpha f)(x) = \alpha \partial f(x).$$

Bukti. Latihan. □

Teorema 3.13. Misalkan $f, g : V \rightarrow \mathbb{R}$ sejati dan konveks. Untuk setiap $x \in \text{dom}(f) \cap \text{dom}(g)$, berlaku

$$\partial f(x) + \partial g(x) \subset \partial(f + g)(x).$$

Selain itu, jika terdapat $x_0 \in \text{dom}(f)^\circ \cap \text{dom}(g)$, maka

$$\partial f(x) + \partial g(x) = \partial(f + g)(x).$$

²Tanda minus pada $-\alpha$ dipilih untuk memudahkan perhitungan.

Bukti. Kita hanya membuktikan inklusi pertama. Bukti arah kedua sedikit lebih rumit dan menggunakan teorema pemisahan Hahn–Banach dengan cara yang serupa dengan bukti keberadaan subgradien.

Ambil $p_1 \in \partial f(x)$ dan $p_2 \in \partial g(x)$, yaitu

$$(3.26) \quad \begin{aligned} f(x) + \langle p_1, y - x \rangle &\leq f(y), \\ g(x) + \langle p_2, y - x \rangle &\leq g(y). \end{aligned}$$

Menjumlahkan kedua ketaksamaan memberikan

$$(3.27) \quad f(x) + g(x) + \langle p_1 + p_2, y - x \rangle \leq f(y) + g(y),$$

sehingga $p_1 + p_2 \in \partial(f + g)(x)$. □

Terakhir, kita mencatat beberapa *aturan hitung* subdiferensial tanpa bukti.

Teorema 3.14. Misalkan $f : W \rightarrow \overline{\mathbb{R}}$ sejati, konveks, dan semikontinu bawah, serta $A : V \rightarrow W$ transformasi linear. Definisikan $h(x) = f(Ax + b)$ untuk $b \in W$. Bagi setiap $x \in \text{dom}(h)$ berlaku aturan lemah

$$A^*(\partial f(Ax + b)) \subseteq \partial h(x).$$

Kesamaan berlaku apabila terdapat $x_0 \in V$ dengan $Ax_0 + b \in \text{dom}(f)^\circ$.

Turunan komposisi fungsi-fungsi terdiferensialkan dihitung dengan aturan rantai. Jadi, turunan $h(x) = g(f(x))$ adalah $Dh(x) = Dg(f(x))Df(x)$. Rumus ini dapat diperluas ke kalkulus subdiferensial.

Teorema 3.15. Misalkan $f : V \rightarrow \mathbb{R}$ konveks, $g : \mathbb{R} \rightarrow \mathbb{R}$ konveks dan tak menurun, serta $h = g \circ f$. Ambil $x \in \text{dom}(f)^\circ$ dan andaikan g terdiferensialkan di $f(x)$. Maka

$$\partial h(x) = g'(f(x))\partial f(x).$$

Teorema 3.16. Misalkan $f : V \rightarrow (-\infty, \infty]$ fungsi konveks sejati. Maka

$$x^* \in \arg \min_{x \in V} f(x)$$

jika dan hanya jika $0 \in \partial f(x^*)$.

Bukti. Pernyataan ini langsung mengikuti ketaksamaan subgradien

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle$$

bagi setiap $x \in \text{dom } f$. □

Teorema 3.17. Misalkan $f : V \rightarrow (-\infty, \infty]$ sejati dan konveks, serta $C \subseteq V$ konveks dengan $\text{dom}(f)^\circ \cap C^\circ \neq \emptyset$. Titik $x^* \in C$ merupakan solusi persoalan optimisasi berkendala jika dan hanya jika terdapat $g \in \partial f(x^*)$ sedemikian sehingga

$$\langle g, x - x^* \rangle \geq 0$$

bagi semua $x \in C$.

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber.

- (i) Kalimat berlebih pada definisi gradien yang kembali menamai pemetaan turunan sebagai A dihapus; definisi turunan Fréchet sebelumnya tetap mempertahankan notasi tersebut.
- (ii) Definisi subdiferensial diberi kodomain real diperluas, domain efektif, dan kuantifikasi pada ruang asal agar ketaksamaannya bertipe benar.
- (iii) Bukti bahwa subdiferensial fungsi konveks terdiferensialkan adalah himpunan berunsur tunggal dilengkapi dengan menerapkan ketaksamaan pada arah negatif; kebalikannya dibatasi pada dimensi hingga dan fungsi yang hingga di sekitar titik tersebut.
- (iv) Pernyataan keberadaan subgradien, hiperbidang pendukung, dan aturan hitung diberi ruang lingkup berdimensi hingga yang dipakai oleh buktinya.
- (v) Bukti lema interior kosong menangani himpunan kosong, memakai titik pusat bola yang benar, memilih himpunan bebas linear maksimal, dan mentranslasikan hiperbidang kembali.
- (vi) Bukti hiperbidang pendukung memperluas ketaksamaan dari interior melalui ketertutupan dan kontinuitas, lalu memakai hiperbidang dari lema sebelumnya pada kasus interior kosong; urutan pasangan dual juga dibetulkan.
- (vii) Norma dual ditulis dengan nilai mutlak dan urutan pasangan dual yang konsisten.
- (viii) Aturan jumlah mengembalikan argumen evaluasi yang hilang; syarat aturan afin dinyatakan pada citra domain.
- (ix) Rujukan silang ke bab prasyarat yang tidak dimuat diganti dengan nama konsep yang tepat, tanpa mengubah ketergantungan matematisnya.

ATRIBUSI DAN LISENSI

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.

OPTIMISASI KONVEKS

UNIT 4: PENURUNAN SUBGRADIEN TERPROYEKSI
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 4, “Projected subgradient descent”, dari versi sumber yang ditentukan di atas. Unit ini melanjutkan Unit 3. Pembaca diharapkan telah mengenal fungsi konveks, subgradien dan subdiferensial, ruang Hilbert, norma, fungsi indikator, serta kondisi optimalitas Fermat.

Notasi, urutan teorema, bukti, dua latihan informal, dan rujukan sumber dipertahankan. Sejumlah kekeliruan matematis dalam sumber diperbaiki secara terbuka; ringkasannya disertakan pada akhir unit dan rekaman terstruktur lengkap menyertai sumber edisi ini. Tidak ada layanan daring atau perangkat lunak tertutup yang diperlukan untuk membaca unit ini.

DAFTAR ISI

4	PENURUNAN SUBGRADIEN TERPROYEKSI	1
---	----------------------------------	---

4 PENURUNAN SUBGRADIEN TERPROYEKSI

Misalkan V ruang Hilbert real, $C \subset V$ himpunan tak kosong, tertutup, dan konveks, serta $f : V \rightarrow \mathbb{R}$ fungsi konveks. Kita tertarik menyelesaikan masalah

$$(4.1) \quad \min_{x \in C} f(x).$$

Kita mengasumsikan bahwa himpunan peminim tidak kosong dan menetapkan $x^* \in \arg \min_{x \in C} f(x)$. Masalah berkendala di atas selalu dapat ditulis sebagai masalah tak berkendala melalui

$$(4.2) \quad \min_{x \in V} f(x) + \delta_C(x),$$

dengan δ_C fungsi indikator himpunan C .¹

Ingat kembali metode optimisasi numerik paling dasar untuk masalah semacam ini ketika $C = V$ dan f terdiferensialkan: penurunan gradien (atau penurunan *tercuram*). Kita memilih nilai awal x_0 , lalu untuk $k = 0, 1, \dots$ melakukan pembaruan

$$(4.3) \quad x_{k+1} = x_k - \tau_k \nabla f(x_k),$$

dengan $\tau_k > 0$ menyatakan ukuran langkah. Algoritma *baru* pertama yang kita tinjau ialah versi subgradien dari penurunan tercuram: untuk $k = 0, 1, \dots$,

$$(4.4) \quad \begin{cases} g_k & \in \partial f(x_k), \\ x_{k+1} & = x_k - \tau_k g_k. \end{cases}$$

Jika $C \neq V$, masalah segera dapat muncul: mungkin saja $x_{k+1} \notin C$. Dalam hal itu, iterasi yang memakai subdiferensial $f + \delta_C$ tidak lagi terdefinisi karena $\partial \delta_C(x) = \emptyset$ untuk $x \notin C$. Karena itu, kita perlu memastikan setiap iterasi baru tetap berada di C ; untuk tujuan ini kita memakai *proyeksi*.

Teorema 4.1 (Teorema proyeksi). Misalkan V ruang Hilbert real dan $C \subset V$ tak kosong, tertutup, dan konveks. Fungsi berikut terdefinisi dengan baik:

$$(4.5) \quad \begin{aligned} \text{proj}_C : V &\rightarrow C, \\ x &\mapsto \arg \min_{y \in C} \|x - y\|. \end{aligned}$$

¹Formulasi ini memakai f yang terdefinisi pada seluruh V , termasuk di luar C .

Bukti. Kita perlu menunjukkan bahwa minimum tercapai secara tunggal. Tetapkan $d = \inf_{y \in C} \|y - x\|$, dan ambil barisan peminimum $(y_n)_n \subset C$, yaitu

$$(4.6) \quad \lim_n \|y_n - x\| = d.$$

Karena C konveks, $(y_n + y_m)/2 \in C$. Identitas jajaran genjang memberi

$$\|y_n - y_m\|^2 = 2\|y_n - x\|^2 + 2\|y_m - x\|^2 - 4\left\|\frac{y_n + y_m}{2} - x\right\|^2 \leq 2\|y_n - x\|^2 + 2\|y_m - x\|^2 - 4d^2.$$

Ruas kanan menuju nol ketika $m, n \rightarrow \infty$, sehingga $(y_n)_n$ merupakan barisan Cauchy. Kelengkapan V menghasilkan $y_n \rightarrow \hat{y} \in V$, sedangkan ketertutupan C menghasilkan $\hat{y} \in C$. Dari kontinuitas norma diperoleh

$$(4.7) \quad \|\hat{y} - x\| = \lim_n \|y_n - x\| = d,$$

jadi peminim memang ada.

Untuk ketunggalan, andaikan $y_1 \neq y_2$ keduanya peminim. Identitas jajaran genjang memberikan

$$(4.8) \quad \left\|\frac{y_1 + y_2}{2} - x\right\|^2 = \frac{1}{2}\|y_1 - x\|^2 + \frac{1}{2}\|y_2 - x\|^2 - \frac{1}{4}\|y_1 - y_2\|^2 < d^2.$$

Namun $(y_1 + y_2)/2 \in C$, yang bertentangan dengan definisi d . Jadi peminimnya tunggal. $\square$

Dengan proyeksi, kita memperoleh cara mengatasi masalah *keluar* dari C : metode subgradien terproyeksi. Pilih $x_0 \in C$; kemudian, untuk $k = 0, 1, \dots$ dan $\tau_k \geq 0$, tetapkan

$$(4.9) \quad \begin{cases} g_k & \in \partial f(x_k), \\ x_{k+1} & = \text{proj}_C(x_k - \tau_k g_k). \end{cases}$$

Untuk membuktikan konvergensi metode ini, kita memerlukan beberapa hasil bantu.

Lema 4.2. Misalkan V ruang Hilbert real dan $C \subset V$ tak kosong, tertutup, dan konveks. Maka

$$(4.10) \quad \langle x - \text{proj}_C(x), y - \text{proj}_C(x) \rangle \leq 0, \quad y \in C.$$

Khususnya, jika C subruang,² maka

$$(4.11) \quad \langle x - \text{proj}_C(x), y \rangle = 0, \quad y \in C.$$

²Artinya, C memenuhi definisi ruang vektor.

Bukti. Untuk setiap $y \in C$, kita mempunyai

$$\begin{aligned}
 (4.12) \quad & \|\text{proj}_C(x) - x\|^2 \leq \|y - x\|^2 \\
 & = \|y - \text{proj}_C(x) + \text{proj}_C(x) - x\|^2 \\
 & = \|y - \text{proj}_C(x)\|^2 + 2\langle y - \text{proj}_C(x), \text{proj}_C(x) - x \rangle + \|\text{proj}_C(x) - x\|^2.
 \end{aligned}$$

Akibatnya,

$$(4.13) \quad 0 \leq \|y - \text{proj}_C(x)\|^2 + 2\langle y - \text{proj}_C(x), \text{proj}_C(x) - x \rangle.$$

Ambil sebarang $z \in C$, lalu pada ketaksamaan di atas masukkan $y = \text{proj}_C(x) + t(z - \text{proj}_C(x))$ untuk $t \in (0, 1)$. Kita memperoleh

$$(4.14) \quad 0 \leq t^2\|z - \text{proj}_C(x)\|^2 + 2t\langle z - \text{proj}_C(x), \text{proj}_C(x) - x \rangle.$$

Setelah dibagi dengan $t > 0$,

$$(4.15) \quad 0 \leq t\|z - \text{proj}_C(x)\|^2 + 2\langle z - \text{proj}_C(x), \text{proj}_C(x) - x \rangle.$$

Dengan mengambil limit $t \rightarrow 0$, kita memperoleh hasil yang diinginkan. Kesamaan untuk kasus subruang ditinggalkan sebagai latihan. $\square$

Proposisi 4.3. Misalkan V ruang Hilbert real dan $C \subset V$ tak kosong, tertutup, dan konveks. Proyeksi pada C bersifat tak ekspansif, yaitu kontinu Lipschitz dengan konstanta satu:

$$(4.16) \quad \|\text{proj}_C(x_1) - \text{proj}_C(x_2)\| \leq \|x_1 - x_2\|.$$

Bukti. Tanpa mengurangi keumuman, andaikan $\|\text{proj}_C(x_2) - \text{proj}_C(x_1)\|^2 \neq 0$, sebab jika tidak, tidak ada yang perlu dibuktikan. Kita memperoleh

$$\begin{aligned}
 (4.17) \quad & \|\text{proj}_C(x_2) - \text{proj}_C(x_1)\|^2 = \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 + x_1 - \text{proj}_C(x_1) \rangle \\
 & = \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 \rangle \\
 & \quad + \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_1 - \text{proj}_C(x_1) \rangle \\
 & \leq \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 \rangle \\
 & = \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_2 + x_2 - x_1 \rangle \\
 & \leq \langle \text{proj}_C(x_1) - \text{proj}_C(x_2), x_2 - \text{proj}_C(x_2) \rangle \\
 & \quad + \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_2 - x_1 \rangle \\
 & \leq \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_2 - x_1 \rangle \\
 & \leq \|\text{proj}_C(x_2) - \text{proj}_C(x_1)\| \|x_2 - x_1\|.
 \end{aligned}$$

Membagi dengan $\|\text{proj}_C(x_2) - \text{proj}_C(x_1)\| \neq 0$ menghasilkan kesimpulan. $\square$

Lema 4.4 (Ketaksamaan fundamental metode subgradien terproyeksi). Misalkan $x^* \in \arg \min_{x \in C} f(x)$, dan misalkan x_k adalah iterasi metode subgradien terproyeksi (4.9), dengan $g_k \in \partial f(x_k)$ dan $\tau_k \geq 0$. Maka

$$(4.18) \quad \|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2 - 2\tau_k(f(x_k) - f(x^*)) + \tau_k^2 \|g_k\|^2.$$

Bukti. Dari definisi subgradien, $f(x_k) + \langle g_k, x^* - x_k \rangle \leq f(x^*)$. Karena $x^* \in C$, kita mempunyai $\text{proj}_C(x^*) = x^*$. Ketakspansifan proyeksi lalu memberikan

$$(4.19) \quad \begin{aligned} \|x_{k+1} - x^*\|^2 &= \|\text{proj}_C(x_k - \tau_k g_k) - \text{proj}_C(x^*)\|^2 \\ &\leq \|x_k - \tau_k g_k - x^*\|^2 \\ &= \|x_k - x^*\|^2 - 2\tau_k \langle g_k, x_k - x^* \rangle + \tau_k^2 \|g_k\|^2 \\ &\leq \|x_k - x^*\|^2 - 2\tau_k(f(x_k) - f(x^*)) + \tau_k^2 \|g_k\|^2. \end{aligned}$$

□

Hal yang wajar dilakukan sekarang ialah memakai hasil sebelumnya untuk menentukan ukuran langkah optimal. Lebih tepatnya, dengan meminimumkan ruas kanan (4.19) terhadap τ_k , kita memperoleh

$$(4.20) \quad \tau_k = \frac{f(x_k) - f(x^*)}{\|g_k\|^2}$$

jika $g_k \neq 0$, dan kita menetapkan $\tau_k = 0$ jika $g_k = 0$. Ukuran langkah ini disebut aturan ukuran langkah Polyak.

Sebagai latihan, buktikan bahwa jika fungsi konveks $f : V \rightarrow \mathbb{R}$ bersifat L -Lipschitz secara global pada V , maka setiap $g \in \partial f(x)$ memenuhi $\|g\| \leq L$. Pada hasil-hasil berikut, kita memakai langsung batas pada subgradien yang dipilih, sehingga juga mencakup situasi berkendala yang tidak memenuhi asumsi Lipschitz global tersebut.

Teorema 4.5. Andaikan subgradien yang dipilih pada iterasi memenuhi $\|g_k\| \leq L$. Dengan aturan ukuran langkah Polyak

$$(4.21) \quad \tau_k = \frac{f(x_k) - f(x^*)}{\|g_k\|^2} \quad \text{jika } g_k \neq 0, \quad \tau_k = 0 \quad \text{jika } g_k = 0.$$

metode subgradien terproyeksi (4.9) memenuhi

- (i) $\|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2$, dengan ketaksamaan ketat jika $f(x_k) > f(x^*)$;
- (ii) $f(x_k) \rightarrow f(x^*)$ ketika $k \rightarrow \infty$; dan
- (iii) $f_{\text{best}}^N - f(x^*) \leq \frac{L\|x_1 - x^*\|}{\sqrt{N}}$, dengan $f_{\text{best}}^N = \min_{k=1, \dots, N} f(x_k)$.

Bukti. Tanpa mengurangi keumuman, kita boleh mengasumsikan $f(x^*) = 0$. Jika tidak, cukup tinjau $\tilde{f}(x) := f(x) - f(x^*)$. Dari [teorema 4.4](#) dan aturan ukuran langkah diperoleh

$$(4.22) \quad \begin{aligned} \|x_{k+1} - x^*\|^2 &\leq \|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 \|g_k\|^2 \\ &= \|x_k - x^*\|^2 - a_k, \end{aligned}$$

dengan $a_k = f(x_k)^2 / \|g_k\|^2$ jika $g_k \neq 0$, dan nol jika $g_k = 0$. Jika $g_k = 0$, kekonveksan memberi $f(x_k) = f(x^*)$. Karena itu, pengurangan bersifat ketat tepat ketika celah nilai fungsi positif.

Dengan menata ulang dan menjumlahkan untuk $k = 1, \dots, N$, kita memperoleh

$$(4.23) \quad \sum_{k=1}^N a_k \leq \|x_1 - x^*\|^2 - \|x_{N+1} - x^*\|^2 \leq \|x_1 - x^*\|^2.$$

Karena $\|g_k\| \leq L$,

$$(4.24) \quad \sum_{k=1}^N f(x_k)^2 \leq \sum_{k=1}^N L^2 a_k \leq L^2 \|x_1 - x^*\|^2.$$

Batas ini berlaku untuk setiap N , sehingga $f(x_k) \rightarrow 0$. Selain itu,

$$(4.25) \quad N(f_{\text{best}}^N)^2 \leq \sum_{k=1}^N f(x_k)^2 \leq L^2 \|x_1 - x^*\|^2,$$

yaitu

$$(4.26) \quad f_{\text{best}}^N \leq \frac{L \|x_1 - x^*\|}{\sqrt{N}}.$$

□

Korolari 4.6. Untuk mencapai ketelitian $f_{\text{best}}^N - f(x^*) \leq \varepsilon$, kita memerlukan

$$N = O\left(\frac{L^2 \|x_1 - x^*\|^2}{\varepsilon^2}\right)$$

iterasi.

Catatan. Ingat bahwa metode gradien mulus standar mencapai kompleksitas $O(1/\varepsilon)$.

Walaupun hasil konvergensi dengan aturan ukuran langkah Polyak menarik secara teoretis dan memberi batas kasus terburuk untuk iterasi terbaik, dalam praktiknya ukuran langkah tersebut tidak dapat dihitung tanpa mengetahui $f(x^*)$. Berikut ini kita berikan hasil konvergensi yang lebih umum.

Teorema 4.7. *Andaikan subgradien yang dipilih memenuhi $\|g_k\| \leq L$, dan ukuran langkah $\tau_k > 0$ memenuhi*

$$\frac{\sum_{k=1}^n \tau_k}{\sum_{k=1}^n \tau_k^2} \rightarrow \infty \quad \text{ketika } n \rightarrow \infty.$$

Maka

$$f_{\text{best}}^n - f(x^*) \leq \frac{\|x_1 - x^*\|^2 + L^2 \sum_{k=1}^n \tau_k^2}{2 \sum_{k=1}^n \tau_k} \rightarrow 0.$$

Bukti. Sekali lagi, untuk menyederhanakan notasi, andaikan $f(x^*) = 0$. Dengan memakai $\|g_k\| \leq L$ dan menjumlahkan ketaksamaan fundamental [teorema 4.4](#) untuk $k = 1, \dots, n$, kita memperoleh

$$(4.27) \quad 2 \sum_{k=1}^n \tau_k f(x_k) \leq \|x_1 - x^*\|^2 + L^2 \sum_{k=1}^n \tau_k^2.$$

Tuliskan

$$\sigma_n = \frac{\sum_{k=1}^n \tau_k}{\sum_{k=1}^n \tau_k^2}.$$

Karena $f_{\text{best}}^n \leq f(x_k)$,

$$(4.28) \quad f_{\text{best}}^n \leq \frac{\sum_{k=1}^n \tau_k f(x_k)}{\sum_{k=1}^n \tau_k} \leq \frac{\|x_1 - x^*\|^2}{2 \sum_{k=1}^n \tau_k} + \frac{L^2}{2\sigma_n}.$$

Hipotesis $\sigma_n \rightarrow \infty$ juga memaksa $\sum_{k=1}^n \tau_k \rightarrow \infty$; karena itu, kedua suku pada ruas kanan menuju nol. $\square$

Varian hasil konvergensi juga dapat diperoleh, misalnya jika C kompak; lihat [\[Beck 2017\]](#) untuk perinciannya.

Konvergensi dapat dipercepat dan juga *ditransfer* dari nilai fungsi ke iterasi $(x_k)_k$ jika kita menambahkan asumsi bahwa f konveks kuat.

Teorema 4.8. *Andaikan f konveks kuat dengan parameter $\mu > 0$ pada C , dan subgradien yang dipilih memenuhi $\|g_k\| \leq L$.³ Mulai dari $x_1 \in C$, gunakan ukuran langkah $\tau_k = \frac{2}{\mu k}$ untuk $k \geq 1$. Untuk $n \geq 2$, metode subgradien terproyeksi (4.9) memenuhi*

$$(i) \quad f_{\text{best}}^n - f(x^*) \leq \frac{2L^2}{\mu(n-1)}; \text{ dan}$$

$$(ii) \quad \|x_n - x^*\| \leq \frac{2L}{\mu\sqrt{n-1}}.$$

³Batas ini dikenakan pada subgradien yang benar-benar dipilih oleh algoritma; batas tersebut tidak disimpulkan hanya dari sifat Lipschitz relatif pada C .

Bukti. Seperti sebelumnya, tanpa mengurangi keumuman, tetapkan $f(x^*) = 0$. Kekonveksan kuat memperbaiki ketaksamaan fundamental menjadi

$$(4.29) \quad \begin{aligned} \|x_{k+1} - x^*\|^2 &\leq (1 - \mu\tau_k)\|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 \|g_k\|^2 \\ &\leq (1 - \mu\tau_k)\|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 L^2. \end{aligned}$$

Dengan menata ulang dan membagi dengan $2\tau_k$, diperoleh

$$(4.30) \quad f(x_k) \leq -\frac{\tau_k^{-1}}{2}\|x_{k+1} - x^*\|^2 + \frac{\tau_k^{-1} - \mu}{2}\|x_k - x^*\|^2 + \frac{\tau_k}{2}L^2.$$

Memasukkan $\tau_k = 2/(\mu k)$ menghasilkan

$$(4.31) \quad f(x_k) \leq -\frac{\mu k}{4}\|x_{k+1} - x^*\|^2 + \frac{\mu(k-2)}{4}\|x_k - x^*\|^2 + \frac{1}{\mu k}L^2.$$

Kalikan dengan $k-1$, lalu jumlahkan terhadap $k = 1, \dots, n$. Suku jarak meneleskop, sehingga

$$(4.32) \quad \sum_{k=1}^n (k-1)f(x_k) \leq -\frac{\mu n(n-1)}{4}\|x_{n+1} - x^*\|^2 + \frac{1}{\mu} \sum_{k=1}^n \frac{k-1}{k}L^2.$$

Karena $\sum_{k=1}^n (k-1) = n(n-1)/2$ dan $\sum_{k=1}^n (k-1)/k \leq n$, kita memperoleh

$$(4.33) \quad \frac{n(n-1)}{2}f_{\text{best}}^n \leq \sum_{k=1}^n (k-1)f(x_k) \leq -\frac{\mu n(n-1)}{4}\|x_{n+1} - x^*\|^2 + \frac{nL^2}{\mu}.$$

Dengan membuang suku jarak yang tak positif, diperoleh

$$(4.34) \quad f_{\text{best}}^n \leq \frac{2L^2}{\mu(n-1)}.$$

Untuk batas iterasi, buang suku $-2\tau_k f(x_k) \leq 0$ dari ketaksamaan fundamental yang diperbaiki. Dengan $d_k = \|x_k - x^*\|$,

$$(4.35) \quad d_{k+1}^2 \leq \left(1 - \frac{2}{k}\right)d_k^2 + \frac{4L^2}{\mu^2 k^2}.$$

Untuk $k = 1$, ketaksamaan ini memberi $d_2^2 \leq 4L^2/\mu^2$. Jika $d_k^2 \leq 4L^2/[\mu^2(k-1)]$, substitusi pada relasi di atas memberikan

$$d_{k+1}^2 \leq \frac{4L^2}{\mu^2} \left(\frac{k-2}{k(k-1)} + \frac{1}{k^2} \right) \leq \frac{4L^2}{\mu^2 k}.$$

Induksi membuktikan $\|x_n - x^*\| \leq 2L/[\mu\sqrt{n-1}]$ untuk setiap $n \geq 2$. □

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber.

- (i) Masalah optimisasi diberi ruang ambien, domain fungsi, himpunan kendala, titik awal, dan peminim yang bertipe lengkap; fungsi indikator kini ditambahkan pada fungsi yang terdefinisi di seluruh ruang.
- (ii) Teorema proyeksi dinyatakan pada ruang Hilbert real dan dibuktikan dengan identitas jajaran genjang, kelengkapan, serta ketertutupan; argumen sumber “barisan terbatas mempunyai subbarisan konvergen” tidak berlaku pada ruang hasil kali dalam umum.
- (iii) Hipotesis himpunan tak kosong, tertutup, dan konveks serta ruang Hilbert diulang pada karakterisasi dan ketakspansifan proyeksi.
- (iv) Semua hasil konvergensi memakai asumsi eksplisit bahwa subgradien yang dipilih dibatasi oleh L , bukan implikasi keliru bahwa fungsi yang Lipschitz hanya pada himpunan kendala membatasi setiap subgradien relatif.
- (v) Ketaksamaan fundamental diberi $x^* \in \arg \min_C f$ dan ukuran langkah tak negatif yang diperlukan oleh buktinya.
- (vi) Teorema Polyak membandingkan norma kuadrat dengan norma kuadrat, memakai indeks yang konsisten, mensyaratkan celah objektif positif untuk penurunan ketat, dan mengembalikan kuadrat yang hilang pada bukti laju $N^{-1/2}$.
- (vii) Pernyataan teorema ukuran langkah umum disatukan kembali dengan limit dan kesimpulannya, serta batas iterasi terbaik ditulis secara eksplisit.
- (viii) Hasil konveks kuat dimulai pada $k = 1$, mengganti kesamaan palsu dengan ketaksamaan, memperbaiki faktor laju nilai fungsi menjadi 2, dan membuktikan batas jarak iterasi dengan induksi. Tanda kutip liar pada rumus sumber juga dihapus.
- (ix) Rujukan silang ke definisi ruang vektor yang tidak termuat diganti dengan nama konsep, sedangkan sitasi Beck dipertahankan dalam bibliografi unit.

BIBLIOGRAFI

A. BECK (2017), *First-order methods in optimization*, SIAM.

ATRIBUSI DAN LISENSI

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.

OPTIMISASI KONVEKS

UNIT 5: METODE GRADIEN PROKSIMAL
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 5, "Proximal Gradient Methods", dari versi sumber yang ditentukan di atas. Unit ini melanjutkan Unit 4. Pembaca diharapkan telah mengenal fungsi proper, semikontinu bawah, dan konveks; subgradien beserta aturan jumlah dan skalanya; kondisi optimalitas Fermat; proyeksi; serta fungsi dengan gradien Lipschitz.

Notasi, urutan hasil, bukti, sitasi, dan semua ajakan belajar dalam sumber dipertahankan. Sejumlah kekeliruan matematis dalam sumber diperbaiki secara terbuka; ringkasannya disertakan pada akhir unit dan rekaman terstruktur lengkap menyertai sumber edisi ini. Tidak ada layanan daring atau perangkat lunak tertutup yang diperlukan untuk membaca unit ini.

DAFTAR ISI

5	METODE GRADIEN PROKSIMAL	1
---	--------------------------	---

5 METODE GRADIEN PROKSIMAL

Kita telah melihat dalam bukti (dan latihan praktis) bahwa metode subgradien tidak memberikan konvergensi yang ideal. Dalam kasus dasar atau terburuk, nilai fungsi berkonvergensi dengan orde $O(1/\sqrt{k})$, dan konvergensi memerlukan ukuran langkah yang mengecil. Dalam bab ini, kita akan memperkenalkan alternatif bagi subgradien (eksplisit) dalam optimisasi.

Perhatikan masalah tak berkendala

$$(5.1) \quad \min_x f(x),$$

dengan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, semikontinu bawah, dan konveks. Ingat pembaruan metode subgradien $x_{k+1} = x_k - \tau_k g_k$, $g_k \in \partial f(x_k)$, atau, secara ekuivalen, $x_{k+1} \in x_k - \tau_k \partial f(x_k)$. Untuk $\tau_k > 0$, kita usulkan pembaruan implisit

$$(5.2) \quad x_{k+1} \in x_k - \tau_k \partial f(x_{k+1}).$$

Pada tahap ini belum jelas apakah metode tersebut terdefinisi dengan baik. Namun, jika memang terdefinisi, secara intuitif kestabilannya dapat membaik karena arah pembaruan dipilih dengan *melihat ke masa depan*. Gagasan ini selaras dengan kestabilan metode implisit untuk mendiskretkan persamaan diferensial (*bandingkan Euler implisit*).

Jika kita amati (5.2) lebih dekat, aturan itu dapat ditulis sebagai

$$(5.3) \quad 0 \in \partial \left(\frac{1}{2} \|\cdot - x_k\|^2 + \tau_k f \right) (x_{k+1}),$$

yang merupakan kondisi optimalitas untuk

$$(5.4) \quad \min_x \frac{1}{2} \|x - x_k\|^2 + \tau_k f(x).$$

Hal ini membawa kita pada definisi berikut.

Definisi 5.1 (Operator proksimal). Operator atau pemetaan proksimal dari $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ didefinisikan sebagai pemetaan

$$(5.5) \quad \begin{aligned} \text{prox}_f : \mathbb{R}^d &\rightarrow \mathbb{R}^d, \\ x &\mapsto \arg \min_{y \in \mathbb{R}^d} \frac{1}{2} \|y - x\|^2 + f(y). \end{aligned}$$

Kita biasanya menyebut prox_f sebagai ‘proks’. Sebagai pemetaan bernilai himpunan, proks selalu dapat dituliskan; tetapi pemetaan itu baru berguna ketika $\text{prox}_f(x) \neq \emptyset$. Kita dapat membuktikan hasil berikut.

Lema 5.2. *Misalkan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, konveks, dan semikontinu bawah. Pemetaan proksimal bernilai tunggal. Lebih lanjut, $y = \text{prox}_f(x)$ jika dan hanya jika $0 \in (y-x) + \partial f(y)$.*

Catatan. Berdasarkan karakterisasi $0 \in (y-x) + \partial f(y)$, kita sering menulis proks sebagai $\text{prox}_f(x) = (\text{Id} + \partial f)^{-1}(x)$.

Bukti. Demi kesederhanaan, andaikan $\text{dom}(f)^\circ \neq \emptyset$; untuk kasus umum, lihat [Beck 2017].

Ambil $g \in \partial f(y_0)$ untuk suatu $y_0 \in \text{dom}(f)^\circ$. Kita mempunyai

$$(5.6) \quad f(y_0) + \langle g, y - y_0 \rangle + \frac{1}{2}\|x - y\|^2 \leq f(y) + \frac{1}{2}\|x - y\|^2.$$

Oleh karena itu (mengapa?), pemetaan $y \mapsto f(y) + \frac{1}{2}\|x - y\|^2$ bersifat koersif. Pemetaan ini juga mewarisi sifat semikontinu bawah dan proper dari f . Dengan metode langsung untuk fungsi proper, semikontinu bawah, dan koersif di ruang berdimensi hingga, terdapat solusi bagi

$$(5.7) \quad \min_{y \in \mathbb{R}^d} \frac{1}{2}\|y - x\|^2 + f(y).$$

Untuk keunikan, definisikan $q_x(y) = \frac{1}{2}\|y - x\|^2 + f(y)$ dan andaikan $y_1 \neq y_2$ adalah dua peminim. Karena suku kuadrat konveks ketat dan f konveks, untuk $\bar{y} = (y_1 + y_2)/2$ berlaku

$$(5.8) \quad \begin{aligned} q_x(\bar{y}) &< \frac{1}{2}(q_x(y_1) + q_x(y_2)) \\ &= \min_{y \in \mathbb{R}^d} q_x(y), \end{aligned}$$

sebuah kontradiksi. Pernyataan terakhir merupakan kondisi optimalitas bagi (5.7). $\square$

Setelah mengetahui bahwa proks terdefinisi dengan baik, kita dapat mendefinisikan metode gradien proksimal. Secara khusus, perhatikan masalah

$$(5.9) \quad \min_{x \in \mathbb{R}^d} F(x) := f(x) + g(x),$$

dengan f konveks dan L -halus, yakni terdiferensialkan dengan gradien L -Lipschitz, sedangkan g proper, konveks, dan semikontinu bawah. Masalah semacam ini sering muncul dalam praktik dan mencakup masalah semula dengan mengambil $f \equiv 0$. Untuk $k = 0, 1, \dots$, metode gradien proksimal didefinisikan oleh

$$(5.10) \quad x_{k+1} = \text{prox}_{\tau_k g}(x_k - \tau_k \nabla f(x_k)).$$

Jadi, kita melakukan langkah gradien atau eksplisit terhadap f , lalu langkah proksimal atau implisit terhadap g .

Sebagai hasil sederhana pertama, kita menunjukkan bahwa titik tetap metode gradien proksimal tepat sama dengan titik optimal.

Lema 5.3. Untuk suatu $\tau > 0$ yang tetap dan $x \in \mathbb{R}^d$, pernyataan berikut ekuivalen:

$$(5.11) \quad x = \text{prox}_{\tau g}(x - \tau \nabla f(x)) \iff 0 \in \partial(f + g)(x).$$

Dengan demikian, x adalah titik tetap jika dan hanya jika x menyelesaikan (5.9).

Bukti. Karakterisasi optimalitas proks memberikan ekuivalensi

$$(5.12) \quad x = \text{prox}_{\tau g}(x - \tau \nabla f(x)) \iff 0 \in \tau \nabla f(x) + \tau \partial g(x).$$

Karena $\tau > 0$, serta menurut aturan jumlah dan aturan skala untuk subdiferensial,

$$(5.13) \quad 0 \in \tau(\nabla f(x) + \partial g(x)) \iff 0 \in \partial(f + g)(x).$$

Untuk fungsi konveks $F = f + g$, kondisi terakhir ekuivalen dengan optimalitas x . $\square$

Selain proks, kita mendefinisikan selubung Moreau sebagai nilai infimum dari objektif yang digunakan untuk proks.

Definisi 5.4 (Selubung Moreau). Misalkan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ dan $\tau > 0$. Selubung Moreau $M_f^\tau : \mathbb{R}^d \rightarrow [-\infty, \infty]$ didefinisikan oleh

$$(5.14) \quad M_f^\tau(x) := \inf_{y \in \mathbb{R}^d} \frac{1}{2\tau} \|x - y\|^2 + f(y).$$

Lema 5.5. Misalkan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, konveks, dan semikontinu bawah, serta $\tau > 0$. Selubung Moreau selalu bernilai real (yakni berhingga), dan

$$(5.15) \quad M_f^\tau(x) = \frac{1}{2\tau} \|x - \text{prox}_{\tau f}(x)\|^2 + f(\text{prox}_{\tau f}(x)).$$

Bukti. Latihan. Terapkan lemma keberadaan dan keunikan proks pada τf , lalu substitusikan peminim unik tersebut ke dalam definisi infimum. $\square$

Contoh 5.6. Kita tinjau beberapa contoh pemetaan proksimal dan selubung Moreau yang sering muncul:

- (i) Misalkan $C \subset \mathbb{R}^d$ tak kosong, tertutup, dan konveks, dan perhatikan fungsi indikator δ_C . Maka

$$(5.16) \quad \text{prox}_{\tau \delta_C}(x) = \text{proj}_C(x), \quad M_{\delta_C}^\tau(x) = \frac{1}{2\tau} \text{dist}(x, C)^2.$$

(ii) Secara khusus, jika $C = \{x \in \mathbb{R}^d \mid \|x\|_\infty \leq 1\}$, maka

$$(5.17) \quad (\text{prox}_{\tau\delta_C}(x))_i = \frac{x_i}{\max\{1, |x_i|\}}.$$

(iii) Jika $f(x) = \|x\|_1$, pemetaan proksimalnya adalah operator *ambang lunak*

$$(5.18) \quad (\text{prox}_{\tau f}(x))_i = \begin{cases} x_i - \tau & x_i > \tau, \\ x_i + \tau & x_i < -\tau, \\ 0 & x_i \in [-\tau, \tau]. \end{cases}$$

Untuk $d = 1$, selubung Moreau-nya tepat merupakan fungsi Huber

$$(5.19) \quad M_{|\cdot|}^\tau(x) = \begin{cases} \frac{|x|^2}{2\tau} & |x| \leq \tau, \\ |x| - \frac{\tau}{2} & |x| > \tau. \end{cases}$$

Lema 5.7 (Aturan komputasi untuk proks). Misalkan semua fungsi dasar yang muncul di bawah proper, semikontinu bawah, dan konveks pada domain berdimensi hingga yang dinyatakan. Aturan berikut berlaku:

- (i) Jika $x = (x_1, \dots, x_m) \in \mathbb{R}^{d_1} \times \dots \times \mathbb{R}^{d_m} \cong \mathbb{R}^d$, $x_i \in \mathbb{R}^{d_i}$, $\sum_i d_i = d$, dan $f(x) = \sum_i f_i(x_i)$, maka $\text{prox}_f(x) = (\text{prox}_{f_i}(x_i))_i$.
- (ii) Jika $f(x) = \alpha g(x) + b$ dengan $\alpha > 0$ dan $b \in \mathbb{R}$, maka $\text{prox}_f = \text{prox}_{\alpha g}$.
- (iii) Jika $f(x) = g(\alpha x + b)$ dengan $\alpha \neq 0$ dan $b \in \mathbb{R}^d$, maka $\text{prox}_f(x) = \alpha^{-1}(\text{prox}_{\alpha^2 g}(\alpha x + b) - b)$.
- (iv) Jika $f(x) = g(Qx)$ dengan $Q \in \mathbb{R}^{d \times d}$ ortogonal, maka $\text{prox}_f(x) = Q^\top \text{prox}_g(Qx)$.
- (v) Jika $f(x) = g(x) + \langle a, x \rangle + b$ dengan $a \in \mathbb{R}^d$ dan $b \in \mathbb{R}$, maka $\text{prox}_f(x) = \text{prox}_g(x - a)$.
- (vi) Jika $f(x) = g(x) + \frac{\gamma}{2} \|x - a\|^2$ dengan $a \in \mathbb{R}^d$ dan $\gamma \geq 0$, maka $\text{prox}_f(x) = \text{prox}_{\tilde{\gamma}g}(\tilde{\gamma}x + \gamma \tilde{\gamma}a)$, dengan $\tilde{\gamma} = (1 + \gamma)^{-1}$.

Selubung Moreau memberikan efek penghalusan pada fungsi f , sebagaimana ditunjukkan oleh hasil berikut.

Lema 5.8. Misalkan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, konveks, dan semikontinu bawah, serta $\tau > 0$. Selubung Moreau bersifat konveks dan terdiferensialkan. Gradiennya $1/\tau$ -Lipschitz dan dapat ditulis sebagai

$$(5.20) \quad \nabla M_f^\tau(x) = \frac{1}{\tau}(x - \text{prox}_{\tau f}(x)).$$

Bukti. Untuk $q(x, y) = \frac{1}{2\tau}\|x - y\|^2 + f(y)$, fungsi q konveks secara bersama pada (x, y) . Jika $p_i = \text{prox}_{\tau f}(x_i)$ dan $t \in [0, 1]$, evaluasi q di $(tx_1 + (1-t)x_2, tp_1 + (1-t)p_2)$ menunjukkan bahwa $M_f^\tau(tx_1 + (1-t)x_2) \leq tM_f^\tau(x_1) + (1-t)M_f^\tau(x_2)$. Jadi, argumen ini tetap sah untuk fungsi f bernilai diperluas.

Tetapkan $p(x) = \text{prox}_{\tau f}(x)$. Dari definisi proks,

$$\begin{aligned} M_f^\tau(x+h) &= \frac{1}{2\tau}\|x+h-p(x+h)\|^2 + f(p(x+h)) \\ &\leq \frac{1}{2\tau}\|x+h-p(x)\|^2 + f(p(x)), \\ M_f^\tau(x) &= \frac{1}{2\tau}\|x-p(x)\|^2 + f(p(x)). \end{aligned} \quad (5.21)$$

Dengan mengurangi dua hubungan itu, kita memperoleh

$$\begin{aligned} M_f^\tau(x+h) - M_f^\tau(x) &\leq \frac{1}{2\tau}(\|x+h-p(x)\|^2 - \|x-p(x)\|^2) \\ &= \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle + \frac{1}{2\tau}\|h\|^2. \end{aligned} \quad (5.22)$$

Secara ekuivalen,

$$M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle \leq \frac{1}{2\tau}\|h\|^2. \quad (5.23)$$

Definisikan residu keterdiferensialan

$$r_x(h) := M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle. \quad (5.24)$$

Kurangkan dua kondisi optimalitas proks, lalu gunakan monotonisitas ∂f dan ketaksamaan Cauchy-Schwarz. Hasilnya ialah $\|p(x)-p(y)\| \leq \|x-y\|$, sehingga p tak ekspansif. Dengan mengevaluasi $M_f^\tau(x)$ pada $p(x+h)$, kita juga mendapatkan

$$r_x(h) \geq \left\langle h, \frac{1}{\tau}(p(x) - p(x+h)) \right\rangle + \frac{1}{2\tau}\|h\|^2 \geq -\frac{1}{2\tau}\|h\|^2. \quad (5.25)$$

Secara keseluruhan,

$$\left| M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle \right| \leq \frac{1}{2\tau}\|h\|^2. \quad (5.26)$$

Jadi, $\nabla M_f^\tau(x) = \tau^{-1}(x-p(x))$. Untuk membuktikan kekontinuan Lipschitz gradien, perhatikan bahwa

$$\begin{aligned} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\|^2 &= \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), (x-p(x)) - (y-p(y)) \right\rangle \\ &= \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), x-y \right\rangle \\ &\quad - \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), p(x) - p(y) \right\rangle. \end{aligned} \quad (5.27)$$

Kondisi optimalitas memberi $\nabla M_f^\tau(x) = \tau^{-1}(x - p(x)) \in \partial f(p(x))$. Karena itu, hasil kali dalam terakhir tidak negatif menurut monotonisitas subdiferensial, sehingga

$$(5.28) \quad \begin{aligned} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\|^2 &\leq \frac{1}{\tau} \langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), x - y \rangle \\ &\leq \frac{1}{\tau} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\| \|x - y\|. \end{aligned}$$

Setelah membagi dengan norma gradien yang berbeda dari nol (kasus nol langsung), diperoleh sifat $1/\tau$ -Lipschitz. $\square$

Catatan. Dengan representasi gradien selubung Moreau di atas, proks dapat ditulis kembali sebagai

$$(5.29) \quad \text{prox}_{\tau f}(x) = x - \tau \left(\frac{1}{\tau} (x - \text{prox}_{\tau f}(x)) \right) = x - \tau \nabla M_f^\tau(x).$$

Jadi, satu langkah proksimal ekuivalen dengan satu langkah gradien pada selubung Moreau.

Contoh 5.9. Untuk fungsi indikator himpunan tak kosong, tertutup, dan konveks C , rumusnya adalah $\text{prox}_{\tau \delta_C}(x) = \text{proj}_C(x)$. Untuk $f(x) = \|x\|_1$, setiap koordinat diberikan oleh ambang lunak $(\text{prox}_{\tau f}(x))_i = \text{sign}(x_i) \max\{|x_i| - \tau, 0\}$, dengan $\text{sign}(0) = 0$. Untuk $f(x) = \|x\|_2$, penyusutan Euklides adalah $\text{prox}_{\tau f}(x) = (1 - \tau/\|x\|_2)_+ x$ jika $x \neq 0$, dan $\text{prox}_{\tau f}(0) = 0$. Verifikasikan ketiga rumus ini langsung dari kondisi optimalitas proks.

Sekarang kita akan membuktikan konvergensi metode gradien proksimal. Mula-mula kita turunkan lemma penting: untuk fungsi L -halus, galat antara fungsi dan hampiran linearnya dibatasi dari atas oleh suku kuadrat.

Lema 5.10. Misalkan $F : \mathbb{R}^d \rightarrow \mathbb{R}$ terdiferensialkan kontinu dan gradiennya L -Lipschitz. Maka

$$(5.30) \quad F(y) \leq F(x) + \langle \nabla F(x), y - x \rangle + \frac{L}{2} \|y - x\|^2.$$

Bukti. Dari teorema dasar kalkulus dan sifat L -halus, kita mempunyai

$$(5.31) \quad \begin{aligned} F(y) - F(x) &= \int_0^1 \frac{d}{dt} F(x + t(y - x)) dt \\ &= \int_0^1 \langle \nabla F(x + t(y - x)), y - x \rangle dt \\ &= \int_0^1 \langle \nabla F(x + t(y - x)) - \nabla F(x), y - x \rangle dt + \int_0^1 \langle \nabla F(x), y - x \rangle dt \\ &\leq \int_0^1 L t \|y - x\|^2 dt + \langle \nabla F(x), y - x \rangle \\ &= \frac{L}{2} \|y - x\|^2 + \langle \nabla F(x), y - x \rangle. \end{aligned}$$

□

Untuk bukti konvergensi metode gradien proksimal, bagi $\tau > 0$ kita perkenalkan notasi

$$(5.32) \quad T_\tau(x) = \frac{1}{\tau}(x - \text{prox}_{\tau g}(x - \tau \nabla f(x))).$$

Dengan fungsi ini, pembaruan gradien proksimal dapat ditulis sebagai

$$(5.33) \quad x_{k+1} = x_k - \tau_k T_{\tau_k}(x_k).$$

Teorema 5.11. Misalkan $f : \mathbb{R}^d \rightarrow \mathbb{R}$ konveks dan L -halus dengan $L > 0$, serta $g : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, semikontinu bawah, dan konveks. Andaikan $\arg \min_x F(x) \neq \emptyset$ dan terdapat $\tau_{\min} > 0$ sedemikian sehingga $0 < \tau_{\min} \leq \tau_k \leq L^{-1}$ untuk semua k . Untuk setiap $x^* \in \arg \min_x F(x)$, algoritma gradien proksimal memenuhi

$$(5.34) \quad F(x_n) - F(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min}n} \quad (n \geq 1).$$

Selain itu, x_k berkonvergensi menuju suatu $\hat{x} \in \arg \min_x F(x)$.

Bukti. Dari definisi T_τ , kita mempunyai

$$(5.35) \quad T_{\tau_k}(x_k) - \nabla f(x_k) \in \partial g(x_k - \tau_k T_{\tau_k}(x_k)) = \partial g(x_{k+1}).$$

Dengan memakai hubungan ini, kekonveksan f , Lemma 5.10, dan $\tau_k \leq L^{-1}$, untuk setiap $z \in \mathbb{R}^d$ diperoleh

$$(5.36) \quad \begin{aligned} F(x_{k+1}) &\leq f(x_k) - \tau_k \langle \nabla f(x_k), T_{\tau_k}(x_k) \rangle + \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\ &\quad + g(z) - \langle T_{\tau_k}(x_k) - \nabla f(x_k), z - (x_k - \tau_k T_{\tau_k}(x_k)) \rangle \\ &\leq f(z) + g(z) - \langle \nabla f(x_k), z - x_k \rangle - \tau_k \langle \nabla f(x_k), T_{\tau_k}(x_k) \rangle + \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\ &\quad - \langle T_{\tau_k}(x_k) - \nabla f(x_k), z - (x_k - \tau_k T_{\tau_k}(x_k)) \rangle \\ &= F(z) - \langle T_{\tau_k}(x_k), z - x_k \rangle - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2. \end{aligned}$$

Dengan mengambil $z = x_k$, kita memperoleh

$$(5.37) \quad F(x_{k+1}) \leq F(x_k) - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2.$$

Jadi, nilai objektif tidak meningkat dan turun ketat kecuali jika $T_{\tau_k}(x_k) = 0$; menurut lemma titik tetap, kasus terakhir berarti x_k optimal. Di sisi lain, ambil $z = x^*$ dan gunakan $T_{\tau_k}(x_k) = \tau_k^{-1}(x_k - x_{k+1})$. Maka

$$(5.38) \quad \begin{aligned} 0 \leq F(x_{k+1}) - F(x^*) &\leq \langle T_{\tau_k}(x_k), x_k - x^* \rangle - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\ &= \frac{1}{2\tau_k} (2 \langle x_k - x_{k+1}, x_k - x^* \rangle - \|x_k - x_{k+1}\|^2) \\ &= \frac{1}{2\tau_k} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2). \end{aligned}$$

Khususnya, $\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \geq 0$, sehingga jarak ke setiap peminim tidak meningkat. Dengan menjumlahkan untuk $k = 0, \dots, n-1$, kita memperoleh

$$\begin{aligned}
 \sum_{k=0}^{n-1} (F(x_{k+1}) - F(x^*)) &\leq \sum_{k=0}^{n-1} \frac{1}{2\tau_k} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2) \\
 (5.39) \qquad \qquad \qquad &\leq \frac{1}{2\tau_{\min}} \sum_{k=0}^{n-1} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2) \\
 &= \frac{1}{2\tau_{\min}} (\|x_0 - x^*\|^2 - \|x_n - x^*\|^2).
 \end{aligned}$$

Karena $F(x_k) - F(x^*)$ juga tidak meningkat,

$$(5.40) \qquad n(F(x_n) - F(x^*)) \leq \sum_{k=0}^{n-1} (F(x_{k+1}) - F(x^*)) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min}}.$$

Jadi,

$$(5.41) \qquad F(x_n) - F(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min}n}.$$

Terakhir, kita buktikan konvergensi $(x_k)_k$. Perhitungan di atas menunjukkan bahwa $\|x_k - x^*\|$ tidak meningkat untuk setiap peminim x^* . Dengan demikian, $(x_k)_k$ terbatas dan, di ruang berdimensi hingga, mempunyai subbarisan konvergen. Misalkan $\hat{x} = \lim_j x_{n(j)}$ adalah suatu titik akumulasi. Karena $F(x_k) \rightarrow \min F$ dan $F = f + g$ semikontinu bawah,

$$F(\hat{x}) \leq \liminf_j F(x_{n(j)}) = \lim_k F(x_k) = \min F.$$

Jadi, $\hat{x}$ adalah peminim dan $\|x_k - \hat{x}\|$ tidak meningkat. Karena itu, terdapat $c \geq 0$ dengan $\|x_k - \hat{x}\| \rightarrow c$. Namun,

$$(5.42) \qquad c = \lim_k \|x_k - \hat{x}\| = \lim_j \|x_{n(j)} - \hat{x}\| = 0.$$

Maka seluruh barisan berkonvergensi ke $\hat{x}$, dan bukti selesai. $\square$

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber.

- (i) Laju subgradien pembuka dikualifikasi sebagai laju dasar atau kasus terburuk; fungsi dinyatakan proper, semikontinu bawah, dan konveks, serta ukuran langkah implisit disyaratkan positif sebelum inklusi diubah menjadi kondisi optimalitas.
- (ii) Bukti keunikan proks kini memakai objektif skalar q_x , dua peminim yang berbeda, dan ketaksamaan titik tengah yang benar; sumber mengulang y_1 dan menyamakan nilai skalar dengan sebuah himpunan arg min.
- (iii) Karakterisasi titik tetap memakai satu $\tau > 0$ yang tetap dan membuktikan ekuivalensi dengan $0 \in \partial(f + g)(x)$; pernyataan sumber tidak benar jika ukuran langkah nol diizinkan.
- (iv) Definisi selubung Moreau memakai inf sebelum ketercapaian dibuktikan dan mensyaratkan $\tau > 0$. Kuadrat yang hilang pada jarak proks juga dipulihkan.
- (v) Contoh proyeksi mensyaratkan himpunan tak kosong, dan salah tik x_t pada ambang lunak diperbaiki menjadi x_i .
- (vi) Aturan komputasi proks diberi domain vektor dan skalar yang benar, asumsi yang menjamin proks bernilai tunggal, serta syarat $\gamma \geq 0$.
- (vii) Bukti penghalusan Moreau kini memberi argumen kekonveksan yang sah untuk fungsi bernilai diperluas, memperbaiki ekspansi yang memakai $p(\gamma)$, mendefinisikan residu keterdiferensialan secara konsisten, dan menempatkan subgradien pada $p(x)$.
- (viii) Kemunculan label sumber yang kedua dan duplikat, `proximal:eq:moreau_diff2`, dipetakan ke label unik `proximal:eq:moreau_diff2_bound`; kemunculan pertama dipertahankan.
- (ix) Contoh sumber yang belum selesai, ?Projection, 1 norm, 2 norm?, dilengkapi dengan rumus proyeksi, ambang lunak, dan penyusutan Euklides, termasuk konvensi pada nol.

- (x) Teorema konvergensi kini mensyaratkan $L > 0$, himpunan peminim tak kosong, dan $0 < \tau_{\min} \leq \tau_k \leq 1/L$. Faktor dua pada identitas polarisasi, indeks penjumlahan, batas laju, dan bukti konvergensi ke suatu peminim diperbaiki.
- (xi) Dua rujukan silang yang tidak termuat diganti dengan nama prasyarat yang tepat: metode langsung untuk keberadaan peminim dan argumen infimum parsial untuk kekonveksan. Sitasi Beck tetap memakai bibliografi sumber yang dibekukan.

BIBLIOGRAFI

A. BECK (2017), *First-order methods in optimization*, SIAM.

ATRIBUSI DAN LISENSI

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.

OPTIMISASI KONVEKS

UNIT 6: AKSELERASI
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 6, *Acceleration*, dari versi sumber yang ditentukan di atas. Unit ini melanjutkan Unit 5. Pembaca diharapkan telah mengenal fungsi konveks dan konveks kuat, gradien Lipschitz, Hessian, radius spektral, operator proksimal, serta metode gradien proksimal.

Urutan hasil, struktur bukti, seluruh rumus, tujuh pengenalan rujukan silang, dan ajakan verifikasi sumber dipertahankan. Sejumlah kekeliruan matematis dalam sumber diperbaiki secara terbuka; ringkasannya disertakan pada akhir unit dan rekaman terstruktur lengkap menyertai sumber edisi ini. Tidak ada sitasi, gambar, atau catatan kaki dalam bab sumber. Tidak ada layanan daring atau perangkat lunak tertutup yang diperlukan untuk membaca unit ini.

DAFTAR ISI

6	AKSELERASI	1
6.1	Metode bola berat Polyak	1
6.2	Akselerasi Nesterov	6

6 AKSELERASI

Untuk setiap $L > 0$, titik awal $x_0 \in \mathbb{R}^d$, bilangan bulat $k \geq 1$, dan $d \geq 2k + 1$, serta untuk setiap metode orde pertama yang iterasinya memenuhi

$$(6.1) \quad x_k \in x_0 + \text{span}\{\nabla f(x_0), \dots, \nabla f(x_{k-1})\}$$

terdapat fungsi konveks $f : \mathbb{R}^d \rightarrow \mathbb{R}$ yang bergradien L -Lipschitz dan mempunyai minimum x^* , sedemikian sehingga

$$(6.2) \quad f(x_k) - f(x^*) \geq \frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}.$$

Perhatikan bahwa sejauh ini kita belum memperoleh laju konvergensi yang lebih baik daripada $O(1/k)$. Menutup kesenjangan menuju $O(1/k^2)$ merupakan tujuan bab ini.

6.1 METODE BOLA BERAT POLYAK

Penurunan gradien untuk meminimumkan masalah tak terkendala

$$(6.3) \quad \min_x f(x)$$

dapat ditafsirkan sebagai diskretisasi dari *aliran gradien*

$$(6.4) \quad \dot{x} = -\nabla f(x).$$

Jika fungsi f ditafsirkan sebagai potensial, maka $-\nabla f$ merupakan gaya yang ditimbulkan potensial tersebut pada sebuah partikel bermassa satu. Secara alami kita dapat menambahkan gesekan ke dalam model ini. Gaya gesek biasanya dimodelkan sebanding dengan kecepatan, sehingga diperoleh

$$(6.5) \quad \ddot{x} = -\gamma\dot{x} - \nabla f(x).$$

Kita mendiskretkan persamaan diferensial biasa ini melalui $\dot{x}(t) \approx \frac{x(t) - x(t-h)}{h}$ dan

$$(6.6) \quad \ddot{x}(t) \approx \frac{\dot{x}(t+h) - \dot{x}(t)}{h} \approx \frac{x(t+h) - 2x(t) + x(t-h)}{h^2}.$$

Dengan menamai $x(t - h) = x_{k-1}$, $x(t) = x_k$, dan $x(t + h) = x_{k+1}$, substitusi ke dalam persamaan (6.5) memberikan

$$(6.7) \quad x_{k+1} - 2x_k + x_{k-1} = -h\gamma(x_k - x_{k-1}) - h^2 \nabla f(x_k).$$

Setelah ditata ulang, pembaruannya menjadi

$$(6.8) \quad x_{k+1} = x_k + (1 - \gamma h)(x_k - x_{k-1}) - h^2 \nabla f(x_k).$$

Dengan menamai ulang konstanta dan mengizinkannya bergantung pada iterasi, kita sampai pada *metode bola berat Polyak*

$$(6.9) \quad x_{k+1} = x_k + \beta_k(x_k - x_{k-1}) - \tau_k \nabla f(x_k).$$

Bahkan tanpa penurunan dari sudut pandang persamaan diferensial, aturan pembaruan ini cukup intuitif: selain arah penurunan bagi f , pembaruan tersebut memuat suku *inersia* yang menambahkan komponen searah dengan langkah sebelumnya.

Bukti konvergensi metode bola berat akan memakai hasil dasar aljabar linear berikut, yang disertakan demi kelengkapan.

Lema 6.1. Untuk setiap $A \in \mathbb{R}^{d \times d}$, dengan $\|\cdot\|$ norma operator yang diinduksi oleh norma Euclidean, berlaku $\lim_{n \rightarrow \infty} \|A^n\|^{1/n} = \rho(A)$, dengan

$$(6.10) \quad \rho(A) = \max_i |\lambda_i(A)|$$

dan $\lambda_i(A)$ nilai eigen A . Kesimpulan yang sama berlaku bagi setiap norma matriks yang kompatibel, karena semua norma pada ruang matriks berdimensi hingga ekuivalen.

Bukti. Kompleksifikasikan A ke operator pada $\mathbb{C}^d$. Norma operator Euclidean untuk matriks real sama pada $\mathbb{R}^d$ dan $\mathbb{C}^d$. Ambil nilai eigen kompleks λ dengan $|\lambda| = \rho(A)$ serta vektor eigennya $v \in \mathbb{C}^d$ yang dinormalisasi. Maka

$$(6.11) \quad \|A^n\|^{1/n} \geq \|A^n v\|^{1/n} = |\lambda| = \rho(A),$$

sehingga $\liminf_{n \rightarrow \infty} \|A^n\|^{1/n} \geq \rho(A)$.

Untuk ketaksamaan sebaliknya, gunakan bentuk normal Jordan kompleks

$$(6.12) \quad A = BDB^{-1}.$$

Setelah blok-blok Jordan diurutkan, matriks D dapat ditulis sebagai

$$(6.13) \quad D = \begin{pmatrix} \lambda_1 & \varepsilon_1 & \dots & \dots \\ 0 & \lambda_2 & \varepsilon_2 & \dots \\ & & \ddots & \ddots \\ & & \dots & \lambda_{d-1} & \varepsilon_{d-1} \\ & & & 0 & \lambda_d \end{pmatrix},$$

dengan $\varepsilon_i \in \{0, 1\}$, dan $\varepsilon_i = 1$ hanya jika posisi i dan $i + 1$ berada dalam blok Jordan yang sama sehingga $\lambda_i = \lambda_{i+1}$. Tuliskan $D = \Lambda + N$, dengan Λ diagonal dan N bagian nilpoten. Kedua matriks ini komutatif. Jika ukuran blok Jordan terbesar adalah m , maka $N^m = 0$. Untuk $\rho(A) > 0$ dan $n \geq m - 1$, ekspansi binomial memberi

$$\begin{aligned}
 \|D^n\| &= \left\| \sum_{j=0}^{m-1} \binom{n}{j} \Lambda^{n-j} N^j \right\| \\
 (6.14) \quad &\leq \sum_{j=0}^{m-1} \binom{n}{j} \|\Lambda^{n-j}\| \|N^j\| \\
 &\leq C_\rho n^{m-1} \rho(A)^{n-m+1},
 \end{aligned}$$

untuk suatu konstanta $C_\rho > 0$ yang tidak bergantung pada n . Jika $\rho(A) = 0$, semua elemen diagonal nol, sehingga $D = N$ dan $D^n = 0$ bagi $n \geq m$; jadi kesimpulan langsung berlaku. Untuk $\rho(A) > 0$, batas di atas menghasilkan

$$(6.15) \quad \|D^n\|^{1/n} \leq C_\rho^{1/n} n^{(m-1)/n} \rho(A)^{1-(m-1)/n}.$$

Karena $C_\rho^{1/n} \rightarrow 1$, $n^{1/n} \rightarrow 1$, dan $\rho(A)^{-(m-1)/n} \rightarrow 1$, kita memperoleh

$$(6.16) \quad \limsup_{n \rightarrow \infty} \|D^n\|^{1/n} \leq \rho(A).$$

Akhirnya,

$$(6.17) \quad \limsup_{n \rightarrow \infty} \|A^n\|^{1/n} = \limsup_{n \rightarrow \infty} \|BD^nB^{-1}\|^{1/n} \leq \limsup_{n \rightarrow \infty} \|B\|^{1/n} \|D^n\|^{1/n} \|B^{-1}\|^{1/n} \leq \rho(A),$$

yang, bersama batas bawah, membuktikan hasilnya. $\square$

Korolari 6.2. *Berlaku $\lim_{k \rightarrow \infty} A^k = 0$ jika dan hanya jika $\rho(A) < 1$. Selain itu, dalam hal ini, untuk setiap $\varepsilon > 0$ terdapat $c(\varepsilon) > 0$ sedemikian sehingga $\|A^k\| \leq c(\varepsilon)(\rho(A) + \varepsilon)^k$.*

Bukti. Jika $A^k \rightarrow 0$, maka untuk setiap pasangan eigen kompleks (λ, v) berlaku $A^k v = \lambda^k v \rightarrow 0$; akibatnya $|\lambda| < 1$ dan $\rho(A) < 1$. Sebaliknya, jika $\rho(A) < 1$, pilih $0 < \varepsilon_0 < 1 - \rho(A)$. Berdasarkan [teorema 6.1](#), terdapat n sedemikian sehingga untuk $k \geq n$,

$$(6.18) \quad \|A^k\| \leq (\rho(A) + \varepsilon_0)^k,$$

yang menuju nol. Untuk pernyataan kuantitatif dan sembarang $\varepsilon > 0$, [teorema 6.1](#) memberikan batas tersebut untuk semua k yang cukup besar. Dengan memperbesar konstanta untuk indeks awal yang berhingga banyaknya, kita dapat memilih

$$(6.19) \quad c(\varepsilon) \geq \max_{0 \leq k < n} \frac{\|A^k\|}{(\rho(A) + \varepsilon)^k},$$

sehingga batas berlaku bagi setiap $k \geq 0$. $\square$

Sekarang kita dapat membuktikan konvergensi metode bola berat. Tekniknya baku: kita menganalisis nilai eigen linearisasi aturan pembaruan.

Teorema 6.3 (Konvergensi bola berat). Misalkan $f \in C^2(U)$ pada suatu lingkungan $U \subset \mathbb{R}^d$ dari peminim stasioner lokal x^* , dengan

$$(6.20) \quad \nabla f(x^*) = 0, \quad 0 < \mu \leq L, \quad \mu \text{Id} \preceq \nabla^2 f(x^*) \preceq L \text{Id}, \quad 0 \leq \beta < 1, \quad 0 < \tau < \frac{2(1+\beta)}{L}.$$

Gunakan parameter konstan $\beta_k = \beta$ dan $\tau_k = \tau$. Terdapat $\varepsilon > 0$ sedemikian sehingga, jika $x_0, x_1 \in B_\varepsilon(x^*)$, maka $x_k \rightarrow x^*$. Lebih khusus, dengan

$$(6.21) \quad q = \rho(\mathcal{H}) < 1, \quad \|x_k - x^*\| \leq c(\delta)(q + \delta)^{k-1} \|(x_1 - x^*, x_0 - x^*)\|$$

untuk setiap $0 < \delta < 1 - q$. Jika yang diketahui tentang kurvatur hanya selang $[\mu, L]$, parameter yang meminimumkan radius spektral kasus terburuk dari model kuadratik atau linearisasi lokal adalah

$$(6.22) \quad q_{\text{wc}} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}, \quad \tau = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta = \left(\frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2.$$

Bukti. Tetapkan $u_k = x_k - x^*$. Karena $\nabla f(x^*) = 0$, rekursi kedalaman dua dapat ditulis tepat sebagai

$$(6.23) \quad \begin{aligned} \begin{bmatrix} u_{k+1} \\ u_k \end{bmatrix} &= \begin{bmatrix} (1+\beta)u_k - \beta u_{k-1} - \tau(\nabla f(x^* + u_k) - \nabla f(x^*)) \\ u_k \end{bmatrix} \\ &= \begin{pmatrix} (1+\beta) \text{Id} & -\beta \text{Id} \\ \text{Id} & 0 \end{pmatrix} \begin{bmatrix} u_k \\ u_{k-1} \end{bmatrix} - \tau(\nabla f(x^* + u_k) - \nabla f(x^*), 0). \end{aligned}$$

Untuk menyiapkan linearisasi, definisikan vektor keadaan dan matriks linear

$$(6.24) \quad s_k := \begin{bmatrix} u_k \\ u_{k-1} \end{bmatrix}, \quad \mathcal{H} := \begin{pmatrix} (1+\beta) \text{Id} - \tau \nabla^2 f(x^*) & -\beta \text{Id} \\ \text{Id} & 0 \end{pmatrix}, \quad s_{k+1} := \begin{bmatrix} u_{k+1} \\ u_k \end{bmatrix}.$$

Teorema dasar kalkulus memberikan

$$(6.25) \quad \begin{aligned} \nabla f(x^* + u_k) - \nabla f(x^*) &= \int_0^1 \nabla^2 f(x^* + t u_k) u_k dt \\ &= \nabla^2 f(x^*) u_k + r_k, \quad r_k := \left[\int_0^1 (\nabla^2 f(x^* + t u_k) - \nabla^2 f(x^*)) dt \right] u_k. \end{aligned}$$

Dengan demikian, rekursi keadaan yang tepat ialah

$$(6.26) \quad \begin{bmatrix} u_{k+1} \\ u_k \end{bmatrix} = \underbrace{\begin{pmatrix} (1+\beta) \text{Id} - \tau \nabla^2 f(x^*) & -\beta \text{Id} \\ \text{Id} & 0 \end{pmatrix}}_{\mathcal{H}} \begin{bmatrix} u_k \\ u_{k-1} \end{bmatrix} + \begin{bmatrix} -\tau r_k \\ 0 \end{bmatrix}.$$

Kontinuitas Hessian menunjukkan $r_k = o(\|u_k\|)$ ketika $u_k \rightarrow 0$.

Berdasarkan [teorema 6.2](#), kita menganalisis nilai eigen $\mathcal{H}$. Jika (v, w) merupakan vektor eigen dengan nilai eigen λ , maka

$$(6.27) \quad \begin{cases} ((1 + \beta) \text{Id} - \tau \nabla^2 f(x^*))v - \beta w &= \lambda v, \\ v &= \lambda w. \end{cases}$$

Dengan menghitung determinan blok, atau mengeliminasi relasi di atas tanpa pernah membagi dengan λ , setiap nilai eigen berkaitan dengan suatu $\eta \in [\mu, L]$ dan memenuhi

$$(6.28) \quad p_\eta(\lambda) := \lambda^2 - (1 + \beta - \tau\eta)\lambda + \beta = 0.$$

Jadi, dengan $a_\eta = 1 + \beta - \tau\eta$, penyempurnaan kuadrat memberikan

$$(6.29) \quad \left(\lambda - \frac{a_\eta}{2}\right)^2 = \left(\frac{a_\eta}{2}\right)^2 - \beta.$$

Akar dalam (6.29) berada ketat di dalam lingkaran satuan jika dan hanya jika kriteria Schur–Jury untuk polinom monik kuadrat real berikut terpenuhi:

$$(6.30) \quad |\beta| < 1, \quad 1 - a_\eta + \beta > 0, \quad 1 + a_\eta + \beta > 0, \quad \iff \quad \beta < 1, \quad \tau\eta > 0, \quad \tau\eta < 2(1 + \beta).$$

Hipotesis teorema memenuhi syarat ini bagi semua $\eta \in [\mu, L]$, termasuk kasus $\beta = 0$; oleh sebab itu $q = \rho(\mathcal{H}) < 1$.

Ambil $0 < \delta < 1 - q$. Terdapat norma ekuivalen $\|\cdot\|_\delta$ pada $\mathbb{R}^{2d}$ yang norma operator terinduksinya memenuhi $\|\mathcal{H}\|_\delta \leq q + \delta/2$. Karena $r(u) = o(\|u\|)$ dan semua norma berdimensi hingga ekuivalen, lingkungan x^* dapat diperkecil sehingga suku gangguan memenuhi batas yang diperlukan. Maka rekursi keadaan menghasilkan

$$(6.31) \quad \|s_{k+1}\|_\delta \leq \|\mathcal{H}\|_\delta \|s_k\|_\delta + \|(-\tau r_k, 0)\|_\delta \leq (q + \delta) \|s_k\|_\delta, \quad \|s_k\|_\delta \leq (q + \delta)^{k-1} \|s_1\|_\delta.$$

Dengan memilih x_0, x_1 cukup dekat ke x^* , bola kecil yang digunakan di atas tetap invarian. Ekuivalensi norma lalu memberikan estimasi dalam pernyataan teorema dan konvergensi lokal.

Tinggal membuktikan optimalitas kasus terburuk yang dinyatakan. Kasus $L = \mu$ langsung: pilihan $\beta = 0$ dan $\tau = 1/L$ membuat $a_\eta = 0$ dan kedua akar nol. Sekarang andaikan $L > \mu$. Untuk setiap radius kasus terburuk yang diklaim $r > 0$, kasus $r \geq 1$ tidak dapat memperbaiki laju yang akan diperoleh, jadi cukup tinjau $0 < r < 1$. Terapkan kriteria Schur–Jury setelah penskalaan $\lambda = rz$. Agar kedua akar setiap polinom p_η bermodulus paling besar r , perlu $0 \leq \beta \leq r^2$ dan $|a_\mu|, |a_L| \leq R$, dengan $R := r + \beta/r$.

Tetapkan $h = (L - \mu)/(L + \mu)$. Karena $La_\mu - \mu a_L = (L - \mu)(1 + \beta)$, kelayakan kedua titik ujung mengharuskan $R \geq h(1 + \beta)$. Selisih $R - h(1 + \beta) = r - h + \beta(1/r - h)$ meningkat

terhadap β pada $0 \leq \beta \leq r^2$, sebab $0 < r < 1$ dan $0 < h < 1$. Oleh karena itu, bahkan nilai maksimumnya harus tak negatif: $2r - h(1 + r^2) \geq 0$. Jadi $2r \geq h(1 + r^2)$, yang pada $0 < r < 1$ ekuivalen dengan $r \geq (\sqrt{L} - \sqrt{\mu})/(\sqrt{L} + \sqrt{\mu})$.

Kesamaan memaksa $\beta = r^2$ serta $a_\mu = 2r$ dan $a_L = -2r$. Menyelesaikan kedua hubungan ujung tersebut menghasilkan

$$(6.32) \quad \begin{aligned} 1 + \beta - \tau\mu &= 2\sqrt{\beta}, & 1 + \beta - \tau L &= -2\sqrt{\beta} \\ \implies \sqrt{\beta} &= q_{wc} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}, & \tau &= \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}. \end{aligned}$$

Dengan pilihan ini, a_η bergerak linear dari $2q_{wc}$ ke $-2q_{wc}$, sehingga semua akar untuk $\eta \in [\mu, L]$ bermodulus paling besar q_{wc} . Batas bawah di atas membuktikan bahwa nilai maksimum tersebut tidak dapat diperkecil. Optimalitas ini merupakan optimalitas radius spektral kasus terburuk bagi fungsi kuadratik dan bagi model asimtotik lokal C^2 , bukan jaminan konvergensi global bagi semua fungsi konveks mulus. $\square$

Latihan verifikasi. Verifikasikan kriteria Schur–Jury di atas langsung dari rumus akar, termasuk kasus $\beta = 0$, dan turunkan kembali parameter kasus terburuk dengan menyamakan perilaku pada $\eta = \mu$ dan $\eta = L$.

6.2 AKSELERASI NESTEROV

Metode Polyak optimal dalam arti radius spektral kasus terburuk bagi fungsi kuadratik konveks kuat, dan secara lokal bagi model C^2 di sekitar peminim. Akselerasi berikut mencapai laju orde optimal di bawah asumsi global yang lebih lemah. Kita kembali meninjau masalah

$$(6.33) \quad \min_{x \in \mathbb{R}^d} F(x) := f(x) + g(x),$$

dengan $f : \mathbb{R}^d \rightarrow \mathbb{R}$ konveks, terdiferensialkan, dan bergradien L -Lipschitz untuk $L > 0$, sedangkan $g : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, semikontinu bawah, dan konveks. Andaikan $\arg \min F \neq \emptyset$. Dengan $x_0 = x_1$, $t_1 = 1$, ukuran langkah tetap $0 < \tau \leq 1/L$, dan $k = 1, 2, \dots$, pembaruan *fast iterative shrinkage-thresholding algorithm* (FISTA, atau metode gradien proksimal cepat) ialah

$$(6.34) \quad \begin{cases} t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \\ \beta_k &= \frac{t_k - 1}{t_{k+1}}, \\ y_k &= x_k + \beta_k(x_k - x_{k-1}), \\ x_{k+1} &= \text{prox}_{\tau g}(y_k - \tau \nabla f(y_k)). \end{cases}$$

Jika $g \equiv 0$, metode ini sangat mirip dengan algoritma bola berat. Namun, gradien kini dievaluasi setelah suku inersia ditambahkan, dan konvergensiya bergantung pada pemilihan adaptif parameter inersia yang cermat.

Lema 6.4. *Tetapkan $t_1 = 1$. Maka*

$$(6.35) \quad t_k \geq \frac{k+1}{2}$$

untuk setiap $k \geq 1$.

Bukti. Bukti mengikuti induksi langsung. Pernyataan benar untuk $k = 1$. Dengan memakai hipotesis induksi, kita memperoleh

$$(6.36) \quad t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2} \geq \frac{1 + \sqrt{1 + (k+1)^2}}{2} \geq \frac{k+2}{2}.$$

□

Lema 6.5 (Ketaksamaan fundamental gradien proksimal). *Definisikan*

$$(6.37) \quad P_\tau(x) = \text{prox}_{\tau g}(x - \tau \nabla f(x)).$$

Di bawah hipotesis komposit di atas, untuk setiap $x, y \in \mathbb{R}^d$ dan $0 < \tau \leq 1/L$, berlaku

$$(6.38) \quad F(x) - F(P_\tau(y)) \geq \frac{1}{2\tau} \|x - P_\tau(y)\|^2 - \frac{1}{2\tau} \|x - y\|^2 + \ell_f(x, y),$$

dengan $\ell_f(x, y) = f(x) - f(y) - \langle x - y, \nabla f(y) \rangle$.

Bukti. Pertama, kita dapat menulis

$$(6.39) \quad \begin{aligned} P_\tau(y) &= \arg \min_z \frac{1}{2\tau} \|z - (y - \tau \nabla f(y))\|^2 + g(z) \\ &= \arg \min_z f(y) + \langle z - y, \nabla f(y) \rangle + \frac{1}{2\tau} \|z - y\|^2 + g(z). \end{aligned}$$

Sebagai catatan, identitas ini menunjukkan bahwa metode gradien proksimal dapat ditafsirkan sebagai langkah proksimal terhadap g ditambah pendekatan linear terhadap f . Definiskan

$$(6.40) \quad \varphi(z) = f(y) + \langle z - y, \nabla f(y) \rangle + \frac{1}{2\tau} \|z - y\|^2 + g(z).$$

Karena g konveks, φ bersifat $1/\tau$ -konveks kuat. Oleh karena itu,

$$(6.41) \quad \varphi(x) - \varphi(P_\tau(y)) \geq \frac{1}{2\tau} \|x - P_\tau(y)\|^2.$$

Lebih lanjut, karena f konveks dan L -halus serta $1/\tau \geq L$, lema penurunan memberikan

$$(6.42) \quad f(z) \leq f(y) + \langle z - y, \nabla f(y) \rangle + \frac{L}{2} \|z - y\|^2 \leq f(y) + \langle z - y, \nabla f(y) \rangle + \frac{1}{2\tau} \|z - y\|^2.$$

Khususnya, $\varphi(P_\tau(y)) \geq F(P_\tau(y))$, sehingga

$$(6.43) \quad \varphi(x) - F(P_\tau(y)) \geq \frac{1}{2\tau} \|x - P_\tau(y)\|^2.$$

Dengan memasukkan definisi φ dan memakai $f(y) + \langle x - y, \nabla f(y) \rangle = f(x) - \ell_f(x, y)$, penataan ulang hubungan terakhir tepat memberikan

$$(6.44) \quad F(x) - F(P_\tau(y)) \geq \frac{1}{2\tau} \|x - P_\tau(y)\|^2 - \frac{1}{2\tau} \|x - y\|^2 + \ell_f(x, y),$$

dan bukti selesai. $\square$

Teorema 6.6 (Konvergensi FISTA). Misalkan $f : \mathbb{R}^d \rightarrow \mathbb{R}$ konveks, terdiferensialkan, dan bergradien L -Lipschitz dengan $L > 0$; misalkan $g : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, semikontinu bawah, dan konveks; serta ambil $x^* \in \arg \min F$. Inisialisasikan FISTA dengan $x_0 = x_1$, $t_1 = 1$, dan ukuran langkah tetap $0 < \tau \leq 1/L$. Untuk setiap $k \geq 2$,

$$(6.45) \quad F(x_k) - F(x^*) \leq \frac{C}{\tau k^2}, \quad C = 2(t_2^2 \|x^* - x_1\|^2 + \|t_2(x^* - x_2) + (t_2 - 1)(x_1 - x^*)\|^2).$$

Bukti. Pilih $x = t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k$ dan $y = y_k$ dalam ketaksamaan fundamental gradien proksimal. Karena f konveks, $\ell_f(x, y) \geq 0$. Maka

$$(6.46) \quad \begin{aligned} & F(t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k) - F(x_{k+1}) \\ & \geq \frac{1}{2\tau} \|t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k - x_{k+1}\|^2 \\ & \quad - \frac{1}{2\tau} \|t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k - y_k\|^2 \\ & = \frac{1}{2\tau t_{k+1}^2} \|x^* + (t_{k+1} - 1)x_k - t_{k+1}x_{k+1}\|^2 \\ & \quad - \frac{1}{2\tau t_{k+1}^2} \|x^* + (t_{k+1} - 1)x_k - t_{k+1}y_k\|^2. \end{aligned}$$

Di sisi lain, menurut kekonveksan F dan fakta $t_k \geq 1$,

$$(6.47) \quad \begin{aligned} F(t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k) - F(x_{k+1}) & \leq t_{k+1}^{-1}F(x^*) + (1 - t_{k+1}^{-1})F(x_k) - F(x_{k+1}) \\ & = (1 - t_{k+1}^{-1})(F(x_k) - F(x^*)) - (F(x_{k+1}) - F(x^*)). \end{aligned}$$

Karena $y_k = x_k + \frac{t_k - 1}{t_{k+1}}(x_k - x_{k-1})$, kita mempunyai

$$(6.48) \quad \|x^* + (t_{k+1} - 1)x_k - t_{k+1}y_k\|^2 = \|x^* - t_k x_k + (t_k - 1)x_{k-1}\|^2.$$

Menggabungkan (6.46), (6.47), dan (6.48) memberikan

$$\begin{aligned}
 (6.49) \quad & t_{k+1}^2(1 - t_{k+1}^{-1})(F(x_k) - F(x^*)) - t_{k+1}^2(F(x_{k+1}) - F(x^*)) \\
 & \geq \frac{1}{2\tau} \|x^* - t_{k+1}x_{k+1} + (t_{k+1} - 1)x_k\|^2 \\
 & \quad - \frac{1}{2\tau} \|x^* - t_kx_k + (t_k - 1)x_{k-1}\|^2.
 \end{aligned}$$

Dari pembaruan FISTA berlaku $t_{k+1}^2(1 - t_{k+1}^{-1}) = t_k^2$. Jadi,

$$\begin{aligned}
 (6.50) \quad & t_k^2(F(x_k) - F(x^*)) - t_{k+1}^2(F(x_{k+1}) - F(x^*)) \\
 & \geq \frac{1}{2\tau} \|x^* - t_{k+1}x_{k+1} + (t_{k+1} - 1)x_k\|^2 \\
 & \quad - \frac{1}{2\tau} \|x^* - t_kx_k + (t_k - 1)x_{k-1}\|^2.
 \end{aligned}$$

Dengan demikian,

$$\begin{aligned}
 (6.51) \quad & t_k^2(F(x_k) - F(x^*)) + \frac{1}{2\tau} \|x^* - t_kx_k + (t_k - 1)x_{k-1}\|^2 \\
 & \geq t_{k+1}^2(F(x_{k+1}) - F(x^*)) + \frac{1}{2\tau} \|x^* - t_{k+1}x_{k+1} + (t_{k+1} - 1)x_k\|^2.
 \end{aligned}$$

Dengan mengiterasikan ketaksamaan ini, untuk $k \geq 2$ diperoleh

$$\begin{aligned}
 (6.52) \quad & t_2^2(F(x_2) - F(x^*)) + \frac{1}{2\tau} \|t_2(x^* - x_2) + (t_2 - 1)(x_1 - x^*)\|^2 \\
 & \geq t_k^2(F(x_k) - F(x^*)) + \frac{1}{2\tau} \|x^* - t_kx_k + (t_k - 1)x_{k-1}\|^2.
 \end{aligned}$$

Selain itu, ketaksamaan fundamental gradien proksimal dengan $x = x^*$ dan $y = y_1 = x_0 = x_1$ memberikan

$$(6.53) \quad F(x^*) - F(x_2) \geq \frac{1}{2\tau} \|x^* - x_2\|^2 - \frac{1}{2\tau} \|x^* - x_1\|^2.$$

Dengan membuang suku kuadrat nonnegatif pada ruas kanan estimasi energi dan memakai batas terakhir, kita menemukan

$$(6.54) \quad F(x_k) - F(x^*) \leq t_k^{-2} \left(\frac{t_2^2}{2\tau} \|x^* - x_1\|^2 + \frac{1}{2\tau} \|t_2(x^* - x_2) + (t_2 - 1)(x_1 - x^*)\|^2 \right).$$

Karena $t_k \geq (k + 1)/2$, batas dalam pernyataan teorema mengikuti. $\square$

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber.

- (i) Batas bawah kompleksitas pembuka kini memulihkan urutan kuantor bahwa untuk setiap metode terdapat fungsi, memuat norma kuadrat yang hilang, dan menyatakan secara eksplisit data awal serta hipotesis bahwa fungsi konveks, bergradien L -Lipschitz, mempunyai peminim dan dimensinya cukup besar untuk jumlah iterasi yang ditinjau.
- (ii) Bukti rumus Gelfand memakai norma operator yang jelas dan kompleksifikasi untuk nilai eigen nonreal. Bentuk Jordan hanya menempatkan satu pada superdiagonal di dalam satu blok, memakai indeks nilpotensi yang benar, menangani $\rho(A) = 0$ secara terpisah, dan memperbaiki pemilihan pangkat ekstrem pada batas.
- (iii) Bukti korolari radius spektral membuktikan arah $A^k \rightarrow 0 \Rightarrow \rho(A) < 1$ melalui vektor eigen dan menangani indeks awal dalam batas geometrik secara eksplisit.
- (iv) Teorema bola berat kini mensyaratkan fungsi C^2 di sekitar peminim stasioner, $0 < \mu \leq L$, serta parameter konstan. Klaim parameter optimal dibatasi pada radius spektral kasus terburuk bagi model kuadratik atau linearisasi lokal.
- (v) Rekursi keadaan tidak lagi memfaktorkan gradien nonlinear sebagai matriks. Selisih gradien dilinearkan melalui Hessian, residu didefinisikan dengan tepat, dan tanda gangguan keadaan diperbaiki menjadi $(-\tau r_k, 0)$.
- (vi) Polinom karakteristik diturunkan tanpa membagi dengan nilai eigen, sehingga kasus $\beta = 0$ tercakup. Batas akar yang keliru diganti dengan kriteria Schur–Jury dan bukti kestabilan lokal dalam norma ekuivalen.
- (vii) Parameter kasus terburuk kini disertai bukti batas bawah minimaks yang lengkap melalui kriteria Schur–Jury terskala, termasuk kasus kelengkungan tunggal $L = \mu$; kondisi kesamaan menghasilkan penyeimbangan kedua ujung spektrum $[\mu, L]$. Klaim optimalitas tidak lagi digeneralisasi menjadi jaminan global bagi semua fungsi konveks mulus.

- (viii) Bagian FISTA kini menyatakan domain, kekonveksan, semikontinuan bawah, keberadaan peminim, $L > 0$, $0 < \tau \leq 1/L$, inisialisasi, dan rentang indeks secara lengkap.
- (ix) Bukti ketaksamaan fundamental memperbaiki frasa kekonveksan g , memulihkan kuadrat yang hilang pada $\|z - y\|^2$, serta menata ulang substitusi fungsi model dengan benar.
- (x) Teorema FISTA kini menyatakan semua hipotesis komposit, menetapkan $k \geq 2$, dan memberi konstanta eksplisit yang bergantung pada inisialisasi. Identitas energi dan teleskop sumber dipertahankan.
- (xi) Salah ketik pada notasi waktu, frasa *bergantung pada iterasi*, komponen inersia, aljabar linear, pernyataan korolari, kemiripan FISTA, dan teks bukti diperbaiki tanpa mengubah isi matematis lainnya.

ATRIBUSI DAN LISENSI

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0. Catatan koreksi dan materi penghubung baru dinyatakan sebagai perubahan edisi; tidak ada dukungan atau pengesahan oleh penulis sumber maupun institusinya.

OPTIMISASI KONVEKS

UNIT 7: DUALITAS
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 7, “Duality”, dari Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1. Sumber berwenang untuk unit ini adalah berkas `duality.tex` edisi v1 dengan SHA-256 berikut:

0b112dee2582813cec5629c02df1dda32
9f690f944b60f4694b1c5762129bea9

Bab-bab prasyarat tidak diulang. Pembaca diharapkan telah mengenal ruang bernorma dan ruang Hilbert, dual dan adjoint operator, semikontinuitas bawah, epigraf dan pemisahan Hahn–Banach, subgradien, operator proksimal, serta dasar analisis konvergensi. Seluruh definisi, contoh, lema, teorema, bukti, latihan, sitasi, dan catatan kaki dalam bab sumber dipertahankan dalam urutan sumber. Kekeliruan yang dapat ditentukan secara matematis diperbaiki secara terbuka dan diringkas pada akhir unit.

Edisi ini berdiri sendiri untuk dibaca dan dibangun, tetapi tidak mengklaim menggantikan konteks lengkap catatan kuliah asal. Istilah teknis Indonesia dipakai secara konsisten; singkatan PDHG dan ADMM dipertahankan karena merupakan nama baku algoritme.

DAFTAR ISI

7	DUALITAS	1
7.1	Dualitas Fenchel	1
7.2	Optimisasi primal–dual	6
7.3	Metode pengali arah bergantian (ADMM)	9

DAFTAR PUSTAKA	14
----------------	----

7 DUALITAS

Dalam bab ini, semua ruang vektor dipahami sebagai ruang Hilbert riil berdimensi hingga. Dual yang digunakan adalah dual kontinu; melalui representasi Riesz kita mengidentifikasi $V^* \cong V$ dan, khususnya, $V^{**} \cong V$. Untuk setiap ruang demikian H , tuliskan $\Gamma_0(H)$ bagi kelas fungsi $H \rightarrow (-\infty, +\infty]$ yang proper, konveks, dan semikontinu bawah.

7.1 DUALITAS FENCHEL

Definisi 7.1 (Konjugat Fenchel/konveks). Misalkan $f : V \rightarrow (-\infty, +\infty]$ proper. Konjugat Fenchel, atau konjugat konveks, didefinisikan sebagai

$$(7.1) \quad \begin{aligned} f^* : V^* &\rightarrow (-\infty, +\infty] \\ f^*(x^*) &= \sup_{x \in V} \langle x^*, x \rangle - f(x). \end{aligned}$$

Contoh 7.2. (i) Fungsi indikator: Misalkan $f = \delta_C$ dengan $C \subset V$ tak kosong dan konveks. Maka $f^*(x^*) = \sup_{x \in C} \langle x^*, x \rangle$ adalah apa yang disebut fungsi pendukung.

(ii) Norma: Misalkan $f = \|\cdot\|$ adalah suatu norma. Maka $f^* = \delta_{\overline{B}_{\|\cdot\|,1}(0)}$. Artinya, f^* adalah fungsi indikator pada bola satuan tertutup terhadap norma dual.

(iii) Sebaliknya, konjugat dari $f = \delta_{\overline{B}_{\|\cdot\|,1}(0)}$ adalah $f^* = \|\cdot\|$ setelah identifikasi $V^{**} \cong V$.

Lema 7.3. Misalkan f proper dan konveks, serta andaikan bahwa $\partial f(\hat{x}) \neq \emptyset$ untuk suatu $\hat{x} \in V$. Dalam dimensi hingga, syarat tambahan ini otomatis dipenuhi pada suatu titik di interior relatif domain efektif; bandingkan [Beck 2017, Corollary 3.19]. Maka f^* proper, konveks, dan semikontinu bawah (lsc).

Bukti. Karena f proper, terdapat $x_0 \in V$ sedemikian sehingga $f(x_0) \in \mathbb{R}$. Akibatnya, untuk setiap x^* ,

$$(7.2) \quad f^*(x^*) \geq \langle x^*, x_0 \rangle - f(x_0) > -\infty.$$

Ambil $g \in \partial f(\hat{x})$. Berdasarkan definisi subgradien, kita mempunyai

$$(7.3) \quad f(\hat{x}) + \langle g, x - \hat{x} \rangle \leq f(x)$$

dan, dengan demikian,

$$(7.4) \quad \begin{aligned} f^*(g) &= \sup_{x \in V} \langle g, x \rangle - f(x) \\ &\leq \sup_{x \in V} f(x) - f(\hat{x}) + \langle g, \hat{x} \rangle - f(x) \\ &\leq \sup_{x \in V} -f(\hat{x}) + \langle g, \hat{x} \rangle < \infty. \end{aligned}$$

Kekonveksan dan semikontinuitas bawah langsung mengikuti fakta bahwa konjugat konveks merupakan supremum titik demi titik dari fungsi-fungsi afin kontinu, yang karena itu konveks dan lsc¹. $\square$

Lema 7.4 (Ketaksamaan Fenchel). *Misalkan f proper. Maka*

$$(7.5) \quad f^*(x^*) + f(x) \geq \langle x^*, x \rangle.$$

Bukti. Latihan. $\square$

Untuk fungsi proper f dengan f^* proper, proses pengambilan konjugat dapat kita *iterasikan* untuk memperoleh *bikonjugat*. Kondisi ini dijamin oleh lema sebelumnya pada kasus konveks yang memenuhi hipotesisnya. Demi kesederhanaan, kita tulis $f^{**} := (f^*)^*$. Karena diasumsikan $V^{**} = V$, bikonjugat kembali terdefinisi pada ruang asal V .

Lema 7.5. *Misalkan f dan f^* proper. Untuk setiap $x \in V$ berlaku $f^{**}(x) \leq f(x)$.*

Bukti. Pertama, perhatikan bahwa untuk setiap x , konjugat memenuhi

$$(7.6) \quad f^*(x^*) \geq \langle x^*, x \rangle - f(x).$$

Oleh karena itu,

$$(7.7) \quad \begin{aligned} f^{**}(x) &= \sup_{x^* \in V^*} \langle x^*, x \rangle - f^*(x^*) \\ &= \sup_{x^* \in V^*} \inf_y \langle x^*, x - y \rangle + f(y) \\ &\leq \sup_{x^* \in V^*} \langle x^*, x - x \rangle + f(x) \\ &= f(x). \end{aligned}$$

$\square$

¹Di sini kekonveksan telah ditunjukkan secara langsung. Rincian untuk lsc ditinggalkan sebagai latihan.

Lema 7.6. Misalkan f proper, konveks, dan lsc. Maka $f^{**} = f$.

Bukti. Karena selalu berlaku $f^{**} \leq f$, tinggal ditunjukkan bahwa $f^{**} \geq f$. Andaikan sebaliknya: terdapat $x_0 \in V$ sedemikian sehingga

$$(7.8) \quad f^{**}(x_0) < f(x_0).$$

Ini berarti $(x_0, f^{**}(x_0)) \notin \text{epi}(f)$. Karena $\text{epi}(f)$ tertutup dan konveks berdasarkan asumsi, teorema Hahn–Banach dapat diterapkan untuk mendapatkan $(g, \alpha) \in V^* \times \mathbb{R}$ dan $c_1, c_2 \in \mathbb{R}$ sedemikian sehingga

$$(7.9) \quad \langle (g, \alpha), (x_0, f^{**}(x_0)) \rangle < c_1 < c_2 < \langle (g, \alpha), (x, t) \rangle, \quad (x, t) \in \text{epi}(f).$$

Karena f proper, pilih $\bar{x} \in \text{dom}(f)$. Dengan memasukkan $(\bar{x}, t) \in \text{epi}(f)$ dan membiarkan $t \rightarrow \infty$, diperoleh $\alpha \geq 0$. Sekarang andaikan $\alpha > 0$. Kita dapat membagi dengan α dan memperoleh

$$(7.10) \quad \left\langle \frac{g}{\alpha}, x_0 - x \right\rangle + f^{**}(x_0) - f(x) \leq \frac{c_1 - c_2}{\alpha} < 0.$$

Ketaksamaan di atas berlaku untuk setiap $x \in \text{dom}(f)$ dan juga secara otomatis untuk setiap x dengan $f(x) = \infty$. Mengambil supremum terhadap x menghasilkan

$$(7.11) \quad \left\langle \frac{g}{\alpha}, x_0 \right\rangle + f^{**}(x_0) + f^*\left(-\frac{g}{\alpha}\right) < 0,$$

yang bertentangan dengan ketaksamaan Fenchel. Pada kasus yang tersisa, yaitu $\alpha = 0$, kita mempunyai

$$(7.12) \quad \langle g, x_0 - x \rangle < c_1 - c_2 < 0.$$

Ambil sembarang $\hat{y} \in \text{dom}(f^*)$. Untuk $\hat{g} = g - \varepsilon \hat{y}$, kita memperoleh

$$(7.13) \quad \begin{aligned} \langle \hat{g}, x_0 - x \rangle + \varepsilon(f^{**}(x_0) - f(x)) &\leq \langle g, x_0 - x \rangle + \varepsilon(\langle -\hat{y}, x_0 - x \rangle + f^{**}(x_0) - f(x)) \\ &\leq c_1 - c_2 + \varepsilon(\langle \hat{y}, -x_0 \rangle + f^{**}(x_0) + f^*(\hat{y})). \end{aligned}$$

Perhatikan bahwa $\hat{y}$ dan x_0 tetap. Karena itu, $\varepsilon > 0$ dapat dipilih cukup kecil agar ruas kanan tetap negatif ketat. Tuliskan $c := c_1 - c_2 + \varepsilon(\langle -\hat{y}, x_0 \rangle + f^{**}(x_0) + f^*(\hat{y})) < 0$. Setelah membagi dengan ε , diperoleh

$$(7.14) \quad \left\langle \frac{\hat{g}}{\varepsilon}, x_0 - x \right\rangle + f^{**}(x_0) - f(x) \leq \frac{c}{\varepsilon} < 0.$$

Sekali lagi mengambil supremum terhadap semua x menghasilkan

$$(7.15) \quad \left\langle \frac{\hat{g}}{\varepsilon}, x_0 \right\rangle + f^{**}(x_0) + f^*\left(-\frac{\hat{g}}{\varepsilon}\right) \leq \frac{c}{\varepsilon} < 0,$$

Hal ini bertentangan dengan ketaksamaan Fenchel. Jadi, asumsi $f^{**}(x_0) < f(x_0)$ selalu menimbulkan kontradiksi. Karena itu, $f^{**}(x_0) \geq f(x_0)$, dan bukti selesai. $\square$

Catatan. Jika f tidak sekaligus konveks dan tertutup, maka, selama keluarga minoran proper di bawah tidak kosong, f^{**} merupakan minoran konveks semikontinu bawah terbesar dari f , yang disebut regularisasi Γ . Lebih tepatnya, tuliskan

$$(7.16) \quad \Gamma(V) = \{\ell : V \rightarrow (-\infty, +\infty] \mid \ell \text{ proper, tertutup, dan konveks}\}.$$

Jika $\{\ell \in \Gamma(V) : \ell \leq f\} \neq \emptyset$, maka

$$(7.17) \quad f^{**}(x) = \sup_{\substack{\ell \in \Gamma(V), \\ \ell \leq f}} \ell(x).$$

Jika keluarga minoran tersebut kosong, supremum pada ruas kanan dipahami sebagai fungsi yang identik $-\infty$. Fungsi ini tidak termasuk dalam $\Gamma(V)$ dan, di bawah konvensi bab ini yang mendefinisikan konjugasi hanya bagi masukan proper, tidak dinotasikan sebagai f^{**} .

Konjugat mempunyai hubungan yang erat dengan subgradien, sebagaimana ditunjukkan oleh lema berikut.

Lema 7.7. *Misalkan f proper, konveks, dan tertutup. Pernyataan-pernyataan berikut ekuivalen:*

- (i) $f(x) + f^*(x^*) = \langle x^*, x \rangle$.
- (ii) $x^* \in \partial f(x)$.
- (iii) $x \in \partial f^*(x^*)$.

Bukti.

(i) $\rightarrow$ (ii): Pernyataan (i) menyiratkan bahwa untuk setiap $z \in V$,

$$(7.18) \quad -f(x) + \langle x^*, x \rangle = f^*(x^*) \geq \langle x^*, z \rangle - f(z).$$

Berdasarkan definisi, ini menyiratkan $x^* \in \partial f(x)$.

(ii) $\rightarrow$ (i): Sebaliknya, pernyataan (ii) menghasilkan, untuk setiap z ,

$$(7.19) \quad -f(x) + \langle x^*, x \rangle \geq \langle x^*, z \rangle - f(z).$$

Dengan mengambil supremum terhadap z , diperoleh $\langle x^*, x \rangle \geq f(x) + f^*(x^*)$. Bersama ketaksamaan Fenchel, ini membuktikan hasilnya.

(i) $\leftrightarrow$ (iii): Karena f proper, konveks, dan tertutup, pernyataan (i) ekuivalen dengan

$$(7.20) \quad f^{**}(x) + f^*(x^*) = \langle x^*, x \rangle.$$

Bukti kemudian diperoleh dengan mengulangi argumen di atas.

□

Teorema 7.8 (Identitas Moreau). Misalkan $f \in \Gamma_0(V)$. Maka

$$(7.21) \quad x = \text{prox}_f(x) + \text{prox}_{f^*}(x).$$

Bukti. Pertama, perhatikan bahwa kedua pemetaan proksimal terdefinisi dengan baik dan bernilai tunggal (mengapa?). Demi kesederhanaan, tuliskan $p = \text{prox}_f(x)$. Dari syarat optimalitas diperoleh $x - p \in \partial f(p)$ dan, berdasarkan [teorema 7.7](#), $p = x - (x - p) \in \partial f^*(x - p)$. Pernyataan terakhir menyiratkan $\text{prox}_{f^*}(x) = x - p$, sehingga bukti selesai. □

Teorema 7.9 (Fenchel–Rockafellar). Misalkan X dan Y ruang Hilbert riil berdimensi hingga, $f \in \Gamma_0(X)$, $g \in \Gamma_0(Y)$, dan $K : X \rightarrow Y$ operator linear terbatas. Selain itu, andaikan terdapat $x_0 \in \text{dom}(f) \cap \text{dom}(g \circ K)$ dengan $Kx_0 \in \text{dom}(g)^\circ$. Andaikan masalah (primal)

$$(7.22) \quad \min_x f(x) + g(Kx)$$

mempunyai solusi $\hat{x}$. Maka masalah dual

$$(7.23) \quad \max_{x^*} -f^*(-K^*x^*) - g^*(x^*)$$

juga mempunyai solusi $\hat{x}^*$, dan berlaku dualitas kuat, yaitu

$$(7.24) \quad \min_x f(x) + g(Kx) = \max_{x^*} -f^*(-K^*x^*) - g^*(x^*).$$

Selain itu, solusi primal dan dual memenuhi

$$(7.25) \quad \begin{cases} -K^*\hat{x}^* & \in \partial f(\hat{x}), \\ \hat{x}^* & \in \partial g(K\hat{x}). \end{cases}$$

Bukti. Pertama, secara langsung diperoleh

$$(7.26) \quad \begin{aligned} \inf_x f(x) + g(Kx) &= \inf_x f(x) + g^{**}(Kx) \\ &= \inf_x \sup_{x^*} f(x) + \langle Kx, x^* \rangle - g^*(x^*) \\ &\geq \sup_{x^*} \inf_x f(x) + \langle Kx, x^* \rangle - g^*(x^*) \\ &= \sup_{x^*} - \sup_x -f(x) + \langle x, -K^*x^* \rangle - g^*(x^*) \\ &= \sup_{x^*} -f^*(-K^*x^*) - g^*(x^*). \end{aligned}$$

Jadi, tinggal dibuktikan ketaksamaan sebaliknya. Hipotesis interior di atas memenuhi syarat kualifikasi bagi aturan jumlah dan rantai subdiferensial. Karena itu, kaidah Fermat pada peminimum $\hat{x}$ memberikan

$$0 \in \partial f(\hat{x}) + K^* \partial g(K\hat{x}).$$

Dengan kata lain, terdapat $\hat{x}^* \in \partial g(K\hat{x})$ sedemikian sehingga $-K^* \hat{x}^* \in \partial f(\hat{x})$. Berdasarkan [teorema 7.7](#), hal ini menyiratkan

$$(7.27) \quad \begin{aligned} g(K\hat{x}) + g^*(\hat{x}^*) &= \langle \hat{x}^*, K\hat{x} \rangle, \\ f(\hat{x}) + f^*(-K^* \hat{x}^*) &= -\langle K^* \hat{x}^*, \hat{x} \rangle = -\langle \hat{x}^*, K\hat{x} \rangle. \end{aligned}$$

Oleh karena itu,

$$(7.28) \quad \begin{aligned} \inf_x f(x) + g(Kx) &= f(\hat{x}) + g(K\hat{x}) \\ &= (-f^*(-K^* \hat{x}^*) - \langle \hat{x}^*, K\hat{x} \rangle) + (-g^*(\hat{x}^*) + \langle \hat{x}^*, K\hat{x} \rangle) \\ &= -f^*(-K^* \hat{x}^*) - g^*(\hat{x}^*) \\ &\leq \sup_{x^*} -f^*(-K^* x^*) - g^*(x^*). \end{aligned}$$

Ini membuktikan kesamaan dalam (7.26) sekaligus menunjukkan bahwa $\hat{x}^*$ adalah solusi masalah dual. $\square$

7.2 OPTIMISASI PRIMAL–DUAL

[Teorema 7.9](#) membuka kemungkinan beberapa metode untuk mencari solusi masalah berbentuk

$$(7.29) \quad \min_x f(x) + g(Kx).$$

Memang, berdasarkan dualitas kuat, kita dapat menangani masalah primal, masalah dual, atau masalah titik pelana

$$(7.30) \quad \min_x \sup_y \mathcal{L}(x, y) := f(x) - g^*(y) + \langle Kx, y \rangle.$$

Tujuan utama peralihan di antara formulasi primal dan dual adalah untuk *memindahkan* operator K . Misalnya, jika g tidak terdiferensialkan sehingga kita ingin menerapkan langkah proksimal pada g , operator K dalam (7.29) pada umumnya membuat $\text{prox}_{g \circ K}$ tidak mempunyai bentuk eksplisit. Sebaliknya, dalam formulasi titik pelana (7.30), operator K hanya muncul dalam hasil kali skalar. Selain itu, perhatikan bahwa menurut [teorema 7.8](#), proksimal suatu fungsi konjugat sama mudah atau sama sulit dihitung dengan proksimal fungsi asalnya. Lebih tepatnya, untuk $\sigma > 0$ berlaku $\text{prox}_{\sigma g^*}(y) = y - \sigma \text{prox}_{g/\sigma}(y/\sigma)$.

Kesenjangan primal–dual didefinisikan sebagai

$$(7.31) \quad \mathcal{G}(x, y) = (f(x) + g(Kx)) - (-f^*(-K^* y) - g^*(y)).$$

Lema 7.10. Di bawah hipotesis dualitas kuat dan ketercapaian primal–dual yang baru saja dinyatakan, kita mempunyai $\mathcal{G}(x, y) \geq 0$, dan $\mathcal{G}(\hat{x}, \hat{y}) = 0$ jika dan hanya jika $\hat{x}$ menyelesaikan masalah primal dan $\hat{y}$ menyelesaikan masalah dual. Kesenjangan tersebut mempunyai representasi

$$(7.32) \quad \mathcal{G}(x, y) = \sup_{y'} \mathcal{L}(x, y') - \inf_{x'} \mathcal{L}(x', y).$$

Khususnya, $(\hat{x}, \hat{y})$ masing-masing optimal untuk masalah primal dan dual jika dan hanya jika, untuk setiap x, y ,

$$(7.33) \quad \mathcal{L}(\hat{x}, y) \leq \mathcal{L}(\hat{x}, \hat{y}) \leq \mathcal{L}(x, \hat{y}).$$

Bukti. Latihan. □

Dengan melakukan optimisasi bergantian dalam (7.30), memakai langkah proksimal terhadap f dan g^* serta langkah gradien terhadap hasil kali dalam, kita memperoleh aturan pembaruan berikut yang dikenal sebagai metode Arrow–Hurwicz:

$$(7.34) \quad \begin{cases} x_{k+1} = \text{prox}_{\tau f}(x_k - \tau K^* y_k) \\ y_{k+1} = \text{prox}_{\sigma g^*}(y_k + \sigma K x_{k+1}). \end{cases}$$

Ternyata, dalam bentuk ini metode tersebut mempunyai sifat konvergensi yang lebih buruk. Untuk memperoleh pembaruan yang lebih baik, algoritme ditulis ulang secara cermat. Dengan memakai $\text{prox}_{\tau f}(x) = (\text{Id} + \tau \partial f)^{-1}(x)$, dapat diperiksa secara langsung bahwa (7.34) ekuivalen dengan

$$(7.35) \quad \begin{cases} x_{k+1} + \tau \partial f(x_{k+1}) = x_k - \tau K^* y_k \\ y_{k+1} + \sigma \partial g^*(y_{k+1}) = y_k + \sigma K x_{k+1}. \end{cases}$$

Setelah membagi masing-masing persamaan dengan τ dan σ , serta menggunakan notasi $z = (x, y)$, bentuk ini dapat ditulis sebagai

$$(7.36) \quad \begin{bmatrix} \frac{1}{\tau} \text{Id} + \partial f & 0 \\ -K & \frac{1}{\sigma} \text{Id} + \partial g^* \end{bmatrix} z_{k+1} = \begin{bmatrix} \frac{1}{\tau} \text{Id} & -K^* \\ 0 & \frac{1}{\sigma} \text{Id} \end{bmatrix} z_k.$$

Bahkan tanpa menelaah rincian bukti, wajar diharapkan bahwa pembaruan yang lebih *simetris* akan lebih baik, khususnya karena sifat menguntungkan matriks simetris. Karena itu, kita mempertimbangkan skema berikut, yang tidak mengubah titik tetap yang mungkin:

$$(7.37) \quad \begin{bmatrix} \frac{1}{\tau} \text{Id} + \partial f & 0 \\ -2K & \frac{1}{\sigma} \text{Id} + \partial g^* \end{bmatrix} z_{k+1} = \begin{bmatrix} \frac{1}{\tau} \text{Id} & -K^* \\ -K & \frac{1}{\sigma} \text{Id} \end{bmatrix} z_k.$$

Matriks pada ruas kanan kini simetris dan definit positif selama $\sigma\tau\|K\|^2 < 1$. Kembali ke operator proksimal, metode gradien hibrida primal–dual ini, yang sering disebut metode Chambolle–Pock berdasarkan [Chambolle & Pock 2011], berbentuk

$$(7.38) \quad \begin{cases} x_{k+1} = \text{prox}_{\tau f}(x_k - \tau K^* y_k) \\ y_{k+1} = \text{prox}_{\sigma g^*}(y_k + \sigma K(2x_{k+1} - x_k)). \end{cases}$$

Untuk analisis, PDHG akan ditulis dalam bentuk abstrak

$$(7.39) \quad \begin{cases} x^+ = \arg \min_x \frac{1}{2\tau}|x - x^-|^2 + \langle x, K^* \bar{y} \rangle + f(x) \\ y^+ = \arg \min_y \frac{1}{2\sigma}|y - y^-|^2 - \langle y, K\bar{x} \rangle + g^*(y). \end{cases}$$

Di sini, superskrip plus menyatakan variabel yang telah diperbarui, superskrip minus menyatakan iterasi lama, sedangkan garis atas masing-masing menyatakan nilai x yang digunakan untuk pembaruan y dan nilai y yang digunakan untuk pembaruan x .

Lema 7.11. Misalkan X dan Y ruang Hilbert riil berdimensi hingga, $f \in \Gamma_0(X)$, $g \in \Gamma_0(Y)$, $K : X \rightarrow Y$ linear terbatas, serta $\tau, \sigma > 0$. Aturan pembaruan (7.39) memenuhi

(7.40)

$$\begin{aligned} \mathcal{L}(x^+, y) - \mathcal{L}(x, y^+) &\leq \frac{1}{2\tau}|x - x^-|^2 + \frac{1}{2\sigma}|y - y^-|^2 \\ &\quad - \frac{1}{2\tau}|x - x^+|^2 - \frac{1}{2\sigma}|y - y^+|^2 - \frac{1}{2\tau}|x^+ - x^-|^2 - \frac{1}{2\sigma}|y^+ - y^-|^2 \\ &\quad + \langle x^+ - x, K^*(y - \bar{y}) \rangle - \langle y^+ - y, K(x - \bar{x}) \rangle. \end{aligned}$$

Bukti. Berdasarkan kekonveksan kuat, pembaruan x^+ dan y^+ memenuhi

(7.41)

$$\begin{aligned} \frac{1}{2\tau}|x^+ - x^-|^2 + \langle x^+, K^* \bar{y} \rangle + f(x^+) + \frac{1}{2\tau}|x - x^+|^2 &\leq \frac{1}{2\tau}|x - x^-|^2 + \langle x, K^* \bar{y} \rangle + f(x) \\ \frac{1}{2\sigma}|y^+ - y^-|^2 - \langle y^+, K\bar{x} \rangle + g^*(y^+) + \frac{1}{2\sigma}|y - y^+|^2 &\leq \frac{1}{2\sigma}|y - y^-|^2 - \langle y, K\bar{x} \rangle + g^*(y). \end{aligned}$$

Menjumlahkan kedua ketaksamaan dan menyusun ulang suku-sukunya memberikan hasil yang diinginkan. $\square$

Teorema 7.12 (Konvergensi PDHG). Misalkan X dan Y ruang Hilbert riil berdimensi hingga, $f \in \Gamma_0(X)$, $g \in \Gamma_0(Y)$, $K : X \rightarrow Y$ linear terbatas, serta $\tau, \sigma > 0$. Perhatikan pembaruan (7.38) dan andaikan ukuran langkah memenuhi $\tau\sigma \leq \|K\|^{-2}$; untuk $K = 0$, syarat ini dipahami otomatis terpenuhi. Untuk $N \geq 1$, definisikan rerata ergodik $X_N = \frac{1}{N} \sum_{k=1}^N x_k$ dan $Y_N = \frac{1}{N} \sum_{k=1}^N y_k$. Maka

$$(7.42) \quad \mathcal{L}(X_N, y) - \mathcal{L}(x, Y_N) \leq \frac{1}{N} \left[\frac{1}{2\tau}|x - x_0|^2 + \frac{1}{2\sigma}|y - y_0|^2 - \langle y - y_0, K(x - x_0) \rangle \right].$$

Catatan. Perhatikan bahwa ukuran langkah sama sekali tidak bergantung pada fungsi f dan g , melainkan hanya pada operator K .

Bukti.

(7.43)

$$\begin{aligned}
 \mathcal{L}(x_{k+1}, y) - \mathcal{L}(x, y_{k+1}) &\leq \frac{1}{2\tau}|x - x_k|^2 + \frac{1}{2\sigma}|y - y_k|^2 \\
 &\quad - \frac{1}{2\tau}|x - x_{k+1}|^2 - \frac{1}{2\sigma}|y - y_{k+1}|^2 - \frac{1}{2\tau}|x_{k+1} - x_k|^2 - \frac{1}{2\sigma}|y_{k+1} - y_k|^2 \\
 &\quad + \langle x_{k+1} - x, K^*(y - y_k) \rangle - \langle y_{k+1} - y, K(x - x_{k+1}) \rangle \\
 &\quad + \langle y_{k+1} - y, K(x_{k+1} - x_k) \rangle \\
 &\leq \left[\frac{1}{2\tau}|x - x_k|^2 + \frac{1}{2\sigma}|y - y_k|^2 - \langle y - y_k, K(x - x_k) \rangle \right] \\
 &\quad - \left[\frac{1}{2\tau}|x - x_{k+1}|^2 + \frac{1}{2\sigma}|y - y_{k+1}|^2 - \langle y - y_{k+1}, K(x - x_{k+1}) \rangle \right] \\
 &\quad - \left[\frac{1}{2\tau}|x_{k+1} - x_k|^2 + \frac{1}{2\sigma}|y_{k+1} - y_k|^2 \right. \\
 &\quad \left. - \langle x_{k+1} - x_k, K^*(y_{k+1} - y_k) \rangle \right].
 \end{aligned}$$

Jika $K = 0$, suku campuran dalam setiap tanda kurung siku lenyap, sehingga semua ekspresi itu tidak negatif. Jika $K \neq 0$, nonnegativitas mengikuti

$$\langle Kx, y \rangle \leq \|Kx\| \|y\| \leq \|K\| \left(\frac{\delta}{2} \|x\|^2 + \frac{1}{2\delta} \|y\|^2 \right) \leq \frac{1}{2\tau} \|x\|^2 + \frac{1}{2\sigma} \|y\|^2,$$

dengan ketaksamaan terakhir diperoleh dari pilihan $\delta = \frac{1}{\tau\|K\|}$ dan fakta bahwa $\|K\|^2 \leq \frac{1}{\tau\sigma}$. Penjumlahan terhadap k menghasilkan

$$(7.44) \quad \sum_{k=0}^{N-1} \mathcal{L}(x_{k+1}, y) - \mathcal{L}(x, y_{k+1}) \leq \left[\frac{1}{2\tau}|x - x_0|^2 + \frac{1}{2\sigma}|y - y_0|^2 - \langle y - y_0, K(x - x_0) \rangle \right].$$

Karena pemetaan $(x, y) \mapsto \mathcal{L}(x, y') - \mathcal{L}(x', y)$ konveks untuk x', y' tetap, kita memperoleh

$$(7.45) \quad \mathcal{L}(x_N, y) - \mathcal{L}(x, y_N) \leq \frac{1}{N} \sum_{k=0}^{N-1} (\mathcal{L}(x_{k+1}, y) - \mathcal{L}(x, y_{k+1})) \leq \frac{1}{N} \left[\frac{1}{2\tau}|x - x_0|^2 + \frac{1}{2\sigma}|y - y_0|^2 - \langle y - y_0, K(x - x_0) \rangle \right].$$

□

7.3 METODE PENGALI ARAH BERGANTIAN (ADMM)

Misalkan $f, g \in \Gamma_0(\mathbb{R}^d)$, $A, B : \mathbb{R}^d \rightarrow \mathbb{R}^m$ linear, dan $z \in \mathbb{R}^m$. Perhatikan masalah optimisasi terkendala

$$(7.46) \quad \min_{Ax+By=z} f(x) + g(y).$$

Masalah ini dapat dirumuskan ulang sebagai masalah titik pelana tak terkendala untuk *Lagrangian teraugmentasi*; yaitu, untuk setiap $\gamma > 0$, kita mempertimbangkan

$$(7.47) \quad \min_{x,y} \sup_{\lambda} L_{\gamma}(x, y, \lambda) := f(x) + g(y) + \langle \lambda, Ax + By - z \rangle + \frac{\gamma}{2} \|Ax + By - z\|^2.$$

Pernyataan berikut dapat ditunjukkan secara langsung.

Lema 7.13. *Masalah (7.46) dan (7.47) ekuivalen.*

Bukti. Latihan! □

Salah satu cara langsung untuk menyelesaikan masalah titik pelana tersebut adalah mengoptimalkan secara bergantian terhadap x dan y , lalu melakukan langkah kenaikan gradien terhadap λ :

$$(7.48) \quad \begin{cases} x_{k+1} = \arg \min_x f(x) + \langle \lambda_k, Ax \rangle + \frac{\gamma}{2} \|Ax + By_k - z\|^2 \\ y_{k+1} = \arg \min_y g(y) + \langle \lambda_k, By \rangle + \frac{\gamma}{2} \|Ax_{k+1} + By - z\|^2 \\ \lambda_{k+1} = \lambda_k + \gamma(Ax_{k+1} + By_{k+1} - z). \end{cases}$$

Perhatikan bahwa γ digunakan sebagai ukuran langkah untuk kenaikan gradien. Pilihan ini dapat dimotivasi secara intuitif oleh fakta bahwa, berdasarkan definisi pembaruan,

$$(7.49) \quad 0 \in \partial g(y_{k+1}) + B^* \lambda_k + \gamma B^*(Ax_{k+1} + By_{k+1} - z).$$

Dengan mengalikan pembaruan λ oleh B^* dan memasukkannya ke (7.49), diperoleh

$$(7.50) \quad B^* \lambda_{k+1} \in -\partial g(y_{k+1}).$$

Dengan demikian, triple ADMM yang benar-benar diperbarui melalui (7.48) memenuhi $0 \in \partial_y L_0(x_{k+1}, y_{k+1}, \lambda_{k+1})$. Pembaruan bergantian tersebut pada umumnya tidak memberikan stasioneritas terhadap x , karena submasalah x masih memakai y_k . Hanya dalam skema hipotetis yang meminimumkan x dan y secara bersama kondisi serupa diperoleh terhadap x , sehingga triple hasil pembaruan bersama itu memenuhi stasioneritas primal penuh untuk L_0 . Kita dapat menunjukkan hasil konvergensi dasar berikut untuk ADMM.

Teorema 7.14. *Ambil $\gamma > 0$. Andaikan terdapat suatu titik pelana dari $L_0(x, y, \lambda)$ dan, pada setiap iterasi, kedua submasalah minimisasi dalam algoritme ADMM di atas mencapai minimumnya; pilih sembarang peminimum tersebut. Dengan $r_k := Ax_k + By_k - z$, berlaku $r_k \rightarrow 0$, $B(y_{k+1} - y_k) \rightarrow 0$, dan*

$$(7.51) \quad f(x_k) + g(y_k) \rightarrow \min_{Ax+By=z} f(x) + g(y).$$

Bukti. Bukti menggunakan suatu teknik penting, yaitu *funksional Lyapunov*. Kita mendefinisikan fungsional $V(y, \lambda)$ yang tidak negatif (terbatas dari bawah) dan menurun sepanjang iterasi. Pada dasarnya, fungsional Lyapunov menggantikan fungsi objektif ketika penurunan objektif itu sendiri tidak dapat dibuktikan. Dalam kasus ini, kita menggunakan

$$(7.52) \quad V(y, \lambda) = \gamma \|B(y - y^*)\|^2 + \gamma^{-1} \|\lambda - \lambda^*\|^2,$$

dengan (x^*, y^*, λ^*) suatu titik pelana bagi L_0 . Penurunan fungsional Lyapunov akan memberikan konvergensi melalui argumen penjumlahan teleskopik yang lazim. Akan tetapi, pembuktian penurunan ini memerlukan beberapa taksiran teknis. Demi kesederhanaan, tuliskan residu $r_k := Ax_k + By_k - z$ dan nilai objektif $p_k := f(x_k) + g(y_k)$; gunakan pula r^* dan p^* untuk titik pelana. Bukti dibagi menjadi tiga langkah.

Langkah 1 Karena (x^*, y^*, λ^*) merupakan titik pelana bagi L_0 , untuk setiap k berlaku $L_0(x^*, y^*, \lambda^*) \leq L_0(x_{k+1}, y_{k+1}, \lambda^*)$. Pernyataan ini ekuivalen dengan

$$(7.53) \quad p^* - p_{k+1} \leq \langle \lambda^*, r_{k+1} \rangle.$$

Langkah 2 Di sisi lain, berdasarkan optimalitas x_{k+1} dan y_{k+1} dalam (7.48), kita memperoleh

$$(7.54) \quad \begin{aligned} 0 &\in \partial f(x_{k+1}) + A^* \lambda_k + \gamma A^* (r_{k+1} + B(y_k - y_{k+1})) \\ 0 &\in \partial g(y_{k+1}) + B^* \lambda_k + \gamma B^* r_{k+1}. \end{aligned}$$

Selain itu, pembaruan λ dapat ditulis sebagai $\lambda_{k+1} = \lambda_k + \gamma r_{k+1}$, sehingga

$$(7.55) \quad \begin{aligned} A^* \lambda_{k+1} &= A^* \lambda_k + \gamma A^* r_{k+1} \\ B^* \lambda_{k+1} &= B^* \lambda_k + \gamma B^* r_{k+1}. \end{aligned}$$

Ketika dimasukkan ke (7.54), persamaan ini memberikan

$$(7.56) \quad \begin{aligned} 0 &\in \partial f(x_{k+1}) + A^* (\lambda_{k+1} + \gamma B(y_k - y_{k+1})) \\ 0 &\in \partial g(y_{k+1}) + B^* \lambda_{k+1}. \end{aligned}$$

Hal ini menyiratkan bahwa x_{k+1} meminimumkan

$$(7.57) \quad x \mapsto f(x) + \langle Ax, \lambda_{k+1} + \gamma B(y_k - y_{k+1}) \rangle,$$

sedangkan y_{k+1} meminimumkan

$$(7.58) \quad y \mapsto g(y) + \langle By, \lambda_{k+1} \rangle.$$

Akibatnya, dari optimalitas diperoleh

$$(7.59) \quad \begin{aligned} f(x_{k+1}) + \langle Ax_{k+1}, \lambda_{k+1} + \gamma B(y_k - y_{k+1}) \rangle + g(y_{k+1}) + \langle By_{k+1}, \lambda_{k+1} \rangle \\ \leq f(x^*) + \langle Ax^*, \lambda_{k+1} + \gamma B(y_k - y_{k+1}) \rangle + g(y^*) + \langle By^*, \lambda_{k+1} \rangle. \end{aligned}$$

Karena titik pelana pasti memenuhi $Ax^* + By^* = z$, sedikit penyusunan ulang memberikan

$$(7.60) \quad p_{k+1} - p^* \leq \gamma \langle A(x^* - x_{k+1}), B(y_k - y_{k+1}) \rangle - \langle r_{k+1}, \lambda_{k+1} \rangle.$$

Terakhir, kita dapat memasukkan $A(x^* - x_{k+1}) = z - By^* - (r_{k+1} + z - By_{k+1}) = -r_{k+1} + B(y_{k+1} - y^*)$ untuk memperoleh

$$(7.61) \quad p_{k+1} - p^* \leq -\gamma \langle -r_{k+1} + B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle - \langle r_{k+1}, \lambda_{k+1} \rangle.$$

Langkah 3 Dengan menjumlahkan (7.53) dan (7.61), lalu mengalikan dengan 2, diperoleh

$$(7.62) \quad -2\gamma \langle r_{k+1}, B(y_{k+1} - y_k) \rangle + 2\gamma \langle B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle + 2 \langle r_{k+1}, \lambda_{k+1} - \lambda^* \rangle \leq 0.$$

Kita akan mengolah ketaksamaan ini. Suku ketiga dapat ditulis ulang menggunakan $\lambda_{k+1} = \lambda_k + \gamma r_{k+1}$ sebagai

$$(7.63) \quad 2 \langle r_{k+1}, \lambda_{k+1} - \lambda^* \rangle = \gamma \|r_{k+1}\|^2 + \gamma \|r_{k+1}\|^2 + 2 \langle r_{k+1}, \lambda_k - \lambda^* \rangle.$$

Dengan mengganti $r_{k+1} = (\lambda_{k+1} - \lambda_k)/\gamma$ pada dua suku terakhir, diperoleh

$$(7.64) \quad \gamma \|r_{k+1}\|^2 + \gamma^{-1} \|\lambda_{k+1} - \lambda_k\|^2 + 2\gamma^{-1} \langle \lambda_{k+1} - \lambda_k, \lambda_k - \lambda^* \rangle.$$

Dengan mengganti $\lambda_{k+1} - \lambda_k = \lambda_{k+1} - \lambda^* + \lambda^* - \lambda_k$ di atas, bentuk ini ekuivalen dengan

$$(7.65) \quad \gamma \|r_{k+1}\|^2 + \gamma^{-1} (\|\lambda_{k+1} - \lambda^*\|^2 - \|\lambda_k - \lambda^*\|^2).$$

Jadi, (7.62) ekuivalen dengan

$$(7.66) \quad 0 \geq -2\gamma \langle r_{k+1}, B(y_{k+1} - y_k) \rangle + 2\gamma \langle B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle + \gamma \|r_{k+1}\|^2 + \gamma^{-1} (\|\lambda_{k+1} - \lambda^*\|^2 - \|\lambda_k - \lambda^*\|^2).$$

Sekarang kita tulis ulang tiga suku pertama,

$$(7.67) \quad -2\gamma \langle r_{k+1}, B(y_{k+1} - y_k) \rangle + 2\gamma \langle B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle + \gamma \|r_{k+1}\|^2.$$

Dengan memperhatikan bahwa

$$(7.68) \quad -2 \langle r_{k+1}, B(y_{k+1} - y_k) \rangle + \|r_{k+1}\|^2 = \|r_{k+1} - B(y_{k+1} - y_k)\|^2 - \|B(y_{k+1} - y_k)\|^2,$$

kita mendapatkan bahwa (7.66) ekuivalen dengan

$$(7.69) \quad \gamma \|r_{k+1} - B(y_{k+1} - y_k)\|^2 - \gamma \|B(y_{k+1} - y_k)\|^2 + 2\gamma \langle B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle,$$

yang ekuivalen dengan

$$(7.70) \quad \gamma \|r_{k+1} - B(y_{k+1} - y_k)\|^2 + \gamma (\|B(y_{k+1} - y^*)\|^2 - \|B(y_k - y^*)\|^2).$$

Secara keseluruhan, (7.66) kemudian menghasilkan

$$(7.71) \quad 0 \geq \gamma \|r_{k+1} - B(y_{k+1} - y_k)\|^2 + \gamma (\|B(y_{k+1} - y^*)\|^2 - \|B(y_k - y^*)\|^2) + \gamma^{-1} (\|\lambda_{k+1} - \lambda^*\|^2 - \|\lambda_k - \lambda^*\|^2).$$

Terakhir, perhatikan bahwa

$$(7.72) \quad \|r_{k+1} - B(y_{k+1} - y_k)\|^2 = \|r_{k+1}\|^2 + \|B(y_{k+1} - y_k)\|^2 - 2 \langle r_{k+1}, B(y_{k+1} - y_k) \rangle.$$

Kita ingin menunjukkan bahwa suku

$$(7.73) \quad \langle r_{k+1}, B(y_{k+1} - y_k) \rangle \leq 0.$$

Untuk $k \geq 1$, ingat bahwa y_k meminimumkan $g(y) + \langle By, \lambda_k \rangle$. Dengan demikian,

$$(7.74) \quad \begin{aligned} g(y_k) + \langle By_k, \lambda_k \rangle &\leq g(y_{k+1}) + \langle By_{k+1}, \lambda_k \rangle \\ g(y_{k+1}) + \langle By_{k+1}, \lambda_{k+1} \rangle &\leq g(y_k) + \langle By_k, \lambda_{k+1} \rangle. \end{aligned}$$

Penjumlahan kedua ketaksamaan memberikan

$$(7.75) \quad \langle B(y_{k+1} - y_k), \lambda_{k+1} - \lambda_k \rangle \leq 0.$$

Dengan memasukkan $\lambda_{k+1} - \lambda_k = \gamma r_{k+1}$, diperoleh tanda yang diinginkan. Oleh karena itu,

$$(7.76) \quad V(y_{k+1}, \lambda_{k+1}) + \gamma \|r_{k+1}\|^2 + \gamma \|B(y_{k+1} - y_k)\|^2 \leq V(y_k, \lambda_k), \quad k \geq 1.$$

Menjumlahkan terhadap k menghasilkan, untuk $K \geq 2$,

$$(7.77) \quad \sum_{k=1}^{K-1} \gamma (\|r_{k+1}\|^2 + \|B(y_{k+1} - y_k)\|^2) \leq V(y_1, \lambda_1).$$

Dari penurunan fungsional Lyapunov, segera diperoleh bahwa λ_k dan By_k merupakan barisan terbatas. Selain itu,

$$(7.78) \quad \begin{cases} r_k & \rightarrow 0 \\ B(y_{k+1} - y_k) & \rightarrow 0. \end{cases}$$

Berdasarkan (7.53) dan (7.61), kita mempunyai

$$(7.79) \quad -\langle \lambda^*, r_{k+1} \rangle \leq p_{k+1} - p^* \leq -\gamma \langle -r_{k+1} + B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle - \langle r_{k+1}, \lambda_{k+1} \rangle.$$

Kemudian (7.78) dan keterbatasan By_k menyiratkan bahwa $p_k \rightarrow p^*$. $\square$

DAFTAR PUSTAKA

- A. BECK (2017), *First-order methods in optimization*, SIAM.
- A. CHAMBOLLE & T. POCK (2011), A first-order primal-dual algorithm for convex problems with applications to imaging, *Journal of mathematical imaging and vision* 40(1), 120–145.

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber. Rekaman terstruktur dengan identitas peristiwa Oo15-HAB-ADV-0050 sampai Oo15-HAB-ADV-0075 menyertai sumber edisi ini.

- (i) Pada contoh konjugat, urutan pasangan dual dibetulkan menjadi $\langle x^*, x \rangle$, dan konjugat indikator bola satuan dual diidentifikasi sebagai norma asal pada V setelah identifikasi $V^{**} \cong V$.
- (ii) Lema keproperan konjugat kini menyatakan hipotesis keberadaan sedikitnya satu subgradien yang dipakai buktinya; evaluasi yang salah tipe $f^*(\hat{x})$ dibetulkan menjadi $f^*(g)$, dan fungsi dalam supremum disebut afin kontinu.
- (iii) Bukti bikonjugat memakai $f(x)$ ketika memilih $y = x$ dan memulihkan dua tanda ketaksamaan yang hilang pada cabang $\alpha = 0$.
- (iv) Identitas Moreau dinyatakan di bawah konvensi ruang Hilbert bab ini agar pemetaan proksimal yang dipakai memang terdefinisi dan bernilai tunggal dalam lingkup bersama yang dinyatakan.
- (v) Rumus kesenjangan primal–dual diperbaiki agar konsisten tipe dan tanda dengan dual Fenchel: $f(x) + g(Kx) - [-f^*(-K^*y) - g^*(y)]$.
- (vi) Pembaruan dual PDHG memakai $\text{prox}_{\sigma g^*}$; submasalah abstraknya diminimumkan terhadap y ; dan koefisien sisa kekonveksan kuat untuk y memakai $1/(2\sigma)$.
- (vii) Rerata ergodik PDHG dan langkah penjumlahannya memakai iterasi 1 sampai N , sesuai ketaksamaan satu langkah untuk x_{k+1} dan y_{k+1} .
- (viii) Submasalah kedua ADMM diminimumkan terhadap y . Notasi gradien yang tidak berlaku bagi g nonsmooth diganti dengan subdiferensial. Tripel ADMM aktual hanya dinyatakan stasioner terhadap y ; stasioneritas primal penuh dibatasi pada skema hipotetis dengan minimisasi bersama.
- (ix) Substitusi residu ADMM dibetulkan menjadi $Ax_{k+1} = r_{k+1} + z - By_{k+1}$ sebelum menurunkan $A(x^* - x_{k+1})$.

- (x) Dalam penurunan Lyapunov ADMM, tanda suku silang, tanda yang dibuktikan oleh optimalitas, faktor γ , dan indeks awal $k \geq 1$ dibetulkan. Penjumlahan teleskopik dimulai dari iterasi pertama yang memenuhi kedua kondisi optimalitas γ .
- (xi) Batas atas terakhir untuk galat nilai objektif mengembalikan tanda minus dan faktor γ yang sudah terdapat pada ketaksamaan berlabel sebelumnya.
- (xii) Kemunculan kedua label `duality:eq:proof_admm6` dipetakan secara transparan ke `duality:eq:proof_admm7`; rujukan tunggalnya diperbarui bersama-sama.
- (xiii) Salah eja, frasa ganda, dan karakter kendali berlebih dalam prosa sumber dinormalkan dalam terjemahan tanpa mengubah matematika lain.
- (xiv) Lingkup bab dibuat koheren sebagai ruang Hilbert riil berdimensi hingga dengan dual kontinu dan identifikasi Riesz; X dan Y dinyatakan eksplisit. Kelas Γ_0 memakai konvensi fungsi proper, konveks, semikontinu bawah dengan nilai dalam $(-\infty, +\infty]$.
- (xv) Karakterisasi regularisasi Γ dibatasi pada keluarga minoran proper yang tidak kosong; jika keluarga itu kosong, supremumnya secara eksplisit adalah fungsi yang identik $-\infty$.
- (xvi) Dalam bukti Fenchel–Rockafellar, inklusi optimalitas kini dijustifikasi oleh kaidah Fermat serta aturan jumlah dan rantai di bawah syarat kualifikasi interior yang telah dinyatakan.
- (xvii) Maksimum titik demi titik yang ketercapaiannya tidak dijamin diganti dengan supremum, dan karakterisasi kesenjangan nol dinyatakan di bawah hipotesis dualitas kuat serta ketercapaian primal–dual.
- (xviii) Identitas Moreau berskala $\text{prox}_{\sigma g^*}(y) = y - \sigma \text{prox}_{g/\sigma}(y/\sigma)$ ditambahkan untuk menjelaskan langkah proksimal dual PDHG.
- (xix) Teorema PDHG kini menyatakan fungsi dalam Γ_0 , ruang dan operatornya, serta positifnya ukuran langkah; penghitung iterasi diganti dari K menjadi N agar tidak bertabrakan dengan operator K , dan kasus operator nol dinyatakan otomatis memenuhi syarat ukuran langkah.
- (xx) Bagian ADMM kini memberi tipe $A, B : \mathbb{R}^d \rightarrow \mathbb{R}^m$ dan $z \in \mathbb{R}^m$, mengasumsikan $\gamma > 0$ serta ketercapaian setiap submasalah eksak, dan menyatakan hanya konvergensi residu, perubahan citra blok, serta nilai objektif yang benar-benar dibuktikan.
- (xxi) Himpunan C pada contoh fungsi indikator disyaratkan tak kosong agar δ_C proper dan fungsi pendukungnya tetap berada dalam kodomain nilai diperluas yang dinyatakan.
- (xxii) Tanda $\alpha \geq 0$ dalam bukti Fenchel–Moreau kini diperoleh dari suatu $\bar{x} \in \text{dom}(f)$ yang dijamin oleh keproperan, lalu dengan membiarkan tinggi epigraf menuju tak hingga; titik terpisah x_0 tidak lagi diasumsikan berada dalam domain efektif.

- (xxiii) Bukti PDHG menangani operator nol secara terpisah, ketika suku campuran lenyap, dan hanya memakai $\delta = 1/(\tau\|K\|)$ ketika $K \neq 0$.
- (xxiv) Lema satu langkah PDHG kini menyatakan sendiri hipotesis ruang Hilbert berdimensi hingga, fungsi dalam Γ_0 , operator linear terbatas, dan ukuran langkah positif yang diperlukan karena lema itu mendahului teorema konvergensi.
- (xxv) Bikonjugasi dan ketaksamaan $f^{**} \leq f$ kini mensyaratkan f serta f^* proper. Dalam kasus keluarga minoran Γ kosong, hanya supremum ruas kanan yang didefinisikan sebagai fungsi identik $-\infty$; di bawah konvensi masukan proper bab ini, fungsi tersebut tidak dinotasikan sebagai f^{**} .

ATRIBUSI, LISENSI, DAN NONDUKUNGAN

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.

Andreas Habring dan TU Graz tidak menyusun, memeriksa, menyetujui, atau mendukung terjemahan ini. Penyebutan nama mereka semata-mata untuk atribusi karya sumber.

OPTIMISASI KONVEKS

UNIT 8: PENURUNAN GRADIEN STOKASTIK
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 8, "Stochastic Gradient Descent", dari Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1. Sumber berwenang untuk unit ini adalah berkas `stochastic.tex` edisi v1 dengan SHA-256 berikut:

610d11b59d8dfabbbbe6fbc509a0f9ac
1727540458c67f8cd3b7bab49566a07d

Bab-bab prasyarat tidak diulang. Pembaca diharapkan telah mengenal fungsi konveks Lipschitz, subgradien, proyeksi metrik pada himpunan konveks tertutup, ekspektasi bersyarat, filtrasi, dan bukti konvergensi metode subgradien terproyeksi. Seluruh motivasi, algoritme, teorema, bukti, dan formula dalam bab sumber dipertahankan dalam urutan sumber. Kekeliruan yang dapat ditentukan secara matematis diperbaiki secara terbuka dan diringkaskan pada akhir unit.

Edisi ini berdiri sendiri untuk dibaca dan dibangun, tetapi tidak mengklaim menggantikan konteks lengkap catatan kuliah asal. Notasi iid dipertahankan sebagai singkatan baku untuk peubah acak yang saling bebas dan berdistribusi identik.

DAFTAR ISI

8	PENURUNAN GRADIEN STOKASTIK	1
---	-----------------------------	---

8 PENURUNAN GRADIEN STOKASTIK

Andaikan kita ingin menyelesaikan

$$(8.1) \quad \min_x f(x),$$

tetapi hanya mempunyai akses ke estimasi acak yang tak bias bagi suatu subgradien f . Artinya, kita mengandaikan dapat mengevaluasi $G(x, z)$ yang memenuhi

$$(8.2) \quad \mathbb{E}[G(x, Z)] \in \partial f(x),$$

dengan Z suatu peubah acak. Ternyata banyak bukti konvergensi dapat dialihkan ke latar stokastik ini dengan hampir tanpa upaya tambahan. Sebelum menunjukkannya, mari kita berikan motivasi untuk latar ini.

Dalam pembelajaran mesin modern, banyak masalah pembelajaran dapat dirumuskan sebagai masalah jumlah hingga. Agar pengambilan sampel seragam menghasilkan estimator gradien yang tak bias, kita memakai normalisasi rerata

$$(8.3) \quad \min_x f(x) := \frac{1}{N} \sum_{i=1}^N f_i(x),$$

dengan N biasanya merupakan banyaknya sampel pelatihan. Sebagai contoh, andaikan kita ingin mempelajari pemetaan berparameter f_θ yang seharusnya menghampiri relasi $x \mapsto y$ berdasarkan data pelatihan $(x_i, y_i)_{i=1}^N$. Masalah pelatihannya dapat berupa

$$(8.4) \quad \min_{\theta} \frac{1}{N} \sum_{i=1}^N \|y_i - f_\theta(x_i)\|^2.$$

Karena ukuran data pelatihan yang dijumpai, sering kali gradien penuh f tidak dapat dihitung secara langsung akibat keterbatasan memori. Jika semua f_i terdiferensialkan, salah satu jalan keluarnya adalah pembaruan stokastik

$$(8.5) \quad \begin{cases} \text{Pilih } i \in \mathcal{I} \text{ secara seragam} \\ x_{k+1} = x_k - \tau \nabla f_i(x_k) \end{cases}$$

dengan $\mathcal{I} = \{1, \dots, N\}$. Dengan mendefinisikan $(Z_k)_k$ sebagai barisan peubah acak iid yang berdistribusi seragam pada $\mathcal{I}$, pembaruan di atas dapat ditulis sebagai

$$(8.6) \quad x_{k+1} = x_k - \tau G(x_k, Z_k)$$

dengan $G(x, z) := \nabla f_z(x)$. Memang, $\mathbb{E}[G(x, Z)] = N^{-1} \sum_{i=1}^N \nabla f_i(x) = \nabla f(x)$, sehingga G memenuhi (8.2).

Teorema 8.1. Misalkan $C \subseteq \mathbb{R}^d$ tak kosong, tertutup, dan konveks, serta misalkan $f : \mathbb{R}^d \rightarrow \mathbb{R}$ konveks dan L -Lipschitz. Andaikan masalah $\min_{x \in C} f(x)$ mempunyai solusi, pilih $x^* \in \arg \min_{x \in C} f(x)$, dan ambil $x_0 \in C$. Untuk $k \geq 0$, misalkan $G_k := G(x_k, Z_k)$ dan jalankan iterasi terproyeksi $x_{k+1} = \text{proj}_C(x_k - \tau_k G_k)$ dengan $\tau_k > 0$.

Tuliskan $\mathcal{F}_k = \sigma(x_0, Z_0, \dots, Z_{k-1})$, sehingga x_k terukur terhadap $\mathcal{F}_k$, dan definisikan $\bar{g}_k := \mathbb{E}[G_k \mid \mathcal{F}_k]$. Andaikan, hampir pasti untuk setiap k ,

$$(8.7) \quad \begin{cases} \bar{g}_k \in \partial f(x_k), \\ \mathbb{E}[\|G_k - \bar{g}_k\|^2 \mid \mathcal{F}_k] \leq \sigma^2 < \infty. \end{cases}$$

Andaikan pula ukuran langkah memenuhi

$$\sum_{k=0}^{K-1} \tau_k \rightarrow \infty, \quad \frac{\sum_{k=0}^{K-1} \tau_k^2}{\sum_{k=0}^{K-1} \tau_k} \rightarrow 0 \quad \text{ketika } K \rightarrow \infty.$$

Untuk $K \geq 1$, definisikan $f_{\text{best}}^K := \min_{0 \leq k \leq K-1} f(x_k)$. Maka $\mathbb{E}[f_{\text{best}}^K - f(x^*)] \rightarrow 0$ ketika $K \rightarrow \infty$.

Bukti. Karena $x^* \in C$, kita mempunyai $\text{proj}_C(x^*) = x^*$. Ketakmembangan proyeksi metrik memberikan

$$(8.8) \quad \begin{aligned} \|x_{k+1} - x^*\|^2 &= \|\text{proj}_C(x_k - \tau_k G_k) - \text{proj}_C(x^*)\|^2 \\ &\leq \|x_k - \tau_k G_k - x^*\|^2 \\ &= \|x_k - x^*\|^2 - 2\tau_k \langle x_k - x^*, G_k \rangle + \tau_k^2 \|G_k\|^2. \end{aligned}$$

Perhatikan bahwa sifat terukur x_k dan ketakbiasan bersyarat memberi

$$(8.9) \quad \begin{aligned} \mathbb{E}[\langle x_k - x^*, G_k \rangle] &= \mathbb{E}[\mathbb{E}[\langle x_k - x^*, G_k \rangle \mid \mathcal{F}_k]] \\ &= \mathbb{E}[\langle x_k - x^*, \bar{g}_k \rangle] \\ &\geq \mathbb{E}[f(x_k) - f(x^*)] \\ &= \mathbb{E}[f(x_k)] - f(x^*), \end{aligned}$$

dengan ketaksamaan subgradien pada baris ketiga. Karena fungsi konveks f bersifat L -Lipschitz pada $\mathbb{R}^d$, setiap subgradiennya mempunyai norma paling besar L . Identitas momen kedua bersyarat kemudian menghasilkan

$$(8.10) \quad \mathbb{E}[\|G_k\|^2 \mid \mathcal{F}_k] = \mathbb{E}[\|G_k - \bar{g}_k\|^2 \mid \mathcal{F}_k] + \|\bar{g}_k\|^2 \leq \sigma^2 + L^2 := M^2.$$

Dengan mengambil ekspektasi pada ketaksamaan pertama, diperoleh

$$(8.11) \quad \mathbb{E}[\|x_{k+1} - x^*\|^2] \leq \mathbb{E}[\|x_k - x^*\|^2] - 2\tau_k(\mathbb{E}[f(x_k)] - f(x^*)) + \tau_k^2 M^2.$$

Selebihnya mengikuti argumen pada kasus deterministik. Menjumlahkan dari $k = 0$ sampai $K-1$, memakai ketaknegatifan suku jarak terakhir, lalu membagi dengan 2 memberikan

$$(8.12) \quad \sum_{k=0}^{K-1} \tau_k (\mathbb{E}[f(x_k)] - f(x^*)) \leq \frac{1}{2} \|x_0 - x^*\|^2 + \frac{M^2}{2} \sum_{k=0}^{K-1} \tau_k^2.$$

Definisikan

$$(8.13) \quad S_K := \sum_{k=0}^{K-1} \tau_k, \quad Q_K := \sum_{k=0}^{K-1} \tau_k^2.$$

Karena $\tau_k > 0$, minimum terbaik tidak melebihi rerata berbobot. Oleh karena itu,

$$(8.14) \quad \begin{aligned} \mathbb{E}[f_{\text{best}}^K - f(x^*)] &\leq \frac{\sum_{k=0}^{K-1} \tau_k \mathbb{E}[f(x_k) - f(x^*)]}{S_K} \\ &\leq \frac{\|x_0 - x^*\|^2}{2S_K} + \frac{M^2 Q_K}{2S_K}. \end{aligned}$$

Berdasarkan kedua syarat ukuran langkah,

$$(8.15) \quad 0 \leq \mathbb{E}[f_{\text{best}}^K - f(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2S_K} + \frac{M^2 Q_K}{2S_K} \longrightarrow 0 \quad (K \rightarrow \infty).$$

□

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber. Rekaman terstruktur dengan identitas peristiwa Oo15-HAB-ADV-0076 sampai Oo15-HAB-ADV-0083 menyertai sumber edisi ini.

- (i) Objektif jumlah hingga dinormalisasi menjadi $N^{-1} \sum_i f_i$. Dengan demikian, pengambilan indeks seragam dan pilihan $G(x, z) = \nabla f_z(x)$ benar-benar memenuhi ketakbiasan yang dinyatakan; pembagian dengan N tidak mengubah himpunan pemimum.
- (ii) Teorema kini menyatakan fungsi konveks Lipschitz, himpunan kendala C yang tak kosong, tertutup, dan konveks, keberadaan solusi $x^* \in C$, titik awal $x_0 \in C$, ukuran langkah positif, serta iterasi SGD terproyeksi yang memang dipakai dalam bukti.
- (iii) Ketakbiasan dan batas varians dirumuskan secara bersyarat terhadap filtrasi sebelum sampel ke- k . Hal ini menutup kesenjangan antara asumsi satu peubah acak tetap dan pembuktian pada iterasi adaptif.
- (iv) Besaran f_{best}^K didefinisikan sebagai nilai terbaik di antara iterasi 0 sampai $K - 1$, dan seluruh penghitungan pada pernyataan serta bukti dibuat konsisten dengan K .
- (v) Identitas momen kedua memakai gradien rata-rata bersyarat $\bar{g}_k$ dan menghasilkan batas $M^2 = \sigma^2 + L^2$ dari varians bersyarat serta sifat Lipschitz, bukan dengan mengurangi norma ekspektasi tak bersyarat pada titik acak.
- (vi) Setelah relasi satu langkah dibagi dua, faktor $1/2$ yang hilang pada suku $M^2 \sum_k \tau_k^2$ dalam sumber dipulihkan.
- (vii) Definisi dan manipulasi σ_n yang tidak konsisten diganti dengan $S_K = \sum_k \tau_k$ dan $Q_K = \sum_k \tau_k^2$. Syarat konvergensi yang benar dinyatakan sebagai $S_K \rightarrow \infty$ dan $Q_K/S_K \rightarrow 0$, lalu diterapkan langsung pada batas galat.
- (viii) Salah ketik prosa, makro ekspektasi E yang hilang garis miring, dan pemisah penja-jaran yang salah tempat pada inklusi subgradien dinormalkan tanpa mengubah isi lain.

ATRIBUSI, LISENSI, DAN NONDUKUNGAN

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.

Andreas Habring dan TU Graz tidak menyusun, memeriksa, menyetujui, atau mendukung terjemahan ini. Penyebutan nama mereka semata-mata untuk atribusi karya sumber.

OPTIMISASI KONVEKS

UNIT 9: TRANSPORTASI OPTIMAL
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 9, "Excursion on Optimal Transport", dari Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1. Sumber berwenang untuk unit ini adalah berkas `optimal_transport.tex` edisi v1 dengan SHA-256 berikut:

719df724b368126cc7540dff461dc33
aba7d5b5b6060132181086dfa17649ba

Bab-bab prasyarat tidak diulang. Pembaca diharapkan telah mengenal ruang terukur dan ukuran probabilitas, konvergensi lemah, ruang Polish dan keketatan, optimisasi konveks, dualitas, serta aljabar matriks. Seluruh definisi, gambar TikZ, teorema, sketsa bukti, lema, catatan, sitasi, catatan kaki, formula, rujukan silang, dan permukaan glosarium dalam bab sumber dipertahankan dalam urutan sumber. Kekeliruan yang dapat ditentukan secara matematis diperbaiki secara terbuka dan diringkas pada akhir unit.

Uraian sumber menyebut dirinya sebagai selingan yang tidak sepenuhnya rigor. Edisi ini mempertahankan sifat pengantar tersebut, sambil menyatakan hipotesis minimum yang diperlukan agar klaim eksistensi, metrik Wasserstein, dualitas Kantorovich, serta faktorisasi dan iterasi Sinkhorn mempunyai makna yang tepat.

DAFTAR ISI

9	SELINGAN TENTANG TRANSPORTASI OPTIMAL	1
9.1	Transportasi optimal Monge dan Kantorovich	1
9.2	Dualitas Kantorovich	4
9.3	Diskretisasi transportasi optimal: Algoritme Sinkhorn–Knopp	6
	DAFTAR PUSTAKA	9

9 SELINGAN TENTANG TRANSPORTASI OPTIMAL

Meskipun tidak sepenuhnya menyatu dengan kuliah ini, kita menutupnya dengan suatu selingan mengenai transportasi optimal (OT), bidang yang sangat penting dalam matematika modern dan pembelajaran mesin. Perlu ditekankan sejak awal bahwa uraian ini hanya pengantar singkat; sejumlah rincian teori ukuran dan topologi yang mendasarinya akan dinyatakan seperlunya.

Notasi Dalam bagian berikut, (X, Σ_X) dan (Y, Σ_Y) adalah ruang terukur¹. Tuliskan $\mathcal{P}(X)$ dan $\mathcal{P}(Y)$ untuk himpunan semua ukuran probabilitas, $\mathcal{M}(X)$ dan $\mathcal{M}(Y)$ untuk ruang ukuran bertanda hingga, serta $\mathcal{M}_+(X)$ dan $\mathcal{M}_+(Y)$ untuk kerucut ukuran tak negatif hingga. Ingat bahwa ukuran bertanda μ pada X adalah fungsi $\mu : \Sigma_X \rightarrow \mathbb{R}$, sedangkan ukuran tak negatif bernilai dalam $[0, \infty)$, dengan $\Sigma_X \subseteq 2^X$ suatu aljabar- σ ², dan memenuhi

(i) $\mu(\emptyset) = 0$;

(ii) untuk setiap barisan $(A_n)_{n \in \mathbb{N}} \subset \Sigma_X$ yang saling lepas, berlaku $\mu(\bigcup_n A_n) = \sum_n \mu(A_n)$.

Ukuran probabilitas adalah ukuran tak negatif dengan $\mu(X) = 1$.


9.1 TRANSPORTASI OPTIMAL MONGE DAN KANTOROVICH

Motivasi khas untuk OT adalah sebagai berikut. Bayangkan kita ingin memindahkan se-tumpuk pasir dari satu tempat ke tempat lain. Berdasarkan kekekalan massa, kedua tumpukan mempunyai massa total yang sama; tanpa mengurangi keumuman, kita andaikan massanya satu. Karena itu, tumpukan awal dapat digambarkan oleh distribusi probabilitas $\alpha \in \mathcal{P}(X)$ dan tumpukan akhir oleh distribusi probabilitas $\beta \in \mathcal{P}(Y)$. Pertanyaan yang hendak dijawab dalam OT adalah:

Bagaimana kita dapat mengangkut tumpukan α ke β dengan biaya minimum?

¹Ketika topologi dibutuhkan, keduanya akan diasumsikan sebagai ruang Polish dengan aljabar- σ Borel; yaitu, ruang topologis separabel yang topologinya dibangkitkan oleh suatu metrik lengkap.

²Secara khusus, Σ_X memuat himpunan kosong serta tertutup terhadap komplemen dan gabungan terhingga.



Gambar 9.1: Ilustrasi OT. Peta T mengangkut *tumpukan* dari α ke β .

Pembaca yang teliti mungkin menyadari bahwa *biaya* belum ditentukan. Andaikan tersedia fungsi biaya terukur yang terbatas dari bawah, $c : X \times Y \rightarrow (-\infty, +\infty]$, dengan $c(x, y)$ menyatakan biaya untuk mengangkut satu satuan massa dari $x \in X$ ke $y \in Y$. Setiap transportasi deterministik dari α ke β dimodelkan oleh pemetaan terukur $T : X \rightarrow Y$. Syarat pengangkutan dapat dirumuskan dengan meminta $\alpha(T^{-1}(A)) = \beta(A)$ untuk setiap $A \in \Sigma_Y$. Ini mengantar kita pada definisi berikut.

Definisi 9.1 (Ukuran hasil dorong (*push-forward*)). Misalkan $\alpha \in \mathcal{P}(X)$ dan $T : X \rightarrow Y$ terukur. Ukuran hasil dorong $T_{\#}\alpha \in \mathcal{P}(Y)$ didefinisikan oleh $T_{\#}\alpha(A) = \alpha(T^{-1}(A))$ untuk setiap $A \in \Sigma_Y$.

Sekarang kita dapat memperkenalkan secara formal masalah Monge untuk OT:

Definisi 9.2 (Monge OT). Misalkan X dan Y ruang terukur, $\alpha \in \mathcal{P}(X)$, $\beta \in \mathcal{P}(Y)$, dan c fungsi biaya terukur yang terbatas dari bawah. Masalah Monge untuk OT adalah

$$(9.1) \quad \inf_{\substack{T: X \rightarrow Y \text{ terukur} \\ T_{\#}\alpha = \beta}} \int c(x, T(x)) d\alpha(x), \quad \inf \emptyset := +\infty.$$

Masalah Monge untuk OT mempunyai beberapa kekurangan. Sebagai contoh, setiap x hanya dapat dipetakan oleh T ke *satu* titik y , sehingga massa pada satu titik x tidak dapat dibagi ke beberapa titik y . Karena itu, apabila α memberikan massa tak nol pada suatu titik, $Y \subseteq \mathbb{R}^q$, dan β kontinu mutlak terhadap ukuran Lebesgue³, tidak ada peta T yang memenuhi syarat. Selain itu, bergantung pada pilihan c , masalah ini umumnya sulit dianalisis karena peubah tak diketahui T muncul di dalam biaya c .

³Hal ini khususnya menyiratkan bahwa β tidak mempunyai massa titik.

Perumusan yang lebih umum dan lebih mudah dianalisis adalah OT Kantorovich. Alih-alih memakai peta $T : X \rightarrow Y$, transportasi juga dimodelkan oleh suatu distribusi. Suatu rencana transportasi adalah distribusi probabilitas γ pada ruang hasil kali terukur $X \times Y$ yang mempunyai α dan β sebagai marginalnya: $\gamma(A \times Y) = \alpha(A)$ dan $\gamma(X \times B) = \beta(B)$ untuk semua $A \in \Sigma_X$ dan $B \in \Sigma_Y$. Secara intuitif, $\gamma(A \times B)$ adalah massa yang diangkut dari A ke B . Himpunan semua distribusi dengan marginal α, β dilambangkan dengan $\Pi(\alpha, \beta)$ dan anggotanya disebut kopling (*coupling*). Sekarang kita dapat mendefinisikan masalah Kantorovich untuk OT.

Definisi 9.3 (Kantorovich OT). Misalkan X dan Y ruang terukur, $\alpha \in \mathcal{P}(X)$, $\beta \in \mathcal{P}(Y)$, dan c fungsi biaya terukur. Masalah Kantorovich untuk OT adalah

$$(9.2) \quad \inf_{\gamma \in \Pi(\alpha, \beta)} \int c(x, y) d\gamma(x, y).$$

Perhatikan bahwa (9.2) jauh lebih menguntungkan daripada (9.1). Secara khusus, objektifnya kini linear.

Catatan. Kita juga dapat merumuskan (9.2) dengan peubah acak. Setiap kopling γ dapat direalisasikan sebagai vektor acak $(X, Y) \sim \gamma$ dengan $X \sim \alpha$ dan $Y \sim \beta$. Biayanya kemudian memenuhi

$$(9.3) \quad \int c(x, y) d\gamma(x, y) = \mathbb{E}[c(X, Y)].$$

Kita nyatakan hasil berikut.

Teorema 9.4 (Eksistensi solusi). Misalkan X dan Y ruang Polish yang dilengkapi aljabar- σ Borelnya, $\alpha \in \mathcal{P}(X)$, dan $\beta \in \mathcal{P}(Y)$. Jika $c : X \times Y \rightarrow (-\infty, +\infty]$ terbatas dari bawah dan semikontinu bawah, maka terdapat rencana transportasi optimal $\hat{\gamma} \in \Pi(\alpha, \beta)$, yaitu solusi untuk (9.2).

Sketsa bukti. Untuk bukti terperinci, lihat misalnya [Villani 2009, Theorem 4.1]. Argumennya adalah metode langsung. Ambil barisan $(\gamma_n)_n \subset \Pi(\alpha, \beta)$ yang nilai biayanya menuju infimum. Karena α dan β ketat pada ruang Polish, keluarga kopling dengan kedua marginal tetap juga ketat. Himpunan $\Pi(\alpha, \beta)$ tertutup terhadap konvergensi lemah; teorema Prokhorov karena itu menyatakan bahwa himpunan tersebut kompak secara lemah. Setelah mengambil suatu subbarisan, diperoleh $\gamma_n \rightharpoonup \hat{\gamma} \in \Pi(\alpha, \beta)$. Karena c semikontinu bawah dan terbatas dari bawah, pemetaan $\gamma \mapsto \int c(x, y) d\gamma(x, y)$ semikontinu bawah secara lemah. Maka $\hat{\gamma}$ meminimumkan biaya dan bukti selesai. $\square$

Satu kasus khusus penting dari transportasi optimal perlu disoroti.

Definisi 9.5 (Jarak Wasserstein). Misalkan (X, d) ruang metrik Polish dan $p \in [1, \infty)$. Tentukan $x_0 \in X$ dan tuliskan $\mathcal{P}_p(X) := \{\mu \in \mathcal{P}(X) : \int d(x, x_0)^p d\mu(x) < \infty\}$; definisi ini tidak bergantung pada pilihan x_0 . Untuk $\alpha, \beta \in \mathcal{P}_p(X)$ dan biaya $c(x, y) = d(x, y)^p$, besaran

$$(9.4) \quad W_p(\alpha, \beta) := \left(\inf_{\gamma \in \Pi(\alpha, \beta)} \int d(x, y)^p d\gamma(x, y) \right)^{1/p}$$

disebut jarak Wasserstein- p .

Secara khusus, W_p adalah metrik pada ruang ukuran probabilitas bermomen ke- p hingga, yaitu $\mathcal{P}_p(X)$.

9.2 DUALITAS KANTOROVICH

Dari [Chapter 7](#) kita telah mengenal konsep dualitas. Dualitas memainkan peran penting dalam OT dan menghasilkan teorema terkenal berikut.

Teorema 9.6 (Dualitas Kantorovich). Misalkan X dan Y ruang Polish dengan aljabar- σ Borelnya, $\alpha \in \mathcal{P}(X)$, $\beta \in \mathcal{P}(Y)$, dan $c : X \times Y \rightarrow [0, \infty]$ semikontinu bawah. Tuliskan $C_b(X)$ dan $C_b(Y)$ untuk fungsi kontinu terbatas bernilai riil. Maka

$$(9.5) \quad \inf_{\gamma \in \Pi(\alpha, \beta)} \int c(x, y) d\gamma(x, y) = \sup_{\substack{\varphi \in C_b(X), \psi \in C_b(Y) \\ \varphi(x) + \psi(y) \leq c(x, y) \quad \forall (x, y)}} \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y).$$

Sketsa bukti. Kita mulai dengan ketaksamaan yang mudah. Ambil $(\varphi, \psi) \in C_b(X) \times C_b(Y)$ sedemikian sehingga $\varphi(x) + \psi(y) \leq c(x, y)$ untuk semua (x, y) , dan ambil sembarang $\gamma \in \Pi(\alpha, \beta)$. Maka

$$(9.6) \quad \begin{aligned} \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) &= \int \varphi(x) d\gamma(x, y) + \int \psi(y) d\gamma(x, y) \\ &= \int (\varphi(x) + \psi(y)) d\gamma(x, y) \\ &\leq \int c(x, y) d\gamma(x, y). \end{aligned}$$

Karena γ dan (φ, ψ) sembarang, kita dapat mengambil infimum di ruas kanan dan supremum di ruas kiri untuk memperoleh

$$(9.7) \quad \sup_{\substack{\varphi \in C_b(X), \psi \in C_b(Y) \\ \varphi(x) + \psi(y) \leq c(x, y) \quad \forall (x, y)}} \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) \leq \inf_{\gamma \in \Pi(\alpha, \beta)} \int c(x, y) d\gamma(x, y).$$

Ketaksamaan sebaliknya lebih rumit. Pertama, kita dapat menulis ulang (9.2) sebagai

$$(9.8) \quad \inf_{\gamma \in \mathcal{M}_+(X \times Y)} \left\{ \int c(x, y) d\gamma + \delta_{\Pi(\alpha, \beta)}(\gamma) \right\},$$

dengan $\delta_{\Pi(\alpha, \beta)}$ fungsi indikator seperti biasa. Untuk $\gamma \in \mathcal{M}_+(X \times Y)$, berlaku

$$(9.9) \quad \delta_{\Pi(\alpha, \beta)}(\gamma) = \sup_{\varphi \in C_b(X), \psi \in C_b(Y)} \left\{ \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) - \int (\varphi(x) + \psi(y)) d\gamma(x, y) \right\}.$$

Jika $\gamma \in \Pi(\alpha, \beta)$, ekspresi di dalam supremum pada ruas kanan bernilai nol untuk setiap (φ, ψ) , sehingga supremumnya nol. Sebaliknya, jika $\gamma \notin \Pi(\alpha, \beta)$, sedikitnya satu marginal berbeda. Ukuran Borel hingga yang berbeda pada ruang Polish dapat dipisahkan oleh suatu fungsi kontinu terbatas; tanpa mengurangi keumuman, terdapat $\varphi \in C_b(X)$ sedemikian sehingga

$$(9.10) \quad \int \varphi d(\alpha - \gamma_x) \neq 0,$$

dengan γ_x marginal- x dari γ . Mengganti φ dengan $t\varphi$ dan memilih tanda t ketika $|t| \rightarrow \infty$ menunjukkan bahwa supremumnya adalah $+\infty$.

Langkah taktrivial untuk ketaksamaan sebaliknya adalah pertukaran infimum dan supremum. Pertukaran itu tidak mengikuti perhitungan formal semata; di bawah hipotesis ruang Polish dan biaya semikontinu bawah tak negatif di atas, pertukaran tersebut dijamin oleh teorema dualitas Kantorovich standar, lihat [Villani 2009, Theorem 5.10]. Dengan justifikasi dualitas kuat ini, diperoleh

$$(9.11) \quad \begin{aligned} \inf_{\gamma \in \Pi(\alpha, \beta)} \int c(x, y) d\gamma(x, y) &= \inf_{\gamma \in \mathcal{M}_+(X \times Y)} \sup_{\varphi \in C_b(X), \psi \in C_b(Y)} \left\{ \int c(x, y) d\gamma(x, y) \right. \\ &\quad \left. + \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) - \int (\varphi(x) + \psi(y)) d\gamma(x, y) \right\} \\ &= \sup_{\varphi \in C_b(X), \psi \in C_b(Y)} \left\{ \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) \right. \\ &\quad \left. + \inf_{\gamma \in \mathcal{M}_+(X \times Y)} \int (c(x, y) - \varphi(x) - \psi(y)) d\gamma(x, y) \right\} \\ &= \sup_{\substack{\varphi \in C_b(X), \psi \in C_b(Y) \\ \varphi(x) + \psi(y) \leq c(x, y) \ \forall (x, y)}} \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y). \end{aligned}$$

Pada persamaan terakhir, infimum terhadap ukuran tak negatif bernilai nol jika $c - \varphi - \psi \geq 0$ di setiap titik (ambil $\gamma = 0$), dan bernilai $-\infty$ jika ketaksamaan itu gagal (skalakan massa Dirac pada titik pelanggaran). Ini sama dengan fungsi indikator kendala dual, sebagaimana pada (9.9). $\square$

9.3 DISKRETISASI TRANSPORTASI OPTIMAL: ALGORITME SINKHORN-KNOPP

Untuk mendiskretisasi (9.2), kita modelkan α dan β sebagai ukuran diskret. Tuliskan $\Delta_n := \{r \in \mathbb{R}_+^n : \mathbb{1}_n^\top r = 1\}$ dan $\Delta_n^\circ := \{r \in \mathbb{R}_{++}^n : \mathbb{1}_n^\top r = 1\}$. Untuk suatu vektor $a = (a_1, \dots, a_n) \in \Delta_n$ dan titik $x_i \in X$, tetapkan

$$(9.12) \quad \alpha = \sum_{i=1}^n a_i \delta_{x_i},$$

dan, serupa dengan itu, untuk $b = (b_1, \dots, b_m) \in \Delta_m$ dan $y_j \in Y$, tetapkan

$$(9.13) \quad \beta = \sum_{j=1}^m b_j \delta_{y_j}.$$

Selanjutnya, definisikan $C = [C_{i,j}]_{i,j} = [c(x_i, y_j)]_{i,j}$. Rencana transportasi adalah matriks $P \in \mathbb{R}^{n \times m}$ sedemikian sehingga

$$(9.14) \quad \begin{cases} \sum_{j=1}^m P_{i,j} &= a_i, \\ \sum_{i=1}^n P_{i,j} &= b_j, \\ P_{i,j} &\geq 0. \end{cases}$$

Kendala marginal dapat ditulis ringkas sebagai $P \mathbb{1}_m = a$ dan $P^\top \mathbb{1}_n = b$. Masalah OT diskret kemudian berbentuk

$$(9.15) \quad \min_{P \in \mathbb{R}^{n \times m}} \langle C, P \rangle = \sum_{i,j} C_{i,j} P_{i,j}$$

dengan syarat $P \mathbb{1}_m = a, \quad P^\top \mathbb{1}_n = b, \quad P_{i,j} \geq 0.$

Dalam praktik, masalah ini sering diregularisasi. Untuk pembahasan regularisasi entropik berikut, andaikan $C \in \mathbb{R}^{n \times m}$, sehingga semua biaya diskret berhingga. Untuk $P \in \mathbb{R}_+^{n \times m}$, definisikan regularisasi entropik

$$(9.16) \quad E(P) := \sum_{i,j} P_{i,j} (\log(P_{i,j}) - 1),$$

dengan konvensi kontinu $0 \log 0 = 0$; di luar ortan tak negatif, tetapkan $E(P) = +\infty$. Untuk $\varepsilon > 0$, pertimbangkan masalah

$$(9.17) \quad \min_{P \in \mathbb{R}_+^{n \times m}} \langle C, P \rangle + \varepsilon E(P) \quad \text{dengan syarat } P \mathbb{1}_m = a, \quad P^\top \mathbb{1}_n = b.$$

Lema 9.7. Andaikan $a \in \Delta_n^\circ$, $b \in \Delta_m^\circ$, $C \in \mathbb{R}^{n \times m}$, dan $\varepsilon > 0$. Solusi masalah (9.17) unik dan mempunyai representasi

$$(9.18) \quad P_{i,j} = u_i K_{i,j} v_j,$$

dengan $u_i, v_j > 0$ dan $K_{i,j} = \exp\left(-\frac{C_{i,j}}{\varepsilon}\right) > 0$. Vektor penskalaan (u, v) unik hingga transformasi $(u, v) \mapsto (tu, t^{-1}v)$ untuk $t > 0$.

Bukti. Himpunan layak adalah politop transportasi tak kosong dan kompak: matriks $Q = ab^\top$ layak, bahkan $Q_{i,j} > 0$. Karena fungsi objektif kontinu pada politop ini, suatu pemimum ada. Fungsi $h(t) = t(\log t - 1)$ dengan $h(0) = 0$ bersifat konveks ketat pada $[0, \infty)$; karena itu, jumlah entropik bersifat konveks ketat dan peminimumnya unik.

Peminimum P tidak dapat mempunyai entri nol. Memang, jika $P_{i,j} = 0$ untuk sedikitnya satu pasangan (i, j) , maka $P_t = (1-t)P + tQ$ tetap layak untuk $t \in (0, 1)$. Pada setiap entri nol, turunan searah satu sisi dari suku entropi memenuhi $\frac{d}{dt}h(tQ_{i,j}) = Q_{i,j} \log(tQ_{i,j}) \rightarrow -\infty$ ketika $t \downarrow 0$, sedangkan kontribusi biaya linear dan turunan pada entri positif tetap hingga. Jadi, untuk $t > 0$ yang cukup kecil, nilai objektif pada P_t lebih kecil daripada pada P , suatu kontradiksi. Dengan demikian, $P_{i,j} > 0$ untuk semua i, j , dan kondisi pengali Lagrange untuk kendala marginal affin dapat diterapkan.

Lagrangian masalah ini adalah

$$(9.19) \quad L(P, \lambda, \mu) = \langle C, P \rangle + \varepsilon E(P) + \langle \lambda, P\mathbb{1}_m - a \rangle + \langle \mu, P^\top \mathbb{1}_n - b \rangle.$$

Kondisi optimalitasnya adalah

$$(9.20) \quad \begin{cases} 0 &= C_{i,j} + \varepsilon \log(P_{i,j}) + \lambda_i + \mu_j, \\ 0 &= P\mathbb{1}_m - a, \\ 0 &= P^\top \mathbb{1}_n - b. \end{cases}$$

Kondisi pertama menyiratkan

$$(9.21) \quad P_{i,j} = \exp\left(-\frac{\lambda_i}{\varepsilon}\right) \exp\left(-\frac{C_{i,j}}{\varepsilon}\right) \exp\left(-\frac{\mu_j}{\varepsilon}\right).$$

Dengan $u_i = \exp(-\lambda_i/\varepsilon)$ dan $v_j = \exp(-\mu_j/\varepsilon)$, diperoleh representasi yang dinyatakan. Jika pasangan positif $(\tilde{u}, \tilde{v})$ menghasilkan rencana yang sama, maka dari $u_i K_{i,j} v_j = \tilde{u}_i K_{i,j} \tilde{v}_j$ dan $K_{i,j} > 0$ diperoleh $\tilde{u}_i/u_i = \tilde{v}_j/v_j$ untuk setiap i, j . Karena ruas kiri hanya bergantung pada i dan ruas kanan hanya pada j , semua rasio itu sama dengan suatu $t > 0$; jadi $(\tilde{u}, \tilde{v}) = (tu, t^{-1}v)$. $\square$

Kendala yang masih harus dipenuhi adalah $P\mathbb{1}_m = \text{diag}(u)K\text{diag}(v)\mathbb{1}_m = \text{diag}(u)Kv = a$ dan $P^\top \mathbb{1}_n = \text{diag}(v)K^\top u = b$. Ini memotivasi algoritme Sinkhorn–Knopp. Pilih $v_0 \in \mathbb{R}_{++}^m$, misalnya $v_0 = \mathbb{1}_m$, lalu untuk $k = 0, 1, 2, \dots$ perbarui

$$(9.22) \quad \begin{cases} u_{k+1} = a \oslash (Kv_k), \\ v_{k+1} = b \oslash (K^\top u_{k+1}), \end{cases}$$

dengan $\oslash$ menyatakan pembagian komponen demi komponen. Berdasarkan positività a , b , dan K , semua penyebut dan iterat tetap positif. Dengan hipotesis pada lema di atas, teorema Sinkhorn–Knopp menyatakan bahwa rencana $\text{diag}(u_k)K\text{diag}(v_k)$, $k \geq 1$, konvergen ke rencana unik pada masalah (9.17). Vektor penskalaannya sendiri tetap mempunyai ambiguitas perkalian $(u, v) \mapsto (tu, t^{-1}v)$.

DAFTAR PUSTAKA

C. VILLANI (2009), *Optimal Transport: Old and New*, **volume** 338, Grundlehren der mathematischen Wissenschaften, Springer Berlin, Heidelberg, DOI: [10.1007/978-3-540-71050-9](https://doi.org/10.1007/978-3-540-71050-9).

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber. Rekaman terstruktur dengan identitas peristiwa Oo15-HAB-ADV-oo84 sampai Oo15-HAB-ADV-oo96 menyertai sumber edisi ini.

- (i) Ruang terukur kini membawa aljabar- σ bernama; setiap himpunan yang dipakai pada marginal dan hasil dorong disyaratkan terukur, serta peta transportasi dan fungsi biaya disyaratkan terukur.
- (ii) Definisi ukuran membedakan ukuran bertanda hingga dari ukuran tak negatif dan melengkapi sifat aljabar- σ yang diperlukan untuk kebermaknaan aditivitas terhingga.
- (iii) Masalah Monge memakai infimum atas peta terukur yang layak, dengan konvensi $\inf \emptyset = +\infty$, karena keberadaan dan ketercapaian peta tidak dijamin.
- (iv) Contoh ketidaklayakan Monge kini menyatakan $Y \subseteq \mathbb{R}^q$ sebelum menyebut ukuran Lebesgue; catatan kaki menyatakan ketiadaan atom sebagai konsekuensi kontinuitas mutlak, bukan sebagai definisi yang ekuivalen.
- (v) Teorema eksistensi kini mensyaratkan ruang Polish Borel. Sketsa bukti memakai keketatan marginal, kekompakan lemah melalui Prokhorov, ketertutupan himpunan kopling, dan semikontinuitas bawah biaya.
- (vi) Jarak Wasserstein dibangun dari metrik d pada ruang Polish dan dibatasi pada $\mathcal{P}_p(X)$, ruang ukuran probabilitas dengan momen ke- p hingga.
- (vii) Teorema dualitas Kantorovich kini menyatakan ruang Polish Borel, biaya semikontinu bawah tak negatif, serta kelas potensial $C_b(X) \times C_b(Y)$ dan kendala titik demi titik.
- (viii) Sketsa dualitas membenarkan pemisahan marginal dengan fungsi kontinu terbatas, memperbaiki domain yang salah $\mathcal{M}_+(\alpha, \beta)$ menjadi $\mathcal{M}_+(X \times Y)$, dan mengidentifikasi secara terbuka pertukaran infimum-supremum sebagai teorema dualitas kuat, bukan akibat manipulasi formal.

- (ix) Bobot diskret dinyatakan sebagai vektor $a \in \Delta_n$ dan $b \in \Delta_m$; vektor satuan pada kendala marginal diberi dimensi yang benar, transpos dipakai konsisten, dan pemisah kendala yang hilang dipulihkan.
- (x) Entropi didefinisikan pada ortan tak negatif dengan $0 \log 0 = 0$ dan bernilai $+\infty$ di luarnya; $\varepsilon > 0$ serta keberhinggaan semua entri matriks biaya dinyatakan sebelum masalah regularisasi.
- (xi) Lema faktorisasi mensyaratkan marginal positif. Eksistensi dan keunikan dibuktikan dari kekompakan politop dan kekonveksan ketat; perturbasi menuju $ab^\top$ membuktikan positifnya setiap entri sebelum kondisi pengali Lagrange digunakan. Ambiguitas penskalaan juga dinyatakan.
- (xii) Iterasi Sinkhorn diberi inisialisasi positif dan indeks yang lengkap. Positivitas penyebut serta konvergensi rencana penskalaan ke rencana entropik unik dinyatakan, sambil mempertahankan ambiguitas perkalian pasangan penskalaan.
- (xiii) Entri daftar pustaka Villani memakai pengarang tunggal Cédric Villani sesuai metadata penerbit; penanda “and others” yang keliru pada berkas sumber tidak lagi menghasilkan nama tampilan “andothers”.

ATRIBUSI, LISENSI, DAN NONDUKUNGAN

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.

Andreas Habring dan TU Graz tidak menyusun, memeriksa, menyetujui, atau mendukung terjemahan ini. Penyebutan nama mereka semata-mata untuk atribusi karya sumber.