

OPTIMISASI KONVEKS

UNIT 4: PENURUNAN SUBGRADIEN TERPROYEKSI
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 4, “Projected subgradient descent”, dari versi sumber yang ditentukan di atas. Unit ini melanjutkan Unit 3. Pembaca diharapkan telah mengenal fungsi konveks, subgradien dan subdiferensial, ruang Hilbert, norma, fungsi indikator, serta kondisi optimalitas Fermat.

Notasi, urutan teorema, bukti, dua latihan informal, dan rujukan sumber dipertahankan. Sejumlah kekeliruan matematis dalam sumber diperbaiki secara terbuka; ringkasannya disertakan pada akhir unit dan rekaman terstruktur lengkap menyertai sumber edisi ini. Tidak ada layanan daring atau perangkat lunak tertutup yang diperlukan untuk membaca unit ini.

DAFTAR ISI

4	PENURUNAN SUBGRADIEN TERPROYEKSI	1
---	----------------------------------	---

4 PENURUNAN SUBGRADIEN TERPROYEKSI

Misalkan V ruang Hilbert real, $C \subset V$ himpunan tak kosong, tertutup, dan konveks, serta $f : V \rightarrow \mathbb{R}$ fungsi konveks. Kita tertarik menyelesaikan masalah

$$(4.1) \quad \min_{x \in C} f(x).$$

Kita mengasumsikan bahwa himpunan peminim tidak kosong dan menetapkan $x^* \in \arg \min_{x \in C} f(x)$. Masalah berkendala di atas selalu dapat ditulis sebagai masalah tak berkendala melalui

$$(4.2) \quad \min_{x \in V} f(x) + \delta_C(x),$$

dengan δ_C fungsi indikator himpunan C .¹

Ingat kembali metode optimisasi numerik paling dasar untuk masalah semacam ini ketika $C = V$ dan f terdiferensialkan: penurunan gradien (atau penurunan *tercuram*). Kita memilih nilai awal x_0 , lalu untuk $k = 0, 1, \dots$ melakukan pembaruan

$$(4.3) \quad x_{k+1} = x_k - \tau_k \nabla f(x_k),$$

dengan $\tau_k > 0$ menyatakan ukuran langkah. Algoritma *baru* pertama yang kita tinjau ialah versi subgradien dari penurunan tercuram: untuk $k = 0, 1, \dots$,

$$(4.4) \quad \begin{cases} g_k & \in \partial f(x_k), \\ x_{k+1} & = x_k - \tau_k g_k. \end{cases}$$

Jika $C \neq V$, masalah segera dapat muncul: mungkin saja $x_{k+1} \notin C$. Dalam hal itu, iterasi yang memakai subdiferensial $f + \delta_C$ tidak lagi terdefinisi karena $\partial \delta_C(x) = \emptyset$ untuk $x \notin C$. Karena itu, kita perlu memastikan setiap iterasi baru tetap berada di C ; untuk tujuan ini kita memakai *proyeksi*.

Teorema 4.1 (Teorema proyeksi). Misalkan V ruang Hilbert real dan $C \subset V$ tak kosong, tertutup, dan konveks. Fungsi berikut terdefinisi dengan baik:

$$(4.5) \quad \begin{aligned} \text{proj}_C : V &\rightarrow C, \\ x &\mapsto \arg \min_{y \in C} \|x - y\|. \end{aligned}$$

¹Formulasi ini memakai f yang terdefinisi pada seluruh V , termasuk di luar C .

Bukti. Kita perlu menunjukkan bahwa minimum tercapai secara tunggal. Tetapkan $d = \inf_{y \in C} \|y - x\|$, dan ambil barisan peminimum $(y_n)_n \subset C$, yaitu

$$(4.6) \quad \lim_n \|y_n - x\| = d.$$

Karena C konveks, $(y_n + y_m)/2 \in C$. Identitas jajaran genjang memberi

$$\|y_n - y_m\|^2 = 2\|y_n - x\|^2 + 2\|y_m - x\|^2 - 4\left\|\frac{y_n + y_m}{2} - x\right\|^2 \leq 2\|y_n - x\|^2 + 2\|y_m - x\|^2 - 4d^2.$$

Ruas kanan menuju nol ketika $m, n \rightarrow \infty$, sehingga $(y_n)_n$ merupakan barisan Cauchy. Kelengkapan V menghasilkan $y_n \rightarrow \hat{y} \in V$, sedangkan ketertutupan C menghasilkan $\hat{y} \in C$. Dari kontinuitas norma diperoleh

$$(4.7) \quad \|\hat{y} - x\| = \lim_n \|y_n - x\| = d,$$

jadi peminim memang ada.

Untuk ketunggalan, andaikan $y_1 \neq y_2$ keduanya peminim. Identitas jajaran genjang memberikan

$$(4.8) \quad \left\|\frac{y_1 + y_2}{2} - x\right\|^2 = \frac{1}{2}\|y_1 - x\|^2 + \frac{1}{2}\|y_2 - x\|^2 - \frac{1}{4}\|y_1 - y_2\|^2 < d^2.$$

Namun $(y_1 + y_2)/2 \in C$, yang bertentangan dengan definisi d . Jadi peminimnya tunggal. $\square$

Dengan proyeksi, kita memperoleh cara mengatasi masalah *keluar* dari C : metode subgradien terproyeksi. Pilih $x_0 \in C$; kemudian, untuk $k = 0, 1, \dots$ dan $\tau_k \geq 0$, tetapkan

$$(4.9) \quad \begin{cases} g_k & \in \partial f(x_k), \\ x_{k+1} & = \text{proj}_C(x_k - \tau_k g_k). \end{cases}$$

Untuk membuktikan konvergensi metode ini, kita memerlukan beberapa hasil bantu.

Lema 4.2. Misalkan V ruang Hilbert real dan $C \subset V$ tak kosong, tertutup, dan konveks. Maka

$$(4.10) \quad \langle x - \text{proj}_C(x), y - \text{proj}_C(x) \rangle \leq 0, \quad y \in C.$$

Khususnya, jika C subruang,² maka

$$(4.11) \quad \langle x - \text{proj}_C(x), y \rangle = 0, \quad y \in C.$$

²Artinya, C memenuhi definisi ruang vektor.

Bukti. Untuk setiap $y \in C$, kita mempunyai

$$\begin{aligned}
 (4.12) \quad & \|\text{proj}_C(x) - x\|^2 \leq \|y - x\|^2 \\
 & = \|y - \text{proj}_C(x) + \text{proj}_C(x) - x\|^2 \\
 & = \|y - \text{proj}_C(x)\|^2 + 2 \langle y - \text{proj}_C(x), \text{proj}_C(x) - x \rangle + \|\text{proj}_C(x) - x\|^2.
 \end{aligned}$$

Akibatnya,

$$(4.13) \quad 0 \leq \|y - \text{proj}_C(x)\|^2 + 2 \langle y - \text{proj}_C(x), \text{proj}_C(x) - x \rangle.$$

Ambil sebarang $z \in C$, lalu pada ketaksamaan di atas masukkan $y = \text{proj}_C(x) + t(z - \text{proj}_C(x))$ untuk $t \in (0, 1)$. Kita memperoleh

$$(4.14) \quad 0 \leq t^2 \|z - \text{proj}_C(x)\|^2 + 2t \langle z - \text{proj}_C(x), \text{proj}_C(x) - x \rangle.$$

Setelah dibagi dengan $t > 0$,

$$(4.15) \quad 0 \leq t \|z - \text{proj}_C(x)\|^2 + 2 \langle z - \text{proj}_C(x), \text{proj}_C(x) - x \rangle.$$

Dengan mengambil limit $t \rightarrow 0$, kita memperoleh hasil yang diinginkan. Kesamaan untuk kasus subruang ditinggalkan sebagai latihan. $\square$

Proposisi 4.3. Misalkan V ruang Hilbert real dan $C \subset V$ tak kosong, tertutup, dan konveks. Proyeksi pada C bersifat tak ekspansif, yaitu kontinu Lipschitz dengan konstanta satu:

$$(4.16) \quad \|\text{proj}_C(x_1) - \text{proj}_C(x_2)\| \leq \|x_1 - x_2\|.$$

Bukti. Tanpa mengurangi keumuman, andaikan $\|\text{proj}_C(x_2) - \text{proj}_C(x_1)\|^2 \neq 0$, sebab jika tidak, tidak ada yang perlu dibuktikan. Kita memperoleh

$$\begin{aligned}
 (4.17) \quad & \|\text{proj}_C(x_2) - \text{proj}_C(x_1)\|^2 = \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 + x_1 - \text{proj}_C(x_1) \rangle \\
 & = \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 \rangle \\
 & \quad + \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_1 - \text{proj}_C(x_1) \rangle \\
 & \leq \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 \rangle \\
 & = \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_2 + x_2 - x_1 \rangle \\
 & \leq \langle \text{proj}_C(x_1) - \text{proj}_C(x_2), x_2 - \text{proj}_C(x_2) \rangle \\
 & \quad + \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_2 - x_1 \rangle \\
 & \leq \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_2 - x_1 \rangle \\
 & \leq \|\text{proj}_C(x_2) - \text{proj}_C(x_1)\| \|x_2 - x_1\|.
 \end{aligned}$$

Membagi dengan $\|\text{proj}_C(x_2) - \text{proj}_C(x_1)\| \neq 0$ menghasilkan kesimpulan. $\square$

Lema 4.4 (Ketaksamaan fundamental metode subgradien terproyeksi). Misalkan $x^* \in \arg \min_{x \in C} f(x)$, dan misalkan x_k adalah iterasi metode subgradien terproyeksi (4.9), dengan $g_k \in \partial f(x_k)$ dan $\tau_k \geq 0$. Maka

$$(4.18) \quad \|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2 - 2\tau_k(f(x_k) - f(x^*)) + \tau_k^2 \|g_k\|^2.$$

Bukti. Dari definisi subgradien, $f(x_k) + \langle g_k, x^* - x_k \rangle \leq f(x^*)$. Karena $x^* \in C$, kita mempunyai $\text{proj}_C(x^*) = x^*$. Ketakspansifan proyeksi lalu memberikan

$$(4.19) \quad \begin{aligned} \|x_{k+1} - x^*\|^2 &= \|\text{proj}_C(x_k - \tau_k g_k) - \text{proj}_C(x^*)\|^2 \\ &\leq \|x_k - \tau_k g_k - x^*\|^2 \\ &= \|x_k - x^*\|^2 - 2\tau_k \langle g_k, x_k - x^* \rangle + \tau_k^2 \|g_k\|^2 \\ &\leq \|x_k - x^*\|^2 - 2\tau_k(f(x_k) - f(x^*)) + \tau_k^2 \|g_k\|^2. \end{aligned}$$

□

Hal yang wajar dilakukan sekarang ialah memakai hasil sebelumnya untuk menentukan ukuran langkah optimal. Lebih tepatnya, dengan meminimumkan ruas kanan (4.19) terhadap τ_k , kita memperoleh

$$(4.20) \quad \tau_k = \frac{f(x_k) - f(x^*)}{\|g_k\|^2}$$

jika $g_k \neq 0$, dan kita menetapkan $\tau_k = 0$ jika $g_k = 0$. Ukuran langkah ini disebut aturan ukuran langkah Polyak.

Sebagai latihan, buktikan bahwa jika fungsi konveks $f : V \rightarrow \mathbb{R}$ bersifat L -Lipschitz secara global pada V , maka setiap $g \in \partial f(x)$ memenuhi $\|g\| \leq L$. Pada hasil-hasil berikut, kita memakai langsung batas pada subgradien yang dipilih, sehingga juga mencakup situasi berkendala yang tidak memenuhi asumsi Lipschitz global tersebut.

Teorema 4.5. Andaikan subgradien yang dipilih pada iterasi memenuhi $\|g_k\| \leq L$. Dengan aturan ukuran langkah Polyak

$$(4.21) \quad \tau_k = \frac{f(x_k) - f(x^*)}{\|g_k\|^2} \quad \text{jika } g_k \neq 0, \quad \tau_k = 0 \quad \text{jika } g_k = 0.$$

metode subgradien terproyeksi (4.9) memenuhi

- (i) $\|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2$, dengan ketaksamaan ketat jika $f(x_k) > f(x^*)$;
- (ii) $f(x_k) \rightarrow f(x^*)$ ketika $k \rightarrow \infty$; dan
- (iii) $f_{\text{best}}^N - f(x^*) \leq \frac{L\|x_1 - x^*\|}{\sqrt{N}}$, dengan $f_{\text{best}}^N = \min_{k=1, \dots, N} f(x_k)$.

Bukti. Tanpa mengurangi keumuman, kita boleh mengasumsikan $f(x^*) = 0$. Jika tidak, cukup tinjau $\tilde{f}(x) := f(x) - f(x^*)$. Dari [teorema 4.4](#) dan aturan ukuran langkah diperoleh

$$(4.22) \quad \begin{aligned} \|x_{k+1} - x^*\|^2 &\leq \|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 \|g_k\|^2 \\ &= \|x_k - x^*\|^2 - a_k, \end{aligned}$$

dengan $a_k = f(x_k)^2 / \|g_k\|^2$ jika $g_k \neq 0$, dan nol jika $g_k = 0$. Jika $g_k = 0$, kekonveksan memberi $f(x_k) = f(x^*)$. Karena itu, pengurangan bersifat ketat tepat ketika celah nilai fungsi positif.

Dengan menata ulang dan menjumlahkan untuk $k = 1, \dots, N$, kita memperoleh

$$(4.23) \quad \sum_{k=1}^N a_k \leq \|x_1 - x^*\|^2 - \|x_{N+1} - x^*\|^2 \leq \|x_1 - x^*\|^2.$$

Karena $\|g_k\| \leq L$,

$$(4.24) \quad \sum_{k=1}^N f(x_k)^2 \leq \sum_{k=1}^N L^2 a_k \leq L^2 \|x_1 - x^*\|^2.$$

Batas ini berlaku untuk setiap N , sehingga $f(x_k) \rightarrow 0$. Selain itu,

$$(4.25) \quad N(f_{\text{best}}^N)^2 \leq \sum_{k=1}^N f(x_k)^2 \leq L^2 \|x_1 - x^*\|^2,$$

yaitu

$$(4.26) \quad f_{\text{best}}^N \leq \frac{L \|x_1 - x^*\|}{\sqrt{N}}.$$

□

Korolari 4.6. Untuk mencapai ketelitian $f_{\text{best}}^N - f(x^*) \leq \varepsilon$, kita memerlukan

$$N = O\left(\frac{L^2 \|x_1 - x^*\|^2}{\varepsilon^2}\right)$$

iterasi.

Catatan. Ingat bahwa metode gradien mulus standar mencapai kompleksitas $O(1/\varepsilon)$.

Walaupun hasil konvergensi dengan aturan ukuran langkah Polyak menarik secara teoretis dan memberi batas kasus terburuk untuk iterasi terbaik, dalam praktiknya ukuran langkah tersebut tidak dapat dihitung tanpa mengetahui $f(x^*)$. Berikut ini kita berikan hasil konvergensi yang lebih umum.

Teorema 4.7. *Andaikan subgradien yang dipilih memenuhi $\|g_k\| \leq L$, dan ukuran langkah $\tau_k > 0$ memenuhi*

$$\frac{\sum_{k=1}^n \tau_k}{\sum_{k=1}^n \tau_k^2} \rightarrow \infty \quad \text{ketika } n \rightarrow \infty.$$

Maka

$$f_{\text{best}}^n - f(x^*) \leq \frac{\|x_1 - x^*\|^2 + L^2 \sum_{k=1}^n \tau_k^2}{2 \sum_{k=1}^n \tau_k} \rightarrow 0.$$

Bukti. Sekali lagi, untuk menyederhanakan notasi, andaikan $f(x^*) = 0$. Dengan memakai $\|g_k\| \leq L$ dan menjumlahkan ketaksamaan fundamental [teorema 4.4](#) untuk $k = 1, \dots, n$, kita memperoleh

$$(4.27) \quad 2 \sum_{k=1}^n \tau_k f(x_k) \leq \|x_1 - x^*\|^2 + L^2 \sum_{k=1}^n \tau_k^2.$$

Tuliskan

$$\sigma_n = \frac{\sum_{k=1}^n \tau_k}{\sum_{k=1}^n \tau_k^2}.$$

Karena $f_{\text{best}}^n \leq f(x_k)$,

$$(4.28) \quad f_{\text{best}}^n \leq \frac{\sum_{k=1}^n \tau_k f(x_k)}{\sum_{k=1}^n \tau_k} \leq \frac{\|x_1 - x^*\|^2}{2 \sum_{k=1}^n \tau_k} + \frac{L^2}{2\sigma_n}.$$

Hipotesis $\sigma_n \rightarrow \infty$ juga memaksa $\sum_{k=1}^n \tau_k \rightarrow \infty$; karena itu, kedua suku pada ruas kanan menuju nol. $\square$

Varian hasil konvergensi juga dapat diperoleh, misalnya jika C kompak; lihat [\[Beck 2017\]](#) untuk perinciannya.

Konvergensi dapat dipercepat dan juga *ditransfer* dari nilai fungsi ke iterasi $(x_k)_k$ jika kita menambahkan asumsi bahwa f konveks kuat.

Teorema 4.8. *Andaikan f konveks kuat dengan parameter $\mu > 0$ pada C , dan subgradien yang dipilih memenuhi $\|g_k\| \leq L$.³ Mulai dari $x_1 \in C$, gunakan ukuran langkah $\tau_k = \frac{2}{\mu k}$ untuk $k \geq 1$. Untuk $n \geq 2$, metode subgradien terproyeksi (4.9) memenuhi*

$$(i) \quad f_{\text{best}}^n - f(x^*) \leq \frac{2L^2}{\mu(n-1)}; \text{ dan}$$

$$(ii) \quad \|x_n - x^*\| \leq \frac{2L}{\mu\sqrt{n-1}}.$$

³Batas ini dikenakan pada subgradien yang benar-benar dipilih oleh algoritma; batas tersebut tidak disimpulkan hanya dari sifat Lipschitz relatif pada C .

Bukti. Seperti sebelumnya, tanpa mengurangi keumuman, tetapkan $f(x^*) = 0$. Kekonveksan kuat memperbaiki ketaksamaan fundamental menjadi

$$(4.29) \quad \begin{aligned} \|x_{k+1} - x^*\|^2 &\leq (1 - \mu\tau_k)\|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 \|g_k\|^2 \\ &\leq (1 - \mu\tau_k)\|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 L^2. \end{aligned}$$

Dengan menata ulang dan membagi dengan $2\tau_k$, diperoleh

$$(4.30) \quad f(x_k) \leq -\frac{\tau_k^{-1}}{2}\|x_{k+1} - x^*\|^2 + \frac{\tau_k^{-1} - \mu}{2}\|x_k - x^*\|^2 + \frac{\tau_k}{2}L^2.$$

Memasukkan $\tau_k = 2/(\mu k)$ menghasilkan

$$(4.31) \quad f(x_k) \leq -\frac{\mu k}{4}\|x_{k+1} - x^*\|^2 + \frac{\mu(k-2)}{4}\|x_k - x^*\|^2 + \frac{1}{\mu k}L^2.$$

Kalikan dengan $k-1$, lalu jumlahkan terhadap $k = 1, \dots, n$. Suku jarak meneleskop, sehingga

$$(4.32) \quad \sum_{k=1}^n (k-1)f(x_k) \leq -\frac{\mu n(n-1)}{4}\|x_{n+1} - x^*\|^2 + \frac{1}{\mu} \sum_{k=1}^n \frac{k-1}{k}L^2.$$

Karena $\sum_{k=1}^n (k-1) = n(n-1)/2$ dan $\sum_{k=1}^n (k-1)/k \leq n$, kita memperoleh

$$(4.33) \quad \frac{n(n-1)}{2}f_{\text{best}}^n \leq \sum_{k=1}^n (k-1)f(x_k) \leq -\frac{\mu n(n-1)}{4}\|x_{n+1} - x^*\|^2 + \frac{nL^2}{\mu}.$$

Dengan membuang suku jarak yang tak positif, diperoleh

$$(4.34) \quad f_{\text{best}}^n \leq \frac{2L^2}{\mu(n-1)}.$$

Untuk batas iterasi, buang suku $-2\tau_k f(x_k) \leq 0$ dari ketaksamaan fundamental yang diperbaiki. Dengan $d_k = \|x_k - x^*\|$,

$$(4.35) \quad d_{k+1}^2 \leq \left(1 - \frac{2}{k}\right)d_k^2 + \frac{4L^2}{\mu^2 k^2}.$$

Untuk $k = 1$, ketaksamaan ini memberi $d_2^2 \leq 4L^2/\mu^2$. Jika $d_k^2 \leq 4L^2/[\mu^2(k-1)]$, substitusi pada relasi di atas memberikan

$$d_{k+1}^2 \leq \frac{4L^2}{\mu^2} \left(\frac{k-2}{k(k-1)} + \frac{1}{k^2} \right) \leq \frac{4L^2}{\mu^2 k}.$$

Induksi membuktikan $\|x_n - x^*\| \leq 2L/[\mu\sqrt{n-1}]$ untuk setiap $n \geq 2$. □

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber.

- (i) Masalah optimisasi diberi ruang ambien, domain fungsi, himpunan kendala, titik awal, dan peminim yang bertipe lengkap; fungsi indikator kini ditambahkan pada fungsi yang terdefinisi di seluruh ruang.
- (ii) Teorema proyeksi dinyatakan pada ruang Hilbert real dan dibuktikan dengan identitas jajaran genjang, kelengkapan, serta ketertutupan; argumen sumber “barisan terbatas mempunyai subbarisan konvergen” tidak berlaku pada ruang hasil kali dalam umum.
- (iii) Hipotesis himpunan tak kosong, tertutup, dan konveks serta ruang Hilbert diulang pada karakterisasi dan ketakspansifan proyeksi.
- (iv) Semua hasil konvergensi memakai asumsi eksplisit bahwa subgradien yang dipilih dibatasi oleh L , bukan implikasi keliru bahwa fungsi yang Lipschitz hanya pada himpunan kendala membatasi setiap subgradien relatif.
- (v) Ketaksamaan fundamental diberi $x^* \in \arg \min_C f$ dan ukuran langkah tak negatif yang diperlukan oleh buktinya.
- (vi) Teorema Polyak membandingkan norma kuadrat dengan norma kuadrat, memakai indeks yang konsisten, mensyaratkan celah objektif positif untuk penurunan ketat, dan mengembalikan kuadrat yang hilang pada bukti laju $N^{-1/2}$.
- (vii) Pernyataan teorema ukuran langkah umum disatukan kembali dengan limit dan kesimpulannya, serta batas iterasi terbaik ditulis secara eksplisit.
- (viii) Hasil konveks kuat dimulai pada $k = 1$, mengganti kesamaan palsu dengan ketaksamaan, memperbaiki faktor laju nilai fungsi menjadi 2, dan membuktikan batas jarak iterasi dengan induksi. Tanda kutip liar pada rumus sumber juga dihapus.
- (ix) Rujukan silang ke definisi ruang vektor yang tidak termuat diganti dengan nama konsep, sedangkan sitasi Beck dipertahankan dalam bibliografi unit.

BIBLIOGRAFI

A. BECK (2017), *First-order methods in optimization*, SIAM.

ATRIBUSI DAN LISENSI

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.