

OPTIMISASI KONVEKS

UNIT 5: METODE GRADIEN PROKSIMAL
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 5, "Proximal Gradient Methods", dari versi sumber yang ditentukan di atas. Unit ini melanjutkan Unit 4. Pembaca diharapkan telah mengenal fungsi proper, semikontinu bawah, dan konveks; subgradien beserta aturan jumlah dan skalanya; kondisi optimalitas Fermat; proyeksi; serta fungsi dengan gradien Lipschitz.

Notasi, urutan hasil, bukti, sitasi, dan semua ajakan belajar dalam sumber dipertahankan. Sejumlah kekeliruan matematis dalam sumber diperbaiki secara terbuka; ringkasannya disertakan pada akhir unit dan rekaman terstruktur lengkap menyertai sumber edisi ini. Tidak ada layanan daring atau perangkat lunak tertutup yang diperlukan untuk membaca unit ini.

DAFTAR ISI

5	METODE GRADIEN PROKSIMAL	1
---	--------------------------	---

5 METODE GRADIEN PROKSIMAL

Kita telah melihat dalam bukti (dan latihan praktis) bahwa metode subgradien tidak memberikan konvergensi yang ideal. Dalam kasus dasar atau terburuk, nilai fungsi berkonvergensi dengan orde $O(1/\sqrt{k})$, dan konvergensi memerlukan ukuran langkah yang mengecil. Dalam bab ini, kita akan memperkenalkan alternatif bagi subgradien (eksplisit) dalam optimisasi.

Perhatikan masalah tak berkendala

$$(5.1) \quad \min_x f(x),$$

dengan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, semikontinu bawah, dan konveks. Ingat pembaruan metode subgradien $x_{k+1} = x_k - \tau_k g_k$, $g_k \in \partial f(x_k)$, atau, secara ekuivalen, $x_{k+1} \in x_k - \tau_k \partial f(x_k)$. Untuk $\tau_k > 0$, kita usulkan pembaruan implisit

$$(5.2) \quad x_{k+1} \in x_k - \tau_k \partial f(x_{k+1}).$$

Pada tahap ini belum jelas apakah metode tersebut terdefinisi dengan baik. Namun, jika memang terdefinisi, secara intuitif kestabilannya dapat membaik karena arah pembaruan dipilih dengan *melihat ke masa depan*. Gagasan ini selaras dengan kestabilan metode implisit untuk mendiskretkan persamaan diferensial (*bandingkan Euler implisit*).

Jika kita amati (5.2) lebih dekat, aturan itu dapat ditulis sebagai

$$(5.3) \quad 0 \in \partial \left(\frac{1}{2} \|\cdot - x_k\|^2 + \tau_k f \right) (x_{k+1}),$$

yang merupakan kondisi optimalitas untuk

$$(5.4) \quad \min_x \frac{1}{2} \|x - x_k\|^2 + \tau_k f(x).$$

Hal ini membawa kita pada definisi berikut.

Definisi 5.1 (Operator proksimal). Operator atau pemetaan proksimal dari $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ didefinisikan sebagai pemetaan

$$(5.5) \quad \begin{aligned} \text{prox}_f : \mathbb{R}^d &\rightarrow 2^{\mathbb{R}^d}, \\ x &\mapsto \arg \min_{y \in \mathbb{R}^d} \frac{1}{2} \|y - x\|^2 + f(y). \end{aligned}$$

Kita biasanya menyebut prox_f sebagai ‘proks’. Sebagai pemetaan bernilai himpunan, proks selalu dapat dituliskan; tetapi pemetaan itu baru berguna ketika $\text{prox}_f(x) \neq \emptyset$. Kita dapat membuktikan hasil berikut.

Lema 5.2. *Misalkan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, konveks, dan semikontinu bawah. Pemetaan proksimal bernilai tunggal. Lebih lanjut, $y = \text{prox}_f(x)$ jika dan hanya jika $0 \in (y-x) + \partial f(y)$.*

Catatan. Berdasarkan karakterisasi $0 \in (y-x) + \partial f(y)$, kita sering menulis proks sebagai $\text{prox}_f(x) = (\text{Id} + \partial f)^{-1}(x)$.

Bukti. Demi kesederhanaan, andaikan $\text{dom}(f)^\circ \neq \emptyset$; untuk kasus umum, lihat [Beck 2017].

Ambil $g \in \partial f(y_0)$ untuk suatu $y_0 \in \text{dom}(f)^\circ$. Kita mempunyai

$$(5.6) \quad f(y_0) + \langle g, y - y_0 \rangle + \frac{1}{2}\|x - y\|^2 \leq f(y) + \frac{1}{2}\|x - y\|^2.$$

Oleh karena itu (mengapa?), pemetaan $y \mapsto f(y) + \frac{1}{2}\|x - y\|^2$ bersifat koersif. Pemetaan ini juga mewarisi sifat semikontinu bawah dan proper dari f . Dengan metode langsung untuk fungsi proper, semikontinu bawah, dan koersif di ruang berdimensi hingga, terdapat solusi bagi

$$(5.7) \quad \min_{y \in \mathbb{R}^d} \frac{1}{2}\|y - x\|^2 + f(y).$$

Untuk keunikan, definisikan $q_x(y) = \frac{1}{2}\|y - x\|^2 + f(y)$ dan andaikan $y_1 \neq y_2$ adalah dua peminim. Karena suku kuadrat konveks ketat dan f konveks, untuk $\bar{y} = (y_1 + y_2)/2$ berlaku

$$(5.8) \quad \begin{aligned} q_x(\bar{y}) &< \frac{1}{2}(q_x(y_1) + q_x(y_2)) \\ &= \min_{y \in \mathbb{R}^d} q_x(y), \end{aligned}$$

sebuah kontradiksi. Pernyataan terakhir merupakan kondisi optimalitas bagi (5.7). $\square$

Setelah mengetahui bahwa proks terdefinisi dengan baik, kita dapat mendefinisikan metode gradien proksimal. Secara khusus, perhatikan masalah

$$(5.9) \quad \min_{x \in \mathbb{R}^d} F(x) := f(x) + g(x),$$

dengan f konveks dan L -halus, yakni terdiferensialkan dengan gradien L -Lipschitz, sedangkan g proper, konveks, dan semikontinu bawah. Masalah semacam ini sering muncul dalam praktik dan mencakup masalah semula dengan mengambil $f \equiv 0$. Untuk $k = 0, 1, \dots$, metode gradien proksimal didefinisikan oleh

$$(5.10) \quad x_{k+1} = \text{prox}_{\tau_k g}(x_k - \tau_k \nabla f(x_k)).$$

Jadi, kita melakukan langkah gradien atau eksplisit terhadap f , lalu langkah proksimal atau implisit terhadap g .

Sebagai hasil sederhana pertama, kita menunjukkan bahwa titik tetap metode gradien proksimal tepat sama dengan titik optimal.

Lema 5.3. Untuk suatu $\tau > 0$ yang tetap dan $x \in \mathbb{R}^d$, pernyataan berikut ekuivalen:

$$(5.11) \quad x = \text{prox}_{\tau g}(x - \tau \nabla f(x)) \iff 0 \in \partial(f + g)(x).$$

Dengan demikian, x adalah titik tetap jika dan hanya jika x menyelesaikan (5.9).

Bukti. Karakterisasi optimalitas proks memberikan ekuivalensi

$$(5.12) \quad x = \text{prox}_{\tau g}(x - \tau \nabla f(x)) \iff 0 \in \tau \nabla f(x) + \tau \partial g(x).$$

Karena $\tau > 0$, serta menurut aturan jumlah dan aturan skala untuk subdiferensial,

$$(5.13) \quad 0 \in \tau(\nabla f(x) + \partial g(x)) \iff 0 \in \partial(f + g)(x).$$

Untuk fungsi konveks $F = f + g$, kondisi terakhir ekuivalen dengan optimalitas x . $\square$

Selain proks, kita mendefinisikan selubung Moreau sebagai nilai infimum dari objektif yang digunakan untuk proks.

Definisi 5.4 (Selubung Moreau). Misalkan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ dan $\tau > 0$. Selubung Moreau $M_f^\tau : \mathbb{R}^d \rightarrow [-\infty, \infty]$ didefinisikan oleh

$$(5.14) \quad M_f^\tau(x) := \inf_{y \in \mathbb{R}^d} \frac{1}{2\tau} \|x - y\|^2 + f(y).$$

Lema 5.5. Misalkan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, konveks, dan semikontinu bawah, serta $\tau > 0$. Selubung Moreau selalu bernilai real (yakni berhingga), dan

$$(5.15) \quad M_f^\tau(x) = \frac{1}{2\tau} \|x - \text{prox}_{\tau f}(x)\|^2 + f(\text{prox}_{\tau f}(x)).$$

Bukti. Latihan. Terapkan lemma keberadaan dan keunikan proks pada τf , lalu substitusikan peminim unik tersebut ke dalam definisi infimum. $\square$

Contoh 5.6. Kita tinjau beberapa contoh pemetaan proksimal dan selubung Moreau yang sering muncul:

- (i) Misalkan $C \subset \mathbb{R}^d$ tak kosong, tertutup, dan konveks, dan perhatikan fungsi indikator δ_C . Maka

$$(5.16) \quad \text{prox}_{\tau \delta_C}(x) = \text{proj}_C(x), \quad M_{\delta_C}^\tau(x) = \frac{1}{2\tau} \text{dist}(x, C)^2.$$

(ii) Secara khusus, jika $C = \{x \in \mathbb{R}^d \mid \|x\|_\infty \leq 1\}$, maka

$$(5.17) \quad (\text{prox}_{\tau\delta_C}(x))_i = \frac{x_i}{\max\{1, |x_i|\}}.$$

(iii) Jika $f(x) = \|x\|_1$, pemetaan proksimalnya adalah operator *ambang lunak*

$$(5.18) \quad (\text{prox}_{\tau f}(x))_i = \begin{cases} x_i - \tau & x_i > \tau, \\ x_i + \tau & x_i < -\tau, \\ 0 & x_i \in [-\tau, \tau]. \end{cases}$$

Untuk $d = 1$, selubung Moreau-nya tepat merupakan fungsi Huber

$$(5.19) \quad M_{|\cdot|}^\tau(x) = \begin{cases} \frac{|x|^2}{2\tau} & |x| \leq \tau, \\ |x| - \frac{\tau}{2} & |x| > \tau. \end{cases}$$

Lema 5.7 (Aturan komputasi untuk proks). Misalkan semua fungsi dasar yang muncul di bawah proper, semikontinu bawah, dan konveks pada domain berdimensi hingga yang dinyatakan. Aturan berikut berlaku:

- (i) Jika $x = (x_1, \dots, x_m) \in \mathbb{R}^{d_1} \times \dots \times \mathbb{R}^{d_m} \cong \mathbb{R}^d$, $x_i \in \mathbb{R}^{d_i}$, $\sum_i d_i = d$, dan $f(x) = \sum_i f_i(x_i)$, maka $\text{prox}_f(x) = (\text{prox}_{f_i}(x_i))_i$.
- (ii) Jika $f(x) = \alpha g(x) + b$ dengan $\alpha > 0$ dan $b \in \mathbb{R}$, maka $\text{prox}_f = \text{prox}_{\alpha g}$.
- (iii) Jika $f(x) = g(\alpha x + b)$ dengan $\alpha \neq 0$ dan $b \in \mathbb{R}^d$, maka $\text{prox}_f(x) = \alpha^{-1}(\text{prox}_{\alpha^2 g}(\alpha x + b) - b)$.
- (iv) Jika $f(x) = g(Qx)$ dengan $Q \in \mathbb{R}^{d \times d}$ ortogonal, maka $\text{prox}_f(x) = Q^\top \text{prox}_g(Qx)$.
- (v) Jika $f(x) = g(x) + \langle a, x \rangle + b$ dengan $a \in \mathbb{R}^d$ dan $b \in \mathbb{R}$, maka $\text{prox}_f(x) = \text{prox}_g(x - a)$.
- (vi) Jika $f(x) = g(x) + \frac{\gamma}{2} \|x - a\|^2$ dengan $a \in \mathbb{R}^d$ dan $\gamma \geq 0$, maka $\text{prox}_f(x) = \text{prox}_{\tilde{\gamma}g}(\tilde{\gamma}x + \gamma \tilde{\gamma}a)$, dengan $\tilde{\gamma} = (1 + \gamma)^{-1}$.

Selubung Moreau memberikan efek penghalusan pada fungsi f , sebagaimana ditunjukkan oleh hasil berikut.

Lema 5.8. Misalkan $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, konveks, dan semikontinu bawah, serta $\tau > 0$. Selubung Moreau bersifat konveks dan terdiferensialkan. Gradiennya $1/\tau$ -Lipschitz dan dapat ditulis sebagai

$$(5.20) \quad \nabla M_f^\tau(x) = \frac{1}{\tau}(x - \text{prox}_{\tau f}(x)).$$

Bukti. Untuk $q(x, y) = \frac{1}{2\tau}\|x - y\|^2 + f(y)$, fungsi q konveks secara bersama pada (x, y) . Jika $p_i = \text{prox}_{\tau f}(x_i)$ dan $t \in [0, 1]$, evaluasi q di $(tx_1 + (1-t)x_2, tp_1 + (1-t)p_2)$ menunjukkan bahwa $M_f^\tau(tx_1 + (1-t)x_2) \leq tM_f^\tau(x_1) + (1-t)M_f^\tau(x_2)$. Jadi, argumen ini tetap sah untuk fungsi f bernilai diperluas.

Tetapkan $p(x) = \text{prox}_{\tau f}(x)$. Dari definisi proks,

$$\begin{aligned} M_f^\tau(x+h) &= \frac{1}{2\tau}\|x+h-p(x+h)\|^2 + f(p(x+h)) \\ &\leq \frac{1}{2\tau}\|x+h-p(x)\|^2 + f(p(x)), \\ M_f^\tau(x) &= \frac{1}{2\tau}\|x-p(x)\|^2 + f(p(x)). \end{aligned} \quad (5.21)$$

Dengan mengurangi dua hubungan itu, kita memperoleh

$$\begin{aligned} M_f^\tau(x+h) - M_f^\tau(x) &\leq \frac{1}{2\tau}(\|x+h-p(x)\|^2 - \|x-p(x)\|^2) \\ &= \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle + \frac{1}{2\tau}\|h\|^2. \end{aligned} \quad (5.22)$$

Secara ekuivalen,

$$M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle \leq \frac{1}{2\tau}\|h\|^2. \quad (5.23)$$

Definisikan residu keterdiferensialan

$$r_x(h) := M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle. \quad (5.24)$$

Kurangkan dua kondisi optimalitas proks, lalu gunakan monotonisitas ∂f dan ketaksamaan Cauchy-Schwarz. Hasilnya ialah $\|p(x)-p(y)\| \leq \|x-y\|$, sehingga p tak ekspansif. Dengan mengevaluasi $M_f^\tau(x)$ pada $p(x+h)$, kita juga mendapatkan

$$r_x(h) \geq \left\langle h, \frac{1}{\tau}(p(x) - p(x+h)) \right\rangle + \frac{1}{2\tau}\|h\|^2 \geq -\frac{1}{2\tau}\|h\|^2. \quad (5.25)$$

Secara keseluruhan,

$$\left| M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle \right| \leq \frac{1}{2\tau}\|h\|^2. \quad (5.26)$$

Jadi, $\nabla M_f^\tau(x) = \tau^{-1}(x-p(x))$. Untuk membuktikan kekontinuan Lipschitz gradien, perhatikan bahwa

$$\begin{aligned} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\|^2 &= \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), (x-p(x)) - (y-p(y)) \right\rangle \\ &= \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), x-y \right\rangle \\ &\quad - \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), p(x) - p(y) \right\rangle. \end{aligned} \quad (5.27)$$

Kondisi optimalitas memberi $\nabla M_f^\tau(x) = \tau^{-1}(x - p(x)) \in \partial f(p(x))$. Karena itu, hasil kali dalam terakhir tidak negatif menurut monotonisitas subdiferensial, sehingga

$$(5.28) \quad \begin{aligned} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\|^2 &\leq \frac{1}{\tau} \langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), x - y \rangle \\ &\leq \frac{1}{\tau} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\| \|x - y\|. \end{aligned}$$

Setelah membagi dengan norma gradien yang berbeda dari nol (kasus nol langsung), diperoleh sifat $1/\tau$ -Lipschitz. $\square$

Catatan. Dengan representasi gradien selubung Moreau di atas, proks dapat ditulis kembali sebagai

$$(5.29) \quad \text{prox}_{\tau f}(x) = x - \tau \left(\frac{1}{\tau} (x - \text{prox}_{\tau f}(x)) \right) = x - \tau \nabla M_f^\tau(x).$$

Jadi, satu langkah proksimal ekuivalen dengan satu langkah gradien pada selubung Moreau.

Contoh 5.9. Untuk fungsi indikator himpunan tak kosong, tertutup, dan konveks C , rumusnya adalah $\text{prox}_{\tau \delta_C}(x) = \text{proj}_C(x)$. Untuk $f(x) = \|x\|_1$, setiap koordinat diberikan oleh ambang lunak $(\text{prox}_{\tau f}(x))_i = \text{sign}(x_i) \max\{|x_i| - \tau, 0\}$, dengan $\text{sign}(0) = 0$. Untuk $f(x) = \|x\|_2$, penyusutan Euklides adalah $\text{prox}_{\tau f}(x) = (1 - \tau/\|x\|_2)_+ x$ jika $x \neq 0$, dan $\text{prox}_{\tau f}(0) = 0$. Verifikasikan ketiga rumus ini langsung dari kondisi optimalitas proks.

Sekarang kita akan membuktikan konvergensi metode gradien proksimal. Mula-mula kita turunkan lemma penting: untuk fungsi L -halus, galat antara fungsi dan hampiran linearnya dibatasi dari atas oleh suku kuadrat.

Lema 5.10. Misalkan $F : \mathbb{R}^d \rightarrow \mathbb{R}$ terdiferensialkan kontinu dan gradiennya L -Lipschitz. Maka

$$(5.30) \quad F(y) \leq F(x) + \langle \nabla F(x), y - x \rangle + \frac{L}{2} \|y - x\|^2.$$

Bukti. Dari teorema dasar kalkulus dan sifat L -halus, kita mempunyai

$$(5.31) \quad \begin{aligned} F(y) - F(x) &= \int_0^1 \frac{d}{dt} F(x + t(y - x)) dt \\ &= \int_0^1 \langle \nabla F(x + t(y - x)), y - x \rangle dt \\ &= \int_0^1 \langle \nabla F(x + t(y - x)) - \nabla F(x), y - x \rangle dt + \int_0^1 \langle \nabla F(x), y - x \rangle dt \\ &\leq \int_0^1 L t \|y - x\|^2 dt + \langle \nabla F(x), y - x \rangle \\ &= \frac{L}{2} \|y - x\|^2 + \langle \nabla F(x), y - x \rangle. \end{aligned}$$

□

Untuk bukti konvergensi metode gradien proksimal, bagi $\tau > 0$ kita perkenalkan notasi

$$(5.32) \quad T_\tau(x) = \frac{1}{\tau}(x - \text{prox}_{\tau g}(x - \tau \nabla f(x))).$$

Dengan fungsi ini, pembaruan gradien proksimal dapat ditulis sebagai

$$(5.33) \quad x_{k+1} = x_k - \tau_k T_{\tau_k}(x_k).$$

Teorema 5.11. Misalkan $f : \mathbb{R}^d \rightarrow \mathbb{R}$ konveks dan L -halus dengan $L > 0$, serta $g : \mathbb{R}^d \rightarrow (-\infty, \infty]$ proper, semikontinu bawah, dan konveks. Andaikan $\arg \min_x F(x) \neq \emptyset$ dan terdapat $\tau_{\min} > 0$ sedemikian sehingga $0 < \tau_{\min} \leq \tau_k \leq L^{-1}$ untuk semua k . Untuk setiap $x^* \in \arg \min_x F(x)$, algoritma gradien proksimal memenuhi

$$(5.34) \quad F(x_n) - F(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min}n} \quad (n \geq 1).$$

Selain itu, x_k berkonvergensi menuju suatu $\hat{x} \in \arg \min_x F(x)$.

Bukti. Dari definisi T_τ , kita mempunyai

$$(5.35) \quad T_{\tau_k}(x_k) - \nabla f(x_k) \in \partial g(x_k - \tau_k T_{\tau_k}(x_k)) = \partial g(x_{k+1}).$$

Dengan memakai hubungan ini, kekonveksan f , Lemma 5.10, dan $\tau_k \leq L^{-1}$, untuk setiap $z \in \mathbb{R}^d$ diperoleh

$$(5.36) \quad \begin{aligned} F(x_{k+1}) &\leq f(x_k) - \tau_k \langle \nabla f(x_k), T_{\tau_k}(x_k) \rangle + \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\ &\quad + g(z) - \langle T_{\tau_k}(x_k) - \nabla f(x_k), z - (x_k - \tau_k T_{\tau_k}(x_k)) \rangle \\ &\leq f(z) + g(z) - \langle \nabla f(x_k), z - x_k \rangle - \tau_k \langle \nabla f(x_k), T_{\tau_k}(x_k) \rangle + \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\ &\quad - \langle T_{\tau_k}(x_k) - \nabla f(x_k), z - (x_k - \tau_k T_{\tau_k}(x_k)) \rangle \\ &= F(z) - \langle T_{\tau_k}(x_k), z - x_k \rangle - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2. \end{aligned}$$

Dengan mengambil $z = x_k$, kita memperoleh

$$(5.37) \quad F(x_{k+1}) \leq F(x_k) - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2.$$

Jadi, nilai objektif tidak meningkat dan turun ketat kecuali jika $T_{\tau_k}(x_k) = 0$; menurut lemma titik tetap, kasus terakhir berarti x_k optimal. Di sisi lain, ambil $z = x^*$ dan gunakan $T_{\tau_k}(x_k) = \tau_k^{-1}(x_k - x_{k+1})$. Maka

$$(5.38) \quad \begin{aligned} 0 \leq F(x_{k+1}) - F(x^*) &\leq \langle T_{\tau_k}(x_k), x_k - x^* \rangle - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\ &= \frac{1}{2\tau_k} (2 \langle x_k - x_{k+1}, x_k - x^* \rangle - \|x_k - x_{k+1}\|^2) \\ &= \frac{1}{2\tau_k} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2). \end{aligned}$$

Khususnya, $\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \geq 0$, sehingga jarak ke setiap peminim tidak meningkat. Dengan menjumlahkan untuk $k = 0, \dots, n-1$, kita memperoleh

$$\begin{aligned}
 \sum_{k=0}^{n-1} (F(x_{k+1}) - F(x^*)) &\leq \sum_{k=0}^{n-1} \frac{1}{2\tau_k} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2) \\
 (5.39) \qquad \qquad \qquad &\leq \frac{1}{2\tau_{\min}} \sum_{k=0}^{n-1} (\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2) \\
 &= \frac{1}{2\tau_{\min}} (\|x_0 - x^*\|^2 - \|x_n - x^*\|^2).
 \end{aligned}$$

Karena $F(x_k) - F(x^*)$ juga tidak meningkat,

$$(5.40) \qquad n(F(x_n) - F(x^*)) \leq \sum_{k=0}^{n-1} (F(x_{k+1}) - F(x^*)) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min}}.$$

Jadi,

$$(5.41) \qquad F(x_n) - F(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min} n}.$$

Terakhir, kita buktikan konvergensi $(x_k)_k$. Perhitungan di atas menunjukkan bahwa $\|x_k - x^*\|$ tidak meningkat untuk setiap peminim x^* . Dengan demikian, $(x_k)_k$ terbatas dan, di ruang berdimensi hingga, mempunyai subbarisan konvergen. Misalkan $\hat{x} = \lim_j x_{n(j)}$ adalah suatu titik akumulasi. Karena $F(x_k) \rightarrow \min F$ dan $F = f + g$ semikontinu bawah,

$$F(\hat{x}) \leq \liminf_j F(x_{n(j)}) = \lim_k F(x_k) = \min F.$$

Jadi, $\hat{x}$ adalah peminim dan $\|x_k - \hat{x}\|$ tidak meningkat. Karena itu, terdapat $c \geq 0$ dengan $\|x_k - \hat{x}\| \rightarrow c$. Namun,

$$(5.42) \qquad c = \lim_k \|x_k - \hat{x}\| = \lim_j \|x_{n(j)} - \hat{x}\| = 0.$$

Maka seluruh barisan berkonvergensi ke $\hat{x}$, dan bukti selesai. $\square$

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber.

- (i) Laju subgradien pembuka dikualifikasi sebagai laju dasar atau kasus terburuk; fungsi dinyatakan proper, semikontinu bawah, dan konveks, serta ukuran langkah implisit disyaratkan positif sebelum inklusi diubah menjadi kondisi optimalitas.
- (ii) Bukti keunikan proks kini memakai objektif skalar q_x , dua peminim yang berbeda, dan ketaksamaan titik tengah yang benar; sumber mengulang y_1 dan menyamakan nilai skalar dengan sebuah himpunan arg min.
- (iii) Karakterisasi titik tetap memakai satu $\tau > 0$ yang tetap dan membuktikan ekuivalensi dengan $0 \in \partial(f + g)(x)$; pernyataan sumber tidak benar jika ukuran langkah nol diizinkan.
- (iv) Definisi selubung Moreau memakai inf sebelum ketercapaian dibuktikan dan mensyaratkan $\tau > 0$. Kuadrat yang hilang pada jarak proks juga dipulihkan.
- (v) Contoh proyeksi mensyaratkan himpunan tak kosong, dan salah tik x_t pada ambang lunak diperbaiki menjadi x_i .
- (vi) Aturan komputasi proks diberi domain vektor dan skalar yang benar, asumsi yang menjamin proks bernilai tunggal, serta syarat $\gamma \geq 0$.
- (vii) Bukti penghalusan Moreau kini memberi argumen kekonveksan yang sah untuk fungsi bernilai diperluas, memperbaiki ekspansi yang memakai $p(\gamma)$, mendefinisikan residu keterdiferensialan secara konsisten, dan menempatkan subgradien pada $p(x)$.
- (viii) Kemunculan label sumber yang kedua dan duplikat, `proximal:eq:moreau_diff2`, dipetakan ke label unik `proximal:eq:moreau_diff2_bound`; kemunculan pertama dipertahankan.
- (ix) Contoh sumber yang belum selesai, ?Projection, 1 norm, 2 norm?, dilengkapi dengan rumus proyeksi, ambang lunak, dan penyusutan Euklides, termasuk konvensi pada nol.

- (x) Teorema konvergensi kini mensyaratkan $L > 0$, himpunan peminim tak kosong, dan $0 < \tau_{\min} \leq \tau_k \leq 1/L$. Faktor dua pada identitas polarisasi, indeks penjumlahan, batas laju, dan bukti konvergensi ke suatu peminim diperbaiki.
- (xi) Dua rujukan silang yang tidak termuat diganti dengan nama prasyarat yang tepat: metode langsung untuk keberadaan peminim dan argumen infimum parsial untuk kekonveksan. Sitasi Beck tetap memakai bibliografi sumber yang dibekukan.

BIBLIOGRAFI

A. BECK (2017), *First-order methods in optimization*, SIAM.

ATRIBUSI DAN LISENSI

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.