

OPTIMISASI KONVEKS

UNIT 8: PENURUNAN GRADIEN STOKASTIK
EDISI BAHASA INDONESIA

Andreas Habring

Sumber edisi v1: 13 Juli 2026

Terjemahan kerja bahasa Indonesia dari *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1.
Sumber asli dan terjemahan ini dilisensikan CC BY 4.0. Perubahan matematis dijelaskan dalam catatan koreksi.

Terjemahan mandiri ini bukan karya resmi atau dukungan Andreas Habring maupun TU Graz.

TENTANG UNIT INI

Unit ini menerjemahkan secara utuh Bab 8, "Stochastic Gradient Descent", dari Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1. Sumber berwenang untuk unit ini adalah berkas `stochastic.tex` edisi v1 dengan SHA-256 berikut:

610d11b59d8dfabbbbe6fbc509a0f9ac
1727540458c67f8cd3b7bab49566a07d

Bab-bab prasyarat tidak diulang. Pembaca diharapkan telah mengenal fungsi konveks Lipschitz, subgradien, proyeksi metrik pada himpunan konveks tertutup, ekspektasi bersyarat, filtrasi, dan bukti konvergensi metode subgradien terproyeksi. Seluruh motivasi, algoritme, teorema, bukti, dan formula dalam bab sumber dipertahankan dalam urutan sumber. Kekeliruan yang dapat ditentukan secara matematis diperbaiki secara terbuka dan diringkaskan pada akhir unit.

Edisi ini berdiri sendiri untuk dibaca dan dibangun, tetapi tidak mengklaim menggantikan konteks lengkap catatan kuliah asal. Notasi iid dipertahankan sebagai singkatan baku untuk peubah acak yang saling bebas dan berdistribusi identik.

DAFTAR ISI

8	PENURUNAN GRADIEN STOKASTIK	1
---	-----------------------------	---

8 PENURUNAN GRADIEN STOKASTIK

Andaikan kita ingin menyelesaikan

$$(8.1) \quad \min_x f(x),$$

tetapi hanya mempunyai akses ke estimasi acak yang tak bias bagi suatu subgradien f . Artinya, kita mengandaikan dapat mengevaluasi $G(x, z)$ yang memenuhi

$$(8.2) \quad \mathbb{E}[G(x, Z)] \in \partial f(x),$$

dengan Z suatu peubah acak. Ternyata banyak bukti konvergensi dapat dialihkan ke latar stokastik ini dengan hampir tanpa upaya tambahan. Sebelum menunjukkannya, mari kita berikan motivasi untuk latar ini.

Dalam pembelajaran mesin modern, banyak masalah pembelajaran dapat dirumuskan sebagai masalah jumlah hingga. Agar pengambilan sampel seragam menghasilkan estimator gradien yang tak bias, kita memakai normalisasi rerata

$$(8.3) \quad \min_x f(x) := \frac{1}{N} \sum_{i=1}^N f_i(x),$$

dengan N biasanya merupakan banyaknya sampel pelatihan. Sebagai contoh, andaikan kita ingin mempelajari pemetaan berparameter f_θ yang seharusnya menghampiri relasi $x \mapsto y$ berdasarkan data pelatihan $(x_i, y_i)_{i=1}^N$. Masalah pelatihannya dapat berupa

$$(8.4) \quad \min_{\theta} \frac{1}{N} \sum_{i=1}^N \|y_i - f_\theta(x_i)\|^2.$$

Karena ukuran data pelatihan yang dijumpai, sering kali gradien penuh f tidak dapat dihitung secara langsung akibat keterbatasan memori. Jika semua f_i terdiferensialkan, salah satu jalan keluarnya adalah pembaruan stokastik

$$(8.5) \quad \begin{cases} \text{Pilih } i \in \mathcal{I} \text{ secara seragam} \\ x_{k+1} = x_k - \tau \nabla f_i(x_k) \end{cases}$$

dengan $\mathcal{I} = \{1, \dots, N\}$. Dengan mendefinisikan $(Z_k)_k$ sebagai barisan peubah acak iid yang berdistribusi seragam pada $\mathcal{I}$, pembaruan di atas dapat ditulis sebagai

$$(8.6) \quad x_{k+1} = x_k - \tau G(x_k, Z_k)$$

dengan $G(x, z) := \nabla f_z(x)$. Memang, $\mathbb{E}[G(x, Z)] = N^{-1} \sum_{i=1}^N \nabla f_i(x) = \nabla f(x)$, sehingga G memenuhi (8.2).

Teorema 8.1. Misalkan $C \subseteq \mathbb{R}^d$ tak kosong, tertutup, dan konveks, serta misalkan $f : \mathbb{R}^d \rightarrow \mathbb{R}$ konveks dan L -Lipschitz. Andaikan masalah $\min_{x \in C} f(x)$ mempunyai solusi, pilih $x^* \in \arg \min_{x \in C} f(x)$, dan ambil $x_0 \in C$. Untuk $k \geq 0$, misalkan $G_k := G(x_k, Z_k)$ dan jalankan iterasi terproyeksi $x_{k+1} = \text{proj}_C(x_k - \tau_k G_k)$ dengan $\tau_k > 0$.

Tuliskan $\mathcal{F}_k = \sigma(x_0, Z_0, \dots, Z_{k-1})$, sehingga x_k terukur terhadap $\mathcal{F}_k$, dan definisikan $\bar{g}_k := \mathbb{E}[G_k \mid \mathcal{F}_k]$. Andaikan, hampir pasti untuk setiap k ,

$$(8.7) \quad \begin{cases} \bar{g}_k \in \partial f(x_k), \\ \mathbb{E}[\|G_k - \bar{g}_k\|^2 \mid \mathcal{F}_k] \leq \sigma^2 < \infty. \end{cases}$$

Andaikan pula ukuran langkah memenuhi

$$\sum_{k=0}^{K-1} \tau_k \rightarrow \infty, \quad \frac{\sum_{k=0}^{K-1} \tau_k^2}{\sum_{k=0}^{K-1} \tau_k} \rightarrow 0 \quad \text{ketika } K \rightarrow \infty.$$

Untuk $K \geq 1$, definisikan $f_{\text{best}}^K := \min_{0 \leq k \leq K-1} f(x_k)$. Maka $\mathbb{E}[f_{\text{best}}^K - f(x^*)] \rightarrow 0$ ketika $K \rightarrow \infty$.

Bukti. Karena $x^* \in C$, kita mempunyai $\text{proj}_C(x^*) = x^*$. Ketakmembangan proyeksi metrik memberikan

$$(8.8) \quad \begin{aligned} \|x_{k+1} - x^*\|^2 &= \|\text{proj}_C(x_k - \tau_k G_k) - \text{proj}_C(x^*)\|^2 \\ &\leq \|x_k - \tau_k G_k - x^*\|^2 \\ &= \|x_k - x^*\|^2 - 2\tau_k \langle x_k - x^*, G_k \rangle + \tau_k^2 \|G_k\|^2. \end{aligned}$$

Perhatikan bahwa sifat terukur x_k dan ketakbiasan bersyarat memberi

$$(8.9) \quad \begin{aligned} \mathbb{E}[\langle x_k - x^*, G_k \rangle] &= \mathbb{E}[\mathbb{E}[\langle x_k - x^*, G_k \rangle \mid \mathcal{F}_k]] \\ &= \mathbb{E}[\langle x_k - x^*, \bar{g}_k \rangle] \\ &\geq \mathbb{E}[f(x_k) - f(x^*)] \\ &= \mathbb{E}[f(x_k)] - f(x^*), \end{aligned}$$

dengan ketaksamaan subgradien pada baris ketiga. Karena fungsi konveks f bersifat L -Lipschitz pada $\mathbb{R}^d$, setiap subgradiennya mempunyai norma paling besar L . Identitas momen kedua bersyarat kemudian menghasilkan

$$(8.10) \quad \mathbb{E}[\|G_k\|^2 \mid \mathcal{F}_k] = \mathbb{E}[\|G_k - \bar{g}_k\|^2 \mid \mathcal{F}_k] + \|\bar{g}_k\|^2 \leq \sigma^2 + L^2 := M^2.$$

Dengan mengambil ekspektasi pada ketaksamaan pertama, diperoleh

$$(8.11) \quad \mathbb{E}[\|x_{k+1} - x^*\|^2] \leq \mathbb{E}[\|x_k - x^*\|^2] - 2\tau_k(\mathbb{E}[f(x_k)] - f(x^*)) + \tau_k^2 M^2.$$

Selebihnya mengikuti argumen pada kasus deterministik. Menjumlahkan dari $k = 0$ sampai $K-1$, memakai ketaknegatifan suku jarak terakhir, lalu membagi dengan 2 memberikan

$$(8.12) \quad \sum_{k=0}^{K-1} \tau_k (\mathbb{E}[f(x_k)] - f(x^*)) \leq \frac{1}{2} \|x_0 - x^*\|^2 + \frac{M^2}{2} \sum_{k=0}^{K-1} \tau_k^2.$$

Definisikan

$$(8.13) \quad S_K := \sum_{k=0}^{K-1} \tau_k, \quad Q_K := \sum_{k=0}^{K-1} \tau_k^2.$$

Karena $\tau_k > 0$, minimum terbaik tidak melebihi rerata berbobot. Oleh karena itu,

$$(8.14) \quad \begin{aligned} \mathbb{E}[f_{\text{best}}^K - f(x^*)] &\leq \frac{\sum_{k=0}^{K-1} \tau_k \mathbb{E}[f(x_k) - f(x^*)]}{S_K} \\ &\leq \frac{\|x_0 - x^*\|^2}{2S_K} + \frac{M^2 Q_K}{2S_K}. \end{aligned}$$

Berdasarkan kedua syarat ukuran langkah,

$$(8.15) \quad 0 \leq \mathbb{E}[f_{\text{best}}^K - f(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2S_K} + \frac{M^2 Q_K}{2S_K} \longrightarrow 0 \quad (K \rightarrow \infty).$$

□

CATATAN KOREKSI TERHADAP SUMBER

Terjemahan ini mempertahankan isi sumber kecuali pada koreksi yang dapat ditentukan berikut. Koreksi dilakukan oleh penyusun edisi bahasa Indonesia dan bukan perubahan yang disahkan oleh penulis sumber. Rekaman terstruktur dengan identitas peristiwa Oo15-HAB-ADV-0076 sampai Oo15-HAB-ADV-0083 menyertai sumber edisi ini.

- (i) Objektif jumlah hingga dinormalisasi menjadi $N^{-1} \sum_i f_i$. Dengan demikian, pengambilan indeks seragam dan pilihan $G(x, z) = \nabla f_z(x)$ benar-benar memenuhi ketakbiasan yang dinyatakan; pembagian dengan N tidak mengubah himpunan pemimum.
- (ii) Teorema kini menyatakan fungsi konveks Lipschitz, himpunan kendala C yang tak kosong, tertutup, dan konveks, keberadaan solusi $x^* \in C$, titik awal $x_0 \in C$, ukuran langkah positif, serta iterasi SGD terproyeksi yang memang dipakai dalam bukti.
- (iii) Ketakbiasan dan batas varians dirumuskan secara bersyarat terhadap filtrasi sebelum sampel ke- k . Hal ini menutup kesenjangan antara asumsi satu peubah acak tetap dan pembuktian pada iterasi adaptif.
- (iv) Besaran f_{best}^K didefinisikan sebagai nilai terbaik di antara iterasi 0 sampai $K - 1$, dan seluruh penghitung pada pernyataan serta bukti dibuat konsisten dengan K .
- (v) Identitas momen kedua memakai gradien rata-rata bersyarat $\bar{g}_k$ dan menghasilkan batas $M^2 = \sigma^2 + L^2$ dari varians bersyarat serta sifat Lipschitz, bukan dengan mengurangi norma ekspektasi tak bersyarat pada titik acak.
- (vi) Setelah relasi satu langkah dibagi dua, faktor $1/2$ yang hilang pada suku $M^2 \sum_k \tau_k^2$ dalam sumber dipulihkan.
- (vii) Definisi dan manipulasi σ_n yang tidak konsisten diganti dengan $S_K = \sum_k \tau_k$ dan $Q_K = \sum_k \tau_k^2$. Syarat konvergensi yang benar dinyatakan sebagai $S_K \rightarrow \infty$ dan $Q_K/S_K \rightarrow 0$, lalu diterapkan langsung pada batas galat.
- (viii) Salah ketik prosa, makro ekspektasi E yang hilang garis miring, dan pemisah penjaran yang salah tempat pada inklusi subgradien dinormalkan tanpa mengubah isi lain.

ATRIBUSI, LISENSI, DAN NONDUKUNGAN

Karya sumber: Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, 13 Juli 2026, <https://arxiv.org/abs/2607.11664v1>. Karya sumber tersedia berdasarkan Creative Commons Attribution 4.0 International (CC BY 4.0), <https://creativecommons.org/licenses/by/4.0/>.

Edisi bahasa Indonesia ini merupakan karya turunan. Hak cipta materi sumber tetap pada pemegang haknya. Anda boleh membagikan dan mengadaptasinya dengan atribusi yang sesuai, tautan lisensi, dan penandaan perubahan sebagaimana disyaratkan CC BY 4.0.

Andreas Habring dan TU Graz tidak menyusun, memeriksa, menyetujui, atau mendukung terjemahan ini. Penyebutan nama mereka semata-mata untuk atribusi karya sumber.