

# Optimisasi Lanjut dan Analisis Konveks

Andreas Habring; Stephen Becker; Mitchell Krock  
dengan lapisan penghubung dan asesmen mandiri

Edisi Bahasa Indonesia (id-ID), 26 Agustus 2026

# Tentang edisi ini

Buku ini adalah edisi Bahasa Indonesia mandiri untuk belajar optimisasi lanjut dan analisis konveks. Tulang punggung terstruktur menerjemahkan lengkap catatan Andreas Habring, arXiv:2607.11664v1, berdasarkan CC BY 4.0. Tiga suplemen terbatas dari catatan Stephen Becker yang diketik Mitchell Krock digunakan berdasarkan Lisensi MIT. Bab penghubung, asesmen, solusi, laboratorium, dan proyek yang ditulis khusus untuk edisi ini tersedia berdasarkan CC BY-SA 4.0. Hak setiap komponen tetap terpisah; tidak ada klaim lisensi payung.

Edisi ini bukan karya resmi atau dukungan Habring, Becker, Krock, institusi mereka, maupun penyedia sumber pendamping. Materi MIT OpenCourseWare, Clément Royer, dan Penn State dipertahankan sebagai pembaca pendamping terpisah dan tidak disisipkan diam-diam ke dalam buku kanonis ini. Materi O018 tentang program linear atau bilangan bulat, simpleks, sensitivitas LP, dan optimisasi jaringan berada di luar cakupan.

Produksi edisi dan pemeriksaan deterministik menggunakan OpenAI Codex gpt-5.6-sol, Ultra. Kredit penarang sumber dan kontribusi manusia tetap dipertahankan. Perubahan substantif dan koreksi didokumentasikan dalam berkas provenans edisi.

PDF ini menyediakan teks yang dapat dicari, bahasa dokumen id-ID, markah, bookmark, tautan, dan pohon struktur berurutan. Karena validator PDF/UA yang dipatok tidak tersedia pada toolchain produksi, edisi ini tidak mengklaim kesesuaian PDF/UA. HTML dan EPUB 3 menyediakan permukaan reflow utama.

# Deskripsi gambar raster

Enam gambar raster dari tulang punggung mempunyai keterangan dan uraian sekitar. Secara ringkas: *sets.png* membandingkan contoh himpunan konveks dan tak konveks; *balls.png* membandingkan bola satuan beberapa norma; *convex\_fct.png* menunjukkan grafik fungsi konveks dan garis tali busurnya; *gradient.png* menunjukkan gradien sebagai penyangga lokal; *subgradient.png* menunjukkan keluarga subgradien pada titik tak mulus; *discontinuous\_function.png* dan *lsc\_function.png* membandingkan fungsi diskontinu dengan fungsi semikontinu bawah. Gambar TikZ dan grafik komputasi dijelaskan oleh keterangan serta teks yang langsung mendahului atau mengikutinya.

# Daftar Isi

|                                                                 |           |
|-----------------------------------------------------------------|-----------|
| Tentang edisi ini                                               | i         |
| Deskripsi gambar raster                                         | ii        |
| <b>I Tulang Punggung: Optimisasi Konveks</b>                    | <b>1</b>  |
| <b>1 Prasyarat</b>                                              | <b>3</b>  |
| 1.1 Ruang vektor, norma, dan hasil kali dalam                   | 3         |
| 1.2 Barisan dan topologi dasar                                  | 6         |
| 1.3 Fungsi                                                      | 7         |
| <b>2 Kekonveksan</b>                                            | <b>12</b> |
| 2.1 Himpunan konveks                                            | 12        |
| 2.2 Fungsi konveks                                              | 15        |
| <b>3 Subgradien</b>                                             | <b>24</b> |
| <b>4 Penurunan subgradien terproyeksi</b>                       | <b>30</b> |
| <b>5 Metode gradien proksimal</b>                               | <b>35</b> |
| <b>6 Akselerasi</b>                                             | <b>41</b> |
| 6.1 Metode bola berat Polyak                                    | 41        |
| 6.2 Akselerasi Nesterov                                         | 45        |
| <b>7 Dualitas</b>                                               | <b>48</b> |
| 7.1 Dualitas Fenchel                                            | 48        |
| 7.2 Optimisasi primal–dual                                      | 52        |
| 7.3 Metode pengali arah bergantian (ADMM)                       | 54        |
| <b>8 Penurunan Gradien Stokastik</b>                            | <b>58</b> |
| <b>9 Selingan tentang Transportasi Optimal</b>                  | <b>60</b> |
| 9.1 Transportasi optimal Monge dan Kantorovich                  | 60        |
| 9.2 Dualitas Kantorovich                                        | 62        |
| 9.3 Diskretisasi transportasi optimal: Algoritme Sinkhorn–Knopp | 63        |
| <b>II Suplemen Terbatas: Dualitas dan Reduksi Varians</b>       | <b>65</b> |
| <b>10 Dualitas Lagrange, kondisi Slater, dan kondisi KKT</b>    | <b>66</b> |
| 10.1 Masalah primal dan Lagrangian                              | 66        |
| 10.2 Kondisi Slater dan dualitas kuat                           | 67        |
| 10.3 Interpretasi titik pelana                                  | 68        |
| 10.4 Kondisi Karush–Kuhn–Tucker                                 | 68        |

|                                                                              |               |
|------------------------------------------------------------------------------|---------------|
| <b>11 Reduksi Varians untuk SAA</b>                                          | <b>70</b>     |
| 11.1 Tabel gradien dan penaksir SAGA . . . . .                               | 70            |
| 11.2 Mengapa koreksi tabel mengurangi varians . . . . .                      | 70            |
| 11.3 Laju konvergensi dan iterat rata-rata . . . . .                         | 71            |
| 11.4 Latihan dengan petunjuk dan solusi . . . . .                            | 72            |
| <br><b>III Metode Stokastik Komposit</b>                                     | <br><b>73</b> |
| <b>12 Metode Stokastik Komposit, Cermin, dan Minibatch</b>                   | <b>74</b>     |
| 12.1 Masalah komposit dan oracle stokastik . . . . .                         | 74            |
| 12.2 Gradien proksimal stokastik . . . . .                                   | 74            |
| 12.3 Minibatch: identitas varians dan biaya oracle . . . . .                 | 75            |
| 12.4 Penurunan cermin stokastik . . . . .                                    | 76            |
| 12.5 Dari SAGA ke pembaruan proksimal . . . . .                              | 78            |
| 12.6 Laboratorium 1: regresi renggang dengan biaya oracle tetap . . . . .    | 78            |
| 12.7 Latihan, petunjuk, dan solusi lengkap . . . . .                         | 79            |
| 12.8 Peta asumsi dan batas klaim . . . . .                                   | 81            |
| <br><b>IV Suplemen Terbatas: Douglas–Rachford</b>                            | <br><b>82</b> |
| <b>13 Pemisahan Douglas–Rachford</b>                                         | <b>83</b>     |
| 13.1 Limit bayangan dan persamaan titik tetap . . . . .                      | 83            |
| 13.2 Hubungan dengan ADMM . . . . .                                          | 84            |
| <br><b>V Operator Monoton dan Pemisahan</b>                                  | <br><b>85</b> |
| <b>14 Ketaksamaan Variasional, Operator Monoton, Resolven, dan Pemisahan</b> | <b>86</b>     |
| 14.1 Kemonotonan dan kemaksimalan . . . . .                                  | 86            |
| 14.2 Ketaksamaan variasional sebagai inklusi monoton . . . . .               | 87            |
| 14.3 Resolven operator monoton maksimal . . . . .                            | 88            |
| 14.4 Metode titik proksimal . . . . .                                        | 88            |
| 14.5 Pemisahan maju–mundur . . . . .                                         | 89            |
| 14.6 Pemisahan Douglas–Rachford dan limit bayangan . . . . .                 | 90            |
| 14.7 Mengapa kemonotonan saja tidak cukup untuk langkah maju . . . . .       | 91            |
| 14.8 Latihan, petunjuk, dan solusi lengkap . . . . .                         | 92            |
| 14.9 Peta asumsi dan batas klaim . . . . .                                   | 93            |
| <br><b>VI Asesmen dan Penutupan Kursus</b>                                   | <br><b>94</b> |
| <b>15 Asesmen, Laboratorium, dan Proyek Penutup</b>                          | <b>95</b>     |
| 15.1 Peta asesmen dan kontrak topologi . . . . .                             | 95            |
| 15.2 Diagnostik prasyarat . . . . .                                          | 98            |
| 15.3 Set soal I: dasar konveks . . . . .                                     | 101           |
| 15.4 Set soal II: metode proksimal . . . . .                                 | 104           |
| 15.5 Set soal III: dualitas dan kondisi KKT . . . . .                        | 107           |
| 15.6 Set soal IV: metode stokastik . . . . .                                 | 110           |
| 15.7 Set soal V: operator monoton dan metode pemisahan . . . . .             | 113           |
| 15.8 Set soal VI: transportasi optimal dan sintesis . . . . .                | 116           |
| 15.9 Rubrik analitik untuk pembuktian . . . . .                              | 119           |
| 15.10 Ujian tengah kumulatif . . . . .                                       | 121           |
| 15.11 Ujian akhir kumulatif . . . . .                                        | 124           |
| 15.12 Laboratorium 3: kegagalan lokal dan globalisasi Newton . . . . .       | 130           |

---

|                  |                                                                           |            |
|------------------|---------------------------------------------------------------------------|------------|
| 15.13            | Laboratorium 4: Sinkhorn log-domain dan sertifikat transportasi . . . . . | 131        |
| 15.14            | Proyek kapstone: masalah invers komposit yang tahan pencilan . . . . .    | 133        |
| <b>Referensi</b> |                                                                           | <b>135</b> |

## **Bagian I**

# **Tulang Punggung: Optimisasi Konveks**

# Prakata

Catatan ini dibangun di atas slide kuliah yang disusun oleh Prof. Thomas Pock. Naskah ini belum merupakan versi final dan mungkin masih memuat salah ketik atau kesalahan, serta kekurangan *teks penghubung* di antara hasil-hasilnya. Catatan ini terutama berfungsi sebagai kumpulan materi untuk kuliah terkait yang saya ampu pada semester musim panas 2026 di Graz University of Technology.

Saya berterima kasih kepada Prof. Christian Clason atas templat  $\text{\LaTeX}$  yang indah ini.

# Bab 1

## Prasyarat

### 1.1 Ruang vektor, norma, dan hasil kali dalam

**Definisi 1.1** (Ruang vektor). Ruang vektor atas suatu medan  $\mathbb{F}$  adalah himpunan  $V$  yang dilengkapi dengan dua operasi  $+$  :  $V \times V \rightarrow V$ ,  $(u, v) \mapsto u + v$ , dan  $\cdot$  :  $\mathbb{F} \times V \rightarrow V$ ,  $(\lambda, v) \mapsto \lambda \cdot v$ , sedemikian sehingga

(i)  $(V, +)$  merupakan grup Abel; yaitu, untuk setiap  $u, v, w \in V$  berlaku:

(i) Asosiativitas:  $(u + v) + w = u + (v + w)$ .

(ii) Unsur netral: terdapat  $e \in V$  sehingga  $v + e = e + v = v$ . Kita menuliskan  $e = 0$ .

(iii) Unsur invers: terdapat  $\tilde{v} \in V$  sehingga  $v + \tilde{v} = 0$ . Kita menuliskan  $\tilde{v} = -v$ .

(iv) Komutativitas:  $v + w = w + v$ .

(ii) Hukum-hukum skalar berikut berlaku untuk setiap  $u, v \in V$  dan  $\lambda, \mu \in \mathbb{F}$ :

(i)  $\lambda \cdot (\mu \cdot v) = (\lambda\mu) \cdot v$ .

(ii)  $\lambda \cdot (u + v) = (\lambda \cdot u) + (\lambda \cdot v)$ .

(iii)  $(\lambda + \mu) \cdot v = (\lambda \cdot v) + (\mu \cdot v)$ .

(iv)  $1 \cdot v = v$ .

Kita menuliskan  $\lambda \cdot v = \lambda v$ .

Mulai sekarang kita membatasi pembahasan pada  $\mathbb{F} = \mathbb{R}$ .

**Contoh 1.2** (Ruang-ruang vektor penting). (i)  $\mathbb{R}^d$ : ruang vektor yang terdiri atas vektor berbentuk

$$v = \begin{pmatrix} v_1 \\ \vdots \\ v_d \end{pmatrix}, \quad (1.1)$$

dengan  $v_i \in \mathbb{R}$ , penjumlahan dilakukan komponen demi komponen, dan perkalian skalar diterapkan pada setiap komponen. Suatu hasil matematika penting menyatakan bahwa setiap ruang vektor berdimensi hingga dapat diidentifikasi dengan  $\mathbb{R}^d$ , dengan  $d$  dimensinya. Karena itu, ketika bekerja dengan ruang berdimensi hingga, kita biasanya dapat membayangkan  $\mathbb{R}^d$ .

(ii) Ruang fungsi: misalkan  $\Omega \subset \mathbb{R}^d$  dan  $f, g : \Omega \rightarrow \mathbb{R}$ . Kita dapat mendefinisikan  $f + g$  serta, untuk  $\lambda \in \mathbb{R}$ ,  $\lambda f$  secara titik demi titik melalui

$$(f + g)(x) = f(x) + g(x), \quad (1.2)$$

$$(\lambda f)(x) = \lambda f(x). \quad (1.3)$$

Dengan cara ini kita dapat membentuk berbagai ruang fungsi. Salah satu contohnya ialah ruang fungsi linear. Mengapa ini benar-benar merupakan ruang vektor yang terdefinisi dengan baik?

**Definisi 1.3** (Norma). Norma adalah fungsi  $\| \cdot \| : V \rightarrow [0, \infty)$  sedemikian sehingga, untuk setiap  $\lambda \in \mathbb{R}$  dan  $u, v \in V$ , berlaku

- (i) Ketegasan positif:  $\|v\| = 0$  jika dan hanya jika  $v = 0$ .
- (ii) Homogenitas:  $\|\lambda u\| = |\lambda| \|u\|$ .
- (iii) Ketaksamaan segitiga:  $\|u + v\| \leq \|u\| + \|v\|$ .

Pasangan  $(V, \| \cdot \|)$  disebut ruang bernorma.

**Catatan.** Berdasarkan kodomainnya, norma selalu tak negatif.

Mulai sekarang semua ruang vektor dianggap bernorma. Jika tidak menimbulkan ambiguitas, kita cukup menuliskan normanya sebagai  $\| \cdot \|$ . Untuk menyatakan norma tertentu kita menggunakan, misalnya,  $\| \cdot \|_\star$ , dengan  $\star$  suatu simbol yang menandai norma tersebut; *bandingkan teorema 1.4*.

**Contoh 1.4** (Norma-norma umum). (i) Norma  $\ell^p$ : untuk  $p \in [1, \infty)$  kita menuliskan

$$\|v\|_p = \left( \sum_{i=1}^d |v_i|^p \right)^{1/p}. \quad (1.4)$$

Untuk  $p = \infty$  kita menuliskan

$$\|v\|_\infty = \max_{i=1, \dots, d} |v_i|. \quad (1.5)$$

- (ii) Tinjau ruang matriks  $n \times m$ , yaitu  $\mathbb{R}^{n \times m}$ . Setiap matriks  $A \in \mathbb{R}^{n \times m}$  dapat diidentifikasi dengan fungsi linear melalui

$$(Av)_i = \sum_{j=1}^m A_{i,j} v_j, \quad i = 1, \dots, n. \quad (1.6)$$

Norma-norma berikut sering digunakan pada  $\mathbb{R}^{n \times m}$ :

- Norma Frobenius:  $\|A\|_F = \sqrt{\sum_{i,j} |A_{i,j}|^2}$ .
- Norma terinduksi: untuk setiap pasangan norma  $\| \cdot \|_a$  pada  $\mathbb{R}^m$  dan  $\| \cdot \|_b$  pada  $\mathbb{R}^n$ , kita mendefinisikan

$$\|A\|_{a,b} := \sup_{\|v\|_a \leq 1} \|Av\|_b = \sup_{v \neq 0} \frac{\|Av\|_b}{\|v\|_a}. \quad (1.7)$$

Norma terinduksi memenuhi  $\|Av\|_b \leq \|A\|_{a,b} \|v\|_a$ . Jika  $a = b$ , kita menuliskan  $\| \cdot \|_{a,a} = \| \cdot \|_a$ . Secara khusus,

$$\|A\|_1 = \max_j \sum_i |A_{i,j}|, \quad (1.8)$$

$$\|A\|_\infty = \max_i \sum_j |A_{i,j}|, \quad (1.9)$$

$$\|A\|_2 = \sqrt{\lambda_{\max}(A^\top A)}. \quad (1.10)$$

Di sini  $\lambda_{\max}$  menyatakan nilai eigen terbesar.

- (iii) Untuk fungsi terukur Lebesgue  $f : \Omega \rightarrow \mathbb{R}$ , dengan  $\Omega \subset \mathbb{R}^d$  terukur, kita dapat mendefinisikan norma  $L^p$  melalui

$$\|f\|_p = \left( \int_{\Omega} |f(x)|^p dx \right)^{1/p}, \quad 1 \leq p < \infty, \quad (1.11)$$

dan<sup>1</sup>

$$\|f\|_\infty = \operatorname{ess\,sup}_{x \in \Omega} |f(x)|. \quad (1.12)$$

Dengan mengidentifikasi fungsi-fungsi yang sama hampir di mana-mana,  $\| \cdot \|_p$  mendefinisikan norma pada ruang vektor

$$L^p(\Omega) = \{f : \Omega \rightarrow \mathbb{R} \mid f \text{ terukur dan } \|f\|_p < \infty\} / \sim_{\text{a.e.}}. \quad (1.13)$$

<sup>1</sup>Secara tepat, fungsi-fungsi diidentifikasi apabila sama hampir di mana-mana. Norma  $L^\infty$  adalah supremum esensial,  $\|f\|_\infty = \inf_{N \subset \Omega} \sup_{x \in \Omega \setminus N} |f(x)|$ . Rincian teori ukuran ini tidak diperlukan dalam kuliah ini.

**Teorema 1.5** (Ekuivalensi norma). *Semua norma pada  $\mathbb{R}^d$  ekuivalen. Artinya, untuk setiap dua norma  $\|\cdot\|_a$  dan  $\|\cdot\|_b$ , terdapat  $m, M > 0$  sedemikian sehingga untuk setiap  $v \in \mathbb{R}^d$  berlaku*

$$m\|v\|_a \leq \|v\|_b \leq M\|v\|_a. \quad (1.14)$$

**Definisi 1.6** (Hasil kali dalam). Pemetaan  $\langle \cdot, \cdot \rangle : V \times V \rightarrow \mathbb{R}$  disebut hasil kali skalar atau hasil kali dalam jika, untuk setiap  $u, v, w \in V$  dan skalar yang relevan, berlaku

- (i) Bilinearitas: pemetaan  $w \mapsto \langle w, u \rangle$  dan  $w \mapsto \langle u, w \rangle$  bersifat linear.
- (ii) Ketegasan positif:  $\langle u, u \rangle \geq 0$ , dan kesamaan berlaku jika dan hanya jika  $u = 0$ .
- (iii) Simetri:  $\langle u, v \rangle = \langle v, u \rangle$ .

Setiap hasil kali dalam mendefinisikan norma melalui  $\|v\| := \sqrt{\langle v, v \rangle}$ . Dalam hal ini,  $V$  disebut ruang hasil kali dalam.

**Korolari 1.7** (Cauchy–Schwarz). *Pada setiap ruang hasil kali dalam  $V$  berlaku*

$$\langle v, w \rangle \leq |\langle v, w \rangle| \leq \|v\| \|w\|, \quad v, w \in V, \quad (1.15)$$

dan ketaksamaan kedua bersifat ketat apabila  $v$  dan  $w$  tidak kolinear.

*Bukti.* Kita boleh mengandaikan  $v, w \neq 0$ , sebab jika tidak hasilnya langsung berlaku. Untuk setiap  $\lambda \in \mathbb{R}$ ,

$$0 \leq \langle v - \lambda w, v - \lambda w \rangle = \|v\|^2 - 2\lambda \langle v, w \rangle + \lambda^2 \|w\|^2. \quad (1.16)$$

Ambil  $\lambda = \langle v, w \rangle / \|w\|^2$ . Maka

$$0 \leq \|v\|^2 - \frac{|\langle v, w \rangle|^2}{\|w\|^2}, \quad (1.17)$$

yang memberikan  $|\langle v, w \rangle| \leq \|v\| \|w\|$ . Jika  $v$  dan  $w$  tidak kolinear, maka  $v - \lambda w \neq 0$  untuk setiap  $\lambda$ , sehingga ketaksamaan dalam (1.16), dan dengan demikian ketaksamaan Cauchy–Schwarz, bersifat ketat.  $\square$

**Teorema 1.8** (Hölder). *Misalkan  $p, q \in [1, \infty]$  memenuhi  $\frac{1}{p} + \frac{1}{q} = 1$ <sup>2</sup>. Untuk setiap  $u, v \in \mathbb{R}^d$  yang dilengkapi dengan hasil kali dalam baku, berlaku*

$$\langle u, v \rangle \leq |\langle u, v \rangle| \leq \|u\|_p \|v\|_q. \quad (1.18)$$

*Bukti.* Kita membedakan kasus-kasus berikut.

- $p = 1$  dan  $q = \infty$ : dengan mudah diperoleh

$$|\langle u, v \rangle| \leq \sum_i |u_i| |v_i| \leq \sum_i |u_i| \|v\|_\infty = \|v\|_\infty \|u\|_1. \quad (1.19)$$

Kasus  $p = \infty, q = 1$  mengikuti dengan menukar  $u$  dan  $v$ .

- $1 < p < \infty$ : ketaksamaan jelas benar jika  $u = 0$  atau  $v = 0$ , sehingga andaikan  $u, v \neq 0$ . Ketaksamaan Young menyatakan bahwa untuk eksponen konjugat  $1 < p, q < \infty$  dan  $a, b \geq 0$  berlaku  $ab \leq a^p/p + b^q/q$ . Karena itu,

$$|\langle u, v \rangle| \leq \sum_i |u_i| |v_i| \leq \sum_i \left( \frac{|u_i|^p}{p} + \frac{|v_i|^q}{q} \right) = \frac{\|u\|_p^p}{p} + \frac{\|v\|_q^q}{q}. \quad (1.20)$$

Mengganti  $u$  dengan  $u/\|u\|_p$  dan  $v$  dengan  $v/\|v\|_q$  dalam (1.20) memberikan

$$\begin{aligned} \frac{|\langle u, v \rangle|}{\|u\|_p \|v\|_q} &= \left| \left\langle \frac{u}{\|u\|_p}, \frac{v}{\|v\|_q} \right\rangle \right| \\ &\leq \frac{\|u/\|u\|_p\|_p^p}{p} + \frac{\|v/\|v\|_q\|_q^q}{q} = \frac{1}{p} + \frac{1}{q} = 1. \end{aligned} \quad (1.21)$$

<sup>2</sup> $p$  dan  $q$  disebut eksponen konjugat Hölder.

□

Dengan ketaksamaan Hölder, kita dapat menunjukkan bahwa norma  $\ell^p$  memenuhi ketaksamaan segitiga, yaitu bagian tersulit dalam membuktikan bahwa besaran tersebut benar-benar merupakan norma.

**Teorema 1.9.** Untuk setiap  $p \in [1, \infty]$  berlaku

$$\|x + y\|_p \leq \|x\|_p + \|y\|_p, \quad x, y \in \mathbb{R}^d. \quad (1.22)$$

*Bukti.* Kasus  $p \in \{1, \infty\}$  ditinggalkan sebagai latihan sederhana. Jadi, andaikan  $1 < p < \infty$ . Kita boleh mengandaikan  $\|x + y\|_p \neq 0$ , sebab jika tidak hasilnya langsung berlaku. Dengan ketaksamaan Hölder dan hubungan  $p - 1 = p/q$ , diperoleh

$$\begin{aligned} \|x + y\|_p^p &= \sum_i |x_i + y_i| |x_i + y_i|^{p-1} \\ &\leq \sum_i |x_i| |x_i + y_i|^{p-1} + \sum_i |y_i| |x_i + y_i|^{p-1} \\ &\leq (\|x\|_p + \|y\|_p) \left( \sum_i |x_i + y_i|^{(p-1)q} \right)^{1/q} \\ &= (\|x\|_p + \|y\|_p) \|x + y\|_p^{p/q}. \end{aligned} \quad (1.23)$$

Membagi kedua ruas dengan  $\|x + y\|_p^{p/q}$  menyelesaikan bukti. □

## 1.2 Barisan dan topologi dasar

**Definisi 1.10** (Kekonvergenan barisan). Barisan  $(x_n)_n \subset \mathbb{R}^d$  disebut konvergen jika terdapat  $x \in \mathbb{R}^d$  sedemikian sehingga untuk setiap  $\varepsilon > 0$  terdapat  $N \in \mathbb{N}$  dengan

$$n \geq N \implies \|x - x_n\| \leq \varepsilon. \quad (1.24)$$

**Catatan.** Berdasarkan ekuivalensi norma, kekonvergenan tidak bergantung pada pilihan norma.

**Definisi 1.11** (Barisan Cauchy). Barisan  $(x_n)_n \subset V$  disebut barisan Cauchy jika dan hanya jika untuk setiap  $\varepsilon > 0$  terdapat  $N \in \mathbb{N}$  sedemikian sehingga  $\|x_n - x_m\| < \varepsilon$  bagi setiap  $n, m \geq N$ .

Sifat Cauchy serupa dengan kekonvergenan. Namun, perhatikan bahwa sifat Cauchy dapat dirumuskan tanpa gagasan titik limit. Hasil berikut mudah dibuktikan.

**Teorema 1.12.** Setiap barisan konvergen merupakan barisan Cauchy.

*Bukti.* Misalkan  $x_n \rightarrow \hat{x}$ . Ketaksamaan segitiga memberikan

$$\|x_n - x_m\| \leq \|x_n - \hat{x}\| + \|x_m - \hat{x}\|, \quad (1.25)$$

dan kedua suku di ruas kanan dapat dibuat sekecil yang diinginkan dengan memilih  $n, m$  cukup besar. □

**Definisi 1.13** (Ruang Banach dan Hilbert). Ruang bernorma  $(V, \|\cdot\|)$  disebut ruang Banach jika setiap barisan Cauchy konvergen. Artinya, jika  $(x_n)_n$  merupakan barisan Cauchy, terdapat  $x \in V$  sehingga  $\|x_n - x\| \rightarrow 0$  ketika  $n \rightarrow \infty$ . Jika normanya berasal dari suatu hasil kali dalam, ruang Banach tersebut disebut ruang Hilbert.

**Contoh 1.14.** Ruang  $(\mathbb{R}^d, \|\cdot\|_p)$  merupakan ruang Banach untuk setiap  $1 \leq p \leq \infty$ .

**Definisi 1.15** (Topologi dasar). Suatu himpunan  $A \subset \mathbb{R}^d$  disebut

- terbuka jika untuk setiap  $x \in A$  terdapat  $\varepsilon > 0$  sehingga  $B_\varepsilon(x) \subset A$ ;
- tertutup jika  $A^c$  terbuka. Ketertutupan ekuivalen dengan sifat berikut: jika  $(x_n)_n \subset A$  dan  $x_n \rightarrow x \in \mathbb{R}^d$ , maka  $x \in A$ .

**Definisi 1.16** (Kekompakan sekuensial). Himpunan  $A \subset \mathbb{R}^d$  disebut kompak secara sekuensial jika setiap barisan di  $A$  mempunyai suatu subbarisan yang konvergen ke titik di  $A$ . Dengan kata lain, untuk setiap  $(x_n)_n \subset A$  terdapat subbarisan  $(x_{n(k)})_k$  dan titik  $x \in A$  sedemikian sehingga  $x_{n(k)} \rightarrow x$ .

**Teorema 1.17** (Bolzano–Weierstrass). *Dalam ruang vektor berdimensi hingga, setiap barisan terbatas mempunyai subbarisan konvergen.*

*Bukti.* Pertama andaikan dimensinya satu, sehingga ruangnya adalah  $\mathbb{R}$ . Misalkan  $(x_n)_n \subset \mathbb{R}$  terbatas. Secara induktif kita membangun dua barisan  $(a_n)_n$  dan  $(b_n)_n$  dengan  $a_n \leq b_n$ ,  $[a_n, b_n] \subset [a_{n-1}, b_{n-1}]$ ,  $b_n - a_n = (b_{n-1} - a_{n-1})/2$ , dan, yang terpenting,  $[a_n, b_n]$  memuat tak hingga banyaknya suku  $x_k$  untuk setiap  $n$ .

Karena barisan terbatas, pilih  $a_0, b_0$  sehingga  $(x_n)_n \subset [a_0, b_0]$ . Jelas interval ini memuat tak hingga banyaknya suku  $x_k$ . Andaikan  $a_n, b_n$  telah dipilih dan tetapkan  $m_n = (a_n + b_n)/2$ . Karena  $[a_n, b_n]$  memuat tak hingga banyaknya suku  $x_k$ , setidaknya salah satu dari  $[a_n, m_n]$  dan  $[m_n, b_n]$  juga memuat tak hingga banyaknya suku. Pilih interval tersebut sebagai  $[a_{n+1}, b_{n+1}]$ .

Sekarang kita membangun subbarisan  $(x_{n(k)})_k$  secara induktif. Pilih  $n(0)$  sehingga  $x_{n(0)} \in [a_0, b_0]$ . Jika  $n(0), \dots, n(m)$  telah dipilih, tetapkan, misalnya,  $n(m+1) = \min\{j \in \mathbb{N} \mid j > n(m), x_j \in [a_{m+1}, b_{m+1}]\}$ . Pilihan ini selalu mungkin karena interval tersebut memuat tak hingga banyaknya suku barisan.

Akhirnya, ambil sembarang  $k \leq \ell$ . Karena  $x_{n(k)}, x_{n(\ell)} \in [a_k, b_k]$ , berlaku

$$|x_{n(k)} - x_{n(\ell)}| \leq b_k - a_k = 2^{-k}(b_0 - a_0). \quad (1.26)$$

Jadi  $(x_{n(k)})_k$  merupakan barisan Cauchy dan karenanya konvergen.

Untuk dimensi lebih besar, yaitu  $\mathbb{R}^d$ , mula-mula pilih subbarisan yang komponen pertamanya konvergen. Dari subbarisan itu pilih lagi subbarisan yang komponen keduanya konvergen, dan lanjutkan demikian. Subbarisan diagonal yang diperoleh setelah langkah ke- $d$  mempunyai semua komponen yang konvergen; khususnya, subbarisan itu konvergen dalam norma satu. Ekuivalensi norma kemudian memberikan kekonvergenan dalam setiap norma.  $\square$

Sebagai akibatnya, kita memperoleh hasil berikut.

**Korolari 1.18.** *Di  $\mathbb{R}^d$ , suatu himpunan kompak jika dan hanya jika tertutup dan terbatas.*

*Bukti.* Misalkan  $A \subset \mathbb{R}^d$  tertutup dan terbatas, serta  $(x_n)_n \subset A$ . Berdasarkan keterbatasan dan [teorema 1.17](#), terdapat subbarisan konvergen; berdasarkan ketertutupan, limitnya berada di  $A$ . Jadi  $A$  kompak.

Sebaliknya, andaikan  $A$  kompak. Jika  $A$  tidak terbatas, untuk setiap  $n \in \mathbb{N}$  kita dapat memilih  $x_n \in A$  dengan  $\|x_n\| \geq n$ . Barisan ini tidak mempunyai subbarisan konvergen, bertentangan dengan kekompakan. Jadi  $A$  terbatas. Selanjutnya, misalkan  $(x_n)_n \subset A$  dan  $x_n \rightarrow x \in \mathbb{R}^d$ . Berdasarkan kekompakan,  $(x_n)_n$  mempunyai subbarisan  $(x_{n(k)})_k$  yang konvergen ke suatu titik di  $A$ . Setiap subbarisan dari barisan konvergen mempunyai limit yang sama, sehingga  $x = \lim_k x_{n(k)} \in A$ . Jadi  $A$  tertutup.  $\square$

### 1.3 Fungsi

**Definisi 1.19** (Kontinuitas). Misalkan  $f : V \rightarrow E$  suatu pemetaan di antara dua ruang bernorma. Fungsi  $f$  disebut kontinu di  $v \in V$  jika salah satu dari dua syarat ekuivalen berikut dipenuhi:

- untuk setiap barisan  $v_n \rightarrow v$ , berlaku  $f(v_n) \rightarrow f(v)$ ;
- untuk setiap  $\varepsilon > 0$  terdapat  $\delta > 0$  sedemikian sehingga

$$\|u - v\| \leq \delta \implies \|f(u) - f(v)\| \leq \varepsilon. \quad (1.27)$$

Jika  $f$  kontinu pada setiap  $v \in V$ , kita cukup mengatakan bahwa  $f$  kontinu.

**Definisi 1.20** (Kontinuitas Lipschitz). Misalkan  $f : V \rightarrow E$  suatu pemetaan di antara dua ruang bernorma. Fungsi  $f$  disebut kontinu Lipschitz jika terdapat  $L \geq 0$  sedemikian sehingga

$$\|f(u) - f(v)\| \leq L\|u - v\|, \quad u, v \in V. \quad (1.28)$$

### 1.3.1 Pemetaan linear dan ruang dual

**Definisi 1.21** (Pemetaan linear). Fungsi  $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  disebut linear jika

$$f(\lambda x + \mu y) = \lambda f(x) + \mu f(y), \quad x, y \in \mathbb{R}^n, \quad \lambda, \mu \in \mathbb{R}. \quad (1.29)$$

Pemetaan linear dapat diidentifikasi dengan matriks.

**Teorema 1.22.** Ruang semua fungsi linear  $\mathbb{R}^n \rightarrow \mathbb{R}^m$  isomorfik<sup>3</sup> dengan ruang semua matriks  $A \in \mathbb{R}^{m \times n}$ .

*Bukti.* Kita mendefinisikan korespondensi satu-ke-satu dengan mengaitkan setiap  $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  pada matriks  $A_f$  yang diberikan oleh

$$(A_f)_{i,j} = f(e_j)_i. \quad (1.30)$$

Pembuktian bahwa korespondensi ini bijektif dan linear ditinggalkan sebagai latihan.  $\square$

**Definisi 1.23** (Ruang dual). Misalkan  $V$  suatu ruang bernorma. Ruang dual  $V^*$  adalah **ruang vektor** semua fungsional linear kontinu dari  $V$  ke  $\mathbb{R}$ , yaitu

$$V^* = \{f : V \rightarrow \mathbb{R} \mid f \text{ linear dan kontinu}\}. \quad (1.31)$$

Unsur  $V^*$  disebut fungsional linear pada  $V$ . Norma kanonik pada  $V^*$  adalah norma dual

$$\|v^*\|_{V^*} := \sup_{\substack{v \in V \\ \|v\|_V \leq 1}} |v^*(v)|. \quad (1.32)$$

Dengan sedikit penyalahgunaan notasi, penerapan suatu unsur dual juga sering ditulis memakai notasi hasil kali dalam:

$$\langle v^*, v \rangle := v^*(v). \quad (1.33)$$

Langsung dari definisi diperoleh

$$|v^*(v)| \leq \|v^*\| \|v\|. \quad (1.34)$$

Hasil berikut sangat penting: pada ruang Hilbert, ruang dual dapat diidentifikasi dengan ruang itu sendiri. Hasil ini juga membenarkan penggunaan notasi hasil kali dalam untuk penerapan unsur dual.

**Teorema 1.24** (Riesz). Misalkan  $V$  ruang Hilbert. Untuk setiap  $v^* \in V^*$  terdapat tepat satu  $v \in V$  sedemikian sehingga

$$v^*(w) = \langle v, w \rangle, \quad w \in V. \quad (1.35)$$

Pemetaan  $v^* \mapsto v$  linear dan memenuhi  $\|v\| = \|v^*\|$ . Secara khusus,  $V^* \cong V$ .

*Bukti.* Jika  $v^* = 0$ , ambil  $v = 0$ . Jadi, andaikan  $v^* \neq 0$ . Karena  $\ker(v^*)$  merupakan subruang tertutup, teorema proyeksi ortogonal pada ruang Hilbert memberikan  $V = \ker(v^*) \oplus \ker(v^*)^\perp$ . Komponen ortogonal dari sembarang titik di luar kernel tidak nol; setelah dinormalkan, kita memperoleh  $z \in \ker(v^*)^\perp$  dengan  $v^*(z) \neq 0$  dan  $\|z\| = 1$ . Untuk sembarang  $w \in V$ ,

$$v^*(zv^*(w) - wv^*(z)) = 0, \quad (1.36)$$

sehingga, berdasarkan ortogonalitas  $z$  terhadap  $\ker(v^*)$ ,

$$\langle zv^*(w) - wv^*(z), z \rangle = 0. \quad (1.37)$$

Akibatnya,

$$\begin{aligned} v^*(w) &= v^*(w) \langle z, z \rangle = \langle zv^*(w), z \rangle \\ &= \langle zv^*(w) - wv^*(z), z \rangle + \langle wv^*(z), z \rangle \\ &= \langle w, v^*(z)z \rangle. \end{aligned} \quad (1.38)$$

Jadi  $v = v^*(z)z$  merupakan unsur yang dicari. Ketunggalan, linearitas pemetaan representasi, dan kesamaan normanya ditinggalkan sebagai latihan.  $\square$

<sup>3</sup>Secara informal: keduanya mempunyai struktur yang sama.

**Contoh 1.25** (Dual). Pada  $\mathbb{R}^d$ , untuk  $1 \leq p \leq \infty$ , norma dual dari  $\|\cdot\|_p$  tepat sama dengan  $\|\cdot\|_q$ , dengan  $\frac{1}{p} + \frac{1}{q} = 1$ .

Sebagian besar pembaca mungkin telah mengenal adjoin atau transpos suatu matriks, yang diperoleh dengan menukar baris dan kolom. Untuk  $A \in \mathbb{R}^{n \times m}$ , adjoin  $A^\top \in \mathbb{R}^{m \times n}$  didefinisikan oleh

$$(A^\top)_{i,j} = A_{j,i}. \quad (1.39)$$

Dengan hasil kali dalam baku, mudah diperiksa bahwa untuk setiap  $x \in \mathbb{R}^m$  dan  $y \in \mathbb{R}^n$  berlaku

$$\langle Ax, y \rangle = \langle x, A^\top y \rangle. \quad (1.40)$$

Sifat terakhir inilah yang mencirikan definisi formal adjoin suatu pemetaan linear. Secara khusus, **adjoin bergantung pada hasil kali dalam yang dipilih**.

**Definisi 1.26.** Misalkan  $A : V \rightarrow W$  pemetaan linear kontinu di antara dua ruang Hilbert. Operator adjoin  $A^* : W \rightarrow V$  didefinisikan oleh

$$\langle Ax, y \rangle = \langle x, A^* y \rangle, \quad x \in V, \quad y \in W. \quad (1.41)$$

**Latihan 1.27.** Tunjukkan bahwa adjoin merupakan operator linear yang terdefinisi dengan baik.

**Lema 1.28.** Misalkan  $U, V, W$  ruang Hilbert. Untuk pemetaan linear kontinu  $A, B : V \rightarrow W$  dan  $\lambda \in \mathbb{R}$ , berlaku

- (i)  $(A^*)^* = A$ ;
- (ii)  $(\lambda A + B)^* = \lambda A^* + B^*$ ;
- (iii) jika  $A : U \rightarrow V$  dan  $B : V \rightarrow W$  linear kontinu, maka  $(BA)^* = A^* B^*$ .

*Bukti.* Latihan. □

**Definisi 1.29** (Fungsi bernilai real diperluas). Misalkan  $V$  ruang vektor. Fungsi  $f : V \rightarrow [-\infty, \infty]$  disebut fungsi bernilai real diperluas. Fungsi  $f$  disebut proper jika tidak pernah bernilai  $-\infty$  dan terdapat  $x \in V$  dengan  $f(x) < \infty$ . Domain efektif suatu fungsi proper  $f$  didefinisikan sebagai

$$\text{dom}(f) = \{x \in V \mid f(x) < \infty\}. \quad (1.42)$$

**Contoh 1.30.** Fungsi bernilai real diperluas yang sering digunakan adalah fungsi indikator. Untuk  $A \subset V$ , fungsi indikator didefinisikan oleh

$$\delta_A(x) = \begin{cases} 0, & x \in A, \\ \infty, & x \notin A. \end{cases} \quad (1.43)$$

Dengan fungsi indikator, masalah optimisasi berkendala dapat ditulis ulang sebagai masalah tak berkendala:

$$\min_{x \in C} f(x) = \min_{x \in V} (f(x) + \delta_C(x)). \quad (1.44)$$

**Definisi 1.31** (Epigraf dan fungsi tertutup). Epigraf fungsi  $f : V \rightarrow (-\infty, \infty]$  didefinisikan sebagai

$$\text{epi}(f) = \{(x, t) \in V \times \mathbb{R} \mid f(x) \leq t\}. \quad (1.45)$$


Fungsi disebut tertutup jika epigrafnya merupakan himpunan tertutup.

**Latihan 1.32.** Jika  $A$  tertutup, tunjukkan bahwa  $\delta_A$  juga tertutup.

**Latihan 1.33.** Apakah domain suatu fungsi tertutup harus tertutup? Buktikan atau berikan contoh penyangkal.

**Definisi 1.34** (Semikontinuitas bawah). Fungsi  $f : V \rightarrow (-\infty, \infty]$  disebut semikontinu bawah (*lower semi-continuous*, lsc) jika untuk setiap barisan  $x_n \rightarrow x$  di  $V$  berlaku

$$f(x) \leq \liminf_{n \rightarrow \infty} f(x_n). \quad (1.46)$$



**Gambar 1.1:** Kegagalan semikontinuitas bawah dapat menyebabkan infimum tidak tercapai.

**Lema 1.35.** Fungsi  $f : V \rightarrow (-\infty, \infty]$  tertutup jika dan hanya jika semikontinu bawah.

*Bukti.*  $\Rightarrow$ : andaikan  $f$  tertutup,  $x_n \rightarrow x$ , dan tuliskan  $L = \liminf_n f(x_n)$ . Jika  $L = +\infty$ , ketaksamaan yang diinginkan langsung berlaku. Jika  $L \in \mathbb{R}$ , ambil subbarisan  $n(k)$  dengan

$$L = \liminf_n f(x_n) = \lim_k f(x_{n(k)}). \quad (1.47)$$

Untuk  $k$  cukup besar nilainya hingga, sehingga  $(x_{n(k)}, f(x_{n(k)})) \in \text{epi}(f)$  dan

$$(x_{n(k)}, f(x_{n(k)})) \rightarrow (x, L). \quad (1.48)$$

Ketertutupan epigraf memberikan  $(x, L) \in \text{epi}(f)$ , jadi  $f(x) \leq L$ . Terakhir,  $L = -\infty$  tidak mungkin: untuk setiap  $M \in \mathbb{R}$  kita dapat memilih subbarisan dengan  $f(x_{n(k)}) \leq M$ ; maka  $(x_{n(k)}, M) \in \text{epi}(f)$  dan ketertutupan akan memberikan  $f(x) \leq M$  untuk setiap  $M$ , bertentangan dengan kodomain  $(-\infty, +\infty]$ .

$\Leftarrow$ : sekarang andaikan  $f$  semikontinu bawah dan  $(x_n, t_n)_n \subset \text{epi}(f)$  dengan  $(x_n, t_n) \rightarrow (x, t)$  dalam  $V \times \mathbb{R}$ . Khususnya,  $x_n \rightarrow x$ . Oleh semikontinuitas bawah,

$$f(x) \leq \liminf_n f(x_n) \leq \liminf_n t_n = \lim_n t_n = t. \quad (1.49)$$

Jadi  $(x, t) \in \text{epi}(f)$ , yang membuktikan bahwa epigrafnya tertutup.  $\square$

**Lema 1.36.** Jika pembatasan  $f$  pada  $\text{dom}(f)$  kontinu dan  $\text{dom}(f)$  tertutup, maka  $f$  tertutup.

*Bukti.* Latihan.  $\square$

**Deskripsi gambar.** Kedua panel menampilkan fungsi sepotong-sepotong yang mempunyai lompatan di  $x = 0$ . Pada panel kiri, cabang kanan mendekati titik kosong  $(0, 0)$  sementara nilai fungsi di  $x = 0$  adalah titik penuh  $(0, 1)$ ; infimum 0 tidak tercapai. Pada panel kanan, titik  $(0, 0)$  diisi dan titik  $(0, 1)$  dibiarkan kosong, sehingga nilai minimum 0 tercapai.

**Definisi 1.37** (Koersif). Fungsi  $f : V \rightarrow (-\infty, +\infty]$  disebut koersif jika

$$\lim_{\|x\| \rightarrow \infty} f(x) = \infty. \quad (1.50)$$

**Teorema 1.38.** Misalkan  $V$  berdimensi hingga dan  $f : V \rightarrow (-\infty, \infty]$  proper, koersif, serta semikontinu bawah. Maka  $f$  mencapai minimumnya pada  $V$ .<sup>4</sup>

*Bukti.* Bukti mengikuti apa yang disebut *metode langsung*.

<sup>4</sup>Asumsi dimensi hingga menyediakan kekompakan sekuensial yang dipakai bukti ini. Generalisasi ke dimensi tak hingga memerlukan hipotesis tambahan, misalnya refleksivitas dan semikontinuitas bawah lemah; ketiga asumsi yang ditampilkan saja tidak cukup.

**Langkah 1: Ambil barisan peminimum.** Misalkan  $(x_n)_n$  suatu barisan peminimum<sup>5</sup>, yaitu

$$\lim_n f(x_n) = \inf_{x \in V} f(x). \quad (1.51)$$

**Langkah 2: Tunjukkan keterbatasan barisan.** Karena  $f$  koersif, barisan peminimum harus terbatas. Jika tidak, terdapat subbarisan  $(x_{n(k)})_k$  dengan  $\|x_{n(k)}\| \rightarrow \infty$ . Koersivitas kemudian memberikan

$$f(x_{n(k)}) \rightarrow \infty, \quad (1.52)$$

yang bertentangan dengan

$$f(x_{n(k)}) \rightarrow \inf f < \infty. \quad (1.53)$$

**Langkah 3: Gunakan kekompakan untuk mengambil subbarisan konvergen.** Berdasarkan [teorema 1.17](#), setiap barisan terbatas dalam ruang vektor berdimensi hingga mempunyai subbarisan konvergen. Jadi kita dapat mengambil subbarisan  $(x_{n(k)})_k$  dengan limit  $\lim_k x_{n(k)} = \hat{x}$ .

**Langkah 4: Simpulkan dengan semikontinuitas bawah.** Berdasarkan semikontinuitas bawah  $f$ ,

$$f(\hat{x}) \leq \liminf_{k \rightarrow \infty} f(x_{n(k)}) = \lim_n f(x_n) = \inf_x f(x) \leq f(\hat{x}). \quad (1.54)$$

Jadi semua ketaksamaan merupakan kesamaan dan  $\hat{x}$  adalah peminim. □

---

<sup>5</sup>Sebagai latihan: mengapa barisan seperti ini selalu ada?

## Bab 2

# Kekonveksan

Tujuan kita dalam kuliah ini adalah menyelesaikan masalah berbentuk

$$\min_{x \in C} f(x), \quad (2.1)$$

dengan  $C \subset V$  suatu *himpunan bagian konveks* dari ruang  $V$  dan  $f : C \rightarrow (-\infty, \infty]$  suatu *fungsi konveks*. Oleh karena itu, pada bagian berikut kita menganalisis secara lebih terperinci arti tepat kekonveksan himpunan dan fungsi serta akibat yang dapat ditarik dari sifat-sifat tersebut.

### 2.1 Himpunan konveks

Suatu himpunan disebut konveks apabila, untuk setiap dua titik di dalamnya, seluruh ruas garis lurus yang menghubungkan kedua titik itu juga termuat di dalam himpunan tersebut. Secara lebih formal:

**Definisi 2.1.** Suatu himpunan  $C \subset V$  disebut konveks jika dan hanya jika, untuk setiap  $x, y \in C$  dan  $\lambda \in (0, 1)$ , berlaku

$$\lambda x + (1 - \lambda)y \in C. \quad (2.2)$$

Perhatikan bahwa

$$\lambda x + (1 - \lambda)y = y + \lambda(x - y), \quad (2.3)$$

yang memperlihatkan dengan lebih jelas bahwa  $\lambda x + (1 - \lambda)y$  menelusuri ruas garis yang menghubungkan  $x$  dan  $y$ .

Lebih lanjut, dengan menggunakan *kombinasi konveks* yang lebih umum, kita dapat dengan mudah menunjukkan hasil berikut.

**Lema 2.2.** Himpunan  $C \subset V$  konveks jika dan hanya jika, untuk setiap  $n \in \mathbb{N}$ ,  $x_i \in C$ , dan  $\lambda_i \in [0, 1]$ ,  $i = 1, \dots, n$ , yang memenuhi  $\sum_{i=1}^n \lambda_i = 1$ , berlaku

$$\sum_{i=1}^n \lambda_i x_i \in C. \quad (2.4)$$

*Bukti.* Latihan. □


Untuk memudahkan notasi, kita mendefinisikan *simpleks satuan* sebagai

$$\Delta^k = \{(\lambda_1, \dots, \lambda_k) \in [0, 1]^k \mid \sum_{i=1}^k \lambda_i = 1\}. \quad (2.5)$$

Sekarang kita dapat mendefinisikan himpunan konveks terkecil yang memuat suatu himpunan, yaitu *selubung konveks*.

**Definisi 2.3** (Selubung konveks). Misalkan  $C \subset V$ . Selubung konveks dari  $C$  didefinisikan sebagai himpunan

$$\text{conv}(C) := \bigcap_{\substack{S \subset V \text{ konveks} \\ C \subset S}} S. \quad (2.6)$$



Gambar 2.1: Baris atas: himpunan konveks. Baris bawah: himpunan tak konveks.

**Lema 2.4.** Berlaku

$$\text{conv}(C) = \left\{ \sum_{i=1}^n \lambda_i x_i \mid n \in \mathbb{N}, x_i \in C, (\lambda_1, \dots, \lambda_n) \in \Delta^n \right\}. \quad (2.7)$$

*Bukti.* Nyatakan ruas kanan (2.7) dengan  $A$ . Kita akan menunjukkan bahwa  $\text{conv}(C) \subset A$  dan  $A \subset \text{conv}(C)$ .

$A \subset \text{conv}(C)$ : Misalkan  $x = \sum_{i=1}^n \lambda_i x_i \in A$ . Untuk setiap  $S \subset V$  yang konveks dan memenuhi  $C \subset S$ , berlaku  $x \in S$ . Oleh karena itu, berdasarkan definisi pada (2.6), diperoleh  $x \in \text{conv}(C)$ .

$\text{conv}(C) \subset A$ : Dapat diperiksa langsung bahwa  $A$  memang merupakan himpunan konveks. Selain itu,  $C \subset A$ . Dengan demikian,  $A$  termasuk salah satu himpunan  $S$  dalam (2.6), sehingga  $\text{conv}(C) \subset A$ .  $\square$

**Deskripsi gambar.** Baris atas memperlihatkan beberapa daerah yang memuat seluruh ruas garis di antara setiap dua titik di dalamnya. Baris bawah memperlihatkan daerah yang memiliki lekukan atau bagian terpisah sehingga terdapat dua titik di dalam himpunan yang ruas penghubungnya keluar dari himpunan.

**Contoh 2.5.** Himpunan-himpunan berikut bersifat konveks (buktinya ditinggalkan sebagai latihan):

- Himpunan kosong  $\emptyset$ .
- Setiap ruang vektor.
- Setiap bola norma; yaitu, untuk setiap norma  $\|\cdot\|$ , setiap  $c \in V$ , dan setiap  $R \geq 0$ , himpunan

$$B_{\|\cdot\|,R}(c) = \{x \in V \mid \|x - c\| < R\} \quad (2.8)$$

dan

$$\overline{B}_{\|\cdot\|,R}(c) = \{x \in V \mid \|x - c\| \leq R\}. \quad (2.9)$$

- Setiap subruang afin; yaitu, untuk setiap vektor  $z, x_1, \dots, x_k \in V$ , himpunan

$$\left\{ x \in V \mid x = z + \sum_{i=1}^k \lambda_i x_i, \lambda_i \in \mathbb{R} \right\}. \quad (2.10)$$


**Deskripsi gambar.** Gambar membandingkan bola satuan dua dimensi untuk beberapa nilai  $p$ . Bentuknya berubah dari belah ketupat melalui lingkaran menuju bentuk yang semakin menyerupai persegi ketika  $p$  bertambah; untuk  $p = 1/2$ , sisi-sisinya melengkung ke dalam sehingga himpunannya tidak konveks.

**Lema 2.6** (Operasi yang mempertahankan kekonveksan). *Pernyataan-pernyataan berikut berlaku:*

(i) *Irisan.* Misalkan  $C_i \subset V$  konveks untuk  $i \in I$ , dengan  $I$  suatu himpunan indeks sembarang. Maka irisan

$$\bigcap_{i \in I} C_i := \{x \in V \mid x \in C_i \forall i \in I\} \quad (2.11)$$

bersifat konveks.



**Gambar 2.2:** Bola norma  $\bar{B}_{\|\cdot\|_{p,R}}(0)$  untuk beberapa norma  $\ell^p$ . Perhatikan bahwa himpunan untuk  $p = 1/2$  tidak konveks karena pilihan ini tidak menghasilkan norma: ketaksamaan segitiga tidak berlaku.

- (ii) *Jumlah berbobot.* Misalkan  $C_i \subset V$  konveks untuk  $i = 1, \dots, N$ , dan misalkan  $\lambda_i \in \mathbb{R}$  untuk  $i = 1, \dots, N$ . Maka himpunan

$$\sum_{i=1}^N \lambda_i C_i := \left\{ \sum_{i=1}^N \lambda_i x_i \mid x_i \in C_i \forall i = 1, \dots, N \right\} \quad (2.12)$$

bersifat konveks.

- (iii) *Produk Kartesius.* Misalkan  $C_i \subset V$  konveks untuk  $i \in I$ , dengan  $I$  suatu himpunan indeks sembarang. Maka produk Kartesius

$$\prod_{i \in I} C_i := \{(x_i)_{i \in I} \mid x_i \in C_i \forall i \in I\} \quad (2.13)$$

bersifat konveks.

- (iv) *Citra dan pracitra<sup>1</sup> di bawah pemetaan linear bersifat konveks.* Secara khusus, untuk  $A : V \rightarrow W$  linear serta  $S \subset V$  dan  $T \subset W$  keduanya konveks, himpunan-himpunan berikut bersifat konveks:

$$A(S) = \{Ax \mid x \in S\}, \quad A^{-1}(T) = \{x \in V \mid Ax \in T\}. \quad (2.14)$$

*Bukti.* Kita hanya membuktikan bagian pertama dan meninggalkan sisanya sebagai latihan. Buktinya langsung. Misalkan  $x, y \in \bigcap_{i \in I} C_i$  dan  $\lambda \in (0, 1)$ . Karena  $x, y \in C_i$  untuk setiap  $i$  dan setiap  $C_i$  konveks, diperoleh  $\lambda x + (1 - \lambda)y \in C_i$  untuk setiap  $i$ . Dengan demikian,  $\lambda x + (1 - \lambda)y \in \bigcap_{i \in I} C_i$ .  $\square$

Kita hendak mendefinisikan secara formal pengertian hiperbidang, yaitu perumuman bidang dua dimensi di  $\mathbb{R}^3$  ke dimensi sembarang.

**Definisi 2.7** (Hiperbidang). Misalkan  $V$  suatu ruang hasil kali dalam. Hiperbidang adalah himpunan  $H$  berbentuk

$$H = \{x \in V \mid \langle x, a \rangle = b\} \quad (2.15)$$

untuk suatu  $a \in V \setminus \{0\}$  dan  $b \in \mathbb{R}$ .

Parameter  $a$  menentukan orientasi bidang dan  $b$  menentukan geserannya. Secara khusus,  $0 \in H$  jika dan hanya jika  $b = 0$ ; dalam kasus ini  $H$  merupakan subruang. Jika  $b \neq 0$ ,  $H$  hanya merupakan subruang afin.

Perhatikan bahwa jika  $x_0 \in H$ , maka

$$H = \{x \in V \mid \langle x - x_0, a \rangle = 0\}. \quad (2.16)$$

Jadi,  $a$  adalah vektor normal terhadap bidang tersebut. Selain itu, dapat diperiksa sebagai latihan bahwa  $\frac{|b|}{\|a\|}$  adalah jarak bidang dari titik asal.

Setiap hiperbidang membagi ruang menjadi dua setengah ruang.

<sup>1</sup>Pracitra terdefinisi dengan baik juga untuk pemetaan yang tidak invertibel.



**Gambar 2.3:** Ilustrasi teorema pemisahan Hahn–Banach dan alasan pemisahan dapat gagal tanpa kekonveksan.

**Definisi 2.8** (Setengah ruang). Misalkan  $V$  suatu ruang hasil kali dalam. Setengah ruang adalah himpunan  $H^-$  berbentuk

$$H^- = \{x \in V \mid \langle x, a \rangle \leq b\} \quad (2.17)$$

untuk suatu  $a \in V \setminus \{0\}$  dan  $b \in \mathbb{R}$ .

Teorema berikut menyatakan bahwa pemisahan tersebut dapat dipilih dengan cara tertentu. Hasil ini ternyata sangat penting dalam optimisasi dan analisis fungsional.

**Teorema 2.9** (Teorema pemisahan Hahn–Banach). Misalkan  $S, T$  dua himpunan bagian konveks yang tak kosong dan saling lepas dari suatu ruang bernorma real  $V$ , dan misalkan  $S$  terbuka. Maka terdapat  $a \in V^*$  yang kontinu dan tak nol serta  $\alpha \in \mathbb{R}$  sedemikian sehingga

$$\langle a, x \rangle < \alpha \leq \langle a, y \rangle, \quad x \in S, y \in T. \quad (2.18)$$

Jika  $S$  dan  $T$  keduanya tertutup dan salah satunya kompak, maka terdapat  $a \in V^*$  yang kontinu dan tak nol,  $\alpha \in \mathbb{R}$ , dan  $\varepsilon > 0$  sedemikian sehingga

$$\langle a, x \rangle \leq \alpha < \alpha + \varepsilon \leq \langle a, y \rangle, \quad x \in S, y \in T. \quad (2.19)$$

Versi kedua memungkinkan kita memperoleh selisih positif tegas antara

$$\sup_{x \in S} \langle a, x \rangle \quad \text{dan} \quad \inf_{y \in T} \langle a, y \rangle.$$

**Deskripsi gambar.** Panel kiri menampilkan dua himpunan konveks tak beririsan yang dipisahkan oleh sebuah garis putus-putus. Panel kanan menampilkan salah satu himpunan yang tak konveks dan melingkupi sebagian himpunan lainnya, sehingga tidak ada satu garis lurus yang dapat memisahkan keduanya.

## 2.2 Fungsi konveks


Seperti diperlihatkan pada Fig. 2.4, kekonveksan sangat memengaruhi pertanyaan tentang keberadaan dan ketunggalan minimum.

**Deskripsi gambar.** Gambar membandingkan grafik satu dimensi berbentuk mangkuk, yang konveks dan memiliki struktur minimum yang teratur, dengan grafik tak konveks yang memiliki lekukan serta beberapa minimum lokal.


**Definisi 2.10** (Syarat orde nol untuk kekonveksan). Misalkan  $C \subset V$  konveks dan  $f : C \rightarrow (-\infty, \infty]$ .

- Fungsi  $f$  disebut konveks jika dan hanya jika, untuk setiap  $x, y \in C$  dan  $\lambda \in (0, 1)$ , berlaku

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y). \quad (2.20)$$



Gambar 2.4: Contoh fungsi konveks dan fungsi tak konveks dalam satu dimensi.



Gambar 2.5: Penafsiran geometris syarat orde nol bagi kekonveksan suatu fungsi.

- Fungsi  $f$  disebut konveks tegas jika dan hanya jika, untuk setiap  $x, y \in \text{dom}(f)$  dengan  $x \neq y$  dan setiap  $\lambda \in (0, 1)$ , berlaku

$$f(\lambda x + (1 - \lambda)y) < \lambda f(x) + (1 - \lambda)f(y). \quad (2.21)$$

- Fungsi  $f$  disebut konveks kuat dengan parameter  $\mu > 0$  jika dan hanya jika, untuk setiap  $x, y \in \text{dom}(f)$  dan  $\lambda \in (0, 1)$ , berlaku

$$f(\lambda x + (1 - \lambda)y) \leq \lambda f(x) + (1 - \lambda)f(y) - \frac{\lambda(1 - \lambda)\mu}{2} \|x - y\|^2. \quad (2.22)$$

Syarat orde nol menyatakan bahwa ruas garis yang menghubungkan dua titik pada grafik, yaitu garis sekan, selalu berada di atas fungsi. Untuk fungsi konveks tegas, garis sekan berada secara tegas di atas fungsi, sedangkan dalam kasus konveks kuat kita bahkan dapat *menyisipkan* fungsi kuadrat di antara keduanya.

**Deskripsi gambar.** Sebuah kurva konveks biru ditampilkan bersama dua titik pada grafik dan ruas sekan yang menghubungkannya. Nilai fungsi pada kombinasi konveks kedua titik berada di bawah nilai yang diperoleh melalui interpolasi linear di sepanjang sekan.

**Contoh 2.11.** Fungsi-fungsi berikut konveks (bukti: latihan):

- Fungsi afin  $f(x) = \langle a, x \rangle + b$  dengan  $a \in V^*$  dan  $b \in \mathbb{R}$ ; khususnya, fungsi linear ketika  $b = 0$ .
- Semua norma merupakan fungsi konveks.

Serupa dengan hasil untuk himpunan konveks, kekonveksan dapat diperluas ke kombinasi konveks dengan banyak titik yang sembarang.

**Teorema 2.12** (Jensen). Misalkan  $C \subset V$  konveks dan  $f : C \rightarrow (-\infty, +\infty]$ . Dengan konvensi  $0 \cdot (+\infty) = 0$ , fungsi  $f$  konveks jika dan hanya jika, untuk setiap  $k \in \mathbb{N}$ ,  $\lambda \in \Delta^k$ , dan  $x_i \in C$ , berlaku

$$f\left(\sum_{i=1}^k \lambda_i x_i\right) \leq \sum_{i=1}^k \lambda_i f(x_i). \quad (2.23)$$

Di atas kita melihat bahwa kekonveksan berarti garis sekan berada di atas fungsi. Kekonveksan juga berarti garis singgung berada di bawah fungsi (*bandingkan Fig. 2.6*).

**Teorema 2.13** (Karakterisasi orde pertama kekonveksan). Misalkan  $C \subset \mathbb{R}^d$  konveks dan  $f : C \rightarrow \mathbb{R}$  mempunyai perluasan yang terdiferensialkan secara kontinu pada suatu lingkungan terbuka dari  $C$ .

- Fungsi  $f$  konveks jika dan hanya jika, untuk semua  $x, y \in C$ ,

$$f(x) + \langle \nabla f(x), y - x \rangle \leq f(y).$$

- Fungsi  $f$  konveks tegas jika dan hanya jika ketaksamaan di atas berlaku tegas untuk semua  $x \neq y$ .

*Bukti.* Kita terlebih dahulu membuktikan butir pertama.

$\Rightarrow$ : Misalkan  $f$  konveks. Maka

$$f(x + \lambda(y - x)) = f(\lambda y + (1 - \lambda)x) \leq \lambda f(y) + (1 - \lambda)f(x). \quad (2.24)$$

Dengan menyusun ulang, diperoleh

$$\frac{f(x + \lambda(y - x)) - f(x)}{\lambda} \leq f(y) - f(x). \quad (2.25)$$

Membiarkan  $\lambda \rightarrow 0$  memberikan hasil yang diinginkan.

$\Leftarrow$ : Sekarang andaikan syarat gradien berlaku. Tuliskan  $x_\lambda = x + \lambda(y - x)$ . Maka

$$f(x_\lambda) + \langle \nabla f(x_\lambda), y - x_\lambda \rangle = f(x_\lambda) + \langle \nabla f(x_\lambda), (1 - \lambda)(y - x) \rangle \leq f(y)$$

dan

$$f(x_\lambda) + \langle \nabla f(x_\lambda), x - x_\lambda \rangle = f(x_\lambda) + \langle \nabla f(x_\lambda), -\lambda(y - x) \rangle \leq f(x).$$

Kalikan ketaksamaan pertama dengan  $\lambda$ , ketaksamaan kedua dengan  $1 - \lambda$ , lalu jumlahkan. Hasilnya

$$f(x_\lambda) \leq \lambda f(y) + (1 - \lambda)f(x).$$

Untuk butir kedua, arah dari syarat orde pertama tegas menuju kekonveksan tegas langsung mengikuti argumen yang sama. Sebaliknya, jika  $f$  konveks tegas dan  $x \neq y$ , fungsi satu variabel  $g(t) = f(x + t(y - x))$  konveks tegas pada  $[0, 1]$ . Kemiringan sekan  $(g(t) - g(0))/t$  tak menurun dalam  $t > 0$  dan, untuk setiap  $t_0 \in (0, 1)$ , bernilai tegas lebih kecil daripada  $g(1) - g(0)$ . Mengambil limit  $t \downarrow 0$  memberikan  $\langle \nabla f(x), y - x \rangle < f(y) - f(x)$ .  $\square$

**Deskripsi gambar.** Grafik sebuah fungsi konveks ditampilkan bersama garis singgungnya pada titik  $x$ . Garis afn  $y \mapsto f(x) + \langle \nabla f(x), y - x \rangle$  berada di bawah grafik fungsi di seluruh domain yang diperlihatkan.

**Definisi 2.14** (Minimum). Misalkan  $f : C \rightarrow \mathbb{R}$  dan  $x^* \in C$ .


- Titik  $x^*$  disebut minimum lokal jika dan hanya jika terdapat  $\varepsilon > 0$  sedemikian sehingga

$$f(x^*) \leq f(x), \quad \forall x \in B_\varepsilon(x^*) \cap C.$$

- Titik  $x^*$  disebut minimum global jika dan hanya jika

$$f(x^*) \leq f(x), \quad \forall x \in C.$$

Minimum disebut *tegas* apabila ketaksamaan yang bersesuaian berlaku tegas untuk semua titik pembandingan  $x \neq x^*$ .



Gambar 2.6: Penafsiran geometris syarat orde pertama bagi fungsi konveks.

Sekarang kita dapat membuktikan hasil penting pertama dalam optimisasi konveks.

**Proposisi 2.15.** Misalkan  $C \subset \mathbb{R}^d$  konveks,  $f : C \rightarrow \mathbb{R}$  konveks dan mempunyai perluasan yang terdiferensialkan secara kontinu pada suatu lingkungan terbuka dari  $C$ , serta  $x^* \in C$ . Jika  $\nabla f(x^*) = 0$ , maka  $x^*$  adalah peminimum **global**.

*Bukti.* Berdasarkan karakterisasi orde pertama kekonveksan,

$$f(x) \geq f(x^*) + \langle \nabla f(x^*), x - x^* \rangle = f(x^*) + 0. \quad (2.26)$$

□

Perhatikan bahwa kebalikan [teorema 2.15](#), yaitu implikasi

$$x^* \text{ adalah minimum} \Rightarrow \nabla f(x^*) = 0, \quad (2.27)$$

secara umum hanya benar apabila  $x^*$  berada di interior  $C$ , yang dinyatakan dengan  $C^\circ$ ; yaitu, terdapat  $\varepsilon > 0$  sedemikian sehingga  $B_\varepsilon(x^*) \subset C$ .

**Teorema 2.16.** Misalkan  $C \subset \mathbb{R}^d$  konveks,  $f : C \rightarrow \mathbb{R}$  konveks dan mempunyai perluasan yang terdiferensialkan secara kontinu pada suatu lingkungan terbuka dari  $C$ , serta  $x^* \in C^\circ$ . Maka  $\nabla f(x^*) = 0$  jika dan hanya jika  $x^*$  adalah peminimum global.

*Bukti.* Satu arah mengikuti [teorema 2.15](#). Untuk arah lainnya, andaikan  $x^*$  suatu minimum. Untuk setiap  $v \in \mathbb{R}^d$ , jika  $t > 0$  cukup kecil, optimalitas memberikan

$$f(x^* + tv) - f(x^*) \geq 0. \quad (2.28)$$

Karena  $t > 0$ , pembagian dengan  $t$  menghasilkan

$$\frac{f(x^* + tv) - f(x^*)}{t} \geq 0. \quad (2.29)$$

Dengan membiarkan  $t \rightarrow 0$ , diperoleh

$$\langle \nabla f(x^*), v \rangle \geq 0. \quad (2.30)$$

Karena  $v$  sembarang, argumen yang sama dapat diterapkan pada  $-v$ . Hasilnya

$$\langle \nabla f(x^*), v \rangle \leq 0.$$

Jadi  $\langle \nabla f(x^*), v \rangle = 0$  untuk setiap  $v$ , dan karenanya  $\nabla f(x^*) = 0$  (mengapa?). □

Dalam satu dimensi, jika suatu fungsi terdiferensialkan, kekonveksannya dapat dikarakterisasi melalui kemonotonan turunannya. Dalam dimensi sembarang berlaku hasil berikut.

**Teorema 2.17** (Kemonotonan gradien). Misalkan  $C \subset \mathbb{R}^d$  konveks dan  $f : C \rightarrow \mathbb{R}$  mempunyai perluasan yang terdiferensialkan secara kontinu pada suatu lingkungan terbuka dari  $C$ . Maka  $f$  konveks jika dan hanya jika, untuk setiap  $x, y \in C$ ,

$$\langle \nabla f(x) - \nabla f(y), x - y \rangle \geq 0. \quad (2.31)$$

*Bukti.*  $\Rightarrow$ : Andaikan  $f$  konveks. Berdasarkan karakterisasi orde pertama kekonveksan,

$$\begin{aligned} f(x) + \langle \nabla f(x), y - x \rangle &\leq f(y), \\ f(y) + \langle \nabla f(y), x - y \rangle &\leq f(x). \end{aligned} \quad (2.32)$$

Menjumlahkan kedua ketaksamaan memberikan hasil yang diinginkan.

$\Leftarrow$ : Andaikan  $\nabla f$  monoton. Berdasarkan teorema dasar kalkulus,

$$\begin{aligned} f(y) - f(x) &= \int_0^1 \frac{d}{dt} f(x + t(y - x)) dt \\ &= \int_0^1 \langle \nabla f(x + t(y - x)), y - x \rangle dt \\ &= \int_0^1 \langle \nabla f(x + t(y - x)) - \nabla f(x), y - x \rangle dt + \langle \nabla f(x), y - x \rangle \\ &= \int_0^1 \frac{1}{t} \underbrace{\langle \nabla f(x + t(y - x)) - \nabla f(x), t(y - x) \rangle}_{\geq 0} dt + \langle \nabla f(x), y - x \rangle \\ &\geq \langle \nabla f(x), y - x \rangle. \end{aligned} \quad (2.33)$$

Pada  $t = 0$ , integran dipahami melalui perpanjangan kontinu; ketaksamaan monoton digunakan untuk  $t \in (0, 1]$ .  $\square$

Terakhir, turunan kedua juga dapat digunakan untuk mengarakterisasi kekonveksan. Secara intuitif, kekonveksan berarti *kelengkungan positif*. Untuk memformalkan hal ini, ingat kembali cara mengurutkan matriks. Untuk dua matriks simetris  $A, B \in \mathbb{R}^{d \times d}$ , kita menuliskan

$$A \succeq B \iff \langle x, Ax \rangle \geq \langle x, Bx \rangle, \quad \forall x \in \mathbb{R}^d \quad (2.34)$$

dan, serupa dengan itu,

$$A \succ B \iff \langle x, Ax \rangle > \langle x, Bx \rangle, \quad \forall x \in \mathbb{R}^d \setminus \{0\}. \quad (2.35)$$

**Teorema 2.18** (Karakterisasi orde kedua kekonveksan). Misalkan  $C \subset \mathbb{R}^d$  terbuka dan konveks, serta  $f : C \rightarrow \mathbb{R}$  terdiferensialkan secara kontinu dua kali.

(i) Fungsi  $f$  konveks jika dan hanya jika  $\nabla^2 f(x) \succeq 0$  untuk setiap  $x \in C$ .

(ii) Jika  $\nabla^2 f(x) \succ 0$  untuk setiap  $x \in C$ , maka  $f$  konveks tegas.

*Bukti.* Kita membuktikan pernyataan pertama dan arah cukup pada pernyataan kedua.

$\Rightarrow$ : Andaikan  $f$  konveks. Berdasarkan kemonotonan gradien, untuk  $t > 0$  berlaku

$$\frac{\langle \nabla f(x + tv) - \nabla f(x), v \rangle}{t} \geq 0. \quad (2.36)$$

Dengan membiarkan  $t \rightarrow 0$ , diperoleh

$$\langle v, \nabla^2 f(x)v \rangle \geq 0. \quad (2.37)$$

Karena  $v$  sembarang, hasilnya mengikuti.

$\Leftarrow$ : Andaikan  $\nabla^2 f \succeq 0$ . Berdasarkan teorema dasar kalkulus,

$$\begin{aligned} \nabla f(y) - \nabla f(x) &= \int_0^1 \frac{d}{dt} \nabla f(x + t(y - x)) dt \\ &= \int_0^1 \nabla^2 f(x + t(y - x))(y - x) dt. \end{aligned} \quad (2.38)$$

Mengambil hasil kali dalam dengan  $y - x$  menghasilkan

$$\begin{aligned} \langle \nabla f(y) - \nabla f(x), y - x \rangle &= \int_0^1 \underbrace{\langle y - x, \nabla^2 f(x + t(y - x))(y - x) \rangle}_{\geq 0} dt \\ &\geq 0. \end{aligned} \quad (2.39)$$

Kemonotonan gradien kini menyiratkan kekonveksan. Untuk membuktikan bagian tegas, tuliskan  $d = y - x \neq 0$ . Jika Hessian positif definit pada setiap titik, maka

$$f(y) - f(x) - \langle \nabla f(x), d \rangle = \int_0^1 \int_0^t \langle d, \nabla^2 f(x + sd)d \rangle ds dt > 0.$$

Jadi ketaksamaan orde pertama berlaku tegas dan  $f$  konveks tegas.  $\square$

**Lema 2.19** (Operasi yang mempertahankan kekonveksan). Misalkan  $f, f_1, \dots, f_n : C \rightarrow \mathbb{R}$  konveks pada suatu himpunan konveks.

(i) Untuk setiap  $\alpha \geq 0$ , fungsi  $\alpha f$  konveks.

(ii) Fungsi  $\sum_i f_i$  konveks.

Bukti. Latihan.  $\square$

**Lema 2.20** (Operasi yang mempertahankan kekonveksan, lanjutan). Misalkan  $f : \mathbb{R}^n \supset C \rightarrow \mathbb{R}$  konveks,  $A \in \mathbb{R}^{n \times m}$ , dan  $b \in \mathbb{R}^n$ . Maka

$$g(x) = f(Ax + b) \quad (2.40)$$

konveks pada  $\{x \in \mathbb{R}^m \mid Ax + b \in C\}$ .

Bukti. Latihan.  $\square$

**Lema 2.21** (Operasi yang mempertahankan kekonveksan, lanjutan). Misalkan  $f : C \rightarrow \mathbb{R}$  konveks dan  $g : I \rightarrow \mathbb{R}$  konveks serta tak menurun, dengan  $I \subset \mathbb{R}$  suatu interval yang memenuhi  $f(C) \subset I$ . Maka  $g \circ f$  konveks.

Bukti. Latihan.  $\square$

**Contoh 2.22.** (i) Fungsi *log-sum-exp* bersifat konveks:

$$f(x) = \log \left( \sum_{i=1}^n e^{x_i} \right). \quad (2.41)$$

(ii) Fungsi kuadratik-per-linear

$$f(x) = \frac{x_1^2}{x_2} \quad (2.42)$$


konveks pada  $\mathbb{R} \times (0, \infty)$ .

(iii) Fungsi  $h(x) = e^{\|x\|^2}$  konveks pada  $\mathbb{R}^d$  karena  $f(x) = \|x\|^2$  konveks dan  $g(t) = e^t$  konveks serta tak menurun.

(iv) Pertimbangkan  $h(x) = (\|x\|^2 + 1)^2$  pada  $\mathbb{R}^d$ . Fungsi  $f(x) = \|x\|^2 + 1$  dan  $g(t) = t^2$  keduanya konveks. Fungsi  $g$  tidak tak menurun pada seluruh  $\mathbb{R}$ , tetapi tak menurun pada  $f(\mathbb{R}^d) = [1, \infty)$ . Akibatnya,  $h$  konveks.

(v) Pada contoh sebelumnya, jika  $f$  diganti dengan  $\|\cdot\|^2 - 1$ , maka  $g$  tidak tak menurun pada  $f(\mathbb{R}^d) = [-1, \infty)$ ; lihat Fig. 2.7.

**Deskripsi gambar.** Panel kiri menampilkan  $f_1(x) = x^2 + 1$  dan  $f_2(x) = x^2 - 1$ . Panel tengah menampilkan  $g(t) = t^2$  serta rentang kedua fungsi tersebut;  $g$  tak menurun pada rentang  $f_1$  tetapi tidak pada seluruh rentang  $f_2$ . Panel kanan memperlihatkan bahwa  $g \circ f_1$  konveks, sedangkan  $g \circ f_2$  memiliki lekukan tak konveks di sekitar titik asal.



Gambar 2.7: Kekonveksan komposisi fungsi.

**Lema 2.23** (Operasi yang mempertahankan kekonveksan, lanjutan). Misalkan  $f_i : C \rightarrow \mathbb{R}$ ,  $i = 1, \dots, n$ , konveks pada himpunan konveks  $C$ . Maka

$$f(x) = \max_{i=1, \dots, n} f_i(x) \quad (2.43)$$

konveks.

*Bukti.* Kita hitung langsung:

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) &= \max_i f_i(\lambda x + (1 - \lambda)y) \\ &\leq \max_i \{\lambda f_i(x) + (1 - \lambda)f_i(y)\} \\ &\leq \lambda \max_j f_j(x) + (1 - \lambda) \max_j f_j(y) \\ &= \lambda f(x) + (1 - \lambda)f(y). \end{aligned} \quad (2.44)$$

□

**Teorema 2.24.** Misalkan  $f : C \times D \rightarrow \mathbb{R}$  konveks pada  $C \times D$ , dengan  $C$  dan  $D$  keduanya konveks. Definisikan

$$g(x) = \inf_{y \in D} f(x, y), \quad (2.45)$$

dan andaikan infimum tersebut hingga untuk setiap  $x \in C$ . Maka  $g$  konveks.

*Bukti.* Pilih barisan  $y_n^x$  dan  $y_n^z$  sedemikian sehingga

$$g(x) = \lim_n f(x, y_n^x), \quad g(z) = \lim_n f(z, y_n^z). \quad (2.46)$$

Maka

$$\begin{aligned} g(\lambda x + (1 - \lambda)z) &\leq f(\lambda x + (1 - \lambda)z, \lambda y_n^x + (1 - \lambda)y_n^z) \\ &\leq \lambda f(x, y_n^x) + (1 - \lambda)f(z, y_n^z). \end{aligned} \quad (2.47)$$

Mengambil limit ketika  $n \rightarrow \infty$  menyelesaikan bukti. □

**Contoh 2.25.** Jarak suatu titik ke himpunan tak kosong dan konveks merupakan fungsi konveks. Jadi, untuk setiap himpunan tak kosong dan konveks  $C \subset \mathbb{R}^d$ , pemetaan berikut konveks:

$$x \mapsto d(x, C) := \inf_{y \in C} \|x - y\|. \quad (2.48)$$

**Teorema 2.26.** Misalkan  $C \subset \mathbb{R}^d$  konveks dan  $f : C \rightarrow \mathbb{R}$ . Maka  $f$  konveks jika dan hanya jika, untuk setiap  $x \in C$  dan  $v \in \mathbb{R}^d$ , fungsi

$$\begin{aligned} g : I_{x,v} &\rightarrow \mathbb{R}, \\ t &\mapsto g(t) = f(x + tv), \end{aligned} \quad (2.49)$$

konveks pada interval  $I_{x,v} := \{t \in \mathbb{R} \mid x + tv \in C\}$ .

*Bukti.*  $\Leftarrow$ : Andaikan  $g$  konveks untuk setiap  $x$  dan  $v$ . Misalkan  $x, y \in C$  dan  $\lambda \in (0, 1)$ . Pertimbangkan

$$g(t) = f(y + t(x - y)). \quad (2.50)$$

Karena  $g$  konveks pada interval yang memuat 0 dan 1,

$$\begin{aligned} f(\lambda x + (1 - \lambda)y) &= g(\lambda) = g(\lambda \cdot 1 + (1 - \lambda) \cdot 0) \\ &\leq \lambda g(1) + (1 - \lambda)g(0) \\ &= \lambda f(x) + (1 - \lambda)f(y). \end{aligned} \quad (2.51)$$

Arah sebaliknya ditinggalkan sebagai latihan.  $\square$

**Contoh 2.27** (Fungsi konveks yang umum). • Contoh pada  $\mathbb{R}$ :

– Fungsi konveks:

- \* Fungsi eksponensial  $f(x) = \exp(ax)$  pada  $\mathbb{R}$ , dengan  $a \in \mathbb{R}$ .
- \* Fungsi pangkat  $f(x) = x^p$  pada  $(0, \infty)$  untuk  $p \geq 1$  atau  $p \leq 0$ .
- \* Pangkat nilai mutlak  $f(x) = |x|^p$  pada  $\mathbb{R}$  untuk  $p \geq 1$ .
- \* Entropi negatif  $f(x) = x \log(x)$  pada  $(0, \infty)$ .

– Fungsi konkaf:

- \* Fungsi pangkat  $f(x) = x^p$  pada  $(0, \infty)$  untuk  $0 \leq p \leq 1$ .
- \* Logaritma  $f(x) = \log(x)$  pada  $(0, \infty)$ .

• Contoh pada ruang Euklides berdimensi hingga:

– Fungsi konveks:

- \* Norma- $p$ ,  $f(x) = \|x\|_p$ .
- \* Pangkat norma- $p$ ,  $f(x) = \|x\|_p^p$ , untuk  $1 \leq p < \infty$ .
- \* Kuadrat terkecil,  $f(x) = \frac{1}{2}\|Ax - b\|_2^2$ , dengan  $A \in \mathbb{R}^{m \times n}$  dan  $b \in \mathbb{R}^m$ .
- \* Maksimum fungsi-fungsi afin:

$$f(x) = \max\{\langle a_1, x \rangle + b_1, \dots, \langle a_m, x \rangle + b_m\},$$

dengan  $a_i \in \mathbb{R}^n$  dan  $b_i \in \mathbb{R}$ .

- \* Perspektif suatu fungsi,  $f(x, y) = yg(x/y)$ , dengan  $g : \mathbb{R}^n \rightarrow \mathbb{R}$  fungsi konveks,  $x \in \mathbb{R}^n$ , dan  $y \in (0, \infty)$ . Jadi domain perspektif ini adalah  $\mathbb{R}^n \times (0, \infty)$ .

– Fungsi konkaf:

- \* Minimum fungsi-fungsi afin:

$$f(x) = \min\{\langle a_1, x \rangle + b_1, \dots, \langle a_m, x \rangle + b_m\}.$$

• Contoh pada  $\mathbb{R}^{m \times n}$ :

– Fungsi konveks:

- \* Fungsi afin

$$f(X) = \text{tr}(A^T X) + b = \sum_{i=1}^m \sum_{j=1}^n A_{ij} X_{ij} + b$$

pada  $\mathbb{R}^{m \times n}$ , dengan  $A \in \mathbb{R}^{m \times n}$  dan  $b \in \mathbb{R}$ .

- \* Norma spektral  $f(X) = \|X\|_2 = \sigma_{\max}(X) = \sqrt{\lambda_{\max}(X^T X)}$ .
- \* Fungsi penghalang untuk matriks definit positif,  $f(X) = -\log \det X$  pada  $\mathbb{S}_{++}^n$ .

Serupa dengan hasil-hasil di atas, kita dapat menunjukkan karakterisasi kekonveksan kuat berikut.

**Teorema 2.28.** Misalkan  $f : C \rightarrow \mathbb{R}$ , dengan  $C \subset \mathbb{R}^d$  konveks, serta  $\mu > 0$ . Karakterisasi berikut berlaku:

- Fungsi  $f$  konveks kuat berparameter  $\mu$  jika dan hanya jika  $f - \frac{\mu}{2} \|\cdot\|^2$  konveks.
- Syarat orde pertama: jika  $f$  mempunyai perluasan yang terdiferensialkan secara kontinu pada suatu lingkungan terbuka dari  $C$ , maka  $f$  konveks kuat berparameter  $\mu$  jika dan hanya jika, untuk setiap  $x, y \in C$ ,

$$f(x) + \langle \nabla f(x), y - x \rangle \leq f(y) - \frac{\mu}{2} \|x - y\|^2.$$

- Syarat orde kedua: jika  $C$  terbuka dan  $f$  terdiferensialkan secara kontinu dua kali pada  $C$ , maka  $f$  konveks kuat berparameter  $\mu$  jika dan hanya jika, untuk setiap  $x \in C$ ,

$$\nabla^2 f(x) \succeq \mu I.$$

*Bukti.* Buktinya merupakan penyesuaian langsung dari bukti untuk kekonveksan biasa dan ditinggalkan sebagai latihan.  $\square$

## Bab 3

# Subgradien

Ingat kembali definisi turunan (Fréchet).

Sepanjang bab ini,  $X$  dan  $Y$  menyatakan ruang bernorma real; apabila gradien digunakan,  $X$  merupakan ruang Hilbert. Setiap kali  $V$  atau  $W$  muncul, keduanya menyatakan ruang bernorma real berdimensi hingga. Pada pasangan dual, argumen pertama selalu fungsional dan argumen kedua selalu vektor.

**Definisi 3.1** (Turunan Fréchet). Misalkan  $f : X \rightarrow Y$ . Fungsi  $f$  dikatakan terdiferensialkan (dalam arti Fréchet) di  $x \in X$  apabila terdapat pemetaan linear kontinu  $A : X \rightarrow Y$  sedemikian sehingga

$$\lim_{\|h\| \rightarrow 0} \frac{\|f(x+h) - f(x) - Ah\|}{\|h\|} = 0. \quad (3.1)$$

Kita menuliskan  $A = Df(x)$ .

**Definisi 3.2** (Gradien). Misalkan  $f : X \rightarrow \mathbb{R}$  terdiferensialkan dan  $X$  merupakan ruang Hilbert. Gradien  $f$  di titik  $x$ , yang dilambangkan dengan  $\nabla f(x)$ , adalah unsur tunggal di  $X$  sedemikian sehingga

$$Df(x)h = \langle \nabla f(x), h \rangle, \quad h \in X. \quad (3.2)$$

Keberadaan dan ketunggalan gradien merupakan akibat langsung dari teorema representasi Riesz, sebab  $Df(x) \in X^*$  apabila  $f$  bernilai real. Perhatikan pula bahwa **gradien bergantung pada hasil kali dalam yang dipilih**.

Walaupun definisi umum di atas mungkin tampak agak abstrak, gradien yang kita temui biasanya cukup sederhana. Secara khusus, apabila  $X = \mathbb{R}^d$  dilengkapi dengan hasil kali dalam Euklides baku, maka

$$\nabla f(x) = Df(x)^T, \quad (3.3)$$

yaitu, gradien hanyalah transpos dari turunannya.

Turunan dapat ditafsirkan sebagai hampiran linear terbaik terhadap fungsi di suatu titik, yakni

$$f(y) = f(x) + Df(x)(y - x) + o(\|y - x\|), \quad (3.4)$$

dengan  $o$  kecil menyatakan suatu suku yang meluruh *lebih cepat daripada laju linear*. Kebanyakan metode optimisasi dapat ditafsirkan sebagai proses berulang untuk meminimumkan hampiran fungsi yang lebih mudah. Akan tetapi, banyak fungsi penting tidak memiliki gradien dalam pengertian di atas. Sebagai contoh, kita mungkin ingin menyelesaikan persoalan

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \lambda \|Kx\|_1, \quad (3.5)$$

dengan  $A$  dan  $K$  linear. Persoalan komposit semacam ini sangat umum dalam pengolahan citra. Karena itu, kita dapat bertanya apakah terdapat gagasan hampiran linear yang lebih umum tetapi memiliki sifat serupa dengan gradien. Definisi berikut menjawab pertanyaan ini secara positif.

**Definisi 3.3** (Subdiferensial). Misalkan  $f : X \rightarrow (-\infty, \infty]$  dan  $x \in \text{dom}(f)$ . Kita menyebut  $g \in X^*$  sebagai *subgradien*  $f$  di  $x$  apabila

$$f(x) + \langle g, y - x \rangle \leq f(y), \quad \forall y \in X. \quad (3.6)$$

Subdiferensial  $\partial f(x)$  di  $x$  adalah himpunan semua subgradien di  $x$ , yakni

$$\partial f(x) = \{g \in X^* \mid f(x) + \langle g, y - x \rangle \leq f(y), \quad \forall y \in X\}. \quad (3.7)$$

Untuk  $x \notin \text{dom}(f)$ , kita menetapkan  $\partial f(x) = \emptyset$ .

Jadi, subdiferensial dapat saja kosong; menurut konvensi di atas, subdiferensial kosong di setiap titik  $x \in X$  dengan  $f(x) = \infty$ .

**Contoh 3.4.**

(i) Norma: Misalkan  $f = \|\cdot\|$ . Maka

$$\partial f(0) = \overline{B}_{\|\cdot\|,1}(0),$$

yaitu bola satuan untuk norma dual. Ingat bahwa norma dual  $\|\cdot\|_*$  didefinisikan oleh

$$\|y\|_* = \sup_{\|x\| \leq 1} |\langle y, x \rangle|.$$

Sebagai contoh, apabila  $f = \|\cdot\|_1$  pada  $\mathbb{R}^n$ , maka

$$\partial f(0) = \overline{B}_{\|\cdot\|_\infty,1}(0) = [-1, 1]^n.$$

(ii) Untuk suatu himpunan tak kosong  $S \subseteq X$  dan titik  $x \in S$ , tinjau fungsi indikator  $\delta_S$ . Subdiferensialnya adalah

$$\partial \delta_S(x) = \{y \in X^* : \langle y, z - x \rangle \leq 0, \quad \forall z \in S\} =: N_S(x),$$

yang disebut *kerucut normal*  $S$  di  $x$ . Subdiferensial fungsi indikator dari bola satuan adalah

$$N_{\overline{B}_{\|\cdot\|,1}(0)}(x) = \begin{cases} \{y \in X^* \mid \|y\|_* \leq \langle y, x \rangle\} & \text{jika } \|x\| \leq 1, \\ \emptyset & \text{jika } \|x\| > 1. \end{cases}$$

Kita perlu memastikan bahwa subdiferensial benar-benar memperumum gradien biasa.

**Lema 3.5.** Misalkan  $f : X \rightarrow \mathbb{R}$  konveks dan terdiferensialkan di  $x \in \text{dom}(f)^\circ$ , dengan  $X$  ruang Hilbert. Maka  $\partial f(x) = \{\nabla f(x)\}$ .

*Bukti.* Kita perlu menunjukkan (i)  $\nabla f(x) \in \partial f(x)$  dan (ii) jika  $g \in \partial f(x)$ , maka  $g = \nabla f(x)$ . Bagian (i) langsung mengikuti karakterisasi orde pertama untuk fungsi konveks terdiferensialkan, yang memberikan

$$f(x) + \langle \nabla f(x), y - x \rangle \leq f(y), \quad y \in X, \quad (3.8)$$


sehingga  $\nabla f(x) \in \partial f(x)$ . Untuk (ii), menurut definisi subgradien, bagi setiap  $g \in \partial f(x)$ ,  $h \in X$ , dan  $t > 0$  yang cukup kecil sehingga  $x + th \in \text{dom}(f)$ , berlaku

$$\langle g, h \rangle \leq \frac{f(x + th) - f(x)}{t}. \quad (3.9)$$

Dengan mengambil limit  $t \rightarrow 0$ , diperoleh  $\langle g, h \rangle \leq \langle \nabla f(x), h \rangle$ . Menerapkan ketaksamaan yang sama pada  $-h$  memberikan ketaksamaan sebaliknya. Karena itu  $\langle g, h \rangle = \langle \nabla f(x), h \rangle$  untuk setiap  $h$ , sehingga  $g = \nabla f(x)$ .  $\square$

Dalam dimensi hingga, kebalikannya juga berlaku bagi fungsi konveks yang hingga pada suatu lingkungan titik  $x$ : jika subdiferensial di  $x$  hanya terdiri atas satu unsur, maka  $f$  terdiferensialkan di  $x$  dan  $\partial f(x) = \{\nabla f(x)\}$ .

**Deskripsi gambar.** Panel kiri memperlihatkan parabola halus dan satu garis singgung putus-putus pada titik yang ditandai. Panel kanan memperlihatkan grafik berbentuk V untuk norma satu dimensi dan tiga garis pendukung dengan kemiringan berbeda yang semuanya melalui titik sudut yang ditandai. Label matematis pada kedua figur dipertahankan persis dari aset sumber.



**Gambar 3.1:** Kiri: gradien sebagai kemiringan garis singgung. Kanan: sebuah subgradien sebagai kemiringan garis pendukung.

### Contoh 3.6.

(i) Untuk  $f(x) = \|x\|_2$ , diperoleh

$$\partial f(x) = \begin{cases} \left\{ \frac{x}{\|x\|_2} \right\} & x \neq 0, \\ \overline{B}_{\|\cdot\|_2,1}(0) & \text{selain itu.} \end{cases}$$

(ii) Khususnya, untuk  $d = 1$  dan  $f(x) = |x|$ , diperoleh

$$\partial f(x) = \begin{cases} \{\text{sign}(x)\} & x \neq 0, \\ [-1, 1] & \text{selain itu.} \end{cases}$$

**Lema 3.7.** Jika domain  $f : X \rightarrow (-\infty, \infty]$  konveks dan subdiferensialnya tak kosong di setiap titik dalam domain, maka  $f$  konveks.

*Bukti.* Misalkan  $x, y \in \text{dom } f$ ,  $\lambda \in (0, 1)$ , dan  $g \in \partial f(x + \lambda(y - x))$ . Menurut definisi subdiferensial,

$$f(x + \lambda(y - x)) + \langle g, x - (x + \lambda(y - x)) \rangle \leq f(x), \quad (3.10)$$

$$f(x + \lambda(y - x)) + \langle g, y - (x + \lambda(y - x)) \rangle \leq f(y), \quad (3.11)$$

atau, setara dengan itu,

$$f(x + \lambda(y - x)) + \langle g, -\lambda(y - x) \rangle \leq f(x), \quad (3.12)$$

$$f(x + \lambda(y - x)) + \langle g, (1 - \lambda)(y - x) \rangle \leq f(y). \quad (3.13)$$

Dengan membagi ketaksamaan pertama oleh  $\lambda$ , membagi yang kedua oleh  $1 - \lambda$ , lalu menjumlahkannya, diperoleh

$$\frac{1}{\lambda} f(x + \lambda(y - x)) + \frac{1}{1 - \lambda} f(x + \lambda(y - x)) \leq \frac{1}{\lambda} f(x) + \frac{1}{1 - \lambda} f(y). \quad (3.14)$$

Mengalikan dengan  $\lambda(1 - \lambda)$  menghasilkan

$$f(x + \lambda(y - x)) \leq (1 - \lambda)f(x) + \lambda f(y), \quad (3.15)$$

sebagaimana yang diperlukan.  $\square$

Seperti disebutkan di atas, subdiferensial dapat kosong. Namun, bagi fungsi konveks berdimensi hingga kita mempunyai jaminan berikut.

Fungsi bernilai real diperluas disebut *sejati (proper)* apabila domain efektifnya tidak kosong dan fungsi itu tidak pernah bernilai minus tak hingga.

**Teorema 3.8.** Misalkan  $X$  ruang bernorma real berdimensi hingga dan  $f : X \rightarrow \overline{\mathbb{R}}$  sejati dan konveks. Maka  $\partial f(x) \neq \emptyset$  untuk setiap  $x \in \text{dom}(f)^\circ$ .

Sebelum membuktikan hasil ini, kita memerlukan beberapa persiapan.

**Lema 3.9.** *Interior suatu himpunan konveks adalah konveks.*

*Bukti.* Misalkan  $C$  konveks. Jika  $C^\circ = \emptyset$ , tidak ada yang perlu dibuktikan; jadi anggap  $C^\circ \neq \emptyset$ . Ambil  $x, y \in C^\circ$  dan  $\lambda \in (0, 1)$ . Kita perlu menunjukkan bahwa  $x_\lambda := \lambda x + (1 - \lambda)y \in C^\circ$ . Terdapat  $\varepsilon > 0$  sedemikian sehingga  $B_\varepsilon(x), B_\varepsilon(y) \subset C^\circ$ . Sekarang ambil  $z \in B_\varepsilon(x_\lambda)$ . Dengan demikian,  $z = x_\lambda + h$  untuk suatu  $\|h\| < \varepsilon$ . Kita dapat menuliskan

$$z = \lambda x + (1 - \lambda)y + h = \lambda(x + h) + (1 - \lambda)(y + h). \quad (3.16)$$

Karena  $x + h \in B_\varepsilon(x) \subset C$  dan  $y + h \in B_\varepsilon(y) \subset C$ , kekonveksan  $C$  memberikan  $z \in C$ . Jadi  $B_\varepsilon(x_\lambda) \subset C$  dan  $x_\lambda \in C^\circ$ .  $\square$

**Lema 3.10.** *Jika  $C \subset \mathbb{R}^d$ ,  $d \geq 1$  konveks dan  $C^\circ = \emptyset$ , maka terdapat hiperbidang  $H$  sedemikian sehingga  $C \subset H$ .*

*Bukti.* Jika  $C$  kosong, sembarang hiperbidang memenuhi kesimpulan. Selanjutnya anggap  $C$  tak kosong. Tanpa mengurangi keumuman, kita boleh menganggap  $0 \in C$ . Jika tidak, pilih sembarang  $x_0 \in C$  dan tinjau  $\tilde{C} = C - x_0$ ; pada akhir bukti, hiperbidang yang diperoleh ditranslasikan kembali.

Kita akan menunjukkan bahwa  $C$  merupakan himpunan bagian suatu subruang berdimensi paling besar  $d - 1$ . Andaikan sebaliknya bahwa  $C$  memuat  $d$  unsur yang bebas linear, yaitu terdapat  $x_1, \dots, x_d \in C$  yang bebas linear. Karena  $C$  konveks, selubung konveks

$$\text{conv}((x_i)_i) = \left\{ \sum_{i=1}^d \lambda_i x_i \mid \lambda \in \Delta^d \right\} \quad (3.17)$$

juga merupakan himpunan bagian  $C$ . Kita mengklaim bahwa  $x_\star := \frac{1}{2d} \sum_{i=1}^d x_i \in C^\circ$ . Pertama, dari kekonveksan,

$$x_\star = \frac{1}{2d} \sum_{i=1}^d x_i = \sum_{i=1}^d \frac{1}{2d} x_i + \frac{1}{2} 0 \in C.$$

Karena  $x_i$  bebas linear, setiap  $h \in \mathbb{R}^d$  dapat ditulis sebagai  $h = \sum_i \lambda_i x_i$ . Pemetaan  $\lambda \mapsto h$  adalah pemetaan linear bijektif  $\mathbb{R}^d \rightarrow \mathbb{R}^d$ . Oleh karena itu terdapat  $\varepsilon > 0$  sedemikian sehingga  $\|h\| < \varepsilon$  mengakibatkan  $|\lambda_i| < \frac{1}{2d}$  untuk semua  $i$ . Khususnya,  $\frac{1}{2d} + \lambda_i \in [0, 1]$  dan  $\sum_{i=1}^d (\frac{1}{2d} + \lambda_i) \in [0, 1]$ . Akibatnya, untuk setiap  $\|h\| < \varepsilon$ ,

$$x_\star + h = \sum_{i=1}^d \left( \frac{1}{2d} + \lambda_i \right) x_i + \left( 1 - \sum_{i=1}^d \left( \frac{1}{2d} + \lambda_i \right) \right) 0 \in C. \quad (3.18)$$

Jadi, apabila  $C$  memuat  $d$  unsur bebas linear, interiornya tidak mungkin kosong, sebab  $B_\varepsilon(x_\star) \subset C$ . Ini bertentangan dengan asumsi. Maka  $C$  memuat paling banyak  $d - 1$  unsur bebas linear. Pilih himpunan bebas linear maksimal  $x_1, \dots, x_k$  di dalam  $C$ ; maksimalitas memberikan

$$C \subset \text{span}\{x_i \mid i = 1, \dots, k\}.$$

Dimensi subruang ini kurang dari  $d$ , sehingga subruang tersebut termuat dalam suatu hiperbidang. Setelah translasi balik bila diperlukan, diperoleh hiperbidang afin yang memuat himpunan semula.  $\square$

Dengan kedua hasil sebelumnya, kita dapat membuktikan teorema hiperbidang pendukung.

**Teorema 3.11** (Teorema hiperbidang pendukung). *Misalkan  $V$  ruang bernorma real berdimensi hingga,  $C \subset V$  tak kosong dan konveks, serta  $x_0 \in \partial C = \overline{C} \setminus C^\circ$ . Maka terdapat  $a \in V^*$ ,  $a \neq 0$ , sedemikian sehingga*

$$\langle a, v \rangle \leq \langle a, x_0 \rangle, \quad v \in C. \quad (3.19)$$

*Bukti.* Hasil ini merupakan akibat teorema pemisahan Hahn–Banach. Kita membedakan dua kasus. Pertama, andaikan  $C^\circ \neq \emptyset$ . Himpunan  $C^\circ$  terbuka, konveks, dan tak kosong. Teorema pemisahan Hahn–Banach dapat diterapkan pada  $C^\circ$  dan  $\{x_0\}$ , sehingga ketaksamaan pendukung berlaku pada interior. Karena  $C \subset \overline{C^\circ}$  dan fungsional pemisah kontinu, ketaksamaan itu meluas ke seluruh  $C$ .

---

<sup>1</sup>yakni batas  $C$

Sebaliknya, jika  $C^\circ$  kosong, lema sebelumnya memberikan hiperbidang afin  $H$  yang memuat  $C$ . Karena  $H$  tertutup dan  $x_0 \in \bar{C}$ , hiperbidang ini juga memuat titik batas tersebut. Ambil  $a \in V^*$  yang tak nol dan  $b \in \mathbb{R}$  sedemikian sehingga

$$H = \{x \mid \langle a, x \rangle = b\}.$$

Fungsional  $a$  ini memenuhi (3.19). □

Sekarang kita dapat membuktikan keberadaan subgradien.

**Bukti teorema 3.8.** Kita ingin menunjukkan bahwa terdapat  $g \in X^*$  sedemikian sehingga

$$f(x) + \langle g, y - x \rangle \leq f(y) \quad (3.20)$$

untuk semua  $y \in X$ . Ini setara dengan

$$\langle g, y \rangle - f(y) \leq \langle g, x \rangle - f(x). \quad (3.21)$$

Bentuk ini menyerupai struktur pemisahan Hahn–Banach. Agar dapat menggunakannya, kita beralih ke epi-graf. Perhatikan bahwa  $(x, f(x)) \in \partial \text{epi}(f)$ . Selain itu, kekonveksan  $f$  mengakibatkan  $\text{epi}(f)$  konveks. Dengan menerapkan teorema hiperbidang pendukung, diperoleh unsur tak nol  $(g, -\alpha) \in (X \times \mathbb{R})^* = X^* \times \mathbb{R}$  sedemikian sehingga<sup>2</sup>

$$\langle (g, -\alpha), (y, t) \rangle \leq \langle (g, -\alpha), (x, f(x)) \rangle, \quad (y, t) \in \text{epi}(f). \quad (3.22)$$

Ini setara dengan

$$\langle g, y \rangle - \alpha t \leq \langle g, x \rangle - \alpha f(x), \quad (y, t) \in \text{epi}(f). \quad (3.23)$$

Kita akan menunjukkan bahwa  $\alpha > 0$ . Andaikan  $\alpha < 0$ . Karena  $(x, t) \in \text{epi}(f)$  untuk setiap  $t > f(x)$ , kita dapat membiarkan  $t \rightarrow \infty$  dan memperoleh kontradiksi. Berikutnya, andaikan  $\alpha = 0$ . Maka

$$\langle g, y - x \rangle \leq 0 \quad (3.24)$$

bagi semua  $y \in \text{dom}(f)$ . Karena  $x \in \text{dom}(f)^\circ$ , hal ini memaksa  $g = 0$ . Padahal teorema pemisahan menghasilkan unsur pemisah yang tak nol; sekali lagi kita memperoleh kontradiksi. Jadi  $\alpha > 0$ , dan kita dapat membagi (3.22) dengan  $\alpha$  untuk memperoleh

$$\langle \tilde{g}, y \rangle - t \leq \langle \tilde{g}, x \rangle - f(x), \quad (y, t) \in \text{epi}(f), \quad (3.25)$$

dengan  $\tilde{g} = g/\alpha$ . Memilih  $t = f(y)$  memberikan  $\tilde{g} \in \partial f(x)$ . □

Seperti pada turunan biasa, kita dapat menurunkan beberapa aturan hitung untuk memperoleh subgradien dalam praktik.

**Teorema 3.12.** Misalkan  $f : V \rightarrow \mathbb{R}$  sejati dan konveks serta  $\alpha \geq 0$ . Maka, untuk setiap  $x \in \text{dom}(f)$ ,

$$\partial(\alpha f)(x) = \alpha \partial f(x).$$

*Bukti.* Latihan. □

**Teorema 3.13.** Misalkan  $f, g : V \rightarrow \mathbb{R}$  sejati dan konveks. Untuk setiap  $x \in \text{dom}(f) \cap \text{dom}(g)$ , berlaku

$$\partial f(x) + \partial g(x) \subset \partial(f + g)(x).$$

Selain itu, jika terdapat  $x_0 \in \text{dom}(f)^\circ \cap \text{dom}(g)$ , maka

$$\partial f(x) + \partial g(x) = \partial(f + g)(x).$$

---

<sup>2</sup>Tanda minus pada  $-\alpha$  dipilih untuk memudahkan perhitungan.

*Bukti.* Kita hanya membuktikan inklusi pertama. Bukti arah kedua sedikit lebih rumit dan menggunakan teorema pemisahan Hahn–Banach dengan cara yang serupa dengan bukti keberadaan subgradien.

Ambil  $p_1 \in \partial f(x)$  dan  $p_2 \in \partial g(x)$ , yaitu

$$\begin{aligned} f(x) + \langle p_1, y - x \rangle &\leq f(y), \\ g(x) + \langle p_2, y - x \rangle &\leq g(y). \end{aligned} \quad (3.26)$$

Menjumlahkan kedua ketaksamaan memberikan

$$f(x) + g(x) + \langle p_1 + p_2, y - x \rangle \leq f(y) + g(y), \quad (3.27)$$

sehingga  $p_1 + p_2 \in \partial(f + g)(x)$ .  $\square$

Terakhir, kita mencatat beberapa *aturan hitung* subdiferensial tanpa bukti.

**Teorema 3.14.** Misalkan  $f : W \rightarrow \overline{\mathbb{R}}$  sejati, konveks, dan semikontinu bawah, serta  $A : V \rightarrow W$  transformasi linear. Definisikan  $h(x) = f(Ax + b)$  untuk  $b \in W$ . Bagi setiap  $x \in \text{dom}(h)$  berlaku aturan lemah

$$A^*(\partial f(Ax + b)) \subseteq \partial h(x).$$

Kesamaan berlaku apabila terdapat  $x_0 \in V$  dengan  $Ax_0 + b \in \text{dom}(f)^\circ$ .

Turunan komposisi fungsi-fungsi terdiferensialkan dihitung dengan aturan rantai. Jadi, turunan  $h(x) = g(f(x))$  adalah  $Dh(x) = Dg(f(x))Df(x)$ . Rumus ini dapat diperluas ke kalkulus subdiferensial.

**Teorema 3.15.** Misalkan  $f : V \rightarrow \mathbb{R}$  konveks,  $g : \mathbb{R} \rightarrow \mathbb{R}$  konveks dan tak menurun, serta  $h = g \circ f$ . Ambil  $x \in \text{dom}(f)^\circ$  dan andaikan  $g$  terdiferensialkan di  $f(x)$ . Maka

$$\partial h(x) = g'(f(x))\partial f(x).$$

**Teorema 3.16.** Misalkan  $f : V \rightarrow (-\infty, \infty]$  fungsi konveks sejati. Maka

$$x^* \in \arg \min_{x \in V} f(x)$$

jika dan hanya jika  $0 \in \partial f(x^*)$ .

*Bukti.* Pernyataan ini langsung mengikuti ketaksamaan subgradien

$$f(x) \geq f(x^*) + \langle 0, x - x^* \rangle$$

bagi setiap  $x \in \text{dom } f$ .  $\square$

**Teorema 3.17.** Misalkan  $f : V \rightarrow (-\infty, \infty]$  sejati dan konveks, serta  $C \subseteq V$  konveks dengan  $\text{dom}(f)^\circ \cap C^\circ \neq \emptyset$ . Titik  $x^* \in C$  merupakan solusi persoalan optimisasi berkendala jika dan hanya jika terdapat  $g \in \partial f(x^*)$  sedemikian sehingga

$$\langle g, x - x^* \rangle \geq 0$$

bagi semua  $x \in C$ .

## Bab 4

# Penurunan subgradien terproyeksi

Misalkan  $V$  ruang Hilbert real,  $C \subset V$  himpunan tak kosong, tertutup, dan konveks, serta  $f : V \rightarrow \mathbb{R}$  fungsi konveks. Kita tertarik menyelesaikan masalah

$$\min_{x \in C} f(x). \quad (4.1)$$

Kita mengasumsikan bahwa himpunan pemimin tidak kosong dan menetapkan  $x^* \in \arg \min_{x \in C} f(x)$ . Masalah berkendala di atas selalu dapat ditulis sebagai masalah tak berkendala melalui

$$\min_{x \in V} f(x) + \delta_C(x), \quad (4.2)$$

dengan  $\delta_C$  fungsi indikator himpunan  $C$ .<sup>1</sup>

Ingat kembali metode optimisasi numerik paling dasar untuk masalah semacam ini ketika  $C = V$  dan  $f$  terdiferensialkan: penurunan gradien (atau penurunan *tercuram*). Kita memilih nilai awal  $x_0$ , lalu untuk  $k = 0, 1, \dots$  melakukan pembaruan

$$x_{k+1} = x_k - \tau_k \nabla f(x_k), \quad (4.3)$$

dengan  $\tau_k > 0$  menyatakan ukuran langkah. Algoritma *baru* pertama yang kita tinjau ialah versi subgradien dari penurunan tercuram: untuk  $k = 0, 1, \dots$ ,

$$\begin{cases} g_k & \in \partial f(x_k), \\ x_{k+1} & = x_k - \tau_k g_k. \end{cases} \quad (4.4)$$

Jika  $C \neq V$ , masalah segera dapat muncul: mungkin saja  $x_{k+1} \notin C$ . Dalam hal itu, iterasi yang memakai subdiferensial  $f + \delta_C$  tidak lagi terdefinisi karena  $\partial \delta_C(x) = \emptyset$  untuk  $x \notin C$ . Karena itu, kita perlu memastikan setiap iterasi baru tetap berada di  $C$ ; untuk tujuan ini kita memakai *proyeksi*.

**Teorema 4.1** (Teorema proyeksi). *Misalkan  $V$  ruang Hilbert real dan  $C \subset V$  tak kosong, tertutup, dan konveks. Fungsi berikut terdefinisi dengan baik:*

$$\begin{aligned} \text{proj}_C : V &\rightarrow C, \\ x &\mapsto \arg \min_{y \in C} \|x - y\|. \end{aligned} \quad (4.5)$$

*Bukti.* Kita perlu menunjukkan bahwa minimum tercapai secara tunggal. Tetapkan  $d = \inf_{y \in C} \|y - x\|$ , dan ambil barisan pemimum  $(y_n)_n \subset C$ , yaitu

$$\lim_n \|y_n - x\| = d. \quad (4.6)$$

Karena  $C$  konveks,  $(y_n + y_m)/2 \in C$ . Identitas jajaran genjang memberi

$$\|y_n - y_m\|^2 = 2\|y_n - x\|^2 + 2\|y_m - x\|^2 - 4\left\|\frac{y_n + y_m}{2} - x\right\|^2 \leq 2\|y_n - x\|^2 + 2\|y_m - x\|^2 - 4d^2.$$

---

<sup>1</sup>Formulasi ini memakai  $f$  yang terdefinisi pada seluruh  $V$ , termasuk di luar  $C$ .

Ruas kanan menuju nol ketika  $m, n \rightarrow \infty$ , sehingga  $(y_n)_n$  merupakan barisan Cauchy. Kelengkapan  $V$  menghasilkan  $y_n \rightarrow \hat{y} \in V$ , sedangkan ketertutupan  $C$  menghasilkan  $\hat{y} \in C$ . Dari kontinuitas norma diperoleh

$$\|\hat{y} - x\| = \lim_n \|y_n - x\| = d, \quad (4.7)$$

jadi peminim memang ada.

Untuk ketunggalan, andaikan  $y_1 \neq y_2$  keduanya peminim. Identitas jajaran genjang memberikan

$$\begin{aligned} \left\| \frac{y_1 + y_2}{2} - x \right\|^2 &= \frac{1}{2} \|y_1 - x\|^2 + \frac{1}{2} \|y_2 - x\|^2 - \frac{1}{4} \|y_1 - y_2\|^2 \\ &< d^2. \end{aligned} \quad (4.8)$$

Namun  $(y_1 + y_2)/2 \in C$ , yang bertentangan dengan definisi  $d$ . Jadi peminimnya tunggal.  $\square$

Dengan proyeksi, kita memperoleh cara mengatasi masalah *keluar* dari  $C$ : metode subgradien terproyeksi. Pilih  $x_0 \in C$ ; kemudian, untuk  $k = 0, 1, \dots$  dan  $\tau_k \geq 0$ , tetapkan

$$\begin{cases} g_k & \in \partial f(x_k), \\ x_{k+1} &= \text{proj}_C(x_k - \tau_k g_k). \end{cases} \quad (4.9)$$

Untuk membuktikan konvergensi metode ini, kita memerlukan beberapa hasil bantu.

**Lema 4.2.** Misalkan  $V$  ruang Hilbert real dan  $C \subset V$  tak kosong, tertutup, dan konveks. Maka

$$\langle x - \text{proj}_C(x), y - \text{proj}_C(x) \rangle \leq 0, \quad y \in C. \quad (4.10)$$

Khususnya, jika  $C$  subruang,<sup>2</sup> maka

$$\langle x - \text{proj}_C(x), y \rangle = 0, \quad y \in C. \quad (4.11)$$

*Bukti.* Untuk setiap  $y \in C$ , kita mempunyai

$$\begin{aligned} \|\text{proj}_C(x) - x\|^2 &\leq \|y - x\|^2 \\ &= \|y - \text{proj}_C(x) + \text{proj}_C(x) - x\|^2 \\ &= \|y - \text{proj}_C(x)\|^2 + 2 \langle y - \text{proj}_C(x), \text{proj}_C(x) - x \rangle + \|\text{proj}_C(x) - x\|^2. \end{aligned} \quad (4.12)$$

Akibatnya,

$$0 \leq \|y - \text{proj}_C(x)\|^2 + 2 \langle y - \text{proj}_C(x), \text{proj}_C(x) - x \rangle. \quad (4.13)$$

Ambil sebarang  $z \in C$ , lalu pada ketaksamaan di atas masukkan  $y = \text{proj}_C(x) + t(z - \text{proj}_C(x))$  untuk  $t \in (0, 1)$ . Kita memperoleh

$$0 \leq t^2 \|z - \text{proj}_C(x)\|^2 + 2t \langle z - \text{proj}_C(x), \text{proj}_C(x) - x \rangle. \quad (4.14)$$

Setelah dibagi dengan  $t > 0$ ,

$$0 \leq t \|z - \text{proj}_C(x)\|^2 + 2 \langle z - \text{proj}_C(x), \text{proj}_C(x) - x \rangle. \quad (4.15)$$

Dengan mengambil limit  $t \rightarrow 0$ , kita memperoleh hasil yang diinginkan. Kesamaan untuk kasus subruang ditinggalkan sebagai latihan.  $\square$

**Proposisi 4.3.** Misalkan  $V$  ruang Hilbert real dan  $C \subset V$  tak kosong, tertutup, dan konveks. Proyeksi pada  $C$  bersifat tak ekspansif, yaitu kontinu Lipschitz dengan konstanta satu:

$$\|\text{proj}_C(x_1) - \text{proj}_C(x_2)\| \leq \|x_1 - x_2\|. \quad (4.16)$$

<sup>2</sup>Artinya,  $C$  memenuhi definisi ruang vektor.

*Bukti.* Tanpa mengurangi keumuman, andaikan  $\|\text{proj}_C(x_2) - \text{proj}_C(x_1)\|^2 \neq 0$ , sebab jika tidak, tidak ada yang perlu dibuktikan. Kita memperoleh

$$\begin{aligned}
\|\text{proj}_C(x_2) - \text{proj}_C(x_1)\|^2 &= \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 + x_1 - \text{proj}_C(x_1) \rangle \\
&= \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 \rangle \\
&\quad + \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_1 - \text{proj}_C(x_1) \rangle \\
&\leq \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_1 \rangle \\
&= \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), \text{proj}_C(x_2) - x_2 + x_2 - x_1 \rangle \\
&\leq \langle \text{proj}_C(x_1) - \text{proj}_C(x_2), x_2 - \text{proj}_C(x_2) \rangle \\
&\quad + \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_2 - x_1 \rangle \\
&\leq \langle \text{proj}_C(x_2) - \text{proj}_C(x_1), x_2 - x_1 \rangle \\
&\leq \|\text{proj}_C(x_2) - \text{proj}_C(x_1)\| \|x_2 - x_1\|.
\end{aligned} \tag{4.17}$$

Membagi dengan  $\|\text{proj}_C(x_2) - \text{proj}_C(x_1)\| \neq 0$  menghasilkan kesimpulan.  $\square$

**Lema 4.4** (Ketaksamaan fundamental metode subgradien terproyeksi). *Misalkan  $x^* \in \arg \min_{x \in C} f(x)$ , dan misalkan  $x_k$  adalah iterasi metode subgradien terproyeksi (4.9), dengan  $g_k \in \partial f(x_k)$  dan  $\tau_k \geq 0$ . Maka*

$$\|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2 - 2\tau_k(f(x_k) - f(x^*)) + \tau_k^2 \|g_k\|^2. \tag{4.18}$$

*Bukti.* Dari definisi subgradien,  $f(x_k) + \langle g_k, x^* - x_k \rangle \leq f(x^*)$ . Karena  $x^* \in C$ , kita mempunyai  $\text{proj}_C(x^*) = x^*$ . Ketakspansifan proyeksi lalu memberikan

$$\begin{aligned}
\|x_{k+1} - x^*\|^2 &= \|\text{proj}_C(x_k - \tau_k g_k) - \text{proj}_C(x^*)\|^2 \\
&\leq \|x_k - \tau_k g_k - x^*\|^2 \\
&= \|x_k - x^*\|^2 - 2\tau_k \langle g_k, x_k - x^* \rangle + \tau_k^2 \|g_k\|^2 \\
&\leq \|x_k - x^*\|^2 - 2\tau_k(f(x_k) - f(x^*)) + \tau_k^2 \|g_k\|^2.
\end{aligned} \tag{4.19}$$

$\square$

Hal yang wajar dilakukan sekarang ialah memakai hasil sebelumnya untuk menentukan ukuran langkah optimal. Lebih tepatnya, dengan meminimumkan ruas kanan (4.19) terhadap  $\tau_k$ , kita memperoleh

$$\tau_k = \frac{f(x_k) - f(x^*)}{\|g_k\|^2} \tag{4.20}$$

jika  $g_k \neq 0$ , dan kita menetapkan  $\tau_k = 0$  jika  $g_k = 0$ . Ukuran langkah ini disebut aturan ukuran langkah Polyak.

Sebagai latihan, buktikan bahwa jika fungsi konveks  $f : V \rightarrow \mathbb{R}$  bersifat  $L$ -Lipschitz secara global pada  $V$ , maka setiap  $g \in \partial f(x)$  memenuhi  $\|g\| \leq L$ . Pada hasil-hasil berikut, kita memakai langsung batas pada subgradien yang dipilih, sehingga juga mencakup situasi berkendala yang tidak memenuhi asumsi Lipschitz global tersebut.

**Teorema 4.5.** *Andaikan subgradien yang dipilih pada iterasi memenuhi  $\|g_k\| \leq L$ . Dengan aturan ukuran langkah Polyak*

$$\tau_k = \frac{f(x_k) - f(x^*)}{\|g_k\|^2} \quad \text{jika } g_k \neq 0, \quad \tau_k = 0 \quad \text{jika } g_k = 0. \tag{4.21}$$

*metode subgradien terproyeksi (4.9) memenuhi*

- (i)  $\|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2$ , dengan ketaksamaan ketat jika  $f(x_k) > f(x^*)$ ;
- (ii)  $f(x_k) \rightarrow f(x^*)$  ketika  $k \rightarrow \infty$ ; dan
- (iii)  $f_{\text{best}}^N - f(x^*) \leq \frac{L\|x_1 - x^*\|}{\sqrt{N}}$ , dengan  $f_{\text{best}}^N = \min_{k=1, \dots, N} f(x_k)$ .

*Bukti.* Tanpa mengurangi keumuman, kita boleh mengasumsikan  $f(x^*) = 0$ . Jika tidak, cukup tinjau  $\tilde{f}(x) := f(x) - f(x^*)$ . Dari [teorema 4.4](#) dan aturan ukuran langkah diperoleh

$$\begin{aligned}\|x_{k+1} - x^*\|^2 &\leq \|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 \|g_k\|^2 \\ &= \|x_k - x^*\|^2 - a_k,\end{aligned}\tag{4.22}$$

dengan  $a_k = f(x_k)^2 / \|g_k\|^2$  jika  $g_k \neq 0$ , dan nol jika  $g_k = 0$ . Jika  $g_k = 0$ , kekonveksan memberi  $f(x_k) = f(x^*)$ . Karena itu, pengurangan bersifat ketat tepat ketika celah nilai fungsi positif.

Dengan menata ulang dan menjumlahkan untuk  $k = 1, \dots, N$ , kita memperoleh

$$\sum_{k=1}^N a_k \leq \|x_1 - x^*\|^2 - \|x_{N+1} - x^*\|^2 \leq \|x_1 - x^*\|^2.\tag{4.23}$$

Karena  $\|g_k\| \leq L$ ,

$$\sum_{k=1}^N f(x_k)^2 \leq \sum_{k=1}^N L^2 a_k \leq L^2 \|x_1 - x^*\|^2.\tag{4.24}$$

Batas ini berlaku untuk setiap  $N$ , sehingga  $f(x_k) \rightarrow 0$ . Selain itu,

$$N(f_{\text{best}}^N)^2 \leq \sum_{k=1}^N f(x_k)^2 \leq L^2 \|x_1 - x^*\|^2,\tag{4.25}$$

yaitu

$$f_{\text{best}}^N \leq \frac{L \|x_1 - x^*\|}{\sqrt{N}}.\tag{4.26}$$

□

**Korolari 4.6.** Untuk mencapai ketelitian  $f_{\text{best}}^N - f(x^*) \leq \varepsilon$ , kita memerlukan

$$N = O\left(\frac{L^2 \|x_1 - x^*\|^2}{\varepsilon^2}\right)$$

iterasi.

**Catatan.** Ingat bahwa metode gradien mulus standar mencapai kompleksitas  $O(1/\varepsilon)$ .

Walaupun hasil konvergensi dengan aturan ukuran langkah Polyak menarik secara teoretis dan memberi batas kasus terburuk untuk iterasi terbaik, dalam praktiknya ukuran langkah tersebut tidak dapat dihitung tanpa mengetahui  $f(x^*)$ . Berikut ini kita berikan hasil konvergensi yang lebih umum.

**Teorema 4.7.** Andaikan subgradien yang dipilih memenuhi  $\|g_k\| \leq L$ , dan ukuran langkah  $\tau_k > 0$  memenuhi

$$\frac{\sum_{k=1}^n \tau_k}{\sum_{k=1}^n \tau_k^2} \rightarrow \infty \quad \text{ketika } n \rightarrow \infty.$$

Maka

$$f_{\text{best}}^n - f(x^*) \leq \frac{\|x_1 - x^*\|^2 + L^2 \sum_{k=1}^n \tau_k^2}{2 \sum_{k=1}^n \tau_k} \rightarrow 0.$$

*Bukti.* Sekali lagi, untuk menyederhanakan notasi, andaikan  $f(x^*) = 0$ . Dengan memakai  $\|g_k\| \leq L$  dan menjumlahkan ketaksamaan fundamental [teorema 4.4](#) untuk  $k = 1, \dots, n$ , kita memperoleh

$$2 \sum_{k=1}^n \tau_k f(x_k) \leq \|x_1 - x^*\|^2 + L^2 \sum_{k=1}^n \tau_k^2.\tag{4.27}$$

Tuliskan

$$\sigma_n = \frac{\sum_{k=1}^n \tau_k}{\sum_{k=1}^n \tau_k^2}.$$

Karena  $f_{\text{best}}^n \leq f(x_k)$ ,

$$f_{\text{best}}^n \leq \frac{\sum_{k=1}^n \tau_k f(x_k)}{\sum_{k=1}^n \tau_k} \leq \frac{\|x_1 - x^*\|^2}{2 \sum_{k=1}^n \tau_k} + \frac{L^2}{2\sigma_n}.\tag{4.28}$$

Hipotesis  $\sigma_n \rightarrow \infty$  juga memaksa  $\sum_{k=1}^n \tau_k \rightarrow \infty$ ; karena itu, kedua suku pada ruas kanan menuju nol. □

Varian hasil konvergensi juga dapat diperoleh, misalnya jika  $C$  kompak; lihat Beck 2017 untuk perinciannya.

Konvergensi dapat dipercepat dan juga *ditransfer* dari nilai fungsi ke iterasi  $(x_k)_k$  jika kita menambahkan asumsi bahwa  $f$  konveks kuat.

**Teorema 4.8.** *Andaikan  $f$  konveks kuat dengan parameter  $\mu > 0$  pada  $C$ , dan subgradien yang dipilih memenuhi  $\|g_k\| \leq L$ .<sup>3</sup> Mulai dari  $x_1 \in C$ , gunakan ukuran langkah  $\tau_k = \frac{2}{\mu k}$  untuk  $k \geq 1$ . Untuk  $n \geq 2$ , metode subgradien terproyeksi (4.9) memenuhi*

$$(i) \quad f_{\text{best}}^n - f(x^*) \leq \frac{2L^2}{\mu(n-1)}; \text{ dan}$$

$$(ii) \quad \|x_n - x^*\| \leq \frac{2L}{\mu\sqrt{n-1}}.$$

*Bukti.* Seperti sebelumnya, tanpa mengurangi keumuman, tetapkan  $f(x^*) = 0$ . Kekonveksan kuat memperbaiki ketaksamaan fundamental menjadi

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &\leq (1 - \mu\tau_k)\|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 \|g_k\|^2 \\ &\leq (1 - \mu\tau_k)\|x_k - x^*\|^2 - 2\tau_k f(x_k) + \tau_k^2 L^2. \end{aligned} \quad (4.29)$$

Dengan menata ulang dan membagi dengan  $2\tau_k$ , diperoleh

$$f(x_k) \leq -\frac{\tau_k^{-1}}{2}\|x_{k+1} - x^*\|^2 + \frac{\tau_k^{-1} - \mu}{2}\|x_k - x^*\|^2 + \frac{\tau_k}{2}L^2. \quad (4.30)$$

Memasukkan  $\tau_k = 2/(\mu k)$  menghasilkan

$$f(x_k) \leq -\frac{\mu k}{4}\|x_{k+1} - x^*\|^2 + \frac{\mu(k-2)}{4}\|x_k - x^*\|^2 + \frac{1}{\mu k}L^2. \quad (4.31)$$

Kalikan dengan  $k-1$ , lalu jumlahkan terhadap  $k = 1, \dots, n$ . Suku jarak meneleskop, sehingga

$$\sum_{k=1}^n (k-1)f(x_k) \leq -\frac{\mu n(n-1)}{4}\|x_{n+1} - x^*\|^2 + \frac{1}{\mu} \sum_{k=1}^n \frac{k-1}{k}L^2. \quad (4.32)$$

Karena  $\sum_{k=1}^n (k-1) = n(n-1)/2$  dan  $\sum_{k=1}^n (k-1)/k \leq n$ , kita memperoleh

$$\frac{n(n-1)}{2}f_{\text{best}}^n \leq \sum_{k=1}^n (k-1)f(x_k) \leq -\frac{\mu n(n-1)}{4}\|x_{n+1} - x^*\|^2 + \frac{nL^2}{\mu}. \quad (4.33)$$

Dengan membuang suku jarak yang tak positif, diperoleh

$$f_{\text{best}}^n \leq \frac{2L^2}{\mu(n-1)}. \quad (4.34)$$

Untuk batas iterasi, buang suku  $-2\tau_k f(x_k) \leq 0$  dari ketaksamaan fundamental yang diperbaiki. Dengan  $d_k = \|x_k - x^*\|$ ,

$$d_{k+1}^2 \leq \left(1 - \frac{2}{k}\right)d_k^2 + \frac{4L^2}{\mu^2 k^2}. \quad (4.35)$$

Untuk  $k = 1$ , ketaksamaan ini memberi  $d_2^2 \leq 4L^2/\mu^2$ . Jika  $d_k^2 \leq 4L^2/[\mu^2(k-1)]$ , substitusi pada relasi di atas memberikan

$$d_{k+1}^2 \leq \frac{4L^2}{\mu^2} \left( \frac{k-2}{k(k-1)} + \frac{1}{k^2} \right) \leq \frac{4L^2}{\mu^2 k}.$$

Induksi membuktikan  $\|x_n - x^*\| \leq 2L/[\mu\sqrt{n-1}]$  untuk setiap  $n \geq 2$ . □

---

<sup>3</sup>Batas ini dikenakan pada subgradien yang benar-benar dipilih oleh algoritma; batas tersebut tidak disimpulkan hanya dari sifat Lipschitz relatif pada  $C$ .

## Bab 5

# Metode gradien proksimal

Kita telah melihat dalam bukti (dan latihan praktis) bahwa metode subgradien tidak memberikan konvergensi yang ideal. Dalam kasus dasar atau terburuk, nilai fungsi berkonvergensi dengan orde  $O(1/\sqrt{k})$ , dan konvergensi memerlukan ukuran langkah yang mengecil. Dalam bab ini, kita akan memperkenalkan alternatif bagi subgradien (eksplisit) dalam optimisasi.

Perhatikan masalah tak berkendala

$$\min_x f(x), \quad (5.1)$$

dengan  $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$  proper, semikontinu bawah, dan konveks. Ingat pembaruan metode subgradien  $x_{k+1} = x_k - \tau_k g_k$ ,  $g_k \in \partial f(x_k)$ , atau, secara ekuivalen,  $x_{k+1} \in x_k - \tau_k \partial f(x_k)$ . Untuk  $\tau_k > 0$ , kita usulkan pembaruan implisit

$$x_{k+1} \in x_k - \tau_k \partial f(x_{k+1}). \quad (5.2)$$

Pada tahap ini belum jelas apakah metode tersebut terdefinisi dengan baik. Namun, jika memang terdefinisi, secara intuitif kestabilannya dapat membaik karena arah pembaruan dipilih dengan *melihat ke masa depan*. Gagasan ini selaras dengan kestabilan metode implisit untuk mendiskretkan persamaan diferensial (*bandingkan Euler implisit*).

Jika kita amati (5.2) lebih dekat, aturan itu dapat ditulis sebagai

$$0 \in \partial \left( \frac{1}{2} \| \cdot - x_k \|^2 + \tau_k f \right) (x_{k+1}), \quad (5.3)$$

yang merupakan kondisi optimalitas untuk

$$\min_x \frac{1}{2} \|x - x_k\|^2 + \tau_k f(x). \quad (5.4)$$

Hal ini membawa kita pada definisi berikut.

**Definisi 5.1** (Operator proksimal). Operator atau pemetaan proksimal dari  $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$  didefinisikan sebagai pemetaan

$$\begin{aligned} \text{prox}_f : \mathbb{R}^d &\rightarrow \mathbb{R}^d, \\ x &\mapsto \arg \min_{y \in \mathbb{R}^d} \frac{1}{2} \|y - x\|^2 + f(y). \end{aligned} \quad (5.5)$$

Kita biasanya menyebut  $\text{prox}_f$  sebagai ?proks?. Sebagai pemetaan bernilai himpunan, proks selalu dapat dituliskan; tetapi pemetaan itu baru berguna ketika  $\text{prox}_f(x) \neq \emptyset$ . Kita dapat membuktikan hasil berikut.

**Lema 5.2.** Misalkan  $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$  proper, konveks, dan semikontinu bawah. Pemetaan proksimal bernilai tunggal. Lebih lanjut,  $y = \text{prox}_f(x)$  jika dan hanya jika  $0 \in (y - x) + \partial f(y)$ .

**Catatan.** Berdasarkan karakterisasi  $0 \in (y - x) + \partial f(y)$ , kita sering menulis proks sebagai  $\text{prox}_f(x) = (\text{Id} + \partial f)^{-1}(x)$ .

*Bukti.* Demi kesederhanaan, andaikan  $\text{dom}(f)^\circ \neq \emptyset$ ; untuk kasus umum, lihat Beck 2017.

Ambil  $g \in \partial f(y_0)$  untuk suatu  $y_0 \in \text{dom}(f)^\circ$ . Kita mempunyai

$$f(y_0) + \langle g, y - y_0 \rangle + \frac{1}{2} \|x - y\|^2 \leq f(y) + \frac{1}{2} \|x - y\|^2. \quad (5.6)$$

Oleh karena itu (mengapa?), pemetaan  $y \mapsto f(y) + \frac{1}{2} \|x - y\|^2$  bersifat koersif. Pemetaan ini juga mewarisi sifat semikontinu bawah dan proper dari  $f$ . Dengan metode langsung untuk fungsi proper, semikontinu bawah, dan koersif di ruang berdimensi hingga, terdapat solusi bagi

$$\min_{y \in \mathbb{R}^d} \frac{1}{2} \|y - x\|^2 + f(y). \quad (5.7)$$

Untuk keunikan, definisikan  $q_x(y) = \frac{1}{2} \|y - x\|^2 + f(y)$  dan andaikan  $y_1 \neq y_2$  adalah dua peminim. Karena suku kuadrat konveks ketat dan  $f$  konveks, untuk  $\bar{y} = (y_1 + y_2)/2$  berlaku

$$\begin{aligned} q_x(\bar{y}) &< \frac{1}{2} (q_x(y_1) + q_x(y_2)) \\ &= \min_{y \in \mathbb{R}^d} q_x(y), \end{aligned} \quad (5.8)$$

sebuah kontradiksi. Pernyataan terakhir merupakan kondisi optimalitas bagi (5.7).  $\square$

Setelah mengetahui bahwa proks terdefinisi dengan baik, kita dapat mendefinisikan metode gradien proksimal. Secara khusus, perhatikan masalah

$$\min_{x \in \mathbb{R}^d} F(x) := f(x) + g(x), \quad (5.9)$$

dengan  $f$  konveks dan  $L$ -halus, yakni terdiferensialkan dengan gradien  $L$ -Lipschitz, sedangkan  $g$  proper, konveks, dan semikontinu bawah. Masalah semacam ini sering muncul dalam praktik dan mencakup masalah semula dengan mengambil  $f \equiv 0$ . Untuk  $k = 0, 1, \dots$ , metode gradien proksimal didefinisikan oleh

$$x_{k+1} = \text{prox}_{\tau_k g}(x_k - \tau_k \nabla f(x_k)). \quad (5.10)$$

Jadi, kita melakukan langkah gradien atau eksplisit terhadap  $f$ , lalu langkah proksimal atau implisit terhadap  $g$ .

Sebagai hasil sederhana pertama, kita menunjukkan bahwa titik tetap metode gradien proksimal tepat sama dengan titik optimal.

**Lema 5.3.** Untuk suatu  $\tau > 0$  yang tetap dan  $x \in \mathbb{R}^d$ , pernyataan berikut ekuivalen:

$$x = \text{prox}_{\tau g}(x - \tau \nabla f(x)) \iff 0 \in \partial(f + g)(x). \quad (5.11)$$

Dengan demikian,  $x$  adalah titik tetap jika dan hanya jika  $x$  menyelesaikan (5.9).

*Bukti.* Karakterisasi optimalitas proks memberikan ekuivalensi

$$x = \text{prox}_{\tau g}(x - \tau \nabla f(x)) \iff 0 \in \tau \nabla f(x) + \tau \partial g(x). \quad (5.12)$$

Karena  $\tau > 0$ , serta menurut aturan jumlah dan aturan skala untuk subdiferensial,

$$0 \in \tau(\nabla f(x) + \partial g(x)) \iff 0 \in \partial(f + g)(x). \quad (5.13)$$

Untuk fungsi konveks  $F = f + g$ , kondisi terakhir ekuivalen dengan optimalitas  $x$ .  $\square$

Selain proks, kita mendefinisikan selubung Moreau sebagai nilai infimum dari objektif yang digunakan untuk proks.

**Definisi 5.4** (Selubung Moreau). Misalkan  $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$  dan  $\tau > 0$ . Selubung Moreau  $M_f^\tau : \mathbb{R}^d \rightarrow [-\infty, \infty]$  didefinisikan oleh

$$M_f^\tau(x) := \inf_{y \in \mathbb{R}^d} \frac{1}{2\tau} \|x - y\|^2 + f(y). \quad (5.14)$$

**Lema 5.5.** Misalkan  $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$  proper, konveks, dan semikontinu bawah, serta  $\tau > 0$ . Selubung Moreau selalu bernilai real (yakni berhingga), dan

$$M_f^\tau(x) = \frac{1}{2\tau} \|x - \text{prox}_{\tau f}(x)\|^2 + f(\text{prox}_{\tau f}(x)). \quad (5.15)$$

*Bukti.* Latihan. Terapkan lemma keberadaan dan keunikan proks pada  $\tau f$ , lalu substitusikan peminim unik tersebut ke dalam definisi infimum.  $\square$

**Contoh 5.6.** Kita tinjau beberapa contoh pemetaan proksimal dan selubung Moreau yang sering muncul:

(i) Misalkan  $C \subset \mathbb{R}^d$  tak kosong, tertutup, dan konveks, dan perhatikan fungsi indikator  $\delta_C$ . Maka

$$\text{prox}_{\tau \delta_C}(x) = \text{proj}_C(x), \quad M_{\delta_C}^\tau(x) = \frac{1}{2\tau} \text{dist}(x, C)^2. \quad (5.16)$$

(ii) Secara khusus, jika  $C = \{x \in \mathbb{R}^d \mid \|x\|_\infty \leq 1\}$ , maka

$$(\text{prox}_{\tau \delta_C}(x))_i = \frac{x_i}{\max\{1, |x_i|\}}. \quad (5.17)$$

(iii) Jika  $f(x) = \|x\|_1$ , pemetaan proksimalnya adalah operator *ambang lunak*

$$(\text{prox}_{\tau f}(x))_i = \begin{cases} x_i - \tau & x_i > \tau, \\ x_i + \tau & x_i < -\tau, \\ 0 & x_i \in [-\tau, \tau]. \end{cases} \quad (5.18)$$

Untuk  $d = 1$ , selubung Moreau-nya tepat merupakan fungsi Huber

$$M_{|\cdot|}^\tau(x) = \begin{cases} \frac{|x|^2}{2\tau} & |x| \leq \tau, \\ |x| - \frac{\tau}{2} & |x| > \tau. \end{cases} \quad (5.19)$$

**Lema 5.7** (Aturan komputasi untuk proks). Misalkan semua fungsi dasar yang muncul di bawah proper, semikontinu bawah, dan konveks pada domain berdimensi hingga yang dinyatakan. Aturan berikut berlaku:

- (i) Jika  $x = (x_1, \dots, x_m) \in \mathbb{R}^{d_1} \times \dots \times \mathbb{R}^{d_m} \cong \mathbb{R}^d$ ,  $x_i \in \mathbb{R}^{d_i}$ ,  $\sum_i d_i = d$ , dan  $f(x) = \sum_i f_i(x_i)$ , maka  $\text{prox}_f(x) = (\text{prox}_{f_i}(x_i))_i$ .
- (ii) Jika  $f(x) = \alpha g(x) + b$  dengan  $\alpha > 0$  dan  $b \in \mathbb{R}$ , maka  $\text{prox}_f = \text{prox}_{\alpha g}$ .
- (iii) Jika  $f(x) = g(\alpha x + b)$  dengan  $\alpha \neq 0$  dan  $b \in \mathbb{R}^d$ , maka  $\text{prox}_f(x) = \alpha^{-1}(\text{prox}_{\alpha^2 g}(\alpha x + b) - b)$ .
- (iv) Jika  $f(x) = g(Qx)$  dengan  $Q \in \mathbb{R}^{d \times d}$  ortogonal, maka  $\text{prox}_f(x) = Q^\top \text{prox}_g(Qx)$ .
- (v) Jika  $f(x) = g(x) + \langle a, x \rangle + b$  dengan  $a \in \mathbb{R}^d$  dan  $b \in \mathbb{R}$ , maka  $\text{prox}_f(x) = \text{prox}_g(x - a)$ .
- (vi) Jika  $f(x) = g(x) + \frac{\gamma}{2} \|x - a\|^2$  dengan  $a \in \mathbb{R}^d$  dan  $\gamma \geq 0$ , maka  $\text{prox}_f(x) = \text{prox}_{\tilde{\gamma} g}(\tilde{\gamma} x + \gamma \tilde{\gamma} a)$ , dengan  $\tilde{\gamma} = (1 + \gamma)^{-1}$ .

Selubung Moreau memberikan efek penghalusan pada fungsi  $f$ , sebagaimana ditunjukkan oleh hasil berikut.

**Lema 5.8.** Misalkan  $f : \mathbb{R}^d \rightarrow (-\infty, \infty]$  proper, konveks, dan semikontinu bawah, serta  $\tau > 0$ . Selubung Moreau bersifat konveks dan terdiferensialkan. Gradiennya  $1/\tau$ -Lipschitz dan dapat ditulis sebagai

$$\nabla M_f^\tau(x) = \frac{1}{\tau} (x - \text{prox}_{\tau f}(x)). \quad (5.20)$$

*Bukti.* Untuk  $q(x, y) = \frac{1}{2\tau} \|x - y\|^2 + f(y)$ , fungsi  $q$  konveks secara bersama pada  $(x, y)$ . Jika  $p_i = \text{prox}_{\tau f}(x_i)$  dan  $t \in [0, 1]$ , evaluasi  $q$  di  $(tx_1 + (1-t)x_2, tp_1 + (1-t)p_2)$  menunjukkan bahwa  $M_f^\tau(tx_1 + (1-t)x_2) \leq tM_f^\tau(x_1) + (1-t)M_f^\tau(x_2)$ . Jadi, argumen ini tetap sah untuk fungsi  $f$  bernilai diperluas.

Tetapkan  $p(x) = \text{prox}_{\tau f}(x)$ . Dari definisi proks,

$$\begin{aligned} M_f^\tau(x+h) &= \frac{1}{2\tau} \|x+h-p(x+h)\|^2 + f(p(x+h)) \\ &\leq \frac{1}{2\tau} \|x+h-p(x)\|^2 + f(p(x)), \\ M_f^\tau(x) &= \frac{1}{2\tau} \|x-p(x)\|^2 + f(p(x)). \end{aligned} \quad (5.21)$$

Dengan mengurangi dua hubungan itu, kita memperoleh

$$\begin{aligned} M_f^\tau(x+h) - M_f^\tau(x) &\leq \frac{1}{2\tau} (\|x+h-p(x)\|^2 - \|x-p(x)\|^2) \\ &= \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle + \frac{1}{2\tau} \|h\|^2. \end{aligned} \quad (5.22)$$

Secara ekuivalen,

$$M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle \leq \frac{1}{2\tau} \|h\|^2. \quad (5.23)$$

Definisikan residu keterdiferensialan

$$r_x(h) := M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle. \quad (5.24)$$

Kurangkan dua kondisi optimalitas proks, lalu gunakan monotonisitas  $\partial f$  dan ketaksamaan Cauchy-Schwarz. Hasilnya ialah  $\|p(x) - p(y)\| \leq \|x - y\|$ , sehingga  $p$  tak ekspansif. Dengan mengevaluasi  $M_f^\tau(x)$  pada  $p(x+h)$ , kita juga mendapatkan

$$r_x(h) \geq \left\langle h, \frac{1}{\tau}(p(x) - p(x+h)) \right\rangle + \frac{1}{2\tau} \|h\|^2 \geq -\frac{1}{2\tau} \|h\|^2. \quad (5.25)$$

Secara keseluruhan,

$$\left| M_f^\tau(x+h) - M_f^\tau(x) - \left\langle h, \frac{1}{\tau}(x-p(x)) \right\rangle \right| \leq \frac{1}{2\tau} \|h\|^2. \quad (5.26)$$

Jadi,  $\nabla M_f^\tau(x) = \tau^{-1}(x - p(x))$ . Untuk membuktikan kekontinuan Lipschitz gradien, perhatikan bahwa

$$\begin{aligned} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\|^2 &= \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), (x-p(x)) - (y-p(y)) \right\rangle \\ &= \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), x-y \right\rangle \\ &\quad - \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), p(x) - p(y) \right\rangle. \end{aligned} \quad (5.27)$$

Kondisi optimalitas memberi  $\nabla M_f^\tau(x) = \tau^{-1}(x - p(x)) \in \partial f(p(x))$ . Karena itu, hasil kali dalam terakhir tidak negatif menurut monotonisitas subdiferensial, sehingga

$$\begin{aligned} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\|^2 &\leq \frac{1}{\tau} \left\langle \nabla M_f^\tau(x) - \nabla M_f^\tau(y), x-y \right\rangle \\ &\leq \frac{1}{\tau} \|\nabla M_f^\tau(x) - \nabla M_f^\tau(y)\| \|x-y\|. \end{aligned} \quad (5.28)$$

Setelah membagi dengan norma gradien yang berbeda dari nol (kasus nol langsung), diperoleh sifat  $1/\tau$ -Lipschitz.  $\square$

**Catatan.** Dengan representasi gradien selubung Moreau di atas, proks dapat ditulis kembali sebagai

$$\text{prox}_{\tau f}(x) = x - \tau \left( \frac{1}{\tau} (x - \text{prox}_{\tau f}(x)) \right) = x - \tau \nabla M_f^\tau(x). \quad (5.29)$$

Jadi, satu langkah proksimal ekuivalen dengan satu langkah gradien pada selubung Moreau.

**Contoh 5.9.** Untuk fungsi indikator himpunan tak kosong, tertutup, dan konveks  $C$ , rumusnya adalah  $\text{prox}_{\tau \delta_C}(x) = \text{proj}_C(x)$ . Untuk  $f(x) = \|x\|_1$ , setiap koordinat diberikan oleh ambang lunak  $(\text{prox}_{\tau f}(x))_i = \text{sign}(x_i) \max\{|x_i| - \tau, 0\}$ , dengan  $\text{sign}(0) = 0$ . Untuk  $f(x) = \|x\|_2$ , penyusutan Euklides adalah  $\text{prox}_{\tau f}(x) = (1 - \tau/\|x\|_2)_+ x$  jika  $x \neq 0$ , dan  $\text{prox}_{\tau f}(0) = 0$ . Verifikasikan ketiga rumus ini langsung dari kondisi optimalitas proks.

Sekarang kita akan membuktikan konvergensi metode gradien proksimal. Mula-mula kita turunkan lemma penting: untuk fungsi  $L$ -halus, galat antara fungsi dan hampiran linearnya dibatasi dari atas oleh suku kuadrat.

**Lema 5.10.** Misalkan  $F : \mathbb{R}^d \rightarrow \mathbb{R}$  terdiferensialkan kontinu dan gradiennya  $L$ -Lipschitz. Maka

$$F(y) \leq F(x) + \langle \nabla F(x), y - x \rangle + \frac{L}{2} \|y - x\|^2. \quad (5.30)$$

*Bukti.* Dari teorema dasar kalkulus dan sifat  $L$ -halus, kita mempunyai

$$\begin{aligned} F(y) - F(x) &= \int_0^1 \frac{d}{dt} F(x + t(y - x)) dt \\ &= \int_0^1 \langle \nabla F(x + t(y - x)), y - x \rangle dt \\ &= \int_0^1 \langle \nabla F(x + t(y - x)) - \nabla F(x), y - x \rangle dt + \int_0^1 \langle \nabla F(x), y - x \rangle dt \\ &\leq \int_0^1 L t \|y - x\|^2 dt + \langle \nabla F(x), y - x \rangle \\ &= \frac{L}{2} \|y - x\|^2 + \langle \nabla F(x), y - x \rangle. \end{aligned} \quad (5.31)$$

□

Untuk bukti konvergensi metode gradien proksimal, bagi  $\tau > 0$  kita perkenalkan notasi

$$T_\tau(x) = \frac{1}{\tau} (x - \text{prox}_{\tau g}(x - \tau \nabla f(x))). \quad (5.32)$$

Dengan fungsi ini, pembaruan gradien proksimal dapat ditulis sebagai

$$x_{k+1} = x_k - \tau_k T_{\tau_k}(x_k). \quad (5.33)$$

**Teorema 5.11.** Misalkan  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  konveks dan  $L$ -halus dengan  $L > 0$ , serta  $g : \mathbb{R}^d \rightarrow (-\infty, \infty]$  proper, semikontinu bawah, dan konveks. Andaikan  $\arg \min_x F(x) \neq \emptyset$  dan terdapat  $\tau_{\min} > 0$  sedemikian sehingga  $0 < \tau_{\min} \leq \tau_k \leq L^{-1}$  untuk semua  $k$ . Untuk setiap  $x^* \in \arg \min_x F(x)$ , algoritma gradien proksimal memenuhi

$$F(x_n) - F(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min} n} \quad (n \geq 1). \quad (5.34)$$

Selain itu,  $x_k$  berkonvergensi menuju suatu  $\hat{x} \in \arg \min_x F(x)$ .

*Bukti.* Dari definisi  $T_\tau$ , kita mempunyai

$$T_{\tau_k}(x_k) - \nabla f(x_k) \in \partial g(x_k - \tau_k T_{\tau_k}(x_k)) = \partial g(x_{k+1}). \quad (5.35)$$

Dengan memakai hubungan ini, kekonveksan  $f$ , Lemma 5.10, dan  $\tau_k \leq L^{-1}$ , untuk setiap  $z \in \mathbb{R}^d$  diperoleh

$$\begin{aligned}
 F(x_{k+1}) &\leq f(x_k) - \tau_k \langle \nabla f(x_k), T_{\tau_k}(x_k) \rangle + \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\
 &\quad + g(z) - \langle T_{\tau_k}(x_k) - \nabla f(x_k), z - (x_k - \tau_k T_{\tau_k}(x_k)) \rangle \\
 &\leq f(z) + g(z) - \langle \nabla f(x_k), z - x_k \rangle - \tau_k \langle \nabla f(x_k), T_{\tau_k}(x_k) \rangle + \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\
 &\quad - \langle T_{\tau_k}(x_k) - \nabla f(x_k), z - (x_k - \tau_k T_{\tau_k}(x_k)) \rangle \\
 &= F(z) - \langle T_{\tau_k}(x_k), z - x_k \rangle - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2.
 \end{aligned} \tag{5.36}$$

Dengan mengambil  $z = x_k$ , kita memperoleh

$$F(x_{k+1}) \leq F(x_k) - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2. \tag{5.37}$$

Jadi, nilai objektif tidak meningkat dan turun ketat kecuali jika  $T_{\tau_k}(x_k) = 0$ ; menurut lemma titik tetap, kasus terakhir berarti  $x_k$  optimal. Di sisi lain, ambil  $z = x^*$  dan gunakan  $T_{\tau_k}(x_k) = \tau_k^{-1}(x_k - x_{k+1})$ . Maka

$$\begin{aligned}
 0 \leq F(x_{k+1}) - F(x^*) &\leq \langle T_{\tau_k}(x_k), x_k - x^* \rangle - \frac{\tau_k}{2} \|T_{\tau_k}(x_k)\|^2 \\
 &= \frac{1}{2\tau_k} \left( 2 \langle x_k - x_{k+1}, x_k - x^* \rangle - \|x_k - x_{k+1}\|^2 \right) \\
 &= \frac{1}{2\tau_k} \left( \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \right).
 \end{aligned} \tag{5.38}$$

Khususnya,  $\|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \geq 0$ , sehingga jarak ke setiap peminim tidak meningkat. Dengan menjumlahkan untuk  $k = 0, \dots, n-1$ , kita memperoleh

$$\begin{aligned}
 \sum_{k=0}^{n-1} (F(x_{k+1}) - F(x^*)) &\leq \sum_{k=0}^{n-1} \frac{1}{2\tau_k} \left( \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \right) \\
 &\leq \frac{1}{2\tau_{\min}} \sum_{k=0}^{n-1} \left( \|x_k - x^*\|^2 - \|x_{k+1} - x^*\|^2 \right) \\
 &= \frac{1}{2\tau_{\min}} \left( \|x_0 - x^*\|^2 - \|x_n - x^*\|^2 \right).
 \end{aligned} \tag{5.39}$$

Karena  $F(x_k) - F(x^*)$  juga tidak meningkat,

$$n(F(x_n) - F(x^*)) \leq \sum_{k=0}^{n-1} (F(x_{k+1}) - F(x^*)) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min}}. \tag{5.40}$$

Jadi,

$$F(x_n) - F(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\tau_{\min} n}. \tag{5.41}$$

Terakhir, kita buktikan konvergensi  $(x_k)_k$ . Perhitungan di atas menunjukkan bahwa  $\|x_k - x^*\|$  tidak meningkat untuk setiap peminim  $x^*$ . Dengan demikian,  $(x_k)_k$  terbatas dan, di ruang berdimensi hingga, mempunyai subbarisan konvergen. Misalkan  $\hat{x} = \lim_j x_{n(j)}$  adalah suatu titik akumulasi. Karena  $F(x_k) \rightarrow \min F$  dan  $F = f + g$  semikontinu bawah,

$$F(\hat{x}) \leq \liminf_j F(x_{n(j)}) = \lim_k F(x_k) = \min F.$$

Jadi,  $\hat{x}$  adalah peminim dan  $\|x_k - \hat{x}\|$  tidak meningkat. Karena itu, terdapat  $c \geq 0$  dengan  $\|x_k - \hat{x}\| \rightarrow c$ . Namun,

$$c = \lim_k \|x_k - \hat{x}\| = \lim_j \|x_{n(j)} - \hat{x}\| = 0. \tag{5.42}$$

Maka seluruh barisan berkonvergensi ke  $\hat{x}$ , dan bukti selesai.  $\square$

## Bab 6

# Akselerasi

Untuk setiap  $L > 0$ , titik awal  $x_0 \in \mathbb{R}^d$ , bilangan bulat  $k \geq 1$ , dan  $d \geq 2k + 1$ , serta untuk setiap metode orde pertama yang iterasinya memenuhi

$$x_k \in x_0 + \text{span}\{\nabla f(x_0), \dots, \nabla f(x_{k-1})\} \quad (6.1)$$

terdapat fungsi konveks  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  yang bergradien  $L$ -Lipschitz dan mempunyai peminim  $x^*$ , sedemikian sehingga

$$f(x_k) - f(x^*) \geq \frac{3L\|x_0 - x^*\|^2}{32(k+1)^2}. \quad (6.2)$$

Perhatikan bahwa sejauh ini kita belum memperoleh laju konvergensi yang lebih baik daripada  $O(1/k)$ . Menutup kesenjangan menuju  $O(1/k^2)$  merupakan tujuan bab ini.

### 6.1 Metode bola berat Polyak

Penurunan gradien untuk meminimumkan masalah tak berkendala

$$\min_x f(x) \quad (6.3)$$

dapat ditafsirkan sebagai diskretisasi dari *aliran gradien*

$$\dot{x} = -\nabla f(x). \quad (6.4)$$

Jika fungsi  $f$  ditafsirkan sebagai potensial, maka  $-\nabla f$  merupakan gaya yang ditimbulkan potensial tersebut pada sebuah partikel bermassa satu. Secara alami kita dapat menambahkan gesekan ke dalam model ini. Gaya gesek biasanya dimodelkan sebanding dengan kecepatan, sehingga diperoleh

$$\ddot{x} = -\gamma\dot{x} - \nabla f(x). \quad (6.5)$$

Kita mendiskretkan persamaan diferensial biasa ini melalui  $\dot{x}(t) \approx \frac{x(t) - x(t-h)}{h}$  dan

$$\ddot{x}(t) \approx \frac{\dot{x}(t+h) - \dot{x}(t)}{h} \approx \frac{x(t+h) - 2x(t) + x(t-h)}{h^2}. \quad (6.6)$$

Dengan menamai  $x(t-h) = x_{k-1}$ ,  $x(t) = x_k$ , dan  $x(t+h) = x_{k+1}$ , substitusi ke dalam [Eq. \(6.5\)](#) memberikan

$$x_{k+1} - 2x_k + x_{k-1} = -h\gamma(x_k - x_{k-1}) - h^2\nabla f(x_k). \quad (6.7)$$

Setelah ditata ulang, pembaruannya menjadi

$$x_{k+1} = x_k + (1 - \gamma h)(x_k - x_{k-1}) - h^2\nabla f(x_k). \quad (6.8)$$

Dengan menamai ulang konstanta dan mengizinkannya bergantung pada iterasi, kita sampai pada *metode bola berat Polyak*

$$x_{k+1} = x_k + \beta_k(x_k - x_{k-1}) - \tau_k\nabla f(x_k). \quad (6.9)$$

Bahkan tanpa penurunan dari sudut pandang persamaan diferensial, aturan pembaruan ini cukup intuitif: selain arah penurunan bagi  $f$ , pembaruan tersebut memuat suku *inersia* yang menambahkan komponen searah dengan langkah sebelumnya.

Bukti konvergensi metode bola berat akan memakai hasil dasar aljabar linear berikut, yang disertakan demi kelengkapan.

**Lema 6.1.** Untuk setiap  $A \in \mathbb{R}^{d \times d}$ , dengan  $\|\cdot\|$  norma operator yang diinduksi oleh norma Euclidean, berlaku  $\lim_{n \rightarrow \infty} \|A^n\|^{1/n} = \rho(A)$ , dengan

$$\rho(A) = \max_i |\lambda_i(A)| \quad (6.10)$$

dan  $\lambda_i(A)$  nilai eigen  $A$ . Kesimpulan yang sama berlaku bagi setiap norma matriks yang kompatibel, karena semua norma pada ruang matriks berdimensi hingga ekuivalen.

*Bukti.* Kompleksifikasikan  $A$  ke operator pada  $\mathbb{C}^d$ . Norma operator Euclidean untuk matriks real sama pada  $\mathbb{R}^d$  dan  $\mathbb{C}^d$ . Ambil nilai eigen kompleks  $\lambda$  dengan  $|\lambda| = \rho(A)$  serta vektor eigennya  $v \in \mathbb{C}^d$  yang dinormalisasi. Maka

$$\|A^n\|^{1/n} \geq \|A^n v\|^{1/n} = |\lambda| = \rho(A), \quad (6.11)$$

sehingga  $\liminf_{n \rightarrow \infty} \|A^n\|^{1/n} \geq \rho(A)$ .

Untuk ketaksamaan sebaliknya, gunakan bentuk normal Jordan kompleks

$$A = BDB^{-1}. \quad (6.12)$$

Setelah blok-blok Jordan diurutkan, matriks  $D$  dapat ditulis sebagai

$$D = \begin{pmatrix} \lambda_1 & \varepsilon_1 & \dots & \dots \\ 0 & \lambda_2 & \varepsilon_2 & \dots \\ & & \ddots & \ddots \\ & & \dots & \lambda_{d-1} & \varepsilon_{d-1} \\ & & & 0 & \lambda_d \end{pmatrix}, \quad (6.13)$$

dengan  $\varepsilon_i \in \{0, 1\}$ , dan  $\varepsilon_i = 1$  hanya jika posisi  $i$  dan  $i + 1$  berada dalam blok Jordan yang sama sehingga  $\lambda_i = \lambda_{i+1}$ . Tuliskan  $D = \Lambda + N$ , dengan  $\Lambda$  diagonal dan  $N$  bagian nilpoten. Kedua matriks ini komutatif. Jika ukuran blok Jordan terbesar adalah  $m$ , maka  $N^m = 0$ . Untuk  $\rho(A) > 0$  dan  $n \geq m - 1$ , ekspansi binomial memberi

$$\begin{aligned} \|D^n\| &= \left\| \sum_{j=0}^{m-1} \binom{n}{j} \Lambda^{n-j} N^j \right\| \\ &\leq \sum_{j=0}^{m-1} \binom{n}{j} \|\Lambda^{n-j}\| \|N^j\| \\ &\leq C_\rho n^{m-1} \rho(A)^{n-m+1}, \end{aligned} \quad (6.14)$$

untuk suatu konstanta  $C_\rho > 0$  yang tidak bergantung pada  $n$ . Jika  $\rho(A) = 0$ , semua elemen diagonal nol, sehingga  $D = N$  dan  $D^n = 0$  bagi  $n \geq m$ ; jadi kesimpulan langsung berlaku. Untuk  $\rho(A) > 0$ , batas di atas menghasilkan

$$\|D^n\|^{1/n} \leq C_\rho^{1/n} n^{(m-1)/n} \rho(A)^{1-(m-1)/n}. \quad (6.15)$$

Karena  $C_\rho^{1/n} \rightarrow 1$ ,  $n^{1/n} \rightarrow 1$ , dan  $\rho(A)^{-(m-1)/n} \rightarrow 1$ , kita memperoleh

$$\limsup_{n \rightarrow \infty} \|D^n\|^{1/n} \leq \rho(A). \quad (6.16)$$

Akhirnya,

$$\limsup_{n \rightarrow \infty} \|A^n\|^{1/n} = \limsup_{n \rightarrow \infty} \|BD^n B^{-1}\|^{1/n} \leq \limsup_{n \rightarrow \infty} \|B\|^{1/n} \|D^n\|^{1/n} \|B^{-1}\|^{1/n} \leq \rho(A), \quad (6.17)$$

yang, bersama batas bawah, membuktikan hasilnya.  $\square$

**Korolari 6.2.** Berlaku  $\lim_{k \rightarrow \infty} A^k = 0$  jika dan hanya jika  $\rho(A) < 1$ . Selain itu, dalam hal ini, untuk setiap  $\varepsilon > 0$  terdapat  $c(\varepsilon) > 0$  sedemikian sehingga  $\|A^k\| \leq c(\varepsilon)(\rho(A) + \varepsilon)^k$ .

*Bukti.* Jika  $A^k \rightarrow 0$ , maka untuk setiap pasangan eigen kompleks  $(\lambda, v)$  berlaku  $A^k v = \lambda^k v \rightarrow 0$ ; akibatnya  $|\lambda| < 1$  dan  $\rho(A) < 1$ . Sebaliknya, jika  $\rho(A) < 1$ , pilih  $0 < \varepsilon_0 < 1 - \rho(A)$ . Berdasarkan [teorema 6.1](#), terdapat  $n$  sedemikian sehingga untuk  $k \geq n$ ,

$$\|A^k\| \leq (\rho(A) + \varepsilon_0)^k, \quad (6.18)$$

yang menuju nol. Untuk pernyataan kuantitatif dan sembarang  $\varepsilon > 0$ , [teorema 6.1](#) memberikan batas tersebut untuk semua  $k$  yang cukup besar. Dengan memperbesar konstanta untuk indeks awal yang berhingga banyaknya, kita dapat memilih

$$c(\varepsilon) \geq \max_{0 \leq k < n} \frac{\|A^k\|}{(\rho(A) + \varepsilon)^k}, \quad (6.19)$$

sehingga batas berlaku bagi setiap  $k \geq 0$ .  $\square$

Sekarang kita dapat membuktikan konvergensi metode bola berat. Tekniknya baku: kita menganalisis nilai eigen linearisasi aturan pembaruan.

**Teorema 6.3** (Konvergensi bola berat). *Misalkan  $f \in C^2(U)$  pada suatu lingkungan  $U \subset \mathbb{R}^d$  dari peminim stasioner lokal  $x^*$ , dengan*

$$\nabla f(x^*) = 0, \quad 0 < \mu \leq L, \quad \mu \text{Id} \preceq \nabla^2 f(x^*) \preceq L \text{Id}, \quad 0 \leq \beta < 1, \quad 0 < \tau < \frac{2(1+\beta)}{L}. \quad (6.20)$$

*Gunakan parameter konstan  $\beta_k = \beta$  dan  $\tau_k = \tau$ . Terdapat  $\varepsilon > 0$  sedemikian sehingga, jika  $x_0, x_1 \in B_\varepsilon(x^*)$ , maka  $x_k \rightarrow x^*$ . Lebih khusus, dengan*

$$q = \rho(\mathcal{H}) < 1, \quad \|x_k - x^*\| \leq c(\delta)(q + \delta)^{k-1} \|(x_1 - x^*, x_0 - x^*)\| \quad (6.21)$$

*untuk setiap  $0 < \delta < 1 - q$ . Jika yang diketahui tentang kurvatur hanya selang  $[\mu, L]$ , parameter yang meminimumkan radius spektral kasus terburuk dari model kuadratik atau linearisasi lokal adalah*

$$q_{\text{wc}} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}, \quad \tau = \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}, \quad \beta = \left( \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}} \right)^2. \quad (6.22)$$

*Bukti.* Tetapkan  $u_k = x_k - x^*$ . Karena  $\nabla f(x^*) = 0$ , rekursi kedalaman dua dapat ditulis tepat sebagai

$$\begin{aligned} \begin{bmatrix} u_{k+1} \\ u_k \end{bmatrix} &= \begin{bmatrix} (1+\beta)u_k - \beta u_{k-1} - \tau(\nabla f(x^* + u_k) - \nabla f(x^*)) \\ u_k \end{bmatrix} \\ &= \begin{pmatrix} (1+\beta) \text{Id} & -\beta \text{Id} \\ \text{Id} & 0 \end{pmatrix} \begin{bmatrix} u_k \\ u_{k-1} \end{bmatrix} - \tau(\nabla f(x^* + u_k) - \nabla f(x^*), 0). \end{aligned} \quad (6.23)$$

Untuk menyiapkan linearisasi, definisikan vektor keadaan dan matriks linear

$$s_k := \begin{bmatrix} u_k \\ u_{k-1} \end{bmatrix}, \quad \mathcal{H} := \begin{pmatrix} (1+\beta) \text{Id} - \tau \nabla^2 f(x^*) & -\beta \text{Id} \\ \text{Id} & 0 \end{pmatrix}, \quad s_{k+1} := \begin{bmatrix} u_{k+1} \\ u_k \end{bmatrix}. \quad (6.24)$$

Teorema dasar kalkulus memberikan

$$\begin{aligned} \nabla f(x^* + u_k) - \nabla f(x^*) &= \int_0^1 \nabla^2 f(x^* + tu_k) u_k \, dt \\ &= \nabla^2 f(x^*) u_k + r_k, \quad r_k := \left[ \int_0^1 (\nabla^2 f(x^* + tu_k) - \nabla^2 f(x^*)) \, dt \right] u_k. \end{aligned} \quad (6.25)$$

Dengan demikian, rekursi keadaan yang tepat ialah

$$\begin{bmatrix} u_{k+1} \\ u_k \end{bmatrix} = \underbrace{\begin{pmatrix} (1+\beta) \text{Id} - \tau \nabla^2 f(x^*) & -\beta \text{Id} \\ \text{Id} & 0 \end{pmatrix}}_{\mathcal{H}} \begin{bmatrix} u_k \\ u_{k-1} \end{bmatrix} + \begin{bmatrix} -\tau r_k \\ 0 \end{bmatrix}. \quad (6.26)$$

Kontinuitas Hessian menunjukkan  $r_k = o(\|u_k\|)$  ketika  $u_k \rightarrow 0$ .

Berdasarkan [teorema 6.2](#), kita menganalisis nilai eigen  $\mathcal{H}$ . Jika  $(v, w)$  merupakan vektor eigen dengan nilai eigen  $\lambda$ , maka

$$\begin{cases} ((1 + \beta) \text{Id} - \tau \nabla^2 f(x^*))v - \beta w &= \lambda v, \\ v &= \lambda w. \end{cases} \quad (6.27)$$

Dengan menghitung determinan blok, atau mengeliminasi relasi di atas tanpa pernah membagi dengan  $\lambda$ , setiap nilai eigen berkaitan dengan suatu  $\eta \in [\mu, L]$  dan memenuhi

$$p_\eta(\lambda) := \lambda^2 - (1 + \beta - \tau\eta)\lambda + \beta = 0. \quad (6.28)$$

Jadi, dengan  $a_\eta = 1 + \beta - \tau\eta$ , penyempurnaan kuadrat memberikan

$$\left(\lambda - \frac{a_\eta}{2}\right)^2 = \left(\frac{a_\eta}{2}\right)^2 - \beta. \quad (6.29)$$

Akar dalam (6.29) berada ketat di dalam lingkaran satuan jika dan hanya jika kriteria Schur–Jury untuk polinom monik kuadrat real berikut terpenuhi:

$$|\beta| < 1, \quad 1 - a_\eta + \beta > 0, \quad 1 + a_\eta + \beta > 0, \quad \iff \quad \beta < 1, \quad \tau\eta > 0, \quad \tau\eta < 2(1 + \beta). \quad (6.30)$$

Hipotesis teorema memenuhi syarat ini bagi semua  $\eta \in [\mu, L]$ , termasuk kasus  $\beta = 0$ ; oleh sebab itu  $q = \rho(\mathcal{H}) < 1$ .

Ambil  $0 < \delta < 1 - q$ . Terdapat norma ekuivalen  $\|\cdot\|_\delta$  pada  $\mathbb{R}^{2d}$  yang norma operator terinduksinya memenuhi  $\|\mathcal{H}\|_\delta \leq q + \delta/2$ . Karena  $r(u) = o(\|u\|)$  dan semua norma berdimensi hingga ekuivalen, lingkungan  $x^*$  dapat diperkecil sehingga suku gangguan memenuhi batas yang diperlukan. Maka rekursi keadaan menghasilkan

$$\|s_{k+1}\|_\delta \leq \|\mathcal{H}\|_\delta \|s_k\|_\delta + \|(-\tau r_k, 0)\|_\delta \leq (q + \delta) \|s_k\|_\delta, \quad \|s_k\|_\delta \leq (q + \delta)^{k-1} \|s_1\|_\delta. \quad (6.31)$$

Dengan memilih  $x_0, x_1$  cukup dekat ke  $x^*$ , bola kecil yang digunakan di atas tetap invarian. Ekuivalensi norma lalu memberikan estimasi dalam pernyataan teorema dan konvergensi lokal.

Tinggal membuktikan optimalitas kasus terburuk yang dinyatakan. Kasus  $L = \mu$  langsung: pilihan  $\beta = 0$  dan  $\tau = 1/L$  membuat  $a_\eta = 0$  dan kedua akar nol. Sekarang andaikan  $L > \mu$ . Untuk setiap radius kasus terburuk yang diklaim  $r > 0$ , kasus  $r \geq 1$  tidak dapat memperbaiki laju yang akan diperoleh, jadi cukup tinjau  $0 < r < 1$ . Terapkan kriteria Schur–Jury setelah penskalaan  $\lambda = rz$ . Agar kedua akar setiap polinom  $p_\eta$  bermodulus paling besar  $r$ , perlu  $0 \leq \beta \leq r^2$  dan  $|a_\mu|, |a_L| \leq R$ , dengan  $R := r + \beta/r$ .

Tetapkan  $h = (L - \mu)/(L + \mu)$ . Karena  $La_\mu - \mu a_L = (L - \mu)(1 + \beta)$ , kelayakan kedua titik ujung mengharuskan  $R \geq h(1 + \beta)$ . Selisih  $R - h(1 + \beta) = r - h + \beta(1/r - h)$  meningkat terhadap  $\beta$  pada  $0 \leq \beta \leq r^2$ , sebab  $0 < r < 1$  dan  $0 < h < 1$ . Oleh karena itu, bahkan nilai maksimumnya harus tak negatif:  $2r - h(1 + r^2) \geq 0$ . Jadi  $2r \geq h(1 + r^2)$ , yang pada  $0 < r < 1$  ekuivalen dengan  $r \geq (\sqrt{L} - \sqrt{\mu})/(\sqrt{L} + \sqrt{\mu})$ .

Kesamaan memaksa  $\beta = r^2$  serta  $a_\mu = 2r$  dan  $a_L = -2r$ . Menyelesaikan kedua hubungan ujung tersebut menghasilkan

$$\begin{aligned} 1 + \beta - \tau\mu &= 2\sqrt{\beta}, & 1 + \beta - \tau L &= -2\sqrt{\beta} \\ \implies \sqrt{\beta} &= q_{\text{wc}} = \frac{\sqrt{L} - \sqrt{\mu}}{\sqrt{L} + \sqrt{\mu}}, & \tau &= \frac{4}{(\sqrt{L} + \sqrt{\mu})^2}. \end{aligned} \quad (6.32)$$

Dengan pilihan ini,  $a_\eta$  bergerak linear dari  $2q_{\text{wc}}$  ke  $-2q_{\text{wc}}$ , sehingga semua akar untuk  $\eta \in [\mu, L]$  bermodulus paling besar  $q_{\text{wc}}$ . Batas bawah di atas membuktikan bahwa nilai maksimum tersebut tidak dapat diperkecil. Optimalitas ini merupakan optimalitas radius spektral kasus terburuk bagi fungsi kuadratik dan bagi model asimtotik lokal  $C^2$ , bukan jaminan konvergensi global bagi semua fungsi konveks mulus.  $\square$

**Latihan verifikasi.** Verifikasikan kriteria Schur–Jury di atas langsung dari rumus akar, termasuk kasus  $\beta = 0$ , dan turunkan kembali parameter kasus terburuk dengan menyamakan perilaku pada  $\eta = \mu$  dan  $\eta = L$ .

## 6.2 Akselerasi Nesterov

Metode Polyak optimal dalam arti radius spektral kasus terburuk bagi fungsi kuadrat konveks kuat, dan secara lokal bagi model  $C^2$  di sekitar peminim. Akselerasi berikut mencapai laju orde optimal di bawah asumsi global yang lebih lemah. Kita kembali meninjau masalah

$$\min_{x \in \mathbb{R}^d} F(x) := f(x) + g(x), \quad (6.33)$$

dengan  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  konveks, terdiferensialkan, dan bergradien  $L$ -Lipschitz untuk  $L > 0$ , sedangkan  $g : \mathbb{R}^d \rightarrow (-\infty, \infty]$  proper, semikontinu bawah, dan konveks. Andaikan  $\arg \min F \neq \emptyset$ . Dengan  $x_0 = x_1$ ,  $t_1 = 1$ , ukuran langkah tetap  $0 < \tau \leq 1/L$ , dan  $k = 1, 2, \dots$ , pembaruan *fast iterative shrinkage-thresholding algorithm* (FISTA, atau metode gradien proksimal cepat) ialah

$$\begin{cases} t_{k+1} &= \frac{1 + \sqrt{1 + 4t_k^2}}{2}, \\ \beta_k &= \frac{t_k - 1}{t_{k+1}}, \\ y_k &= x_k + \beta_k(x_k - x_{k-1}), \\ x_{k+1} &= \text{prox}_{\tau g}(y_k - \tau \nabla f(y_k)). \end{cases} \quad (6.34)$$

Jika  $g \equiv 0$ , metode ini sangat mirip dengan algoritma bola berat. Namun, gradien kini dievaluasi setelah suku inersia ditambahkan, dan konvergensinya bergantung pada pemilihan adaptif parameter inersia yang cermat.

**Lema 6.4.** Tetapkan  $t_1 = 1$ . Maka

$$t_k \geq \frac{k+1}{2} \quad (6.35)$$

untuk setiap  $k \geq 1$ .

*Bukti.* Bukti mengikuti induksi langsung. Pernyataan benar untuk  $k = 1$ . Dengan memakai hipotesis induksi, kita memperoleh

$$t_{k+1} = \frac{1 + \sqrt{1 + 4t_k^2}}{2} \geq \frac{1 + \sqrt{1 + (k+1)^2}}{2} \geq \frac{k+2}{2}. \quad (6.36)$$

□

**Lema 6.5** (Ketaksamaan fundamental gradien proksimal). *Definisikan*

$$P_\tau(x) = \text{prox}_{\tau g}(x - \tau \nabla f(x)). \quad (6.37)$$

Di bawah hipotesis komposit di atas, untuk setiap  $x, y \in \mathbb{R}^d$  dan  $0 < \tau \leq 1/L$ , berlaku

$$F(x) - F(P_\tau(y)) \geq \frac{1}{2\tau} \|x - P_\tau(y)\|^2 - \frac{1}{2\tau} \|x - y\|^2 + \ell_f(x, y), \quad (6.38)$$

dengan  $\ell_f(x, y) = f(x) - f(y) - \langle x - y, \nabla f(y) \rangle$ .

*Bukti.* Pertama, kita dapat menulis

$$\begin{aligned} P_\tau(y) &= \arg \min_z \frac{1}{2\tau} \|z - (y - \tau \nabla f(y))\|^2 + g(z) \\ &= \arg \min_z f(y) + \langle z - y, \nabla f(y) \rangle + \frac{1}{2\tau} \|z - y\|^2 + g(z). \end{aligned} \quad (6.39)$$

Sebagai catatan, identitas ini menunjukkan bahwa metode gradien proksimal dapat ditafsirkan sebagai langkah proksimal terhadap  $g$  ditambah pendekatan linear terhadap  $f$ . Definiskan

$$\varphi(z) = f(y) + \langle z - y, \nabla f(y) \rangle + \frac{1}{2\tau} \|z - y\|^2 + g(z). \quad (6.40)$$

Karena  $g$  konveks,  $\varphi$  bersifat  $1/\tau$ -konveks kuat. Oleh karena itu,

$$\varphi(x) - \varphi(P_\tau(y)) \geq \frac{1}{2\tau} \|x - P_\tau(y)\|^2. \quad (6.41)$$

Lebih lanjut, karena  $f$  konveks dan  $L$ -halus serta  $1/\tau \geq L$ , lema penurunan memberikan

$$f(z) \leq f(y) + \langle z - y, \nabla f(y) \rangle + \frac{L}{2} \|z - y\|^2 \leq f(y) + \langle z - y, \nabla f(y) \rangle + \frac{1}{2\tau} \|z - y\|^2. \quad (6.42)$$

Khususnya,  $\varphi(P_\tau(y)) \geq F(P_\tau(y))$ , sehingga

$$\varphi(x) - F(P_\tau(y)) \geq \frac{1}{2\tau} \|x - P_\tau(y)\|^2. \quad (6.43)$$

Dengan memasukkan definisi  $\varphi$  dan memakai  $f(y) + \langle x - y, \nabla f(y) \rangle = f(x) - \ell_f(x, y)$ , penataan ulang hubungan terakhir tepat memberikan

$$F(x) - F(P_\tau(y)) \geq \frac{1}{2\tau} \|x - P_\tau(y)\|^2 - \frac{1}{2\tau} \|x - y\|^2 + \ell_f(x, y), \quad (6.44)$$

dan bukti selesai.  $\square$

**Teorema 6.6** (Konvergensi FISTA). Misalkan  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  konveks, terdiferensialkan, dan bergradien  $L$ -Lipschitz dengan  $L > 0$ ; misalkan  $g : \mathbb{R}^d \rightarrow (-\infty, \infty]$  proper, semikontinu bawah, dan konveks; serta ambil  $x^* \in \arg \min F$ . Inisialisasikan FISTA dengan  $x_0 = x_1$ ,  $t_1 = 1$ , dan ukuran langkah tetap  $0 < \tau \leq 1/L$ . Untuk setiap  $k \geq 2$ ,

$$F(x_k) - F(x^*) \leq \frac{C}{\tau k^2}, \quad C = 2 \left( t_2^2 \|x^* - x_1\|^2 + \|t_2(x^* - x_2) + (t_2 - 1)(x_1 - x^*)\|^2 \right). \quad (6.45)$$

*Bukti.* Pilih  $x = t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k$  dan  $y = y_k$  dalam ketaksamaan fundamental gradien proksimal. Karena  $f$  konveks,  $\ell_f(x, y) \geq 0$ . Maka

$$\begin{aligned} & F(t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k) - F(x_{k+1}) \\ & \geq \frac{1}{2\tau} \|t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k - x_{k+1}\|^2 \\ & \quad - \frac{1}{2\tau} \|t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k - y_k\|^2 \\ & = \frac{1}{2\tau t_{k+1}^2} \|x^* + (t_{k+1} - 1)x_k - t_{k+1}x_{k+1}\|^2 \\ & \quad - \frac{1}{2\tau t_{k+1}^2} \|x^* + (t_{k+1} - 1)x_k - t_{k+1}y_k\|^2. \end{aligned} \quad (6.46)$$

Di sisi lain, menurut kekonveksan  $F$  dan fakta  $t_k \geq 1$ ,

$$\begin{aligned} F(t_{k+1}^{-1}x^* + (1 - t_{k+1}^{-1})x_k) - F(x_{k+1}) & \leq t_{k+1}^{-1}F(x^*) + (1 - t_{k+1}^{-1})F(x_k) - F(x_{k+1}) \\ & = (1 - t_{k+1}^{-1})(F(x_k) - F(x^*)) - (F(x_{k+1}) - F(x^*)). \end{aligned} \quad (6.47)$$

Karena  $y_k = x_k + \frac{t_k - 1}{t_{k+1}}(x_k - x_{k-1})$ , kita mempunyai

$$\|x^* + (t_{k+1} - 1)x_k - t_{k+1}y_k\|^2 = \|x^* - t_k x_k + (t_k - 1)x_{k-1}\|^2. \quad (6.48)$$

Menggabungkan (6.46), (6.47), dan (6.48) memberikan

$$\begin{aligned} & t_{k+1}^2 (1 - t_{k+1}^{-1})(F(x_k) - F(x^*)) - t_{k+1}^2 (F(x_{k+1}) - F(x^*)) \\ & \geq \frac{1}{2\tau} \|x^* - t_{k+1}x_{k+1} + (t_{k+1} - 1)x_k\|^2 \\ & \quad - \frac{1}{2\tau} \|x^* - t_k x_k + (t_k - 1)x_{k-1}\|^2. \end{aligned} \quad (6.49)$$

Dari pembaruan FISTA berlaku  $t_{k+1}^2(1 - t_{k+1}^{-1}) = t_k^2$ . Jadi,

$$\begin{aligned} & t_k^2(F(x_k) - F(x^*)) - t_{k+1}^2(F(x_{k+1}) - F(x^*)) \\ & \geq \frac{1}{2\tau} \|x^* - t_{k+1}x_{k+1} + (t_{k+1} - 1)x_k\|^2 \\ & \quad - \frac{1}{2\tau} \|x^* - t_kx_k + (t_k - 1)x_{k-1}\|^2. \end{aligned} \quad (6.50)$$

Dengan demikian,

$$\begin{aligned} & t_k^2(F(x_k) - F(x^*)) + \frac{1}{2\tau} \|x^* - t_kx_k + (t_k - 1)x_{k-1}\|^2 \\ & \geq t_{k+1}^2(F(x_{k+1}) - F(x^*)) + \frac{1}{2\tau} \|x^* - t_{k+1}x_{k+1} + (t_{k+1} - 1)x_k\|^2. \end{aligned} \quad (6.51)$$

Dengan mengiterasikan ketaksamaan ini, untuk  $k \geq 2$  diperoleh

$$\begin{aligned} & t_2^2(F(x_2) - F(x^*)) + \frac{1}{2\tau} \|t_2(x^* - x_2) + (t_2 - 1)(x_1 - x^*)\|^2 \\ & \geq t_k^2(F(x_k) - F(x^*)) + \frac{1}{2\tau} \|x^* - t_kx_k + (t_k - 1)x_{k-1}\|^2. \end{aligned} \quad (6.52)$$

Selain itu, ketaksamaan fundamental gradien proksimal dengan  $x = x^*$  dan  $y = y_1 = x_0 = x_1$  memberikan

$$F(x^*) - F(x_2) \geq \frac{1}{2\tau} \|x^* - x_2\|^2 - \frac{1}{2\tau} \|x^* - x_1\|^2. \quad (6.53)$$

Dengan membuang suku kuadrat nonnegatif pada ruas kanan estimasi energi dan memakai batas terakhir, kita menemukan

$$F(x_k) - F(x^*) \leq t_k^{-2} \left( \frac{t_2^2}{2\tau} \|x^* - x_1\|^2 + \frac{1}{2\tau} \|t_2(x^* - x_2) + (t_2 - 1)(x_1 - x^*)\|^2 \right). \quad (6.54)$$

Karena  $t_k \geq (k + 1)/2$ , batas dalam pernyataan teorema mengikuti.  $\square$

## Bab 7

# Dualitas

Dalam bab ini, semua ruang vektor dipahami sebagai ruang Hilbert riil berdimensi hingga. Dual yang digunakan adalah dual kontinu; melalui representasi Riesz kita mengidentifikasi  $V^* \cong V$  dan, khususnya,  $V^{**} \cong V$ . Untuk setiap ruang demikian  $H$ , tuliskan  $\Gamma_0(H)$  bagi kelas fungsi  $H \rightarrow (-\infty, +\infty]$  yang proper, konveks, dan semikontinu bawah.

### 7.1 Dualitas Fenchel

**Definisi 7.1** (Konjugat Fenchel/konveks). Misalkan  $f : V \rightarrow (-\infty, +\infty]$  proper. Konjugat Fenchel, atau konjugat konveks, didefinisikan sebagai

$$\begin{aligned} f^* : V^* &\rightarrow (-\infty, +\infty] \\ f^*(x^*) &= \sup_{x \in V} \langle x^*, x \rangle - f(x). \end{aligned} \quad (7.1)$$

**Contoh 7.2.** (i) Fungsi indikator: Misalkan  $f = \delta_C$  dengan  $C \subset V$  tak kosong dan konveks. Maka  $f^*(x^*) = \sup_{x \in C} \langle x^*, x \rangle$  adalah apa yang disebut fungsi pendukung.

(ii) Norma: Misalkan  $f = \|\cdot\|$  adalah suatu norma. Maka  $f^* = \delta_{\overline{B}_{\|\cdot\|,1}(0)}$ . Artinya,  $f^*$  adalah fungsi indikator pada bola satuan tertutup terhadap norma dual.

(iii) Sebaliknya, konjugat dari  $f = \delta_{\overline{B}_{\|\cdot\|,1}(0)}$  adalah  $f^* = \|\cdot\|$  setelah identifikasi  $V^{**} \cong V$ .

**Lema 7.3.** Misalkan  $f$  proper dan konveks, serta andaikan bahwa  $\partial f(\hat{x}) \neq \emptyset$  untuk suatu  $\hat{x} \in V$ . Dalam dimensi hingga, syarat tambahan ini otomatis dipenuhi pada suatu titik di interior relatif domain efektif; bandingkan Beck 2017, Corollary 3.19. Maka  $f^*$  proper, konveks, dan semikontinu bawah (lsc).

*Bukti.* Karena  $f$  proper, terdapat  $x_0 \in V$  sedemikian sehingga  $f(x_0) \in \mathbb{R}$ . Akibatnya, untuk setiap  $x^*$ ,

$$f^*(x^*) \geq \langle x^*, x_0 \rangle - f(x_0) > -\infty. \quad (7.2)$$

Ambil  $g \in \partial f(\hat{x})$ . Berdasarkan definisi subgradien, kita mempunyai

$$f(\hat{x}) + \langle g, x - \hat{x} \rangle \leq f(x) \quad (7.3)$$

dan, dengan demikian,

$$\begin{aligned} f^*(g) &= \sup_{x \in V} \langle g, x \rangle - f(x) \\ &\leq \sup_{x \in V} f(x) - f(\hat{x}) + \langle g, \hat{x} \rangle - f(x) \\ &\leq \sup_{x \in V} -f(\hat{x}) + \langle g, \hat{x} \rangle < \infty. \end{aligned} \quad (7.4)$$

Kekonveksan dan semikontinuitas bawah langsung mengikuti fakta bahwa konjugat konveks merupakan supremum titik demi titik dari fungsi-fungsi afin kontinu, yang karena itu konveks dan lsc<sup>1</sup>.  $\square$

<sup>1</sup>Di sini kekonveksan telah ditunjukkan secara langsung. Rincian untuk lsc ditinggalkan sebagai latihan.

**Lema 7.4** (Ketaksamaan Fenchel). *Misalkan  $f$  proper. Maka*

$$f^*(x^*) + f(x) \geq \langle x^*, x \rangle. \quad (7.5)$$

*Bukti.* Latihan. □

Untuk fungsi proper  $f$  dengan  $f^*$  proper, proses pengambilan konjugat dapat kita *iterasikan* untuk memperoleh *bikonjugat*. Kondisi ini dijamin oleh lema sebelumnya pada kasus konveks yang memenuhi hipotesisnya. Demi kesederhanaan, kita tulis  $f^{**} := (f^*)^*$ . Karena diasumsikan  $V^{**} = V$ , bikonjugat kembali terdefinisi pada ruang asal  $V$ .

**Lema 7.5.** *Misalkan  $f$  dan  $f^*$  proper. Untuk setiap  $x \in V$  berlaku  $f^{**}(x) \leq f(x)$ .*

*Bukti.* Pertama, perhatikan bahwa untuk setiap  $x$ , konjugat memenuhi

$$f^*(x^*) \geq \langle x^*, x \rangle - f(x). \quad (7.6)$$

Oleh karena itu,

$$\begin{aligned} f^{**}(x) &= \sup_{x^* \in V^*} \langle x^*, x \rangle - f^*(x^*) \\ &= \sup_{x^* \in V^*} \inf_y \langle x^*, x - y \rangle + f(y) \\ &\leq \sup_{x^* \in V^*} \langle x^*, x - x \rangle + f(x) \\ &= f(x). \end{aligned} \quad (7.7)$$

□

**Lema 7.6.** *Misalkan  $f$  proper, konveks, dan lsc. Maka  $f^{**} = f$ .*

*Bukti.* Karena selalu berlaku  $f^{**} \leq f$ , tinggal ditunjukkan bahwa  $f^{**} \geq f$ . Andaikan sebaliknya: terdapat  $x_0 \in V$  sedemikian sehingga

$$f^{**}(x_0) < f(x_0). \quad (7.8)$$

Ini berarti  $(x_0, f^{**}(x_0)) \notin \text{epi}(f)$ . Karena  $\text{epi}(f)$  tertutup dan konveks berdasarkan asumsi, teorema Hahn–Banach dapat diterapkan untuk mendapatkan  $(g, \alpha) \in V^* \times \mathbb{R}$  dan  $c_1, c_2 \in \mathbb{R}$  sedemikian sehingga

$$\langle (g, \alpha), (x_0, f^{**}(x_0)) \rangle < c_1 < c_2 < \langle (g, \alpha), (x, t) \rangle, \quad (x, t) \in \text{epi}(f). \quad (7.9)$$

Karena  $f$  proper, pilih  $\bar{x} \in \text{dom}(f)$ . Dengan memasukkan  $(\bar{x}, t) \in \text{epi}(f)$  dan membiarkan  $t \rightarrow \infty$ , diperoleh  $\alpha \geq 0$ . Sekarang andaikan  $\alpha > 0$ . Kita dapat membagi dengan  $\alpha$  dan memperoleh

$$\left\langle \frac{g}{\alpha}, x_0 - x \right\rangle + f^{**}(x_0) - f(x) \leq \frac{c_1 - c_2}{\alpha} < 0. \quad (7.10)$$

Ketaksamaan di atas berlaku untuk setiap  $x \in \text{dom}(f)$  dan juga secara otomatis untuk setiap  $x$  dengan  $f(x) = \infty$ . Mengambil supremum terhadap  $x$  menghasilkan

$$\left\langle \frac{g}{\alpha}, x_0 \right\rangle + f^{**}(x_0) + f^*\left(-\frac{g}{\alpha}\right) < 0, \quad (7.11)$$

yang bertentangan dengan ketaksamaan Fenchel. Pada kasus yang tersisa, yaitu  $\alpha = 0$ , kita mempunyai

$$\langle g, x_0 - x \rangle < c_1 - c_2 < 0. \quad (7.12)$$

Ambil sembarang  $\hat{y} \in \text{dom}(f^*)$ . Untuk  $\hat{g} = g - \varepsilon \hat{y}$ , kita memperoleh

$$\begin{aligned} \langle \hat{g}, x_0 - x \rangle + \varepsilon(f^{**}(x_0) - f(x)) &\leq \langle g, x_0 - x \rangle + \varepsilon(\langle -\hat{y}, x_0 - x \rangle + f^{**}(x_0) - f(x)) \\ &\leq c_1 - c_2 + \varepsilon(\langle \hat{y}, -x_0 \rangle + f^{**}(x_0) + f^*(\hat{y})). \end{aligned} \quad (7.13)$$

Perhatikan bahwa  $\hat{y}$  dan  $x_0$  tetap. Karena itu,  $\varepsilon > 0$  dapat dipilih cukup kecil agar ruas kanan tetap negatif ketat. Tuliskan  $c := c_1 - c_2 + \varepsilon(\langle -\hat{y}, x_0 \rangle + f^{**}(x_0) + f^*(\hat{y})) < 0$ . Setelah membagi dengan  $\varepsilon$ , diperoleh

$$\left\langle \frac{\hat{g}}{\varepsilon}, x_0 - x \right\rangle + f^{**}(x_0) - f(x) \leq \frac{c}{\varepsilon} < 0. \quad (7.14)$$

Sekali lagi mengambil supremum terhadap semua  $x$  menghasilkan

$$\left\langle \frac{\hat{g}}{\varepsilon}, x_0 \right\rangle + f^{**}(x_0) + f^*\left(-\frac{\hat{g}}{\varepsilon}\right) \leq \frac{c}{\varepsilon} < 0, \quad (7.15)$$

Hal ini bertentangan dengan ketaksamaan Fenchel. Jadi, asumsi  $f^{**}(x_0) < f(x_0)$  selalu menimbulkan kontradiksi. Karena itu,  $f^{**}(x_0) \geq f(x_0)$ , dan bukti selesai.  $\square$

**Catatan.** Jika  $f$  tidak sekaligus konveks dan tertutup, maka, selama keluarga minoran proper di bawah tidak kosong,  $f^{**}$  merupakan minoran konveks semikontinu bawah terbesar dari  $f$ , yang disebut regularisasi  $\Gamma$ . Lebih tepatnya, tuliskan

$$\Gamma(V) = \{\ell : V \rightarrow (-\infty, +\infty] \mid \ell \text{ proper, tertutup, dan konveks}\}. \quad (7.16)$$

Jika  $\{\ell \in \Gamma(V) : \ell \leq f\} \neq \emptyset$ , maka

$$f^{**}(x) = \sup_{\substack{\ell \in \Gamma(V), \\ \ell \leq f}} \ell(x). \quad (7.17)$$

Jika keluarga minoran tersebut kosong, supremum pada ruas kanan dipahami sebagai fungsi yang identik  $-\infty$ . Fungsi ini tidak termasuk dalam  $\Gamma(V)$  dan, di bawah konvensi bab ini yang mendefinisikan konjugasi hanya bagi masukan proper, tidak dinotasikan sebagai  $f^{**}$ .

Konjugat mempunyai hubungan yang erat dengan subgradien, sebagaimana ditunjukkan oleh lema berikut.

**Lema 7.7.** Misalkan  $f$  proper, konveks, dan tertutup. Pernyataan-pernyataan berikut ekuivalen:

- (i)  $f(x) + f^*(x^*) = \langle x^*, x \rangle$ .
- (ii)  $x^* \in \partial f(x)$ .
- (iii)  $x \in \partial f^*(x^*)$ .

*Bukti.*

(i)  $\rightarrow$  (ii): Pernyataan (i) menyiratkan bahwa untuk setiap  $z \in V$ ,

$$-f(x) + \langle x^*, x \rangle = f^*(x^*) \geq \langle x^*, z \rangle - f(z). \quad (7.18)$$

Berdasarkan definisi, ini menyiratkan  $x^* \in \partial f(x)$ .

(ii)  $\rightarrow$  (i): Sebaliknya, pernyataan (ii) menghasilkan, untuk setiap  $z$ ,

$$-f(x) + \langle x^*, x \rangle \geq \langle x^*, z \rangle - f(z). \quad (7.19)$$

Dengan mengambil supremum terhadap  $z$ , diperoleh  $\langle x^*, x \rangle \geq f(x) + f^*(x^*)$ . Bersama ketaksamaan Fenchel, ini membuktikan hasilnya.

(i)  $\leftrightarrow$  (iii): Karena  $f$  proper, konveks, dan tertutup, pernyataan (i) ekuivalen dengan

$$f^{**}(x) + f^*(x^*) = \langle x^*, x \rangle. \quad (7.20)$$

Bukti kemudian diperoleh dengan mengulangi argumen di atas.

$\square$

**Teorema 7.8** (Identitas Moreau). Misalkan  $f \in \Gamma_0(V)$ . Maka

$$x = \text{prox}_f(x) + \text{prox}_{f^*}(x). \quad (7.21)$$

*Bukti.* Pertama, perhatikan bahwa kedua pemetaan proksimal terdefinisi dengan baik dan bernilai tunggal (mengapa?). Demi kesederhanaan, tuliskan  $p = \text{prox}_f(x)$ . Dari syarat optimalitas diperoleh  $x - p \in \partial f(p)$  dan, berdasarkan [teorema 7.7](#),  $p = x - (x - p) \in \partial f^*(x - p)$ . Pernyataan terakhir menyiratkan  $\text{prox}_{f^*}(x) = x - p$ , sehingga bukti selesai.  $\square$

**Teorema 7.9** (Fenchel–Rockafellar). *Misalkan  $X$  dan  $Y$  ruang Hilbert riil berdimensi hingga,  $f \in \Gamma_0(X)$ ,  $g \in \Gamma_0(Y)$ , dan  $K : X \rightarrow Y$  operator linear terbatas. Selain itu, andaikan terdapat  $x_0 \in \text{dom}(f) \cap \text{dom}(g \circ K)$  dengan  $Kx_0 \in \text{dom}(g)^\circ$ . Andaikan masalah (primal)*

$$\min_x f(x) + g(Kx) \quad (7.22)$$

*mempunyai solusi  $\hat{x}$ . Maka masalah dual*

$$\max_{x^*} -f^*(-K^*x^*) - g^*(x^*) \quad (7.23)$$

*juga mempunyai solusi  $\hat{x}^*$ , dan berlaku dualitas kuat, yaitu*

$$\min_x f(x) + g(Kx) = \max_{x^*} -f^*(-K^*x^*) - g^*(x^*). \quad (7.24)$$

*Selain itu, solusi primal dan dual memenuhi*

$$\begin{cases} -K^*\hat{x}^* & \in \partial f(\hat{x}), \\ \hat{x}^* & \in \partial g(K\hat{x}). \end{cases} \quad (7.25)$$

*Bukti.* Pertama, secara langsung diperoleh

$$\begin{aligned} \inf_x f(x) + g(Kx) &= \inf_x f(x) + g^{**}(Kx) \\ &= \inf_x \sup_{x^*} f(x) + \langle Kx, x^* \rangle - g^*(x^*) \\ &\geq \sup_{x^*} \inf_x f(x) + \langle Kx, x^* \rangle - g^*(x^*) \\ &= \sup_{x^*} - \sup_x -f(x) + \langle x, -K^*x^* \rangle - g^*(x^*) \\ &= \sup_{x^*} -f^*(-K^*x^*) - g^*(x^*). \end{aligned} \quad (7.26)$$

Jadi, tinggal dibuktikan ketaksamaan sebaliknya. Hipotesis interior di atas memenuhi syarat kualifikasi bagi aturan jumlah dan rantai subdiferensial. Karena itu, kaidah Fermat pada peminimum  $\hat{x}$  memberikan

$$0 \in \partial f(\hat{x}) + K^*\partial g(K\hat{x}).$$

Dengan kata lain, terdapat  $\hat{x}^* \in \partial g(K\hat{x})$  sedemikian sehingga  $-K^*\hat{x}^* \in \partial f(\hat{x})$ . Berdasarkan [teorema 7.7](#), hal ini menyiratkan

$$\begin{aligned} g(K\hat{x}) + g^*(\hat{x}^*) &= \langle \hat{x}^*, K\hat{x} \rangle, \\ f(\hat{x}) + f^*(-K^*\hat{x}^*) &= -\langle K^*\hat{x}^*, \hat{x} \rangle = -\langle \hat{x}^*, K\hat{x} \rangle. \end{aligned} \quad (7.27)$$

Oleh karena itu,

$$\begin{aligned} \inf_x f(x) + g(Kx) &= f(\hat{x}) + g(K\hat{x}) \\ &= (-f^*(-K^*\hat{x}^*) - \langle \hat{x}^*, K\hat{x} \rangle) + (-g^*(\hat{x}^*) + \langle \hat{x}^*, K\hat{x} \rangle) \\ &= -f^*(-K^*\hat{x}^*) - g^*(\hat{x}^*) \\ &\leq \sup_{x^*} -f^*(-K^*x^*) - g^*(x^*). \end{aligned} \quad (7.28)$$

Ini membuktikan kesamaan dalam (7.26) sekaligus menunjukkan bahwa  $\hat{x}^*$  adalah solusi masalah dual.  $\square$

## 7.2 Optimisasi primal–dual

**Teorema 7.9** membuka kemungkinan beberapa metode untuk mencari solusi masalah berbentuk

$$\min_x f(x) + g(Kx). \quad (7.29)$$

Memang, berdasarkan dualitas kuat, kita dapat menangani masalah primal, masalah dual, atau masalah titik pelana

$$\min_x \sup_y \mathcal{L}(x, y) := f(x) - g^*(y) + \langle Kx, y \rangle. \quad (7.30)$$

Tujuan utama peralihan di antara formulasi primal dan dual adalah untuk *memindahkan* operator  $K$ . Misalnya, jika  $g$  tidak terdiferensialkan sehingga kita ingin menerapkan langkah proksimal pada  $g$ , operator  $K$  dalam (7.29) pada umumnya membuat  $\text{prox}_{g \circ K}$  tidak mempunyai bentuk eksplisit. Sebaliknya, dalam formulasi titik pelana (7.30), operator  $K$  hanya muncul dalam hasil kali skalar. Selain itu, perhatikan bahwa menurut **teorema 7.8**, proksimal suatu fungsi konjugat sama mudah atau sama sulit dihitung dengan proksimal fungsi asalnya. Lebih tepatnya, untuk  $\sigma > 0$  berlaku  $\text{prox}_{\sigma g^*}(y) = y - \sigma \text{prox}_{g/\sigma}(y/\sigma)$ .

Kesenjangan primal–dual didefinisikan sebagai

$$\mathcal{G}(x, y) = (f(x) + g(Kx)) - (-f^*(-K^*y) - g^*(y)). \quad (7.31)$$

**Lema 7.10.** *Di bawah hipotesis dualitas kuat dan ketercapaian primal–dual yang baru saja dinyatakan, kita mempunyai  $\mathcal{G}(x, y) \geq 0$ , dan  $\mathcal{G}(\hat{x}, \hat{y}) = 0$  jika dan hanya jika  $\hat{x}$  menyelesaikan masalah primal dan  $\hat{y}$  menyelesaikan masalah dual. Kesenjangan tersebut mempunyai representasi*

$$\mathcal{G}(x, y) = \sup_{y'} \mathcal{L}(x, y') - \inf_{x'} \mathcal{L}(x', y). \quad (7.32)$$

Khususnya,  $(\hat{x}, \hat{y})$  masing-masing optimal untuk masalah primal dan dual jika dan hanya jika, untuk setiap  $x, y$ ,

$$\mathcal{L}(\hat{x}, y) \leq \mathcal{L}(\hat{x}, \hat{y}) \leq \mathcal{L}(x, \hat{y}). \quad (7.33)$$

*Bukti.* Latihan. □

Dengan melakukan optimisasi bergantian dalam (7.30), memakai langkah proksimal terhadap  $f$  dan  $g^*$  serta langkah gradien terhadap hasil kali dalam, kita memperoleh aturan pembaruan berikut yang dikenal sebagai metode Arrow–Hurwicz:

$$\begin{cases} x_{k+1} = \text{prox}_{\tau f}(x_k - \tau K^* y_k) \\ y_{k+1} = \text{prox}_{\sigma g^*}(y_k + \sigma K x_{k+1}). \end{cases} \quad (7.34)$$

Ternyata, dalam bentuk ini metode tersebut mempunyai sifat konvergensi yang lebih buruk. Untuk memperoleh pembaruan yang lebih baik, algoritme ditulis ulang secara cermat. Dengan memakai  $\text{prox}_{\tau f}(x) = (\text{Id} + \tau \partial f)^{-1}(x)$ , dapat diperiksa secara langsung bahwa (7.34) ekuivalen dengan

$$\begin{cases} x_{k+1} + \tau \partial f(x_{k+1}) = x_k - \tau K^* y_k \\ y_{k+1} + \sigma \partial g^*(y_{k+1}) = y_k + \sigma K x_{k+1}. \end{cases} \quad (7.35)$$

Setelah membagi masing-masing persamaan dengan  $\tau$  dan  $\sigma$ , serta menggunakan notasi  $z = (x, y)$ , bentuk ini dapat ditulis sebagai

$$\begin{bmatrix} \frac{1}{\tau} \text{Id} + \partial f & 0 \\ -K & \frac{1}{\sigma} \text{Id} + \partial g^* \end{bmatrix} z_{k+1} = \begin{bmatrix} \frac{1}{\tau} \text{Id} & -K^* \\ 0 & \frac{1}{\sigma} \text{Id} \end{bmatrix} z_k. \quad (7.36)$$

Bahkan tanpa menelaah rincian bukti, wajar diharapkan bahwa pembaruan yang lebih *simetris* akan lebih baik, khususnya karena sifat menguntungkan matriks simetris. Karena itu, kita mempertimbangkan skema berikut, yang tidak mengubah titik tetap yang mungkin:

$$\begin{bmatrix} \frac{1}{\tau} \text{Id} + \partial f & 0 \\ -2K & \frac{1}{\sigma} \text{Id} + \partial g^* \end{bmatrix} z_{k+1} = \begin{bmatrix} \frac{1}{\tau} \text{Id} & -K^* \\ -K & \frac{1}{\sigma} \text{Id} \end{bmatrix} z_k. \quad (7.37)$$

Matriks pada ruas kanan kini simetris dan definit positif selama  $\sigma\tau\|K\|^2 < 1$ . Kembali ke operator proksimal, metode gradien hibrida primal–dual ini, yang sering disebut metode Chambolle–Pock berdasarkan Chambolle and Pock 2011, berbentuk

$$\begin{cases} x_{k+1} = \text{prox}_{\tau f}(x_k - \tau K^* y_k) \\ y_{k+1} = \text{prox}_{\sigma g}(y_k + \sigma K(2x_{k+1} - x_k)). \end{cases} \quad (7.38)$$

Untuk analisis, PDHG akan ditulis dalam bentuk abstrak

$$\begin{cases} x^+ = \arg \min_x \frac{1}{2\tau}|x - x^-|^2 + \langle x, K^* \bar{y} \rangle + f(x) \\ y^+ = \arg \min_y \frac{1}{2\sigma}|y - y^-|^2 - \langle y, K\bar{x} \rangle + g^*(y). \end{cases} \quad (7.39)$$

Di sini, superskrip plus menyatakan variabel yang telah diperbarui, superskrip minus menyatakan iterasi lama, sedangkan garis atas masing-masing menyatakan nilai  $x$  yang digunakan untuk pembaruan  $y$  dan nilai  $y$  yang digunakan untuk pembaruan  $x$ .

**Lema 7.11.** Misalkan  $X$  dan  $Y$  ruang Hilbert riil berdimensi hingga,  $f \in \Gamma_0(X)$ ,  $g \in \Gamma_0(Y)$ ,  $K : X \rightarrow Y$  linear terbatas, serta  $\tau, \sigma > 0$ . Aturan pembaruan (7.39) memenuhi

$$\begin{aligned} \mathcal{L}(x^+, y) - \mathcal{L}(x, y^+) &\leq \frac{1}{2\tau}|x - x^-|^2 + \frac{1}{2\sigma}|y - y^-|^2 \\ &\quad - \frac{1}{2\tau}|x - x^+|^2 - \frac{1}{2\sigma}|y - y^+|^2 - \frac{1}{2\tau}|x^+ - x^-|^2 - \frac{1}{2\sigma}|y^+ - y^-|^2 \\ &\quad + \langle x^+ - x, K^*(y - \bar{y}) \rangle - \langle y^+ - y, K(x - \bar{x}) \rangle. \end{aligned} \quad (7.40)$$

*Bukti.* Berdasarkan kekonveksan kuat, pembaruan  $x^+$  dan  $y^+$  memenuhi

$$\begin{aligned} \frac{1}{2\tau}|x^+ - x^-|^2 + \langle x^+, K^* \bar{y} \rangle + f(x^+) + \frac{1}{2\tau}|x - x^+|^2 &\leq \frac{1}{2\tau}|x - x^-|^2 + \langle x, K^* \bar{y} \rangle + f(x) \\ \frac{1}{2\sigma}|y^+ - y^-|^2 - \langle y^+, K\bar{x} \rangle + g^*(y^+) + \frac{1}{2\sigma}|y - y^+|^2 &\leq \frac{1}{2\sigma}|y - y^-|^2 - \langle y, K\bar{x} \rangle + g^*(y). \end{aligned} \quad (7.41)$$

Menjumlahkan kedua ketaksamaan dan menyusun ulang suku-sukunya memberikan hasil yang diinginkan.  $\square$

**Teorema 7.12** (Konvergensi PDHG). Misalkan  $X$  dan  $Y$  ruang Hilbert riil berdimensi hingga,  $f \in \Gamma_0(X)$ ,  $g \in \Gamma_0(Y)$ ,  $K : X \rightarrow Y$  linear terbatas, serta  $\tau, \sigma > 0$ . Perhatikan pembaruan (7.38) dan andaikan ukuran langkah memenuhi  $\tau\sigma \leq \|K\|^{-2}$ ; untuk  $K = 0$ , syarat ini dipahami otomatis terpenuhi. Untuk  $N \geq 1$ , definisikan rerata ergodik  $X_N = \frac{1}{N} \sum_{k=1}^N x_k$  dan  $Y_N = \frac{1}{N} \sum_{k=1}^N y_k$ . Maka

$$\mathcal{L}(X_N, y) - \mathcal{L}(x, Y_N) \leq \frac{1}{N} \left[ \frac{1}{2\tau}|x - x_0|^2 + \frac{1}{2\sigma}|y - y_0|^2 - \langle y - y_0, K(x - x_0) \rangle \right]. \quad (7.42)$$

**Catatan.** Perhatikan bahwa ukuran langkah sama sekali tidak bergantung pada fungsi  $f$  dan  $g$ , melainkan hanya pada operator  $K$ .

*Bukti.*

$$\begin{aligned} \mathcal{L}(x_{k+1}, y) - \mathcal{L}(x, y_{k+1}) &\leq \frac{1}{2\tau}|x - x_k|^2 + \frac{1}{2\sigma}|y - y_k|^2 \\ &\quad - \frac{1}{2\tau}|x - x_{k+1}|^2 - \frac{1}{2\sigma}|y - y_{k+1}|^2 - \frac{1}{2\tau}|x_{k+1} - x_k|^2 - \frac{1}{2\sigma}|y_{k+1} - y_k|^2 \\ &\quad + \langle x_{k+1} - x, K^*(y - y_k) \rangle - \langle y_{k+1} - y, K(x - x_{k+1}) \rangle \\ &\quad + \langle y_{k+1} - y, K(x_{k+1} - x_k) \rangle \\ &\leq \left[ \frac{1}{2\tau}|x - x_k|^2 + \frac{1}{2\sigma}|y - y_k|^2 - \langle y - y_k, K(x - x_k) \rangle \right] \\ &\quad - \left[ \frac{1}{2\tau}|x - x_{k+1}|^2 + \frac{1}{2\sigma}|y - y_{k+1}|^2 - \langle y - y_{k+1}, K(x - x_{k+1}) \rangle \right] \\ &\quad - \left[ \frac{1}{2\tau}|x_{k+1} - x_k|^2 + \frac{1}{2\sigma}|y_{k+1} - y_k|^2 \right. \\ &\quad \left. - \langle x_{k+1} - x_k, K^*(y_{k+1} - y_k) \rangle \right]. \end{aligned} \quad (7.43)$$

Jika  $K = 0$ , suku campuran dalam setiap tanda kurung siku lenyap, sehingga semua ekspresi itu tidak negatif. Jika  $K \neq 0$ , nonnegativitas mengikuti

$$\langle Kx, y \rangle \leq \|Kx\| \|y\| \leq \|K\| \left( \frac{\delta}{2} \|x\|^2 + \frac{1}{2\delta} \|y\|^2 \right) \leq \frac{1}{2\tau} \|x\|^2 + \frac{1}{2\sigma} \|y\|^2,$$

dengan ketaksamaan terakhir diperoleh dari pilihan  $\delta = \frac{1}{\tau\|K\|}$  dan fakta bahwa  $\|K\|^2 \leq \frac{1}{\tau\sigma}$ . Penjumlahan terhadap  $k$  menghasilkan

$$\sum_{k=0}^{N-1} \mathcal{L}(x_{k+1}, y) - \mathcal{L}(x, y_{k+1}) \leq \left[ \frac{1}{2\tau} |x - x_0|^2 + \frac{1}{2\sigma} |y - y_0|^2 - \langle y - y_0, K(x - x_0) \rangle \right]. \quad (7.44)$$

Karena pemetaan  $(x, y) \mapsto \mathcal{L}(x, y') - \mathcal{L}(x', y)$  konveks untuk  $x', y'$  tetap, kita memperoleh

$$\mathcal{L}(X_N, y) - \mathcal{L}(x, Y_N) \leq \frac{1}{N} \sum_{k=0}^{N-1} (\mathcal{L}(x_{k+1}, y) - \mathcal{L}(x, y_{k+1})) \leq \frac{1}{N} \left[ \frac{1}{2\tau} |x - x_0|^2 + \frac{1}{2\sigma} |y - y_0|^2 - \langle y - y_0, K(x - x_0) \rangle \right]. \quad (7.45)$$

□

### 7.3 Metode pengali arah bergantian (ADMM)

Misalkan  $f, g \in \Gamma_0(\mathbb{R}^d)$ ,  $A, B : \mathbb{R}^d \rightarrow \mathbb{R}^m$  linear, dan  $z \in \mathbb{R}^m$ . Perhatikan masalah optimisasi berkendala

$$\min_{Ax+By=z} f(x) + g(y). \quad (7.46)$$

Masalah ini dapat dirumuskan ulang sebagai masalah titik pelana tak berkendala untuk *Lagrangian teraugmentasi*; yaitu, untuk setiap  $\gamma > 0$ , kita mempertimbangkan

$$\min_{x,y} \sup_{\lambda} L_{\gamma}(x, y, \lambda) := f(x) + g(y) + \langle \lambda, Ax + By - z \rangle + \frac{\gamma}{2} \|Ax + By - z\|^2. \quad (7.47)$$

Pernyataan berikut dapat ditunjukkan secara langsung.

**Lema 7.13.** Masalah (7.46) dan (7.47) ekuivalen.

*Bukti.* Latihan! □

Salah satu cara langsung untuk menyelesaikan masalah titik pelana tersebut adalah mengoptimalkan secara bergantian terhadap  $x$  dan  $y$ , lalu melakukan langkah kenaikan gradien terhadap  $\lambda$ :

$$\begin{cases} x_{k+1} = \arg \min_x f(x) + \langle \lambda_k, Ax \rangle + \frac{\gamma}{2} \|Ax + By_k - z\|^2 \\ y_{k+1} = \arg \min_y g(y) + \langle \lambda_k, By \rangle + \frac{\gamma}{2} \|Ax_{k+1} + By - z\|^2 \\ \lambda_{k+1} = \lambda_k + \gamma(Ax_{k+1} + By_{k+1} - z). \end{cases} \quad (7.48)$$

Perhatikan bahwa  $\gamma$  digunakan sebagai ukuran langkah untuk kenaikan gradien. Pilihan ini dapat dimotivasi secara intuitif oleh fakta bahwa, berdasarkan definisi pembaruan,

$$0 \in \partial g(y_{k+1}) + B^* \lambda_k + \gamma B^* (Ax_{k+1} + By_{k+1} - z). \quad (7.49)$$

Dengan mengalikan pembaruan  $\lambda$  oleh  $B^*$  dan memasukkannya ke (7.49), diperoleh

$$B^* \lambda_{k+1} \in -\partial g(y_{k+1}). \quad (7.50)$$

Dengan demikian, triple ADMM yang benar-benar diperbarui melalui (7.48) memenuhi

$$0 \in \partial_y L_0(x_{k+1}, y_{k+1}, \lambda_{k+1}).$$

Pembaruan bergantian tersebut pada umumnya tidak memberikan stasioneritas terhadap  $x$ , karena submasalah  $x$  masih memakai  $y_k$ . Hanya dalam skema hipotetis yang meminimumkan  $x$  dan  $y$  secara bersama kondisi serupa diperoleh terhadap  $x$ , sehingga triple hasil pembaruan bersama itu memenuhi stasioneritas primal penuh untuk  $L_0$ . Kita dapat menunjukkan hasil konvergensi dasar berikut untuk ADMM.

**Teorema 7.14.** Ambil  $\gamma > 0$ . Andaikan terdapat suatu titik pelana dari  $L_0(x, y, \lambda)$  dan, pada setiap iterasi, kedua submasalah minimisasi dalam algoritme ADMM di atas mencapai minimumnya; pilih sembarang peminimum tersebut. Dengan  $r_k := Ax_k + By_k - z$ , berlaku  $r_k \rightarrow 0$ ,  $B(y_{k+1} - y_k) \rightarrow 0$ , dan

$$f(x_k) + g(y_k) \rightarrow \min_{Ax+By=z} f(x) + g(y). \quad (7.51)$$

*Bukti.* Bukti menggunakan suatu teknik penting, yaitu *fungsi Lyapunov*. Kita mendefinisikan fungsional  $V(y, \lambda)$  yang tidak negatif (terbatas dari bawah) dan menurun sepanjang iterasi. Pada dasarnya, fungsional Lyapunov menggantikan fungsi objektif ketika penurunan objektif itu sendiri tidak dapat dibuktikan. Dalam kasus ini, kita menggunakan

$$V(y, \lambda) = \gamma \|B(y - y^*)\|^2 + \gamma^{-1} \|\lambda - \lambda^*\|^2, \quad (7.52)$$

dengan  $(x^*, y^*, \lambda^*)$  suatu titik pelana bagi  $L_0$ . Penurunan fungsional Lyapunov akan memberikan konvergensi melalui argumen penjumlahan teleskopik yang lazim. Akan tetapi, pembuktian penurunan ini memerlukan beberapa taksiran teknis. Demi kesederhanaan, tuliskan residu  $r_k := Ax_k + By_k - z$  dan nilai objektif  $p_k := f(x_k) + g(y_k)$ ; gunakan pula  $r^*$  dan  $p^*$  untuk titik pelana. Bukti dibagi menjadi tiga langkah.

**Langkah 1** Karena  $(x^*, y^*, \lambda^*)$  merupakan titik pelana bagi  $L_0$ , untuk setiap  $k$  berlaku  $L_0(x^*, y^*, \lambda^*) \leq L_0(x_{k+1}, y_{k+1}, \lambda^*)$ . Pernyataan ini ekuivalen dengan

$$p^* - p_{k+1} \leq \langle \lambda^*, r_{k+1} \rangle. \quad (7.53)$$

**Langkah 2** Di sisi lain, berdasarkan optimalitas  $x_{k+1}$  dan  $y_{k+1}$  dalam (7.48), kita memperoleh

$$\begin{aligned} 0 &\in \partial f(x_{k+1}) + A^* \lambda_k + \gamma A^*(r_{k+1} + B(y_k - y_{k+1})) \\ 0 &\in \partial g(y_{k+1}) + B^* \lambda_k + \gamma B^* r_{k+1}. \end{aligned} \quad (7.54)$$

Selain itu, pembaruan  $\lambda$  dapat ditulis sebagai  $\lambda_{k+1} = \lambda_k + \gamma r_{k+1}$ , sehingga

$$\begin{aligned} A^* \lambda_{k+1} &= A^* \lambda_k + \gamma A^* r_{k+1} \\ B^* \lambda_{k+1} &= B^* \lambda_k + \gamma B^* r_{k+1}. \end{aligned} \quad (7.55)$$

Ketika dimasukkan ke (7.54), persamaan ini memberikan

$$\begin{aligned} 0 &\in \partial f(x_{k+1}) + A^*(\lambda_{k+1} + \gamma B(y_k - y_{k+1})) \\ 0 &\in \partial g(y_{k+1}) + B^* \lambda_{k+1}. \end{aligned} \quad (7.56)$$

Hal ini menyiratkan bahwa  $x_{k+1}$  meminimumkan

$$x \mapsto f(x) + \langle Ax, \lambda_{k+1} + \gamma B(y_k - y_{k+1}) \rangle, \quad (7.57)$$

sedangkan  $y_{k+1}$  meminimumkan

$$y \mapsto g(y) + \langle By, \lambda_{k+1} \rangle. \quad (7.58)$$

Akibatnya, dari optimalitas diperoleh

$$\begin{aligned} f(x_{k+1}) + \langle Ax_{k+1}, \lambda_{k+1} + \gamma B(y_k - y_{k+1}) \rangle + g(y_{k+1}) + \langle By_{k+1}, \lambda_{k+1} \rangle \\ \leq f(x^*) + \langle Ax^*, \lambda_{k+1} + \gamma B(y_k - y_{k+1}) \rangle + g(y^*) + \langle By^*, \lambda_{k+1} \rangle. \end{aligned} \quad (7.59)$$

Karena titik pelana pasti memenuhi  $Ax^* + By^* = z$ , sedikit penyusunan ulang memberikan

$$p_{k+1} - p^* \leq \gamma \langle A(x^* - x_{k+1}), B(y_k - y_{k+1}) \rangle - \langle r_{k+1}, \lambda_{k+1} \rangle. \quad (7.60)$$

Terakhir, kita dapat memasukkan  $A(x^* - x_{k+1}) = z - By^* - (r_{k+1} + z - By_{k+1}) = -r_{k+1} + B(y_{k+1} - y^*)$  untuk memperoleh

$$p_{k+1} - p^* \leq -\gamma \langle -r_{k+1} + B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle - \langle r_{k+1}, \lambda_{k+1} \rangle. \quad (7.61)$$

**Langkah 3** Dengan menjumlahkan (7.53) dan (7.61), lalu mengalikan dengan 2, diperoleh

$$-2\gamma \langle r_{k+1}, B(y_{k+1} - y_k) \rangle + 2\gamma \langle B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle + 2 \langle r_{k+1}, \lambda_{k+1} - \lambda^* \rangle \leq 0. \quad (7.62)$$

Kita akan mengolah ketaksamaan ini. Suku ketiga dapat ditulis ulang menggunakan  $\lambda_{k+1} = \lambda_k + \gamma r_{k+1}$  sebagai

$$2 \langle r_{k+1}, \lambda_{k+1} - \lambda^* \rangle = \gamma \|r_{k+1}\|^2 + \gamma \|r_{k+1}\|^2 + 2 \langle r_{k+1}, \lambda_k - \lambda^* \rangle. \quad (7.63)$$

Dengan mengganti  $r_{k+1} = (\lambda_{k+1} - \lambda_k)/\gamma$  pada dua suku terakhir, diperoleh

$$\gamma \|r_{k+1}\|^2 + \gamma^{-1} \|\lambda_{k+1} - \lambda_k\|^2 + 2\gamma^{-1} \langle \lambda_{k+1} - \lambda_k, \lambda_k - \lambda^* \rangle. \quad (7.64)$$

Dengan mengganti  $\lambda_{k+1} - \lambda_k = \lambda_{k+1} - \lambda^* + \lambda^* - \lambda_k$  di atas, bentuk ini ekuivalen dengan

$$\gamma \|r_{k+1}\|^2 + \gamma^{-1} (\|\lambda_{k+1} - \lambda^*\|^2 - \|\lambda_k - \lambda^*\|^2). \quad (7.65)$$

Jadi, (7.62) ekuivalen dengan

$$0 \geq -2\gamma \langle r_{k+1}, B(y_{k+1} - y_k) \rangle + 2\gamma \langle B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle + \gamma \|r_{k+1}\|^2 + \gamma^{-1} (\|\lambda_{k+1} - \lambda^*\|^2 - \|\lambda_k - \lambda^*\|^2). \quad (7.66)$$

Sekarang kita tulis ulang tiga suku pertama,

$$-2\gamma \langle r_{k+1}, B(y_{k+1} - y_k) \rangle + 2\gamma \langle B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle + \gamma \|r_{k+1}\|^2. \quad (7.67)$$

Dengan memperhatikan bahwa

$$-2 \langle r_{k+1}, B(y_{k+1} - y_k) \rangle + \|r_{k+1}\|^2 = \|r_{k+1} - B(y_{k+1} - y_k)\|^2 - \|B(y_{k+1} - y_k)\|^2, \quad (7.68)$$

kita mendapatkan bahwa (7.66) ekuivalen dengan

$$\gamma \|r_{k+1} - B(y_{k+1} - y_k)\|^2 - \gamma \|B(y_{k+1} - y_k)\|^2 + 2\gamma \langle B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle, \quad (7.69)$$

yang ekuivalen dengan

$$\gamma \|r_{k+1} - B(y_{k+1} - y_k)\|^2 + \gamma (\|B(y_{k+1} - y^*)\|^2 - \|B(y_k - y^*)\|^2). \quad (7.70)$$

Secara keseluruhan, (7.66) kemudian menghasilkan

$$0 \geq \gamma \|r_{k+1} - B(y_{k+1} - y_k)\|^2 + \gamma (\|B(y_{k+1} - y^*)\|^2 - \|B(y_k - y^*)\|^2) + \gamma^{-1} (\|\lambda_{k+1} - \lambda^*\|^2 - \|\lambda_k - \lambda^*\|^2). \quad (7.71)$$

Terakhir, perhatikan bahwa

$$\|r_{k+1} - B(y_{k+1} - y_k)\|^2 = \|r_{k+1}\|^2 + \|B(y_{k+1} - y_k)\|^2 - 2 \langle r_{k+1}, B(y_{k+1} - y_k) \rangle. \quad (7.72)$$

Kita ingin menunjukkan bahwa suku

$$\langle r_{k+1}, B(y_{k+1} - y_k) \rangle \leq 0. \quad (7.73)$$

Untuk  $k \geq 1$ , ingat bahwa  $y_k$  meminimumkan  $g(y) + \langle By, \lambda_k \rangle$ . Dengan demikian,

$$\begin{aligned} g(y_k) + \langle By_k, \lambda_k \rangle &\leq g(y_{k+1}) + \langle By_{k+1}, \lambda_k \rangle \\ g(y_{k+1}) + \langle By_{k+1}, \lambda_{k+1} \rangle &\leq g(y_k) + \langle By_k, \lambda_{k+1} \rangle. \end{aligned} \quad (7.74)$$

Penjumlahan kedua ketaksamaan memberikan

$$\langle B(y_{k+1} - y_k), \lambda_{k+1} - \lambda_k \rangle \leq 0. \quad (7.75)$$

Dengan memasukkan  $\lambda_{k+1} - \lambda_k = \gamma r_{k+1}$ , diperoleh tanda yang diinginkan. Oleh karena itu,

$$V(y_{k+1}, \lambda_{k+1}) + \gamma \|r_{k+1}\|^2 + \gamma \|B(y_{k+1} - y_k)\|^2 \leq V(y_k, \lambda_k), \quad k \geq 1. \quad (7.76)$$

Menjumlahkan terhadap  $k$  menghasilkan, untuk  $K \geq 2$ ,

$$\sum_{k=1}^{K-1} \gamma (\|r_{k+1}\|^2 + \|B(y_{k+1} - y_k)\|^2) \leq V(y_1, \lambda_1). \quad (7.77)$$

Dari penurunan fungsional Lyapunov, segera diperoleh bahwa  $\lambda_k$  dan  $By_k$  merupakan barisan terbatas. Selain itu,

$$\begin{cases} r_k & \rightarrow 0 \\ B(y_{k+1} - y_k) & \rightarrow 0. \end{cases} \quad (7.78)$$

Berdasarkan (7.53) dan (7.61), kita mempunyai

$$-\langle \lambda^*, r_{k+1} \rangle \leq p_{k+1} - p^* \leq -\gamma \langle -r_{k+1} + B(y_{k+1} - y^*), B(y_{k+1} - y_k) \rangle - \langle r_{k+1}, \lambda_{k+1} \rangle. \quad (7.79)$$

Kemudian (7.78) dan keterbatasan  $By_k$  menyiratkan bahwa  $p_k \rightarrow p^*$ .  $\square$

## Bab 8

# Penurunan Gradien Stokastik

Andaikan kita ingin menyelesaikan

$$\min_x f(x), \quad (8.1)$$

tetapi hanya mempunyai akses ke estimasi acak yang tak bias bagi suatu subgradien  $f$ . Artinya, kita mengandaikan dapat mengevaluasi  $G(x, z)$  yang memenuhi

$$\mathbb{E}[G(x, Z)] \in \partial f(x), \quad (8.2)$$

dengan  $Z$  suatu peubah acak. Ternyata banyak bukti konvergensi dapat dialihkan ke latar stokastik ini dengan hampir tanpa upaya tambahan. Sebelum menunjukkannya, mari kita berikan motivasi untuk latar ini.

Dalam pembelajaran mesin modern, banyak masalah pembelajaran dapat dirumuskan sebagai masalah jumlah hingga. Agar pengambilan sampel seragam menghasilkan estimator gradien yang tak bias, kita makai normalisasi rerata

$$\min_x f(x) := \frac{1}{N} \sum_{i=1}^N f_i(x), \quad (8.3)$$

dengan  $N$  biasanya merupakan banyaknya sampel pelatihan. Sebagai contoh, andaikan kita ingin mempelajari pemetaan berparameter  $f_\theta$  yang seharusnya menghampiri relasi  $x \mapsto y$  berdasarkan data pelatihan  $(x_i, y_i)_{i=1}^N$ . Masalah pelatihannya dapat berupa

$$\min_{\theta} \frac{1}{N} \sum_{i=1}^N \|y_i - f_\theta(x_i)\|^2. \quad (8.4)$$

Karena ukuran data pelatihan yang dijumpai, sering kali gradien penuh  $f$  tidak dapat dihitung secara langsung akibat keterbatasan memori. Jika semua  $f_i$  terdiferensialkan, salah satu jalan keluarnya adalah pembaruan stokastik

$$\begin{cases} \text{Pilih } i \in \mathcal{I} \text{ secara seragam} \\ x_{k+1} = x_k - \tau \nabla f_i(x_k) \end{cases} \quad (8.5)$$

dengan  $\mathcal{I} = \{1, \dots, N\}$ . Dengan mendefinisikan  $(Z_k)_k$  sebagai barisan peubah acak iid yang berdistribusi seragam pada  $\mathcal{I}$ , pembaruan di atas dapat ditulis sebagai

$$x_{k+1} = x_k - \tau G(x_k, Z_k) \quad (8.6)$$

dengan  $G(x, z) := \nabla f_z(x)$ . Memang,  $\mathbb{E}[G(x, Z)] = N^{-1} \sum_{i=1}^N \nabla f_i(x) = \nabla f(x)$ , sehingga  $G$  memenuhi (8.2).

**Teorema 8.1.** Misalkan  $C \subseteq \mathbb{R}^d$  tak kosong, tertutup, dan konveks, serta misalkan  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  konveks dan  $L$ -Lipschitz. Andaikan masalah  $\min_{x \in C} f(x)$  mempunyai solusi, pilih  $x^* \in \arg \min_{x \in C} f(x)$ , dan ambil  $x_0 \in C$ . Untuk  $k \geq 0$ , misalkan  $G_k := G(x_k, Z_k)$  dan jalankan iterasi terproyeksi  $x_{k+1} = \text{proj}_C(x_k - \tau_k G_k)$  dengan  $\tau_k > 0$ .

Tuliskan  $\mathcal{F}_k = \sigma(x_0, Z_0, \dots, Z_{k-1})$ , sehingga  $x_k$  terukur terhadap  $\mathcal{F}_k$ , dan definisikan  $\bar{g}_k := \mathbb{E}[G_k \mid \mathcal{F}_k]$ . Andaikan, hampir pasti untuk setiap  $k$ ,

$$\begin{cases} \bar{g}_k \in \partial f(x_k), \\ \mathbb{E}[\|G_k - \bar{g}_k\|^2 \mid \mathcal{F}_k] \leq \sigma^2 < \infty. \end{cases} \quad (8.7)$$

Andaikan pula ukuran langkah memenuhi

$$\sum_{k=0}^{K-1} \tau_k \longrightarrow \infty, \quad \frac{\sum_{k=0}^{K-1} \tau_k^2}{\sum_{k=0}^{K-1} \tau_k} \longrightarrow 0 \quad \text{ketika } K \longrightarrow \infty.$$

Untuk  $K \geq 1$ , definisikan  $f_{\text{best}}^K := \min_{0 \leq k \leq K-1} f(x_k)$ . Maka  $\mathbb{E}[f_{\text{best}}^K - f(x^*)] \rightarrow 0$  ketika  $K \rightarrow \infty$ .

*Bukti.* Karena  $x^* \in C$ , kita mempunyai  $\text{proj}_C(x^*) = x^*$ . Ketakmembangan proyeksi metrik memberikan

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &= \|\text{proj}_C(x_k - \tau_k G_k) - \text{proj}_C(x^*)\|^2 \\ &\leq \|x_k - \tau_k G_k - x^*\|^2 \\ &= \|x_k - x^*\|^2 - 2\tau_k \langle x_k - x^*, G_k \rangle + \tau_k^2 \|G_k\|^2. \end{aligned} \quad (8.8)$$

Perhatikan bahwa sifat terukur  $x_k$  dan ketakbiasan bersyarat memberi

$$\begin{aligned} \mathbb{E}[\langle x_k - x^*, G_k \rangle] &= \mathbb{E}[\mathbb{E}[\langle x_k - x^*, G_k \rangle \mid \mathcal{F}_k]] \\ &= \mathbb{E}[\langle x_k - x^*, \bar{g}_k \rangle] \\ &\geq \mathbb{E}[f(x_k) - f(x^*)] \\ &= \mathbb{E}[f(x_k)] - f(x^*), \end{aligned} \quad (8.9)$$

dengan ketaksamaan subgradien pada baris ketiga. Karena fungsi konveks  $f$  bersifat  $L$ -Lipschitz pada  $\mathbb{R}^d$ , setiap subgradiennya mempunyai norma paling besar  $L$ . Identitas momen kedua bersyarat kemudian menghasilkan

$$\mathbb{E}[\|G_k\|^2 \mid \mathcal{F}_k] = \mathbb{E}[\|G_k - \bar{g}_k\|^2 \mid \mathcal{F}_k] + \|\bar{g}_k\|^2 \leq \sigma^2 + L^2 := M^2. \quad (8.10)$$

Dengan mengambil ekspektasi pada ketaksamaan pertama, diperoleh

$$\mathbb{E}[\|x_{k+1} - x^*\|^2] \leq \mathbb{E}[\|x_k - x^*\|^2] - 2\tau_k (\mathbb{E}[f(x_k)] - f(x^*)) + \tau_k^2 M^2. \quad (8.11)$$

Selebihnya mengikuti argumen pada kasus deterministik. Menjumlahkan dari  $k = 0$  sampai  $K - 1$ , memakai ketaknegatifan suku jarak terakhir, lalu membagi dengan 2 memberikan

$$\sum_{k=0}^{K-1} \tau_k (\mathbb{E}[f(x_k)] - f(x^*)) \leq \frac{1}{2} \|x_0 - x^*\|^2 + \frac{M^2}{2} \sum_{k=0}^{K-1} \tau_k^2. \quad (8.12)$$

Definisikan

$$S_K := \sum_{k=0}^{K-1} \tau_k, \quad Q_K := \sum_{k=0}^{K-1} \tau_k^2. \quad (8.13)$$

Karena  $\tau_k > 0$ , minimum terbaik tidak melebihi rerata berbobot. Oleh karena itu,

$$\begin{aligned} \mathbb{E}[f_{\text{best}}^K - f(x^*)] &\leq \frac{\sum_{k=0}^{K-1} \tau_k \mathbb{E}[f(x_k) - f(x^*)]}{S_K} \\ &\leq \frac{\|x_0 - x^*\|^2}{2S_K} + \frac{M^2 Q_K}{2S_K}. \end{aligned} \quad (8.14)$$

Berdasarkan kedua syarat ukuran langkah,

$$0 \leq \mathbb{E}[f_{\text{best}}^K - f(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2S_K} + \frac{M^2 Q_K}{2S_K} \longrightarrow 0 \quad (K \rightarrow \infty). \quad (8.15)$$

□

## Bab 9

# Selingan tentang Transportasi Optimal

Meskipun tidak sepenuhnya menyatu dengan kuliah ini, kita menutupnya dengan suatu selingan mengenai transportasi optimal (OT), bidang yang sangat penting dalam matematika modern dan pembelajaran mesin. Perlu ditekankan sejak awal bahwa uraian ini hanya pengantar singkat; sejumlah rincian teori ukuran dan topologi yang mendasarinya akan dinyatakan seperlunya.

**Notasi** Dalam bagian berikut,  $(X, \Sigma_X)$  dan  $(Y, \Sigma_Y)$  adalah ruang terukur<sup>1</sup>. Tuliskan  $\mathcal{P}(X)$  dan  $\mathcal{P}(Y)$  untuk himpunan semua ukuran probabilitas,  $\mathcal{M}(X)$  dan  $\mathcal{M}(Y)$  untuk ruang ukuran bertanda hingga, serta  $\mathcal{M}_+(X)$  dan  $\mathcal{M}_+(Y)$  untuk kerucut ukuran tak negatif hingga. Ingat bahwa ukuran bertanda  $\mu$  pada  $X$  adalah fungsi  $\mu : \Sigma_X \rightarrow \mathbb{R}$ , sedangkan ukuran tak negatif bernilai dalam  $[0, \infty)$ , dengan  $\Sigma_X \subseteq 2^X$  suatu aljabar- $\sigma$ <sup>2</sup>, dan memenuhi

(i)  $\mu(\emptyset) = 0$ ;

(ii) untuk setiap barisan  $(A_n)_{n \in \mathbb{N}} \subset \Sigma_X$  yang saling lepas, berlaku  $\mu(\bigcup_n A_n) = \sum_n \mu(A_n)$ .

Ukuran probabilitas adalah ukuran tak negatif dengan  $\mu(X) = 1$ .

### 9.1 Transportasi optimal Monge dan Kantorovich

Motivasi khas untuk OT adalah sebagai berikut. Bayangkan kita ingin memindahkan setumpuk pasir dari satu tempat ke tempat lain. Berdasarkan kekekalan massa, kedua tumpukan mempunyai massa total yang sama; tanpa mengurangi keumuman, kita andaikan massanya satu. Karena itu, tumpukan awal dapat digambarkan oleh distribusi probabilitas  $\alpha \in \mathcal{P}(X)$  dan tumpukan akhir oleh distribusi probabilitas  $\beta \in \mathcal{P}(Y)$ . Pertanyaan yang hendak dijawab dalam OT adalah:

*Bagaimana kita dapat mengangkut tumpukan  $\alpha$  ke  $\beta$  dengan biaya minimum?*

Pembaca yang teliti mungkin menyadari bahwa *biaya* belum ditentukan. Andaikan tersedia fungsi biaya terukur yang terbatas dari bawah,  $c : X \times Y \rightarrow (-\infty, +\infty]$ , dengan  $c(x, y)$  menyatakan biaya untuk mengangkut satu satuan massa dari  $x \in X$  ke  $y \in Y$ . Setiap transportasi deterministik dari  $\alpha$  ke  $\beta$  dimodelkan oleh pemetaan terukur  $T : X \rightarrow Y$ . Syarat pengangkutan dapat dirumuskan dengan meminta  $\alpha(T^{-1}(A)) = \beta(A)$  untuk setiap  $A \in \Sigma_Y$ . Ini mengantar kita pada definisi berikut.

**Definisi 9.1** (Ukuran hasil dorong (*push-forward*)). Misalkan  $\alpha \in \mathcal{P}(X)$  dan  $T : X \rightarrow Y$  terukur. Ukuran hasil dorong  $T_\# \alpha \in \mathcal{P}(Y)$  didefinisikan oleh  $T_\# \alpha(A) = \alpha(T^{-1}(A))$  untuk setiap  $A \in \Sigma_Y$ .


Sekarang kita dapat memperkenalkan secara formal masalah Monge untuk OT:

**Definisi 9.2** (Monge OT). Misalkan  $X$  dan  $Y$  ruang terukur,  $\alpha \in \mathcal{P}(X)$ ,  $\beta \in \mathcal{P}(Y)$ , dan  $c$  fungsi biaya terukur yang terbatas dari bawah. Masalah Monge untuk OT adalah

$$\inf_{\substack{T: X \rightarrow Y \text{ terukur} \\ T_\# \alpha = \beta}} \int c(x, T(x)) d\alpha(x), \quad \inf \emptyset := +\infty. \quad (9.1)$$

<sup>1</sup>Ketika topologi dibutuhkan, keduanya akan diasumsikan sebagai ruang Polish dengan aljabar- $\sigma$  Borel; yaitu, ruang topologis separabel yang topologinya dibangkitkan oleh suatu metrik lengkap.

<sup>2</sup>Secara khusus,  $\Sigma_X$  memuat himpunan kosong serta tertutup terhadap komplemen dan gabungan terhitung.



Gambar 9.1: Ilustrasi OT. Peta  $T$  mengangkut *tumpukan* dari  $\alpha$  ke  $\beta$ .

Masalah Monge untuk OT mempunyai beberapa kekurangan. Sebagai contoh, setiap  $x$  hanya dapat dipetakan oleh  $T$  ke *satu* titik  $y$ , sehingga massa pada satu titik  $x$  tidak dapat dibagi ke beberapa titik  $y$ . Karena itu, apabila  $\alpha$  memberikan massa tak nol pada suatu titik,  $Y \subseteq \mathbb{R}^q$ , dan  $\beta$  kontinu mutlak terhadap ukuran Lebesgue<sup>3</sup>, tidak ada peta  $T$  yang memenuhi syarat. Selain itu, bergantung pada pilihan  $c$ , masalah ini umumnya sulit dianalisis karena peubah tak diketahui  $T$  muncul di dalam biaya  $c$ .

Perumusan yang lebih umum dan lebih mudah dianalisis adalah OT Kantorovich. Alih-alih memakai peta  $T : X \rightarrow Y$ , transportasi juga dimodelkan oleh suatu distribusi. Suatu rencana transportasi adalah distribusi probabilitas  $\gamma$  pada ruang hasil kali terukur  $X \times Y$  yang mempunyai  $\alpha$  dan  $\beta$  sebagai marginalnya:  $\gamma(A \times Y) = \alpha(A)$  dan  $\gamma(X \times B) = \beta(B)$  untuk semua  $A \in \Sigma_X$  dan  $B \in \Sigma_Y$ . Secara intuitif,  $\gamma(A \times B)$  adalah massa yang diangkut dari  $A$  ke  $B$ . Himpunan semua distribusi dengan marginal  $\alpha, \beta$  dilambangkan dengan  $\Pi(\alpha, \beta)$  dan anggotanya disebut kopling (*coupling*). Sekarang kita dapat mendefinisikan masalah Kantorovich untuk OT.

**Definisi 9.3** (Kantorovich OT). Misalkan  $X$  dan  $Y$  ruang terukur,  $\alpha \in \mathcal{P}(X)$ ,  $\beta \in \mathcal{P}(Y)$ , dan  $c$  fungsi biaya terukur. Masalah Kantorovich untuk OT adalah

$$\inf_{\gamma \in \Pi(\alpha, \beta)} \int c(x, y) d\gamma(x, y). \quad (9.2)$$

Perhatikan bahwa (9.2) jauh lebih menguntungkan daripada (9.1). Secara khusus, objektifnya kini linear.

**Catatan.** Kita juga dapat merumuskan (9.2) dengan peubah acak. Setiap kopling  $\gamma$  dapat *direalisasikan* sebagai vektor acak  $(X, Y) \sim \gamma$  dengan  $X \sim \alpha$  dan  $Y \sim \beta$ . Biayanya kemudian memenuhi

$$\int c(x, y) d\gamma(x, y) = \mathbb{E}[c(X, Y)]. \quad (9.3)$$

Kita nyatakan hasil berikut.

**Teorema 9.4** (Eksistensi solusi). Misalkan  $X$  dan  $Y$  ruang Polish yang dilengkapi aljabar- $\sigma$  Borelnya,  $\alpha \in \mathcal{P}(X)$ , dan  $\beta \in \mathcal{P}(Y)$ . Jika  $c : X \times Y \rightarrow (-\infty, +\infty]$  terbatas dari bawah dan semikontinu bawah, maka terdapat rencana transportasi optimal  $\hat{\gamma} \in \Pi(\alpha, \beta)$ , yaitu solusi untuk (9.2).

*Sketsa bukti.* Untuk bukti terperinci, lihat misalnya Villani 2009, Theorem 4.1. Argumennya adalah metode langsung. Ambil barisan  $(\gamma_n)_n \subset \Pi(\alpha, \beta)$  yang nilai biayanya menuju infimum. Karena  $\alpha$  dan  $\beta$  ketat pada ruang Polish, keluarga kopling dengan kedua marginal tetap juga ketat. Himpunan  $\Pi(\alpha, \beta)$  tertutup terhadap konvergensi lemah; teorema Prokhorov karena itu menyatakan bahwa himpunan tersebut kompak secara lemah. Setelah mengambil suatu subbarisan, diperoleh  $\gamma_n \rightarrow \hat{\gamma} \in \Pi(\alpha, \beta)$ . Karena  $c$  semikontinu bawah dan terbatas dari bawah, pemetaan  $\gamma \mapsto \int c(x, y) d\gamma(x, y)$  semikontinu bawah secara lemah. Maka  $\hat{\gamma}$  meminimumkan biaya dan bukti selesai.  $\square$

<sup>3</sup>Hal ini khususnya menyiratkan bahwa  $\beta$  tidak mempunyai massa titik.

Satu kasus khusus penting dari transportasi optimal perlu disoroti.

**Definisi 9.5** (Jarak Wasserstein). Misalkan  $(X, d)$  ruang metrik Polish dan  $p \in [1, \infty)$ . Tetapkan  $x_0 \in X$  dan tuliskan  $\mathcal{P}_p(X) := \{\mu \in \mathcal{P}(X) : \int d(x, x_0)^p d\mu(x) < \infty\}$ ; definisi ini tidak bergantung pada pilihan  $x_0$ . Untuk  $\alpha, \beta \in \mathcal{P}_p(X)$  dan biaya  $c(x, y) = d(x, y)^p$ , besaran

$$W_p(\alpha, \beta) := \left( \inf_{\gamma \in \Pi(\alpha, \beta)} \int d(x, y)^p d\gamma(x, y) \right)^{1/p} \quad (9.4)$$

disebut jarak Wasserstein- $p$ .

Secara khusus,  $W_p$  adalah metrik pada ruang ukuran probabilitas bermomen ke- $p$  hingga, yaitu  $\mathcal{P}_p(X)$ .

## 9.2 Dualitas Kantorovich

Dari [Chapter 7](#) kita telah mengenal konsep dualitas. Dualitas memainkan peran penting dalam OT dan menghasilkan teorema terkenal berikut.

**Teorema 9.6** (Dualitas Kantorovich). Misalkan  $X$  dan  $Y$  ruang Polish dengan aljabar- $\sigma$  Borelnya,  $\alpha \in \mathcal{P}(X)$ ,  $\beta \in \mathcal{P}(Y)$ , dan  $c : X \times Y \rightarrow [0, \infty]$  semikontinu bawah. Tuliskan  $C_b(X)$  dan  $C_b(Y)$  untuk fungsi kontinu terbatas bernilai riil. Maka

$$\inf_{\gamma \in \Pi(\alpha, \beta)} \int c(x, y) d\gamma(x, y) = \sup_{\substack{\varphi \in C_b(X), \psi \in C_b(Y) \\ \varphi(x) + \psi(y) \leq c(x, y) \quad \forall (x, y)}} \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y). \quad (9.5)$$

*Sketsa bukti.* Kita mulai dengan ketaksamaan yang mudah. Ambil  $(\varphi, \psi) \in C_b(X) \times C_b(Y)$  sedemikian sehingga  $\varphi(x) + \psi(y) \leq c(x, y)$  untuk semua  $(x, y)$ , dan ambil sembarang  $\gamma \in \Pi(\alpha, \beta)$ . Maka

$$\begin{aligned} \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) &= \int \varphi(x) d\gamma(x, y) + \int \psi(y) d\gamma(x, y) \\ &= \int (\varphi(x) + \psi(y)) d\gamma(x, y) \\ &\leq \int c(x, y) d\gamma(x, y). \end{aligned} \quad (9.6)$$

Karena  $\gamma$  dan  $(\varphi, \psi)$  sembarang, kita dapat mengambil infimum di ruas kanan dan supremum di ruas kiri untuk memperoleh

$$\sup_{\substack{\varphi \in C_b(X), \psi \in C_b(Y) \\ \varphi(x) + \psi(y) \leq c(x, y) \quad \forall (x, y)}} \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) \leq \inf_{\gamma \in \Pi(\alpha, \beta)} \int c(x, y) d\gamma(x, y). \quad (9.7)$$

Ketaksamaan sebaliknya lebih rumit. Pertama, kita dapat menulis ulang (9.2) sebagai

$$\inf_{\gamma \in \mathcal{M}_+(X \times Y)} \left\{ \int c(x, y) d\gamma + \delta_{\Pi(\alpha, \beta)}(\gamma) \right\}, \quad (9.8)$$

dengan  $\delta_{\Pi(\alpha, \beta)}$  fungsi indikator seperti biasa. Untuk  $\gamma \in \mathcal{M}_+(X \times Y)$ , berlaku

$$\begin{aligned} \delta_{\Pi(\alpha, \beta)}(\gamma) &= \sup_{\varphi \in C_b(X), \psi \in C_b(Y)} \left\{ \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) \right. \\ &\quad \left. - \int (\varphi(x) + \psi(y)) d\gamma(x, y) \right\}. \end{aligned} \quad (9.9)$$

Jika  $\gamma \in \Pi(\alpha, \beta)$ , ekspresi di dalam supremum pada ruas kanan bernilai nol untuk setiap  $(\varphi, \psi)$ , sehingga supremumnya nol. Sebaliknya, jika  $\gamma \notin \Pi(\alpha, \beta)$ , sedikitnya satu marginal berbeda. Ukuran Borel hingga yang

berbeda pada ruang Polish dapat dipisahkan oleh suatu fungsi kontinu terbatas; tanpa mengurangi keumuman, terdapat  $\varphi \in C_b(X)$  sedemikian sehingga

$$\int \varphi d(\alpha - \gamma_x) \neq 0, \quad (9.10)$$

dengan  $\gamma_x$  marginal- $x$  dari  $\gamma$ . Mengganti  $\varphi$  dengan  $t\varphi$  dan memilih tanda  $t$  ketika  $|t| \rightarrow \infty$  menunjukkan bahwa supremumnya adalah  $+\infty$ .

Langkah taktrivial untuk ketaksamaan sebaliknya adalah pertukaran infimum dan supremum. Pertukaran itu tidak mengikuti perhitungan formal semata; di bawah hipotesis ruang Polish dan biaya semikontinu bawah tak negatif di atas, pertukaran tersebut dijamin oleh teorema dualitas Kantorovich standar, lihat Villani 2009, Theorem 5.10. Dengan justifikasi dualitas kuat ini, diperoleh

$$\begin{aligned} \inf_{\gamma \in \Pi(\alpha, \beta)} \int c(x, y) d\gamma(x, y) &= \inf_{\gamma \in \mathcal{M}_+(X \times Y)} \sup_{\varphi \in C_b(X), \psi \in C_b(Y)} \left\{ \int c(x, y) d\gamma(x, y) \right. \\ &\quad \left. + \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) \right. \\ &\quad \left. - \int (\varphi(x) + \psi(y)) d\gamma(x, y) \right\} \\ &= \sup_{\varphi \in C_b(X), \psi \in C_b(Y)} \left\{ \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y) \right. \\ &\quad \left. + \inf_{\gamma \in \mathcal{M}_+(X \times Y)} \int (c(x, y) - \varphi(x) - \psi(y)) d\gamma(x, y) \right\} \\ &= \sup_{\substack{\varphi \in C_b(X), \psi \in C_b(Y) \\ \varphi(x) + \psi(y) \leq c(x, y) \quad \forall (x, y)}} \int \varphi(x) d\alpha(x) + \int \psi(y) d\beta(y). \end{aligned} \quad (9.11)$$

Pada persamaan terakhir, infimum terhadap ukuran tak negatif bernilai nol jika  $c - \varphi - \psi \geq 0$  di setiap titik (ambil  $\gamma = 0$ ), dan bernilai  $-\infty$  jika ketaksamaan itu gagal (skalakan massa Dirac pada titik pelanggaran). Ini sama dengan fungsi indikator kendala dual, sebagaimana pada (9.9).  $\square$

### 9.3 Diskretisasi transportasi optimal: Algoritme Sinkhorn–Knopp

Untuk mendiskretisasi (9.2), kita modelkan  $\alpha$  dan  $\beta$  sebagai ukuran diskret. Tuliskan  $\Delta_n := \{r \in \mathbb{R}_+^n : \mathbb{1}_n^\top r = 1\}$  dan  $\Delta_n^\circ := \{r \in \mathbb{R}_{++}^n : \mathbb{1}_n^\top r = 1\}$ . Untuk suatu vektor  $a = (a_1, \dots, a_n) \in \Delta_n$  dan titik  $x_i \in X$ , tetapkan

$$\alpha = \sum_{i=1}^n a_i \delta_{x_i}, \quad (9.12)$$

dan, serupa dengan itu, untuk  $b = (b_1, \dots, b_m) \in \Delta_m$  dan  $y_j \in Y$ , tetapkan

$$\beta = \sum_{j=1}^m b_j \delta_{y_j}. \quad (9.13)$$

Selanjutnya, definisikan  $C = [C_{i,j}]_{i,j} = [c(x_i, y_j)]_{i,j}$ . Rencana transportasi adalah matriks  $P \in \mathbb{R}^{n \times m}$  sedemikian sehingga

$$\begin{cases} \sum_{j=1}^m P_{i,j} &= a_i, \\ \sum_{i=1}^n P_{i,j} &= b_j, \\ P_{i,j} &\geq 0. \end{cases} \quad (9.14)$$

Kendala marginal dapat ditulis ringkas sebagai  $P \mathbb{1}_m = a$  dan  $P^\top \mathbb{1}_n = b$ . Masalah OT diskret kemudian berbentuk

$$\min_{P \in \mathbb{R}^{n \times m}} \langle C, P \rangle = \sum_{i,j} C_{i,j} P_{i,j} \quad (9.15)$$

dengan syarat  $P \mathbb{1}_m = a$ ,  $P^\top \mathbb{1}_n = b$ ,  $P_{i,j} \geq 0$ .

Dalam praktik, masalah ini sering diregularisasi. Untuk pembahasan regularisasi entropik berikut, andaikan  $C \in \mathbb{R}^{n \times m}$ , sehingga semua biaya diskret berhingga. Untuk  $P \in \mathbb{R}_+^{n \times m}$ , definisikan regularisasi entropik

$$E(P) := \sum_{i,j} P_{i,j} (\log(P_{i,j}) - 1), \quad (9.16)$$

dengan konvensi kontinu  $0 \log 0 = 0$ ; di luar ortan tak negatif, tetapkan  $E(P) = +\infty$ . Untuk  $\varepsilon > 0$ , pertimbangkan masalah

$$\min_{P \in \mathbb{R}_+^{n \times m}} \langle C, P \rangle + \varepsilon E(P) \quad \text{dengan syarat } P \mathbb{1}_m = a, \quad P^\top \mathbb{1}_n = b. \quad (9.17)$$

**Lema 9.7.** Andaikan  $a \in \Delta_n^\circ$ ,  $b \in \Delta_m^\circ$ ,  $C \in \mathbb{R}^{n \times m}$ , dan  $\varepsilon > 0$ . Solusi masalah (9.17) unik dan mempunyai representasi

$$P_{i,j} = u_i K_{i,j} v_j, \quad (9.18)$$

dengan  $u_i, v_j > 0$  dan  $K_{i,j} = \exp\left(-\frac{C_{i,j}}{\varepsilon}\right) > 0$ . Vektor penskalaan  $(u, v)$  unik hingga transformasi  $(u, v) \mapsto (tu, t^{-1}v)$  untuk  $t > 0$ .

*Bukti.* Himpunan layak adalah politop transportasi tak kosong dan kompak: matriks  $Q = ab^\top$  layak, bahkan  $Q_{i,j} > 0$ . Karena fungsi objektif kontinu pada politop ini, suatu peminimum ada. Fungsi  $h(t) = t(\log t - 1)$  dengan  $h(0) = 0$  bersifat konveks ketat pada  $[0, \infty)$ ; karena itu, jumlah entropik bersifat konveks ketat dan peminimumnya unik.

Peminimum  $P$  tidak dapat mempunyai entri nol. Memang, jika  $P_{i,j} = 0$  untuk sedikitnya satu pasangan  $(i, j)$ , maka  $P_t = (1-t)P + tQ$  tetap layak untuk  $t \in (0, 1)$ . Pada setiap entri nol, turunan searah satu sisi dari suku entropi memenuhi  $\frac{d}{dt} h(tQ_{i,j}) = Q_{i,j} \log(tQ_{i,j}) \rightarrow -\infty$  ketika  $t \downarrow 0$ , sedangkan kontribusi biaya linear dan turunan pada entri positif tetap hingga. Jadi, untuk  $t > 0$  yang cukup kecil, nilai objektif pada  $P_t$  lebih kecil daripada pada  $P$ , suatu kontradiksi. Dengan demikian,  $P_{i,j} > 0$  untuk semua  $i, j$ , dan kondisi pengali Lagrange untuk kendala marginal affin dapat diterapkan.

Lagrangian masalah ini adalah

$$L(P, \lambda, \mu) = \langle C, P \rangle + \varepsilon E(P) + \langle \lambda, P \mathbb{1}_m - a \rangle + \langle \mu, P^\top \mathbb{1}_n - b \rangle. \quad (9.19)$$

Kondisi optimalitasnya adalah

$$\begin{cases} 0 &= C_{i,j} + \varepsilon \log(P_{i,j}) + \lambda_i + \mu_j, \\ 0 &= P \mathbb{1}_m - a, \\ 0 &= P^\top \mathbb{1}_n - b. \end{cases} \quad (9.20)$$

Kondisi pertama menyiratkan

$$P_{i,j} = \exp\left(-\frac{\lambda_i}{\varepsilon}\right) \exp\left(-\frac{C_{i,j}}{\varepsilon}\right) \exp\left(-\frac{\mu_j}{\varepsilon}\right). \quad (9.21)$$

Dengan  $u_i = \exp(-\lambda_i/\varepsilon)$  dan  $v_j = \exp(-\mu_j/\varepsilon)$ , diperoleh representasi yang dinyatakan. Jika pasangan positif  $(\tilde{u}, \tilde{v})$  menghasilkan rencana yang sama, maka dari  $u_i K_{i,j} v_j = \tilde{u}_i K_{i,j} \tilde{v}_j$  dan  $K_{i,j} > 0$  diperoleh  $\tilde{u}_i/u_i = v_j/\tilde{v}_j$  untuk setiap  $i, j$ . Karena ruas kiri hanya bergantung pada  $i$  dan ruas kanan hanya pada  $j$ , semua rasio itu sama dengan suatu  $t > 0$ ; jadi  $(\tilde{u}, \tilde{v}) = (tu, t^{-1}v)$ .  $\square$

Kendala yang masih harus dipenuhi adalah  $P \mathbb{1}_m = \text{diag}(u) K \text{diag}(v) \mathbb{1}_m = \text{diag}(u) K v = a$  dan  $P^\top \mathbb{1}_n = \text{diag}(v) K^\top u = b$ . Ini memotivasi algoritme Sinkhorn–Knopp. Pilih  $v_0 \in \mathbb{R}_{++}^m$ , misalnya  $v_0 = \mathbb{1}_m$ , lalu untuk  $k = 0, 1, 2, \dots$  perbarui

$$\begin{cases} u_{k+1} = a \oslash (K v_k), \\ v_{k+1} = b \oslash (K^\top u_{k+1}), \end{cases} \quad (9.22)$$

dengan  $\oslash$  menyatakan pembagian komponen demi komponen. Berdasarkan positivitas  $a, b$ , dan  $K$ , semua penyebut dan iterat tetap positif. Dengan hipotesis pada lema di atas, teorema Sinkhorn–Knopp menyatakan bahwa rencana  $\text{diag}(u_k) K \text{diag}(v_k)$ ,  $k \geq 1$ , konvergen ke rencana unik pada masalah (9.17). Vektor penskalaannya sendiri tetap mempunyai ambiguitas perkalian  $(u, v) \mapsto (tu, t^{-1}v)$ .

## **Bagian II**

# **Suplemen Terbatas: Dualitas dan Reduksi Varians**

## Bab 10

# Dualitas Lagrange, kondisi Slater, dan kondisi KKT

Bab ini melengkapi tulang punggung Habring dengan satu jalur terpadu dari Lagrangian ke kondisi Slater dan kondisi Karush-Kuhn-Tucker (KKT). Notasi dibuat konsisten untuk masalah minimisasi. Bagian sumber yang khusus membahas dualitas program linear tidak disertakan karena materi itu berada dalam batas kurikulum O018.

**Kredit catatan donor.**

Catatan donor menyatakan bahwa bagian dualitas mengikuti Bab 5 Boyd dan Vandenberghe (B&V), merujuk ke §5.3 untuk ilustrasi, dan mengaitkan interpretasi perpotongan maksimum atau titik bersama minimum dengan Bertsekas. Kredit turunan ini dipertahankan; edisi ini tidak mengimpor isi di luar rentang donor yang dibekukan.

### 10.1 Masalah primal dan Lagrangian

Pertimbangkan masalah

$$\begin{aligned} p^* &= \inf_{x \in D} f_0(x) \\ \text{dengan syarat} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p, \end{aligned} \tag{10.1}$$

dengan  $D$  memuat domain bersama fungsi-fungsi tersebut. Kita memakai  $p^* = +\infty$  jika masalah tidak layak dan  $p^* = -\infty$  jika nilainya tidak terbatas ke bawah.

**Definisi 10.1** (Lagrangian). Lagrangian masalah (10.1) adalah

$$L(x, \lambda, \nu) = f_0(x) + \sum_{i=1}^m \lambda_i f_i(x) + \sum_{j=1}^p \nu_j h_j(x). \tag{10.2}$$

Vektor  $\lambda \in \mathbb{R}^m$  dan  $\nu \in \mathbb{R}^p$  disebut variabel dual atau pengali Lagrange. Untuk kendala pertidaksamaan kita akan mensyaratkan  $\lambda \geq 0$  komponen demi komponen.

Lagrangian bergantung pada cara masalah ditulis. Misalnya, untuk  $\inf_x f(x) + g(x)$  kita dapat memperkenalkan  $z$  dan kendala  $x = z$ , lalu membentuk Lagrangian terhadap kendala kesamaan itu. Pemisahan variabel seperti ini sering membuka struktur yang tidak tampak pada rumusan asal.

**Definisi 10.2** (Fungsi dual). Fungsi dual Lagrange didefinisikan oleh

$$g(\lambda, \nu) = \inf_{x \in D} L(x, \lambda, \nu). \tag{10.3}$$

Fungsi  $g$  cekung terhadap  $(\lambda, \nu)$ , bahkan bila masalah primal tidak konveks, sebab  $g$  adalah infimum titik demi titik dari fungsi-fungsi afin dalam variabel dual.

Sebagai kaidah umum yang terkait, minimisasi parsial dari fungsi konveks bersama menghasilkan fungsi konveks pada variabel yang tersisa, sedangkan supremum titik demi titik dari fungsi-fungsi konveks tetap konveks.

**Definisi 10.3** (Masalah dual). Masalah dual Lagrange adalah

$$d^* = \sup_{\lambda \geq 0, v \in \mathbb{R}^p} g(\lambda, v). \quad (10.4)$$

Ini merupakan masalah maksimisasi cekung, atau secara ekuivalen masalah minimisasi konveks untuk  $-g$ .

**Teorema 10.4** (Dualitas lemah). Untuk masalah (10.1) selalu berlaku

$$d^* \leq p^*. \quad (10.5)$$

*Bukti.* Ambil titik layak  $\tilde{x}$ . Untuk setiap  $\lambda \geq 0$  dan setiap  $v$ ,

$$g(\lambda, v) \leq L(\tilde{x}, \lambda, v) = f_0(\tilde{x}) + \underbrace{\sum_{i=1}^m \lambda_i f_i(\tilde{x})}_{\leq 0} + \underbrace{\sum_{j=1}^p v_j h_j(\tilde{x})}_{=0} \leq f_0(\tilde{x}). \quad (10.6)$$

Mengambil infimum terhadap semua titik primal yang layak memberi  $g(\lambda, v) \leq p^*$ . Mengambil supremum terhadap semua titik dual yang layak membuktikan (10.5).  $\square$

Jika  $d^* = p^*$ , kita mengatakan bahwa *dualitas kuat* berlaku. Selain memberi sertifikat batas bawah, masalah dual dapat memindahkan operator linear, menyingkap kehalusan, atau menghasilkan rumusan numerik yang lebih sesuai. Untuk masalah nonkonveks sekalipun, nilai dual tetap menyediakan batas bawah yang sah, walaupun kesenjangan dualitas mungkin positif.

## 10.2 Kondisi Slater dan dualitas kuat

Sekarang andaikan  $f_0, f_1, \dots, f_m$  konveks dan kendala kesamaan berbentuk  $Ax = b$ . Tuliskan  $I_{\text{na}}$  bagi indeks kendala pertidaksamaan yang tidak afin.

**Definisi 10.5** (Kondisi Slater). Kondisi Slater dipenuhi jika terdapat  $\bar{x}$  dalam interior relatif domain bersama sedemikian sehingga

$$A\bar{x} = b, \quad f_i(\bar{x}) < 0 \quad (i \in I_{\text{na}}), \quad f_i(\bar{x}) \leq 0 \quad (i \notin I_{\text{na}}). \quad (10.7)$$

Jadi hanya kendala pertidaksamaan nonafin yang harus dipenuhi secara ketat.

**Teorema 10.6** (Slater). Jika masalah primal konveks, kondisi Slater dipenuhi, dan  $p^*$  berhingga, maka  $d^* = p^*$  dan suatu titik dual optimum  $(\lambda^*, v^*)$  tercapai.

Kondisi Slater bersifat cukup, bukan perlu. Contoh semidefinit berikut menunjukkan salah satu gejala degenerasi. Pertimbangkan

$$\inf_{X=X^T \succeq 0} \left\langle \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}, X \right\rangle \quad \text{dengan syarat} \quad \left\langle \begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}, X \right\rangle = 2. \quad (10.8)$$

Setiap titik layak berbentuk  $X = \begin{pmatrix} a & 1 \\ 1 & b \end{pmatrix} \succeq 0$ , sehingga  $a, b \geq 0$  dan  $ab \geq 1$ . Barisan  $X_\varepsilon = \begin{pmatrix} \varepsilon & 1 \\ 1 & 1/\varepsilon \end{pmatrix}$  memberi nilai objektif yang menuju nol ketika  $\varepsilon \downarrow 0$ . Jadi  $p^* = 0$ , tetapi infimum primal tidak tercapai. Dualnya tetap mempunyai solusi optimum bernilai nol; contoh ini memperingatkan bahwa ketercapaian primal tidak mengikuti hanya dari kesamaan nilai primal dan dual.

Berikut gagasan geometri di balik teorema Slater. Definisikan himpunan nilai terganggu

$$\mathcal{A} = \{(u, v, t) : \exists x \in D, \quad f_i(x) \leq u_i, \quad h(x) = v, \quad f_0(x) \leq t\} \quad (10.9)$$

dan sinar terbuka

$$\mathcal{B} = \{(0, 0, s) : s < p^*\}. \quad (10.10)$$

Kekonveksan fungsi-fungsi kendala membuat  $\mathcal{A}$  konveks, dan  $\mathcal{A} \cap \mathcal{B} = \emptyset$ . Teorema pemisahan memberi normal  $(\lambda^*, \nu^*, \mu^*)$ . Monotonisitas  $\mathcal{A}$  terhadap  $u$  dan  $t$  memberi  $\lambda^* \geq 0$  dan  $\mu^* \geq 0$ . Kondisi Slater menyingkirkan  $\mu^* = 0$ , yaitu hiperbidang penyangga vertikal, sehingga  $\mu^* > 0$  dan normal dapat dinormalkan menjadi  $(\lambda^*, \nu^*, 1)$ . Ketaksamaan pemisahan kemudian menghasilkan

$$\inf_{x \in D} L(x, \lambda^*, \nu^*) \geq p^*. \quad (10.11)$$

Dualitas lemah memberi ketaksamaan sebaliknya; karena itu  $d^* = p^*$  dan pengali dual optimum tercapai. Interpretasi yang sama dapat dinyatakan sebagai perpotongan maksimum atau titik bersama minimum dalam geometri perturbasi.

### 10.3 Interpretasi titik pelana

Untuk Lagrangian (10.2), masalah primal dan dual dapat ditulis sebagai

$$\begin{aligned} p^* &= \inf_x \sup_{\lambda \geq 0, \nu} L(x, \lambda, \nu), \\ d^* &= \sup_{\lambda \geq 0, \nu} \inf_x L(x, \lambda, \nu). \end{aligned} \quad (10.12)$$

Ketaksamaan minimaks

$$\sup_{\lambda \geq 0, \nu} \inf_x L(x, \lambda, \nu) \leq \inf_x \sup_{\lambda \geq 0, \nu} L(x, \lambda, \nu) \quad (10.13)$$

adalah bentuk titik-pelana dari dualitas lemah.

**Definisi 10.7** (Titik pelana). Tripel  $(x^*, \lambda^*, \nu^*)$  adalah titik pelana Lagrangian jika  $\lambda^* \geq 0$  dan

$$L(x^*, \lambda, \nu) \leq L(x^*, \lambda^*, \nu^*) \leq L(x, \lambda^*, \nu^*) \quad (10.14)$$

untuk setiap  $x \in D$ ,  $\lambda \geq 0$ , dan  $\nu \in \mathbb{R}^p$ .

Sebagai contoh, pertimbangkan

$$\min_x \|x\|_1 \quad \text{dengan syarat} \quad \|Ax - b\|_2^2 \leq \varepsilon^2. \quad (10.15)$$

Lagrangiannya adalah

$$L(x, \lambda) = \|x\|_1 + \lambda(\|Ax - b\|_2^2 - \varepsilon^2), \quad \lambda \geq 0. \quad (10.16)$$

Jika pengali optimum memenuhi  $\lambda^* > 0$ , minimisasi Lagrangian terhadap  $x$  ekuivalen, setelah dibagi dengan  $2\lambda^*$ , dengan

$$\min_x \frac{1}{2} \|Ax - b\|_2^2 + \frac{1}{2\lambda^*} \|x\|_1. \quad (10.17)$$

Jadi rumusan berkendala dan rumusan berpenalti berhubungan melalui pengali optimum. Hubungan ini tidak boleh diperoleh dengan membagi oleh  $\lambda^*$  jika pengalinya nol.

### 10.4 Kondisi Karush-Kuhn-Tucker

Andaikan fungsi-fungsi pada masalah (10.1) dapat didiferensialkan. Tripel  $(x^*, \lambda^*, \nu^*)$  memenuhi kondisi KKT jika

- (i) **stasioneritas:**  $\nabla_x L(x^*, \lambda^*, \nu^*) = 0$ ; pada kasus konveks tak mulus, bentuk yang sesuai adalah  $0 \in \partial_x L(x^*, \lambda^*, \nu^*)$ ;
- (ii) **kelayakan primal:**  $f_i(x^*) \leq 0$  dan  $h_j(x^*) = 0$ ;
- (iii) **kelayakan dual:**  $\lambda^* \geq 0$ ;
- (iv) **kekomplesmenteran:**  $\lambda_i^* f_i(x^*) = 0$  untuk setiap  $i = 1, \dots, m$ .

**Teorema 10.8** (KKT perlu dari pasangan primal-dual optimum). *Andaikan optimum primal dan dual tercapai, dualitas kuat berlaku, dan  $x \mapsto L(x, \lambda^*, v^*)$  memiliki syarat optimalitas Fermat yang berlaku pada  $x^*$ . Maka pasangan optimum memenuhi kondisi KKT. Pernyataan ini tetap dapat dipakai pada masalah nonkonveks bila stasioneritas Lagrangian benar-benar mengikuti dari minimisasi globalnya dan seluruh syarat domain dipenuhi.*

**Teorema 10.9** (KKT cukup untuk masalah konveks). *Jika  $f_0, f_1, \dots, f_m$  konveks,  $h_j$  afin, dan suatu tripel memenuhi kondisi KKT, maka  $x^*$  optimum primal,  $(\lambda^*, v^*)$  optimum dual, dan  $p^* = d^*$ .*

*Bukti.* Stasioneritas dan kekonveksan  $x \mapsto L(x, \lambda^*, v^*)$  membuat  $x^*$  peminimum global Lagrangian. Karena itu

$$\begin{aligned} d^* &\geq g(\lambda^*, v^*) = \inf_x L(x, \lambda^*, v^*) \\ &= L(x^*, \lambda^*, v^*) = f_0(x^*) + \sum_i \lambda_i^* f_i(x^*) + \sum_j v_j^* h_j(x^*) \\ &= f_0(x^*) \geq p^*. \end{aligned} \quad (10.18)$$

Dualitas lemah memberi  $d^* \leq p^*$ , sehingga semua ketaksamaan adalah kesamaan.  $\square$

**Teorema 10.10** (KKT perlu di bawah kondisi Slater). *Jika masalah primal konveks memenuhi kondisi Slater dan suatu solusi primal  $x^*$  ada dengan nilai berhingga, maka terdapat pengali  $(\lambda^*, v^*)$  sedemikian sehingga tripel tersebut memenuhi kondisi KKT.*

#### 10.4.1 Contoh: proyeksi pada bola $\ell^1$

Proyeksi  $y \in \mathbb{R}^n$  pada bola  $B_1(\tau) = \{x : \|x\|_1 \leq \tau\}$ , dengan  $\tau > 0$ , menyelesaikan

$$\min_x \frac{1}{2} \|x - y\|_2^2 \quad \text{dengan syarat} \quad \|x\|_1 \leq \tau. \quad (10.19)$$

Kondisi KKT memberi

$$x_i = S_\lambda(y_i) = \text{sign}(y_i) \max\{|y_i| - \lambda, 0\}, \quad \lambda \geq 0, \quad (10.20)$$

bersama  $\|x\|_1 \leq \tau$  dan  $\lambda(\|x\|_1 - \tau) = 0$ . Jika  $\|y\|_1 \leq \tau$ , maka  $\lambda = 0$  dan  $x = y$ . Jika  $\|y\|_1 > \tau$ , maka  $\lambda > 0$  adalah akar unik dari

$$\sum_{i=1}^n \max\{|y_i| - \lambda, 0\} = \tau. \quad (10.21)$$

Ruas kiri kontinu, menurun, dan linear sepotong-sepotong dengan titik patah  $|y_i|$ ; akar dapat dicari dengan biseksi atau, lebih efisien, dengan mengurutkan titik patah. Identitas Moreau menjelaskan hubungan yang tepat:

$$\text{prox}_{\tau\|\cdot\|_\infty}(y) = y - \text{proj}_{B_1(\tau)}(y). \quad (10.22)$$

Kekomplementeran juga mengikuti dari kesamaan primal-dual. Untuk titik pelana optimum  $(x^*, \lambda^*, v^*)$  berlaku

$$f_0(x^*) = L(x^*, \lambda^*, v^*) = f_0(x^*) + \sum_i \lambda_i^* f_i(x^*), \quad (10.23)$$

karena kendala kesamaan lenyap. Setiap suku  $\lambda_i^* f_i(x^*) \leq 0$ , sehingga jumlah nol memaksa  $\lambda_i^* f_i(x^*) = 0$  untuk setiap  $i$ .

#### 10.4.2 Contoh: masalah kuadratik dengan kendala kesamaan

Pertimbangkan

$$\min_x \frac{1}{2} x^\top P x + q^\top x + r \quad \text{dengan syarat} \quad A x = b, \quad P \succeq 0. \quad (10.24)$$

Kondisi KKT adalah

$$P x^* + q + A^\top v^* = 0, \quad A x^* = b, \quad (10.25)$$

atau sistem titik pelana

$$\begin{pmatrix} P & A^\top \\ A & 0 \end{pmatrix} \begin{pmatrix} x^* \\ v^* \end{pmatrix} = \begin{pmatrix} -q \\ b \end{pmatrix}. \quad (10.26)$$

Setiap solusi sistem ini adalah solusi optimum masalah konveks tersebut. Solusi tunggal hanya dijamin jika matriks KKT nonsingular; satu syarat cukup yang umum adalah  $A$  berperingkat baris penuh dan  $P$  definit positif pada  $\ker(A)$ .

## Bab 11

# Reduksi Varians untuk SAA

Pertimbangkan masalah jumlah hingga dari aproksimasi rata-rata sampel (*sample average approximation*, SAA)

$$\min_{x \in \mathbb{R}^n} f(x), \quad f(x) = \frac{1}{N} \sum_{i=1}^N f_i(x), \quad (11.1)$$

dengan  $f$  bernilai hingga pada domain model. Sebagai contoh, untuk model dengan prediktor linear dan fungsi kerugian dapat dipakai

$$f_i(x) = \ell(a_i^\top x - b_i), \quad (11.2)$$

dengan  $\ell$  fungsi kerugian. Huruf  $\ell$  menggantikan huruf  $L$  pada donor agar tidak bertabrakan dengan konstanta kemulusan Lipschitz yang dipakai di bawah.

### 11.1 Tabel gradien dan penaksir SAGA

Pilih iterat awal  $x_0$  dan inisialisasikan satu titik tabel  $\varphi_i^0 = x_0$  untuk setiap  $i = 1, \dots, N$ . Simpan, pada iterasi  $k \geq 0$ ,

$$g_i^k = \nabla f_i(\varphi_i^k), \quad \bar{g}_k = \frac{1}{N} \sum_{i=1}^N g_i^k. \quad (11.3)$$

Dengan  $x \in \mathbb{R}^n$ , tabel lengkap mempunyai  $N$  kolom gradien di  $\mathbb{R}^n$ . Ambil indeks acak  $J_k \sim \text{Unif}\{1, \dots, N\}$  dan bentuk

$$v_k = \nabla f_{J_k}(x_k) - g_{J_k}^k + \bar{g}_k. \quad (11.4)$$

Pembaruan SAGA tanpa suku proksimal adalah

$$x_{k+1} = x_k - t_k v_k. \quad (11.5)$$

Sesudah  $v_k$  dihitung dari tabel lama, hanya kolom terpilih yang disegarkan:

$$g_i^{k+1} = \begin{cases} \nabla f_i(x_k), & i = J_k, \\ g_i^k, & i \neq J_k, \end{cases} \quad \varphi_i^{k+1} = \begin{cases} x_k, & i = J_k, \\ \varphi_i^k, & i \neq J_k. \end{cases} \quad (11.6)$$

Ini menuliskan secara eksplisit inisialisasi dan urutan pembaruan yang hanya tersirat pada donor. Suku  $-g_{J_k}^k + \bar{g}_k$  merupakan peubah kontrol (*control variate*). Donor juga menyebut SAG dan SVRG; keduanya adalah metode reduksi varians lain, tetapi algoritmanya tidak diimpor dari bagian di luar rentang beku.

### 11.2 Mengapa koreksi tabel mengurangi varians

**Penghubung mandiri.**

Ambil  $\mathcal{F}_k$  sebagai informasi sebelum  $J_k$  ditarik, sehingga  $x_k$  dan seluruh tabel tetap ketika ekspektasi bersyarat dihitung.

**Proposisi 11.1** (Takbias bersyarat). Penaksir (11.4) memenuhi

$$\mathbb{E}[v_k \mid \mathcal{F}_k] = \nabla f(x_k). \quad (11.7)$$

*Bukti.* Keseragaman  $J_k$  memberi

$$\begin{aligned}\mathbb{E}[v_k \mid \mathcal{F}_k] &= \frac{1}{N} \sum_{i=1}^N (\nabla f_i(x_k) - g_i^k + \bar{g}_k) \\ &= \nabla f(x_k) - \bar{g}_k + \bar{g}_k = \nabla f(x_k).\end{aligned}$$

□

Lebih tepat lagi, tuliskan  $a_i^k = \nabla f_i(x_k) - g_i^k$  dan  $\bar{a}_k = N^{-1} \sum_i a_i^k$ . Maka

$$\mathbb{E}[\|v_k - \nabla f(x_k)\|_2^2 \mid \mathcal{F}_k] = \frac{1}{N} \sum_{i=1}^N \|a_i^k - \bar{a}_k\|_2^2 \leq \frac{1}{N} \sum_{i=1}^N \|a_i^k\|_2^2. \quad (11.8)$$

Identitas ini memperlihatkan mekanismenya: ketika gradien tersimpan mendekati gradien komponen pada iterat sekarang, ruas kanan menyusut meskipun langkah  $t_k$  tidak dipaksa menuju nol. Berbeda dari SAG, koreksi SAGA pada (11.4) membuat arah langkah takbias. SVRG mencapai gagasan serupa dengan gradien penuh pada titik acuan berkala, sehingga tidak menyimpan seluruh tabel gradien tetapi memakai evaluasi gradien tambahan.

### 11.3 Laju konvergensi dan iterat rata-rata

Pernyataan donor “untuk  $t$  yang sesuai, metode ini konvergen secara linear” memerlukan hipotesis. Bentuk berikut adalah spesialisasi nonkomposit dari hasil SAGA oleh Defazio, Bach, dan Lacoste-Julien (2014).

**Teorema 11.2** (Laju linear SAGA dengan kekonveksan kuat). *Andaikan setiap  $f_i$  konveks, terdiferensial, dan mempunyai gradien  $L$ -Lipschitz. Andaikan pula  $f$  pada (11.1)  $\mu$ -konveks kuat dan mempunyai peminimum  $x^*$ . Jika seluruh titik tabel diinisialisasi pada  $x_0$  dan  $t_k = t = 1/(3L)$ , maka*

$$\mathbb{E}\|x_k - x^*\|_2^2 \leq \left(1 - \min\left\{\frac{1}{4N}, \frac{\mu}{3L}\right\}\right)^k C_0, \quad (11.9)$$

dengan

$$C_0 = \|x_0 - x^*\|_2^2 + \frac{2N}{3L} (f(x_0) - f(x^*)). \quad (11.10)$$

Konstanta dan laju pada teorema tersebut mengikuti hasil adaptivitas terhadap kekonveksan kuat dalam Defazio, Bach, dan Lacoste-Julien, SAGA (2014). Teorema donor tanpa hipotesis tidak dipertahankan sebagai klaim universal: tanpa kemulusan dan struktur konveks yang sesuai, laju linear tidak mengikuti hanya dari bentuk pembaruan.

Jika  $f$  hanya konveks, definisikan iterat rata-rata secara tidak ambigu sebagai

$$\bar{x}_k = \frac{1}{k} \sum_{r=1}^k x_r. \quad (11.11)$$

Di bawah asumsi konveks dan  $L$ -mulus di atas, dengan  $t = 1/(3L)$ , hasil yang sama memberi batas

$$\mathbb{E}[f(\bar{x}_k)] - f(x^*) \leq \frac{4N}{k} \left[ \frac{2L}{N} \|x_0 - x^*\|_2^2 + f(x_0) - f(x^*) \right]. \quad (11.12)$$

Jadi perataan bukan jaminan tanpa syarat untuk laju yang lebih baik; dalam rezim konveks yang dinyatakan, ia menyediakan jaminan sublinear  $O(1/k)$  untuk nilai fungsi.

## 11.4 Latihan dengan petunjuk dan solusi

Latihan berikut merupakan materi baru untuk edisi ini; tidak ada latihan, petunjuk, atau solusi pada rentang donor.

**Latihan 11.3** (Takbias dan identitas varians). Dengan  $a_i^k = \nabla f_i(x_k) - g_i^k$ , buktikan Proposisi 11.1 dan identitas (11.8). Jelaskan kapan varians bersyaratnya sama dengan nol.

**Petunjuk.** Gunakan  $v_k - \nabla f(x_k) = a_{J_k}^k - \bar{a}_k$  dan kembangkan kuadratnya.

**Solusi lengkap.** Keseragaman indeks memberi  $\mathbb{E}[a_{J_k}^k \mid \mathcal{F}_k] = \bar{a}_k$ , sehingga selisih tersebut bermean nol. Selanjutnya,

$$\begin{aligned} \mathbb{E}\|a_{J_k}^k - \bar{a}_k\|_2^2 &= \frac{1}{N} \sum_i \left( \|a_i^k\|_2^2 - 2 \langle a_i^k, \bar{a}_k \rangle + \|\bar{a}_k\|_2^2 \right) \\ &= \frac{1}{N} \sum_i \|a_i^k\|_2^2 - \|\bar{a}_k\|_2^2, \end{aligned}$$

yang sama dengan ruas tengah (11.8) dan tidak melebihi ruas kanannya. Variansnya nol tepat ketika semua  $a_i^k$  sama; khususnya, nol jika  $g_i^k = \nabla f_i(x_k)$  untuk semua  $i$ .

**Latihan 11.4** (Satu langkah kuadratik). Ambil  $N = 2$ ,  $f_1(x) = \frac{1}{2}(x-1)^2$ ,  $f_2(x) = \frac{1}{2}(x+1)^2$ ,  $x_k = 2$ ,  $\varphi_1^k = 0$ , dan  $\varphi_2^k = 1$ . Hitung dua nilai mungkin bagi  $v_k$ , ekspektasi dan variansnya, lalu bandingkan dengan gradien stokastik biasa  $\nabla f_{J_k}(x_k)$ . Untuk  $t_k = 0,1$ , hitung pula dua iterat berikutnya.

**Petunjuk.**  $g_1^k = -1$ ,  $g_2^k = 2$ , dan  $\bar{g}_k = 1/2$ .

**Solusi lengkap.** Pada  $x_k = 2$ , gradien komponen adalah 1 dan 3. Oleh karena itu  $v_k = 1 - (-1) + 1/2 = 5/2$  jika  $J_k = 1$ , sedangkan  $v_k = 3 - 2 + 1/2 = 3/2$  jika  $J_k = 2$ . Maka  $\mathbb{E}[v_k] = 2 = \nabla f(2)$  dan  $\text{Var}(v_k) = \frac{1}{2}[(1/2)^2 + (-1/2)^2] = 1/4$ . Penaksir SGD biasa bernilai 1 atau 3, sehingga mean-nya juga 2 tetapi variansnya 1. Dengan  $t_k = 0,1$ , SAGA menghasilkan  $x_{k+1} = 1,75$  atau  $x_{k+1} = 1,85$ .

**Bagian III**

**Metode Stokastik Komposit**

## Bab 12

# Metode Stokastik Komposit, Cermin, dan Minibatch

Bab ini mengisi penghubung yang belum tersedia di tulang punggung Habring dan tiga modul Becker yang telah diterima. Habring telah mengembangkan operator proksimal, gradien proksimal deterministik, dan subgradien stokastik terproyeksi. Modul Becker 3 telah membuktikan ketakbiasan penaksir SAGA dan identitas varians tabelnya. Yang masih diperlukan ialah satu kerangka yang menjelaskan bagaimana operator proksimal, geometri non-Euklides, pengambilan sampel minibatch, dan reduksi varians saling terhubung.

Seluruh rumusan, bukti penghubung, latihan, petunjuk, solusi, dan laboratorium dalam bab ini ditulis secara mandiri. Catatan Habring, catatan gradien stokastik Clément W. Royer, modul Becker 3, serta rujukan penelitian pada akhir bab dipakai untuk memeriksa istilah, batas teori, dan konteks; tidak ada prosa, tata letak, gambar, atau kode mereka yang disalin.

Kita memakai norma  $\|\cdot\|$  pada ruang berdimensi hingga dan norma dual

$$\|y\|_* = \sup_{\|x\| \leq 1} \langle y, x \rangle. \quad (12.1)$$

Untuk bagian proksimal dan minibatch, norma tersebut adalah norma Euklides. Filtrasi  $\mathcal{F}_k$  memuat seluruh informasi sebelum oracle pada iterasi  $k$  dipanggil. Dengan demikian,  $x_k$  terukur terhadap  $\mathcal{F}_k$ .

### 12.1 Masalah komposit dan oracle stokastik

Pertimbangkan masalah komposit

$$\min_{x \in \mathbb{R}^d} F(x), \quad F(x) = f(x) + g(x), \quad (12.2)$$

dengan  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  konveks, terdiferensialkan, dan mempunyai gradien  $L$ -Lipschitz, sedangkan  $g : \mathbb{R}^d \rightarrow (-\infty, +\infty]$  proper, konveks, dan semikontinu bawah. Andaikan himpunan peminim  $X^* = \arg \min F$  tidak kosong.

Oracle pada  $x_k$  mengembalikan  $G_k$  dan memenuhi, hampir pasti,

$$\mathbb{E}[G_k \mid \mathcal{F}_k] = \nabla f(x_k), \quad \mathbb{E}[\|G_k - \nabla f(x_k)\|^2 \mid \mathcal{F}_k] \leq v_k^2. \quad (12.3)$$

Besaran  $v_k^2$  boleh berubah sepanjang iterasi. Notasi ini sengaja memisahkan varians oracle dari konstanta kemulusan  $L$  dan dari fungsi kerugian  $\ell$  pada model statistik.

### 12.2 Gradien proksimal stokastik

Dengan ukuran langkah  $\tau_k > 0$ , pembaruan gradien proksimal stokastik ialah

$$x_{k+1} = \text{prox}_{\tau_k g}(x_k - \tau_k G_k). \quad (12.4)$$

Jika  $g = \delta_C$  adalah fungsi indikator himpunan konveks tertutup  $C$ , pembaruan ini menjadi proyeksi stokastik. Jika  $g(x) = \lambda\|x\|_1$ , pembaruan ini menjadi ambang lunak setelah langkah gradien stokastik.

**Algoritma 1: gradien proksimal stokastik.** Pilih  $x_0 \in \text{dom } g$ . Untuk  $k = 0, 1, \dots$ , panggil oracle pada  $x_k$  untuk memperoleh  $G_k$ , pilih  $\tau_k$ , lalu hitung (12.4). Untuk pelaporan ergodik, simpan rerata iterat yang disebutkan dalam teorema berikut.

**Lema 12.1** (Ketaksamaan satu langkah). *Ambil  $x \in \text{dom } g$  dan tetapkan  $\tau_k = \tau$  dengan  $0 < \tau \leq (2L)^{-1}$ . Di bawah (12.3), iterasi (12.4) memenuhi*

$$\mathbb{E}[F(x_{k+1}) - F(x) \mid \mathcal{F}_k] \leq \frac{\|x_k - x\|^2 - \mathbb{E}[\|x_{k+1} - x\|^2 \mid \mathcal{F}_k]}{2\tau} + \tau v_k^2. \quad (12.5)$$

*Bukti.* Tuliskan  $x^+ = x_{k+1}$ ,  $s = x^+ - x_k$ , dan  $\delta_k = G_k - \nabla f(x_k)$ . Kondisi optimalitas proks memberikan

$$\frac{x_k - x^+}{\tau} - G_k \in \partial g(x^+). \quad (12.6)$$

Ketaksamaan subgradien untuk  $g$ , kekonveksan  $f$ , dan lemma penurunan untuk  $f$  yang  $L$ -mulus menghasilkan

$$F(x^+) - F(x) \leq \frac{\|x_k - x\|^2 - \|x^+ - x\|^2}{2\tau} - \frac{1 - L\tau}{2\tau} \|s\|^2 - \langle \delta_k, x^+ - x \rangle. \quad (12.7)$$

Pecah suku terakhir sebagai  $-\langle \delta_k, s \rangle - \langle \delta_k, x_k - x \rangle$ . Karena  $x_k - x$  terukur terhadap  $\mathcal{F}_k$  dan  $\mathbb{E}[\delta_k \mid \mathcal{F}_k] = 0$ , suku kedua hilang dalam ekspektasi bersyarat. Untuk suku pertama, maksimisasi kuadrat atau ketaksamaan Young memberi

$$-\langle \delta_k, s \rangle - \frac{1 - L\tau}{2\tau} \|s\|^2 \leq \frac{\tau}{2(1 - L\tau)} \|\delta_k\|^2 \leq \tau \|\delta_k\|^2, \quad (12.8)$$

dengan ketaksamaan terakhir menggunakan  $\tau L \leq 1/2$ . Mengambil ekspektasi bersyarat membuktikan klaim.  $\square$

**Teorema 12.2** (Batas ergodik proksimal stokastik). *Andaikan  $v_k^2 \leq \sigma^2/b$  untuk semua  $k$ , dengan  $b \geq 1$ . Ambil  $x^* \in X^*$ ,  $0 < \tau \leq (2L)^{-1}$ , dan definisikan*

$$\bar{x}_K = \frac{1}{K} \sum_{k=0}^{K-1} x_{k+1}. \quad (12.9)$$

*Maka, untuk  $K \geq 1$ ,*

$$\mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau \sigma^2}{b}. \quad (12.10)$$

*Bukti.* Terapkan Lema 12.1 dengan  $x = x^*$ , ambil ekspektasi penuh, lalu jumlahkan untuk  $k = 0, \dots, K-1$ . Suku jarak meneleskop dan suku terakhir yang tidak negatif dapat dibuang. Kekonveksan  $F$  memberi  $F(\bar{x}_K) \leq K^{-1} \sum_{k=0}^{K-1} F(x_{k+1})$ , yang menyelesaikan bukti.  $\square$

Jika  $R = \|x_0 - x^*\| > 0$ ,  $\sigma > 0$ , dan batas kemulusan tidak aktif, pilihan yang menyeimbangkan kedua suku pada (12.10) ialah

$$\tau = R \sqrt{\frac{b}{2\sigma^2 K}}, \quad \mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\sqrt{2} R \sigma}{\sqrt{b K}}. \quad (12.11)$$

Dalam praktik,  $R$  dan  $\sigma$  biasanya tidak diketahui. Rumus ini adalah penjelas skala, bukan resep penalaan tanpa diagnosis.

### 12.3 Minibatch: identitas varians dan biaya oracle

Ambil  $b$  sampel bersyarat iid  $G_{k,1}, \dots, G_{k,b}$  dengan rerata  $\nabla f(x_k)$  dan varians kuadrat paling besar  $\sigma^2$ . Penaksir minibatch dengan penggantian adalah

$$\widehat{G}_k^{(b)} = \frac{1}{b} \sum_{j=1}^b G_{k,j}. \quad (12.12)$$

**Proposisi 12.3** (Penyusutan varians dengan penggantian). Penaksir (12.12) tak bias dan memenuhi

$$\mathbb{E} \left[ \|\widehat{G}_k^{(b)} - \nabla f(x_k)\|^2 \mid \mathcal{F}_k \right] \leq \frac{\sigma^2}{b}. \quad (12.13)$$

*Bukti.* Setelah dikondisikan pada  $\mathcal{F}_k$ , simpangan setiap sampel mempunyai rerata nol dan pasangan simpangan yang berbeda saling bebas. Semua suku silang dalam kuadrat norma mempunyai ekspektasi nol. Tersisa  $b$  suku diagonal yang masing-masing dikalikan  $b^{-2}$ .  $\square$

Untuk jumlah hingga  $f = N^{-1} \sum_{i=1}^N f_i$ , pengambilan sampel tanpa penggantian mempunyai koreksi populasi hingga yang tidak boleh disamakan dengan rumus iid.

**Proposisi 12.4** (Koreksi populasi hingga). Andaikan  $N \geq 2$  dan  $1 \leq b \leq N$ . Pada suatu  $x$ , tuliskan  $h_i = \nabla f_i(x) - \nabla f(x)$  dan  $V_N = N^{-1} \sum_{i=1}^N \|h_i\|^2$ . Jika  $S$  dipilih seragam dari semua subhimpunan berukuran  $b$  tanpa penggantian, maka

$$\mathbb{E} \left\| \frac{1}{b} \sum_{i \in S} \nabla f_i(x) - \nabla f(x) \right\|^2 = \frac{N-b}{b(N-1)} V_N. \quad (12.14)$$

*Bukti.* Peluang inklusi satu indeks adalah  $b/N$  dan peluang inklusi dua indeks berbeda adalah  $b(b-1)/(N(N-1))$ . Kembangkan kuadrat norma. Karena  $\sum_i h_i = 0$ , berlaku  $\sum_{i \neq j} \langle h_i, h_j \rangle = -\sum_i \|h_i\|^2$ . Substitusi kedua peluang inklusi lalu penyederhanaan memberikan faktor pada (12.14). Khusus  $b = N$ , varians tepat nol.  $\square$

Minibatch menurunkan varians per iterasi, tetapi memakai  $b$  evaluasi gradien komponen. Jika biaya serial yang tersedia adalah  $T = bK$ , batas tertala ideal  $\sqrt{2}R\sigma/\sqrt{bK}$  menjadi  $\sqrt{2}R\sigma/\sqrt{T}$ : tidak ada percepatan kompleksitas oracle hanya dari pengelompokan. Keuntungan nyata dapat datang dari paralelisme, arsitektur perangkat, pengurangan komunikasi, atau batas langkah yang lebih baik. Pernyataan ini juga menjelaskan mengapa perbandingan hanya berdasarkan banyak iterasi dapat menyesatkan.

## 12.4 Penurunan cermin stokastik

Proyeksi Euklides memperlakukan semua arah dengan geometri yang sama. Pada simpleks, matriks semidefinit positif, atau ruang dengan struktur sparsitas, pilihan geometri lain dapat lebih alami.

Misalkan  $X \subset \mathbb{R}^d$  tak kosong, tertutup, dan konveks. Ambil fungsi pembangkit  $h : X \rightarrow \mathbb{R}$  yang bernilai hingga dan kontinu pada  $X$ , terdiferensialkan di setiap iterasi, dan  $\alpha$ -konveks kuat terhadap  $\|\cdot\|$ . Untuk setiap  $x \in X$  dan setiap titik keterdiferensialan  $y$ ,

$$h(x) \geq h(y) + \langle \nabla h(y), x - y \rangle + \frac{\alpha}{2} \|x - y\|^2. \quad (12.15)$$

Divergensi Bregman yang dibangkitkan oleh  $h$  ialah

$$D_h(x, y) = h(x) - h(y) - \langle \nabla h(y), x - y \rangle. \quad (12.16)$$

Divergensi ini tidak harus simetris dan bukan metrik, tetapi  $D_h(x, y) \geq (\alpha/2)\|x - y\|^2$ .

Untuk fungsi konveks  $\Phi : X \rightarrow \mathbb{R}$ , andaikan oracle menghasilkan  $G_k$  dengan

$$\bar{G}_k := \mathbb{E}[G_k \mid \mathcal{F}_k] \in \partial\Phi(x_k), \quad \mathbb{E}[\|G_k\|_*^2 \mid \mathcal{F}_k] \leq M^2. \quad (12.17)$$

Ambil  $\tau_k > 0$  dan andaikan masalah berikut hampir pasti mencapai peminim unik  $x_{k+1}$  pada titik keterdiferensialan  $h$ :

$$x_{k+1} = \arg \min_{x \in X} \{ \tau_k \langle G_k, x \rangle + D_h(x, x_k) \}. \quad (12.18)$$

Untuk pembandingan optimum  $x^*$  yang dipakai di bawah, andaikan pula  $D_h(x^*, x_0) < \infty$ . Asumsi eksplisit ini dapat diganti dengan syarat Legendre/interior standar yang menjamin sifat-sifat yang sama.

**Algoritma 2: penurunan cermin stokastik.** Pilih  $x_0$  dalam daerah terdiferensialkan  $h$ . Pada iterasi  $k$ , ambil subgradien stokastik  $G_k$ , selesaikan masalah Bregman (12.18), dan perbarui rerata berbobot  $\sum_j \tau_j x_j / \sum_j \tau_j$ .

**Lema 12.5** (Ketaksamaan tiga titik stokastik). Untuk setiap  $x \in X$ , pembaruan (12.18) memenuhi

$$\tau_k \langle G_k, x_k - x \rangle \leq D_h(x, x_k) - D_h(x, x_{k+1}) + \frac{\tau_k^2}{2\alpha} \|G_k\|_*^2. \quad (12.19)$$

*Bukti.* Kondisi optimalitas pada himpunan  $X$  memberi

$$\langle \tau_k G_k + \nabla h(x_{k+1}) - \nabla h(x_k), x - x_{k+1} \rangle \geq 0. \quad (12.20)$$

Identitas tiga titik Bregman mengubah bagian yang memuat  $h$  menjadi

$$\tau_k \langle G_k, x_{k+1} - x \rangle \leq D_h(x, x_k) - D_h(x, x_{k+1}) - D_h(x_{k+1}, x_k). \quad (12.21)$$

Tambahkan  $\tau_k \langle G_k, x_k - x_{k+1} \rangle$  pada kedua sisi. Gunakan  $D_h(x_{k+1}, x_k) \geq (\alpha/2) \|x_{k+1} - x_k\|^2$ , dualitas norma, dan ketaksamaan Young. Hasilnya tepat (12.19).  $\square$

**Teorema 12.6** (Batas ergodik cermin stokastik). Di bawah (12.17), untuk  $K \geq 1$  definisikan  $S_K = \sum_{k=0}^{K-1} \tau_k$  dan

$$\tilde{x}_K = \frac{1}{S_K} \sum_{k=0}^{K-1} \tau_k x_k. \quad (12.22)$$

Untuk setiap  $x^* \in \arg \min_{x \in X} \Phi(x)$ ,

$$\mathbb{E}[\Phi(\tilde{x}_K) - \Phi(x^*)] \leq \frac{D_h(x^*, x_0)}{S_K} + \frac{M^2}{2\alpha} \frac{\sum_{k=0}^{K-1} \tau_k^2}{S_K}. \quad (12.23)$$

*Bukti.* Ambil ekspektasi bersyarat pada Lema 12.5. Karena  $x_k - x^*$  terukur terhadap  $\mathcal{F}_k$  dan  $\bar{G}_k \in \partial\Phi(x_k)$ ,

$$\mathbb{E}[\langle G_k, x_k - x^* \rangle \mid \mathcal{F}_k] \geq \Phi(x_k) - \Phi(x^*). \quad (12.24)$$

Jumlahkan sehingga divergensi Bregman meneleskop, lalu gunakan kekonveksan  $\Phi$  pada rerata berbobot.  $\square$

Untuk  $M > 0$  dan  $D_h(x^*, x_0) > 0$ , gunakan  $\tau = \sqrt{2\alpha D_h(x^*, x_0)/(M^2 K)}$ . Ruas kanan kemudian menjadi

$$M \sqrt{\frac{2D_h(x^*, x_0)}{\alpha K}}. \quad (12.25)$$

Pada geometri Euklides,  $h(x) = \|x\|_2^2/2$  dan pembaruan cermin menjadi subgradien stokastik terproyeksi. Jadi metode cermin memperluas, bukan menduplikasi, teorema stokastik Habring.

### 12.4.1 Simpleks dan pembaruan eksponensial

Pada simpleks  $\Delta_d = \{x \in \mathbb{R}_+^d : \sum_{j=1}^d x_j = 1\}$ , ambil  $h(x) = \sum_j x_j \log x_j$ , dengan konvensi perluasan kontinu  $0 \log 0 = 0$ . Fungsi ini kontinu pada  $\Delta_d$  dan terdiferensialkan pada interior relatifnya. Mulai dari  $x_{0,j} > 0$ . Divergensi Bregman ialah divergensi Kullback–Leibler. Terhadap norma  $\ell_1$ , fungsi ini 1-konveks kuat. Kondisi optimalitas memberi pembaruan tertutup

$$x_{k+1,j} = \frac{x_{k,j} \exp(-\tau_k G_{k,j})}{\sum_{r=1}^d x_{k,r} \exp(-\tau_k G_{k,r})}. \quad (12.26)$$

Jika  $x_0$  seragam, maka  $D_h(x^*, x_0) \leq \log d$ . Dengan batas  $\|G_k\|_\infty \leq M$ , Teorema 12.6 memberi skala  $M\sqrt{2 \log(d)/K}$  setelah penalaan ideal. Ketergantungan logaritmik pada dimensi menjelaskan kegunaan geometri entropi di simpleks.

## 12.5 Dari SAGA ke pembaruan proksimal

Untuk masalah jumlah hingga  $f = N^{-1} \sum_i f_i$ , modul Becker 3 mendefinisikan penaksir SAGA

$$v_k = \nabla f_{j_k}(x_k) - g_{j_k}^k + \bar{g}_k \quad (12.27)$$

dan membuktikan  $\mathbb{E}[v_k \mid \mathcal{F}_k] = \nabla f(x_k)$ . Untuk masalah komposit, perubahan algoritmik yang benar bukan mengurangi subgradien  $g$ , melainkan memakai langkah proksimal

$$x_{k+1} = \text{prox}_{\tau g}(x_k - \tau v_k). \quad (12.28)$$

**Korolari 12.7** (Penghubung varians untuk Prox-SAGA). *Andaikan asumsi masalah komposit berlaku,  $0 < \tau \leq (2L)^{-1}$ , dan definisikan*

$$\omega_k^2 = \mathbb{E}[\|v_k - \nabla f(x_k)\|^2 \mid \mathcal{F}_k]. \quad (12.29)$$

Untuk  $\bar{x}_K = K^{-1} \sum_{k=0}^{K-1} x_{k+1}$  dan  $x^* \in X^*$ ,

$$\mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau}{K} \sum_{k=0}^{K-1} \mathbb{E}[\omega_k^2]. \quad (12.30)$$

Jika  $\mathbb{E}[\omega_k^2] \leq C\rho^k$  dengan  $C \geq 0$  dan  $0 < \rho < 1$ , maka

$$\mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau C}{K(1 - \rho)}. \quad (12.31)$$

*Bukti.* Terapkan bukti Teorema 12.2 dengan  $G_k = v_k$  dan varians bersyarat  $\omega_k^2$ . Untuk klaim terakhir, gunakan jumlah deret geometri hingga yang dibatasi oleh  $(1 - \rho)^{-1}$ .  $\square$

Korolari ini menjelaskan hubungan yang hilang, tetapi sengaja tidak mengklaim bahwa varians SAGA selalu turun geometrik. Pembuktian klaim semacam itu memerlukan fungsi Lyapunov gabungan untuk galat iterat dan galat tabel. Teorema laju linear bersyarat pada modul Becker 3 menyediakan hasil khusus untuk kasus mulus dan konveks kuat; korolari di sini menunjukkan bagaimana penaksir yang sama masuk ke masalah komposit.

## 12.6 Laboratorium 1: regresi renggang dengan biaya oracle tetap

Laboratorium terbuka pada `labs/original-01/stochastic-composite-lab.py` membangun masalah regresi kuadrat dengan regularisasi  $\ell_1$ ,

$$F(x) = \frac{1}{2N} \|Ax - y\|_2^2 + \lambda \|x\|_1. \quad (12.32)$$

Skrip membandingkan gradien proksimal stokastik, minibatch dengan penggantian, dan Prox-SAGA pada anggaran evaluasi gradien komponen yang sama. Referensi numerik dihitung oleh FISTA deterministik sampai norma pemetaan gradien proksimal memenuhi toleransi yang dilaporkan.

Tugas laboratorium:

- (i) jalankan skrip tanpa mengubah benih acak dan verifikasi konfigurasi beku yang dicatat pada berkas hasil;
- (ii) bandingkan kesenjangan objektif terhadap evaluasi gradien komponen, bukan hanya terhadap iterasi;
- (iii) periksa apakah minibatch menurunkan varians arah pada checkpoint yang sama;
- (iv) ubah ukuran minibatch tetapi pertahankan anggaran oracle, lalu jelaskan perbedaan antara keuntungan statistik dan keuntungan paralel;
- (v) ganti  $\lambda$  dan ukur perubahan sparsitas serta norma pemetaan gradien proksimal;

- (vi) laporkan setiap hasil yang bertentangan dengan batas teori beserta asumsi yang mungkin tidak terpenuhi.

CSV dan JSON yang dihasilkan adalah permukaan aksesibel utama. Grafik SVG hanya merupakan bantuan visual dan tidak menjadi satu-satunya pembawa informasi.

Dengan konfigurasi beku ( $N = 320$ ,  $d = 40$ ,  $\lambda = 0,03$ , 12 epoch, dan 3.840 evaluasi gradien komponen per metode), nilai referensi FISTA adalah 0,31517396778742246 dengan norma pemetaan gradien proksimal  $1,49 \times 10^{-15}$ . Hasil terminal deterministik adalah:

| Metode                    | Kesenjangan objektif    | Norma pemetaan          | Tak nol |
|---------------------------|-------------------------|-------------------------|---------|
| Proks-SGD, $b = 1$        | $4,9169 \times 10^{-2}$ | $2,1155 \times 10^{-2}$ | 33      |
| Proks-minibatch, $b = 16$ | $2,5707 \times 10^{-3}$ | $9,8630 \times 10^{-3}$ | 10      |
| Prox-SAGA                 | $2,0444 \times 10^{-9}$ | $9,8666 \times 10^{-6}$ | 5       |

Angka tersebut adalah satu eksperimen terkontrol, bukan urutan kinerja universal. Berkas hasil JSON, CSV, dan SVG mempunyai SHA-256 berikut:

86ff701a...c447  
61a6591a...5d37  
87c772d9...2830.

Identitas lengkap dicatat dalam receipt QA.

## 12.7 Latihan, petunjuk, dan solusi lengkap

**Latihan 12.8** (Pembaruan proksimal untuk Lasso). Untuk  $f(x) = (2N)^{-1} \|Ax - y\|_2^2$  dan  $g(x) = \lambda \|x\|_1$ , tuliskan pembaruan (12.4) ketika minibatch  $S_k$  dipakai. Tunjukkan bahwa setiap koordinat diperoleh dengan ambang lunak.

**Petunjuk bertahap.** (i) Hitung gradien setiap suku kuadrat. (ii) Gunakan keterpisahan norma  $\ell_1$ . (iii) Selesaikan masalah proksimal skalar pada tiga kasus tanda.

**Solusi lengkap.** Jika  $f_i(x) = \frac{1}{2}(a_i^\top x - y_i)^2$ , maka

$$G_k = \frac{1}{|S_k|} \sum_{i \in S_k} a_i(a_i^\top x_k - y_i). \quad (12.33)$$

Tuliskan  $z_k = x_k - \tau_k G_k$ . Karena  $\text{prox}_{\tau_k \lambda \|\cdot\|_1}$  terpisah per koordinat,

$$(x_{k+1})_j = \text{sign}((z_k)_j) \max\{|(z_k)_j| - \tau_k \lambda, 0\}. \quad (12.34)$$

Rumus ini mengikuti dengan memeriksa kondisi  $0 \in u - z + \tau_k \lambda \partial|u|$  pada  $u > 0$ ,  $u < 0$ , dan  $u = 0$ .

**Latihan 12.9** (Konstanta pada ketaksamaan satu langkah). Mulai dari (12.7). Buktikan batas yang lebih tajam

$$\mathbb{E}[F(x_{k+1}) - F(x) \mid \mathcal{F}_k] \leq \frac{\|x_k - x\|^2 - \mathbb{E}\|x_{k+1} - x\|^2}{2\tau} + \frac{\tau v_k^2}{2(1 - L\tau)} \quad (12.35)$$

untuk  $0 < \tau < L^{-1}$ .

**Petunjuk bertahap.** (i) Maksimalkan  $-\langle \delta, s \rangle - c\|s\|^2$  terhadap  $s$ . (ii) Ambil  $c = (1 - L\tau)/(2\tau)$ . (iii) Gunakan ketakbiasan hanya setelah memisahkan  $x_k - x$ .

**Solusi lengkap.** Dualitas norma Euklides dan pelengkapan kuadrat memberikan

$$\sup_s \{-\langle \delta, s \rangle - c\|s\|^2\} = \frac{\|\delta\|^2}{4c} = \frac{\tau\|\delta\|^2}{2(1 - L\tau)}. \quad (12.36)$$

Suku  $-\langle \delta_k, x_k - x \rangle$  mempunyai ekspektasi bersyarat nol. Substitusi batas varians menyelesaikan klaim. Lema utama memakai  $\tau L \leq 1/2$  hanya untuk mengganti faktor ini dengan batas sederhana  $\tau v_k^2$ .

**Latihan 12.10** (Sampel tanpa penggantian). Untuk  $N \geq 2$ , buktikan Proposisi 12.4 dengan peubah indikator  $I_i = \mathbb{1}\{i \in S\}$ . Periksa kasus  $b = 1$  dan  $b = N$ .

**Petunjuk bertahap.** (i) Gunakan  $\mathbb{E}I_i = b/N$ . (ii) Untuk  $i \neq j$ , gunakan  $\mathbb{E}[I_i I_j] = b(b-1)/(N(N-1))$ . (iii) Pakai  $\sum_i h_i = 0$ .

**Solusi lengkap.** Karena  $b^{-1} \sum_{i \in S} h_i = b^{-1} \sum_i I_i h_i$ , ekspektasi kuadrat normanya adalah

$$\frac{1}{b^2} \left[ \frac{b}{N} \sum_i \|h_i\|^2 + \frac{b(b-1)}{N(N-1)} \sum_{i \neq j} \langle h_i, h_j \rangle \right]. \quad (12.37)$$

Suku silang sama dengan  $-\sum_i \|h_i\|^2$ . Koefisien akhirnya  $(N-b)/(bN(N-1))$ , dan penggantian  $\sum_i \|h_i\|^2 = NV_N$  memberi rumus yang diminta. Untuk  $b = 1$  faktor menjadi satu; untuk  $b = N$  menjadi nol.

**Latihan 12.11** (Cermin entropi pada simpleks). Turunkan (12.26) dari (12.18). Jelaskan mengapa iterat yang mulai positif tetap positif dan berjumlah satu.

**Petunjuk bertahap.** (i) Tambahkan pengali Lagrange untuk  $\sum_j x_j = 1$ . (ii) Diferensialkan terhadap setiap  $x_j$ . (iii) Gunakan kendala jumlah untuk menentukan faktor normalisasi.

**Solusi lengkap.** Dengan konvensi  $0 \log 0 = 0$  dan  $D_h(x, x_k) = \sum_j x_j \log(x_j/x_{k,j})$  pada simpleks, kondisi stasioner adalah

$$\tau_k G_{k,j} + \log(x_j/x_{k,j}) + 1 + \eta = 0. \quad (12.38)$$

Jadi  $x_j = x_{k,j} \exp(-\tau_k G_{k,j}) \exp(-1 - \eta)$ . Menjumlahkan seluruh koordinat menunjukkan bahwa faktor terakhir adalah kebalikan jumlah pada penyebut (12.26). Eksponensial dan penyebut positif mempertahankan kepositifan, sedangkan normalisasi mempertahankan jumlah satu.

**Latihan 12.12** (Anggaran oracle dan ukuran minibatch). Andaikan batas tertala ideal adalah  $\sqrt{2}R\sigma/\sqrt{bK}$  dan satu iterasi minibatch memakai  $b$  evaluasi gradien komponen. Untuk anggaran serial  $T = bK$ , tentukan ketergantungannya pada  $b$ . Sebutkan dua keadaan ketika minibatch tetap berguna.

**Petunjuk bertahap.** (i) Ganti  $K$  dengan  $T/b$ . (ii) Bedakan waktu dinding dari jumlah panggilan oracle. (iii) Perhatikan pengambilan sampel tanpa penggantian.

**Solusi lengkap.** Substitusi memberi

$$\frac{\sqrt{2}R\sigma}{\sqrt{b(T/b)}} = \frac{\sqrt{2}R\sigma}{\sqrt{T}}, \quad (12.39)$$

yang bebas dari  $b$ . Jadi model ideal tidak memprediksi penghematan evaluasi gradien serial. Minibatch tetap berguna jika evaluasi dapat diparalelkan atau komunikasi dapat diamortisasi; ia juga dapat membantu melalui koreksi populasi hingga tanpa penggantian, vektorisasi perangkat, atau batas langkah yang tidak tercakup dalam model sederhana.

**Latihan 12.13** (Varians yang menyusut pada Prox-SAGA). Mulai dari (12.30). Jika  $\mathbb{E}\omega_k^2 \leq C/(k+1)$ , turunkan batas eksplisit menggunakan bilangan harmonik  $H_K = \sum_{j=1}^K j^{-1}$ . Bandingkan dengan kasus geometrik.

**Petunjuk bertahap.** (i) Jumlahkan batas varians. (ii) Gunakan  $H_K \leq 1 + \log K$ . (iii) Jangan menyimpulkan laju iterat terakhir dari batas ergodik.

**Solusi lengkap.** Substitusi langsung memberi

$$\mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau C H_K}{K} \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau C(1 + \log K)}{K}. \quad (12.40)$$

Peluruhan geometrik menjadikan jumlah varians terbatas secara seragam dan menghasilkan  $O(1/K)$  tanpa faktor logaritmik. Kedua kesimpulan hanya berlaku untuk rerata  $\bar{x}_K$  dalam korolari ini; laju iterat terakhir memerlukan analisis tambahan.

## 12.8 Peta asumsi dan batas klaim

| Hasil                       | Asumsi penentu                                                                                                 | Yang tidak diklaim                               |
|-----------------------------|----------------------------------------------------------------------------------------------------------------|--------------------------------------------------|
| Proksimal stokastik         | $f$ konveks dan $L$ -mulus; $g$ proper, tertutup, konveks; oracle tak bias; varians terbatas                   | laju iterat terakhir atau konvergensi nonkonveks |
| Minibatch iid               | sampel bersyarat bebas dengan penggantian                                                                      | koreksi populasi hingga                          |
| Minibatch tanpa penggantian | subhimpunan seragam berukuran $1 \leq b \leq N$ dari populasi dengan $N \geq 2$                                | independensi antaranggota batch                  |
| Cermin stokastik            | pembangkit $\alpha$ -konveks kuat; pembaruan terdefinisi; $D_h(x^*, x_0) < \infty$ ; momen dual kedua terbatas | simetri divergensi Bregman                       |
| Prox-SAGA penghubung        | ketakbiasan SAGA dan kontrol varians yang dinyatakan                                                           | peluruhan geometrik varians tanpa Lyapunov       |

Bab ini tidak membahas ketaksamaan variasional atau operator monoton maksimal; materi tersebut adalah tranche asli berikutnya. Bab ini juga tidak mengulang LP/MIP, simpleks sebagai algoritma pemrograman linear, dualitas LP, sensitivitas LP, jaringan, atau optimisasi diskret yang merupakan cakupan O018. Kata *simpleks* di sini hanya menunjuk himpunan probabilitas  $\Delta_d$ .

## Rujukan matematis dan saksi verifikasi

- Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, khususnya operator proksimal dan subgradien stokastik.
- Clément W. Royer, *Lecture Notes on Stochastic Gradient Methods*, edisi 2023/2024, khususnya pembahasan minibatch dan biaya epoch; dipakai sebagai saksi perbandingan, bukan sumber prosa bab ini.
- Lorenzo Rosasco, Silvia Villa, dan Bang Côm Vũ, *Convergence of Stochastic Proximal Gradient Algorithm*, arXiv:1403.5074, sebagai rujukan primer bagi keluarga metode proksimal stokastik.
- Amir Beck dan Marc Teboulle, *Mirror Descent and Nonlinear Projected Subgradient Methods for Convex Optimization*, *Operations Research Letters* 31 (2003), 167–175, DOI:10.1016/S0167-6377(02)00231-6.
- Aaron Defazio, Francis Bach, dan Simon Lacoste-Julien, *SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives*, arXiv:1407.0202v3.

## **Bagian IV**

# **Suplemen Terbatas: Douglas–Rachford**

## Bab 13

# Pemisahan Douglas–Rachford

Bab ini menyajikan metode Douglas–Rachford untuk meminimumkan jumlah dua fungsi konveks melalui operator proksimal. Notasi subdiferensial dan bentuk dual dinormalkan agar persamaan konsisten dengan parameter skala yang dipakai dalam algoritma.

### Kredit catatan donor.

Catatan donor menyatakan bahwa bagian ini mengikuti Bauschke dan Combettes (B&C), edisi kedua (2017), §20.3, dan mengatribusi analisis Douglas–Rachford kepada Lions dan Mercier (1979). Kredit turunan tersebut dipertahankan; edisi ini tidak mengimpor isi dari bagian yang bersebelahan.

Ambil  $f, g \in \Gamma_0(\mathbb{R}^n)$ , yaitu fungsi konveks proper dan semikontinu bawah. Seperti pada donor, andaikan terdapat titik pelana primal–dual dan aturan jumlah subdiferensial

$$\partial(f + g) = \partial f + \partial g \quad (13.1)$$

berlaku. Masalah primal adalah

$$(P) \quad p^* = \min_{x \in \mathbb{R}^n} \{f(x) + g(x)\}. \quad (13.2)$$

Dengan konjugat Fenchel  $h^*(u) = \sup_x \{\langle u, x \rangle - h(x)\}$ , bentuk maksimisasi dual yang konsisten adalah

$$(D) \quad d^* = \sup_{u \in \mathbb{R}^n} \{-f^*(-u) - g^*(u)\}. \quad (13.3)$$

Secara ekuivalen, titik dual yang sama meminimumkan  $f^*(-u) + g^*(u)$ . Tanda pada bentuk dual donor diperbaiki secara terbuka dalam edisi ini.

Untuk  $h \in \Gamma_0(\mathbb{R}^n)$  dan  $\rho > 0$ , tuliskan

$$\text{prox}_{\rho h}(v) = \arg \min_{w \in \mathbb{R}^n} \left\{ h(w) + \frac{1}{2\rho} \|w - v\|_2^2 \right\} = (I + \rho \partial h)^{-1}(v). \quad (13.4)$$

Pilih  $y_0 \in \mathbb{R}^n$ , parameter skala  $\rho > 0$ , dan parameter relaksasi tetap  $\lambda \in (0, 2)$ . Iterasi Douglas–Rachford adalah

$$\begin{aligned} x_k &= \text{prox}_{\rho g}(y_k), \\ z_k &= \text{prox}_{\rho f}(2x_k - y_k), \\ y_{k+1} &= y_k + \lambda(z_k - x_k). \end{aligned} \quad (13.5)$$

Catatan donor memperingatkan bahwa konvensi untuk  $\rho$  pada bagian lain mungkin memakai kebalikannya. Di sini  $\rho$  selalu memiliki arti yang ditetapkan oleh (13.4).

### 13.1 Limit bayangan dan persamaan titik tetap

**Teorema 13.1** (Limit bayangan merupakan solusi primal). *Jika barisan pada (13.5) memenuhi  $y_k \rightarrow \bar{y}$  dan*

$$\bar{x} = \text{prox}_{\rho g}(\bar{y}), \quad (13.6)$$

*maka  $\bar{x}$  adalah solusi optimal masalah (13.2).*

*Bukti.* Karena  $y_k$  konvergen,  $y_{k+1} - y_k = \lambda(z_k - x_k) \rightarrow 0$ , sehingga  $z_k - x_k \rightarrow 0$ . Operator proksimal kontinu, maka

$$\bar{x} = \text{prox}_{\rho g}(\bar{y}), \quad \bar{x} = \text{prox}_{\rho f}(2\bar{x} - \bar{y}). \quad (13.7)$$

Syarat optimalitas kedua operator proksimal memberi

$$\frac{\bar{y} - \bar{x}}{\rho} \in \partial g(\bar{x}), \quad \frac{\bar{x} - \bar{y}}{\rho} \in \partial f(\bar{x}). \quad (13.8)$$

Menjumlahkan kedua inklusi dan memakai aturan (13.1) menghasilkan  $0 \in \partial(f + g)(\bar{x})$ , yang setara dengan optimalitas primal.  $\square$

Persamaan titik tetapnya dapat dilihat langsung dari syarat optimalitas. Untuk solusi primal  $x$ , pilih  $u \in \partial g(x)$  dengan  $-u \in \partial f(x)$ , lalu definisikan  $y = x + \rho u$ . Dengan demikian

$$\begin{aligned} y &\in x + \rho \partial g(x), & x &= (I + \rho \partial g)^{-1}(y) = \text{prox}_{\rho g}(y), \\ 2x - y &= x - \rho u \in x + \rho \partial f(x), & x &= (I + \rho \partial f)^{-1}(2x - y) = \text{prox}_{\rho f}(2x - y). \end{aligned} \quad (13.9)$$

Jadi, dengan

$$x = \text{prox}_{\rho g}(y), \quad z = \text{prox}_{\rho f}(2x - y), \quad (13.10)$$

syarat solusi menjadi  $z - x = 0$ . Pembaruan  $y \leftarrow y + \lambda(z - x)$  pada (13.5) merupakan iterasi relaksasi menuju titik tetap itu. Faktor  $\rho$  dan pilihan subgradien  $u$  ditulis eksplisit karena subdiferensial pada umumnya bernilai himpunan dan tidak dapat diperlakukan sebagai satu vektor  $dg(x)$ .

## 13.2 Hubungan dengan ADMM

Pernyataan singkat donor bahwa ADMM merupakan kasus khusus Douglas–Rachford dipahami dalam bentuk yang lazim dan lebih presisi: ADMM dapat diperoleh sebagai pemisahan Douglas–Rachford yang diterapkan pada masalah dual yang sesuai. Bagian ADMM yang mendahului rentang beku tidak diimpor ke modul ini.

## **Bagian V**

# **Operator Monoton dan Pemisahan**

## Bab 14

# Ketaksamaan Variasional, Operator Monoton, Resolven, dan Pemisahan

Bab sebelumnya menghubungkan metode proksimal dengan oracle stokastik, minibatch, geometri Bregman, dan reduksi varians. Bab ini mengambil langkah abstraksi berikutnya: kondisi optimalitas diperlakukan sebagai pencarian nol operator bernilai himpunan. Kerangka ini menyatukan ketaksamaan variasional, subdiferensial, kerucut normal, langkah proksimal implisit, pemisahan maju-mundur, dan pemisahan Douglas-Rachford.

Seluruh uraian, bukti penghubung, latihan, solusi, dan laboratorium dalam bab ini ditulis secara mandiri. Bab Habring tentang subgradien dan metode gradien proksimal serta modul Becker tentang Douglas-Rachford dipakai sebagai prasyarat dan saksi konsistensi. Tidak ada prosa, tata letak, gambar, latihan, solusi, atau kode dari sumber tersebut yang disalin.

Untuk operator bernilai himpunan  $A : \mathbb{R}^d \rightrightarrows \mathbb{R}^d$ , definisikan

$$\text{graph } A = \{(x, u) : u \in Ax\}, \quad \text{dom } A = \{x : Ax \neq \emptyset\}, \quad \text{zer } A = \{x : 0 \in Ax\}. \quad (14.1)$$

Notasi  $Ax$  menekankan bahwa nilai operator dapat berupa himpunan, bukan satu vektor. Masalah dasar bab ini ialah

$$\text{cari } x^* \in \mathbb{R}^d \text{ sehingga } 0 \in (A + B)x^*. \quad (14.2)$$

### 14.1 Kemonotonan dan kemaksimalan

**Definisi 14.1** (Operator monoton dan monoton kuat). Operator  $A : \mathbb{R}^d \rightrightarrows \mathbb{R}^d$  disebut *monoton* jika

$$\langle u - v, x - y \rangle \geq 0 \quad \text{untuk semua } (x, u), (y, v) \in \text{graph } A. \quad (14.3)$$

Ia disebut  $\mu$ -monoton kuat, dengan  $\mu > 0$ , jika ruas kanan dapat diganti oleh  $\mu\|x - y\|^2$ .

**Definisi 14.2** (Operator monoton maksimal). Operator monoton  $A$  disebut *monoton maksimal* jika tidak ada operator monoton lain yang grafiknya memuat  $\text{graph } A$  secara ketat. Kata *maksimal* merujuk pada inklusi grafik, bukan pada nilai fungsi atau ukuran norma.

Kemonotonan saja belum menjamin bahwa operator mempunyai cukup banyak nilai untuk mendefinisikan langkah implisit pada setiap titik. Sebagai contoh, operator dengan grafik tunggal  $\{(0, 0)\}$  monoton, tetapi tidak maksimal, karena grafik itu dapat diperluas menjadi grafik operator nol pada seluruh  $\mathbb{R}^d$ .

**Proposisi 14.3** (Subdiferensial bersifat monoton). Jika  $f : \mathbb{R}^d \rightarrow (-\infty, +\infty]$  proper dan konveks, maka  $\partial f$  monoton.

*Bukti.* Ambil  $u \in \partial f(x)$  dan  $v \in \partial f(y)$ . Ketaksamaan subgradien memberi

$$f(y) \geq f(x) + \langle u, y - x \rangle, \quad f(x) \geq f(y) + \langle v, x - y \rangle. \quad (14.4)$$

Menjumlahkan keduanya menghasilkan  $\langle u - v, x - y \rangle \geq 0$ .  $\square$

Teorema Rockafellar memperkuat hasil tersebut: jika  $f$  juga semikontinu bawah, maka  $\partial f$  monoton maksimal. Bab ini memakai teorema itu sebagai hasil dasar, bukan membuktikan kembali argumen pemisahan lengkapnya. Akibat pentingnya ialah kerucut normal dan operator proksimal masuk ke dalam kerangka yang sama.

## 14.2 Ketaksamaan variasional sebagai inklusi monoton

Untuk himpunan konveks tertutup tak kosong  $C \subseteq \mathbb{R}^d$ , kerucut normal pada  $x$  didefinisikan oleh

$$N_C(x) = \begin{cases} \{u : \langle u, y - x \rangle \leq 0 \text{ untuk semua } y \in C\}, & x \in C, \\ \emptyset, & x \notin C. \end{cases} \quad (14.5)$$

Karena  $N_C = \partial\delta_C$ , operator ini monoton maksimal.

**Definisi 14.4** (Ketaksamaan variasional). Untuk pemetaan  $F : \mathbb{R}^d \rightarrow \mathbb{R}^d$ , masalah  $VI(F, C)$  ialah mencari  $x^* \in C$  sedemikian sehingga

$$\langle F(x^*), y - x^* \rangle \geq 0 \quad \text{untuk semua } y \in C. \quad (14.6)$$

**Proposisi 14.5** (Ekuivalensi VI-inklusi). Suatu titik  $x^*$  menyelesaikan  $VI(F, C)$  jika dan hanya jika

$$0 \in F(x^*) + N_C(x^*). \quad (14.7)$$

Secara ekuivalen, untuk setiap  $\gamma > 0$ ,

$$x^* = P_C(x^* - \gamma F(x^*)). \quad (14.8)$$

*Bukti.* Menurut (14.5), inklusi  $-F(x^*) \in N_C(x^*)$  tepat berarti  $x^* \in C$  dan  $\langle -F(x^*), y - x^* \rangle \leq 0$  untuk setiap  $y \in C$ . Membalik tanda menghasilkan (14.6). Karakterisasi proyeksi  $p = P_C z \iff z - p \in N_C(p)$  dengan  $z = x^* - \gamma F(x^*)$  memberi ekuivalensi proyeksi.  $\square$

Jika  $F = \nabla f$  untuk fungsi konveks terdiferensialkan  $f$ , kondisi ini adalah kondisi optimalitas bagi  $\min_{x \in C} f(x)$ . Namun, ketaksamaan variasional lebih luas: pemetaan monoton tidak harus merupakan gradien.

**Proposisi 14.6** (Keunikan di bawah kemonotonan kuat). Jika  $F$   $\mu$ -monoton kuat pada  $C$ , maka  $VI(F, C)$  mempunyai paling banyak satu solusi.

*Bukti.* Andaikan  $x$  dan  $y$  keduanya solusi. Masukkan  $y$  ke ketaksamaan untuk  $x$  dan  $x$  ke ketaksamaan untuk  $y$ . Setelah dijumlahkan,

$$\langle F(x) - F(y), x - y \rangle \leq 0. \quad (14.9)$$

Kemonotonan kuat memberi ruas kiri sekurang-kurangnya  $\mu\|x - y\|^2$ . Jadi  $x = y$ .  $\square$

**Teorema 14.7** (Eksistensi konstruktif bagi VI monoton kuat). Andaikan  $F$   $\mu$ -monoton kuat dan  $L$ -Lipschitz pada  $C$ , dengan  $0 < \mu \leq L$ . Untuk

$$0 < \gamma < \frac{2\mu}{L^2}, \quad T_\gamma = P_C(I - \gamma F), \quad (14.10)$$

pemetaan  $T_\gamma : C \rightarrow C$  merupakan kontraksi dengan faktor

$$q = \sqrt{1 - 2\gamma\mu + \gamma^2 L^2} < 1. \quad (14.11)$$

Karena itu,  $VI(F, C)$  mempunyai tepat satu solusi  $x^*$ , dan iterasi  $x_{k+1} = T_\gamma x_k$  memenuhi  $\|x_k - x^*\| \leq q^k \|x_0 - x^*\|$ .

*Bukti.* Sifat tak ekspansif proyeksi, kemonotonan kuat, dan sifat Lipschitz memberi

$$\begin{aligned} \|T_\gamma x - T_\gamma y\|^2 &\leq \|(x - y) - \gamma(Fx - Fy)\|^2 \\ &\leq (1 - 2\gamma\mu + \gamma^2 L^2) \|x - y\|^2. \end{aligned} \quad (14.12)$$

Rentang  $\gamma$  membuat faktor kuadrat lebih kecil dari satu. Himpunan tertutup  $C$  lengkap, maka teorema titik tetap Banach memberi satu-satunya titik tetap dan konvergensi geometrik. Menurut (14.8), titik tetap itu tepat solusi VI.  $\square$

Bab ini tidak memakai *simpleks* sebagai algoritma pemrograman linear. Proyeksi, kerucut normal, dan ketaksamaan variasional di sini berada dalam analisis konveks kontinu dan tidak mengimpor LP/MIP, dualitas atau sensitivitas LP, jaringan, maupun optimisasi diskret dari O018.

### 14.3 Resolven operator monoton maksimal

Untuk  $\gamma > 0$ , definisikan resolven dan resolven terefleksi

$$J_{\gamma A} = (I + \gamma A)^{-1}, \quad R_{\gamma A} = 2J_{\gamma A} - I. \quad (14.13)$$

Secara apriori, invers tersebut dapat bernilai himpunan atau tidak terdefinisi pada sebagian titik. Untuk operator monoton  $A$ , teorema Minty menutup kedua celah itu: di ruang Euclid,  $A$  monoton maksimal jika dan hanya jika  $\text{ran}(I + \gamma A) = \mathbb{R}^d$  untuk setiap  $\gamma > 0$ .

**Teorema 14.8** (Resolven terdefinisi dan tak ekspansif kukuh). *Jika  $A$  monoton maksimal dan  $\gamma > 0$ , maka  $J_{\gamma A}$  bernilai tunggal pada seluruh  $\mathbb{R}^d$  dan*

$$\|J_{\gamma A}x - J_{\gamma A}y\|^2 \leq \langle J_{\gamma A}x - J_{\gamma A}y, x - y \rangle. \quad (14.14)$$

Akibatnya,  $J_{\gamma A}$  tak ekspansif dan  $R_{\gamma A}$  tak ekspansif.

*Bukti.* Teorema Minty memberi keberadaan pada setiap  $x$ . Ambil  $p = J_{\gamma A}x$  dan  $q = J_{\gamma A}y$ . Maka  $(x - p)/\gamma \in Ap$  dan  $(y - q)/\gamma \in Aq$ . Kemonotonan memberi

$$\langle p - q, (x - p) - (y - q) \rangle \geq 0, \quad (14.15)$$

yang sama dengan (14.14). Jika dua nilai resolven berkorespondensi dengan  $x$  yang sama, ketaksamaan itu memaksa keduanya sama, sehingga resolven bernilai tunggal. Ketaksamaan Cauchy–Schwarz memberi sifat tak ekspansif. Terakhir,

$$\begin{aligned} \|R_{\gamma A}x - R_{\gamma A}y\|^2 &= \|2(p - q) - (x - y)\|^2 \\ &= \|x - y\|^2 - 4(\langle p - q, x - y \rangle - \|p - q\|^2) \\ &\leq \|x - y\|^2. \end{aligned} \quad (14.16)$$

□

**Korolari 14.9** (Nol sebagai titik tetap). *Untuk setiap  $\gamma > 0$ ,*

$$x \in \text{zer } A \iff x = J_{\gamma A}x. \quad (14.17)$$

*Jika  $A = \partial f$ , maka  $J_{\gamma A} = \text{prox}_{\gamma f}$ ; jika  $A = N_C$ , maka  $J_{\gamma A} = P_C$ .*

*Bukti.* Ekuivalensi pertama langsung dari  $x = J_{\gamma A}x \iff x \in x + \gamma Ax$ . Dua identitas terakhir adalah kondisi optimalitas proksimal dan proyeksi. □

### 14.4 Metode titik proksimal

Metode titik proksimal menerapkan resolven secara berulang:

$$x_{k+1} = J_{\gamma A}x_k, \quad \gamma > 0. \quad (14.18)$$

Ini adalah langkah implisit karena  $(x_k - x_{k+1})/\gamma \in Ax_{k+1}$ .

**Teorema 14.10** (Penurunan Fejér dan konvergensi titik proksimal). *Andaikan  $A$  monoton maksimal dan  $Z = \text{zer } A \neq \emptyset$ . Maka untuk setiap  $z \in Z$ , iterasi (14.18) memenuhi*

$$\|x_{k+1} - z\|^2 + \|x_{k+1} - x_k\|^2 \leq \|x_k - z\|^2. \quad (14.19)$$

*Dalam dimensi hingga,  $x_k$  konvergen ke suatu titik dalam  $Z$ .*

*Bukti.* Karena  $z = J_{\gamma A}z$ , terapkan ketaksamaan (14.14) pada  $x_k$  dan  $z$ , lalu gunakan identitas

$$\|x_k - z\|^2 = \|x_k - x_{k+1}\|^2 + \|x_{k+1} - z\|^2 + 2 \langle x_k - x_{k+1}, x_{k+1} - z \rangle. \quad (14.20)$$

Hasilnya adalah (14.19). Jadi jarak ke setiap titik  $Z$  tidak membesar dan  $\sum_k \|x_{k+1} - x_k\|^2 < \infty$ .

Barisan terbatas, sehingga mempunyai titik gugus  $\bar{x}$ . Sepanjang subbarisan yang menuju  $\bar{x}$ , berlaku  $x_{k+1} \rightarrow \bar{x}$  dan  $(x_k - x_{k+1})/\gamma \rightarrow 0$ . Grafik operator monoton maksimal tertutup; karena  $(x_{k+1}, (x_k - x_{k+1})/\gamma) \in \text{graph } A$ , diperoleh  $0 \in A\bar{x}$ . Sifat Fejér terhadap  $\bar{x}$  kemudian memaksa seluruh barisan konvergen ke  $\bar{x}$ .  $\square$

Hasil ini menjelaskan kestabilan langkah implisit tanpa mengklaim bahwa  $J_{\gamma A}$  selalu mudah dihitung. Pemisahan operator berguna ketika resolven bagian-bagian operator jauh lebih sederhana daripada resolven jumlahnya.

## 14.5 Pemisahan maju–mundur

Pemetaan tunggal  $B : \mathbb{R}^d \rightarrow \mathbb{R}^d$  disebut  $\beta$ -kokorsif jika

$$\langle Bx - By, x - y \rangle \geq \beta \|Bx - By\|^2 \quad \text{untuk semua } x, y. \quad (14.21)$$

Kokorsivitas lebih kuat daripada gabungan kemonotonan dan kontinuitas Lipschitz. Gradien fungsi konveks dengan gradien  $L$ -Lipschitz bersifat  $1/L$ -kokorsif.

Untuk  $A$  monoton maksimal dan  $B$   $\beta$ -kokorsif, definisikan

$$T_{\text{FB}} = J_{\gamma A}(I - \gamma B), \quad 0 < \gamma < 2\beta. \quad (14.22)$$

**Teorema 14.11** (Titik tetap dan konvergensi maju–mundur). *Andaikan  $\text{zer}(A + B) \neq \emptyset$ . Maka*

$$x \in \text{zer}(A + B) \iff x = T_{\text{FB}}x. \quad (14.23)$$

Untuk  $0 < \gamma < 2\beta$ , iterasi  $x_{k+1} = T_{\text{FB}}x_k$  konvergen di ruang berdimensi hingga ke suatu nol  $A + B$ .

*Bukti.* Dari definisi resolven,

$$\begin{aligned} x = J_{\gamma A}(x - \gamma Bx) &\iff x - \gamma Bx \in x + \gamma Ax \\ &\iff 0 \in Ax + Bx. \end{aligned} \quad (14.24)$$

Selanjutnya, (14.21) memberi

$$\|(I - \gamma B)x - (I - \gamma B)y\|^2 \leq \|x - y\|^2 - \gamma(2\beta - \gamma)\|Bx - By\|^2. \quad (14.25)$$

Jadi langkah maju tererata untuk rentang langkah yang dinyatakan. Resolven tak ekspansif kukuh (*firmlly nonexpansive*), dan komposisinya tererata dengan parameter  $2\beta/(4\beta - \gamma) \in (0, 1)$ . Iterasi Picard pemetaan tererata dengan himpunan titik tetap tak kosong bersifat Fejér, residunya menuju nol, dan dalam dimensi hingga konvergen ke suatu titik tetap. Gunakan ekuivalensi (14.23).  $\square$

Dengan  $A = \partial g$  dan  $B = \nabla f$ , pemetaan ini tepat menjadi langkah gradien proksimal yang telah diterjemahkan dari Habring. Nilai tambah bab ini ialah batas operatornya: langkah eksplisit memerlukan struktur seperti kokorsivitas, bukan hanya kemonotonan.

### 14.5.1 Perbaikan ekstragradien untuk operator monoton Lipschitz

Untuk VI dengan  $F$  monoton dan  $L$ -Lipschitz, kokorsivitas belum tentu berlaku. Langkah proyeksi tunggal dapat diganti oleh dua evaluasi berurutan:

$$y_k = P_C(x_k - \gamma F(x_k)), \quad x_{k+1} = P_C(x_k - \gamma F(y_k)), \quad 0 < \gamma < \frac{1}{L}. \quad (14.26)$$

**Teorema 14.12** (Penurunan Fejér ekstragradien). *Jika himpunan solusi  $VI(F, C)$  tidak kosong, maka untuk setiap solusi  $x^*$ ,*

$$\|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2 - (1 - \gamma L)(\|x_k - y_k\|^2 + \|y_k - x_{k+1}\|^2). \quad (14.27)$$

*Dalam dimensi hingga,  $x_k$  konvergen ke suatu solusi VI.*

*Bukti.* Karakterisasi proyeksi untuk pembaruan kedua dan sifat solusi VI, bersama kemonotonan  $F$ , memberi

$$\|x_{k+1} - x^*\|^2 \leq \|x_k - x^*\|^2 - \|x_k - x_{k+1}\|^2 - 2\gamma \langle F(y_k), x_{k+1} - y_k \rangle. \quad (14.28)$$

Karakterisasi proyeksi untuk  $y_k$ , diuji pada  $x_{k+1} \in C$ , memberi

$$\langle x_k - y_k, x_{k+1} - y_k \rangle \leq \gamma \langle F(x_k), x_{k+1} - y_k \rangle. \quad (14.29)$$

Substitusi, sifat Lipschitz, dan  $2ab \leq a^2 + b^2$  menghasilkan

$$\begin{aligned} \|x_{k+1} - x^*\|^2 &\leq \|x_k - x^*\|^2 - \|x_k - y_k\|^2 - \|y_k - x_{k+1}\|^2 \\ &\quad + 2\gamma L \|x_k - y_k\| \|y_k - x_{k+1}\|, \end{aligned} \quad (14.30)$$

lalu (14.27). Kedua selisih berurutan menuju nol. Ambil titik gugus  $\bar{x}$  dan lewatkan ketaksamaan proyeksi pertama ke limit; diperoleh  $\langle F(\bar{x}), z - \bar{x} \rangle \geq 0$  untuk setiap  $z \in C$ . Jadi setiap titik gugus adalah solusi, dan sifat Fejér memaksa konvergensi seluruh barisan.  $\square$

## 14.6 Pemisahan Douglas–Rachford dan limit bayangan

Andaikan  $A$  dan  $B$  monoton maksimal. Definisikan

$$T_{DR} = \frac{1}{2}(I + R_{YA}R_{YB}) = I - J_{YB} + J_{YA}(2J_{YB} - I). \quad (14.31)$$

Karena kedua resolven terefleksi tak ekspansif, komposisinya tak ekspansif dan  $T_{DR}$  tak ekspansif kukuh.

**Teorema 14.13** (Titik tetap dan solusi bayangan Douglas–Rachford). *Andaikan  $\text{zer}(A + B) \neq \emptyset$ . Barisan*

$$y_{k+1} = T_{DR}y_k, \quad x_k = J_{YB}y_k, \quad (14.32)$$

*konvergen dalam dimensi hingga menuju  $\bar{y} \in \text{Fix } T_{DR}$ , dan bayangannya memenuhi  $J_{YB}\bar{y} \in \text{zer}(A + B)$ .*

*Bukti.* Jika  $y$  titik tetap, tetapkan  $x = J_{YB}y$  dan  $z = J_{YA}(2x - y)$ . Persamaan titik tetap dalam bentuk kedua (14.31) memberi  $z = x$ . Kondisi resolven lalu memberi

$$\frac{y - x}{\gamma} \in Bx, \quad \frac{x - y}{\gamma} \in Ax, \quad (14.33)$$

sehingga  $0 \in (A + B)x$ .

Sebaliknya, jika  $0 \in (A + B)x$ , pilih  $b \in Bx$  dengan  $-b \in Ax$  dan tetapkan  $y = x + \gamma b$ . Maka  $x = J_{YB}y$  dan  $x = J_{YA}(2x - y)$ , jadi  $y$  titik tetap. Himpunan titik tetap karena itu tidak kosong. Kekukuhan tak ekspansif  $T_{DR}$  dan argumen Fejér yang sama dengan metode titik proksimal memberi  $y_k \rightarrow \bar{y}$ . Kontinuitas resolven memberi  $x_k \rightarrow J_{YB}\bar{y}$ , yang merupakan nol jumlah.  $\square$

Modul Becker 2 sudah menyediakan bentuk proksimal konkret untuk  $A = \partial f$  dan  $B = \partial g$ , berikut penormalan skala serta hubungan primal–dualnya. Bagian ini tidak mengulang materi tersebut; ia menjelaskan mengapa rumus yang sama bekerja untuk operator monoton maksimal yang tidak harus merupakan subdiferensial.

## 14.7 Mengapa kemonotonan saja tidak cukup untuk langkah maju

Ambil  $\omega \neq 0$  dan operator linear

$$S = \omega \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}. \quad (14.34)$$

Karena  $\langle Sh, h \rangle = 0$  untuk semua  $h$ , operator  $S$  monoton. Ia juga monoton maksimal karena  $I + \gamma S$  invertibel untuk setiap  $\gamma > 0$ . Namun,  $S$  tidak  $\beta$ -kokorsif untuk satu pun  $\beta > 0$ : ruas kiri ketaksamaan kokorsif selalu nol, sedangkan ruas kanan positif bila  $h \neq 0$ .

Langkah maju  $x_{k+1} = (I - \gamma S)x_k$  memenuhi

$$\|x_{k+1}\|^2 = (1 + \gamma^2 \omega^2) \|x_k\|^2, \quad (14.35)$$

sehingga menjauh dari nol untuk  $x_0 \neq 0$ . Sebaliknya, langkah resolven  $x_{k+1} = J_{\gamma S} x_k$  memenuhi

$$\|x_{k+1}\| = \frac{1}{\sqrt{1 + \gamma^2 \omega^2}} \|x_k\|. \quad (14.36)$$

Contoh ini memisahkan dengan jelas tiga gagasan: monoton, Lipschitz, dan kokorsif tidak saling dapat dipertukarkan.

### Laboratorium 2: inklusi linear-skew dengan regularisasi $\ell_1$

Laboratorium pendamping mempelajari

$$0 \in Mx - b + \lambda \partial \|x\|_1, \quad M = \mu I + \omega \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}, \quad \mu > 0. \quad (14.37)$$

Bagian simetris  $\mu I$  membuat operator  $x \mapsto Mx - b$  monoton kuat, sedangkan bagian skew menjaganya di luar kelas gradien fungsi konveks biasa. Operator itu  $\beta$ -kokorsif dengan

$$\beta = \frac{\mu}{\mu^2 + \omega^2}. \quad (14.38)$$

Kode membandingkan tiga jejak: maju–mundur dengan langkah di dalam rentang  $0 < \gamma < 2\beta$ , maju–mundur dengan langkah beku di luar jaminan teorema, dan Douglas–Rachford dengan resolven linear eksak serta ambang lunak. Solusi acuan unik diperoleh dengan enumerasi sembilan pola aktif tanda  $\{-1, 0, 1\}^2$ , bukan dengan menyembunyikan jawaban di dalam algoritma. NumPy memeriksa sistem linear, residu inklusi, dan identitas resolven. Diagnostik kedua memakai operator skew murni untuk mencocokkan faktor norma eksak langkah maju, ekstragradien, dan resolven hingga galat pembulatan.

Tugas laboratorium:

- (i) Jalankan konfigurasi beku dan cocokkan ringkasan JSON serta CSV.
- (ii) Verifikasi secara numerik bahwa langkah stabil memenuhi  $\gamma < 2\beta$ , sedangkan langkah diagnostik berada di luar rentang itu.
- (iii) Periksa bahwa residu titik tetap

$$r_\gamma(x) = \|x - \text{soft}(x - \gamma(Mx - b), \gamma\lambda)\| \quad (14.39)$$

menuju nol bagi jejak yang diterima.

- (iv) Ubah  $\omega$  tanpa mengubah  $\mu$  dan jelaskan pengaruhnya pada  $\beta$  serta rentang langkah maju–mundur.
- (v) Gunakan CSV, bukan gambar saja, untuk membandingkan residu akhir dan galat terhadap solusi acuan.
- (vi) Pada diagnostik skew murni, cocokkan faktor kontraksi ekstragradien  $\sqrt{1 - \gamma^2 + \gamma^4}$  dengan hasil numerik.

## 14.8 Latihan, petunjuk, dan solusi lengkap

**Latihan 14.14** (Dari VI ke kerucut normal). Untuk  $C = [0, +\infty)$  dan  $F(x) = ax - b$  dengan  $a > 0$ , tentukan solusi VI( $F, C$ ) melalui inklusi kerucut normal.

**Petunjuk bertahap.** (i) Pisahkan kasus  $x > 0$  dan  $x = 0$ . (ii) Untuk  $x > 0$ ,  $N_C(x) = \{0\}$ . (iii) Pada  $x = 0$ ,  $N_C(0) = (-\infty, 0]$ .

**Solusi lengkap.** Jika  $x > 0$ , inklusi  $0 \in ax - b + N_C(x)$  memberi  $x = b/a$ , yang sah hanya bila  $b > 0$ . Pada  $x = 0$ , inklusi menjadi  $0 \in -b + (-\infty, 0]$ , atau  $b \leq 0$ . Jadi solusi tunggal adalah

$$x^* = \max\{b/a, 0\}. \quad (14.40)$$

**Latihan 14.15** (Monoton tetapi belum maksimal). Definisikan operator  $A$  melalui

$$\text{graph } A = \{(0, 0)\}. \quad (14.41)$$

Buktikan bahwa  $A$  monoton tetapi tidak monoton maksimal.

**Petunjuk bertahap.** (i) Uji definisi kemonotonan pada satu pasangan yang tersedia. (ii) Cari operator monoton dengan grafik lebih besar.

**Solusi lengkap.** Satu-satunya pasangan grafik yang dapat dibandingkan adalah  $(0, 0)$  dengan dirinya sendiri, sehingga hasil kali dalam pada definisi bernilai nol. Jadi  $A$  monoton. Operator nol  $\tilde{A}x = \{0\}$  untuk semua  $x \in \mathbb{R}^d$  juga monoton dan  $\text{graph } A \subsetneq \text{graph } \tilde{A}$ . Karena ada perluasan monoton ketat,  $A$  tidak maksimal.

**Latihan 14.16** (Resolven dan refleksi). Mulai dari (14.14). Buktikan bahwa  $R_{\gamma A} = 2J_{\gamma A} - I$  tak ekspansif.

**Petunjuk bertahap.** (i) Tetapkan  $p = J_{\gamma A}x$  dan  $q = J_{\gamma A}y$ . (ii) Kembangkan kuadrat norma  $2(p - q) - (x - y)$ .

**Solusi lengkap.** Perluasan langsung memberi

$$\begin{aligned} \|R_{\gamma A}x - R_{\gamma A}y\|^2 &= \|x - y\|^2 + 4\|p - q\|^2 - 4\langle p - q, x - y \rangle \\ &\leq \|x - y\|^2, \end{aligned} \quad (14.42)$$

karena kekakuan tak ekspansif menyatakan  $\|p - q\|^2 \leq \langle p - q, x - y \rangle$ .

**Latihan 14.17** (Operator skew: eksplisit versus implisit). Untuk  $\omega = 1$  pada (14.34), hitung norma operator langkah maju  $I - \gamma S$ , langkah ekstragradien  $(1 - \gamma^2)I - \gamma S$ , dan resolven  $(I + \gamma S)^{-1}$ .

**Petunjuk bertahap.** (i) Gunakan  $S^\top = -S$  dan  $S^\top S = \omega^2 I$ . (ii) Hitung kuadrat norma pada vektor sembarang.

**Solusi lengkap.**

$$(I - \gamma S)^\top (I - \gamma S) = (1 + \gamma^2 \omega^2)I, \quad (14.43)$$

dan dengan  $\omega = 1$  normanya  $\sqrt{1 + \gamma^2} > 1$ . Untuk ekstragradien, suku silang kembali hilang dan normanya  $\sqrt{(1 - \gamma^2)^2 + \gamma^2} = \sqrt{1 - \gamma^2 + \gamma^4} < 1$  bila  $0 < \gamma < 1$ . Selain itu,  $(I + \gamma S)^\top (I + \gamma S) = (1 + \gamma^2)I$ , sehingga norma inversnya  $1/\sqrt{1 + \gamma^2} < 1$ .

**Latihan 14.18** (Rentang langkah untuk bagian linear-skew). Untuk  $M = \mu I + S$  dengan  $\mu > 0$ , buktikan bahwa pemetaan  $x \mapsto Mx - b$  bersifat  $\beta$ -kokorsif dengan  $\beta = \mu/(\mu^2 + \omega^2)$ .

**Petunjuk bertahap.** (i) Konstanta  $b$  hilang ketika dua nilai dikurangkan. (ii) Gunakan  $\langle Sh, h \rangle = 0$  dan  $\|Mh\|^2 = (\mu^2 + \omega^2)\|h\|^2$ .

**Solusi lengkap.** Untuk  $h = x - y$ ,

$$\langle Mx - My, x - y \rangle = \mu\|h\|^2, \quad \|Mx - My\|^2 = (\mu^2 + \omega^2)\|h\|^2. \quad (14.44)$$

Bila  $h = 0$ , kesamaan kokorsif berlaku langsung. Bila  $h \neq 0$ , membagi kedua identitas memberi tepat  $\langle Mx - My, x - y \rangle = \beta\|Mx - My\|^2$ .

**Latihan 14.19** (Bayangan titik tetap Douglas–Rachford). Andaikan  $y = T_{DR}y$  dan tetapkan  $x = J_{\gamma B}y$ . Tunjukkan secara langsung bahwa  $0 \in (A + B)x$ .

**Petunjuk bertahap.** (i) Tulis  $z = J_{\gamma A}(2x - y)$ . (ii) Gunakan bentuk kedua (14.31) untuk memperoleh  $z = x$ . (iii) Jumlahkan dua inklusi resolven.

**Solusi lengkap.** Persamaan titik tetap memberi  $0 = -x + z$ , sehingga  $z = x$ . Dari definisi resolven,

$$\frac{y - x}{\gamma} \in Bx, \quad \frac{2x - y - z}{\gamma} = \frac{x - y}{\gamma} \in Ax. \quad (14.45)$$

Kedua unsur menjumlah menjadi nol, maka  $0 \in (A + B)x$ .

## 14.9 Peta asumsi dan batas klaim

| Hasil            | Asumsi penentu                                                           | Yang tidak diklaim                                |
|------------------|--------------------------------------------------------------------------|---------------------------------------------------|
| Ekuivalensi VI   | $C$ konveks tertutup tak kosong; definisi kerucut normal                 | keberadaan solusi tanpa asumsi tambahan           |
| Resolven         | $A$ monoton maksimal; $\gamma > 0$                                       | resolven jumlah mudah dihitung                    |
| Titik proksimal  | himpunan nol tak kosong; dimensi hingga; langkah tetap positif           | laju linear tanpa kemonotonan kuat                |
| Maju–mundur      | $A$ monoton maksimal; $B$ $\beta$ -kokorsif; $0 < \gamma < 2\beta$       | konvergensi untuk operator monoton Lipschitz umum |
| Ekstragradien    | $F$ monoton dan $L$ -Lipschitz; $C$ konveks tertutup; $0 < \gamma < 1/L$ | satu evaluasi operator per iterasi                |
| Douglas–Rachford | $A, B$ monoton maksimal; nol jumlah tak kosong                           | setiap iterat bayangan sudah merupakan solusi     |
| Laboratorium     | konfigurasi linear-skew dua dimensi yang dibekukan                       | kinerja universal atau peringkat algoritma        |

## Rujukan matematis dan saksi verifikasi

- Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, khususnya subdiferensial, operator proksimal, dan gradien proksimal; dipakai sebagai tulang punggung prasyarat.
- Stephen Becker dan Mitchell Krock, catatan kelas optimisasi konveks pada commit beku 98ed693, khususnya modul Douglas–Rachford yang telah diterima; dipakai untuk menjaga notasi dan batas nonduplikasi.
- George J. Minty, *Monotone (Nonlinear) Operators in Hilbert Space*, *Duke Mathematical Journal* 29 (1962), 341–346, DOI:10.1215/S0012-7094-62-02933-2.
- R. Tyrrell Rockafellar, *On the Maximal Monotonicity of Subdifferential Mappings*, *Pacific Journal of Mathematics* 33 (1970), 209–216, DOI:10.2140/PJM.1970.33.209.
- Pierre-Louis Lions dan Bertrand Mercier, *Splitting Algorithms for the Sum of Two Nonlinear Operators*, *SIAM Journal on Numerical Analysis* 16 (1979), 964–979, DOI:10.1137/0716071.

**Bagian VI**

**Asesmen dan Penutupan Kursus**

## Bab 15

# Asesmen, Laboratorium, dan Proyek Penutup

Bab ini menyediakan lapisan penutup kursus yang dapat dipakai untuk belajar mandiri: peta asesmen kumulatif, diagnostik prasyarat, enam set soal, rubrik pembuktian, ujian tengah dan akhir, dua laboratorium komputasi, serta satu proyek kapstone. Setiap soal mempunyai petunjuk bertahap, jawaban singkat, dan solusi acuan lengkap. Kode laboratorium dan proyek menghasilkan sertifikat deterministik yang dapat diperiksa tanpa perangkat lunak berpemilik.

Seluruh uraian, soal, solusi, rubrik, kode, dan instans sintetik dalam bab ini ditulis mandiri dan tersedia berdasarkan CC BY-SA 4.0. Bab ini tidak menyalin materi O018 tentang program linear atau bilangan bulat, simpleks, sensitivitas LP, ataupun optimisasi jaringan. Pendamping MIT OCW, Royer, dan Penn tetap merupakan karya terpisah dengan hak dan atribusinya sendiri.

### 15.1 Peta asesmen dan kontrak topologi

Bagian ini memetakan asesmen Original-03 tanpa mengulang bunyi soal. Seluruh teks baru pada tranche ini ditulis secara independen dan dilisensikan di bawah CC BY-SA 4.0. Notasi mengikuti spine Habring serta suplemen dan tranche yang sudah diterima, tetapi tidak ada butir donor yang disalin. Materi program linear, integer, simpleks, pemodelan riset operasi, dan wilayah O018 lainnya sengaja tidak dimasukkan.

Kontrak yang dapat diurai mesin adalah sebagai berikut. Setiap butir induk memiliki ID `*.problem.NNNN`. Setiap subbutir memiliki ID `*.prompt.NNNN` dan tepat satu pasangan `*.hint1.NNNN/*.hint2.NNNN`, satu `*.answer.NNNN`, serta satu `*.solution.NNNN`. Komentar `ORIG03-ASSESSMENT-MAP-ID` pada peta ini hanya merupakan rujukan nondeklaratif. Deklarasi otoritatif `ORIG03-STABLE-ID` dan label LaTeX yang berpadanan berada tepat pada butir soal di modul 01–10. Tujuh label `orig03:rubric:proof:0001` sampai `orig03:rubric:proof:0007` disediakan sebagai rujukan logis bagi rubrik bukti yang dihimpun oleh agregator.

#### 15.1.1 Lima puluh empat prompt baru

**Diagnostik prasyarat: 20 prompt.**

- `diag.prompt.0001`: norma dasar dan aritmetika vektor.
- `diag.prompt.0002`: rantai ketaksamaan norma.
- `diag.prompt.0003`: proyeksi pada hiperbidang.
- `diag.prompt.0004`: karakterisasi proyeksi konveks.
- `diag.prompt.0005`: koordinat kombinasi konveks.
- `diag.prompt.0006`: kestabilan kekonveksan terhadap irisan.
- `diag.prompt.0007`: gradien dan Hessian kuadratik.

- `diag.prompt.0008`: konstanta kuat-konveks dan mulus.
- `diag.prompt.0009`: penyangga afin orde pertama.
- `diag.prompt.0010`: stasioneritas dan optimalitas global.
- `diag.prompt.0011`: subdiferensial nilai mutlak.
- `diag.prompt.0012`: ambang lunak skalar.
- `diag.prompt.0013`: ekspektasi dan varians diskret.
- `diag.prompt.0014`: rata-rata sampel independen.
- `diag.prompt.0015`: penyelesaian rekurensi kontraktif.
- `diag.prompt.0016`: kompleksitas iterasi geometrik.
- `diag.prompt.0017`: kerucut normal dan optimalitas terkendala.
- `diag.prompt.0018`: bentuk titik tetap proyeksi.
- `diag.prompt.0019`: ortogonalitas dalam Cauchy–Schwarz.
- `diag.prompt.0020`: ketaksamaan Young berbobot.

**Set soal dasar konveks: 12 prompt.**

- `ps01.prompt.0001`: maksimum fungsi afin.
- `ps01.prompt.0002`: subdiferensial fungsi nilai mutlak.
- `ps01.prompt.0003`: minimisasi komposit satu dimensi.
- `ps01.prompt.0004`: spektrum kuadratik konveks.
- `ps01.prompt.0005`: kontraksi eksak langkah gradien.
- `ps01.prompt.0006`: evaluasi numerik Jensen.
- `ps01.prompt.0007`: pembuktian Jensen dua titik.
- `ps01.prompt.0008`: konjugat kuadratik.
- `ps01.prompt.0009`: bikonjugat kuadratik.
- `ps01.prompt.0010`: celah Fenchel–Young.
- `ps01.prompt.0011`: proyeksi pada kotak.
- `ps01.prompt.0012`: bukti pemotongan koordinat.

**Set soal metode proksimal: 11 prompt.**

- `ps02.prompt.0001`: penurunan rumus ambang lunak.
- `ps02.prompt.0002`: proks nilai mutlak berdimensi tiga.
- `ps02.prompt.0003`: operator iterasi gradien proksimal.
- `ps02.prompt.0004`: dua iterasi dan solusi eksak.
- `ps02.prompt.0005`: lema penurunan untuk gradien Lipschitz.
- `ps02.prompt.0006`: langkah kuadratik tajam.

- `ps02.prompt.0007`: bentuk operator maju–mundur.
- `ps02.prompt.0008`: titik tetap dan minimizer.
- `ps02.prompt.0009`: kontraksi operator maju–mundur.
- `ps02.prompt.0010`: resolven operator linear monoton kuat.
- `ps02.prompt.0011`: laju titik proksimal.

**Set soal dualitas dan KKT: 11 prompt.**

- `ps03.prompt.0001`: fungsi dual masalah kuadratik berekualitas.
- `ps03.prompt.0002`: sistem KKT dan celah nol.
- `ps03.prompt.0003`: pengali KKT kendala pertidaksamaan.
- `ps03.prompt.0004`: Slater dan dual skalar.
- `ps03.prompt.0005`: KKT proyeksi pada hiperbidang afin.
- `ps03.prompt.0006`: nilai primal dan dual hiperbidang.
- `ps03.prompt.0007`: keunikan dan kecukupan KKT.
- `ps03.prompt.0008`: pengali sebagai sensitivitas nilai.
- `ps03.prompt.0009`: ekspansi eksak fungsi nilai.
- `ps03.prompt.0010`: KKT proyeksi pada bola.
- `ps03.prompt.0011`: Slater dan kecukupan pada bola.

### 15.1.2 Empat belas latihan terselesaikan yang sudah diterima

Daftar berikut hanya memetakan ID dan peran kurikuler; bunyi latihan, petunjuk, dan solusi tetap berada pada modul asalnya.

- `d90.becker.98ed693.b03.exercise.0001`: ketakbiasan dalam reduksi varians.
- `d90.becker.98ed693.b03.exercise.0002`: identitas varians dan langkah kuadratik.
- `d90.orig.v1.tr01.exercise.0001`: operator proksimal Lasso.
- `d90.orig.v1.tr01.exercise.0002`: ketaksamaan satu langkah.
- `d90.orig.v1.tr01.exercise.0003`: sampling tanpa penggantian.
- `d90.orig.v1.tr01.exercise.0004`: cermin entropi.
- `d90.orig.v1.tr01.exercise.0005`: anggaran oracle minibatch.
- `d90.orig.v1.tr01.exercise.0006`: varians Prox-SAGA.
- `d90.orig.v1.tr02.exercise.0001`: VI dan kerucut normal.
- `d90.orig.v1.tr02.exercise.0002`: maksimalitas.
- `d90.orig.v1.tr02.exercise.0003`: resolven.
- `d90.orig.v1.tr02.exercise.0004`: operator skew.
- `d90.orig.v1.tr02.exercise.0005`: rentang langkah.
- `d90.orig.v1.tr02.exercise.0006`: bayangan Douglas–Rachford.

Dengan demikian, peta awal ini merujuk 54 prompt pada modul 01–04 dan 14 latihan terselesaikan yang sudah diterima tanpa mendeklarasikan ulang ID-nya. Asesmen kumulatif lanjutan, rubrik bukti, dua laboratorium komputasi, dan proyek kapstone kini lengkap pada modul 05–13 yang mengikuti peta ini.

## 15.2 Diagnostik prasyarat

Sepuluh butir berikut menguji prasyarat yang dipakai di seluruh buku. Setiap subbutir merupakan prompt tersendiri dengan dua tingkat petunjuk, jawaban ringkas, dan solusi lengkap. Materi ini tidak memuat pemodelan atau algoritma yang menjadi wilayah 0018.

**Latihan 15.1** (Norma dan ketaksamaan dasar). (i) Untuk  $x = (3, -4) \in \mathbb{R}^2$ , hitung  $\|x\|_1$ ,  $\|x\|_2$ , dan  $\|x\|_\infty$ .

(ii) Buktikan bahwa untuk setiap  $z \in \mathbb{R}^n$ ,

$$\|z\|_\infty \leq \|z\|_2 \leq \|z\|_1 \leq \sqrt{n} \|z\|_2.$$

**Petunjuk tahap 1 (diag.prompt.0001).** Gunakan langsung tiga definisi norma.

**Petunjuk tahap 2 (diag.prompt.0001).** Nilai mutlak koordinatnya adalah 3 dan 4.

**Jawaban ringkas (diag.prompt.0001).**  $\|x\|_1 = 7$ ,  $\|x\|_2 = 5$ , dan  $\|x\|_\infty = 4$ .

**Solusi lengkap (diag.prompt.0001).** Definisi memberi  $\|x\|_1 = |3| + |-4| = 7$ ,  $\|x\|_2 = \sqrt{3^2 + (-4)^2} = 5$ , dan  $\|x\|_\infty = \max\{3, 4\} = 4$ .

**Petunjuk tahap 1 (diag.prompt.0002).** Bandingkan setiap koordinat dengan jumlah kuadrat, lalu gunakan Cauchy–Schwarz untuk ketaksamaan terakhir.

**Petunjuk tahap 2 (diag.prompt.0002).** Kembangkan  $(\sum_i |z_i|)^2$  dan gunakan  $\sum_i |z_i| \leq \sqrt{\sum_i 1^2} \sqrt{\sum_i z_i^2}$ .

**Jawaban ringkas (diag.prompt.0002).** Rantai tersebut berlaku untuk semua  $z$ ; konstanta  $\sqrt{n}$  tajam pada vektor yang semua koordinat mutlaknya sama.

**Solusi lengkap (diag.prompt.0002).** Untuk setiap  $i$ ,  $|z_i|^2 \leq \sum_j |z_j|^2$ , sehingga  $\|z\|_\infty \leq \|z\|_2$ . Selanjutnya,  $\sum_i |z_i|^2 \leq (\sum_i |z_i|)^2$ , sehingga  $\|z\|_2 \leq \|z\|_1$ . Akhirnya Cauchy–Schwarz memberi  $\sum_i |z_i| \leq (\sum_i 1)^{1/2} (\sum_i |z_i|^2)^{1/2}$ . Ini menghasilkan ketaksamaan terakhir. Jika  $|z_1| = \dots = |z_n| > 0$ , ketaksamaan terakhir menjadi kesamaan. *Rubrik bukti: 15.9.1.*

**Latihan 15.2** (Proyeksi dan ortogonalitas). (i) Proyeksikan  $y = (2, -1)$  pada hiperbidang  $H = \{x \in \mathbb{R}^2 : x_1 + x_2 = 0\}$ .

(ii) Untuk himpunan konveks tertutup takkosong  $C$ , buktikan bahwa  $p = P_C(y)$  jika dan hanya jika  $\langle y - p, z - p \rangle \leq 0$  untuk setiap  $z \in C$ .

**Petunjuk tahap 1 (diag.prompt.0003).** Gunakan normal  $a = (1, 1)$  dan rumus proyeksi pada  $a^T x = 0$ .

**Petunjuk tahap 2 (diag.prompt.0003).** Kurangkan  $((a^T y)/(a^T a))a$  dari  $y$ .

**Jawaban ringkas (diag.prompt.0003).**  $P_H(y) = (3/2, -3/2)$ .

**Solusi lengkap (diag.prompt.0003).** Karena  $a^T y = 1$  dan  $a^T a = 2$ ,

$$P_H(y) = y - \frac{a^T y}{a^T a} a = (2, -1) - \frac{1}{2}(1, 1) = \left(\frac{3}{2}, -\frac{3}{2}\right).$$

Jumlah koordinat hasilnya nol, sedangkan selisih  $y - P_H(y)$  sejajar normal  $a$ , jadi hasil tersebut memang proyeksi ortogonal.

**Petunjuk tahap 1 (diag.prompt.0004).** Untuk arah maju gunakan titik  $p + t(z - p)$ ; untuk arah balik kembangkan  $\|y - z\|^2$ .

**Petunjuk tahap 2 (diag.prompt.0004).** Minimalitas fungsi kuadrat dalam  $t \in [0, 1]$  memberi turunan kanan taknegatif di  $t = 0$ .

**Jawaban ringkas (diag.prompt.0004).** Kondisi hasil kali dalam tersebut tepat merupakan kondisi optimalitas orde pertama bagi minimisasi jarak kuadrat pada  $C$ .

**Solusi lengkap (diag.prompt.0004).** Jika  $p = P_C(y)$ , maka untuk  $z \in C$  dan  $t \in [0, 1]$ , kekonveksan memberi  $p + t(z - p) \in C$ . Fungsi  $q(t) = \|y - p - t(z - p)\|^2$  minimum di  $t = 0$ , sehingga  $q'(0) = -2\langle y - p, z - p \rangle \geq 0$ . Sebaliknya, bila kondisi hasil kali dalam berlaku, maka untuk setiap  $z \in C$ ,

$$\|y - z\|^2 = \|y - p\|^2 + \|z - p\|^2 - 2\langle y - p, z - p \rangle \geq \|y - p\|^2.$$

Jadi  $p$  meminimalkan jarak. Keunikan mengikuti kekonveksan ketat jarak kuadrat. *Rubrik bukti: 15.9.4.*

**Latihan 15.3** (Kombinasi dan irisan konveks). (i) Tentukan  $t \in [0, 1]$  sehingga  $(1, 2) = t(0, 1) + (1 - t)(2, 3)$ .

(ii) Buktikan bahwa irisan sebarang keluarga himpunan konveks adalah konveks.

**Petunjuk tahap 1 (diag.prompt.0005).** Samakan koordinat pertama.

**Petunjuk tahap 2 (diag.prompt.0005).** Persamaan  $2(1-t) = 1$  memberi kandidat tunggal; periksa koordinat kedua.

**Jawaban ringkas (diag.prompt.0005).**  $t = 1/2$ .

**Solusi lengkap (diag.prompt.0005).** Koordinat pertama memberi  $2(1-t) = 1$ , jadi  $t = 1/2$ . Koordinat kedua lalu bernilai  $t + 3(1-t) = 1/2 + 3/2 = 2$ . Karena  $1/2 \in [0, 1]$ , ini kombinasi konveks yang sah.

**Petunjuk tahap 1 (diag.prompt.0006).** Ambil dua titik dalam irisan dan uji kombinasi konveksnya pada setiap anggota keluarga.

**Petunjuk tahap 2 (diag.prompt.0006).** Keanggotaan pada irisan berarti keanggotaan serentak pada semua himpunan.

**Jawaban ringkas (diag.prompt.0006).** Irisan tetap konveks; irisan kosong juga konveks secara vakum.

**Solusi lengkap (diag.prompt.0006).** Tuliskan  $C = \bigcap_{i \in I} C_i$  dengan setiap  $C_i$  konveks. Jika  $x, y \in C$  dan  $t \in [0, 1]$ , maka  $x, y \in C_i$  untuk setiap  $i$ . Karena  $C_i$  konveks,  $tx + (1-t)y \in C_i$  untuk setiap  $i$ , sehingga titik itu berada di  $C$ . Bila  $C$  kosong, implikasi dalam definisi konveks benar secara vakum. *Rubrik bukti: 15.9.1.*

**Latihan 15.4** (Kuadratik, gradien, dan spektrum). (i) Untuk  $f(x) = \frac{1}{2}x^T Qx + b^T x$  dengan  $Q = \begin{pmatrix} 4 & 1 \\ 1 & 2 \end{pmatrix}$  dan  $b = (-1, 3)$ , hitung  $\nabla f(1, -1)$  dan  $\nabla^2 f$ .

(ii) Tentukan konstanta kuat-konveks terbesar  $\mu$  dan konstanta Lipschitz gradien terkecil  $L$  bagi  $f$ .

**Petunjuk tahap 1 (diag.prompt.0007).** Karena  $Q$  simetris,  $\nabla f(x) = Qx + b$ .

**Petunjuk tahap 2 (diag.prompt.0007).** Hitung  $Q(1, -1)^T = (3, -1)^T$ .

**Jawaban ringkas (diag.prompt.0007).**  $\nabla f(1, -1) = (2, 2)$  dan  $\nabla^2 f = Q$ .

**Solusi lengkap (diag.prompt.0007).** Diferensiasi bentuk kuadratik simetris memberi  $\nabla f(x) = Qx + b$  dan  $\nabla^2 f = Q$ . Pada  $x = (1, -1)$ ,  $Qx = (4 - 1, 1 - 2) = (3, -1)$ , sehingga  $Qx + b = (2, 2)$ .

**Petunjuk tahap 1 (diag.prompt.0008).** Cari kedua nilai eigen matriks simetris  $Q$ .

**Petunjuk tahap 2 (diag.prompt.0008).** Persamaan karakteristiknya  $\lambda^2 - 6\lambda + 7 = 0$ .

**Jawaban ringkas (diag.prompt.0008).**  $\mu = 3 - \sqrt{2}$  dan  $L = 3 + \sqrt{2}$ .

**Solusi lengkap (diag.prompt.0008).** Nilai eigen  $Q$  adalah akar  $\lambda^2 - 6\lambda + 7 = 0$ , yaitu  $3 \pm \sqrt{2}$ . Untuk kuadratik dengan Hessian konstan simetris positif definit, konstanta kuat-konveks terbesar adalah nilai eigen minimum dan konstanta Lipschitz gradien terkecil adalah nilai eigen maksimum. Jadi hasilnya  $\mu = 3 - \sqrt{2}$  dan  $L = 3 + \sqrt{2}$ . *Rubrik bukti: 15.9.2.*

**Latihan 15.5** (Kondisi orde pertama). (i) Untuk  $f(x) = (x-2)^2 + 1$ , tuliskan penyangga afin orde pertama di  $x_0 = 0$  dan verifikasi bahwa penyangga itu menyentuh  $f$  di  $x_0$ .

(ii) Buktikan bahwa jika  $f$  konveks dan terdiferensialkan serta  $\nabla f(x^*) = 0$ , maka  $x^*$  adalah minimizer global.

**Petunjuk tahap 1 (diag.prompt.0009).** Gunakan  $f(x_0) + f'(x_0)(x - x_0)$ .

**Petunjuk tahap 2 (diag.prompt.0009).**  $f(0) = 5$  dan  $f'(0) = -4$ .

**Jawaban ringkas (diag.prompt.0009).** Penyangga afinnya  $\ell(x) = 5 - 4x$ , dan  $\ell(0) = f(0) = 5$ .

**Solusi lengkap (diag.prompt.0009).** Turunan  $f'(x) = 2(x-2)$ , jadi  $f'(0) = -4$ . Karena itu  $\ell(x) = f(0) + f'(0)x = 5 - 4x$ . Selisihnya  $f(x) - \ell(x) = x^2 \geq 0$ , dan selisih nol di  $x = 0$ .

**Petunjuk tahap 1 (diag.prompt.0010).** Gunakan ketaksamaan orde pertama bagi fungsi konveks.

**Petunjuk tahap 2 (diag.prompt.0010).** Substitusikan gradien nol dalam  $f(y) \geq f(x^*) + \langle \nabla f(x^*), y - x^* \rangle$ .

**Jawaban ringkas (diag.prompt.0010).**  $f(y) \geq f(x^*)$  untuk setiap  $y$ .

**Solusi lengkap (diag.prompt.0010).** Kekonveksan dan keterdiferensialan memberi, untuk setiap  $y$ ,

$$f(y) \geq f(x^*) + \langle \nabla f(x^*), y - x^* \rangle = f(x^*).$$

Jadi tidak ada titik dengan nilai lebih kecil daripada  $x^*$ . *Rubrik bukti: 15.9.1.*

**Latihan 15.6** (Subgradien dan operator proksimal). (i) Tentukan  $\partial|x|$  pada  $x = -2$ ,  $x = 0$ , dan  $x = 3$ .

(ii) Hitung  $\text{prox}_{|\cdot|}(-3)$ .

**Petunjuk tahap 1 (diag.prompt.0011).** Di luar nol gunakan turunan; di nol gunakan definisi subgradien.

**Petunjuk tahap 2 (diag.prompt.0011).** Pada nol,  $g$  harus memenuhi  $|y| \geq gy$  untuk semua  $y$ .

**Jawaban ringkas (diag.prompt.0011).**  $\partial|-2| = \{-1\}$ ,  $\partial|0| = [-1, 1]$ , dan  $\partial|3| = \{1\}$ .

**Solusi lengkap (diag.prompt.0011).** Fungsi  $|x|$  terdiferensialkan dengan turunan  $-1$  untuk  $x < 0$  dan  $1$  untuk  $x > 0$ . Pada nol, syarat subgradien adalah  $|y| \geq gy$  untuk setiap  $y$ . Pemilihan  $y > 0$  memberi  $g \leq 1$ , sedangkan  $y < 0$  memberi  $g \geq -1$ . Jadi subdiferensial di nol adalah  $[-1, 1]$ .

**Petunjuk tahap 1 (diag.prompt.0012).** Gunakan rumus ambang lunak dengan ambang satu.

**Petunjuk tahap 2 (diag.prompt.0012).**  $S_1(v) = \text{sign}(v) \max\{|v| - 1, 0\}$ .

**Jawaban ringkas (diag.prompt.0012).**  $\text{prox}_{|\cdot|}(-3) = -2$ .

**Solusi lengkap (diag.prompt.0012).** Operator proksimal meminimalkan  $|x| + \frac{1}{2}(x+3)^2$ . Karena minimizer negatif, turunan pada cabang  $x < 0$  adalah  $-1 + x + 3 = x + 2$ , yang nol pada  $x = -2$ . Titik itu konsisten dengan cabangnya dan memberi hasil yang sama dengan  $S_1(-3) = -2$ .

**Latihan 15.7** (Ekspektasi dan rata-rata sampel). (i) Peubah acak  $X$  bernilai  $-1$  dengan peluang  $2/3$  dan  $2$  dengan peluang  $1/3$ . Hitung  $\mathbb{E}X$  dan  $\text{Var}(X)$ .

(ii) Jika  $X_1, \dots, X_m$  saling independen dan berdistribusi seperti  $X$ , tentukan ekspektasi dan varians  $\bar{X}_m = m^{-1} \sum_{i=1}^m X_i$ .

**Petunjuk tahap 1 (diag.prompt.0013).** Hitung momen pertama dan kedua.

**Petunjuk tahap 2 (diag.prompt.0013).**  $\mathbb{E}X^2 = (2/3)1 + (1/3)4$ .

**Jawaban ringkas (diag.prompt.0013).**  $\mathbb{E}X = 0$  dan  $\text{Var}(X) = 2$ .

**Solusi lengkap (diag.prompt.0013).** Kita memperoleh  $\mathbb{E}X = (2/3)(-1) + (1/3)2 = 0$  dan  $\mathbb{E}X^2 = (2/3)1 + (1/3)4 = 2$ . Maka  $\text{Var}(X) = \mathbb{E}X^2 - (\mathbb{E}X)^2 = 2$ .

**Petunjuk tahap 1 (diag.prompt.0014).** Gunakan linearitas ekspektasi dan aditivitas varians bagi peubah independen.

**Petunjuk tahap 2 (diag.prompt.0014).** Faktor  $1/m$  dikuadratkan ketika menghitung varians.

**Jawaban ringkas (diag.prompt.0014).**  $\mathbb{E}\bar{X}_m = 0$  dan  $\text{Var}(\bar{X}_m) = 2/m$ .

**Solusi lengkap (diag.prompt.0014).** Linearitas memberi  $\mathbb{E}\bar{X}_m = m^{-1} \sum_i \mathbb{E}X_i = 0$ . Independensi memberi

$$\text{Var}(\bar{X}_m) = \frac{1}{m^2} \sum_{i=1}^m \text{Var}(X_i) = \frac{1}{m^2} (2m) = \frac{2}{m}.$$

*Rubrik bukti: 15.9.3.*

**Latihan 15.8** (Rekurensi kontraktif). (i) Selesaikan  $x_{k+1} = \frac{3}{4}x_k + 1$  dengan  $x_0 = 0$  dan tentukan titik tetapnya.

(ii) Tentukan bilangan bulat terkecil  $k$  yang menjamin  $|x_k - 4| \leq 10^{-2}$ .

**Petunjuk tahap 1 (diag.prompt.0015).** Kurangkan titik tetap dari kedua ruas.

**Petunjuk tahap 2 (diag.prompt.0015).** Titik tetap memenuhi  $x = \frac{3}{4}x + 1$ .

**Jawaban ringkas (diag.prompt.0015).** Titik tetapnya  $4$  dan  $x_k = 4(1 - (3/4)^k)$ .

**Solusi lengkap (diag.prompt.0015).** Persamaan titik tetap memberi  $x^* = 4$ . Dengan  $e_k = x_k - 4$  diperoleh  $e_{k+1} = \frac{3}{4}e_k$  dan  $e_0 = -4$ . Jadi  $e_k = -4(3/4)^k$  dan  $x_k = 4(1 - (3/4)^k)$ .

**Petunjuk tahap 1 (diag.prompt.0016).** Gunakan bentuk tertutup galat dari subbutir sebelumnya.

**Petunjuk tahap 2 (diag.prompt.0016).** Selesaikan  $(3/4)^k \leq 1/400$  dengan logaritma.

**Jawaban ringkas (diag.prompt.0016).**  $k = 21$ .

**Solusi lengkap (diag.prompt.0016).** Karena  $|x_k - 4| = 4(3/4)^k$ , syaratnya adalah  $(3/4)^k \leq 1/400$ . Karena  $\log(3/4) < 0$ ,

$$k \geq \frac{\log(1/400)}{\log(3/4)} \approx 20.827.$$

Bilangan bulat terkecil yang memenuhi adalah  $21$ .

**Latihan 15.9** (Kerucut normal dan titik tetap proyeksi). (i) Minimalkan  $f(x) = (x - 2)^2$  pada  $C = [0, 1]$  dan verifikasi  $0 \in f'(x^*) + N_C(x^*)$  dengan konvensi  $N_C(x) = \{v : v(y - x) \leq 0 \forall y \in C\}$ .

(ii) Verifikasi bahwa untuk setiap  $\gamma > 0$ , solusi tersebut memenuhi  $x^* = P_C(x^* - \gamma f'(x^*))$ .

**Petunjuk tahap 1 (diag.prompt.0017).** Minimizer tak terkendala berada di luar interval.

**Petunjuk tahap 2 (diag.prompt.0017).** Pada ujung kanan,  $N_{[0,1]}(1) = [0, \infty)$ .

**Jawaban ringkas (diag.prompt.0017).**  $x^* = 1$ ,  $f'(1) = -2$ , dan  $2 \in N_C(1)$ .

**Solusi lengkap (diag.prompt.0017).** Fungsi menurun pada  $[0, 1]$ , jadi minimumnya tercapai di  $x^* = 1$ . Turunannya  $f'(x) = 2(x - 2)$  memberi  $f'(1) = -2$ . Dari definisi, setiap  $v \geq 0$  memenuhi  $v(y - 1) \leq 0$  untuk  $y \in [0, 1]$ , sehingga  $N_C(1) = [0, \infty)$ . Memilih  $v = 2$  menghasilkan  $0 = -2 + 2 \in f'(1) + N_C(1)$ . *Rubrik bukti: 15.9.4.*

**Petunjuk tahap 1 (diag.prompt.0018).** Substitusikan  $x^* = 1$  dan  $f'(1) = -2$ .

**Petunjuk tahap 2 (diag.prompt.0018).** Argumen proyeksinya menjadi  $1 + 2\gamma > 1$ .

**Jawaban ringkas (diag.prompt.0018).**  $P_{[0,1]}(1 + 2\gamma) = 1 = x^*$ .

**Solusi lengkap (diag.prompt.0018).** Untuk  $\gamma > 0$ ,  $x^* - \gamma f'(x^*) = 1 - \gamma(-2) = 1 + 2\gamma$ . Proyeksi setiap bilangan lebih besar daripada satu pada  $[0, 1]$  adalah satu. Karena itu  $P_C(x^* - \gamma f'(x^*)) = 1 = x^*$ .

**Latihan 15.10** (Cauchy–Schwarz dan Young). (i) Untuk  $u = (1, 2)$  dan  $v = (2, -1)$ , hitung hasil kali dalam dan kedua normanya, lalu periksa ketaksamaan Cauchy–Schwarz.

(ii) Buktikan bahwa untuk  $a, b \in \mathbb{R}$  dan  $\eta > 0$ ,  $2ab \leq \eta a^2 + \eta^{-1}b^2$ , serta tentukan syarat kesamaan.

**Petunjuk tahap 1 (diag.prompt.0019).** Hitung  $u^T v$  sebelum normanya.

**Petunjuk tahap 2 (diag.prompt.0019).** Kedua norma sama dengan  $\sqrt{5}$ .

**Jawaban ringkas (diag.prompt.0019).**  $\langle u, v \rangle = 0$  dan  $0 \leq 5$ .

**Solusi lengkap (diag.prompt.0019).**  $\langle u, v \rangle = 1 \cdot 2 + 2 \cdot (-1) = 0$ , sedangkan  $\|u\|_2 = \|v\|_2 = \sqrt{5}$ . Jadi  $|\langle u, v \rangle| = 0 \leq \|u\|_2 \|v\|_2 = 5$ . Vektor-vektor tersebut ortogonal, bukan sejajar, sehingga ketaksamaan tidak menjadi kesamaan pada batas atas yang positif.

**Petunjuk tahap 1 (diag.prompt.0020).** Mulai dari kuadrat yang taknegatif.

**Petunjuk tahap 2 (diag.prompt.0020).** Kembangkan  $(\sqrt{\eta} a - b/\sqrt{\eta})^2$ .

**Jawaban ringkas (diag.prompt.0020).** Ketaksamaan selalu berlaku dan kesamaan terjadi tepat ketika  $b = \eta a$ .

**Solusi lengkap (diag.prompt.0020).** Karena

$$0 \leq \left( \sqrt{\eta} a - \frac{b}{\sqrt{\eta}} \right)^2 = \eta a^2 - 2ab + \eta^{-1} b^2,$$

pemindahan suku memberi ketaksamaan yang diminta. Kuadrat itu nol tepat jika  $\sqrt{\eta} a = b/\sqrt{\eta}$ , yaitu  $b = \eta a$ .

*Rubrik bukti: 15.9.1.*

### 15.3 Set soal I: dasar konveks

Lima masalah berikut melatih definisi konveksitas, kelengkungan kuadratik, ketaksamaan Jensen, konjugasi Fenchel, dan proyeksi. Setiap subbutir adalah prompt tersendiri dengan dua petunjuk, jawaban ringkas, dan solusi lengkap.

**Latihan 15.11** (Maksimum afin, subdiferensial, dan optimalitas). (i) Untuk  $a_1, a_2 \in \mathbb{R}^n$  dan  $b_1, b_2 \in \mathbb{R}$ , buktikan bahwa

$$f(x) = \max\{a_1^\top x + b_1, a_2^\top x + b_2\}$$

adalah fungsi konveks.

(ii) Tentukan  $\partial|x|$  untuk setiap  $x \in \mathbb{R}$ .

(iii) Tentukan peminimum dan nilai minimum

$$\varphi(x) = |x| + \frac{1}{2}(x - 1)^2,$$

serta verifikasi syarat optimalitas subgradien di titik tersebut.

**Petunjuk tahap 1 (ps01.prompt.0001).** Tuliskan kedua fungsi afin sebagai  $\ell_i(x) = a_i^\top x + b_i$ .

**Petunjuk tahap 2 (ps01.prompt.0001).** Untuk  $t \in [0, 1]$ , batasi setiap  $t\ell_i(x) + (1-t)\ell_i(y)$  dengan kombinasi maksimum di  $x$  dan  $y$ .

**Jawaban ringkas (ps01.prompt.0001).**  $f$  konveks karena maksimum berhingga fungsi-fungsi afin adalah konveks.

**Solusi lengkap (ps01.prompt.0001).** Ambil  $x, y \in \mathbb{R}^n$  dan  $t \in [0, 1]$ . Untuk setiap  $i \in \{1, 2\}$ ,

$$\ell_i(tx + (1-t)y) = t\ell_i(x) + (1-t)\ell_i(y) \leq tf(x) + (1-t)f(y).$$

Mengambil maksimum terhadap  $i$  pada ruas kiri memberi  $f(tx + (1-t)y) \leq tf(x) + (1-t)f(y)$ , yakni definisi konveksitas. *Rubrik bukti: 15.9.1.*

**Petunjuk tahap 1 (ps01.prompt.0002).** Di luar nol,  $|x|$  terdiferensialkan.

**Petunjuk tahap 2 (ps01.prompt.0002).** Di  $x = 0$ , gunakan definisi  $g \in \partial| \cdot |(0)$ , yaitu  $|y| \geq gy$  untuk semua  $y$ .

**Jawaban ringkas (ps01.prompt.0002).**

$$\partial|x| = \begin{cases} \{-1\}, & x < 0, \\ [-1, 1], & x = 0, \\ \{1\}, & x > 0. \end{cases}$$

**Solusi lengkap (ps01.prompt.0002).** Untuk  $x > 0$  dan  $x < 0$ , turunan  $|x|$  masing-masing adalah 1 dan  $-1$ ; subdiferensial fungsi konveks yang terdiferensialkan adalah singleton yang berisi turunannya. Di nol, syarat subgradien adalah  $|y| \geq gy$  untuk semua  $y$ . Memilih  $y > 0$  memberi  $g \leq 1$ , sedangkan  $y < 0$  memberi  $g \geq -1$ . Sebaliknya, setiap  $g \in [-1, 1]$  memenuhi  $gy \leq |y|$ , sehingga interval tersebut tepat merupakan subdiferensial di nol.

**Petunjuk tahap 1 (ps01.prompt.0003).** Gunakan  $0 \in \partial\varphi(x)$ .

**Petunjuk tahap 2 (ps01.prompt.0003).** Uji titik  $x = 0$  dengan  $\partial\varphi(0) = [-1, 1] + (0 - 1)$ .

**Jawaban ringkas (ps01.prompt.0003).** Peminimum uniknya adalah  $x^* = 0$  dan nilai minimumnya  $\varphi(x^*) = 1/2$ .

**Solusi lengkap (ps01.prompt.0003).** Karena suku kuadrat bersifat konveks kuat,  $\varphi$  mempunyai paling banyak satu peminimum. Di nol,

$$\partial\varphi(0) = \partial| \cdot |(0) + (0 - 1) = [-1, 1] - 1 = [-2, 0],$$

yang memuat nol. Maka syarat optimalitas perlu dan cukup untuk fungsi konveks terpenuhi, sehingga  $x^* = 0$ . Substitusi memberi  $\varphi(0) = 0 + \frac{1}{2} = \frac{1}{2}$ .

**Latihan 15.12** (Parameter kelengkungan dan langkah gradien). Untuk

$$Q = \begin{pmatrix} 1 & 0 \\ 0 & 4 \end{pmatrix}, \quad f(x) = \frac{1}{2}x^\top Qx,$$

jawab pertanyaan berikut.

- (i) Tentukan konstanta konveksitas kuat terbesar  $\mu$  dan konstanta Lipschitz terkecil  $L$  untuk gradien  $f$  dalam norma Euclid.
- (ii) Untuk langkah gradien  $x^+ = x - \frac{1}{4}\nabla f(x)$ , hitung  $x^+$  dan buktikan  $f(x^+) \leq \frac{9}{16}f(x)$ . Tentukan kapan batas itu tajam.

**Petunjuk tahap 1 (ps01.prompt.0004).** Gunakan nilai eigen ekstrem Hessian.

**Petunjuk tahap 2 (ps01.prompt.0004).** Hessian  $\nabla^2 f = Q$  mempunyai nilai eigen 1 dan 4.

**Jawaban ringkas (ps01.prompt.0004).**  $\mu = 1$  dan  $L = 4$ .

**Solusi lengkap (ps01.prompt.0004).** Untuk kuadrat simetris, konstanta konveksitas kuat terbesar adalah  $\lambda_{\min}(Q)$  dan konstanta Lipschitz gradien terkecil adalah  $\|Q\|_2 = \lambda_{\max}(Q)$ . Karena spektrum  $Q$  adalah  $\{1, 4\}$ , diperoleh  $\mu = 1$  dan  $L = 4$ . Keduanya tajam pada masing-masing arah eigen.

**Petunjuk tahap 1 (ps01.prompt.0005).** Hitung  $(I - \frac{1}{4}Q)x$ .

**Petunjuk tahap 2 (ps01.prompt.0005).** Bandingkan  $\frac{1}{2}(\frac{3}{4}x_1)^2$  dengan  $\frac{9}{16}\frac{1}{2}(x_1^2 + 4x_2^2)$ .

**Jawaban ringkas (ps01.prompt.0005).**  $x^+ = (\frac{3}{4}x_1, 0)$ ; faktor  $9/16$  tajam tepat pada arah sumbu pertama (selain kasus nol,  $x_2 = 0$ ).

**Solusi lengkap (ps01.prompt.0005).** Karena  $\nabla f(x) = (x_1, 4x_2)$ ,

$$x^+ = x - \frac{1}{4}\nabla f(x) = \left(\frac{3}{4}x_1, 0\right).$$

Jadi

$$f(x^+) = \frac{1}{2}\frac{9}{16}x_1^2 \leq \frac{9}{16}\frac{1}{2}(x_1^2 + 4x_2^2) = \frac{9}{16}f(x).$$

Selisih ruas kanan dan kiri adalah  $\frac{9}{8}x_2^2$ , sehingga kesamaan terjadi jika dan hanya jika  $x_2 = 0$ .

**Latihan 15.13** (Ketaksamaan Jensen). Ambil  $f(x) = x^2$ , titik  $x_1 = -1$ ,  $x_2 = 3$ , dan bobot  $\theta_1 = 1/4$ ,  $\theta_2 = 3/4$ .

(i) Hitung kedua ruas ketaksamaan Jensen untuk data tersebut.

(ii) Buktikan ketaksamaan Jensen dua titik langsung dari definisi fungsi konveks.

**Petunjuk tahap 1 (ps01.prompt.0006).** Hitung dahulu rata-rata berbobot kedua titik.

**Petunjuk tahap 2 (ps01.prompt.0006).**  $\frac{1}{4}(-1) + \frac{3}{4}(3) = 2$ .

**Jawaban ringkas (ps01.prompt.0006).** Ruas kiri adalah 4 dan ruas kanan adalah 7, jadi  $4 \leq 7$ .

**Solusi lengkap (ps01.prompt.0006).** Rata-rata berbobotnya  $\bar{x} = 2$ , sehingga  $f(\bar{x}) = 2^2 = 4$ . Sementara itu,

$$\frac{1}{4}f(-1) + \frac{3}{4}f(3) = \frac{1}{4}(1) + \frac{3}{4}(9) = 7.$$

Karena  $4 \leq 7$ , data tersebut memenuhi ketaksamaan Jensen.

**Petunjuk tahap 1 (ps01.prompt.0007).** Tuliskan definisi konveksitas dengan parameter  $t \in [0, 1]$ .

**Petunjuk tahap 2 (ps01.prompt.0007).** Ganti  $t$  dengan  $\theta_1$  dan  $1 - t$  dengan  $\theta_2$ .

**Jawaban ringkas (ps01.prompt.0007).** Untuk  $\theta_1, \theta_2 \geq 0$  dan  $\theta_1 + \theta_2 = 1$ ,  $f(\theta_1 x_1 + \theta_2 x_2) \leq \theta_1 f(x_1) + \theta_2 f(x_2)$ .

**Solusi lengkap (ps01.prompt.0007).** Definisi konveksitas menyatakan bahwa, untuk semua  $x_1, x_2$  dan  $t \in [0, 1]$ ,

$$f(tx_1 + (1-t)x_2) \leq tf(x_1) + (1-t)f(x_2).$$

Setiap pasangan bobot nonnegatif dengan jumlah satu dapat ditulis sebagai  $t = \theta_1$  dan  $1 - t = \theta_2$ . Substitusi memberi persis ketaksamaan Jensen dua titik. *Rubrik bukti: 15.9.1.*

**Latihan 15.14** (Konjugat kuadratik dan celah Fenchel–Young). Untuk  $a > 0$ , definisikan  $f(x) = \frac{a}{2}x^2$  pada  $\mathbb{R}$ .

(i) Hitung konjugat Fenchel  $f^*(y)$ .

(ii) Hitung  $f^{**}(x)$  secara langsung dan bandingkan dengan  $f(x)$ .

(iii) Nyatakan celah Fenchel–Young  $f(x) + f^*(y) - xy$  sebagai kuadrat dan tentukan syarat kesamaan.

**Petunjuk tahap 1 (ps01.prompt.0008).** Maksimalkan  $xy - \frac{a}{2}x^2$  terhadap  $x$ .

**Petunjuk tahap 2 (ps01.prompt.0008).** Titik stasionernya memenuhi  $y - ax = 0$ .

**Jawaban ringkas (ps01.prompt.0008).**  $f^*(y) = y^2/(2a)$ .

**Solusi lengkap (ps01.prompt.0008).** Menurut definisi,

$$f^*(y) = \sup_x \left\{ xy - \frac{a}{2}x^2 \right\}.$$

Fungsi di dalam supremum cekung kuat terhadap  $x$ ; turunannya nol di  $x = y/a$ . Substitusi menghasilkan  $y(y/a) - \frac{a}{2}(y/a)^2 = y^2/(2a)$ .

**Petunjuk tahap 1 (ps01.prompt.0009).** Terapkan kembali definisi konjugat pada  $f^*(y) = y^2/(2a)$ .

**Petunjuk tahap 2 (ps01.prompt.0009).** Maksimum  $xy - y^2/(2a)$  tercapai di  $y = ax$ .

**Jawaban ringkas (ps01.prompt.0009).**  $f^{**}(x) = ax^2/2 = f(x)$ .

**Solusi lengkap (ps01.prompt.0009).** Kita memperoleh

$$f^{**}(x) = \sup_y \left\{ xy - \frac{y^2}{2a} \right\}.$$

Turunan terhadap  $y$  adalah  $x - y/a$ , jadi pemaksimum uniknya  $y = ax$ . Nilai supremumnya  $ax^2 - ax^2/2 = ax^2/2 = f(x)$ .

**Petunjuk tahap 1 (ps01.prompt.0010).** Samakan penyebut pada  $\frac{a}{2}x^2 + \frac{1}{2a}y^2 - xy$ .

**Petunjuk tahap 2 (ps01.prompt.0010).** Kenali kuadrat dari  $ax - y$ .

**Jawaban ringkas (ps01.prompt.0010).** Celahnya  $(ax - y)^2/(2a) \geq 0$ , dan kesamaan berlaku tepat ketika  $y = ax$ .

**Solusi lengkap (ps01.prompt.0010).** Perhitungan langsung memberi

$$f(x) + f^*(y) - xy = \frac{a}{2}x^2 + \frac{y^2}{2a} - xy = \frac{(ax - y)^2}{2a}.$$

Karena  $a > 0$ , nilai ini nonnegatif. Nilainya nol jika dan hanya jika  $ax - y = 0$ , yakni  $y = ax = \nabla f(x)$ . *Rubrik bukti: 15.9.2.*

**Latihan 15.15** (Proyeksi pada kotak). Misalkan  $C = [0, 3]^3$  dan  $v = (-1, 2, 4)$ .

(i) Hitung proyeksi Euclid  $P_C(v)$ .

(ii) Buktikan bahwa proyeksi pada kotak  $[\ell, u]^n$  diperoleh dengan memotong setiap koordinat ke interval  $[\ell, u]$ .

**Petunjuk tahap 1 (ps01.prompt.0011).** Potong setiap koordinat ke interval  $[0, 3]$ .

**Petunjuk tahap 2 (ps01.prompt.0011).**  $-1$  dipetakan ke  $0$ ,  $2$  tetap, dan  $4$  dipetakan ke  $3$ .

**Jawaban ringkas (ps01.prompt.0011).**  $P_C(v) = (0, 2, 3)$ .

**Solusi lengkap (ps01.prompt.0011).** Meminimumkan  $\frac{1}{2}\|x-v\|_2^2$  pada  $C$  terpisah menjadi tiga masalah skalar. Peminimum  $\frac{1}{2}(x_i - v_i)^2$  pada  $[0, 3]$  masing-masing adalah  $0$ ,  $2$ , dan  $3$ . Karena jumlah mencapai minimum tepat ketika setiap sukunya minimum,  $P_C(v) = (0, 2, 3)$ .

**Petunjuk tahap 1 (ps01.prompt.0012).** Tuliskan kuadrat jarak sebagai jumlah fungsi satu koordinat.

**Petunjuk tahap 2 (ps01.prompt.0012).** Peminimum skalar adalah  $\ell$  jika  $v_i < \ell$ ,  $v_i$  jika  $\ell \leq v_i \leq u$ , dan  $u$  jika  $v_i > u$ .

**Jawaban ringkas (ps01.prompt.0012).**

$$[P_{[\ell, u]^n}(v)]_i = \min\{u, \max\{\ell, v_i\}\}.$$

**Solusi lengkap (ps01.prompt.0012).** Masalah proyeksi adalah

$$\min_{\ell \leq x_i \leq u} \frac{1}{2} \sum_{i=1}^n (x_i - v_i)^2.$$

Daerah layak merupakan hasil kali interval dan objektif merupakan jumlah suku yang masing-masing hanya bergantung pada satu koordinat. Karena itu, setiap koordinat dapat diminimumkan secara independen. Fungsi skalar  $(s - v_i)^2/2$  berkurang hingga  $s = v_i$  lalu meningkat; pembatasan pada  $[\ell, u]$  menghasilkan  $s = \min\{u, \max\{\ell, v_i\}\}$ . Menggabungkan semua koordinat membuktikan rumus tersebut. *Rubrik bukti: 15.9.4.*

## 15.4 Set soal II: metode proksimal

Lima masalah berikut menghubungkan operator proksimal, pemisahan maju-mundur, lemma penurunan, resolven monoton, dan laju titik proksimal.

**Latihan 15.16** (Ambang lunak sebagai operator proksimal). Untuk  $\lambda > 0$ , definisikan  $S_\lambda(v) = \text{sign}(v) \max\{|v| - \lambda, 0\}$ .

- (i) Buktikan bahwa  $\text{prox}_{\lambda|\cdot|}(v) = S_\lambda(v)$  untuk setiap  $v \in \mathbb{R}$ .
- (ii) Dengan penerapan per koordinat, hitung  $\text{prox}_{(3/4)\|\cdot\|_1}(3, -1/2, -2)$ .

**Petunjuk tahap 1 (ps02.prompt.0001).** Tuliskan syarat optimalitas untuk  $\min_x \{\lambda|x| + \frac{1}{2}(x-v)^2\}$ .

**Petunjuk tahap 2 (ps02.prompt.0001).** Pisahkan kasus  $x > 0$ ,  $x < 0$ , dan  $x = 0$  dalam  $0 \in x - v + \lambda\partial|x|$ .

**Jawaban ringkas (ps02.prompt.0001).**

$$\text{prox}_{\lambda|\cdot|}(v) = \begin{cases} v - \lambda, & v > \lambda, \\ 0, & |v| \leq \lambda, \\ v + \lambda, & v < -\lambda, \end{cases} = S_\lambda(v).$$

**Solusi lengkap (ps02.prompt.0001).** Objektif bersifat konveks kuat, sehingga syarat

$$0 \in x - v + \lambda\partial|x|$$

menentukan peminimum unik. Jika  $x > 0$ , syaratnya  $x = v - \lambda$ , konsisten tepat ketika  $v > \lambda$ . Jika  $x < 0$ , diperoleh  $x = v + \lambda$ , konsisten tepat ketika  $v < -\lambda$ . Jika  $x = 0$ , syarat menjadi  $v \in \lambda[-1, 1]$ , ekuivalen dengan  $|v| \leq \lambda$ . Ketiga kasus itu persis rumus  $S_\lambda(v)$ . *Rubrik bukti: 15.9.5.*

**Petunjuk tahap 1 (ps02.prompt.0002).** Norma satu dan kuadrat jarak keduanya terpisah menurut koordinat.

**Petunjuk tahap 2 (ps02.prompt.0002).** Terapkan  $S_{3/4}$  pada ketiga koordinat.

**Jawaban ringkas (ps02.prompt.0002).**  $\text{prox}_{(3/4)\|\cdot\|_1}(3, -1/2, -2) = (9/4, 0, -5/4)$ .

**Solusi lengkap (ps02.prompt.0002).** Pemisahan koordinat memberi

$$S_{3/4}(3) = 3 - \frac{3}{4} = \frac{9}{4}, \quad S_{3/4}(-1/2) = 0, \quad S_{3/4}(-2) = -2 + \frac{3}{4} = -\frac{5}{4}.$$

Menggabungkan ketiga peminimum skalar menghasilkan vektor yang dinyatakan.

**Latihan 15.17** (Iterasi maju-mundur skalar). Pertimbangkan  $F(x) = \frac{1}{2}(x-3)^2 + |x|$  dan langkah  $\gamma = 1/2$ .

- (i) Turunkan pemetaan iterasi maju-mundur  $x^+ = T(x)$ .
- (ii) Dari  $x_0 = 0$ , hitung  $x_1$  dan  $x_2$ , lalu tentukan peminimum eksak  $F$ .

**Petunjuk tahap 1 (ps02.prompt.0003).** Pisahkan bagian mulus  $g(x) = \frac{1}{2}(x-3)^2$  dan  $h(x) = |x|$ .

**Petunjuk tahap 2 (ps02.prompt.0003).** Gunakan  $T(x) = \text{prox}_{\gamma h}(x - \gamma g'(x))$ .

**Jawaban ringkas (ps02.prompt.0003).**  $T(x) = S_{1/2}((x+3)/2)$ .

**Solusi lengkap (ps02.prompt.0003).** Karena  $g'(x) = x-3$  dan  $\gamma = 1/2$ ,

$$x - \gamma g'(x) = x - \frac{1}{2}(x-3) = \frac{x+3}{2}.$$

Langkah mundur adalah operator proksimal  $\text{prox}_{(1/2)|\cdot|} = S_{1/2}$ , sehingga  $T(x) = S_{1/2}((x+3)/2)$ .

**Petunjuk tahap 1 (ps02.prompt.0004).** Substitusikan berturut-turut  $x_0$  dan  $x_1$  ke  $T$ .

**Petunjuk tahap 2 (ps02.prompt.0004).** Untuk peminimum, selesaikan  $0 \in x - 3 + \partial|x|$ .

**Jawaban ringkas (ps02.prompt.0004).**  $x_1 = 1$ ,  $x_2 = 3/2$ , dan peminimum uniknya  $x^* = 2$ .

**Solusi lengkap (ps02.prompt.0004).** Kita memperoleh

$$x_1 = S_{1/2}(3/2) = 1, \quad x_2 = S_{1/2}(2) = \frac{3}{2}.$$

Syarat optimalitas adalah  $0 \in x - 3 + \partial|x|$ . Pada cabang  $x > 0$ , syarat itu menjadi  $0 = x - 2$ , sehingga  $x = 2$ , yang konsisten dengan cabang. Cabang  $x < 0$  tidak menghasilkan titik yang konsisten, dan di nol interval  $-3 + [-1, 1]$  tidak memuat nol. Konveksitas kuat suku kuadratik menjamin keunikan, jadi  $x^* = 2$ .

**Latihan 15.18** (Lemma penurunan). Misalkan  $f: \mathbb{R}^n \rightarrow \mathbb{R}$  terdiferensialkan dan gradiennya  $L$ -Lipschitz.

- (i) Buktikan

$$f(y) \leq f(x) + \nabla f(x)^\top (y - x) + \frac{L}{2} \|y - x\|_2^2.$$

- (ii) Untuk  $f(x) = \frac{L}{2}x^2$  pada  $\mathbb{R}$ , terapkan langkah gradien  $x^+ = x - L^{-1}f'(x)$  dan periksa ketajaman batas penurunan yang dihasilkan.

**Petunjuk tahap 1 (ps02.prompt.0005).** Integralkan gradien sepanjang ruas dari  $x$  ke  $y$ .

**Petunjuk tahap 2 (ps02.prompt.0005).** Dengan  $d = y - x$ , batasi  $[\nabla f(x + td) - \nabla f(x)]^\top d$  oleh  $Lt\|d\|_2^2$ .

**Jawaban ringkas (ps02.prompt.0005).** Batas mengikuti teorema dasar kalkulus pada  $t \mapsto f(x + t(y - x))$  dan integral  $\int_0^1 Lt \, dt = L/2$ .

**Solusi lengkap (ps02.prompt.0005).** Tetapkan  $d = y - x$ . Teorema dasar kalkulus memberi

$$f(y) - f(x) = \int_0^1 \nabla f(x + td)^\top d \, dt = \nabla f(x)^\top d + \int_0^1 [\nabla f(x + td) - \nabla f(x)]^\top d \, dt.$$

Cauchy–Schwarz dan sifat Lipschitz menghasilkan

$$[\nabla f(x + td) - \nabla f(x)]^\top d \leq \|\nabla f(x + td) - \nabla f(x)\|_2 \|d\|_2 \leq Lt\|d\|_2^2.$$

Mengintegralkan batas terakhir dari nol sampai satu membuktikan klaim. *Rubrik bukti: 15.9.2.*

**Petunjuk tahap 1 (ps02.prompt.0006).** Hitung  $f'(x) = Lx$ .

**Petunjuk tahap 2 (ps02.prompt.0006).** Bandingkan hasil dengan  $f(x^+) \leq f(x) - (2L)^{-1}|f'(x)|^2$ .

**Jawaban ringkas (ps02.prompt.0006).**  $x^+ = 0$  dan  $f(x^+) = f(x) - (2L)^{-1}|f'(x)|^2 = 0$ ; batasnya mencapai kesamaan.

**Solusi lengkap (ps02.prompt.0006).** Karena  $f'(x) = Lx$ , langkah berukuran  $1/L$  memberi  $x^+ = x - x = 0$ . Lemma penurunan dengan  $y = x - L^{-1}f'(x)$  memberi

$$f(x^+) \leq f(x) - \frac{1}{2L}|f'(x)|^2.$$

Untuk kuadratik ini, ruas kanan sama dengan  $\frac{L}{2}x^2 - \frac{1}{2L}L^2x^2 = 0 = f(0) = f(x^+)$ , sehingga batas tersebut tajam untuk setiap  $x$ .

**Latihan 15.19** (Pemisahan maju–mundur sebagai kontraksi). Pada  $\mathbb{R}$ , ambil  $A = \partial|\cdot|$ ,  $B(x) = x - 2$ , dan  $\gamma = 1/2$ .

- (i) Hitung  $T = J_{\gamma A}(I - \gamma B)$  secara eksplisit.
- (ii) Tentukan titik tetap  $T$  dan hubungkan dengan peminimum  $|x| + \frac{1}{2}(x - 2)^2$ .
- (iii) Buktikan bahwa  $T$  adalah kontraksi dengan faktor paling besar  $1/2$  dan simpulkan keunikan titik tetapnya.

**Petunjuk tahap 1 (ps02.prompt.0007).**  $J_{\gamma \partial|\cdot|} = \text{prox}_{\gamma|\cdot|}$ .

**Petunjuk tahap 2 (ps02.prompt.0007).** Hitung  $x - \frac{1}{2}(x - 2) = x/2 + 1$ .

**Jawaban ringkas (ps02.prompt.0007).**  $T(x) = S_{1/2}(x/2 + 1)$ .

**Solusi lengkap (ps02.prompt.0007).** Definisi resoven dan identitas resoven subdiferensial memberi

$$T(x) = \text{prox}_{(1/2)|\cdot|} \left( x - \frac{1}{2}(x - 2) \right) = S_{1/2} \left( \frac{x}{2} + 1 \right).$$

**Petunjuk tahap 1 (ps02.prompt.0008).** Coba  $x = 1$  dalam rumus eksplisit  $T$ .

**Petunjuk tahap 2 (ps02.prompt.0008).** Bandingkan persamaan titik tetap dengan  $0 \in x - 2 + \partial|x|$ .

**Jawaban ringkas (ps02.prompt.0008).** Titik tetapnya  $x^* = 1$ , yang juga merupakan peminimum unik objektif.

**Solusi lengkap (ps02.prompt.0008).** Rumus eksplisit memberi  $T(1) = S_{1/2}(3/2) = 1$ . Selain itu,  $x = T(x)$  ekuivalen dengan  $x = J_{\gamma A}(x - \gamma Bx)$ , lalu dengan  $0 \in Ax + Bx = \partial|x| + x - 2$ . Ini persis syarat optimalitas untuk  $|x| + \frac{1}{2}(x - 2)^2$ . Pada  $x = 1 > 0$ , syaratnya  $0 = 1 + 1 - 2$ . Suku kuadratik konveks kuat, jadi peminimum tersebut unik.

**Petunjuk tahap 1 (ps02.prompt.0009).** Operator proksimal bersifat non-ekspansif.

**Petunjuk tahap 2 (ps02.prompt.0009).** Bandingkan argumen ambang lunak untuk  $x$  dan  $y$ .

**Jawaban ringkas (ps02.prompt.0009).**  $|T(x) - T(y)| \leq \frac{1}{2}|x - y|$ ; karena itu titik tetapnya tunggal.

**Solusi lengkap (ps02.prompt.0009).** Non-ekspansivitas  $S_{1/2}$  menghasilkan

$$|T(x) - T(y)| \leq \left| \left( \frac{x}{2} + 1 \right) - \left( \frac{y}{2} + 1 \right) \right| = \frac{1}{2}|x - y|.$$

Jadi  $T$  adalah kontraksi. Jika  $x$  dan  $y$  keduanya titik tetap, maka  $|x - y| = |T(x) - T(y)| \leq |x - y|/2$ , yang memaksa  $x = y$ . *Rubrik bukti: 15.9.5.*

**Latihan 15.20** (Laju titik proksimal untuk operator linear). Ambil  $A(x) = mx$  dengan  $m > 0$  dan parameter  $\gamma > 0$ .

(i) Hitung resolven  $J_{\gamma A} = (I + \gamma A)^{-1}$ .

(ii) Untuk iterasi titik proksimal  $x_{k+1} = J_{\gamma A}(x_k)$ , turunkan rumus eksak  $x_k$  dan lajunya menuju nol.

**Petunjuk tahap 1 (ps02.prompt.0010).** Tetapkan  $z = J_{\gamma A}(x)$ .

**Petunjuk tahap 2 (ps02.prompt.0010).** Selesaikan  $x = z + \gamma m z$  terhadap  $z$ .

**Jawaban ringkas (ps02.prompt.0010).**  $J_{\gamma A}(x) = x/(1 + \gamma m)$ .

**Solusi lengkap (ps02.prompt.0010).** Definisi resolven menyatakan  $z = J_{\gamma A}(x)$  jika dan hanya jika  $x \in z + \gamma A(z)$ . Karena  $A(z) = mz$ , ini menjadi  $x = (1 + \gamma m)z$ . Faktor  $1 + \gamma m$  positif, sehingga  $z = x/(1 + \gamma m)$ . *Rubrik bukti: 15.9.5.*

**Petunjuk tahap 1 (ps02.prompt.0011).** Substitusikan rumus resolven ke relasi iterasi.

**Petunjuk tahap 2 (ps02.prompt.0011).** Ulangi perkalian oleh konstanta  $(1 + \gamma m)^{-1}$ .

**Jawaban ringkas (ps02.prompt.0011).**  $x_k = (1 + \gamma m)^{-k} x_0$  dan  $|x_k| = (1 + \gamma m)^{-k} |x_0| \rightarrow 0$  secara linear.

**Solusi lengkap (ps02.prompt.0011).** Rumus resolven memberi  $x_{k+1} = (1 + \gamma m)^{-1} x_k$ . Induksi terhadap  $k$  menghasilkan  $x_k = (1 + \gamma m)^{-k} x_0$ . Karena  $m, \gamma > 0$ , faktor  $q = (1 + \gamma m)^{-1}$  berada dalam  $(0, 1)$ . Maka  $|x_k| = q^k |x_0|$  dan konvergensinya menuju nol bersifat linear dengan faktor eksak  $q$ .

## 15.5 Set soal III: dualitas dan kondisi KKT

Lima masalah berikut melatih pembentukan fungsi dual, kondisi Karush–Kuhn–Tucker (KKT), kondisi Slater, dan sensitivitas nilai optimal.

**Latihan 15.21** (Kendala persamaan skalar). Pertimbangkan masalah

$$\min_{x \in \mathbb{R}} \frac{1}{2} x^2 \quad \text{dengan kendala} \quad x = 1.$$

(i) Turunkan fungsi dual, lalu tentukan pengali dan nilai dual optimal.

(ii) Verifikasi semua kondisi KKT dan kesenjangan dualitas nol.

**Petunjuk tahap 1 (ps03.prompt.0001).** Gunakan Lagrangian  $L(x, \lambda) = \frac{1}{2} x^2 + \lambda(x - 1)$ .

**Petunjuk tahap 2 (ps03.prompt.0001).** Infimum terhadap  $x$  tercapai di  $x = -\lambda$ .

**Jawaban ringkas (ps03.prompt.0001).**  $g(\lambda) = -\frac{1}{2} \lambda^2 - \lambda$ ,  $\lambda^* = -1$ , dan  $d^* = 1/2$ .

**Solusi lengkap (ps03.prompt.0001).** Meminimumkan Lagrangian terhadap  $x$  memberi syarat  $x + \lambda = 0$ , jadi  $x = -\lambda$ . Karena Lagrangian konveks kuat terhadap  $x$ , titik ini memberi infimum dan

$$g(\lambda) = L(-\lambda, \lambda) = -\frac{1}{2} \lambda^2 - \lambda.$$

Masalah dual memaksimalkan kuadrat cekung ini pada  $\lambda \in \mathbb{R}$ . Persamaan  $g'(\lambda) = -\lambda - 1 = 0$  memberi  $\lambda^* = -1$  dan  $g(-1) = 1/2$ . *Rubrik bukti: 15.9.6.*

**Petunjuk tahap 1 (ps03.prompt.0002).** KKT untuk kendala persamaan terdiri atas kelayakan primal dan stasioneritas.

**Petunjuk tahap 2 (ps03.prompt.0002).** Substitusikan  $x^* = 1$  dan  $\lambda^* = -1$ .

**Jawaban ringkas (ps03.prompt.0002).**  $x^* = 1$  layak dan  $x^* + \lambda^* = 0$ ; nilai primal dan dual sama-sama  $1/2$ .

**Solusi lengkap (ps03.prompt.0002).** Kelayakan primal memberi  $x^* - 1 = 0$ . Stasioneritas memberi  $\nabla_x L(x^*, \lambda^*) = x^* + \lambda^* = 1 - 1 = 0$ . Tidak ada syarat tanda atau kelengkapan komplementer untuk pengali persamaan. Nilai primal adalah  $p^* = \frac{1}{2}(1)^2 = 1/2$ , sedangkan hasil dual pada subbutir sebelumnya memberi  $d^* = 1/2$ . Jadi  $p^* - d^* = 0$ . *Rubrik bukti: 15.9.6.*

**Latihan 15.22** (Kendala ketaksamaan aktif). Pertimbangkan

$$\min_{x \in \mathbb{R}} (x - 2)^2 \quad \text{dengan kendala} \quad x \leq 1.$$

(i) Gunakan kondisi KKT untuk menentukan solusi primal dan pengali optimal.

(ii) Verifikasi kondisi Slater, turunkan fungsi dual, dan periksa nilainya di pengali optimal.

**Petunjuk tahap 1 (ps03.prompt.0003).** Tuliskan kendala sebagai  $x - 1 \leq 0$  dengan pengali  $\lambda \geq 0$ .

**Petunjuk tahap 2 (ps03.prompt.0003).** Gunakan stasioneritas  $2(x - 2) + \lambda = 0$  dan kelengkapan komplementer  $\lambda(x - 1) = 0$ .

**Jawaban ringkas (ps03.prompt.0003).**  $x^* = 1$  dan  $\lambda^* = 2$ .

**Solusi lengkap (ps03.prompt.0003).** Jika kendala tidak aktif, kelengkapan komplementer memberi  $\lambda = 0$  dan stasioneritas memberi  $x = 2$ , yang tidak layak. Maka kendala aktif:  $x^* = 1$ . Stasioneritas kemudian memberi  $2(1 - 2) + \lambda^* = 0$ , sehingga  $\lambda^* = 2 \geq 0$ . Kelayakan primal, kelayakan dual, stasioneritas, dan kelengkapan komplementer semuanya terpenuhi. Karena masalah konveks, titik KKT ini optimal. *Rubrik bukti: 15.9.6.*

**Petunjuk tahap 1 (ps03.prompt.0004).**  $x = 0$  adalah kandidat titik Slater.

**Petunjuk tahap 2 (ps03.prompt.0004).** Dalam  $L(x, \lambda) = (x - 2)^2 + \lambda(x - 1)$ , infimum terhadap  $x$  tercapai di  $x = 2 - \lambda/2$ .

**Jawaban ringkas (ps03.prompt.0004).** Slater berlaku;  $g(\lambda) = \lambda - \lambda^2/4$  untuk  $\lambda \geq 0$ , dan  $g(2) = 1 = p^*$ .

**Solusi lengkap (ps03.prompt.0004).** Titik  $x = 0$  memenuhi  $x - 1 = -1 < 0$ , jadi kondisi Slater berlaku. Untuk  $\lambda \geq 0$ , peminimum Lagrangian terhadap  $x$  adalah  $x(\lambda) = 2 - \lambda/2$ . Substitusi memberi

$$g(\lambda) = \left(-\frac{\lambda}{2}\right)^2 + \lambda\left(1 - \frac{\lambda}{2}\right) = \lambda - \frac{\lambda^2}{4}.$$

Kuadratik cekung ini maksimum di  $\lambda = 2$  dengan nilai 1. Nilai primal di  $x^* = 1$  juga  $(1 - 2)^2 = 1$ , sesuai dualitas kuat yang dijamin Slater. *Rubrik bukti: 15.9.6.*

**Latihan 15.23** (Proyeksi norma minimum pada hiperbidang). Ambil  $a \in \mathbb{R}^n \setminus \{0\}$  dan  $b \in \mathbb{R}$ , lalu pertimbangkan

$$\min_x \frac{1}{2} \|x\|_2^2 \quad \text{dengan kendala} \quad a^\top x = b.$$

(i) Selesaikan sistem KKT untuk memperoleh  $x^*$  dan  $\lambda^*$ .

(ii) Turunkan fungsi dual dan verifikasi bahwa nilai primal dan dual optimal sama.

(iii) Buktikan bahwa solusi primal itu unik dan bahwa kondisi KKT cukup untuk optimalitas pada masalah ini.

**Petunjuk tahap 1 (ps03.prompt.0005).** Gunakan  $L(x, \lambda) = \frac{1}{2} \|x\|_2^2 + \lambda(a^\top x - b)$ .

**Petunjuk tahap 2 (ps03.prompt.0005).** Stasioneritas memberi  $x = -\lambda a$ ; substitusikan ke kendala.

**Jawaban ringkas (ps03.prompt.0005).**

$$x^* = \frac{b}{\|a\|_2^2} a, \quad \lambda^* = -\frac{b}{\|a\|_2^2}.$$

**Solusi lengkap (ps03.prompt.0005).** Stasioneritas adalah  $x + \lambda a = 0$ , sehingga  $x = -\lambda a$ . Kelayakan persamaan lalu memberi  $-\lambda \|a\|_2^2 = b$ . Karena  $a \neq 0$ , penyebutnya positif dan

$$\lambda^* = -\frac{b}{\|a\|_2^2}, \quad x^* = -\lambda^* a = \frac{b}{\|a\|_2^2} a.$$

*Rubrik bukti: 15.9.6.*

**Petunjuk tahap 1 (ps03.prompt.0006).** Ambil infimum Lagrangian di  $x = -\lambda a$ .

**Petunjuk tahap 2 (ps03.prompt.0006).** Maksimalkan kuadrat cekung yang diperoleh terhadap  $\lambda \in \mathbb{R}$ .

**Jawaban ringkas (ps03.prompt.0006).**  $g(\lambda) = -\frac{1}{2}\lambda^2\|a\|_2^2 - \lambda b$  dan  $p^* = d^* = b^2/(2\|a\|_2^2)$ .

**Solusi lengkap (ps03.prompt.0006).** Substitusi  $x = -\lambda a$  ke Lagrangian memberi

$$g(\lambda) = -\frac{1}{2}\lambda^2\|a\|_2^2 - \lambda b.$$

Turunannya nol pada  $\lambda^* = -b/\|a\|_2^2$ , dan substitusi memberi  $d^* = b^2/(2\|a\|_2^2)$ . Di sisi primal,

$$\frac{1}{2}\|x^*\|_2^2 = \frac{1}{2} \frac{b^2\|a\|_2^2}{\|a\|_2^4} = \frac{b^2}{2\|a\|_2^2} = d^*.$$

**Petunjuk tahap 1 (ps03.prompt.0007).** Gunakan konveksitas kuat objektif untuk keunikan.

**Petunjuk tahap 2 (ps03.prompt.0007).** Gunakan ketaksamaan konveksitas orde pertama pada titik KKT dan hilangkan suku linear dengan kelayakan persamaan.

**Jawaban ringkas (ps03.prompt.0007).** Objektif konveks kuat pada himpunan layak konveks, sehingga pemimum tunggal; stasioneritas dan kelayakan KKT menjamin optimalitas global.

**Solusi lengkap (ps03.prompt.0007).** Fungsi  $f(x) = \frac{1}{2}\|x\|_2^2$  bersifat konveks kuat dengan parameter satu. Pembatasannya pada hiperbidang afin tetap konveks kuat, jadi tidak mungkin mempunyai dua pemimum berbeda. Untuk kecukupan, ambil pasangan KKT  $(x^*, \lambda^*)$ . Stasioneritas memberi  $\nabla f(x^*) = -\lambda^* a$ . Untuk setiap  $x$  layak, konveksitas memberi

$$f(x) \geq f(x^*) + \nabla f(x^*)^\top (x - x^*) = f(x^*) - \lambda^* a^\top (x - x^*) = f(x^*),$$

karena  $a^\top x = a^\top x^* = b$ . Maka titik KKT optimal global, dan konveksitas kuat membuatnya unik. *Rubrik bukti: 15.9.6.*

**Latihan 15.24** (Sensitivitas ruas kanan). Definisikan fungsi nilai

$$p(u) = \min_x \left\{ \frac{1}{2}x^2 : x = u \right\}.$$

- Hitung  $p(u)$ , pengali optimal  $\lambda^*(u)$  untuk kendala  $x - u = 0$ , dan hubungan antara  $p'(u)$  dan pengali itu.
- Untuk perturbasi  $\delta$ , turunkan ekspansi eksak  $p(u + \delta)$  dan identifikasi suku sensitivitas orde pertama serta galat orde keduanya.

**Petunjuk tahap 1 (ps03.prompt.0008).** Kendala langsung memaksa  $x = u$ .

**Petunjuk tahap 2 (ps03.prompt.0008).** Stasioneritas Lagrangian  $\frac{1}{2}x^2 + \lambda(x - u)$  adalah  $x + \lambda = 0$ .

**Jawaban ringkas (ps03.prompt.0008).**  $p(u) = u^2/2$ ,  $\lambda^*(u) = -u$ , dan  $p'(u) = u = -\lambda^*(u)$ .

**Solusi lengkap (ps03.prompt.0008).** Satu-satunya titik layak adalah  $x^*(u) = u$ , sehingga  $p(u) = u^2/2$ . Stasioneritas memberi  $x^*(u) + \lambda^*(u) = 0$ , jadi  $\lambda^*(u) = -u$ . Mendiferensialkan fungsi nilai menghasilkan  $p'(u) = u = -\lambda^*(u)$ . Tanda minus muncul karena kendala ditulis sebagai  $x - u = 0$ . *Rubrik bukti: 15.9.7.*

**Petunjuk tahap 1 (ps03.prompt.0009).** Kembangkan  $(u + \delta)^2/2$ .

**Petunjuk tahap 2 (ps03.prompt.0009).** Ganti  $u$  pada suku linear dengan  $-\lambda^*(u)$ .

**Jawaban ringkas (ps03.prompt.0009).**  $p(u + \delta) = p(u) - \lambda^*(u)\delta + \delta^2/2$ .

**Solusi lengkap (ps03.prompt.0009).** Perhitungan eksak memberi

$$p(u + \delta) = \frac{1}{2}(u + \delta)^2 = \frac{1}{2}u^2 + u\delta + \frac{1}{2}\delta^2 = p(u) - \lambda^*(u)\delta + \frac{1}{2}\delta^2.$$

Jadi  $-\lambda^*(u)\delta$  adalah perubahan linear yang diprediksi pengali, sedangkan  $\delta^2/2$  adalah galat orde kedua yang eksak. *Rubrik bukti: 15.9.7.*

**Latihan 15.25** (Proyeksi pada bola Euclid melalui KKT). Ambil  $c \in \mathbb{R}^n$  dan  $r$  dengan  $0 < r < \|c\|_2$ . Pertimbangkan

$$\min_x \frac{1}{2} \|x - c\|_2^2 \quad \text{dengan kendala} \quad \|x\|_2 \leq r.$$

Gunakan representasi mulus  $g(x) = \frac{1}{2} (\|x\|_2^2 - r^2) \leq 0$ .

- (i) Selesaikan kondisi KKT untuk menentukan  $x^*$  dan pengali  $\mu^*$ .
- (ii) Verifikasi kondisi Slater dan buktikan bahwa pasangan KKT tersebut merupakan solusi primal-dual global yang unik pada sisi primal.

**Petunjuk tahap 1 (ps03.prompt.0010).** Stasioneritas adalah  $x - c + \mu x = 0$ .

**Petunjuk tahap 2 (ps03.prompt.0010).** Karena  $c$  berada di luar bola, kendala optimal aktif; gunakan  $x = c/(1 + \mu)$  dan  $\|x\|_2 = r$ .

**Jawaban ringkas (ps03.prompt.0010).**

$$x^* = r \frac{c}{\|c\|_2}, \quad \mu^* = \frac{\|c\|_2}{r} - 1 > 0.$$

**Solusi lengkap (ps03.prompt.0010).** Lagrangiannya  $L(x, \mu) = \frac{1}{2} \|x - c\|_2^2 + \frac{\mu}{2} (\|x\|_2^2 - r^2)$  dengan  $\mu \geq 0$ . Stasioneritas memberi  $(1 + \mu)x = c$ . Jika  $\mu = 0$ , maka  $x = c$ , yang tidak layak karena  $\|c\|_2 > r$ . Jadi  $\mu^* > 0$ , dan kelengkapan komplementer memaksa  $\|x^*\|_2 = r$ . Dari  $x^* = c/(1 + \mu^*)$  diperoleh  $1 + \mu^* = \|c\|_2/r$ , sehingga rumus yang dinyatakan berlaku. *Rubrik bukti: 15.9.6.*

**Petunjuk tahap 1 (ps03.prompt.0011).**  $x = 0$  memenuhi kendala secara ketat.

**Petunjuk tahap 2 (ps03.prompt.0011).** Gabungkan Slater, konveksitas masalah, dan konveksitas kuat objektif.

**Jawaban ringkas (ps03.prompt.0011).** Slater berlaku di  $x = 0$ ; KKT perlu dan cukup, dualitas kuat berlaku, dan  $x^*$  unik karena objektif konveks kuat.

**Solusi lengkap (ps03.prompt.0011).** Karena  $r > 0$ , titik  $x = 0$  memenuhi  $g(0) = -r^2/2 < 0$ , jadi kondisi Slater berlaku. Objektif dan fungsi kendala konveks serta terdiferensialkan; karena itu, di bawah Slater, kondisi KKT bersifat perlu dan cukup dan tidak ada kesenjangan dualitas. Pasangan pada subbutir sebelumnya memenuhi kelayakan primal,  $\mu^* \geq 0$ , stasioneritas, dan kelengkapan komplementer, sehingga optimal global. Objektif  $\frac{1}{2} \|x - c\|_2^2$  bersifat konveks kuat, maka peminimum primal pada himpunan bola yang konveks adalah unik. *Rubrik bukti: 15.9.6.*

## 15.6 Set soal IV: metode stokastik

**Latihan 15.26** (Pencuplikan tak seragam dan koreksi kepentingan). Misalkan

$$F(x) = \frac{1}{N} \sum_{i=1}^N f_i(x), \quad g_i = \nabla f_i(x),$$

dan, bersyarat pada informasi masa lalu  $\mathcal{F}$ , indeks  $I$  dipilih dengan peluang  $p_i > 0$ ,  $\sum_i p_i = 1$ . Peluang dan titik  $x$  boleh  $\mathcal{F}$ -terukur.

- (i) Hitung bias penduga naif  $H = g_I$  terhadap  $\nabla F(x)$ .
- (ii) Tunjukkan bahwa  $G = g_I/(Np_I)$  tidak bias secara bersyarat.
- (iii) Turunkan rumus eksak untuk  $\mathbb{E}[\|G - \nabla F(x)\|^2 \mid \mathcal{F}]$ .

**Petunjuk bertahap. Tahap 1.** Tulis ekspektasi bersyarat sebagai jumlah atas semua nilai yang mungkin bagi  $I$ . **Tahap 2.** Setelah memperoleh ketakbiasan, gunakan identitas  $\mathbb{E}\|G - m\|^2 = \mathbb{E}\|G\|^2 - \|m\|^2$  dengan  $m = \mathbb{E}[G \mid \mathcal{F}]$ .

**Jawaban singkat.** Penduga naif mempunyai bias  $\sum_i p_i g_i - N^{-1} \sum_i g_i$ . Sementara itu,

$$\mathbb{E}[G \mid \mathcal{F}] = \nabla F(x), \quad \mathbb{E}[\|G - \nabla F(x)\|^2 \mid \mathcal{F}] = \frac{1}{N^2} \sum_{i=1}^N \frac{\|g_i\|^2}{p_i} - \|\nabla F(x)\|^2.$$

**Solusi lengkap.** Karena  $p_i$  dan  $g_i$  diketahui setelah mengondisikan pada  $\mathcal{F}$ ,

$$\mathbb{E}[H \mid \mathcal{F}] = \sum_i p_i g_i.$$

Jadi selisihnya dari gradien penuh adalah  $\sum_i (p_i - 1/N) g_i$ , yang umumnya tidak nol. Untuk penduga terkoreksi,

$$\mathbb{E}[G \mid \mathcal{F}] = \sum_i p_i \frac{g_i}{N p_i} = \frac{1}{N} \sum_i g_i = \nabla F(x).$$

Selanjutnya,

$$\mathbb{E}[\|G\|^2 \mid \mathcal{F}] = \sum_i p_i \frac{\|g_i\|^2}{N^2 p_i^2} = \frac{1}{N^2} \sum_i \frac{\|g_i\|^2}{p_i}.$$

Mengurangkan kuadrat norma mean bersyarat memberi rumus varians yang dinyatakan pada jawaban singkat. Positivitas setiap  $p_i$  penting agar koreksi terdefinisi dan tidak menghilangkan komponen mana pun.

**Latihan 15.27** (Ketaksamaan tiga titik untuk langkah Bregman komposit). Pada himpunan konveks tertutup  $C$ , misalkan  $h$  terdiferensialkan dan konveks,  $r$  konveks proper semikontinu-bawah, dan

$$x^+ \in \arg \min_{x \in C} \{ \eta \langle g, x \rangle + \eta r(x) + D_h(x, x_k) \}, \quad \eta > 0.$$

Buktikan bahwa untuk setiap  $u \in C$ ,

$$\eta (\langle g, x^+ - u \rangle + r(x^+) - r(u)) \leq D_h(u, x_k) - D_h(u, x^+) - D_h(x^+, x_k).$$

Nyatakan dengan jelas kondisi optimalitas yang Anda gunakan.

**Petunjuk bertahap.** **Tahap 1.** Pilih  $s^+ \in \partial r(x^+)$  dan  $n^+ \in N_C(x^+)$  dari inklusi optimalitas. **Tahap 2.** Gunakan ketaksamaan subgradien dan identitas tiga titik untuk divergensi Bregman.

**Jawaban singkat.** Inklusi

$$0 \in \eta g + \eta \partial r(x^+) + \nabla h(x^+) - \nabla h(x_k) + N_C(x^+)$$

bersama dengan

$$\langle \nabla h(x^+) - \nabla h(x_k), u - x^+ \rangle = D_h(u, x_k) - D_h(u, x^+) - D_h(x^+, x_k)$$

memberikan hasilnya.

**Solusi lengkap.** Ambil  $s^+ \in \partial r(x^+)$  dan  $n^+ \in N_C(x^+)$  sehingga

$$0 = \eta g + \eta s^+ + \nabla h(x^+) - \nabla h(x_k) + n^+.$$

Karena  $u \in C$ , definisi kerucut normal memberi  $\langle n^+, u - x^+ \rangle \leq 0$ . Mengalikan persamaan optimalitas dengan  $x^+ - u$  menghasilkan

$$\eta \langle g, x^+ - u \rangle + \eta \langle s^+, x^+ - u \rangle \leq \langle \nabla h(x^+) - \nabla h(x_k), u - x^+ \rangle.$$

Ketaksamaan subgradien menyatakan  $\langle s^+, x^+ - u \rangle \geq r(x^+) - r(u)$ . Ruas kanan sama dengan selisih tiga divergensi Bregman pada jawaban singkat. Substitusi kedua fakta itu menyelesaikan bukti.

**Latihan 15.28** (Varians terbatas bukan momen kedua seragam). Pertimbangkan  $f(x) = x^2/2$  dan orakel stokastik  $G(x, \xi) = x + \xi$ , dengan  $\mathbb{E}\xi = 0$  dan  $\mathbb{E}\xi^2 = \sigma^2 < \infty$ .

- (i) Verifikasi ketakbiasan dan varians bersyarat yang seragam.
- (ii) Tunjukkan bahwa tidak ada batas seragam untuk  $\mathbb{E}|G(x, \xi)|^2$  ketika  $x$  menjelajahi  $\mathbb{R}$ .
- (iii) Buktikan arah sebaliknya: jika  $\mathbb{E}\|G(x, \xi)\|^2 \leq M^2$  dan  $G$  tidak bias, maka  $\|\nabla f(x)\| \leq M$ .

**Petunjuk bertahap.** **Tahap 1.** Pisahkan  $G - \nabla f$  dari  $G$  sendiri. **Tahap 2.** Untuk arah sebaliknya, terapkan ketaksamaan Jensen pada fungsi kuadrat norma.

**Jawaban singkat.**  $G$  tidak bias dan  $\mathbb{E}|G - \nabla f(x)|^2 = \sigma^2$ , tetapi  $\mathbb{E}|G|^2 = x^2 + \sigma^2$ , sehingga tak terbatas seragam. Sebaliknya,  $\|\nabla f(x)\|^2 = \|\mathbb{E}G\|^2 \leq \mathbb{E}\|G\|^2 \leq M^2$ .

**Solusi lengkap.** Gradien eksak ialah  $\nabla f(x) = x$ . Karena mean  $\xi$  nol,  $\mathbb{E}[G(x, \xi)] = x$ , sedangkan  $G(x, \xi) - \nabla f(x) = \xi$ . Jadi varians galat orakel selalu  $\sigma^2$ , tidak bergantung pada  $x$ . Namun,

$$\mathbb{E}|x + \xi|^2 = x^2 + 2x\mathbb{E}\xi + \mathbb{E}\xi^2 = x^2 + \sigma^2,$$

yang menuju tak hingga saat  $|x| \rightarrow \infty$ . Dengan demikian, asumsi varians terbatas tidak boleh diam-diam diganti dengan asumsi momen kedua seragam. Untuk arah terakhir, ketakbiasan dan konveksitas kuadrat norma memberi

$$\|\nabla f(x)\|^2 = \|\mathbb{E}G(x, \xi)\|^2 \leq \mathbb{E}\|G(x, \xi)\|^2 \leq M^2.$$

**Latihan 15.29** (Bias bersyarat pada pengacakan ulang). Dalam satu epok, ambil permutasi seragam  $\pi$  dari  $\{1, \dots, N\}$ . Setelah indeks  $\pi_1, \dots, \pi_t$  terungkap, misalkan  $R_t$  adalah himpunan indeks yang tersisa dan  $\mathcal{F}_t$  memuat riwayat tersebut.

- (i) Untuk titik beku  $x$ , hitung  $\mathbb{E}[\nabla f_{\pi_{t+1}}(x) \mid \mathcal{F}_t]$ .
- (ii) Tunjukkan bahwa jumlah gradien selama satu epok pada titik beku tepat sama dengan  $N\nabla F(x)$ .
- (iii) Jelaskan mengapa bukti SGD yang mengandalkan selisih martingal tidak dapat langsung dipakai ketika titik iterasi berubah di dalam epok.

**Petunjuk bertahap.** **Tahap 1.** Bersyarat pada riwayat, indeks berikutnya seragam hanya pada  $R_t$ , bukan pada seluruh himpunan indeks. **Tahap 2.** Bedakan identitas kombinatorial pada satu titik  $x$  dari jumlah  $\nabla f_{\pi_t}(x_t)$  pada titik-titik yang berlainan.

**Jawaban singkat.**

$$\mathbb{E}[\nabla f_{\pi_{t+1}}(x) \mid \mathcal{F}_t] = \frac{1}{|R_t|} \sum_{i \in R_t} \nabla f_i(x), \quad \sum_{t=1}^N \nabla f_{\pi_t}(x) = N\nabla F(x).$$

Mean bersyarat pertama umumnya bukan gradien penuh; bila  $x_t$  berubah, identitas jumlah pada titik beku juga tidak berlaku.

**Solusi lengkap.** Setelah  $t$  indeks terungkap, setiap elemen  $R_t$  mempunyai peluang  $1/|R_t|$  untuk muncul berikutnya. Karena itu mean bersyarat adalah rata-rata gradien komponen yang tersisa. Rata-rata ini hanya sama dengan gradien penuh dalam keadaan khusus. Di sisi lain, sebuah permutasi memuat setiap indeks tepat sekali, sehingga untuk satu titik yang sama,

$$\sum_{t=1}^N \nabla f_{\pi_t}(x) = \sum_{i=1}^N \nabla f_i(x) = N\nabla F(x).$$

Pada algoritme sebenarnya, suku ke- $t$  dinilai di  $x_t$ , sehingga jumlahnya adalah  $\sum_t \nabla f_{\pi_t}(x_t)$  dan tidak lagi dapat diganti oleh jumlah gradien pada satu titik. Selain itu, galat gradien terhadap gradien penuh umumnya mempunyai mean bersyarat tak nol. Maka argumen selisih martingal SGD dengan pengambilan sampel independen memerlukan analisis baru, bukan sekadar penggantian notasi.

**Latihan 15.30** (Lantai galat akibat derau persisten). Misalkan barisan tak negatif memenuhi

$$a_{k+1} \leq (1 - \mu\eta)a_k + \eta^2\sigma^2, \quad 0 < \mu\eta < 1.$$

Turunkan batas tertutup untuk  $a_k$ , hitung limit superiornya, dan jelaskan apa yang harus diubah agar jaminan konvergensi eksak tetap masuk akal ketika  $\sigma > 0$ .

**Petunjuk bertahap.** **Tahap 1.** Tetapkan  $q = 1 - \mu\eta$  dan buka rekursi sebagai deret geometrik. **Tahap 2.** Bandingkan faktor kontraksi  $q^k$  dengan suku paksa yang tidak lenyap.

**Jawaban singkat.** Dengan  $q = 1 - \mu\eta$ ,

$$a_k \leq q^k a_0 + \frac{\eta\sigma^2}{\mu}(1 - q^k), \quad \limsup_{k \rightarrow \infty} a_k \leq \frac{\eta\sigma^2}{\mu}.$$

Langkah tetap dengan derau persisten hanya menjamin lingkungan solusi; langkah menurun atau reduksi varians diperlukan untuk meniadakan rantai ini.

**Solusi lengkap.** Iterasi rekursi memberikan

$$a_k \leq q^k a_0 + \eta^2 \sigma^2 \sum_{j=0}^{k-1} q^j = q^k a_0 + \eta^2 \sigma^2 \frac{1 - q^k}{1 - q}.$$

Karena  $1 - q = \mu\eta$ , suku kedua sama dengan  $\eta\sigma^2(1 - q^k)/\mu$ . Hipotesis memastikan  $0 < q < 1$ , sehingga  $q^k \rightarrow 0$  dan batas limit superior mengikuti. Bila  $\eta$  tetap dan  $\sigma > 0$ , suku paksa tidak hilang; rekursi itu sendiri tidak dapat membuktikan  $a_k \rightarrow 0$ . Jadwal langkah yang menuju nol dengan syarat penjumlahan yang sesuai, atau penduga dengan varians yang ikut menuju nol, mengubah rekursi sehingga rantai galat dapat lenyap.

## 15.7 Set soal V: operator monoton dan metode pemisahan

**Latihan 15.31** (Keberadaan, ketunggalan, dan titik tetap maju-mundur). Pada ruang Euklides berdimensi hingga, misalkan  $f$  proper, semikontinu-bawah, dan  $\mu$ -konveks kuat dengan  $\mu > 0$ . Misalkan  $g$  konveks dan terdiferensialkan pada seluruh ruang, dengan  $\nabla g$  bersifat  $\beta$ -kokersif. Buktikan bahwa  $f + g$  mempunyai tepat satu peminimum  $x^*$  dan bahwa, untuk setiap  $\gamma > 0$ ,

$$x^* = J_{\gamma\partial f}(x^* - \gamma\nabla g(x^*)).$$

Jelaskan peran aturan penjumlahan subdiferensial dalam argumen Anda.

**Petunjuk bertahap.** **Tahap 1.** Gunakan batas bawah kuadratik dari konveksitas kuat untuk mendapatkan kekompakan himpunan sublevel. **Tahap 2.** Ubah inklusi  $0 \in \partial f(x^*) + \nabla g(x^*)$  menjadi definisi resoven.

**Jawaban singkat.**  $f + g$  proper, semikontinu-bawah, koersif, dan  $\mu$ -konveks kuat; jadi ia mempunyai peminimum tunggal. Kontinuitas  $g$  memberi  $\partial(f + g) = \partial f + \nabla g$ , dan syarat Fermat ekuivalen dengan

$$x^* - \gamma\nabla g(x^*) \in x^* + \gamma\partial f(x^*),$$

yakni persamaan titik tetap yang diminta.

**Solusi lengkap.** Konveksitas kuat memberikan batas bawah kuadratik bagi  $f$  di sekitar suatu titik dalam domainnya. Fungsi konveks terdiferensialkan  $g$  mempunyai batas bawah affin dari bidang singgungnya. Karena itu suku kuadrat mendominasi batas affin ketika norma membesar, sehingga  $f + g$  koersif. Fungsi tersebut proper dan semikontinu-bawah, maka dalam dimensi hingga ia mencapai minimum. Jumlahnya tetap  $\mu$ -konveks kuat, sehingga dua peminimum yang berbeda tidak mungkin ada.

Karena  $g$  bernilai hingga dan kontinu di seluruh ruang, aturan penjumlahan berlaku tanpa syarat kualifikasi tambahan:

$$\partial(f + g)(x) = \partial f(x) + \nabla g(x).$$

Syarat Fermat untuk peminimum tunggal adalah  $-\nabla g(x^*) \in \partial f(x^*)$ . Mengalikan dengan  $\gamma$  dan menata ulang memberi  $x^* - \gamma\nabla g(x^*) \in (I + \gamma\partial f)(x^*)$ . Menerapkan invers  $J_{\gamma\partial f} = (I + \gamma\partial f)^{-1}$  memberi persamaan titik tetap.

**Latihan 15.32** (Keaveragen operator maju-mundur dan laju residu). Misalkan  $A$  maksimal monoton dan  $B$  bersifat  $\beta$ -kokersif. Untuk  $0 < \gamma < 2\beta$ , definisikan

$$T = J_{\gamma A}(I - \gamma B), \quad x_{k+1} = Tx_k,$$

dan anggap  $\text{Fix } T \neq \emptyset$ .

- (i) Tunjukkan bahwa  $I - \gamma B$  bersifat  $\gamma/(2\beta)$ -averaged dan  $J_{\gamma A}$  bersifat  $1/2$ -averaged.
- (ii) Gunakan aturan komposisi untuk memperoleh  $\alpha = 2\beta/(4\beta - \gamma)$  sebagai parameter averaged bagi  $T$ .
- (iii) Untuk  $z \in \text{Fix } T$ , turunkan ketaksamaan penurunan dan batas untuk residu terkecil di antara  $k$  iterasi pertama.

**Petunjuk bertahap.** **Tahap 1.** Tulis  $I - \gamma B = (1 - a)I + a(I - 2\beta B)$  dengan  $a = \gamma/(2\beta)$ . **Tahap 2.** Terapkan karakterisasi kuadrat operator averaged, lalu jumlahkan ketaksamaan itu dari 0 sampai  $k - 1$ .

**Jawaban singkat.** Komposisi kedua operator tersebut bersifat  $\alpha$ -averaged dengan  $\alpha = 2\beta/(4\beta - \gamma)$ . Untuk setiap titik tetap  $z$ ,

$$\|Tx_k - z\|^2 \leq \|x_k - z\|^2 - \frac{1 - \alpha}{\alpha} \|(I - T)x_k\|^2,$$

dan karenanya

$$\min_{0 \leq j < k} \|(I - T)x_j\| \leq \sqrt{\frac{\alpha}{(1 - \alpha)k}} \|x_0 - z\|.$$

**Solusi lengkap.** Kokersivitas  $B$  menyiratkan bahwa  $I - 2\beta B$  non-ekspansif. Dengan  $a = \gamma/(2\beta) \in (0, 1)$ ,

$$I - \gamma B = (1 - a)I + a(I - 2\beta B),$$

sehingga operator maju bersifat  $a$ -averaged. Resolven operator maksimal monoton firmly non-ekspansif, yang sama dengan  $1/2$ -averaged. Jika dua operator masing-masing  $a_1$ - dan  $a_2$ -averaged, komposisinya dapat diambil averaged dengan parameter

$$\frac{a_1 + a_2 - 2a_1a_2}{1 - a_1a_2}.$$

Memasukkan  $a_1 = 1/2$  dan  $a_2 = \gamma/(2\beta)$  menghasilkan  $\alpha = 2\beta/(4\beta - \gamma) \in (0, 1)$ .

Karakterisasi kuadrat operator  $\alpha$ -averaged memberi, karena  $Tz = z$ ,

$$\|Tx_k - z\|^2 \leq \|x_k - z\|^2 - \frac{1 - \alpha}{\alpha} \|(I - T)x_k\|^2.$$

Penjumlahan meneleskopkan ruas norma dan menunjukkan

$$\sum_{j=0}^{k-1} \|(I - T)x_j\|^2 \leq \frac{\alpha}{1 - \alpha} \|x_0 - z\|^2.$$

Nilai minimum tidak melebihi rata-rata; mengambil akar memberikan batas pada jawaban singkat dan menunjukkan residu terbaik berorde  $O(k^{-1/2})$ .

**Latihan 15.33** (Jendela langkah untuk operator monoton tak simetris). Untuk  $a > 0$ , pertimbangkan operator linear

$$B_a = \begin{pmatrix} 1 & -a \\ a & 1 \end{pmatrix} \quad \text{pada } \mathbb{R}^2.$$

Buktikan bahwa  $B_a$  bersifat 1-monoton kuat, mempunyai konstanta Lipschitz  $\sqrt{1 + a^2}$ , dan bersifat  $1/(1 + a^2)$ -kokersif. Tentukan secara eksak kapan iterasi maju  $x_{k+1} = (I - \gamma B_a)x_k$  merupakan kontraksi. Gunakan hasil itu untuk mendiagnosis klaim bahwa monoton kuat saja selalu membolehkan semua  $0 < \gamma < 2$ .

**Petunjuk bertahap.** **Tahap 1.** Untuk  $d \in \mathbb{R}^2$ , hitung  $\langle B_a d, d \rangle$  dan  $\|B_a d\|^2$ . **Tahap 2.** Hitung norma faktor  $(1 - \gamma)I - \gamma a J$ , dengan  $J$  rotasi seperempat putaran.

**Jawaban singkat.** Untuk setiap  $d$ ,  $\langle B_a d, d \rangle = \|d\|^2$  dan  $\|B_a d\|^2 = (1 + a^2)\|d\|^2$ . Faktor kontraksinya adalah

$$\rho(\gamma) = \sqrt{(1 - \gamma)^2 + a^2 \gamma^2},$$

sehingga kontraksi terjadi tepat ketika  $0 < \gamma < 2/(1 + a^2)$ .

**Solusi lengkap.** Bagian simetris  $B_a$  adalah identitas. Karena itu  $\langle B_a d, d \rangle = \|d\|^2$ , yang membuktikan monoton kuat dengan modulus satu. Perkalian langsung memberi  $B_a^\top B_a = (1 + a^2)I$ ; jadi norma operatornya  $\sqrt{1 + a^2}$  dan

$$\langle B_a d, d \rangle = \frac{1}{1 + a^2} \|B_a d\|^2,$$

yakni kokersivitas yang dinyatakan.

Matriks iterasi mempunyai bagian skalar  $1 - \gamma$  dan bagian rotasi  $-\gamma a J$ , sehingga norma setiap vektor dikalikan dengan  $\rho(\gamma)$ . Syarat  $\rho(\gamma) < 1$  ekuivalen dengan

$$(1 - \gamma)^2 + a^2 \gamma^2 < 1 \iff 0 < \gamma < \frac{2}{1 + a^2}.$$

Jadi interval  $(0, 2)$  tidak seragam terhadap bagian antisimetri. Monoton kuat tanpa kontrol Lipschitz atau kokersivitas tidak cukup untuk membenarkan klaim langkah tersebut.

**Latihan 15.34** (Sertifikat titik tetap Douglas–Rachford). Pada  $\mathbb{R}$ , minimalkan  $f(x) + g(x)$  dengan  $f(x) = |x|$  dan  $g = \delta_{[1, \infty)}$ . Ambil  $\gamma = 1$  dan konvensi

$$T = \frac{1}{2}(I + R_g R_f), \quad R_q = 2 \operatorname{prox}_q - I.$$

Tentukan peminimum, lalu verifikasi secara langsung bahwa  $z^\star = 2$  adalah titik tetap  $T$  dan bahwa bayangannya  $\operatorname{prox}_f(z^\star)$  sama dengan peminimum.

**Petunjuk bertahap.** **Tahap 1.** Gunakan penyusutan lunak untuk  $\operatorname{prox}_{|\cdot|}$  dan proyeksi untuk  $\operatorname{prox}_{\delta_{[1, \infty)}}$ . **Tahap 2.** Ikuti urutan  $2 \mapsto R_f(2) \mapsto R_g R_f(2)$  tanpa menukar konvensi komposisi.

**Jawaban singkat.** Peminimumnya  $x^\star = 1$ . Selain itu,  $\operatorname{prox}_f(2) = 1$ ,  $R_f(2) = 0$ ,  $\operatorname{prox}_g(0) = 1$ , dan  $R_g(0) = 2$ . Maka  $T(2) = 2$  dan bayangan  $\operatorname{prox}_f(2) = x^\star$ .

**Solusi lengkap.** Kendala efektif  $g$  memaksa  $x \geq 1$ . Pada himpunan itu  $|x| = x$ , sehingga nilai terkecil dicapai secara tunggal di  $x^\star = 1$ . Proksimal  $f$  dengan parameter satu adalah penyusutan lunak; akibatnya  $\operatorname{prox}_f(2) = 2 - 1 = 1$  dan  $R_f(2) = 2(1) - 2 = 0$ . Proksimal indikator adalah proyeksi ke  $[1, \infty)$ , sehingga  $\operatorname{prox}_g(0) = 1$  dan  $R_g(0) = 2(1) - 0 = 2$ . Oleh sebab itu

$$T(2) = \frac{1}{2}(2 + 2) = 2.$$

Variabel titik tetap  $z^\star$  tidak harus sama dengan solusi primal; pada konvensi ini solusi diperoleh dari bayangan proksimalnya, yang memang bernilai satu.

**Latihan 15.35** (Metode titik proksimal dengan galat yang dapat dijumlahkan). Misalkan  $A$  maksimal monoton pada ruang Euklides berdimensi hingga, zer  $A \neq \emptyset$ , dan  $\gamma > 0$ . Pertimbangkan

$$x_{k+1} = J_{\gamma A} x_k + e_k, \quad \sum_{k=0}^{\infty} \|e_k\| < \infty.$$

Buktikan bahwa  $(x_k)$  konvergen ke suatu titik di zer  $A$ . Dalam bukti Anda, tunjukkan juga bahwa  $x_k - J_{\gamma A} x_k \rightarrow 0$ .

**Petunjuk bertahap.** **Tahap 1.** Tetapkan  $y_k = J_{\gamma A} x_k$  dan gunakan firm non-ekspansivitas terhadap  $z \in$  zer  $A$ . **Tahap 2.** Jumlahkan galat kuadrat yang dihasilkan; lalu gunakan ketertutupan graf operator maksimal monoton pada subsekuens konvergen.

**Jawaban singkat.** Firm non-ekspansivitas memberi

$$\|y_k - z\|^2 + \|x_k - y_k\|^2 \leq \|x_k - z\|^2.$$

Perturbasi yang normanya dapat dijumlahkan membuat barisan kuasi-Fejér, dan penjumlahan ketaksamaan memperlihatkan  $\sum_k \|x_k - y_k\|^2 < \infty$ . Semua titik klaster adalah nol  $A$ ; dalam dimensi hingga sifat kuasi-Fejér lalu memberi konvergensi seluruh barisan.

**Solusi lengkap.** Ambil  $z \in \text{zer } A$ . Maka  $J_{\gamma A} z = z$ . Dengan  $y_k = J_{\gamma A} x_k$ , firm non-ekspansivitas menghasilkan

$$\|y_k - z\|^2 + \|x_k - y_k\|^2 \leq \|x_k - z\|^2. \quad (1)$$

Karena  $x_{k+1} = y_k + e_k$ ,  $\|x_{k+1} - z\| \leq \|x_k - z\| + \|e_k\|$ . Jumlah norma galat hingga, sehingga  $(x_k)$  dan  $(y_k)$  terbatas dan jarak terhadap setiap nol mempunyai limit.

Mengembangkan kuadrat  $\|y_k + e_k - z\|^2$  lalu memakai (1) memberi

$$\|x_{k+1} - z\|^2 \leq \|x_k - z\|^2 - \|x_k - y_k\|^2 + 2\langle y_k - z, e_k \rangle + \|e_k\|^2.$$

Karena  $(y_k)$  terbatas dan galat dapat dijumlahkan, kedua suku galat di ruas kanan dapat dijumlahkan. Penjumlahan ketaksamaan menunjukkan  $\sum_k \|x_k - y_k\|^2 < \infty$ , jadi residu itu menuju nol.

Setiap subsekuens konvergen  $x_{k_j} \rightarrow \bar{x}$  juga memenuhi  $y_{k_j} \rightarrow \bar{x}$ . Dari definisi resolven,  $(x_{k_j} - y_{k_j})/\gamma \in Ay_{k_j}$ , dan ruas kiri menuju nol. Graf operator maksimal monoton tertutup, sehingga  $0 \in A\bar{x}$ . Jadi semua titik klaster berada di zer  $A$ . Barisan terbatas dalam dimensi hingga mempunyai titik klaster, dan sifat kuasi-Fejér beserta fakta bahwa semua titik klasternya adalah nol memaksa seluruh barisan konvergen ke satu nol  $A$ .

## 15.8 Set soal VI: transportasi optimal dan sintesis

**Latihan 15.36** (Stabilitas terhadap perturbasi biaya seragam). Misalkan  $\Pi(\alpha, \beta)$  adalah himpunan kopling probabilitas dan dua fungsi biaya memenuhi  $\|c - \tilde{c}\|_\infty \leq \varepsilon$ . Tuliskan  $v$  dan  $\tilde{v}$  untuk nilai optimal dengan biaya  $c$  dan  $\tilde{c}$ .

(i) Buktikan  $|v - \tilde{v}| \leq \varepsilon$ .

(ii) Jika  $P_c$  optimal untuk biaya  $c$ , buktikan bahwa ia paling jauh  $2\varepsilon$ -suboptimal untuk biaya  $\tilde{c}$ .

**Petunjuk bertahap.** **Tahap 1.** Integralkan batas titik demi titik terhadap sembarang kopling probabilitas.

**Tahap 2.** Sisipkan nilai  $v$  di antara biaya  $\tilde{c}$  pada  $P_c$  dan nilai  $\tilde{v}$ .

**Jawaban singkat.** Untuk setiap  $P \in \Pi(\alpha, \beta)$ ,  $|\langle c, P \rangle - \langle \tilde{c}, P \rangle| \leq \varepsilon$ . Mengambil infimum memberi  $|v - \tilde{v}| \leq \varepsilon$ , dan

$$\langle \tilde{c}, P_c \rangle - \tilde{v} \leq 2\varepsilon.$$

**Solusi lengkap.** Karena massa total setiap kopling adalah satu,

$$\left| \int (c - \tilde{c}) dP \right| \leq \int |c - \tilde{c}| dP \leq \varepsilon.$$

Jadi  $\langle \tilde{c}, P \rangle \leq \langle c, P \rangle + \varepsilon$  untuk setiap  $P$ . Mengambil infimum memberi  $\tilde{v} \leq v + \varepsilon$ . Menukar peran kedua biaya memberi  $v \leq \tilde{v} + \varepsilon$ , sehingga batas nilai optimal terbukti. Selanjutnya,

$$\langle \tilde{c}, P_c \rangle - \tilde{v} \leq \langle c, P_c \rangle + \varepsilon - (v - \varepsilon) = 2\varepsilon,$$

karena  $\langle c, P_c \rangle = v$ . Batas kedua memuat dua sumber galat: evaluasi rencana dan pergeseran nilai optimal.

**Latihan 15.37** (Sertifikat dual untuk translasi). Pada  $\mathbb{R}$ , ambil biaya  $c(x, y) = \frac{1}{2}(y - x)^2$ . Misalkan  $\alpha$  mempunyai momen pertama hingga dan  $\beta = (x \mapsto x + a)_{\#} \alpha$  untuk suatu  $a \in \mathbb{R}$ .

(i) Hitung biaya kopling deterministik  $y = x + a$ .

(ii) Buktikan bahwa  $\varphi(x) = -ax$  dan  $\psi(y) = ay - a^2/2$  layak untuk masalah dual Kantorovich.

(iii) Gunakan kesetaraan primal-dual untuk menyimpulkan optimalitas kopling translasi tersebut.

**Petunjuk bertahap. Tahap 1.** Kurangi  $\varphi(x) + \psi(y)$  dari  $c(x, y)$  dan lengkapi kuadrat dalam  $y - x$ . **Tahap 2.** Gunakan identitas  $\int y d\beta(y) = \int (x + a) d\alpha(x)$ .

**Jawaban singkat.** Biaya kopling translasi adalah  $a^2/2$ , dan

$$c(x, y) - \varphi(x) - \psi(y) = \frac{1}{2}(y - x - a)^2 \geq 0.$$

Nilai dual kedua potensial juga  $a^2/2$ , sehingga kopling dan potensial itu optimal.

**Solusi lengkap.** Pada kopling  $y = x + a$ , biaya bernilai konstan  $\frac{1}{2}a^2$ , sehingga integralnya  $a^2/2$ . Untuk semua  $x, y$ ,

$$\frac{1}{2}(y - x)^2 - (-ax + ay - a^2/2) = \frac{1}{2}(y - x - a)^2 \geq 0.$$

Maka  $\varphi(x) + \psi(y) \leq c(x, y)$ , dengan kesetaraan tepat pada graf translasi. Momen pertama menjamin integral potensial terdefinisi, dan

$$\int \varphi d\alpha + \int \psi d\beta = -a \int x d\alpha + a \int (x + a) d\alpha - a^2/2 = a^2/2.$$

Dual lemah menyatakan bahwa nilai ini tidak dapat melebihi biaya kopling mana pun. Karena kopling translasi mencapai nilai yang sama, celah dualnya nol dan kopling itu optimal.

**Latihan 15.38** (Penskalaan Sinkhorn dalam domain log dan kebebasan gauge). Untuk marginal positif  $a \in \mathbb{R}^n$  dan  $b \in \mathbb{R}^m$ , definisikan

$$K_{ij} = \exp(-C_{ij}/\varepsilon), \quad P = \text{diag}(u)K \text{diag}(v),$$

dengan  $u_i, v_j > 0$ . Tuliskan  $\rho_i = \log u_i$  dan  $\tau_j = \log v_j$ .

- (i) Turunkan pembaruan baris dan kolom dalam bentuk log-sum-exp.
- (ii) Buktikan bahwa  $u \mapsto tu, v \mapsto v/t$  tidak mengubah  $P$ .
- (iii) Jelaskan secara matematis mengapa pemusatan  $\rho$  dan  $\tau$  dengan pergeseran yang berlawanan dapat mencegah luapan numerik tanpa mengubah kopling.

**Petunjuk bertahap. Tahap 1.** Selesaikan persamaan  $P\mathbb{1} = a$  terhadap setiap  $u_i$ , lalu ambil logaritma; lakukan hal yang sama untuk kolom. **Tahap 2.** Tambahkan konstanta  $s$  pada semua  $\rho_i$  dan kurangkan  $s$  dari semua  $\tau_j$ .

**Jawaban singkat.**

$$\rho_i = \log a_i - \text{LSE}_j(-C_{ij}/\varepsilon + \tau_j), \quad \tau_j = \log b_j - \text{LSE}_i(-C_{ij}/\varepsilon + \rho_i).$$

Transformasi  $(\rho, \tau) \mapsto (\rho + s\mathbb{1}, \tau - s\mathbb{1})$  membiarkan setiap jumlah  $\rho_i + \tau_j$  tetap, sehingga  $P$  tidak berubah.

**Solusi lengkap.** Kendala baris adalah  $u_i \sum_j K_{ij} v_j = a_i$ , jadi

$$\rho_i = \log a_i - \log \sum_j \exp(-C_{ij}/\varepsilon + \tau_j).$$

Logaritma jumlah eksponensial adalah fungsi LSE. Dengan cara yang sama, kendala kolom menghasilkan rumus untuk  $\tau_j$  pada jawaban singkat. Jika  $t > 0$ , maka

$$\text{diag}(tu)K \text{diag}(v/t) = \text{diag}(u)K \text{diag}(v).$$

Dalam koordinat log, ini tepat sama dengan menambahkan  $s = \log t$  pada  $\rho$  dan mengurangkannya dari  $\tau$ . Karena entri  $P$  bergantung pada  $\rho_i + \tau_j - C_{ij}/\varepsilon$ , semua entri tetap sama. Kita boleh memilih  $s$ , misalnya untuk memusatkan rentang nilai log, agar eksponensial perantara tidak terlalu besar atau kecil. Operasi itu mengubah representasi, bukan kopling atau marginalnya.

**Latihan 15.39** (Batas bias regularisasi entropi). Pada tabel kopling probabilitas berukuran  $n \times m$ , definisikan  $H(P) = -\sum_{ij} P_{ij} \log P_{ij}$  dengan konvensi  $0 \log 0 = 0$ . Misalkan  $P^*$  meminimalkan  $\langle C, P \rangle$  dan  $P_\varepsilon$  meminimalkan

$$\langle C, P \rangle - \varepsilon H(P)$$

pada himpunan kopling yang sama. Buktikan

$$0 \leq \langle C, P_\varepsilon \rangle - \langle C, P^* \rangle \leq \varepsilon \log(nm).$$

**Petunjuk bertahap.** **Tahap 1.** Bandingkan nilai objektif teratur pada  $P_\varepsilon$  dan  $P^*$ . **Tahap 2.** Gunakan  $0 \leq H(P) \leq \log(nm)$  untuk setiap distribusi pada  $nm$  sel.

**Jawaban singkat.** Optimalitas kedua rencana memberi batas bawah nol dan

$$\langle C, P_\varepsilon \rangle - \langle C, P^* \rangle \leq \varepsilon (H(P_\varepsilon) - H(P^*)) \leq \varepsilon \log(nm).$$

**Solusi lengkap.** Karena  $P^*$  optimal untuk biaya tanpa regularisasi,  $\langle C, P_\varepsilon \rangle \geq \langle C, P^* \rangle$ . Di sisi lain, optimalitas  $P_\varepsilon$  untuk objektif teratur menyatakan

$$\langle C, P_\varepsilon \rangle - \varepsilon H(P_\varepsilon) \leq \langle C, P^* \rangle - \varepsilon H(P^*).$$

Menata ulang memberi ketaksamaan pertama pada jawaban singkat. Entropi distribusi dengan paling banyak  $nm$  atom berada di antara nol dan  $\log(nm)$ . Maka  $H(P_\varepsilon) - H(P^*) \leq \log(nm)$ , yang menyelesaikan batas atas. Batas ini mengukur bias biaya tak teratur, bukan jarak antara kedua rencana.

**Latihan 15.40** (Kelengkungan dual entropik dan arah gauge). Pertimbangkan fungsi dual

$$D(f, g) = a^\top f + b^\top g - \varepsilon \sum_{i,j} \exp\left(\frac{f_i + g_j - C_{ij}}{\varepsilon}\right),$$

dan tuliskan  $P_{ij} = \exp((f_i + g_j - C_{ij})/\varepsilon)$ .

- (i) Hitung gradien terhadap  $f$  dan  $g$ .
- (ii) Hitung bentuk kuadratik Hessian pada arah  $(s, t)$  dan buktikan kekonkafan.
- (iii) Identifikasi arah gauge. Jika graf bipartit dukungan positif  $P$  terhubung, buktikan bahwa hanya arah gauge yang mempunyai kelengkungan nol.

**Petunjuk bertahap.** **Tahap 1.** Diferensiasikan satu eksponensial dan kelompokkan jumlah baris serta kolom. **Tahap 2.** Bentuk kuadratik dapat ditulis sebagai jumlah berbobot dari  $(s_i + t_j)^2$ .

**Jawaban singkat.**

$$\nabla_f D = a - P\mathbb{1}, \quad \nabla_g D = b - P^\top \mathbb{1},$$

dan

$$\begin{pmatrix} s \\ t \end{pmatrix}^\top \nabla^2 D \begin{pmatrix} s \\ t \end{pmatrix} = -\frac{1}{\varepsilon} \sum_{i,j} P_{ij} (s_i + t_j)^2 \leq 0.$$

Arah  $(s, t) = (c\mathbb{1}, -c\mathbb{1})$  adalah arah gauge; bila dukungan terhubung, semua arah nol berbentuk demikian.

**Solusi lengkap.** Diferensiasi terhadap  $f_i$  menghasilkan  $a_i - \sum_j P_{ij}$ , sedangkan diferensiasi terhadap  $g_j$  menghasilkan  $b_j - \sum_i P_{ij}$ . Diferensiasi kedua pada lintasan  $(f + \theta s, g + \theta t)$  memberi

$$\left. \frac{d^2}{d\theta^2} D(f + \theta s, g + \theta t) \right|_{\theta=0} = -\frac{1}{\varepsilon} \sum_{i,j} P_{ij} (s_i + t_j)^2.$$

Bobotnya nonnegatif, sehingga  $D$  konkaf. Bentuk kuadratik nol tepat bila  $s_i + t_j = 0$  pada setiap sisi dukungan positif. Pada graf bipartit yang terhubung, kondisi ini memaksa semua  $s_i$  sama dengan satu konstanta  $c$  dan semua  $t_j = -c$ . Itulah transformasi  $(f, g) \mapsto (f + c\mathbb{1}, g - c\mathbb{1})$  yang tidak mengubah  $P$ . Jadi dual bersifat konkaf ketat setelah satu gauge dipatok, meskipun tidak konkaf ketat pada representasi yang belum dinormalisasi.

## 15.9 Rubrik analitik untuk pembuktian

Setiap kriteria di bawah dinilai dengan skala yang sama: **0** tidak ada atau tidak sah; **1** fragmen relevan dengan galat mayor; **2** arah sebagian benar tetapi masih ada celah substantif; **3** benar dengan satu kekurangan minor yang tidak mengubah kesimpulan; dan **4** lengkap, tepat, dan seluruh dependensi logis dinyatakan. Setiap rubrik mempunyai empat kriteria, jadi skor maksimumnya adalah 16. Keanggunan gaya tidak boleh menutupi galat matematika, dan notasi alternatif yang ekuivalen harus dinilai berdasarkan isinya.

### 15.9.1 Rubrik proof.0001: hipotesis, tipe, dan kuantor

**Kriteria (masing-masing 0–4).**

- (i) Menyatakan objek, ruang, domain, dan kodomain secara konsisten.
- (ii) Menempatkan semua kuantor dan dependensi parameter pada lingkup yang benar, termasuk perbedaan antara pernyataan titik demi titik dan seragam.
- (iii) Menggunakan tepat hipotesis tertutupan, konveksitas, keterbatasan, atau keterukuran pada langkah yang memerlukannya.
- (iv) Menutup semua kasus tepi dan memastikan bahwa kesimpulan mempunyai tipe logis yang sama dengan klaim semula.

**Kegagalan umum.** Menganggap domain sama dengan seluruh ruang; menukar “untuk setiap” dengan “terdapat”; memakai konstanta yang diam-diam bergantung pada iterasi; membagi dengan besaran yang belum dibuktikan positif; atau menyatakan limit tanpa menentukan topologi.

### 15.9.2 Rubrik proof.0002: keberadaan dan argumen topologis

**Kriteria (masing-masing 0–4).**

- (i) Mengidentifikasi himpunan sublevel atau barisan peminimum yang tepat dan membuktikan keterbatasan atau kekompakannya.
- (ii) Menggunakan semikontinuitas-bawah, tertutupan, atau kekompakan dengan arah ketaksamaan dan topologi yang benar.
- (iii) Membedakan dengan tegas keberadaan, ketunggalan, dan kestabilan, serta memberi hipotesis tersendiri bagi masing-masing klaim.
- (iv) Menangani fungsi bernilai-diperluas, domain efektif, dan nilai tak hingga tanpa operasi aljabar yang tidak sah.

**Kegagalan umum.** Mengatakan “kontinu maka minimum ada” pada himpunan tak kompak; menganggap konveksitas memberi ketunggalan; menyimpulkan koersivitas hanya dari keterbatasan-bawah; mengabaikan domain kosong; atau mengambil limit dalam domain yang belum dibuktikan tertutup.

### 15.9.3 Rubrik proof.0003: penurunan, teleskop, dan laju

**Kriteria (masing-masing 0–4).**

- (i) Menurunkan ketaksamaan satu-langkah dari asumsi yang dinyatakan, dengan tanda, faktor, dan norma yang benar.
- (ii) Menentukan besaran potensial nonnegatif dan meneleskopkan indeks tanpa kehilangan suku batas.
- (iii) Memilih langkah atau parameter dalam rentang yang benar dan melacak semua konstanta hingga batas akhir.
- (iv) Membedakan laju nilai fungsi, jarak iterasi, dan residu, termasuk apakah klaim berlaku untuk iterasi terakhir, terbaik, atau rata-rata.

**Kegagalan umum.** Menghapus suku bertanda tak diketahui; kesalahan indeks awal/akhir; memilih langkah setelah melihat kuantitas acak masa depan; mengubah batas  $O(k^{-1/2})$  menjadi  $O(k^{-1})$  dengan menguadratkan sepihak; atau menyembunyikan konstanta yang bergantung pada dimensi.

#### 15.9.4 Rubrik proof.0004: dualitas, kualifikasi, dan KKT

**Kriteria (masing-masing 0–4).**

- (i) Membentuk Lagrangian dengan tanda, ruang dual, dan domain yang benar.
- (ii) Menyatakan kondisi kualifikasi yang benar-benar cukup sebelum menggunakan dualitas kuat atau keberadaan pengali.
- (iii) Menurunkan kelayakan primal, kelayakan dual, stasioneritas, dan kelonggaran komplementer tanpa melewati inklusi subdiferensial.
- (iv) Membuktikan kebutuhan atau kecukupan kondisi KKT sesuai kelas masalah, serta menghubungkannya dengan titik pelana atau nilai dual.

**Kegagalan umum.** Menyatakan KKT tanpa kualifikasi; memberi pengali bertanda salah; mengganti inklusi dengan persamaan gradien saat fungsi tak mulus; menyamakan dualitas lemah dengan kuat; atau memakai kelonggaran komplementer untuk menyimpulkan kelayakan yang belum dibuktikan.

#### 15.9.5 Rubrik proof.0005: filtrasi dan argumen stokastik

**Kriteria (masing-masing 0–4).**

- (i) Mendefinisikan filtrasi dan menyatakan dengan benar besaran yang terukur sebelum pengambilan sampel berikutnya.
- (ii) Menghitung ekspektasi bersyarat, ketakbiasan, dan bias tanpa mengasumsikan independensi yang tidak tersedia.
- (iii) Membedakan batas varians dari batas momen kedua dan menggunakan hukum varians total atau Jensen secara sah.
- (iv) Menukar ekspektasi, penjumlahan, limit, atau subdiferensial hanya jika syarat integrabilitas dan teorema yang dibutuhkan telah dipenuhi.

**Kegagalan umum.** Mengondisikan pada informasi yang sudah memuat sampel baru; menyebut galat sebagai selisih martingal padahal mean bersyaratnya tidak nol; mengganti  $\mathbb{E}\|G\|^2$  dengan varians; memakai sampel tanpa pengembalian seolah-olah independen; atau mengambil ekspektasi dari kuantitas tak terintegralkan.

#### 15.9.6 Rubrik proof.0006: operator monoton dan resolven

**Kriteria (masing-masing 0–4).**

- (i) Menyatakan domain operator bernilai-himpunan dan membedakan monotoni, monotoni maksimal, monotoni kuat, serta kokersivitas.
- (ii) Mengubah inklusi menjadi persamaan resolven atau titik tetap dengan urutan komposisi dan parameter yang benar.
- (iii) Menggunakan firm non-ekspansivitas, keaveragan, atau kontraksi dengan konstanta yang dibuktikan, bukan diasumsikan.
- (iv) Menghubungkan residu atau titik klaster dengan nol operator melalui ketertutupan graf dan argumen konvergensi yang lengkap.

**Kegagalan umum.** Menganggap semua operator monoton maksimal; memperlakukan resolven sebagai invers biasa; menukar  $R_A R_B$  dengan  $R_B R_A$ ; mengabaikan domain pada aturan jumlah; atau menyimpulkan konvergensi iterasi hanya dari residu yang menuju nol tanpa kontrol titik klaster.

### 15.9.7 Rubrik proof.0007: contoh penyangkal dan sertifikat komputasional

**Kriteria (masing-masing 0–4).**

- (i) Menargetkan tepat satu hipotesis atau kesimpulan dan memastikan contoh memenuhi semua asumsi lain yang dipertahankan.
- (ii) Menghitung objek kunci secara eksak atau dengan batas galat yang tersertifikasi, termasuk kasus tepi yang relevan.
- (iii) Memisahkan bukti matematis dari ilustrasi numerik serta menyatakan presisi, toleransi, dan residu bila komputasi dipakai.
- (iv) Menjelaskan secara eksplisit bagaimana hasil contoh membatalkan klaim universal atau bagaimana sertifikat memverifikasi klaim yang terbatas.

**Kegagalan umum.** Contoh melanggar asumsi lain; satu plot diperlakukan sebagai bukti universal; residu kecil disamakan dengan galat solusi tanpa batas kondisi; pembulatan mengubah tanda; atau program menguji hanya satu parameter sementara klaimnya untuk semua parameter.

## 15.10 Ujian tengah kumulatif

**Latihan 15.41** (Keberadaan dan ketunggalan model kuadrat- $\ell^1$ ). Untuk  $A \in \mathbb{R}^{m \times n}$ ,  $b \in \mathbb{R}^m$ , dan  $\lambda > 0$ , pertimbangkan

$$F(x) = \|Ax - b\|_2^2 + \lambda \|x\|_1.$$

Buktikan bahwa  $F$  selalu mempunyai minimum. Apakah minimum itu selalu tunggal? Berikan satu kondisi sederhana pada  $A$  yang menjamin ketunggalan.

**Petunjuk bertahap.** **Tahap 1.** Bandingkan  $F(x)$  dengan  $\lambda \|x\|_1$  ketika  $\|x\|_2 \rightarrow \infty$ . **Tahap 2.** Untuk ketunggalan, cari kondisi yang membuat suku kuadrat konveks ketat; untuk menyangkal ketunggalan umum, izinkan  $A$  memiliki kernel.

**Jawaban singkat.**  $F$  kontinu dan koersif karena  $F(x) \geq \lambda \|x\|_1$ , sehingga minimum dicapai. Ketunggalan tidak selalu berlaku; misalnya  $A = 0$  dan  $b = 0$  sebenarnya memberi minimum tunggal, tetapi matriks dengan kolom identik dapat menghasilkan banyak representasi  $\ell^1$  dengan nilai sama. Kondisi sederhana yang cukup adalah  $A$  berperingkat kolom penuh.

**Solusi lengkap.** Kedua suku  $F$  kontinu dan tak negatif. Karena  $\|x\|_1 \geq \|x\|_2$ ,

$$F(x) \geq \lambda \|x\|_2 \longrightarrow \infty \quad \text{ketika } \|x\|_2 \rightarrow \infty.$$

Jadi semua himpunan sublevel tak kosong yang relevan kompak, dan teorema Weierstrass memberi keberadaan minimum.

Ketunggalan dapat gagal. Sebagai contoh, ambil  $A = \begin{pmatrix} 1 & 1 \end{pmatrix}$ ,  $b = 1$ , dan  $0 < \lambda < 2$ . Untuk  $x_1, x_2 \geq 0$  dengan  $x_1 + x_2 = s$ , objektif hanya bergantung pada  $s$ :  $(s - 1)^2 + \lambda s$ . Nilai minimumnya dicapai pada  $s = 1 - \lambda/2 > 0$ , dan setiap pembagian nonnegatif dari  $s$  memberi minimum berbeda. Jika  $A$  berperingkat kolom penuh, maka  $x \mapsto \|Ax - b\|_2^2$  konveks ketat. Jumlah fungsi konveks ketat dengan fungsi konveks tetap konveks ketat, sehingga minimum yang sudah terbukti ada harus tunggal.

**Latihan 15.42** (Konjugat kuadrat bergeser). Untuk  $\mu > 0$  dan  $c \in \mathbb{R}^n$ , definisikan

$$f(x) = \frac{\mu}{2} \|x\|^2 + \langle c, x \rangle.$$

Hitung  $f^*$  secara langsung dari definisi, verifikasi  $f^{**} = f$ , dan tentukan konstanta Lipschitz terkecil dari  $\nabla f^*$ .

**Petunjuk bertahap. Tahap 1.** Maksimalkan kuadrat konkaf dalam definisi  $f^*(y) = \sup_x \{\langle y, x \rangle - f(x)\}$ .  
**Tahap 2.** Terapkan perhitungan yang sama pada  $f^*$  atau substitusikan gradien inversnya.

**Jawaban singkat.**

$$f^*(y) = \frac{1}{2\mu} \|y - c\|^2, \quad \nabla f^*(y) = \frac{y - c}{\mu}.$$

Karena itu  $f^{**} = f$ , dan konstanta Lipschitz terkecil gradien  $f^*$  adalah  $1/\mu$ .

**Solusi lengkap.** Definisi konjugat memberi

$$f^*(y) = \sup_x \left\{ \langle y - c, x \rangle - \frac{\mu}{2} \|x\|^2 \right\}.$$

Titik stasionernya  $x = (y - c)/\mu$ , dan substitusi menghasilkan  $\|y - c\|^2/(2\mu)$ . Selanjutnya,

$$f^{**}(x) = \sup_y \left\{ \langle x, y \rangle - \frac{1}{2\mu} \|y - c\|^2 \right\}.$$

Peminimum negatif kuadrat, atau kondisi stasioner, memberi  $y = c + \mu x$ . Nilainya  $\langle c, x \rangle + \mu \|x\|^2/2 = f(x)$ . Akhirnya,

$$\|\nabla f^*(y) - \nabla f^*(z)\| = \frac{1}{\mu} \|y - z\|.$$

Kesetaraan berlaku untuk setiap pasangan berbeda, jadi  $1/\mu$  bukan hanya batas yang cukup, melainkan konstanta terkecil.

**Latihan 15.43** (Ketaksamaan satu langkah gradien proksimal). Misalkan  $f$  konveks dengan gradien  $L$ -Lipschitz dan  $r$  konveks proper semikontinu-bawah. Untuk  $0 < \eta \leq 1/L$ , definisikan

$$x^+ = \text{prox}_{\eta r}(x - \eta \nabla f(x)), \quad F = f + r.$$

Buktikan bahwa untuk setiap  $u \in \text{dom } r$ ,

$$F(x^+) - F(u) \leq \frac{\|x - u\|^2 - \|x^+ - u\|^2}{2\eta}.$$

Kemudian turunkan batas  $O(1/k)$  untuk nilai fungsi iterasi gradien proksimal bila peminimum  $x^*$  ada.

**Petunjuk bertahap. Tahap 1.** Gabungkan lemma penurunan untuk  $f$  dengan inklusi optimalitas proksimal dan ketaksamaan subgradien untuk  $r$ . **Tahap 2.** Gunakan identitas tiga norma, tetapkan  $u = x^*$ , lalu jumlahkan dan manfaatkan monoton nilai objektif.

**Jawaban singkat.** Suku tambahan yang muncul adalah  $-(1/(2\eta) - L/2)\|x^+ - x\|^2 \leq 0$ , sehingga ketaksamaan yang diminta berlaku. Untuk iterasi  $x_{j+1}$  yang sama,

$$F(x_k) - F(x^*) \leq \frac{\|x_0 - x^*\|^2}{2\eta k}.$$

**Solusi lengkap.** Inklusi proksimal menyediakan  $s^+ \in \partial r(x^+)$  dengan

$$s^+ = -\nabla f(x) - \frac{1}{\eta}(x^+ - x).$$

Lemma penurunan, konveksitas  $f$ , dan ketaksamaan subgradien memberi

$$\begin{aligned} F(x^+) - F(u) &\leq \langle \nabla f(x), x^+ - u \rangle + \frac{L}{2} \|x^+ - x\|^2 + \langle s^+, x^+ - u \rangle \\ &= -\frac{1}{\eta} \langle x^+ - x, x^+ - u \rangle + \frac{L}{2} \|x^+ - x\|^2 \\ &= \frac{\|x - u\|^2 - \|x^+ - u\|^2}{2\eta} - \left( \frac{1}{2\eta} - \frac{L}{2} \right) \|x^+ - x\|^2. \end{aligned}$$

Koefisien terakhir nonnegatif karena  $\eta \leq 1/L$ , sehingga suku negatif itu dapat dibuang. Dengan  $u = x^*$ , penjumlahan untuk  $j = 0, \dots, k-1$  meneleskopkan jarak dan memberi

$$\sum_{j=0}^{k-1} (F(x_{j+1}) - F(x^*)) \leq \frac{\|x_0 - x^*\|^2}{2\eta}.$$

Ketaksamaan yang sama dengan  $u = x_j$  menunjukkan nilai  $F(x_j)$  tidak naik. Karena itu suku terakhir tidak melebihi rata-rata  $k$  suku, yang menghasilkan batas pada jawaban singkat.

**Latihan 15.44** (Newton dan penerimaan langkah penuh Armijo). Misalkan

$$f(x) = \frac{1}{2}x^\top Qx - b^\top x, \quad Q \succ 0.$$

Dari titik sembarang  $x$ , tentukan arah Newton  $p$ , buktikan bahwa  $x + p$  adalah peminimum eksak, dan tunjukkan bahwa uji Armijo

$$f(x + p) \leq f(x) + c\nabla f(x)^\top p$$

menerima langkah penuh untuk setiap  $0 < c \leq 1/2$ .

**Petunjuk bertahap.** **Tahap 1.** Selesaikan  $Qp = -\nabla f(x)$  dan hitung gradien di  $x + p$ . **Tahap 2.** Gunakan ekspansi kuadrat eksak sepanjang  $p$  serta  $\nabla f(x)^\top p = -p^\top Qp$ .

**Jawaban singkat.**  $p = Q^{-1}(b - Qx)$  dan  $x + p = Q^{-1}b = x^*$ . Selain itu,

$$f(x + p) = f(x) - \frac{1}{2}p^\top Qp, \quad \nabla f(x)^\top p = -p^\top Qp,$$

sehingga Armijo berlaku tepat bila  $c \leq 1/2$  (atau trivial bila  $p = 0$ ).

**Solusi lengkap.** Gradiennya  $Qx - b$  dan Hessiannya  $Q$ . Persamaan Newton  $Qp = -(Qx - b)$  memberi  $p = Q^{-1}b - x$ , sehingga titik baru adalah  $Q^{-1}b$ . Karena  $Q$  definit positif, titik stasioner ini peminimum tunggal. Ekspansi eksak memberi

$$f(x + p) = f(x) + \nabla f(x)^\top p + \frac{1}{2}p^\top Qp = f(x) - \frac{1}{2}p^\top Qp.$$

Ruas kanan uji Armijo adalah  $f(x) - c p^\top Qp$ . Untuk  $p \neq 0$ , definit positifnya  $Q$  membuat uji ekuivalen dengan  $1/2 \geq c$ . Jika  $p = 0$ , titik sudah optimal dan kedua ruas sama untuk semua  $c$ .

**Latihan 15.45** (KKT untuk proyeksi pada bola). Ambil  $R > 0$  dan  $c \in \mathbb{R}^n$  dengan  $\|c\| > R$ . Selesaikan

$$\min_x \frac{1}{2}\|x - c\|^2 \quad \text{dengan syarat} \quad h(x) = \frac{1}{2}(\|x\|^2 - R^2) \leq 0.$$

Verifikasi kondisi Slater, tulis seluruh kondisi KKT, dan hitung pasangan primal–dual optimal secara eksplisit.

**Petunjuk bertahap.** **Tahap 1.** Titik nol adalah titik Slater; karena  $c$  di luar bola, kendala pada solusi harus aktif. **Tahap 2.** Stasioneritas memberi  $(1 + \lambda)x = c$ .

**Jawaban singkat.** KKT terdiri dari

$$x - c + \lambda x = 0, \quad \text{quad}h(x) \leq 0, \quad \text{quad}\lambda \geq 0, \quad \text{quad}\lambda h(x) = 0.$$

Solusinya

$$x^* = R \frac{c}{\|c\|}, \quad \lambda^* = \frac{\|c\|}{R} - 1.$$

**Solusi lengkap.** Karena  $h(0) = -R^2/2 < 0$ , Slater berlaku. Masalah konveks dan objektifnya konveks ketat, sehingga KKT perlu dan cukup serta solusi primal tunggal. Lagrangiannya

$$L(x, \lambda) = \frac{1}{2}\|x - c\|^2 + \frac{\lambda}{2}(\|x\|^2 - R^2).$$

Stasioneritas dan tiga kondisi lainnya tercantum pada jawaban singkat. Solusi tanpa kendala  $x = c$  tidak layak, maka kendala aktif dan  $\|x\| = R$ . Dari  $(1 + \lambda)x = c$  diperoleh bahwa  $x$  searah dengan  $c$ . Menormakan persamaan itu menghasilkan  $1 + \lambda = \|c\|/R$ , sehingga pasangan yang dinyatakan mengikuti. Pengalinya positif, maka semua kondisi KKT terpenuhi.

**Latihan 15.46** (Ketika kualifikasi gagal dan pengali tidak ada). Pertimbangkan masalah konveks skalar

$$\min_{x \in \mathbb{R}} x \quad \text{dengan syarat} \quad x^2 \leq 0.$$

Tentukan solusi, tunjukkan bahwa Slater gagal, dan buktikan bahwa tidak ada pengali  $\lambda \geq 0$  yang memenuhi kondisi KKT pada solusi. Jelaskan mengapa contoh ini tidak menyangkal teorema KKT dengan kualifikasi.

**Petunjuk bertahap.** **Tahap 1.** Tentukan seluruh himpunan layak dari ketaksamaan kuadrat. **Tahap 2.** Differensiasikan  $L(x, \lambda) = x + \lambda x^2$  di titik layak.

**Jawaban singkat.** Satu-satunya titik layak dan optimal ialah  $x^* = 0$ . Tidak ada titik dengan  $x^2 < 0$ , jadi Slater gagal. Stasioneritas KKT menuntut  $1 + 2\lambda x^* = 0$ , yakni  $1 = 0$ , mustahil untuk setiap  $\lambda$ .

**Solusi lengkap.** Karena kuadrat selalu nonnegatif, syarat  $x^2 \leq 0$  ekuivalen dengan  $x = 0$ . Maka  $x^* = 0$  adalah satu-satunya titik layak dan otomatis peminimum. Slater memerlukan titik dengan  $x^2 < 0$ , yang tidak ada. Untuk pengali  $\lambda \geq 0$ , Lagrangian adalah  $L(x, \lambda) = x + \lambda x^2$  dan kondisi stasioneritas pada  $x^*$  ialah

$$0 = \frac{\partial L}{\partial x}(0, \lambda) = 1 + 2\lambda \cdot 0 = 1,$$

sebuah kontradiksi. Teorema KKT yang menjamin keberadaan pengali memakai kondisi kualifikasi seperti Slater. Hipotesis itu gagal di sini, sehingga ketiadaan pengali justru menunjukkan mengapa kualifikasi tidak boleh dihilangkan.

## 15.11 Ujian akhir kumulatif

**Latihan 15.47** (Eksistensi komposit dengan regularisasi kuadratik). Misalkan  $h : \mathbb{R}^m \rightarrow \mathbb{R}$  konveks, kontinu, dan tak negatif;  $r : \mathbb{R}^n \rightarrow (-\infty, +\infty]$  proper, semikontinu-bawah, konveks, dan tak negatif;  $A : \mathbb{R}^n \rightarrow \mathbb{R}^m$  linear; serta  $\lambda > 0$ . Buktikan bahwa

$$F(x) = h(Ax) + r(x) + \frac{\lambda}{2}\|x\|^2$$

mempunyai tepat satu peminimum. Nyatakan bagian argumen yang membuktikan keberadaan dan bagian yang membuktikan ketunggalan.

**Petunjuk bertahap.** **Tahap 1.** Gunakan ketaknegatifan dua suku pertama untuk membatasi himpunan sublevel. **Tahap 2.** Periksa apa yang terjadi pada modulus konveksitas kuat ketika fungsi konveks ditambahkan pada kuadrat  $\lambda\|x\|^2/2$ .

**Jawaban singkat.**  $F$  proper, semikontinu-bawah, dan  $F(x) \geq \lambda\|x\|^2/2$ , sehingga ia koersif dan mencapai minimum. Selain itu,  $F$  bersifat  $\lambda$ -konveks kuat, sehingga peminimumnya tunggal.

**Solusi lengkap.** Karena  $r$  proper, terdapat  $x_0$  dengan  $r(x_0) < \infty$ ; fungsi  $h$  bernilai hingga, jadi  $F(x_0) < \infty$  dan  $F$  proper. Komposisi  $h \circ A$  kontinu dan konveks, sementara  $r$  semikontinu-bawah. Maka  $F$  semikontinu-bawah. Dari ketaknegatifan,

$$F(x) \geq \frac{\lambda}{2} \|x\|^2 \longrightarrow +\infty \quad \text{ketika } \|x\| \rightarrow \infty.$$

Jadi sebuah barisan peminimum berada dalam himpunan terbatas; dalam dimensi hingga kita dapat mengambil subsekuens konvergen, dan semikontinuitas-bawah menunjukkan bahwa limitnya mencapai infimum. Ini membuktikan keberadaan.

Fungsi kuadrat adalah  $\lambda$ -konveks kuat. Penambahan dua fungsi konveks mempertahankan modulus itu, jadi  $F$  juga  $\lambda$ -konveks kuat. Jika ada dua peminimum berbeda, ketaksamaan konveksitas kuat pada titik tengah akan memberi nilai yang lebih kecil secara ketat daripada nilai minimum, kontradiksi. Maka peminimum tunggal.

**Latihan 15.48** (Pencarian balik untuk model proksimal). Misalkan  $f$  konveks dengan gradien  $L$ -Lipschitz,  $r$  proper semikontinu-bawah dan konveks, serta  $x \in \text{dom } r$ . Untuk  $M > 0$ , definisikan

$$x_M = \arg \min_y \left\{ r(y) + f(x) + \langle \nabla f(x), y - x \rangle + \frac{M}{2} \|y - x\|^2 \right\}.$$

Algoritme menggandakan  $M$  sampai uji majorisasi

$$f(x_M) \leq f(x) + \langle \nabla f(x), x_M - x \rangle + \frac{M}{2} \|x_M - x\|^2 \quad (\text{A})$$

terpenuhi. Buktikan bahwa pencarian berhenti secara hingga, lalu buktikan sertifikat penurunan

$$(f + r)(x_M) \leq (f + r)(x) - \frac{M}{2} \|x_M - x\|^2.$$

Nyatakan residu gradien proksimal yang dapat dihitung dari langkah ini.

**Petunjuk bertahap.** **Tahap 1.** Lemma penurunan menjamin (A) untuk semua  $M \geq L$ . **Tahap 2.** Model yang diminimalkan bersifat  $M$ -konveks kuat dan nilainya di  $y = x$  sama dengan  $(f + r)(x)$ .

**Jawaban singkat.** Penggandaan akhirnya menghasilkan  $M \geq L$ , sehingga (A) berlaku. Konveksitas kuat model memberi nilai model di  $x_M$  paling besar  $(f + r)(x) - M\|x_M - x\|^2/2$ ; (A) memindahkan batas itu ke objektif sebenarnya. Residu yang lazim adalah  $G_M(x) = M(x - x_M)$ .

**Solusi lengkap.** Lemma penurunan menyatakan untuk semua  $y$ ,

$$f(y) \leq f(x) + \langle \nabla f(x), y - x \rangle + \frac{L}{2} \|y - x\|^2.$$

Jadi begitu urutan penggandaan mencapai  $M \geq L$ , uji (A) pasti diterima; jumlah penggandaan hingga.

Tuliskan model di dalam kurung sebagai  $Q_M(y)$ . Ia  $M$ -konveks kuat dan  $x_M$  adalah peminimumnya. Dengan memakai  $0 \in \partial Q_M(x_M)$  dalam ketaksamaan konveksitas kuat,

$$Q_M(x) \geq Q_M(x_M) + \frac{M}{2} \|x - x_M\|^2.$$

Karena  $Q_M(x) = (f + r)(x)$  dan uji (A) memberi  $(f + r)(x_M) \leq Q_M(x_M)$ , kedua ketaksamaan menghasilkan sertifikat yang diminta. Vektor  $G_M(x) = M(x - x_M)$  dapat dihitung dari langkah. Ia nol tepat bila  $x = x_M$ , yang melalui kondisi optimalitas ekuivalen dengan  $0 \in \nabla f(x) + \partial r(x)$ .

**Latihan 15.49** (KKT untuk regularisasi analisis dan kendala norma). Untuk  $\tau > 0$  dan  $R > 0$ , pertimbangkan

$$\min_x \frac{1}{2} \|Ax - b\|^2 + \tau \|x\|_1 \quad \text{dengan syarat} \quad \|Bx - d\|_2 \leq R.$$

Anggap terdapat  $\bar{x}$  dengan  $\|B\bar{x} - d\|_2 < R$ . Turunkan sistem KKT lengkap. Tuliskan subgradien norma Euclidean baik ketika  $Bx - d \neq 0$  maupun ketika  $Bx - d = 0$ , dan jelaskan mengapa sistem KKT cukup untuk optimalitas global.

**Petunjuk bertahap. Tahap 1.** Gunakan pengali  $\nu \geq 0$  untuk fungsi kendala  $q(x) = \|Bx - d\|_2 - R$ . **Tahap 2.** Terapkan aturan rantai subdiferensial pada norma dan pisahkan kasus argumen nol.

**Jawaban singkat.** Terdapat  $s \in \partial\|x\|_1$ ,  $q \in \partial\|Bx - d\|_2$ , dan  $\nu \geq 0$  sehingga

$$0 = A^T(Ax - b) + \tau s + \nu B^T q,$$

$$\|Bx - d\|_2 \leq R, \text{quad} \nu(\|Bx - d\|_2 - R) = 0.$$

Jika  $z \neq 0$ ,  $\partial\|z\|_2 = \{z/\|z\|_2\}$ ; jika  $z = 0$ , subdiferensialnya adalah bola satuan. Slater membuat KKT perlu dan, karena masalah konveks, juga cukup.

**Solusi lengkap.** Lagrangian adalah

$$\mathcal{L}(x, \nu) = \frac{1}{2}\|Ax - b\|^2 + \tau\|x\|_1 + \nu(\|Bx - d\|_2 - R).$$

Kondisi Slater yang diberikan menjamin keberadaan pengali optimal dan aturan KKT tanpa celah dual. Stationeritas adalah inklusi

$$0 \in A^T(Ax - b) + \tau\partial\|x\|_1 + \nu B^T\partial\|Bx - d\|_2.$$

Memilih  $s$  dan  $q$  dari kedua subdiferensial mengubahnya menjadi persamaan pada jawaban singkat. Secara koordinat,  $s_i = \text{sign}(x_i)$  jika  $x_i \neq 0$  dan  $s_i \in [-1, 1]$  jika  $x_i = 0$ . Untuk norma Euclidean,  $q = z/\|z\|$  saat  $z = Bx - d \neq 0$ , sedangkan sembarang  $q$  dengan  $\|q\| \leq 1$  sah saat  $z = 0$ .

Sistem dilengkapi oleh kelayakan primal, kelayakan dual  $\nu \geq 0$ , dan kelonggaran komplementer. Objektif dan fungsi kendala konveks; maka setiap pasangan yang memenuhi sistem membentuk sertifikat titik pelana Lagrangian dan memberi minimum global.

**Latihan 15.50** (Distribusi kepentingan dengan momen kedua minimum). Misalkan  $g_1, \dots, g_N$  adalah vektor tak nol yang diketahui. Untuk peluang  $p_i > 0$ ,  $\sum_i p_i = 1$ , ambil  $I \sim p$  dan  $G = g_I/(Np_I)$ . Di antara semua distribusi  $p$ , tentukan distribusi yang meminimalkan  $\mathbb{E}\|G\|^2$ , hitung nilai minimumnya, dan tulis varians minimum terhadap mean  $\bar{g} = N^{-1} \sum_i g_i$ .

**Petunjuk bertahap. Tahap 1.** Masalah skalar yang harus diminimalkan adalah  $\sum_i \|g_i\|^2/p_i$  pada simpleks. **Tahap 2.** Gunakan pengali Lagrange atau Cauchy-Schwarz, lalu kurangi  $\|\bar{g}\|^2$  dari momen kedua.

**Jawaban singkat.**

$$p_i^* = \frac{\|g_i\|}{\sum_j \|g_j\|}, \quad \min_p \mathbb{E}\|G\|^2 = \frac{1}{N^2} \left( \sum_i \|g_i\| \right)^2.$$

Varians minimumnya adalah nilai terakhir dikurangi  $\|\bar{g}\|^2$ .

**Solusi lengkap.** Ketakbiasan mengikuti dari  $\mathbb{E}G = \sum_i p_i g_i / (Np_i) = \bar{g}$ . Momen keduanya ialah

$$\mathbb{E}\|G\|^2 = \frac{1}{N^2} \sum_i \frac{\|g_i\|^2}{p_i}.$$

Cauchy-Schwarz memberi

$$\left( \sum_i \|g_i\| \right)^2 = \left( \sum_i \frac{\|g_i\|}{\sqrt{p_i}} \sqrt{p_i} \right)^2 \leq \left( \sum_i \frac{\|g_i\|^2}{p_i} \right) \left( \sum_i p_i \right).$$

Kesetaraan terjadi tepat ketika  $\|g_i\|/\sqrt{p_i}$  sebanding dengan  $\sqrt{p_i}$ , yakni  $p_i \propto \|g_i\|$ . Karena semua vektor tak nol, distribusi itu strictly positif dan layak. Substitusi memberi nilai minimum. Identitas  $\mathbb{E}\|G - \bar{g}\|^2 = \mathbb{E}\|G\|^2 - \|\bar{g}\|^2$  memberi varians yang diminta.

**Latihan 15.51** (Laju rata-rata descent cermin stokastik). Misalkan  $C$  konveks,  $h$  terdiferensialkan dan 1-konveks kuat terhadap norma  $\|\cdot\|$ , serta  $f$  konveks pada  $C$ . Dengan filtrasi  $\mathcal{F}_k$ , anggap

$$\mathbb{E}[G_k \mid \mathcal{F}_k] = g_k \in \partial f(x_k), \quad \mathbb{E}[\|G_k\|_*^2 \mid \mathcal{F}_k] \leq G^2.$$

Iterasi diberikan oleh

$$x_{k+1} \in \arg \min_{x \in C} \{\eta \langle G_k, x \rangle + D_h(x, x_k)\}.$$

Jika  $x^*$  meminimalkan  $f$  dan  $D_h(x^*, x_0) \leq D^2/2$ , buktikan untuk  $\bar{x}_K = K^{-1} \sum_{k=0}^{K-1} x_k$  dan  $\eta = D/(G\sqrt{K})$  bahwa

$$\mathbb{E}[f(\bar{x}_K) - f(x^*)] \leq \frac{DG}{\sqrt{K}}.$$

**Petunjuk bertahap.** **Tahap 1.** Dari ketaksamaan tiga titik dan konveksitas kuat  $h$ , turunkan batas satu langkah dengan suku  $\eta^2 \|G_k\|_*^2/2$ . **Tahap 2.** Ambil ekspektasi bersyarat, jumlahkan, gunakan Jensen pada  $f(\bar{x}_K)$ , lalu optimalkan langkah konstan.

**Jawaban singkat.** Ketaksamaan dasar memberi

$$\eta \mathbb{E}[f(x_k) - f(x^*)] \leq \mathbb{E}[D_h(x^*, x_k) - D_h(x^*, x_{k+1})] + \frac{\eta^2 G^2}{2}.$$

Setelah dijumlahkan dan dibagi  $\eta K$ , batasnya  $D^2/(2\eta K) + \eta G^2/2$ ; pilihan langkah yang diberikan membuatnya  $DG/\sqrt{K}$ .

**Solusi lengkap.** Optimalitas langkah cermin dan identitas tiga titik menghasilkan, untuk  $u \in C$ ,

$$\eta \langle G_k, x_{k+1} - u \rangle \leq D_h(u, x_k) - D_h(u, x_{k+1}) - D_h(x_{k+1}, x_k).$$

Tambahkan  $\eta \langle G_k, x_k - x_{k+1} \rangle$  pada kedua ruas. Karena  $D_h(x_{k+1}, x_k) \geq \|x_{k+1} - x_k\|^2/2$ , Young memberi

$$\eta \langle G_k, x_k - u \rangle \leq D_h(u, x_k) - D_h(u, x_{k+1}) + \frac{\eta^2}{2} \|G_k\|_*^2.$$

Ambil  $u = x^*$  dan ekspektasi bersyarat. Karena  $x_k$  terukur terhadap  $\mathcal{F}_k$ , ketakbiasan memberi  $\mathbb{E}[\langle G_k, x_k - x^* \rangle \mid \mathcal{F}_k] = \langle g_k, x_k - x^* \rangle \geq f(x_k) - f(x^*)$ . Maka ketaksamaan pada jawaban singkat berlaku.

Menjumlahkan untuk  $k = 0, \dots, K-1$  meneleskopkan divergensi dan memberi

$$\frac{1}{K} \sum_{k=0}^{K-1} \mathbb{E}[f(x_k) - f(x^*)] \leq \frac{D^2}{2\eta K} + \frac{\eta G^2}{2}.$$

Konveksitas dan Jensen membatasi ruas kiri dari bawah oleh  $\mathbb{E}[f(\bar{x}_K) - f(x^*)]$ . Substitusi  $\eta = D/(G\sqrt{K})$  membuat kedua suku kanan sama dengan  $DG/(2\sqrt{K})$ , sehingga hasil mengikuti.

**Latihan 15.52** (Kontraksi resolven operator monoton kuat). Misalkan  $A$  maksimal monoton dan  $\mu$ -monoton kuat dengan  $\mu > 0$ . Buktikan bahwa untuk setiap  $\gamma > 0$ ,

$$\|J_{\gamma A} x - J_{\gamma A} y\| \leq \frac{1}{1 + \gamma \mu} \|x - y\|.$$

Simpulkan bahwa  $A$  mempunyai paling banyak satu nol dan, jika nol  $x^*$  ada, iterasi  $x_{k+1} = J_{\gamma A} x_k$  konvergen linear kepadanya.

**Petunjuk bertahap.** **Tahap 1.** Tetapkan  $p = J_{\gamma A} x$ ,  $q = J_{\gamma A} y$ , lalu tulis anggota  $Ap$  dan  $Aq$  dari definisi resolven. **Tahap 2.** Terapkan monoton kuat dan Cauchy–Schwarz; kemudian ambil  $y = x^*$ .

**Jawaban singkat.** Monotoni kuat memberi

$$\langle p - q, x - y \rangle \geq (1 + \gamma\mu)\|p - q\|^2,$$

yang bersama Cauchy–Schwarz menghasilkan kontraksi. Karena  $J_{\gamma A}x^\star = x^\star$ ,

$$\|x_k - x^\star\| \leq (1 + \gamma\mu)^{-k}\|x_0 - x^\star\|.$$

**Solusi lengkap.** Dari definisi resoven,

$$\frac{x - p}{\gamma} \in Ap, \quad \frac{y - q}{\gamma} \in Aq.$$

Monotoni kuat memberikan

$$\left\langle p - q, \frac{x - p}{\gamma} - \frac{y - q}{\gamma} \right\rangle \geq \mu\|p - q\|^2.$$

Setelah dikalikan  $\gamma$  dan ditata ulang, ini menjadi ketaksamaan pada jawaban singkat. Jika  $p \neq q$ , Cauchy–Schwarz dan pembagian oleh  $\|p - q\|$  memberi batas Lipschitz; bila  $p = q$  batasnya trivial.

Jika  $u$  dan  $v$  keduanya nol  $A$ , monotoni kuat memberi  $0 \geq \mu\|u - v\|^2$ , sehingga  $u = v$ . Untuk nol yang ada,  $J_{\gamma A}x^\star = x^\star$ . Penerapan berulang faktor kontraksi  $q = (1 + \gamma\mu)^{-1} < 1$  memberi batas linear yang dinyatakan.

**Latihan 15.53** (Sinkhorn sebagai maksimisasi blok dual). Misalkan  $a_i, b_j > 0$  dan total massanya sama. Untuk  $\varepsilon > 0$ , tinjau

$$D(f, g) = a^\top f + b^\top g - \varepsilon \sum_{i,j} \exp\left(\frac{f_i + g_j - C_{ij}}{\varepsilon}\right).$$

Buktikan bahwa, dengan  $g$  tetap, pemaksimal unik terhadap setiap  $f_i$  adalah

$$f_i = \varepsilon \log a_i - \varepsilon \log \sum_j \exp\left(\frac{g_j - C_{ij}}{\varepsilon}\right),$$

dan turunkan pembaruan analog untuk  $g_j$ . Simpulkan bahwa penskalaan Sinkhorn adalah maksimisasi koordinat blok eksak dan nilai dual tidak menurun pada setiap setengah langkah. Jelaskan ketidaktunggalan bersama akibat gauge.

**Petunjuk bertahap.** **Tahap 1.** Nolkan turunan parsial terhadap satu  $f_i$  dan periksa tanda turunan keduanya. **Tahap 2.** Ulangi untuk  $g_j$  dan amati transformasi  $(f, g) \mapsto (f + c\mathbb{1}, g - c\mathbb{1})$ .

**Jawaban singkat.** Persamaan stasioner blok  $f$  ialah

$$a_i = \sum_j \exp((f_i + g_j - C_{ij})/\varepsilon),$$

yang memberi rumus pada soal; rumus blok  $g$  diperoleh dengan menukar baris dan kolom. Setiap turunan kedua blok negatif, jadi pembaruan adalah maksimum unik dan tidak menurunkan  $D$ . Pasangan bersama hanya unik hingga penambahan konstanta pada  $f$  dan pengurangan konstanta yang sama pada  $g$ .

**Solusi lengkap.** Untuk  $g$  tetap,

$$\frac{\partial D}{\partial f_i} = a_i - \sum_j \exp((f_i + g_j - C_{ij})/\varepsilon).$$

Menetapkannya nol dan mengeluarkan faktor  $\exp(f_i/\varepsilon)$  memberi rumus eksplisit pada soal. Turunan kedua adalah

$$-\frac{1}{\varepsilon} \sum_j \exp((f_i + g_j - C_{ij})/\varepsilon) < 0,$$

dan tidak ada suku silang antara  $f_i$  yang berlainan ketika  $g$  tetap. Jadi rumus itu adalah pemaksimal blok unik. Secara simetris,

$$g_j = \varepsilon \log b_j - \varepsilon \log \sum_i \exp\left(\frac{f_i - C_{ij}}{\varepsilon}\right).$$

Mengganti satu blok dengan pemaksimal eksaknya tidak dapat menurunkan nilai fungsi dual. Dalam variabel skala eksponensial, kedua rumus adalah pembaruan baris dan kolom Sinkhorn.

Jika  $f$  ditambah  $c\mathbb{1}$  dan  $g$  dikurangi  $c\mathbb{1}$ , semua jumlah  $f_i + g_j$  tetap. Suku linear juga tetap karena total massa  $a$  dan  $b$  sama. Jadi nilai dual dan kopling tidak berubah; inilah kebebasan gauge yang membuat pemaksimal pasangan tidak tunggal sebelum normalisasi.

**Latihan 15.54** (Pemilihan pemisahan untuk model stokastik terstruktur). Pertimbangkan

$$\min_{x \in C} s(x) + \tau \|Wx\|_1, \quad s(x) = \mathbb{E}_\xi[\ell_\xi(A_\xi x - b_\xi)],$$

dengan  $C = \{x : \|x\|_2 \leq R\}$ ,  $\tau > 0$ , dan  $s$  konveks terdiferensialkan. Tuliskan inklusi optimalitas primal dan sistem primal–dual dengan variabel  $y$  untuk suku  $\ell^1$ . Bandingkan kapan gradien proksimal stokastik langsung layak dipakai dan kapan pemisahan primal–dual lebih sesuai. Berikan sepasang residu KKT dan asumsi orakel minimum yang diperlukan untuk klaim konvergensi stokastik.

**Petunjuk bertahap.** **Tahap 1.** Gabungkan  $\partial(\tau\|W\cdot\|_1)$  dengan kerucut normal  $N_C$ , lalu gunakan aturan rantai melalui  $W^\top$ . **Tahap 2.** Bandingkan proksimal gabungan dengan proyeksi ke  $C$  dan proksimal konjugat norma  $\ell^1$  yang dapat dihitung secara terpisah.

**Jawaban singkat.** Optimalitas ekuivalen dengan keberadaan  $y$  sehingga

$$0 \in \nabla s(x) + W^\top y + N_C(x), \quad y \in \tau \partial\|Wx\|_1.$$

Gradien proksimal langsung sesuai bila  $\text{prox}_{\eta(\tau\|W\cdot\|_1 + \delta_C)}$  mudah; pemisahan primal–dual sesuai bila hanya proyeksi ke  $C$  dan proyeksi dual ke bola  $\ell^\infty$  yang mudah. Residu dapat berupa jarak kedua inklusi ke nol. Orakel harus tidak bias secara bersyarat, bermomen kedua terkendali, dan langkah harus memenuhi syarat penjumlahan yang sesuai.

**Solusi lengkap.** Dengan aturan rantai konveks,

$$\partial(\tau\|W\cdot\|_1)(x) = W^\top(\tau\partial\|Wx\|_1).$$

Karena kendala ditulis sebagai indikator  $\delta_C$ , syarat Fermat adalah

$$0 \in \nabla s(x) + W^\top(\tau\partial\|Wx\|_1) + N_C(x).$$

Memperkenalkan  $y \in \tau\partial\|Wx\|_1$  menghasilkan sistem pada jawaban singkat. Secara ekuivalen,  $Wx \in \partial(\tau\|\cdot\|_1)^*(y)$ , dan fungsi konjugat itu adalah indikator bola  $\{y : \|y\|_\infty \leq \tau\}$ .

Jika proksimal gabungan  $\tau\|W\cdot\|_1 + \delta_C$  tersedia dalam bentuk tertutup atau dapat dihitung murah, langkah gradien proksimal stokastik memisahkan bagian halus  $s$  secara langsung. Untuk  $W$  umum, proksimal gabungan biasanya tidak terurai menjadi penyusutan lunak lalu proyeksi. Metode primal–dual menjaga  $Wx$  sebagai operator linear dan hanya membutuhkan proyeksi ke bola  $C$  serta proyeksi  $y$  ke bola  $\ell^\infty$  berjari-jari  $\tau$ ; karena itu ia lebih sesuai pada keadaan tersebut.

Satu pasangan residu matematis adalah

$$r_p(x, y) = \text{dist}(0, \nabla s(x) + W^\top y + N_C(x)),$$

$$r_d(x, y) = \text{dist}(Wx, \partial(\tau\|\cdot\|_1)^*(y)),$$

dengan nilai tak hingga bila  $y$  berada di luar domain konjugat. Keduanya nol tepat pada pasangan KKT. Untuk analisis stokastik, penduga gradien  $G_k$  sekurang-kurangnya harus memenuhi  $\mathbb{E}[G_k \mid \mathcal{F}_k] = \nabla s(x_k)$  dan batas momen kedua atau varians yang sesuai. Pada skema Robbins–Monro dasar, langkah positif lazimnya memenuhi  $\sum_k \eta_k = \infty$  dan  $\sum_k \eta_k^2 < \infty$ ; klaim laju dengan langkah tetap memerlukan asumsi tambahan seperti reduksi varians atau menerima lantai galat. Norma operator  $W$  juga harus masuk ke batas langkah primal–dual, bukan diabaikan.

## 15.12 Laboratorium 3: kegagalan lokal dan globalisasi Newton

Laboratorium ini memperlihatkan bahwa arah yang tampak “orde dua” belum tentu aman secara global. Kita memakai fungsi konveks mulus

$$F(x, y) = \log(\cosh x) + \frac{1}{2}y^2, \quad \nabla F(x, y) = \begin{pmatrix} \tanh x \\ y \end{pmatrix}, \quad \nabla^2 F(x, y) = \begin{pmatrix} \operatorname{sech}^2 x & 0 \\ 0 & 1 \end{pmatrix}. \quad (15.1)$$

Minimum uniknya adalah  $(0, 0)$  dengan nilai nol. Walaupun Hessian selalu positif, kelengkungan pada arah  $x$  sangat kecil ketika  $|x|$  besar. Karena itu, langkah Newton penuh dari titik awal yang disediakan dapat melompat ke daerah dengan nilai objektif jauh lebih tinggi. Contoh ini memisahkan dua persoalan: pemilihan arah dan pemilihan panjang langkah.

Kode tetap berada di `labs/original-03/globalisasi-newton.py`. Dengan seed dan konfigurasi yang dibekukan, kode membandingkan empat metode:

- (i) gradien dengan langkah tetap yang sengaja terlalu besar;
- (ii) gradien dengan pencarian balik Armijo;
- (iii) Newton murni dengan langkah penuh;
- (iv) Newton teredam dengan Hessian terkoreksi  $B_k = \nabla^2 F(z_k) + \tau_k I$ , dengan  $\lambda_{\min}(B_k) \geq \underline{\mu}$ .

Jejak lengkap ditulis ke CSV, ringkasan dan sertifikat ditulis ke JSON, dan SVG hanya memvisualkan data yang sama. Tidak ada kesimpulan numerik yang bergantung pada grafik.

### Prompt

**Latihan 15.55** (Tugas laboratorium). Jalankan skrip sekali dan kerjakan hal-hal berikut.

- (i) Turunkan langkah Newton murni pada koordinat  $x$  dan jelaskan mengapa  $x_0 \approx 3$  menghasilkan lompatan besar walaupun fungsi konveks.
- (ii) Dari jejak CSV, temukan kenaikan objektif pertama bagi Newton murni dan kegagalan metode gradien berlangkah tetap.
- (iii) Buktikan bahwa syarat Armijo

$$F(z_k + \alpha_k d_k) \leq F(z_k) + c_1 \alpha_k \nabla F(z_k)^\top d_k$$

menghasilkan penurunan ketat bila  $d_k$  adalah arah turun.

- (iv) Buktikan bahwa koreksi  $\tau_k = \max\{0, \underline{\mu} - \lambda_{\min}(\nabla^2 F(z_k))\}$  membuat  $d_k = -B_k^{-1} \nabla F(z_k)$  menjadi arah turun selama gradien tidak nol.
- (v) Cocokkan bukti Anda dengan seluruh boolean sertifikat dalam JSON dan jelaskan mengapa “gagal” di sini merupakan bukti terkontrol, bukan galat program.

### Petunjuk bertahap

- (i) Gunakan  $\operatorname{sech}^2 x = 1 - \tanh^2 x$  dan tulis  $x^+ = x - \tanh(x)/\operatorname{sech}^2(x)$ .
- (ii) Bandingkan kolom `objective` pada dua baris berturutan; jangan menyimpulkan kegagalan hanya dari gambar.
- (iii) Pada ruas kanan Armijo, tanda  $\nabla F(z_k)^\top d_k < 0$  adalah fakta penentu.
- (iv) Gunakan  $B_k \succeq \underline{\mu} I$  untuk menunjukkan  $\nabla F(z_k)^\top d_k = -g_k^\top B_k^{-1} g_k < 0$ .
- (v) Periksa juga bahwa semua langkah metode teredam diterima oleh Armijo dan nilai objektifnya monoton menurun.

## Jawaban singkat

Newton murni gagal karena invers kelengkungan  $1/\text{sech}^2(x_0)$  sangat besar. Langkah gradien tetap gagal karena faktor koordinat kuadratnya adalah  $1 - \alpha = -1.5$ . Pencarian balik memendekkan langkah sampai memenuhi penurunan cukup. Koreksi Hessian menjamin arah turun, sedangkan Armijo mengglobalisasi panjang langkah; kombinasi keduanya mencapai toleransi gradien yang dibekukan.

## Solusi acuan lengkap

Pada koordinat pertama, Newton murni memberi

$$x^+ = x - \frac{\tanh x}{\text{sech}^2 x} = x - \sinh x \cosh x.$$

Untuk  $x \approx 3$ , suku  $\sinh x \cosh x$  berorde  $10^2$ , sehingga iterasi melompat melintasi minimizer dan menaikkan  $\log(\cosh x)$ . Pada iterasi berikutnya  $\text{sech}^2 x$  mendekati nol pada presisi mesin; skrip berhenti sebelum pembagian hampir singular merusak jejak. Untuk gradien tetap pada koordinat kedua berlaku  $y^+ = (1 - 2.5)y = -1.5y$ , jadi magnitudonya tumbuh geometrik.

Untuk arah gradien  $d = -g$ , kita memiliki  $g^\top d = -\|g\|^2 < 0$ . Karena  $F$  diferensiabel, terdapat  $\bar{\alpha} > 0$  sehingga setiap  $0 < \alpha \leq \bar{\alpha}$  memenuhi Armijo; pencarian balik dengan faktor dalam  $(0, 1)$  karena itu berhenti dalam banyak langkah berhingga. Untuk arah Newton terkoreksi, konstruksi  $B_k \succeq \mu I$  memberi

$$g_k^\top d_k = -g_k^\top B_k^{-1} g_k \leq -\frac{\|g_k\|^2}{\lambda_{\max}(B_k)} < 0.$$

Maka argumen pencarian balik yang sama berlaku. Sertifikat program memeriksa langsung batas eigenvalue, tanda turunan arah, semua penerimaan Armijo, monotonisitas objektif, dan norma gradien akhir. Sebaliknya, metode yang tidak diglobalisasi diwajibkan memperlihatkan kenaikan atau ledakan yang telah ditentukan; dengan demikian jalur gagal merupakan bagian dari eksperimen.

**Hak dan firewall O018.** Teks, soal, solusi, dan kode laboratorium ini ditulis mandiri untuk lapisan Original-03 dan tersedia berdasarkan CC BY-SA 4.0. Tidak ada prosa, soal, solusi, kode, atau susunan pedagogis O018 yang disalin atau diadaptasi; O018 tetap merupakan korpus terpisah.

## 15.13 Laboratorium 4: Sinkhorn log-domain dan sertifikat transportasi

Diberikan histogram positif  $a \in \mathbb{R}^m, b \in \mathbb{R}^n$  dengan  $\mathbb{1}^\top a = \mathbb{1}^\top b = 1$  dan matriks biaya  $C$ , masalah transportasi teratur-entropi yang dipakai di sini adalah

$$\min_{P \mathbb{1}=a, P^\top \mathbb{1}=b, P \geq 0} \langle C, P \rangle + \varepsilon \sum_{ij} P_{ij} (\log P_{ij} - 1). \quad (15.2)$$

Representasi langsung  $K_{ij} = \exp(-C_{ij}/\varepsilon)$  rentan underflow. Skrip `labs/original-03/transportasi-entropik.py` menyimpan potensial dual  $f, g$  dan melakukan pembaruan dengan `logsumexp`. Kopling dibentuk hanya dari

$$\log P_{ij} = \frac{f_i + g_j - C_{ij}}{\varepsilon}.$$

Eksperimen utama memakai titik dan massa yang dihasilkan oleh seed tetap. Dua eksperimen ekuivalen kemudian dijalankan: (i)  $C$  dan  $\varepsilon$  dikalikan faktor positif yang sama; (ii) konstanta besar ditambahkan ke semua entri  $C$ . Transformasi pertama mempertahankan rasio biaya-entropi, sedangkan transformasi kedua menambah konstanta pada nilai objektif tanpa mengubah minimizer. Kasus kedua memaksa seluruh kernel naif menjadi nol, tetapi pembaruan log-domain tetap menghasilkan kopling yang sama.

## Prompt

- Latihan 15.56** (Tugas laboratorium). (i) Turunkan pembaruan bergantian bagi  $f$  dan  $g$  dari kendala marginal.
- (ii) Buktikan bentuk dual dan identitas celah primal-dual yang diperiksa skrip.
- (iii) Verifikasi dari CSV bahwa setiap entri kopling utama positif dan bahwa jumlah baris serta kolom cocok dengan  $a$  dan  $b$  dalam toleransi.
- (iv) Buktikan invariansi kopling ketika  $(C, \varepsilon)$  diganti dengan  $(sC, s\varepsilon)$ ,  $s > 0$ .
- (v) Jelaskan mengapa  $C \mapsto C + \gamma \mathbb{1} \mathbb{1}^\top$  tidak mengubah kopling, lalu cocokkan dengan uji underflow terkontrol.

## Petunjuk bertahap

- (i) Ambil log dari persamaan  $P_{ij} = \exp((f_i + g_j - C_{ij})/\varepsilon)$  dan selesaikan satu potensial ketika potensial lain dibekukan.
- (ii) Gunakan konjugat dari  $p \mapsto \varepsilon p(\log p - 1)$ , yaitu  $q \mapsto \varepsilon \exp(q/\varepsilon)$ .
- (iii) Jangan menjumlahkan kernel naif pada uji stres; periksa penghitung nol dan residual hasil log-domain secara terpisah.
- (iv) Untuk penskalaan, pilih potensial baru  $(sf, sg)$ .
- (v) Untuk penambahan konstanta, serap  $\gamma$  ke salah satu potensial.

## Jawaban singkat

Pembaruan log-domain menormalkan satu marginal pada satu waktu tanpa pernah membentuk kernel kecil. Dualnya adalah

$$\max_{f,g} a^\top f + b^\top g - \varepsilon \sum_{ij} \exp((f_i + g_j - C_{ij})/\varepsilon).$$

CSV dan JSON membuktikan residual marginal, positività numerik, kesepakatan primal-dual, invariansi penskalaan, invariansi pergeseran biaya, dan pemulihan dari kasus ketika kernel naif seluruhnya underflow.

## Solusi acuan lengkap

Untuk  $g$  tetap, kendala baris memberi

$$a_i = \sum_j \exp((f_i + g_j - C_{ij})/\varepsilon), \quad f_i = \varepsilon [\log a_i - \text{LSE}_j((g_j - C_{ij})/\varepsilon)].$$

Rumus bagi  $g_j$  analog dari kendala kolom. Konjugasi entropi menghasilkan dual pada jawaban singkat. Jika  $P$  dibentuk dari potensial, nilai primal

$$p = \langle C, P \rangle + \varepsilon \sum_{ij} P_{ij}(\log P_{ij} - 1)$$

dan nilai dual

$$d = a^\top f + b^\top g - \varepsilon \sum_{ij} P_{ij}$$

berimpit pada optimum; program memeriksa  $|p - d|$ .

Jika  $C' = sC$  dan  $\varepsilon' = s\varepsilon$ , potensial  $f' = sf$ ,  $g' = sg$  memberi log-kopling yang persis sama. Jika  $C' = C + \gamma \mathbb{1} \mathbb{1}^\top$ , pilih  $f' = f + \gamma \mathbb{1}$  dan  $g' = g$ ; sekali lagi log-kopling tidak berubah. Namun kernel naif memuat faktor  $\exp(-\gamma/\varepsilon)$  dan dapat menjadi nol pada aritmetika floating point. Potensial log-domain menyerap konstanta sebelum eksponensiasi akhir, sehingga residual marginal, positività kopling utama, dan kesepakatan dengan dua masalah ekuivalen tetap dapat diperiksa.

**Hak dan firewall O018.** Teks, soal, solusi, dan kode ini merupakan material baru CC BY-SA 4.0. Tidak ada byte, prosa, latihan, solusi, kode, atau struktur instruksional O018 yang digunakan; peran laboratorium ini terbatas pada penutupan komputasional Original-03.

## 15.14 Proyek kapstone: masalah invers komposit yang tahan pencilan

Proyek ini menyatukan pemodelan konveks, gradien Lipschitz, operator proksimal, formulasi dual, pemisahan primal-dual, anggaran oracle, dan sertifikat a posteriori. Instans tetap dibentuk oleh `labs/original-03/kapstone-invers-komposit.py`: matriks  $A \in \mathbb{R}^{72 \times 48}$ , sinyal renggang  $x^b$ , derau kecil, dan delapan pencilan besar. Modelnya

$$\min_x \Phi(x) := \sum_{i=1}^{72} h_\delta((Ax - b)_i) + \lambda \|x\|_1, \quad h_\delta(r) = \begin{cases} \frac{1}{2}r^2, & |r| \leq \delta, \\ \delta(|r| - \frac{1}{2}\delta), & |r| > \delta. \end{cases} \quad (15.3)$$

FISTA dengan restart gradien dan PDHG dijalankan untuk jumlah iterasi yang sama. Setiap iterasi inti masing-masing memakai satu aplikasi  $A$  dan satu aplikasi  $A^\top$ , sehingga perbandingan memakai anggaran operator yang sama. Jejak CSV mencatat objektif, batas bawah dual layak, celah tersertifikasi, dan galat rekonstruksi. SVG hanya merupakan visualisasi jejak tersebut.

### Prompt

**Latihan 15.57** (Tugas proyek dan tujuh tonggak). Selesaikan tujuh tonggak berikut dan serahkan uraian matematis bersama JSON, CSV, serta SVG yang dihasilkan tanpa perubahan konfigurasi.

- (i) **Instans dan pencilan.** Rekonstruksi instans dari seed, verifikasi ukuran, support sinyal, dan delapan indeks pencilan.
- (ii) **Model konveks.** Buktikan kekonveksan (15.3) dan jelaskan mengapa Huber lebih tahan pencilan daripada kuadrat murni.
- (iii) **Bagian mulus.** Turunkan gradien  $A^\top \text{clip}(Ax - b, -\delta, \delta)$  dan batas Lipschitz  $L = \|A\|_2^2$ .
- (iv) **Langkah proksimal.** Turunkan soft-threshold bagi  $\lambda\|x\|_1$  dan tulis iterasi FISTA yang dipakai.
- (v) **Dual dan PDHG.** Turunkan konjugat Huber, kendala dual, serta pembaruan PDHG; buktikan  $\tau\sigma\|A\|_2^2 < 1$ .
- (vi) **Anggaran sepadan.** Bandingkan kedua metode pada jumlah perkalian matriks-vektor yang sama, bukan pada waktu dinding.
- (vii) **Sertifikat dan interpretasi.** Verifikasi kelayakan dual, celah primal-dual, pemetaan gradien proksimal, dan perbaikan terhadap least squares; nyatakan juga apa yang tidak dibuktikan eksperimen ini.

### Petunjuk bertahap

- (i) Hash matriks dan data dalam JSON adalah identitas instans, bukan pengganti pemeriksaan ukuran dan seed.
- (ii) Turunan Huber adalah proyeksi skalar ke  $[-\delta, \delta]$  dan bersifat satu-Lipschitz.
- (iii) Komposisi dengan  $A$  mengalikan konstanta Lipschitz oleh  $\|A\|_2^2$ .
- (iv) Gunakan  $\text{prox}_{t\lambda\|\cdot\|_1}(v) = \text{sign}(v)(|v| - t\lambda)_+$ .
- (v) Konjugat Huber adalah  $\frac{1}{2}u^2 + \iota_{[-\delta, \delta]}(u)$ ; konjugat norma satu menghasilkan kendala  $\|A^\top u\|_\infty \leq \lambda$ .
- (vi) Kolom `matrix_vector_products` adalah sumbu perbandingan yang benar.
- (vii) Skala kandidat dual bila perlu untuk memperoleh batas bawah yang benar-benar layak sebelum menghitung celah.

## Jawaban singkat

Model adalah jumlah fungsi konveks. Bagian Huber mulus memiliki gradien  $L$ -Lipschitz dengan  $L = \|A\|_2^2$ , dan bagian norma satu memiliki proksimal soft-threshold. Dualnya memaksimalkan

$$-b^\top u - \frac{1}{2}\|u\|^2 \quad \text{dengan} \quad \|u\|_\infty \leq \delta, \quad \|A^\top u\|_\infty \leq \lambda.$$

FISTA dan PDHG mencapai objektif yang cocok pada anggaran operator sama; batas dual layak memberi celah terukur, dan kedua rekonstruksi mengungguli least squares pada instans berpencilan yang dibekukan.

## Solusi acuan lengkap

Karena  $h_\delta$  dan norma satu konveks, komposisi afin dan penjumlahan mempertahankan kekonveksan. Turunan Huber adalah  $h'_\delta(r) = \text{clip}(r, -\delta, \delta)$ . Proyeksi ini satu-Lipschitz, sehingga

$$\|\nabla f(x) - \nabla f(y)\| \leq \|A\|_2^2 \|x - y\|.$$

Langkah  $t < 1/L$  yang dibekukan karena itu sah. Optimalisasi proksimal skalar memberi soft-threshold, lalu ekstrapolasi Nesterov menghasilkan FISTA; restart gradien memakai vektor yang sudah tersedia tanpa mengubah dua aplikasi operator inti per iterasi.

Dari  $h_\delta^*(u) = \frac{1}{2}u^2 + \iota_{[-\delta, \delta]}(u)$  dan  $(\lambda \|\cdot\|_1)^*(v) = \iota_{\{\|v\|_\infty \leq \lambda\}}(v)$ , dual yang tertulis pada jawaban singkat mengikuti melalui Fenchel–Rockafellar. Proksimal  $h_\delta^*$  adalah pembagian oleh  $1 + \sigma$  diikuti kliping ke  $[-\delta, \delta]$ ; proksimal primal tetap soft-threshold. Pilihan  $\tau = \sigma = 0.99/\|A\|_2$  memberi  $\tau\sigma\|A\|_2^2 = 0.99^2 < 1$ .

Pada iterasi berhingga, kandidat dual dapat melanggar kendala kedua sedikit. Penskalaan

$$\hat{u} = \rho u, \quad \rho = \min \left\{ 1, \frac{\lambda}{\|A^\top u\|_\infty} \right\}$$

mempertahankan kendala kotak dan memastikan kelayakan. Nilai dual  $-b^\top \hat{u} - \|\hat{u}\|^2/2$  menjadi batas bawah rigor bagi objektif primal. Program menguji kelayakan, celah terhadap batas terbaik, norma pemetaan gradien proksimal FISTA, kesamaan anggaran, kedekatan kedua objektif, dan galat rekonstruksi terhadap baseline least squares. Bukti ini berlaku untuk instans dan toleransi yang dinyatakan; ia tidak mengklaim bahwa parameter yang sama optimal bagi semua masalah invers atau semua pola pencilan.

**Hak dan firewall O018.** Proyek, bukti, soal, solusi, kode, dan instans sintetik ini ditulis mandiri dan tersedia berdasarkan CC BY-SA 4.0. Tidak ada materi O018 yang disalin, diadaptasi, atau dijadikan templat tersembunyi; O018 tetap terpisah dari lapisan penutupan Original-03.

# Referensi

- Beck, A. (2017). *First-Order Methods in Optimization*. SIAM.
- Chambolle, A. and T. Pock (2011). ?A First-Order Primal-Dual Algorithm for Convex Problems with Applications to Imaging? in *Journal of Mathematical Imaging and Vision*: 40.1, **pages** 120–145.
- Villani, C. (2009). *Optimal Transport: Old and New*. **volume** 338. Grundlehren der mathematischen Wissenschaften. Springer Berlin, Heidelberg. DOI: [10.1007/978-3-540-71050-9](https://doi.org/10.1007/978-3-540-71050-9).