

OPTIMISASI LANJUT DAN ANALISIS KONVEKS

TRANCHE ASLI 1: METODE STOKASTIK KOMPOSIT, CERMIN, DAN MINIBATCH
EDISI BAHASA INDONESIA

Lapisan penyelesaian kursus mandiri

Versi kerja 25 Agustus 2026

Materi asli untuk menutup kesenjangan kurikulum Oo15/D9o.

Teks dan laboratorium baru: CC BY-SA 4.o; kelas dan makro: CC BY 4.o.

Rujukan matematis tidak menyiratkan penyusunan, pemeriksaan, persetujuan, sponsor, atau dukungan oleh penulis maupun institusi yang dirujuk.

TENTANG TRANCHE INI

Tranche ini adalah lapisan penghubung mandiri setelah tulang punggung Habring dan tiga modul Becker yang diterima. Ia bukan terjemahan terselubung dari satu sumber lain. Definisi, teorema, bukti, algoritma, latihan, petunjuk, solusi, dan laboratorium ditulis secara mandiri, lalu diperiksa terhadap sumber matematis yang disebutkan di akhir bab.

Peran tranche ini terbatas dan dapat diuji: menghubungkan operator proksimal dengan oracle stokastik; membuktikan pengurangan varians minibatch dengan dan tanpa penggantian; mengembangkan penurunan cermin stokastik dalam geometri Bregman; serta menempatkan penaksir SAGA yang telah diterima ke dalam langkah proksimal komposit tanpa mengklaim teorema yang belum dibuktikan.

Tidak ada prosa matematis, gambar, latihan, solusi, atau kode laboratorium pihak ketiga yang disalin. Infrastruktur pembaca memakai salinan persis `shinybook.cls` yang dibundel dengan sumber Habring dan adaptasi Indonesia `macros-id.tex` dari `macros.tex` milik Habring; keduanya dipertahankan berdasarkan bukti lisensi CC BY 4.0 pada tingkat kiriman arXiv dan tidak dilisensikan ulang sebagai CC BY-SA; `shinybook.cls` sendiri tidak memuat pemberitahuan lisensi terpisah. Prakata sumber Habring mengakui templat Christian Clason, dan kredit tersebut dipertahankan di sini. Catatan Royer berlisensi CC BY-NC 4.0 dan material sumber lain mempertahankan hak masing-masing; semuanya dipakai hanya sebagai saksi verifikasi dan rujukan matematis. Seluruh teks substantif dan kode laboratorium baru tranche ini tersedia berdasarkan CC BY-SA 4.0. Ini adalah edisi mandiri dan tidak menyiratkan dukungan pihak yang dirujuk.

Provenans produksi dan QA: OpenAI Codex gpt-5.6-sol, Ultra, atas instruksi pengguna repositori. Seluruh kredit penulis dan kontributor manusia pada sumber pendamping tetap dipertahankan.

DAFTAR ISI

1	METODE STOKASTIK KOMPOSIT, CERMEN, DAN MINIBATCH	1
1.1	Masalah komposit dan oracle stokastik	1
1.2	Gradien proksimal stokastik	2
1.3	Minibatch: identitas varians dan biaya oracle	3
1.4	Penurunan cermin stokastik	4
1.5	Dari SAGA ke pembaruan proksimal	6
1.6	Laboratorium 1: regresi renggang dengan biaya oracle tetap	7
1.7	Latihan, petunjuk, dan solusi lengkap	8
1.8	Peta asumsi dan batas klaim	11

1 METODE STOKASTIK KOMPOSIT, CERMIN, DAN MINIBATCH

Bab ini mengisi penghubung yang belum tersedia di tulang punggung Habring dan tiga modul Becker yang telah diterima. Habring telah mengembangkan operator proksimal, gradien proksimal deterministik, dan subgradien stokastik terproyeksi. Modul Becker 3 telah membuktikan ketakbiasan penaksir SAGA dan identitas varians tabelnya. Yang masih diperlukan ialah satu kerangka yang menjelaskan bagaimana operator proksimal, geometri non-Euklides, pengambilan sampel minibatch, dan reduksi varians saling terhubung.

Seluruh rumusan, bukti penghubung, latihan, petunjuk, solusi, dan laboratorium dalam bab ini ditulis secara mandiri. Catatan Habring, catatan gradien stokastik Clément W. Royer, modul Becker 3, serta rujukan penelitian pada akhir bab dipakai untuk memeriksa istilah, batas teori, dan konteks; tidak ada prosa, tata letak, gambar, atau kode mereka yang disalin.

Kita memakai norma $\|\cdot\|$ pada ruang berdimensi hingga dan norma dual

$$(1.1) \quad \|y\|_* = \sup_{\|x\| \leq 1} \langle y, x \rangle.$$

Untuk bagian proksimal dan minibatch, norma tersebut adalah norma Euklides. Filtrasi $\mathcal{F}_k$ memuat seluruh informasi sebelum oracle pada iterasi k dipanggil. Dengan demikian, x_k terukur terhadap $\mathcal{F}_k$.

1.1 MASALAH KOMPOSIT DAN ORACLE STOKASTIK

Pertimbangkan masalah komposit

$$(1.2) \quad \min_{x \in \mathbb{R}^d} F(x), \quad F(x) = f(x) + g(x),$$

dengan $f : \mathbb{R}^d \rightarrow \mathbb{R}$ konveks, terdiferensialkan, dan mempunyai gradien L -Lipschitz, sedangkan $g : \mathbb{R}^d \rightarrow (-\infty, +\infty]$ proper, konveks, dan semikontinu bawah. Andaikan himpunan peminim $X^* = \arg \min F$ tidak kosong.

Oracle pada x_k mengembalikan G_k dan memenuhi, hampir pasti,

$$(1.3) \quad \mathbb{E}[G_k \mid \mathcal{F}_k] = \nabla f(x_k), \quad \mathbb{E}[\|G_k - \nabla f(x_k)\|^2 \mid \mathcal{F}_k] \leq v_k^2.$$

Besaran v_k^2 boleh berubah sepanjang iterasi. Notasi ini sengaja memisahkan varians oracle dari konstanta kemulusan L dan dari fungsi kerugian ℓ pada model statistik.

1.2 GRADIEN PROKSIMAL STOKASTIK

Dengan ukuran langkah $\tau_k > 0$, pembaruan gradien proksimal stokastik ialah

$$(1.4) \quad x_{k+1} = \text{prox}_{\tau_k g}(x_k - \tau_k G_k).$$

Jika $g = \delta_C$ adalah fungsi indikator himpunan konveks tertutup C , pembaruan ini menjadi proyeksi stokastik. Jika $g(x) = \lambda\|x\|_1$, pembaruan ini menjadi ambang lunak setelah langkah gradien stokastik.

Algoritma 1: gradien proksimal stokastik. Pilih $x_0 \in \text{dom } g$. Untuk $k = 0, 1, \dots$, panggil oracle pada x_k untuk memperoleh G_k , pilih τ_k , lalu hitung (1.4). Untuk pelaporan ergodik, simpan rerata iterat yang disebutkan dalam teorema berikut.

Lema 1.1 (Ketaksamaan satu langkah). Ambil $x \in \text{dom } g$ dan tetapkan $\tau_k = \tau$ dengan $0 < \tau \leq (2L)^{-1}$. Di bawah (1.3), iterasi (1.4) memenuhi

$$(1.5) \quad \mathbb{E}[F(x_{k+1}) - F(x) \mid \mathcal{F}_k] \leq \frac{\|x_k - x\|^2 - \mathbb{E}[\|x_{k+1} - x\|^2 \mid \mathcal{F}_k]}{2\tau} + \tau v_k^2.$$

Bukti. Tuliskan $x^+ = x_{k+1}$, $s = x^+ - x_k$, dan $\delta_k = G_k - \nabla f(x_k)$. Kondisi optimalitas proks memberikan

$$(1.6) \quad \frac{x_k - x^+}{\tau} - G_k \in \partial g(x^+).$$

Ketaksamaan subgradien untuk g , kekonveksan f , dan lemma penurunan untuk f yang L -mulus menghasilkan

$$(1.7) \quad F(x^+) - F(x) \leq \frac{\|x_k - x\|^2 - \|x^+ - x\|^2}{2\tau} - \frac{1 - L\tau}{2\tau} \|s\|^2 - \langle \delta_k, x^+ - x \rangle.$$

Pecah suku terakhir sebagai $-\langle \delta_k, s \rangle - \langle \delta_k, x_k - x \rangle$. Karena $x_k - x$ terukur terhadap $\mathcal{F}_k$ dan $\mathbb{E}[\delta_k \mid \mathcal{F}_k] = 0$, suku kedua hilang dalam ekspektasi bersyarat. Untuk suku pertama, maksimisasi kuadrat atau ketaksamaan Young memberi

$$(1.8) \quad -\langle \delta_k, s \rangle - \frac{1 - L\tau}{2\tau} \|s\|^2 \leq \frac{\tau}{2(1 - L\tau)} \|\delta_k\|^2 \leq \tau \|\delta_k\|^2,$$

dengan ketaksamaan terakhir menggunakan $\tau L \leq 1/2$. Mengambil ekspektasi bersyarat membuktikan klaim. $\square$

Teorema 1.2 (Batas ergodik proksimal stokastik). *Andaikan $v_k^2 \leq \sigma^2/b$ untuk semua k , dengan $b \geq 1$. Ambil $x^* \in X^*$, $0 < \tau \leq (2L)^{-1}$, dan definisikan*

$$(1.9) \quad \bar{x}_K = \frac{1}{K} \sum_{k=0}^{K-1} x_{k+1}.$$

Maka, untuk $K \geq 1$,

$$(1.10) \quad \mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau\sigma^2}{b}.$$

Bukti. Terapkan Lema 1.1 dengan $x = x^*$, ambil ekspektasi penuh, lalu jumlahkan untuk $k = 0, \dots, K-1$. Suku jarak meneleskop dan suku terakhir yang tidak negatif dapat dibuang. Kekonveksan F memberi $F(\bar{x}_K) \leq K^{-1} \sum_{k=0}^{K-1} F(x_{k+1})$, yang menyelesaikan bukti. $\square$

Jika $R = \|x_0 - x^*\| > 0$, $\sigma > 0$, dan batas kemulusan tidak aktif, pilihan yang menyeimbangkan kedua suku pada (1.10) ialah

$$(1.11) \quad \tau = R \sqrt{\frac{b}{2\sigma^2 K}}, \quad \mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\sqrt{2}R\sigma}{\sqrt{bK}}.$$

Dalam praktik, R dan σ biasanya tidak diketahui. Rumus ini adalah penjelas skala, bukan resep penalaan tanpa diagnosis.

1.3 MINIBATCH: IDENTITAS VARIANS DAN BIAYA ORACLE

Ambil b sampel bersyarat iid $G_{k,1}, \dots, G_{k,b}$ dengan rerata $\nabla f(x_k)$ dan varians kuadrat paling besar σ^2 . Penaksir minibatch dengan penggantian adalah

$$(1.12) \quad \widehat{G}_k^{(b)} = \frac{1}{b} \sum_{j=1}^b G_{k,j}.$$

Proposisi 1.3 (Penyusutan varians dengan penggantian). Penaksir (1.12) tak bias dan memenuhi

$$(1.13) \quad \mathbb{E} \left[\|\widehat{G}_k^{(b)} - \nabla f(x_k)\|^2 \mid \mathcal{F}_k \right] \leq \frac{\sigma^2}{b}.$$

Bukti. Setelah dikondisikan pada $\mathcal{F}_k$, simpangan setiap sampel mempunyai rerata nol dan pasangan simpangan yang berbeda saling bebas. Semua suku silang dalam kuadrat norma mempunyai ekspektasi nol. Tersisa b suku diagonal yang masing-masing dikalikan b^{-2} . $\square$

Untuk jumlah hingga $f = N^{-1} \sum_{i=1}^N f_i$, pengambilan sampel tanpa penggantian mempunyai koreksi populasi hingga yang tidak boleh disamakan dengan rumus iid.

Proposisi 1.4 (Koreksi populasi hingga). Andaikan $N \geq 2$ dan $1 \leq b \leq N$. Pada suatu x , tuliskan $h_i = \nabla f_i(x) - \nabla f(x)$ dan $V_N = N^{-1} \sum_{i=1}^N \|h_i\|^2$. Jika S dipilih seragam dari semua subhimpunan berukuran b tanpa penggantian, maka

$$(1.14) \quad \mathbb{E} \left\| \frac{1}{b} \sum_{i \in S} \nabla f_i(x) - \nabla f(x) \right\|^2 = \frac{N-b}{b(N-1)} V_N.$$

Bukti. Peluang inklusi satu indeks adalah b/N dan peluang inklusi dua indeks berbeda adalah $b(b-1)/(N(N-1))$. Kembangkan kuadrat norma. Karena $\sum_i h_i = 0$, berlaku $\sum_{i \neq j} \langle h_i, h_j \rangle = -\sum_i \|h_i\|^2$. Substitusi kedua peluang inklusi lalu penyederhanaan memberikan faktor pada (1.14). Khusus $b = N$, varians tepat nol. $\square$

Minibatch menurunkan varians per iterasi, tetapi memakai b evaluasi gradien komponen. Jika biaya serial yang tersedia adalah $T = bK$, batas tertala ideal $\sqrt{2R\sigma}/\sqrt{bK}$ menjadi $\sqrt{2R\sigma}/\sqrt{T}$: tidak ada percepatan kompleksitas oracle hanya dari pengelompokan. Keuntungan nyata dapat datang dari paralelisme, arsitektur perangkat, pengurangan komunikasi, atau batas langkah yang lebih baik. Pernyataan ini juga menjelaskan mengapa perbandingan hanya berdasarkan banyak iterasi dapat menyesatkan.

1.4 PENURUNAN CERMIN STOKASTIK

Proyeksi Euklides memperlakukan semua arah dengan geometri yang sama. Pada simpleks, matriks semidefinit positif, atau ruang dengan struktur sparsitas, pilihan geometri lain dapat lebih alami.

Misalkan $X \subset \mathbb{R}^d$ tak kosong, tertutup, dan konveks. Ambil fungsi pembangkit $h : X \rightarrow \mathbb{R}$ yang bernilai hingga dan kontinu pada X , terdiferensialkan di setiap iterat, dan α -konveks kuat terhadap $\|\cdot\|$. Untuk setiap $x \in X$ dan setiap titik keterdiferensialan y ,

$$(1.15) \quad h(x) \geq h(y) + \langle \nabla h(y), x - y \rangle + \frac{\alpha}{2} \|x - y\|^2.$$

Divergensi Bregman yang dibangkitkan oleh h ialah

$$(1.16) \quad D_h(x, y) = h(x) - h(y) - \langle \nabla h(y), x - y \rangle.$$

Divergensi ini tidak harus simetris dan bukan metrik, tetapi $D_h(x, y) \geq (\alpha/2) \|x - y\|^2$.

Untuk fungsi konveks $\Phi : X \rightarrow \mathbb{R}$, andaikan oracle menghasilkan G_k dengan

$$(1.17) \quad \bar{G}_k := \mathbb{E}[G_k \mid \mathcal{F}_k] \in \partial \Phi(x_k), \quad \mathbb{E}[\|G_k\|_*^2 \mid \mathcal{F}_k] \leq M^2.$$

Ambil $\tau_k > 0$ dan andaikan masalah berikut hampir pasti mencapai peminim unik x_{k+1} pada titik keterdiferensialan h :

$$(1.18) \quad x_{k+1} = \arg \min_{x \in X} \{ \tau_k \langle G_k, x \rangle + D_h(x, x_k) \}.$$

Untuk pembandingan optimum x^* yang dipakai di bawah, andaikan pula $D_h(x^*, x_0) < \infty$. Asumsi eksplisit ini dapat diganti dengan syarat Legendre/interior standar yang menjamin sifat-sifat yang sama.

Algoritma 2: penurunan cermin stokastik. Pilih x_0 dalam daerah terdiferensialkan h . Pada iterasi k , ambil subgradien stokastik G_k , selesaikan masalah Bregman (1.18), dan perbarui rerata berbobot $\sum_j \tau_j x_j / \sum_j \tau_j$.

Lema 1.5 (Ketaksamaan tiga titik stokastik). Untuk setiap $x \in X$, pembaruan (1.18) memenuhi

$$(1.19) \quad \tau_k \langle G_k, x_k - x \rangle \leq D_h(x, x_k) - D_h(x, x_{k+1}) + \frac{\tau_k^2}{2\alpha} \|G_k\|_*^2.$$

Bukti. Kondisi optimalitas pada himpunan X memberi

$$(1.20) \quad \langle \tau_k G_k + \nabla h(x_{k+1}) - \nabla h(x_k), x - x_{k+1} \rangle \geq 0.$$

Identitas tiga titik Bregman mengubah bagian yang memuat h menjadi

$$(1.21) \quad \tau_k \langle G_k, x_{k+1} - x \rangle \leq D_h(x, x_k) - D_h(x, x_{k+1}) - D_h(x_{k+1}, x_k).$$

Tambahkan $\tau_k \langle G_k, x_k - x_{k+1} \rangle$ pada kedua sisi. Gunakan $D_h(x_{k+1}, x_k) \geq (\alpha/2) \|x_{k+1} - x_k\|^2$, dualitas norma, dan ketaksamaan Young. Hasilnya tepat (1.19). $\square$

Teorema 1.6 (Batas ergodik cermin stokastik). Di bawah (1.17), untuk $K \geq 1$ definisikan $S_K = \sum_{k=0}^{K-1} \tau_k$ dan

$$(1.22) \quad \tilde{x}_K = \frac{1}{S_K} \sum_{k=0}^{K-1} \tau_k x_k.$$

Untuk setiap $x^* \in \arg \min_{x \in X} \Phi(x)$,

$$(1.23) \quad \mathbb{E}[\Phi(\tilde{x}_K) - \Phi(x^*)] \leq \frac{D_h(x^*, x_0)}{S_K} + \frac{M^2}{2\alpha} \frac{\sum_{k=0}^{K-1} \tau_k^2}{S_K}.$$

Bukti. Ambil ekspektasi bersyarat pada Lema 1.5. Karena $x_k - x^*$ terukur terhadap $\mathcal{F}_k$ dan $\bar{G}_k \in \partial\Phi(x_k)$,

$$(1.24) \quad \mathbb{E}[\langle G_k, x_k - x^* \rangle \mid \mathcal{F}_k] \geq \Phi(x_k) - \Phi(x^*).$$

Jumlahkan sehingga divergensi Bregman meneleskop, lalu gunakan kekonveksan Φ pada rerata berbobot. $\square$

Untuk $M > 0$ dan $D_h(x^*, x_0) > 0$, gunakan $\tau = \sqrt{2\alpha D_h(x^*, x_0)/(M^2 K)}$. Ruas kanan kemudian menjadi

$$(1.25) \quad M \sqrt{\frac{2D_h(x^*, x_0)}{\alpha K}}.$$

Pada geometri Euklides, $h(x) = \|x\|_2^2/2$ dan pembaruan cermin menjadi subgradien stokastik terproyeksi. Jadi metode cermin memperluas, bukan menduplikasi, teorema stokastik Habring.

1.4.1 SIMPLEKS DAN PEMBARUAN EKSPONENSIAL

Pada simpleks $\Delta_d = \{x \in \mathbb{R}_+^d : \sum_{j=1}^d x_j = 1\}$, ambil $h(x) = \sum_j x_j \log x_j$, dengan konvensi perluasan kontinu $0 \log 0 = 0$. Fungsi ini kontinu pada Δ_d dan terdiferensialkan pada interior relatifnya. Mulai dari $x_{0,j} > 0$. Divergensi Bregman ialah divergensi Kullback–Leibler. Terhadap norma ℓ_1 , fungsi ini 1-konveks kuat. Kondisi optimalitas memberi pembaruan tertutup

$$(1.26) \quad x_{k+1,j} = \frac{x_{k,j} \exp(-\tau_k G_{k,j})}{\sum_{r=1}^d x_{k,r} \exp(-\tau_k G_{k,r})}.$$

Jika x_0 seragam, maka $D_h(x^*, x_0) \leq \log d$. Dengan batas $\|G_k\|_\infty \leq M$, Teorema 1.6 memberi skala $M\sqrt{2 \log(d)/K}$ setelah penalaan ideal. Ketergantungan logaritmik pada dimensi menjelaskan kegunaan geometri entropi di simpleks.

1.5 DARI SAGA KE PEMBARUAN PROKSIMAL

Untuk masalah jumlah hingga $f = N^{-1} \sum_i f_i$, modul Becker 3 mendefinisikan penaksir SAGA

$$(1.27) \quad v_k = \nabla f_{j_k}(x_k) - g_{j_k}^k + \bar{g}_k$$

dan membuktikan $\mathbb{E}[v_k \mid \mathcal{F}_k] = \nabla f(x_k)$. Untuk masalah komposit, perubahan algoritmik yang benar bukan mengurangi subgradien g , melainkan memakai langkah proksimal

$$(1.28) \quad x_{k+1} = \text{prox}_{\tau g}(x_k - \tau v_k).$$

Korolari 1.7 (Penghubung varians untuk Prox-SAGA). *Andaikan asumsi masalah komposit berlaku, $0 < \tau \leq (2L)^{-1}$, dan definisikan*

$$(1.29) \quad \omega_k^2 = \mathbb{E}[\|v_k - \nabla f(x_k)\|^2 \mid \mathcal{F}_k].$$

Untuk $\bar{x}_K = K^{-1} \sum_{k=0}^{K-1} x_{k+1}$ dan $x^* \in X^*$,

$$(1.30) \quad \mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau}{K} \sum_{k=0}^{K-1} \mathbb{E}[\omega_k^2].$$

Jika $\mathbb{E}[\omega_k^2] \leq C\rho^k$ dengan $C \geq 0$ dan $0 < \rho < 1$, maka

$$(1.31) \quad \mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau C}{K(1 - \rho)}.$$

Bukti. Terapkan bukti Teorema 1.2 dengan $G_k = v_k$ dan varians bersyarat ω_k^2 . Untuk klaim terakhir, gunakan jumlah deret geometri hingga yang dibatasi oleh $(1 - \rho)^{-1}$. $\square$

Korolari ini menjelaskan hubungan yang hilang, tetapi sengaja tidak mengklaim bahwa varians SAGA selalu turun geometrik. Pembuktian klaim semacam itu memerlukan fungsi Lyapunov gabungan untuk galat iterat dan galat tabel. Teorema laju linear bersyarat pada modul Becker 3 menyediakan hasil khusus untuk kasus mulus dan konveks kuat; korolari di sini menunjukkan bagaimana penaksir yang sama masuk ke masalah komposit.

1.6 LABORATORIUM 1: REGRESI RENGANG DENGAN BIAYA ORACLE TETAP

Laboratorium terbuka pada `labs/original-01/stochastic-composite-lab.py` membangun masalah regresi kuadrat dengan regularisasi ℓ_1 ,

$$(1.32) \quad F(x) = \frac{1}{2N} \|Ax - y\|_2^2 + \lambda \|x\|_1.$$

Skrip membandingkan gradien proksimal stokastik, minibatch dengan penggantian, dan Prox-SAGA pada anggaran evaluasi gradien komponen yang sama. Referensi numerik dihitung oleh FISTA deterministik sampai norma pemetaan gradien proksimal memenuhi toleransi yang dilaporkan.

Tugas laboratorium:

- (i) jalankan skrip tanpa mengubah benih acak dan verifikasi konfigurasi beku yang dicatat pada berkas hasil;
- (ii) bandingkan kesenjangan objektif terhadap evaluasi gradien komponen, bukan hanya terhadap iterasi;
- (iii) periksa apakah minibatch menurunkan varians arah pada checkpoint yang sama;
- (iv) ubah ukuran minibatch tetapi pertahankan anggaran oracle, lalu jelaskan perbedaan antara keuntungan statistik dan keuntungan paralel;

- (v) ganti λ dan ukur perubahan sparsitas serta norma pemetaan gradien proksimal;
- (vi) laporkan setiap hasil yang bertentangan dengan batas teori beserta asumsi yang mungkin tidak terpenuhi.

CSV dan JSON yang dihasilkan adalah permukaan aksesibel utama. Grafik SVG hanya merupakan bantuan visual dan tidak menjadi satu-satunya pembawa informasi.

Dengan konfigurasi beku ($N = 320$, $d = 40$, $\lambda = 0,03$, 12 epoch, dan 3.840 evaluasi gradien komponen per metode), nilai referensi FISTA adalah 0,31517396778742246 dengan norma pemetaan gradien proksimal $1,49 \times 10^{-15}$. Hasil terminal deterministik adalah:

Metode	Kesenjangan objektif	Norma pemetaan	Tak nol
Proks-SGD, $b = 1$	$4,9169 \times 10^{-2}$	$2,1155 \times 10^{-2}$	33
Proks-minibatch, $b = 16$	$2,5707 \times 10^{-3}$	$9,8630 \times 10^{-3}$	10
Prox-SAGA	$2,0444 \times 10^{-9}$	$9,8666 \times 10^{-6}$	5

Angka tersebut adalah satu eksperimen terkontrol, bukan urutan kinerja universal. Berkas hasil JSON, CSV, dan SVG mempunyai SHA-256 berikut:

```
86ff701a. . . c447
61a6591a. . . 5d37
87c772d9. . . 2830.
```

Identitas lengkap dicatat dalam receipt QA.

1.7 LATIHAN, PETUNJUK, DAN SOLUSI LENGKAP

Latihan 1.8 (Pembaruan proksimal untuk Lasso). Untuk $f(x) = (2N)^{-1}\|Ax - y\|_2^2$ dan $g(x) = \lambda\|x\|_1$, tuliskan pembaruan (1.4) ketika minibatch S_k dipakai. Tunjukkan bahwa setiap koordinat diperoleh dengan ambang lunak.

Petunjuk bertahap. (i) Hitung gradien setiap suku kuadrat. (ii) Gunakan keterpisahan norma ℓ_1 . (iii) Selesaikan masalah proksimal skalar pada tiga kasus tanda.

Solusi lengkap. Jika $f_i(x) = \frac{1}{2}(a_i^\top x - y_i)^2$, maka

$$(1.33) \quad G_k = \frac{1}{|S_k|} \sum_{i \in S_k} a_i(a_i^\top x_k - y_i).$$

Tuliskan $z_k = x_k - \tau_k G_k$. Karena $\text{prox}_{\tau_k \lambda \|\cdot\|_1}$ terpisah per koordinat,

$$(1.34) \quad (x_{k+1})_j = \text{sign}((z_k)_j) \max\{|(z_k)_j| - \tau_k \lambda, 0\}.$$

Rumus ini mengikuti dengan memeriksa kondisi $0 \in u - z + \tau_k \lambda \partial|u|$ pada $u > 0$, $u < 0$, dan $u = 0$.

Latihan 1.9 (Konstanta pada ketaksamaan satu langkah). Mulai dari (1.7). Buktikan batas yang lebih tajam

$$(1.35) \quad \mathbb{E}[F(x_{k+1}) - F(x) \mid \mathcal{F}_k] \leq \frac{\|x_k - x\|^2 - \mathbb{E}\|x_{k+1} - x\|^2}{2\tau} + \frac{\tau v_k^2}{2(1 - L\tau)}$$

untuk $0 < \tau < L^{-1}$.

Petunjuk bertahap. (i) Maksimalkan $-\langle \delta, s \rangle - c\|s\|^2$ terhadap s . (ii) Ambil $c = (1 - L\tau)/(2\tau)$. (iii) Gunakan ketakbiasan hanya setelah memisahkan $x_k - x$.

Solusi lengkap. Dualitas norma Euklides dan pelengkapan kuadrat memberikan

$$(1.36) \quad \sup_s \{-\langle \delta, s \rangle - c\|s\|^2\} = \frac{\|\delta\|^2}{4c} = \frac{\tau\|\delta\|^2}{2(1 - L\tau)}.$$

Suku $-\langle \delta_k, x_k - x \rangle$ mempunyai ekspektasi bersyarat nol. Substitusi batas varians menyelesaikan klaim. Lema utama memakai $\tau L \leq 1/2$ hanya untuk mengganti faktor ini dengan batas sederhana τv_k^2 .

Latihan 1.10 (Sampel tanpa penggantian). Untuk $N \geq 2$, buktikan Proposisi 1.4 dengan peubah indikator $I_i = 1\{i \in S\}$. Periksa kasus $b = 1$ dan $b = N$.

Petunjuk bertahap. (i) Gunakan $\mathbb{E}I_i = b/N$. (ii) Untuk $i \neq j$, gunakan $\mathbb{E}[I_i I_j] = b(b - 1)/(N(N - 1))$. (iii) Pakai $\sum_i h_i = 0$.

Solusi lengkap. Karena $b^{-1} \sum_{i \in S} h_i = b^{-1} \sum_i I_i h_i$, ekspektasi kuadrat normanya adalah

$$(1.37) \quad \frac{1}{b^2} \left[\frac{b}{N} \sum_i \|h_i\|^2 + \frac{b(b - 1)}{N(N - 1)} \sum_{i \neq j} \langle h_i, h_j \rangle \right].$$

Suku silang sama dengan $-\sum_i \|h_i\|^2$. Koefisien akhirnya $(N - b)/(bN(N - 1))$, dan penggantian $\sum_i \|h_i\|^2 = NV_N$ memberi rumus yang diminta. Untuk $b = 1$ faktor menjadi satu; untuk $b = N$ menjadi nol.

Latihan 1.11 (Cermin entropi pada simpleks). Turunkan (1.26) dari (1.18). Jelaskan mengapa iterat yang mulai positif tetap positif dan berjumlah satu.

Petunjuk bertahap. (i) Tambahkan pengali Lagrange untuk $\sum_j x_j = 1$. (ii) Diferensialkan terhadap setiap x_j . (iii) Gunakan kendala jumlah untuk menentukan faktor normalisasi.

Solusi lengkap. Dengan konvensi $0 \log 0 = 0$ dan $D_h(x, x_k) = \sum_j x_j \log(x_j/x_{k,j})$ pada simpleks, kondisi stasioner adalah

$$(1.38) \quad \tau_k G_{k,j} + \log(x_j/x_{k,j}) + 1 + \eta = 0.$$

Jadi $x_j = x_{k,j} \exp(-\tau_k G_{k,j}) \exp(-1 - \eta)$. Menjumlahkan seluruh koordinat menunjukkan bahwa faktor terakhir adalah kebalikan jumlah pada penyebut (1.26). Eksponensial dan penyebut positif mempertahankan kepositifan, sedangkan normalisasi mempertahankan jumlah satu.

Latihan 1.12 (Anggaran oracle dan ukuran minibatch). Andaikan batas tertala ideal adalah $\sqrt{2}R\sigma/\sqrt{bK}$ dan satu iterasi minibatch memakai b evaluasi gradien komponen. Untuk anggaran serial $T = bK$, tentukan ketergantungannya pada b . Sebutkan dua keadaan ketika minibatch tetap berguna.

Petunjuk bertahap. (i) Ganti K dengan T/b . (ii) Bedakan waktu dinding dari jumlah panggilan oracle. (iii) Perhatikan pengambilan sampel tanpa penggantian.

Solusi lengkap. Substitusi memberi

$$(1.39) \quad \frac{\sqrt{2}R\sigma}{\sqrt{b(T/b)}} = \frac{\sqrt{2}R\sigma}{\sqrt{T}},$$

yang bebas dari b . Jadi model ideal tidak memprediksi penghematan evaluasi gradien serial. Minibatch tetap berguna jika evaluasi dapat diparalelkan atau komunikasi dapat di-amortisasi; ia juga dapat membantu melalui koreksi populasi hingga tanpa penggantian, vektorisasi perangkat, atau batas langkah yang tidak tercakup dalam model sederhana.

Latihan 1.13 (Varians yang menyusut pada Prox-SAGA). Mulai dari (1.30). Jika $\mathbb{E}\omega_k^2 \leq C/(k+1)$, turunkan batas eksplisit menggunakan bilangan harmonik $H_K = \sum_{j=1}^K j^{-1}$. Bandingkan dengan kasus geometrik.

Petunjuk bertahap. (i) Jumlahkan batas varians. (ii) Gunakan $H_K \leq 1 + \log K$. (iii) Jangan menyimpulkan laju iterat terakhir dari batas ergodik.

Solusi lengkap. Substitusi langsung memberi

$$(1.40) \quad \mathbb{E}[F(\bar{x}_K) - F(x^*)] \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau CH_K}{K} \leq \frac{\|x_0 - x^*\|^2}{2\tau K} + \frac{\tau C(1 + \log K)}{K}.$$

Peluruhan geometrik menjadikan jumlah varians terbatas secara seragam dan menghasilkan $\mathcal{O}(1/K)$ tanpa faktor logaritmik. Kedua kesimpulan hanya berlaku untuk rerata $\bar{x}_K$ dalam korolari ini; laju iterat terakhir memerlukan analisis tambahan.

1.8 PETA ASUMSI DAN BATAS KLAIM

Hasil	Asumsi penentu	Yang tidak diklaim
Proksimal stokastik	f konveks dan L -mulus; g proper, tertutup, konveks; oracle tak bias; varians terbatas	laju iterat terakhir atau konvergensi nonkonveks
Minibatch iid	sampel bersyarat bebas dengan penggantian	koreksi populasi hingga
Minibatch tanpa penggantian	subhimpunan seragam berukuran $1 \leq b \leq N$ dari populasi dengan $N \geq 2$	independensi antaranggota batch
Cermin stokastik	pembangkit α -konveks kuat; pembaruan terdefinisi; $D_h(x^*, x_0) < \infty$; momen dual kedua terbatas	simetri divergensi Bregman
Prox-SAGA penghubung	ketakbiasan SAGA dan kontrol varians yang dinyatakan	peluruhan geometrik varians tanpa Lyapunov

Bab ini tidak membahas ketaksamaan variasional atau operator monoton maksimal; materi tersebut adalah tranche asli berikutnya. Bab ini juga tidak mengulang LP/MIP, simpleks sebagai algoritma pemrograman linear, dualitas LP, sensitivitas LP, jaringan, atau optimisasi diskret yang merupakan cakupan Oo18. Kata *simpleks* di sini hanya menunjuk himpunan probabilitas Δ_d .

RUJUKAN MATEMATIS DAN SAKSI VERIFIKASI

- Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1, khususnya operator proksimal dan subgradien stokastik.
- Clément W. Royer, *Lecture Notes on Stochastic Gradient Methods*, edisi 2023/2024, khususnya pembahasan minibatch dan biaya epoch; dipakai sebagai saksi perbandingan, bukan sumber prosa bab ini.
- Lorenzo Rosasco, Silvia Villa, dan Bang Công Vũ, *Convergence of Stochastic Proximal Gradient Algorithm*, arXiv:1403.5074, sebagai rujukan primer bagi keluarga metode proksimal stokastik.
- Amir Beck dan Marc Teboulle, *Mirror Descent and Nonlinear Projected Subgradient Methods for Convex Optimization*, *Operations Research Letters* 31 (2003), 167–175, DOI:10.1016/S0167-6377(02)00231-6.

- Aaron Defazio, Francis Bach, dan Simon Lacoste-Julien, *SAGA: A Fast Incremental Gradient Method With Support for Non-Strongly Convex Composite Objectives*, arXiv:1407.0202v3.

HAK, ATRIBUSI, DAN NONDUKUNGAN

Materi asli dalam tranche ini—termasuk uraian, formulasi penghubung, bukti, algoritma, latihan, petunjuk, solusi, laboratorium, dan dokumentasi—tersedia berdasarkan Creative Commons Attribution-ShareAlike 4.0 International (CC BY-SA 4.0), melalui [laman lisensi resmi](#).

Kelas dokumen `shinybook.cls` adalah salinan persis kelas yang dibundel bersama Andreas Habring, *Lecture Notes: Convex Optimization*, arXiv:2607.11664v1; `macros-id.tex` adalah adaptasi Indonesia dari `macros.tex` dalam paket yang sama. Kedua komponen itu tersedia berdasarkan bukti lisensi Creative Commons Attribution 4.0 International (CC BY 4.0) pada tingkat kiriman arXiv, melalui [laman lisensi resmi](#), dan bukan bagian dari lisensi CC BY-SA untuk materi baru. Berkas kelas itu tidak memuat pemberitahuan lisensi terpisah. Prakata Habring menyatakan bahwa templat catatan kuliah tersebut berasal dari Christian Clason; kredit templat itu dipertahankan tanpa menyiratkan dukungan.

Saksi verifikasi yang dirujuk meliputi karya Andreas Habring, Clément W. Royer, Lorenzo Rosasco, Silvia Villa, Bang Công Vũ, Amir Beck, Marc Teboulle, Stephen Becker, Mitchell Krock, Aaron Defazio, Francis Bach, dan Simon Lacoste-Julien. Penyebutan mereka hanya untuk atribusi matematika dan provenans. Tidak seorang pun dari mereka maupun institusinya menyusun, memeriksa, menyetujui, mensponsori, atau mendukung edisi ini.

CATATAN AKSESIBILITAS

PDF ini dapat dicari, memakai bahasa dokumen id-ID, dan merupakan permukaan tata letak tetap. HTML semantik dan EPUB reflow menyediakan permukaan baca yang lebih sesuai untuk pembesaran, layar sempit, dan teknologi bantu. Hasil laboratorium tersedia dalam CSV dan JSON sehingga informasi angka tidak bergantung pada grafik.